

Pipeline House — Transactions boursières des représentants

Pilote « Test » du 1^{er} trimestre 2025 — synthèse complète

25 juin 2026

1 Objectif & résultat à utiliser

Objectif. Extraire *toutes* les transactions boursières déclarées par les membres de la Chambre des représentants pour le 1^{er} trimestre 2025, à partir des PDF officiels du *House Clerk*, puis valider leur exactitude contre une source indépendante (QuiverQuant). Deux extractions complémentaires — texte (PDF lisibles) et vision (PDF scannés) — sont fusionnées en une table unique.

Le résultat à utiliser.


- `data_v1/tables/06_house_2025q1_transactions_FINAL.csv` — la table complète : **2 272 transactions** (1 105 électroniques + 1 167 OCR).
- `data_v1/tables/house_2025q1_FINAL.xlsx` — même contenu + onglets synthèse, validation et QA (rendu portable).

Table des matières

1	Objectif & résultat à utiliser	1
2	Vue d'ensemble	2
3	D'où viennent les données	2
4	Le pipeline en détail	3
4.1	Étape 1 — PDF électroniques (lisibles)	3
4.2	Étape 2 — PDF scannés (OCR), enrichissement et fusion	3
5	Statistiques de sortie	4
6	Validation contre QuiverQuant	4
7	Limites connues (honnêteté)	5
8	Schéma des colonnes (table finale)	6
9	Reproductibilité & fichiers	6

2 Vue d'ensemble

Le flux en un schéma



Les chiffres en un coup d'œil

Indicateur	Valeur
PTR (dépôts) traités	117
PDF lisibles / scannés	100 / 17
Représentants uniques	66
Transactions finales	2 272
dont électroniques / OCR	1 105 / 1 167
Couverture ticker	90,4 %
Couverture asset_type	97,2 %
Montant renseigné	99,96 % (1 ligne manquante)
Volume déclaré (mi-fourchette)	≈ 107 016 376 \$
Période (date de transaction)	25/11/2024 → 25/03/2025
Échecs d'extraction	0

À savoir (vocabulaire).

- **PTR** = *Periodic Transaction Report* : déclaration obligatoire d'une transaction.
- **T1 2025** = transactions *divulguées* au 1^{er} trimestre 2025.
- **OCR** = lecture d'un PDF scanné (image) par un modèle de vision (Claude Vision).

3 D'où viennent les données

Quatre sources. **Trois construisent les données ; une seule valide** (QuiverQuant n'est jamais utilisé pour extraire ni pour remplir un champ).

Source	Rôle	Accès
House Clerk — ZIP annuel	Index XML de tous les PTR	<code>disclosures-clerk.house.gov/.../2025FD.zip</code>
House Clerk — PDF	Les 117 PTR (le contenu)	<code>.../ptr-pdfs/2025/{doc_id}.pdf</code>
unitedstates.github.io	Référentiel des élus (identité, parti, comités)	Fichiers JSON <code>legislators / committees</code>
QuiverQuant (API + extrait local)	Validation seulement	<code>api.quiverquant.com/beta/bulk/congresstrading</code> ; copie <code>data_v1/external/</code>

4 Le pipeline en détail

En amont (commun aux deux étapes)

1. Construire le référentiel des élus (bioguide, parti, comités clés) → `01_ref_universe.csv` (12 767) et `02_ref_house_key.csv` (126 ; comités Financial / Armed / Intelligence).
2. Télécharger l'index des PTR et filtrer la fenêtre T1 2025 → `03_ptr_index.csv` (117).
3. Télécharger chaque PDF, tester s'il contient du texte (`has_text`), et le trier : **lisible** ou **scanné** → `04_download_manifest.csv` (117 → 100 / 17).

4.1 Étape 1 — PDF électroniques (lisibles)

100 PDF contenant du texte sélectionnable.

- Extraction du texte (`pdfplumber`).
- Parsing par expressions régulières : type d'opération, dates, ticker, montant, propriétaire.
- Gestion des lignes coupées sur plusieurs lignes (continuation).
- Jointure à l'identité du déposant (bioguide).

Résultat : `06_house_2025q1_transactions.csv` — **1 105 transactions**. **0 échec** de parsing (`05_parse_failures.csv` vide).

4.2 Étape 2 — PDF scannés (OCR), enrichissement et fusion

17 PDF sans texte (images), lus par **Claude Vision** (`claude-sonnet-4-6`).

- Chaque PDF → images (DPI 200) → lecture par lots ; **sortie structurée forcée** (`tool_use` sur `record_transactions`, champs validés) — pas de JSON fragile.
- **Cache versionné** (par `doc_id` + empreinte du prompt) : un re-run sans changement ne rappelle pas l'API (gratuit).
- **Filtre de la ligne-exemple** pré-imprimée sur les formulaires (« Example Mega Corp »), écartée systématiquement.
- **Enrichissement ticker en 3 passes tracées** (`ticker_source`) : **explicit** (présent dans le nom), **elec_dict** (dictionnaire bâti sur les lignes électroniques tickées), puis **passé LLM** (Claude nom→ticker, sortie structurée, cache versionné `ticker_llm_cache.json` ; **228 / 310** noms résolus) ; plus `asset_type` par règles.
- **Déduplication inter-sources uniquement** : les répétitions réelles intra-OCR (vrais trades répétés) sont conservées.

Résultats : `06b_house_2025q1_ocr_transactions.csv` (1 167) puis **fusion** → `06_house_2025q1_transactions_FINAL.csv` — **2 272 transactions**. **0 échec** de lot (`06c_ocr_failures.csv` vide) ; packaging `house_2025q1_FINAL.xlsx`.

La passe LLM ticker, en bref. Le dictionnaire électronique plafonnait la couverture ticker OCR à 46 % (il ne connaît que les noms déjà tradés en électronique). La passe LLM résout les grandes valeurs cotées absentes du dictionnaire → **OCR 46 % → 90 %**, auditée à **93 %** contre Quiver. Quiver n'est jamais utilisé pour remplir le ticker.

5 Statistiques de sortie

Volumétrie et complétude

Champ	Couverture
Transactions totales	2 272
électroniques / OCR	1 105 / 1 167
ticker (global)	2 053 / 2 272 = 90,4 %
dont électronique	998 / 1 105 $\approx$ 90 %
dont OCR	1 055 / 1 167 = 90,4 %
asset_type (global)	2 208 / 2 272 = 97,2 %
Montant renseigné	2 271 / 2 272 = 99,96 %
Volume total (Σ mi-fourchette)	107 016 376 \$

ticker_source (côté OCR, 1 167) : *explicit* 23 · *elec_dict* 517 · *llm* 515 · *none* 112.

Répartition par type d'opération

Opération	Nombre	Part
Achat (Purchase)	1 206	53,1 %
Vente (Sale)	791	34,8 %
Vente partielle (Sale partial)	209	9,2 %
Vente partielle (Partial Sale)	61	2,7 %
Échange (Exchange)	5	0,2 %
Total	2 272	100 %

Top 10 des déposants (par nombre de transactions)

Représentant	Transactions
Rohit Khanna	1 036
Rob Bresnahan	235
Josh Gottheimer	186
Julie Johnson	99
Gilbert Cisneros	82
Michael T. McCaul	82
Jefferson Shreve	67
Marjorie Taylor Greene	65
Tim Moore	46
April McClain Delaney	37

Note : Khanna pèse à lui seul $\approx$ 45,6 % du total (1 036 / 2 272), entièrement via OCR. C'est un cas réel (confirmé par Quiver et par contrôle visuel page à page), pas une anomalie — voir section 7.

6 Validation contre QuiverQuant

Quiver, c'est quoi ? Une base **indépendante** qui recense les mêmes transactions du Congrès. Elle sert ici d'**arbitre** : nos chiffres sont-ils justes et complets ? Comparaison **par déposant**, fenêtre alignée sur la *date de divulgation*.

Côté électronique (56 déposants comparés)

Résultat	Déposants
Match exact ($\Delta = 0$)	26
Nous > Quiver	30
Quiver > Nous	0
Total transactions — nous	1 105
Total transactions — Quiver	980

Exemples : Bresnahan 235/234 · Gottheimer 186/182 · M. T. Greene 65/59 · Tim Moore 46/31 · Julie Johnson 99/99.

Côté OCR (10 déposants concernés)

Déposant	docs	OCR	Quiver	Verdict
Rohit Khanna	2	1 036	756	OCR $\geq$ Quiver
Michael T. McCaul	1	82	56	OCR $\geq$ Quiver
Chuck Fleischmann	1	21	13	OCR $\geq$ Quiver
Tony Wied	2	11	4	OCR $\geq$ Quiver
Keith Self	1	5	0	Quiver sans donnée
Vicente Gonzalez	2	3	0	Quiver sans donnée
Brad Sherman	3	3	0	Quiver sans donnée
Gus Bilirakis	1	2	0	Quiver sans donnée
Adrian Smith	1	2	0	Quiver sans donnée
Ann Wagner	1	2	0	Quiver sans donnée

Audit de la passe LLM ticker (06e_ticker_llm_audit.csv)

Sur 500 tickers LLM rapprochables d'un couple (déposant, nom) de Quiver : **466 concordants = 93 %**. Les 34 écarts sont en majorité des **artefacts Quiver** (parts préférentielles -PA/-PG, société voisine : AIG/AFG, VRTX/VERX) où notre ticker d'action ordinaire est le bon.

À retenir. **Aucun cas** où Quiver a *plus* de transactions que nous (ni en électronique, ni en OCR). Là où nous avons plus, vérification visuelle faite : c'est **Quiver qui sous-recense** les dépôts papier denses. **0 échec d'extraction** ; **1 seule anomalie QA** signalée (Bilirakis, montant illisible).

7 Limites connues (honnêteté)

- **Gonzalez — 1 PTR sur 2 manqué.** Il a déposé **deux** PTR scannés. Le doc 8220796 est bien capté (3 transactions : HSBC, et TESLA acheté les 01/03 et 12/03). Le doc 8220809 est un **formulaire très pâle** : le modèle n'a lu que la *ligne-exemple* (filtrée) → **0 ligne** extraite, sa transaction réelle (vente TESLA $\approx$ 17/03) est **manquée**. Quiver = 0 sur ce déposant, donc pas de référence externe.
- **Bilirakis.** 1 ligne (« GE Vernova », doc 8220747) avec montant et date illisibles. Conservée mais incomplète — **c'est le seul drapeau QA** de tout le pipeline.
- **asset_type non harmonisé.** Le champ est rempli à 97,2 %, mais **hétérogène entre sources** : côté électronique, $\approx$ 39 lignes portent les *codes bruts* du formulaire (CT = crypto comme Ethereum / memecoins, CS = notes corporate ou titres adossés, HN / PS / OL), non normalisés vers les libellés (Stock, Mutual Fund, ...).
- **Ticker OCR résiduel ($\approx$ 10 %).** Les noms laissés vides sont des actifs **non cotés** (produits structurés, perpétuelles, options) ou des noms trop dégradés par l'OCR — laissés vides à dessein, jamais devinés.

- **47 doublons exacts (Khanna), conservés.** Ses déclarations couvrent plusieurs **trusts familiaux** (Ahuja/Khanna) passant le même ordre le même jour, tous codés sous le même propriétaire → la même clé apparaît légitimement N fois (réel, confirmé page à page : Salesforce 27/02 ×4). Dédupliquer serait **destructeur**; une minorité d’artefacts OCR subsistent, non séparables automatiquement ($\approx 0,1\text{--}0,5\%$, confinés à Khanna).

8 Schéma des colonnes (table finale)

22 colonnes, regroupées :

- **Identité (7)** : `bioguide_id`, `declarant_name`, `chamber`, `party`, `state_district`, `committee_membership`, `committees_key_flag`.
- **Dates (2)** : `transaction_date`, `disclosure_date`.
- **Actif (3)** : `ticker`, `asset_description`, `asset_type`.
- **Opération & montant (4)** : `operation_type`, `amount_range`, `amount_midpoint`, `amount_split_flag`.
- **Traçabilité (6)** : `owner`, `doc_id`, `source_url`, `natural_key_hash`, `provenance` (house-pdf-electronic ou house-pdf-ocr), `ticker_source` (explicit / elec_dict / llm / none; vide pour les lignes électroniques).

9 Reproductibilité & fichiers

Environnement autonome

Tout est contenu dans le dossier `2025_test/` :

- `.venv` local + kernel `jupyter-house-2025test` (via `requirements.txt` : `anthropic 0.112.0`, `pandas 3.0.3`, `pdfplumber 0.11.10`, `pymupdf 1.27.2.3`, `python-dotenv 1.2.2`, `openpyxl 3.1.5`, `requests 2.34.2`, + `ipykernel` / `nbconvert`).
- Clés dans `.env` local (`ANTHROPIC_API_KEY` + `QUIVER_API_KEY`; gabarit `.env.example`).
- Quiver embarqué : `data_v1/external/quiver_congress_trading_2025.csv`.
- Chemins ancrés par `BASE_DIR` (indépendant du répertoire de lancement).

Comment relancer

1. **Étape 1** : `notebook_v1_house_2025q1.ipynb` (électronique) → référentiels, index, téléchargement/tri, parsing texte (06, 07).
2. **Étape 2** : `notebook_v1_house_2025q1_ocr.ipynb` (OCR) → extraction vision, enrichissement (dont passe LLM ticker), fusion → `..._FINAL.csv`, validation (06*d*), audit (06*e*), `house_2025q1_FINAL.xlsx`.

Les caches (`data_v1/ocr_cache/`, `data_v1/ticker_llm_cache.json`) sont versionnés : sans changement de prompt, le re-run est gratuit (aucun appel API).

Carte des fichiers (data_v1/)

Fichier	Rôle
tables/01_ref_universe.csv (12 767)	Tous les législateurs (lookup bioguide)
tables/02_ref_house_key.csv (126)	Membres des comités clés
tables/03_ptr_index.csv (117)	Index des PTR T1 2025
tables/04_download_manifest.csv (117)	Téléchargement + has_text (lisible/scanné)
tables/05_parse_failures.csv	PDF lisibles non parsés — vide = 0 échec
tables/06_house_2025q1_transactions.csv (1 105)	Transactions électroniques
tables/06b_ocr_transactions.csv (1 167)	Transactions OCR
tables/06_transactions_FINAL.csv (2 272)	Table complète (à utiliser)
tables/house_2025q1_FINAL.xlsx	Classeur Excel (transactions + synthèse + validation + QA)
tables/06c_ocr_failures.csv	Échecs OCR — vide = 0
tables/06c_ocr_qa_flags.csv (1)	Anomalies de cohérence OCR
tables/06d_ocr_quiver_comparison.csv (10)	Comparaison OCR ↔ Quiver
tables/06e_ticker_llm_audit.csv (500)	Audit des tickers LLM ↔ Quiver
tables/07_quiver_comparison.csv (56)	Comparaison électronique ↔ Quiver
pdfs/lisibles_parses/ (100)	· PDF source
non_lisibles/ (17)	
ocr_cache/ (17)	· Caches versionnés
ticker_llm_cache.json	
external/quiver_congress_trading_2025.csv	· Quiver embarqué (validation/audit)

Les fichiers/dossiers **vides** (05_parse_failures.csv, 06c_ocr_failures.csv) sont des **marqueurs « 0 échec »** — résultat attendu, pas du bruit.

Message en une ligne. Pipeline complet sur le T1 2025 (117 PTR → 2 272 transactions), **double extraction** (texte + OCR vision) + **passé LLM ticker** (couverture → 90 %), **0 échec**, et **validé** contre une source indépendante : nos données sont **au moins aussi complètes que Quiver partout**.