

Pipeline House — Transactions boursières des représentants

Pilote « Test » du 1^{er} trimestre 2025 — note de synthèse

25 juin 2026

Objectif. Extraire toutes les transactions boursières déclarées par les membres de la Chambre des représentants pour le 1^{er} trimestre 2025, à partir des PDF officiels du *House Clerk*. Puis valider leur exactitude contre une source indépendante (QuiverQuant).

Le résultat à utiliser.


- `data_v1/tables/06_house_2025q1_transactions_FINAL.csv` — la table complète : **2 272 transactions** (1 105 électroniques + 1 167 OCR).
- `data_v1/tables/house_2025q1_FINAL.xlsx` — même contenu + onglets synthèse, validation et QA (version portable).

Table des matières

1	Vue d'ensemble	2
2	D'où viennent les données	2
3	Le pipeline en 2 étapes	3
3.1	Étape 1 — PDF électroniques (lisibles)	3
3.2	Étape 2 — PDF scannés (OCR) + fusion	3
4	Statistiques de sortie	4
5	Validation contre QuiverQuant	4
6	Limites connues (honnêteté)	5
7	Schéma des colonnes (table finale)	5
8	Fichiers & reproductibilité	6

1 Vue d'ensemble

Le flux en un schéma



Les chiffres en un coup d'œil

Indicateur	Valeur
PTR (dépôts) traités	117
PDF lisibles / scannés	100 / 17
Représentants uniques	66
Transactions finales	2 272
dont électroniques / OCR	1 105 / 1 167
Couverture ticker	67,7 %
Couverture asset_type	97,2 %
Volume déclaré (mi-fourchette)	≈ 107 M\$
Période (date de transaction)	25/11/2024 → 25/03/2025
Échecs d'extraction	0

À savoir (vocabulaire).

- **PTR** = *Periodic Transaction Report* : déclaration obligatoire d'une transaction.
- **T1 2025** = transactions *divulguées* au 1^{er} trimestre 2025.
- **OCR** = lecture d'un PDF scanné (image) par un modèle de vision (Claude Vision).

2 D'où viennent les données

Quatre sources. **Trois servent à construire les données ; une seule sert à valider** (QuiverQuant n'est jamais utilisé pour extraire).

Source	Rôle	Accès
House Clerk — ZIP annuel	Index XML de tous les PTR	<code>disclosures-clerk.house.gov/.../2025FD.zip</code>
House Clerk — PDF	Les 117 PTR (le contenu)	<code>.../ptr-pdfs/2025/{doc_id}.pdf</code>
<code>unitedstates.github.io</code>	Référentiel des élus (identité, parti, comités)	Fichiers JSON <code>legislators / committees</code>
QuiverQuant (API)	Validation seulement	<code>api.quiverquant.com/beta/bulk/congresstrading</code>

3 Le pipeline en 2 étapes

En amont (commun aux deux étapes)

1. Construire le référentiel des élus (bioguide, parti, comités clés) → `01_ref_universe.csv` (12 767) et `02_ref_house_key.csv` (126).
2. Télécharger l'index des PTR et filtrer la fenêtre T1 2025 → `03_ptr_index.csv` (117).
3. Télécharger chaque PDF, tester s'il contient du texte (`has_text`), et le trier : **lisible** ou **scanné** → `04_download_manifest.csv` (117).

3.1 Étape 1 — PDF électroniques (lisibles)

100 PDF contenant du texte sélectionnable.

- Extraction du texte (`pdfplumber`).
- Parsing par expressions régulières : type d'opération, dates, ticker, montant, propriétaire.
- Gestion des lignes coupées sur plusieurs lignes (continuation).
- Jointure à l'identité du déposant (bioguide).

Résultat : `06_house_2025q1_transactions.csv` — **1 105 transactions**. **0 échec** de parsing (`05_parse_failures.csv` vide).

3.2 Étape 2 — PDF scannés (OCR) + fusion

17 PDF sans texte (images). Lus par **Claude Vision**.

- Chaque PDF → images → lecture par lots; **sortie structurée forcée** (`tool_use`, champs validés) — pas de JSON fragile dans du texte.
- **Cache versionné** (par `doc_id` + empreinte du prompt) : un re-run sans changement ne rappelle pas l'API (gratuit).
- **Filtre de la ligne-exemple** pré-imprimée sur les formulaires (« Example Mega Corp »), écartée systématiquement.
- **Enrichissement** : `ticker` (depuis le nom, ou dictionnaire bâti sur l'étape 1) et `asset_type`; traçabilité via `ticker_source`.
- **Déduplication inter-sources uniquement** : les répétitions réelles d'un même déposant (vrais trades répétés) sont conservées.

Résultats : `06b_house_2025q1_ocr_transactions.csv` (1 167) puis **fusion** → `06_house_2025q1_transactions_FINAL.csv` — **2 272 transactions**. **0 échec** de lot (`06c_ocr_failures.csv` vide).

4 Statistiques de sortie

Volumétrie et complétude

Champ	Couverture
Transactions totales	2 272
électroniques / OCR	1 105 / 1 167
ticker (global)	1 538 / 2 272 = 67,7 %
dont électronique	≈ 90 %
dont OCR	540 / 1 167 = 46 %
asset_type (global)	2 208 / 2 272 = 97,2 %
Montant renseigné	≈ 100 % (1 ligne manquante)
Volume total (Σ mi-fourchette)	107 016 376 \$

Répartition par type d'opération

Opération	Nombre	Part
Achat (Purchase)	1 206	53,1 %
Vente (Sale)	791	34,8 %
Vente partielle (Sale partial)	209	9,2 %
Vente partielle (Partial Sale)	61	2,7 %
Échange (Exchange)	5	0,2 %
Total	2 272	100 %

Top 10 des déposants (par nombre de transactions)

Représentant	Transactions
Rohit Khanna	1 036
Rob Bresnahan	235
Josh Gottheimer	186
Julie Johnson	99
Gilbert Cisneros	82
Michael T. McCaul	82
Jefferson Shreve	67
Marjorie Taylor Greene	65
Tim Moore	46
April McClain Delaney	37

Note : Khanna pèse à lui seul ≈ 46 % du total (1 036 / 2 272), entièrement via OCR. C'est un cas réel, pas une anomalie (voir section 5).

5 Validation contre QuiverQuant

Quiver, c'est quoi ? QuiverQuant est une base **indépendante** qui recense les mêmes transactions du Congrès. Elle sert ici d'**arbitre** : nos chiffres sont-ils justes et complets ?

Méthode. Comparaison **par déposant** (nous *vs* Quiver). Fenêtre alignée sur la *date de divulgation* (sinon on comparerait des périodes différentes).

Côté électronique (56 déposants comparés)

Résultat	Déposants
Match exact ($\Delta = 0$)	26
Nous > Quiver	30
Quiver > Nous	0
Total transactions — nous	1 105
Total transactions — Quiver	980

Quelques exemples : Bresnahan 235/234 (+1) · Gottheimer 186/182 (+4) · M. T. Greene 65/59 (+6)
 · Tim Moore 46/31 (+15) · Julie Johnson 99/99 (0).

Côté OCR (10 déposants concernés)

Déposant	docs	OCR	Quiver	Verdict
Rohit Khanna	2	1 036	756	OCR $\geq$ Quiver
Michael T. McCaul	1	82	56	OCR $\geq$ Quiver
Chuck Fleischmann	1	21	13	OCR $\geq$ Quiver
Tony Wied	2	11	4	OCR $\geq$ Quiver
Keith Self	1	5	0	Quiver sans donnée
Vicente Gonzalez	1	3	0	Quiver sans donnée
Brad Sherman	3	3	0	Quiver sans donnée
Gus Bilirakis	1	2	0	Quiver sans donnée
Adrian Smith	1	2	0	Quiver sans donnée
Ann Wagner	1	2	0	Quiver sans donnée

À retenir. Aucun cas où Quiver a *plus* de transactions que nous (ni en électronique, ni en OCR). Là où nous avons plus, vérification visuelle faite : c'est **Quiver qui sous-recense** les dépôts papier denses (et fusionne des trades répétés réels). **0 échec d'extraction ; 1 seule anomalie** signalée (Bilirakis, montant illisible).

6 Limites connues (honnêteté)

- **Gonzalez** : 1 transaction (TESLA, vente du 17/03/25) **manquée** sur un formulaire très pâle. Quiver = 0 sur ce déposant, donc pas de référence externe.
- **Bilirakis** : 1 ligne (« GE Vernova ») avec montant/date illisibles. Conservée mais incomplète — c'est le seul drapeau QA.
- **Ticker OCR plafonné à 46 %** : limite du dictionnaire électronique + fautes de lecture OCR sur certains noms.
- **Surplus Khanna** (+280 vs Quiver) : cohérent avec les contrôles visuels, mais **non audité ligne à ligne** (formulaire de 34 pages).

7 Schéma des colonnes (table finale)

22 colonnes, regroupées :

- **Identité (7)** : bioguide_id, declarant_name, chamber, party, state_district, committee_membership, committees_key_flag.
- **Dates (2)** : transaction_date, disclosure_date.
- **Actif (3)** : ticker, asset_description, asset_type.
- **Opération & montant (4)** : operation_type, amount_range, amount_midpoint, amount_split_flag.

- **Traçabilité (6)** : owner, doc_id, source_url, natural_key_hash, provenance (electronic ou ocr), ticker_source (origine du ticker OCR).

8 Fichiers & reproductibilité

- **À utiliser** : 06_house_2025q1_transactions_FINAL.csv · house_2025q1_FINAL.xlsx.
- **Étapes** : notebook_v1_house_2025q1.ipynb (électronique) · notebook_v1_house_2025q1_ocr.ipynb (OCR + fusion).
- **Validation / QA** : 07_quiver_comparison.csv (élec, 56) · 06d_ocr_quiver_comparison.csv (OCR, 10) · 06c_ocr_qa_flags.csv (1).
- **Marqueurs « 0 échec »** (fichiers vides = succès attendu) : 05_parse_failures.csv · 06c_ocr_failures.csv.
- **Environnement** : semaine 1/.venv (kernel jupyter-house-ocr); clés ANTHROPIC_API_KEY + QUIVER_API_KEY.

Message à retenir en une ligne. Pipeline complet sur le T1 2025 (117 PTR → 2 272 transactions), **double extraction** (texte + OCR vision), **0 échec**, et **validé** contre une source indépendante : nos données sont **au moins aussi complètes que Quiver partout**.