

Pipeline House — Transactions boursières des représentants

Volume 2 : années 2020→2026 (électronique) + OCR par échantillon

25 juin 2026

suite du pilote « Test » du 1^{er} trimestre 2025

1 Ce document est la suite du pilote 2025

À lire d’abord. Ce document est le **Volume 2**. Le pilote `../2025_test/` (T1 2025) a déjà décrit *toute la méthodologie* ; on ne la répète pas ici. On y **renvoie** pour : le vocabulaire (PTR, OCR, Quiver), la mécanique du pipeline (`pdfplumber` + regex ; OCR Claude Vision en sortie structurée ; cache versionné), le *mécanisme* de la passe LLM nom→ticker, le schéma des 22 colonnes et le dictionnaire `provenance/ticker_source`.


Ce volume couvre uniquement le **nouveau** : (1) le passage à l’échelle de l’extraction **électronique sur 2020→2026 (totale)**, validée contre Quiver année par année ; (2) l’**OCR repensé** — recensement complet des 547 PDF scannés, puis OCR d’un **échantillon représentatif par année** (et non des 547), comparé à Quiver. Tous les chiffres sont recalculés depuis `data_v1/`.

Table des matières

1	Ce document est la suite du pilote 2025	1
2	Vue d’ensemble (Volume 2)	2
3	Électronique 2020→2026 (extraction totale)	2
4	L’OCR repensé : census des scannés + échantillon par année	3
4.1	Census complet des 547 PDF scannés	3
4.2	Décision : un échantillon représentatif par année (pas les 547)	3
4.3	Résultats de l’échantillon	3
5	Limites connues (honnêteté)	4
6	Reproductibilité & fichiers	4

2 Vue d'ensemble (Volume 2)

Le flux en un schéma



Les chiffres en un coup d'œil

Indicateur	Valeur
Période	2020 → 2026 (7 années)
Transactions électroniques (TOTAL)	32 676
Concordance Quiver (élec, transaction)	99,01 %
Trades « vraiment absents » (élec, 6 ans)	9
PDF scannés recensés (census)	547
clusters A / B / C	74 / 322 / 151
OCR : échantillon traité	70 docs (10/an)
transactions OCR (échantillon)	4 596
couverture ticker (avec passe LLM)	78 %

3 Électronique 2020→2026 (extraction totale)

Les PDF lisibles de chaque année sont parsés et figés dans 06_house_{année}_transactions.csv. La concordance ci-dessous est mesurée par la **méthode honnête « standard Q1 »** (dédup des amendements Quiver, exclusion des déposants papier des deux côtés, cross-check « ticker raté » vs « vraiment absent » ; cf. *pilote 2025 pour le détail*). Reproduite par `notebook_digital.ipynb`.

Année	txns	déclarants	ticker %	concordance Quiver	vrais-absents
2020	6 886	96	91,0	99,71 %	0
2021	5 457	105	91,1	99,68 %	1
2022	3 601	97	86,8	98,88 %	0
2023	4 161	88	86,9	98,10 %	3
2024	2 694	90	81,8	98,01 %	2
2025	7 577	96	90,5	98,93 %	1
2026	2 300	79	84,0	98,64 %	2
Total	32 676	—	88,6	99,01 %	9

Lecture de l'écart. Sur 6 ans, **only-Quiver** = 241 trades, dont **232 « ticker-raté »** (présents chez nous mais sans ticker boursier extrait : préférentielles, Trésor, fonds) et seulement **9 « vraiment absents »**. Ces 9, tous expliqués (aucun bug d'extraction) : Malinowski (ANIK, 2020) ; Schrader (VRNG/ELN/MSCI, 2022) ; Calhoun (AFRM/IBM, 2024) ; Gottheimer (IFNNY, 2025) ; Pelosi (INTC/UBER, 2026).

Dérives de format corrigées (trouvées en validant contre Quiver) : casse des PDF pré-2021 (rendement 2020 **84 %** → **100 %**) ; pollution de descriptions (lignes d'annotation écartées) ; MLP sans code [XX] (manques 2020 **183** → **15**).

Électronique = prêt. 32 676 transactions 2020→2026, concordance Quiver **99,01 %** ($\geq 98\%$ chaque année), **9 vrais-absents** sur 6 ans. Quiver n'est jamais réinjecté.

4 L'OCR repensé : census des scannés + échantillon par année

4.1 Census complet des 547 PDF scannés

Recensement visuel des **547** PDF sans texte (data_v1/tables/_scan_census_547.csv). Constat structurant : il n'existe **qu'un seul type de document** (le formulaire officiel House) ; ce qui varie, c'est l'*orientation* et la *saisie*. Trois clusters :

Cluster	docs	part	Profil OCR
A — tapé droit	74	13,5 %	le plus propre ; lecture directe
B — tapé tourné 90°	322	58,9 %	le gros du corpus ; lisible une fois redressé
C — manuscrit	151	27,6 %	le point dur ; concentré 2020-2021, quasi nul en 2026

543/547 sont le même formulaire officiel ; les **2 seuls** vrais relevés externes sont les dépôts de Ted Yoho (2020, Morgan Stanley). **81 %** des scans sont *tournés* ; seulement **6** sont réellement illisibles.

4.2 Décision : un échantillon représentatif par année (pas les 547)

Le livrable OCR n'est **pas** l'OCR des 547. On OCR un **échantillon représentatif de ~10 documents par année**, stratifié par cluster et priorisant les déposants couverts par Quiver. Pourquoi : (i) le **coût** d'un OCR exhaustif des 547 (souvent denses) n'est pas justifié pour établir la *justesse* de la méthode ; (ii) le **manuscrit** (cluster C) est intrinsèquement dur *et* peu vérifiable (Quiver y est quasi absent), donc un sur-investissement OCR n'y serait pas valable.

4.3 Résultats de l'échantillon

70 docs (10/an : 2 A / 6 B / 2 C ; 2026 = 8 A / 2 C faute de cluster B), **4 596 transactions** (echantillon_ocr.py : prompt durci, cap de pages, cache dédié ; restitué par notebook_ocr.ipynb). Couverture **ticker = 78 %** (3 565/4 596) après la **passse LLM nom→ticker** (*mécanisme : cf. pilote 2025*) — sources : explicit 170 · elec_dict 2 399 · llm 996 · none 1 031 (vrais non-cotés : munis, obligations, options).

Concordance Quiver fenêtrée (part de nos couples confirmés par Quiver) :

Cluster	préc. ticker	préc. (ticker, date)	Année	préc. (ticker, date)
A — tapé droit	0,78	0,58	2020	0,38
B — tapé tourné	0,74	0,45	2022	0,25
C — manuscrit	0,76	0,02*	2024	0,44
			2025	0,54
			2026	0,77

* Cluster C : Quiver quasi absent sur ces petits déposants manuscrits → non vérifiable (et non un échec OCR).

La **précision ticker** est élevée partout (0,74–0,78 : on n’invente pas d’instrument) ; la précision (**ticker, date**) décroît sur les scans anciens/dégradés — l’écart vient de la *lecture des dates*, pas des tickers. Les scans récents et propres (2026) atteignent **0,77**. À noter : 2020 et 2026 sont par ailleurs OCR à 100 % hors échantillon (7 764 / 3 850 txns), déjà sur disque.

5 Limites connues (honnêteté)

- **OCR = échantillon, pas exhaustif.** Les 547 scannés ne sont *pas* tous extraits au niveau transaction — choix assumé (cf. §4.2). Le livrable OCR est un échantillon représentatif par année, destiné à *mesurer* la justesse, pas à fournir l’intégralité des trades papier.
- **Manuscrit (cluster C).** Intrinsèquement difficile, **et** peu vérifiable : Quiver ne couvre quasiment pas ces petits déposants. La qualité y est mesurée par stabilité, pas par Quiver.
- **Concordance (ticker, date) gatée par les dates.** La précision *ticker* est haute, mais la précision (*ticker, date*) chute sur les vieux scans / le manuscrit, car la lecture des **dates** manuscrites/dégradées est l’étape fragile.
- **Tickers non-cotés laissés vides.** Munis, obligations, options : **ticker** null à dessein (jamais deviné).

6 Reproductibilité & fichiers

Dossier autonome (modèle 2025) : `.venv local + kernel jupiter-house-toutes-annees, .env/.env.example/requirements.txt` ; **547 PDF scannés + index + YAML + baseline + cache Quiver embarqués** dans `data_v1/` ; moteurs `house_multiyear.py` / `house_ocr_multiyear.py` à la racine, chemins ancrés par `BASE_DIR` ; `grep "semaine 1" = 0` ; l’écarté (scripts one-shot, intermédiaires, doublon 2025q1) rangé dans `_archive/`.

Deux notebooks (source de vérité) :

1. `notebook_digital.ipynb` — électronique total + concordance Quiver (reproduit les 99,01 %).
2. `notebook_ocr.ipynb` — census 547 + aperçus visuels A/B/C + OCR de l’échantillon + concordance.

Pour le reste (mécanique détaillée, schéma des colonnes) : cf. *synthèse du pilote 2025*.

Message en une ligne. Électronique **total** 2020→2026 (**32 676** transactions, **99 %** de concordance Quiver, 9 vrais-absents) et OCR **validé par échantillon représentatif par année** (census 547 → 3 clusters → 10 docs/an) — suite directe du pilote 2025, dans un dossier entièrement autonome.