

Tables de données — membres, tickers, panel annuel

Notebook 09 · 4 CSV dans `tables/` · donnée propre et comprise, avant toute stratégie

Les 4 fichiers

<code>membres.csv</code>	1 ligne = 1 membre	372 × 94
<code>tickers.csv</code>	1 ligne = 1 ticker	4618 × 40
<code>membres_annees.csv</code>	1 ligne = (membre, année)	2628 × 11
<code>dictionnaire_colonnes.csv</code>	définition de chaque colonne	145

Deux périmètres nommés partout : $\mathcal{T}^{brut}$ = table cano-
nique 2013-2026 (**134 429** trades, 372 membres, 4618 ti-
ckers) ; $\mathcal{T} \subset \mathcal{T}^{brut}$ = trades dont le ticker a un prix ex-
ploitable (**118 029** trades, 3289 tickers) — le périmètre du
moteur 05b/07. Toute colonne de flux/portefeuille vit sur $\mathcal{T}$;
`n_trades_brut` garde la trace de $\mathcal{T}^{brut}$.

membres.csv — 6 familles

A Identité/mandat (13) : parti, chambre, état, congrès min/max, ancienneté, **leader** (+postes, fichier vérifié des 12 postes de parti), comités THOMAS et `secteurs_jurisdiction` = $\bigcup_c \text{COMITE_GICS}[c]$ (matrice gelée du 08).

B Activité, temps de présence (21) : n trades (brut/ $\mathcal{T}$ /achats/ventes), notional $\sum A_j$ (midpoint — mesure censurée par intervalle), taille médiane, $\mathbb{P}(A_j \leq 8000,5)$, délai médian de déclaration, parts de retard (> 45 j, > 365 j), owner dominant, parts conjoint/élu, premier/dernier trade, durée d'activité, `actif_12m` (« encore dans le jeu » : 103 membres).

**C Portefeuille reconstruit (36 ; NaN si non recons-
truit)** — parts FIFO $n_k^m(t)$, $V_m = \sum_k n_k^m P_k$, $w_k^m = n_k^m P_k / V_m$:

$$\text{HHI} = \overline{\sum_k (w_k^m)^2}, \quad N^{eff} = 1/\text{HHI}, \quad \text{TO} = \frac{\sum_j A_j}{2\bar{V}_m} \cdot \frac{252}{T_m}$$

durées de détention par épisodes FIFO : médiane pondérée-
parts et médiane de survie **Kaplan-Meier** (censure = po-
sition encore ouverte ; NaN si $> 50\%$ encore détenu — lire avec `part_ouverte`) ; actions principales `top1..3_ticker` +
parts, `top10_tickers` ; 12 parts sectorielles GICS ($\sum = 1$).

D Risque/performance (14 ; série time-weighted r_m) :

$$\text{vol} = \sigma(r_m)\sqrt{252}, \quad \text{sharpe} = \frac{\bar{r}_m}{\sigma} \sqrt{252}$$

$$\text{sortino} = \frac{\bar{r}_m}{\sigma(r_m)} \sqrt{252}, \quad r_m = \alpha + \beta r_{SPY} + \varepsilon$$

$$\beta, \alpha_{ann}, \text{appraisal} = \frac{\alpha}{\sigma_\varepsilon} \sqrt{252}, \quad t_{appr}$$

plus CAGR, maxDD, IR vs SPY (+ t), excès de CAGR vs SPY, `eligible` ($n \geq 10$ trades et $T_m \geq 126$ j : 223 membres).

F Track record par trade (7 ; critères du 03) — pour chaque achat j , entrée $J+1(\tau_j)$, sortie min(première vente FIFO, +252j), **brut** vs SPY :

$$\text{hit_rate} = \mathbb{P}(x_j > 0), \quad t_x = \frac{\bar{x}}{\sigma_x/\sqrt{n}}$$

$$\text{profit_factor} = \min\left(\frac{\sum x^+}{|\sum x^-|}, 10\right)$$

(58 926 achats évalués ; excès moyen pooled $-0,23\%$ — cohé-
rent avec le « copier tout le monde perd » du 06).

E Comportement (3) : `part_ci_achats` (achats ali-
gnés comité×secteur, 16,4% sur $\mathcal{T}$), `part_trades_repetes`,
`part_coachat` (≥ 3 acheteurs le même mois).

tickers.csv — 4 familles

A Identité (8) : description, classe d'actif, secteur GICS, ETF proxy, délisté (+type). **B Flux Congrès (19)** : trades/achats/ventes, notionals (net = buy — sell), n membres (acheteurs/vendeurs), part Démocrate du notio-
nal d'achat, part Sénat, part conjoint, part alignée comité, bornes de dates, mois actifs, `coachat_max`, top-3 membres. **C Marché (10)** — sur la série de prix **brute** (jours cotés, pas le forward-fill du moteur, qui biaiserait la vol des délis-
tés vers 0) : $\sigma(\Delta \log P)\sqrt{252}$, β vs SPY (≥ 126 obs), CAGR fenêtre, maxDD, $\text{ADV\$} = \text{med}(P^{raw} \cdot \text{Vol})$ (cache volume dédié). **D Croisement (3)** : excès moyen à 21/63 j après les achats (entrée $J+1(\tau_j)$, brut vs SPY).

membres_annees.csv — panel

Par (membre, année) : activité (n trades, notional, tickers, secteur dominant) et performance annuelle de r_m (vol, Sharpe, `ret_annee` = $\prod(1 + r_m) - 1$, excès vs SPY mêmes jours ; NaN si < 40 jours actifs).

Ce qui garantit les chiffres

- Moteur **recopié à l'identique** des notebooks audités (05b via 07 ; étiquettes « COPIE EXACTE » dans le notebook) ; validations : périmètre 118 029/3 289/266/223, Khanna (32 684 trades, Sharpe 0,87) et McCaul repro-
duits, épisodes FIFO 61 963/28 944 (44% encore déte-
nus), KM pooled 910 j, Pelosi 2024 = +38,5%, aligne-
ment comité 17,0% (nb) /15,2% (\$) sur le périmètre du 08.
- **8 contrôles croisés** avant écriture (sommes de trades et de notionals identiques entre les deux tables au cen-
time, bipartite $\sum_k n_{membres} = \sum_m n_{tickers}$, bornes de dates, compteurs de population) : aucun CSV incohérent ne peut sortir.
- Dictionnaire aligné par **assert** sur les colonnes réelle-
ment écrites (145).

Limites à garder en tête

Montants = midpoints de tranches STOCK Act (cen-
sure par intervalle) ; options absentes des PTR collectés ;
`chamber/party` par mode (un House→Sénat a un mode arbi-
traire) ; 1 329 tickers sans prix exploitable (colonnes marché NaN) ; certains « délistés » cotent encore en OTC chez Yahoo (ex. BBBY).

Détail complet : 09_Tables_Membres_Tickers.ipynb (69 cel-
lules, Run All ≈ 1 min hors-ligne, validations §1.1-§12) et
`tables/dictionnaire_colonnes.csv`.