

Congress Trading Signal

☰ Category	Equity
📅 ETA	31 juillet 2026
☰ Month	
👤 Owner	Ⓐ Alice Lemaire
☰ Quarter	Q3
⚙️ Status	Not started

Contexte et objectif

L'idée est de construire une stratégie systématique qui copie les transactions financières déclarées par les membres du Congrès américain et certains insiders médiatiques. La prémisse est simple : ces personnes ont potentiellement accès à des informations privilégiées — via leur appartenance à des commissions clés (Finance, Defense, Intelligence) ou leur exposition médiatique — et leurs transactions déclarées constituent un signal exploitable. L'objectif est d'automatiser entièrement l'extraction de ces déclarations, d'en construire un signal propre, et de le backtester sur le framework de recherche Ramify.

Ramify traitant principalement des ETF indiciels, la stratégie est conçue en deux versions successives : une première sur actions directes pour valider le signal brut, une seconde avec translation vers des ETF sectoriels pour s'intégrer à l'univers d'investissement habituel de Ramify.

Ce qu'on veut produire

Un pipeline de bout en bout : des PDFs de déclarations brutes jusqu'à un backtest annoté sur le framework Ramify, avec une stratégie d'entrée et de sortie explicitement définie, un mécanisme de sélection annuelle des congressmen à suivre, et un pipeline de mapping sectoriel vers les ETF.

Étapes du projet

Le projet est structuré sur quatre semaines, avec deux semaines entières dédiées à la data — c'est la partie la plus critique. Un backtest sur des données mal extraites ne vaut rien.

Semaine 1 — Exploration, sourcing et architecture

Avant d'écrire une ligne de code, cartographier précisément ce qui existe. La source principale est le STOCK Act, entré en vigueur en 2012, avec des données exploitables en pratique à partir de 2013. Deux sources primaires : la Chambre des représentants via disclosures.house.gov en format XML structuré, et le Sénat via efts.senate.gov en PDFs souvent scannés et de qualité variable. Des agrégateurs tiers existent — Capitol Trades, Quiver Quant — à évaluer en complément ou en fallback selon leur coverage historique réel comparé aux sources primaires.

Les deux premiers jours sont consacrés à cet audit : comprendre la structure exacte des fichiers par source, les champs disponibles, les années couvertes, les trous éventuels. L'objectif est une décision d'architecture documentée — quelles sources, dans quel ordre de priorité, avec quel traitement par source — avant de commencer quoi que ce soit d'autre.

Les jours suivants sont dédiés au téléchargement automatisé de l'ensemble des fichiers disponibles depuis 2013. Pas de transformation encore — juste s'assurer qu'on a tout, que rien ne manque, et que le stockage intermédiaire est organisé proprement par source, par année, par chambre.

En fin de semaine, on construit le pipeline LLM. Le modèle (Claude API, Sonnet) reçoit les documents bruts et doit extraire de manière fiable pour chaque transaction : nom du déclarant, `transaction_date`, `disclosure_date`, ticker, type d'opération, fourchette de montant, type d'actif. Le prompt est itéré sur un échantillon représentatif — quelques dizaines de documents House XML et quelques PDFs Senate de qualité variable — jusqu'à obtenir un taux d'extraction satisfaisant. La convention sur les fourchettes de montant (midpoint recommandé) est définie et documentée à ce stade.

Semaine 2 — Nettoyage, validation et pipeline final

C'est là que la majorité des problèmes concrets apparaissent. Les tickers peuvent être mal orthographiés ou obsolètes — à réconcilier avec un référentiel propre. Les noms de déclarants sont souvent inconsistants d'une année à l'autre ("Nancy Pelosi", "N. Pelosi", "Pelosi Nancy"). Des doublons peuvent apparaître entre sources. Certaines transactions n'ont pas de ticker identifiable

— décider si on les jette ou on les conserve avec un flag. Chaque règle de nettoyage doit être documentée explicitement, pas appliquée silencieusement.

Avant de passer au backtest, une validation systématique de la qualité est nécessaire. Vérifications à effectuer : cohérence des dates (`disclosure_date` toujours postérieure à `transaction_date` , délai légal de 45 jours respecté — les outliers sont suspects), distribution des montants par personne et par année, coverage par congressman (qui a combien de trades, sur quelles années), taux de transactions sans sortie déclarée. Produire un rapport de qualité synthétique — quelques graphiques et statistiques descriptives — qui servira de référence pour l'interprétation ultérieure du backtest.

En fin de semaine, finaliser le pipeline end-to-end automatisé : téléchargement → extraction LLM → nettoyage → table finale. Ajouter les métadonnées utiles pour la sélection : chambre, parti, années en poste, appartenance aux commissions clés — disponibles via l'API officielle du Congrès (api.congress.gov). Ajouter également le pipeline de mapping sectoriel : pour chaque ticker extrait, identifier le secteur dominant via la classification GICS (disponible via yfinance ou OpenBB), puis mapper vers l'ETF sectoriel correspondant dans l'univers Ramify. Les questions à trancher à ce stade : quel univers d'ETF sectoriels cibles, et comment gérer les entreprises présentes dans plusieurs secteurs. Tester le pipeline sur une mise à jour simulée pour s'assurer que tout tourne de manière incrémentale sans relancer l'extraction complète.

Le format de stockage final est laissé à l'appréciation de la stagiaire — CSV, SQLite, Parquet ou autre — selon ce qui s'intègre le mieux au framework Ramify existant. Ce qui est non négociable, c'est que la table soit propre, documentée, et que les champs suivants soient garantis sans valeurs manquantes : `declarant_name` , `chamber` , `party` , `committee_membership` , `transaction_date` , `disclosure_date` , `ticker` , `sector_gics` , `etf_proxy` , `operation_type` , `amount_midpoint` , `asset_type` .

Semaines 3 et 4 — Stratégie et backtest

Une fois la data validée, on construit la stratégie et on la teste sur le framework Ramify, dans ses deux versions successives.

Stratégie d'entrée et de sortie

La logique est du copy trading pur. On entre en position sur un instrument dès qu'une disclosure de type "Purchase" est publiée par un congressman suivi, à

la `disclosure_date` de cet achat. On sort selon une hiérarchie à deux règles : en priorité, si le même congressman publie une disclosure de type "Sale" sur ce ticker, on sort à la `disclosure_date` de cette vente ; sinon, on sort de manière forcée 12 mois après la date d'entrée.

Exemple concret : Pelosi déclare un achat de NVDA avec une `disclosure_date` au 15 mars 2023. On entre ce jour-là. Si elle déclare une vente avec une `disclosure_date` au 20 septembre 2023, on sort ce jour-là. Si aucune vente n'est déclarée, on sort le 15 mars 2024. Chaque trade est une observation avec une entrée et une sortie explicites, sans ambiguïté.

Version 1 — Actions directes

On trade le ticker exact déclaré dans la disclosure. C'est la version la plus directe, utilisée pour valider le signal brut et construire les track records individuels. Cette version sert de référence avant de passer à la version ETF.

Version 2 — ETF sectoriels

Pour chaque ticker déclaré, on substitue l'ETF sectoriel correspondant via le mapping GICS construit en semaine 2. Un achat de NVDA devient par exemple un achat de XLK (Technology Select Sector SPDR). La logique d'entrée et de sortie reste strictement identique, seul l'instrument change. C'est cette version qui s'intègre à l'univers d'investissement habituel de Ramify.

Sélection annuelle des congressmen suivis

En fin d'année, on sélectionne les K congressmen à suivre pour l'année suivante — K étant un paramètre à tester, typiquement entre 4 et 10. Pour être éligible, un congressman doit avoir déclaré un minimum de 10 trades sur la période d'évaluation. Les positions ouvertes sur des congressmen non reconduits sont laissées courir jusqu'à leur sortie naturelle, sans coupure arbitraire.

Intuition sur le critère de sélection

Plusieurs métriques sont envisageables. Le hit rate seul est lisible mais ne capture pas la magnitude. Le return moyen par trade est plus informatif mais sensible aux outliers. Le Sharpe sur la série de trades est le critère le plus robuste pour comparer des personnes avec des fréquences de trading différentes. L'alpha vs SPX est ce qui compte vraiment.

Au-delà de la performance passée, la recherche académique suggère que l'appartenance aux commissions est un prédicteur structurel plus stable que le track record individuel. Les membres des commissions Finance, Defense et Intelligence ont accès de manière récurrente à des informations non publiques. Intégrer ce filtre dès la présélection est recommandé — par exemple en imposant qu'au moins la moitié des K congressmen sélectionnés appartiennent à l'une de ces commissions.

Références

Papiers académiques

Ziobrowski et al. (2004), *Abnormal Returns from the Common Stock Investments of the U.S. Senate*, Journal of Financial and Quantitative Analysis — le papier fondateur, alpha annuel documenté autour de 12% avant STOCK Act. Ziobrowski et al. (2011) — même étude sur la Chambre, alpha plus faible mais significatif. Karadas (2019), *Trading on Private Information* — analyse post-STOCK Act, montre que l'appartenance aux commissions clés est le meilleur prédicteur. Eggers & Hainmueller (2013), *Capitol Losses* — regard critique sur la persistance du signal post-2012, utile pour calibrer les attentes.

Sur le problème de sélection et confiance dynamique

Mauboussin, *The Success Equation* (2012) — traite du problème de séparer skill et luck sur des séries courtes, très accessible. Sutton & Barto, *Reinforcement Learning: An Introduction* (2018), chapitre 2 uniquement — formalise le problème de confiance dynamique dans un cadre multi-armed bandit, disponible gratuitement en ligne. Grinold & Kahn, *Active Portfolio Management* (2000) — cadre du Fundamental Law of Active Management, pertinent pour évaluer la valeur d'un signal avec peu d'observations par personne.

Sur les pièges du backtest

De Prado, *Advances in Financial Machine Learning* (2018) — chapitres sur le backtest et la détection du overfitting, indispensable pour ne pas surinterpréter les résultats d'une sélection sur performance passée.