

Fiche récapitulative — Congress Trading Signal · la couche données (2014-2026)

Résumé explicatif : vision d'ensemble et résultats clés, sans le détail des fonctions. Le détail technique complet est dans [RAPPORT QUALITE.md](#) ; la traçabilité des vérifications est dans [AUDIT DONNEES 2014 2026.md](#).

1. Le problème

- Depuis le **STOCK Act (2012)**, les membres du Congrès américain doivent **déclarer publiquement** leurs transactions boursières, en principe sous **45 jours** (rapports appelés *PTR*).
- Hypothèse de recherche (littérature : Ziobrowski, Karadas) : par leur position (commissions clés, accès à l'information), ces déclarations pourraient contenir un **signal exploitable**.
- L'idée à terme : une stratégie de **copy-trading** qui réplique ces trades **après** leur publication (jamais avant — principe *anti-look-ahead*).
- Mais** avant toute stratégie, il faut une **couche de données irréprochable**. C'est mon livrable.

2. Le livrable en une phrase

- Une base **propre, traçable et honnêtement validée** de **169 000 transactions uniques de membres élus** (170 920 lignes brutes – 1 920 re-divulgations dédoublées), sur les **2 chambres, 2014–2026** — et sa déclinaison prête-recherche : la **table canonique de backtest, 134 464 lignes × 36 colonnes** (`data/clean/transactions_backtest_2014_2026.csv`).

3. D'où viennent les données

- Chambre** : le site public du *House Clerk* → un index annuel officiel → les **PDF** des déclarations. **100 % des 8 252 PTR listés par le Clerk 2014-2026 sont traités** (parsés, OCRisés, ou écartés par une règle écrite).
- Sénat** : le portail *eFD* → soit une **page web**, soit un **scan papier** ; les 25 dépôts sans transaction ont chacun une raison documentée (`06d_docs_sans_transaction.csv`).
- Référentiel public des élus** (identité, parti, commissions) + **référentiels transverses** (`data/reference/` : renommages/délistages de tickers, carte secteurs, snapshots de commissions par Congrès).
- Deux services externes** : **Claude Vision** (lire les scans) et **Quiver** (valider — *jamais réinjecté*). S'y ajoutent deux sources de cross-validation indépendantes (*senate-stock-watcher*, *mirror house-stock-watcher*).
- Deux dates** par déclaration : date du **trade** et date de **divulgation**. Tout usage aval entre sur la divulgation → *anti-look-ahead*.

4. Le défi central : électronique vs scanné

- Une déclaration arrive sous **2 formes** : du **texte** exploitable directement, ou une **image** qu'il faut « lire ».
- C'est la **fourche** du projet → **4 sous-corpus** : Chambre électronique **58 728**, Chambre OCR **93 261**, Sénat électronique **13 026**, Sénat OCR **3 985**.
- Point marquant : **~61 % des lignes de la Chambre viennent de scans** — de gros déposants (Khanna, McCaul) déclarent exclusivement sur papier.

5. La construction, étape par étape

5.1 — Qui a déclaré ? (résolution d'identité)

- Nom libre → **identifiant officiel unique** (bioguide) via référentiel + matcher tolérant (surnoms, homonymes — chaque déposant est rattaché au bon élu, cas d'homonymie compris).
- Résultat** : **100 % des lignes rattachées, les deux chambres**.

5.2 — Trier les formats

- Chambre : test de la couche texte de chaque PDF ; Sénat : le portail indique le type. Cette fourche fixe la composition du §4.

5.3 — Chambre électronique (PDF lisibles)

- Parsing déterministe qui **reconstitue** chaque transaction (lignes recollées, motif « opération + 2 dates + montant »).
- Résultat** : **58 728 transactions** — le parseur gère la police pré-2018 (petites capitales) et les gabarits mixtes (union de deux lecteurs) : les achats et les ventes sont extraits à parité.

5.4 — Sénat électronique (pages HTML)

- Tableaux web à en-têtes irréguliers → appariement flou des colonnes. **Résultat** : **13 026 transactions**.

5.5 — Chambre scannée (OCR Claude Vision)

- 753 scans recensés et classifiés** (tapé droit / tapé tourné / manuscrit) ; redressement par reconnaissance d'orientation ; lecture structurée avec cache versionné (un re-run ne re-paie rien).
- Manuscrit (cluster C) exclu par défaut** (dates trop incertaines) — politique **rejouable** : 582 documents écartés par cette règle (liste versionnée), avec exceptions explicites : 3 gros déposants réintégrés (les écarter ferait perdre trop de transactions corroborées) + 33 documents relus et validés à la main.
- Résultat** : **93 261 lignes**, très concentrées (Khanna + McCaul + Renacci ≈ 48 % du House).

5.6 — Sénat papier (images)

- Même moteur Vision ; **3 985 lignes**, surtout Blumenthal, massivement des obligations municipales (non cotées — d'où la couverture ticker plus basse du Sénat).

5.7 — Secteur (GICS → ETF)

- Cascade factuelle (yfinance) → LLM → corrections manuelles, source tracée. Les **ETF diversifiés n'ont pas de secteur GICS** (classe `etf_broad` dans la carte transverse — un secteur n'aurait pas de sens) et les symboles recyclés sont datés.
- **Couverture** (= remplissage, pas exactitude ; le non-coté n'a ni ticker ni secteur par nature) : ticker **84,1 % (Chambre) / 77,9 % (Sénat)** ; secteur **79,8 % / 70,4 %**. Dans la table canonique de backtest : secteur actions **100 %**.

5.8 — Les tables finales

- **Clé naturelle de 7 champs** (sans ticker ni date de divulgation) + rang d'occurrence → dédup **non destructrice** (les lots multi-comptes réels Self/Spouse/Joint sont préservés — ne jamais `drop_duplicates()`).
- **FINAL par année** : 28 colonnes, 12 champs « métier » garantis sur les 2 chambres. Commissions = photo actuelle dans les FINAL ; la **table canonique** ajoute parti **et** commissions **point-in-time** (à la date du trade, Congrès par Congrès), tickers canoniques Yahoo avec renommages, flags de traçabilité (dépôts tardifs, délistés, lots).

6. Les résultats clés

- **169 000** transactions uniques (House 151 989 + Sénat 17 011) · 2 chambres · 13 ans.
- **Complétude prouvée** : 100 % de l'index officiel House traité ; Sénat = sur-ensemble strict de senate-stock-watcher (6 231 transactions externes 2014-2020 : **100 % retrouvées** — seule divergence : la façon de représenter les opérations d'échange, pas des transactions manquantes).
- **Identité** : **100 %** ; montants renseignés 99,4 % (milieu exact de fourchette, convention unique).
- **Table de recherche canonique** : **134 464 lignes × 36 colonnes**, invariants garantis par asserts (bioguide, ticker, montant, direction, chronologie, hash).

7. La validation externe

- **Quiver** (vérité-terrain, jamais réinjectée) : électronique quasi parfait (98-99 %) ; dans notre fenêtre on retrouve **93,5 % (House) / 92,1 % (Sénat)** des trades Quiver ; on est **plus complet** que Quiver (+26 524 combinaisons cotées).
- Les « doublons » apparents de Quiver sont élucidés : ce sont majoritairement des **lots multi-comptes réels** (le champ owner, que Quiver ne publie pas, les distingue chez nous).
- **Sources indépendantes** : senate-stock-watcher (100 % couvert) et mirror house-stock-watcher (99,5 % post-2018).

8. Qualité & reproductibilité

- **Rapport qualité automatique** régénérable offline (python `-m common.quality`), déterministe, avec section « couverture vs univers officiel ».
- **Jeux de référence figés (« golden »)** : 230 fichiers Chambre + 138 Sénat, comparés octet à octet à chaque exécution (zéro écart toléré) ; **10/10 tests** de régression verts ; chaque transformation reproduite depuis les colonnes figées.

9. Les limites assumées

- **Manuscrit exclu** par défaut (dates incertaines) — documenté, rejouable, avec exceptions explicites.
- **Pas de ticker/secteur pour le non-coté** (par nature) ; ~758 lignes OCR récentes à ticker non résolu (candidates à une future passe).
- **Prix des titres délistés** : plus aucune source gratuite (Yahoo purge, Stooq verrouillé) → traitement PAR TYPE via `ticker_renames.csv` (faillite ≈ perte totale, rachat = clôture à la date du deal) au lieu d'une disparition silencieuse.
- **Commissions des FINAL** = photo actuelle (le point-in-time est dans la table canonique).
- Cutoff de collecte : **2026-07-03** (House) / 2026-06-25 (Sénat, 3 dépôts postérieurs documentés).

10. Conclusion & suite

- Une couche de données **complète (prouvée contre l'univers officiel), identifiée, enrichie, validée par trois sources externes et reproductible** — prête pour la recherche.
- **Suite (phases S3-S4)** : basculer la recherche sur la table canonique et appliquer [PATCHS_S3S4_A_APPLIQUER.md](#).