

Plan des slides — La couche données (V4)

le plan à suivre pour la refonte, une idée par slide

Alice Lemaire — document de travail

Juillet 2026

Ce document est un plan, pas les slides. Chaque « fiche » ci-dessous = une future slide. Périmètre : **le deck données seulement** (les Parties 1–5 actuelles de `SLIDES_DONNEES_S1S2.tex`) ; le backtest (PARTIE II) et les tables (PARTIE III) ne sont ni replanifiés ni déplacés. La mise en forme (orientation, charte, figures exactes) est un détail d'exécution, hors de ce plan.

1 Le diagnostic — six règles d'or

Retour du chef de recherche : *bien, mais pas assez organisé*. Traduit en règles appliquées à chaque fiche de ce plan :

1. **Une idée par slide** — le titre est une phrase affirmative qui *est* l'idée ; si une slide en porte deux, on la coupe.
2. **Le plan d'abord** — l'histoire est annoncée en ouverture ; chaque étape s'ouvre sur une question simple et se ferme sur une réponse chiffrée.
3. **Pensée chronologique** — on suit le trajet de la donnée (brute → pipeline → enrichie → vérifiée → livrée) ; les détails ne viennent qu'à *l'intérieur* des étapes.
4. **Chiffres légendés** — au plus 3 chiffres par slide, chacun avec sa légende « à quoi ça correspond » (exceptions : les 2 slides-bilan à 4 tuiles).
5. **Zéro mini-détail** — tout ce qui ne porte ni l'histoire ni la crédibilité descend en annexe ou disparaît (liste en §7).
6. **Choix explicites** — chaque choix méthodologique est énoncé dans un encadré uniforme : « on a choisi X parce que Y » (carte complète en §5).

Volumétrie : deck données actuel = **47 frames** (titre + plan + 5 transitions + 40 slides de contenu) → cible = **35 pages** de flux principal (titre + 5 intercalaires + **29 fiches** : 3 d'ouverture + 26 de contenu É1–É5), plus 7 planches d'annexe (réserve pour questions).

2 Le récit, et l'architecture cible

Le récit en une phrase : *des déclarations publiques hétérogènes — PDF, scans, pages web — on a construit une table de recherche unique, prouvée de l'intérieur et de l'extérieur, livrée avec ses limites écrites.*

Bloc	Slides	Question d'entrée	Réponse de sortie
Ouverture	3	— (résultats d'abord)	les 4 résultats + le plan en 5 étapes
É1 · Donnée brute	6	à quoi ressemble la matière première ?	2 guichets · 4 formats · une matière majoritairement papier
É2 · Pipeline	5	comment 10 000 documents deviennent une table ?	169 000 transactions extraites, 100 % identifiées
É3 · Enrichir	3	que faut-il ajouter pour un backtest ?	12 champs garantis, chaque enrichissement tracé
É4 · Vérification	8	comment sait-on qu'on n'a rien raté, ni rien inventé ?	rien raté (173) · cohérent dedans (87,8 %) · sur-ensemble du tiers (> 92 %)
É5 · Livrable	3+1	qu'est-ce qu'on livre, avec quelles limites ?	134 464 × 36, limites écrites

Numérotation : les « Partie 1...5 » internes deviennent « **Étape 1...5** » (la frise du deck s'appelle déjà « cinq étapes ») — le mot « Partie » est libéré pour le niveau global (backtest, tables), traité plus tard.

3 Le plan, slide par slide

Ouverture (3 slides, après le titre)

O1 · NEUVE « Depuis 2012, chaque élu du Congrès doit déclarer ses transactions en bourse sous 45 jours »

Idée — le cadre légal en 30 secondes — qui (Chambre + Sénat), quoi (chaque transaction, dans un *Periodic Transaction Report*, « PTR »), et la question de recherche : peut-on en tirer un signal ?

Chiffres — **45 j** (délai légal de déclaration d'un trade) · **2014–2026** (la fenêtre étudiée — la loi, elle, date de 2012) · **2 chambres** (435 représentants + 100 sénateurs)

Provenance — neuve — c'est le plus gros trou du deck actuel : le STOCK Act vit en note de bas de page de la slide plan. Définit : STOCK Act, PTR, dépôt, Chambre/Sénat.

O2 · NEUVE « La couche données, en quatre résultats »

Idée — les résultats d'abord — le reste du deck ne fait que prouver ces quatre nombres ; chute : « comment peut-on affirmer ça ? c'est l'objet de la présentation ».

Chiffres — 4 tuiles (exception assumée) : **169 000** transactions uniques, identité rattachée à 100 % · **100 %** des 8 252 déclarations officielles (PTR) traitées · **> 92 %** de la base d'un fournisseur commercial indépendant retrouvés chez nous (nous sommes son sur-ensemble) + **87,8 %** des positions de sortie expliquées comptablement · **134 464 × 36** : la table livrée, limites écrites

Provenance — neuve — tuiles empruntées à l'actuelle « Ce qu'il faut retenir » (S29), qui reste en clôture : O2 promet, la fin prouve.

O3 · refonte « Le plan : cinq étapes, une promesse »

Idée — l'histoire promise en une image — la frise donnée brute → pipeline → enrichir → vérification → livrable, seule promesse du deck.

Chiffres — **5 étapes** (aucun autre chiffre sur cette slide)

Provenance — refonte de l'actuelle S1 « Le plan » : la frise TikZ existante est conservée, la note STOCK Act remonte en O1.

Étape 1 · La donnée brute (6 slides)

Intercalaire d'entrée — question affichée : *À quoi ressemble la matière première — et pourquoi ce n'est pas juste télécharger un CSV ?*

1.1 · fusion « Tout est public : deux guichets, treize années »

Idée — la Chambre publie des archives annuelles indexées ; le Sénat, un portail de recherche derrière un accord obligatoire — les deux sont automatisés ; côté Sénat, la liste des dépôts s'obtient par recherche (un lien par dépôt).

Chiffres — **35 315** (dépôts de tous types dans l'index Chambre 2014–2026) · **13 années** couvertes

Choix — **l'index annuel officiel est notre autorité** : c'est lui qui définit l'univers des documents à traiter — pas ce qu'on a réussi à lire.

Provenance — fusion S2a + S2b + S7a + S7b (2 captures max : site Chambre, portail eFD) ; zoom XML et formulaire de recherche → annexe A2 ; jargon « CSRF/jeton » supprimé (dire : « accord obligatoire, accepté par notre collecteur ») ; le « 1 705 rapports » de la capture actuelle est illustratif (non recalculable, verdict de l'audit) — ne pas en faire un chiffre clé.

1.2 · conservée « Sur douze types de dépôts, un seul porte le signal : le P »

Idée — les PTR sont les seules déclarations de transactions datées sous 45 j — on filtre, et on promet d'ouvrir les 11 autres types à l'Étape 4.

Chiffres — **12** (types de dépôts existants) · **8 252** (PTR parmi les 35 315 dépôts)

Choix — on ne construit le signal qu'avec les dépôts de type **P**, parce qu'eux seuls déclarent des transactions datées sous 45 jours — les 11 autres types seront tous ouverts à l'Étape 4 (Vérification).

Provenance — S3 conservée quasi telle quelle (figure des 12 types).

1.3 · fusion « Chaque dépôt s'ouvre dans un des deux mondes — texte ou image : quatre sous-corpus »

Idée — la même donnée réglementaire existe sous 4 formats (Chambre : PDF lisible / PDF scanné ; Sénat : page web / papier scanné) → 4 voies de traitement distinctes.

Chiffres — **71 % / 29 %** (dépôts Chambre lisibles vs scannés) · **4 sous-corpus** (chambre × format) · **57,6 %** (part du corpus final qui viendra d'images : 55,2 Chambre + 2,4 Sénat)

Choix — on découpe le corpus en **4 sous-corpus** et chaque voie reçoit son extracteur dédié — un traitement uniforme raterait la moitié.

Provenance — fusion S4 (deux mondes) + S7c (Sénat électronique) + S8 (Sénat papier) : 4 vignettes, une par sous-corpus ; « DocID » réduit à une ligne (« le numéro du dépôt, qui donne l'URL de son PDF ») ; les 4 variantes du papier Sénat → annexe.

1.4 · conservée « Le vrai point dur n'est pas le scan : c'est le manuscrit »

Idée — l'OCR moderne lit le tapé même tourné à 90° ; le manuscrit cursif est la seule zone rouge — il faudra une politique, tranchée à l'Étape 2.

Chiffres — **775** (scans manuscrits sur les 2 424 scans Chambre recensés) · 1 ligne Sénat : le papier y existe aussi, en faible volume

Provenance — S6 conservée (3 vignettes : tapé droit / tapé couché / manuscrit) + la ligne Sénat ; « 255/373 couchées » purgé (redite) ; définit OCR (« lecture automatique d'une image »).

1.5 · allégée « Deux dates par transaction — seule la date de dépôt est fiable : c'est elle le signal »

Idée — la date de dépôt est une métadonnée, jamais lue dans le document (fiable) ; la date de transaction est extraite du texte ou de l'image (risquée → garde-fous, jamais inventée).

Chiffres — 27 j / 24 j (délai médian de divulgation Chambre / Sénat) · les dates de transaction douteuses sont **flaguées**, jamais réécrites

Choix — le signal est daté à la **date de dépôt** (divulgation), jamais à la date du trade : c'est ce qu'un investisseur réel aurait su, quand il l'aurait su (anti-look-ahead) — et toute date de transaction douteuse est flaguée, jamais réécrite au hasard.

Provenance — S9 (« Les dates ») allégée : tableau des 4 voies réduit à 2 colonnes ; la fenêtre de plausibilité $[-90j, +10j]$ descend en note.

1.6 · corrigée « 169 000 transactions — dont ~40 % viennent de deux élus, exclusivement sur papier »

Idée — la matière est massive mais très concentrée, et majoritairement du papier : le papier n'est pas un détail, c'est le centre de gravité du corpus (ferme l'étape).

Chiffres — 169 000 (transactions uniques, annonce de ce que les étapes 2-3 vont extraire) · **Khanna 41 080** + **McCaul 27 123** $\approx 40\%$ du corpus (**erratum** : le deck dit 27 154) · **55,2 %** (part du corpus issue des scans Chambre)

Provenance — S10 conservée (barre des 4 voies + top déposants) ; l'idée « le papier est la majorité du corpus », aujourd'hui en petit gris, monte dans le titre.

Bandeau de sortie (sur la dernière slide de l'étape) — **Réponse** : 2 guichets publics · 4 formats · 8 252 PTR — une matière majoritairement papier.

Étape 2 · Le pipeline (5 slides)

Intercalaire d'entrée — question affichée : *Comment passe-t-on de ~10 000 documents hétérogènes à une seule table ?*

2.1 · conservée « Le flux de bout en bout tient en une image »

Idée — acquisition → tri → 4 extractions → tronc commun (normalisation, identité, enrichissement) → table — la carte que les 4 slides suivantes détaillent.

Chiffres — 4 voies → 1 table · 169 000 uniques (170 920 lignes brutes)

Provenance — S11 conservée avec sa révélation en 4 temps (c'est la slide d'altitude du deck — sa densité est assumée) ; les noms de fichiers internes sortent du schéma ; « clé naturelle » n'y apparaît plus (pas encore définie à ce stade).

2.2 · fusion « Les deux voies électroniques : du parsing déterministe de bout en bout »

Idée — pour le texte (PDF lisible, page web), pas d'IA — du code déterministe, y compris le recollage des lignes coupées ; la figure multiligne montre pourquoi un parseur naïf raterait la moitié.

Chiffres — 58 728 + 13 026 (transactions extraites : Chambre électronique + Sénat électronique) · en notes : 7 996 montants recollés, 102 dépôts sans transaction, tous consignés

Choix — la Chambre a **deux gabarits** de formulaire (l'ancien sans code type d'actif, le moderne avec [ST], apparu vers 2018) — **routés document par document**, jamais par année fixe.

Provenance — fusion S13 (deux pistes) + S5b (défi multiligne, qui devient l'illustration) ; S5a (le PTR lisible en grand) → annexe A1.

2.3 · allégée « Les scans Chambre : Vision lit tout — le manuscrit est écarté par une règle mesurée et rejouable »

Idée — l’OCR par IA lit le tapé même tourné ; le manuscrit, non corroborable par le mètre externe, est écarté par une règle écrite plutôt que d’injecter des lectures douteuses.

Chiffres — **93 261** (transactions extraites des scans Chambre) · **12,9 % vs 88 %** (part du manuscrit vs du tapé droit corroborée par Quiver, *même sans exiger la date*) · **582** (PTR manuscrits écartés — 7,1 % de l’index)

Choix — **gating manuscrit** : on écarte 582 PTR par une règle écrite et rejouable, avec exceptions explicites — parce qu’on ne met en table que ce qu’on sait lire.

Provenance — S14 allégée : census 74/1 575/775 (déjà vu en 1.4), `tool_use/JSON/cache`, « 4,8 % avec date », « 3 déposants + 33 docs » → annexe. Définit **Quiver** à sa première apparition : « fournisseur commercial des mêmes données, notre mètre externe (détail à l’Étape 4) ». Titres 2.3/2.4 en miroir.

2.4 · allégée « Le papier Sénat : gardé — faute de mètre externe pour le mesurer »

Idée — même moteur de lecture, politique inverse et assumée : Quiver est aveugle au papier du Sénat, donc aucune mesure d’exclusion possible — on garde, sous garde-fous internes, et on l’écrit.

Chiffres — **3 985** (transactions papier Sénat, 14 déposants) · **38,7 %** (part portée par Blumenthal, massivement du non-coté → couverture ticker plus basse = composition, pas défaut) · **2,4 %** (poids de cette voie dans le corpus : le risque est borné)

Choix — on n’écarte que ce qu’on a pu **mesurer** — l’asymétrie Chambre/Sénat est documentée, pas cachée.

Provenance — S15 allégée (l’extrait réel Boozman garde 3 lignes) ; « 255/373 » et « le prompt annonce 90° ou 180° » supprimés.

2.5 · allégée « Chaque ligne est rattachée à un élu officiel : identité 100 % »

Idée — « Buddy Carter », « N. Pelosi », « Hon. Earl L. Carter »... → un identifiant officiel unique par une cascade d’essais ; les réparations se font à la lecture, jamais en réécrivant les fichiers extraits.

Chiffres — **100 %** (des lignes rattachées à un élu) · **367 + 78** (membres distincts Chambre + Sénat) · **1** (seul override manuel par chambre — la cascade fait le reste)

Choix — les fichiers extraits sont **figés** ; toute réparation est appliquée **à la lecture** — l’audit reste possible à l’octet près.

Provenance — S12 conservée (cascade) ; vignette YAML réduite ; pièges Bob Casey / Angie Craig → annexe. Définit *bioguide* : « l’identifiant officiel unique d’un élu au Congrès ».

Bandeau de sortie (sur la dernière slide de l’étape) — **Réponse** : 58 728 + 93 261 + 13 026 + 3 985 = 169 000 transactions extraites, 100 % identifiées.

Étape 3 · Enrichir (3 slides)

Intercalaire d’entrée — question affichée : *Que faut-il ajouter pour qu’un backtest puisse s’en servir ?*

3.1 · fusion « Chaque transaction reçoit un ticker et un secteur — par deux cascades tracées »

Idée — l'enrichissement n'est jamais une devinette silencieuse : deux cascades ordonnées du plus sûr au moins sûr, chaque étage tracé ligne à ligne.

Chiffres — **84,1 % / 77,9 %** (ticker renseigné Chambre / Sénat — les vides sont du non-coté légitime, pas des défauts) · **2 540** (lignes qui retrouvent leur symbole par récupération à double preuve) · **79,8 % / 70,4 %** (secteur renseigné — 11 secteurs, chacun adossé à son ETF)

Choix — cascade ticker **ordonnée et tracée** (explicite → dictionnaire → LLM contraint → récupération) — la couverture mesure le *remplissage*, pas l'exactitude.

Provenance — fusion S16a + S16b ; la liste des 11 ETF un par un → annexe A7 (1 ligne suffit en séance). Définit GICS en une ligne.

3.2 · scindée « Une transaction = 7 champs : l'empreinte dédouble sans jamais détruire »

Idée — l'empreinte d'une transaction (qui · quand · quoi · sens · montant · pour qui · chambre) fait qu'une re-déclaration ne compte qu'une fois — tandis que les vrais lots répétés sont préservés par un compteur d'occurrence.

Chiffres — **7 champs** (l'empreinte — ticker et date de divulgation exclus délibérément) · **170 920** → **169 000** (lignes brutes → transactions uniques : -1 920 re-divulgations)

Choix — dédup **non destructrice** : empreinte + compteur d'occurrence, jamais de dédoublement aveugle — le ticker est exclu de l'empreinte car ajouté après coup.

Provenance — moitié de S17 ; « clé naturelle » reformulée « empreinte » ; `occurrence_index / drop_duplicates()` bannis du texte.

3.3 · scindée « Le contrat de la table corpus : 12 champs garantis, montant = milieu de fourchette »

Idée — à la sortie de l'étape 3, chaque ligne garantit les 12 champs qu'un chercheur attend — avec une convention de montant unique et assumée (ferme l'étape).

Chiffres — **12 champs garantis** (qui, quoi, quand ×2, sens, montant, ticker, secteur, ETF, parti, commissions — le deck actuel n'en énumère que 11 : compléter la liste exacte contre le schéma, voir §8) · **169 000 × 28** (la table corpus complète)

Choix — la loi ne donne qu'une **fourchette** de montant : on prend son **milieu exact** (d'où les « ,5 » dans la table) — convention documentée plutôt que fausse précision.

Provenance — autre moitié de S17 + convention montant remontée de S28 ; partiellement neuve.

Bandeau de sortie (sur la dernière slide de l'étape) — **Réponse** : 169 000 transactions uniques · 12 champs garantis · chaque enrichissement tracé.

Étape 4 · Vérification (8 slides)

Intercalaire d'entrée — question affichée : *Comment sait-on qu'on n'a rien raté — ni rien inventé ?*

4.1 · conservée « Vérifier, c'est répondre à trois questions »

Idée — complétude (a-t-on tout le périmètre?), cohérence (les flux se recollent-ils comptablement?), corroboration (des tiers indépendants voient-ils la même chose?) — la même confiance, testée de l'intérieur puis de l'extérieur.

Chiffres — les 3 tuiles-réponses annoncées : **173** (actions résiduelles échappant au signal) · **87,8 %** (*des positions de sortie expliquées* — Chambre, membres testables) · **93,5 %** (des combinaisons du fournisseur externe retrouvées chez nous — Chambre)

Provenance — S18 conservée telle quelle (la meilleure slide d'architecture du deck); seules les légendes des tuiles sont précisées.

4.2 · fusion « Complétude : on ouvre les 11 autres types — les transactions ne vivent que dans P, O, T et leurs amendements »

Idée — la vie déclarative d'un élu (entrée H, annuels O, sortie T, amendements A, candidats C...) et la découverte : les annuels contiennent aussi des transactions (Schedule B); les photos de patrimoine (Schedule A) serviront à la cohérence.

Chiffres — **11** (types tous ouverts, promesse de 1.2 tenue) · **31 %** (part des annuels O contenant des transactions) · **57 259** (lignes de transactions brutes vivant hors PTR, doublons compris)

Provenance — fusion S19 (cycle de vie) + S20 (famille patrimoine : 5 vignettes → 1 bande) + capture Pelosi de S21 en illustration; matrice des sections A→J → annexe A3; administratifs + blind trust → annexe A4. Définit Schedule A (photo du patrimoine) / Schedule B (liste des transactions).

4.3 · fusion « Verdict complétude : le hors-PTR est du patrimoine découvert trop tard — le signal ne perd que 173 actions »

Idée — la hiérarchie complète en une slide : 57 259 lignes brutes hors PTR → une fois doublons et échos retirés, l'essentiel est ETF/fonds re-déclarés → il ne manque au signal que 173 vraies actions, toutes anciennes; publiées ~1 an après coup, ces lignes nourrissent le patrimoine, jamais le signal.

Chiffres — **374 j** (délai médian trade → publication de ces lignes, contre 27 j en PTR) · **173** (actions cotées réellement absentes du signal, toutes pré-2018)

Choix — les transactions hors PTR alimentent le **patrimoine**, jamais le **signal** — cohérent avec l'anti-look-ahead de l'Étape 1.

Provenance — essence de S21 (surprises) + Coh-5 (gain net O/A/T); le bloc chiffré 26 115 / 22 216 / 3 899 descend en annexe A5, ré-ancré sur sa source (lignée v1-house) avec note anti-confusion (§4).

4.4 · fusion « Cohérence : le test comptable — patrimoine d'entrée + nos transactions = patrimoine de sortie »

Idée — qui est testable de bout en bout? il faut la photo d'entrée ET la photo de sortie ET des actions cotées — la loi elle-même limite l'échantillon; on définit ici photo (patrimoine) vs flux (transactions).

Chiffres — **900** (membres passés par la Chambre dans la fenêtre) · **149** (cycles complets : entrés PUIS sortis depuis 2014) · **56** (testables stricts : les deux photos + actions cotées)

Provenance — fusion Coh-1 + Coh-2 + Coh-3 (l'entonnoir 900 → 149 → 106 → 56 remplace le quadrant; la table de couverture 470 entrées / 463 sorties → annexe A7); le mot « quadrant » disparaît.

4.5 · allégée « Cohérence : 87,8 % des positions de sortie expliquées — 3,3 % restent vraiment inexplicables »

Idee — premier passage 78,7 % ; puis chaque position inexplicable est instruite une par une (déclarée ailleurs, structurelle) → 87,8 %, et un reliquat nominal minuscule.

Chiffres — 78,7 % → 87,8 % (positions de sortie expliquées, avant / après instruction des cas) · 45 / 1 371 = 3,3 % (positions vraiment inexplicables, 14 membres)

Choix — chaque position inexplicable est **classée par preuve documentaire**, pas éliminée statistiquement (table nominative conservée).

Provenance — Coh-4 allégée : sous-comptes (74/49/2 · 59/32/30/1) → note de bas de slide ; blind trust Phillips → annexe. Règle d'affichage : toujours « 87,8 % des positions expliquées », jamais « 87,8 % » nu.

4.6 · conservée « Reconstruire n'est pas vérifier : 9 portefeuilles reconstruits sur 10 restent sans preuve »

Idee — partition honnête des 900 (hors d'atteinte / partiel / complet non testable / vérifiable strict) — le 87,8 % ne vaut que sur les 56 testables, et on l'affiche.

Chiffres — 20 / 715 / 109 / 56 (la partition, somme = 900 — un seul visuel)

Choix — on affiche le **périmètre réel du test** plutôt que de laisser croire à une vérification universelle.

Provenance — Coh-6 conservée telle quelle.

4.7 · fusion « Corroboration : nous retrouvons > 92 % de la base du tiers — et nous sommes son sur-ensemble »

Idee — on compare des ensembles (jamais une fusion de données) en trois crans — exister → dater → concorder ; presque tout ce que Quiver a, nous l'avons aussi ; nous avons beaucoup en plus, et nos vrais trous se comptent un à un.

Chiffres — 93,5 % / 92,1 % (combinaisons élu-ticker-sens de Quiver retrouvées chez nous, Chambre / Sénat) · ≈ 26 500 (combinaisons présentes chez nous, absentes chez Quiver — notre sur-ensemble) · 27 + 11 (nos vrais trous, documentés un à un)

Choix — Quiver est une **vérité-terrain jamais réinjectée** : il mesure la table, ne la remplit jamais — et en cas de désaccord de date, **le PDF officiel arbitre toujours**.

Provenance — fusion S24 (le Venn, conservé) + S25 compressée (l'escalier des 3 niveaux en bandeau ; badges « sens 96,8 % · montant 94,2 % ») ; la table des coquilles (3031-04-30...) et les « 545 candidats » → annexe A6 ; le vocabulaire « tuples / N1-N2-N3 / merge » disparaît.

4.8 · resserrée « Cinq preuves de plus, un principe : rien n'est réinjecté »

Idee — univers officiel re-traversé, deux collectes indépendantes, un agrégateur tiers, des signatures de fichiers pour la non-régression — tout mesure, rien ne remplit (ferme l'étape).

Chiffres — 100 % (des 8 252 PTR de l'index : parsés, lus par OCR, ou écartés par règle écrite) · 100 % / 99,5 % (lignes des deux collectes indépendantes retrouvées chez nous) · 368 (signatures de fichiers : tout re-run doit reproduire les tables à l'octet près)

Provenance — S26 resserrée : 5 cartes → 3 ; Kadoa → 1 ligne « agrégateur tiers » ; le mot « golden » banni (dire « re-run reproductible à l'octet près »).

Bandeau de sortie (sur la dernière slide de l'étape) — **Réponse** : rien raté (173 actions résiduelles côté patrimoine · 27 + 11 vrais trous face au tiers) · cohérent dedans (87,8 % des positions expliquées) · sur-ensemble dehors (> 92 % de la base du tiers retrouvée chez nous).

Étape 5 · Le livrable (3 slides + bilan)

Intercalaire d'entrée — question affichée : *Qu'est-ce qu'on livre, et avec quelles limites ?*

5.1 · re-titrée « De 169 000 à 134 464 : on ne retire que l'avéré inutilisable »

Idée — quatre portes objectives (dates cohérentes, coté, direction claire, montant présent) — et un sauvetage : le ticker coté fait foi quand la case déclarée est vide.

Chiffres — **169 000** → **134 464** (79,6 % du corpus conservé) · **-29 771** (la plus grosse coupe : le non-coté, sans prix de marché possible) · **21 878** (lignes sauvées « ticker-first »)

Choix — on ne retire que l'**avéré inutilisable** ; le doute est **flagué, jamais retiré** (late filing 12,2 %, délistés, lots multi-comptes) — la recherche décide.

Provenance — S27 conservée ; le principe, aujourd'hui en colonne de droite, devient le titre.

5.2 · allégée « Du symbole au prix : 118 029 trades valorisables — et un biais de survie assumé »

Idée — la couverture prix est haute mais décroît vers le passé (titres morts non valorisables) ; la limite est écrite, les lignes non couvertes restent dans la table, flaguées.

Chiffres — **118 029** (trades avec prix fiable, soit $\approx 88\%$ — note obligatoire : même valeur numérique que le taux de cohérence de l'Étape 4, pure coïncidence, aucun lien) · **3 289 / 4 618** (symboles exploitables après garde-fous) · **74 %** → **99 %** (couverture 2014 → 2026 : le biais de survie)

Choix — **biais de survie assumé et écrit**, pas caché.

Provenance — S27b allégée (garde-fous prix et « 84 renommages » → note) ; **ajout** d'une ligne de réconciliation 134 464 (table) vs 134 429 (entrée du moteur aval) — cause exacte des 35 lignes à tracer avant rédaction (§8).

5.3 · allégée « La table livrée : 134 464 lignes × 36 colonnes, traçables au document près »

Idée — le livrable concret — 4 lignes réelles en exemple, les familles de colonnes, la composition, et les limites écrites au même endroit que la table (ferme l'étape).

Chiffres — **134 464 × 36** (372 élus ; chaque ligne traçable à son document source) · **99,4 %** (montants renseignés) · **91,3 % / 50,8 %** (part Chambre ; part d'achats)

Provenance — S28 allégée : les 4 lignes réelles restent (très pédagogiques) ; 5 familles de colonnes → 3 puces ; les limites (582 manuscrits écartés, biais de survie) restent sur la slide.

FIN · conservée « La couche données, en quatre chiffres »

Idée — la réponse à la promesse d'O2 : oui, on peut se fier à la table — vérifiée de l'intérieur et de l'extérieur, limites comprises.

Chiffres — 4 tuiles (exception assumée) : **100 %** de l'univers officiel (8 252 PTR) traité · **169 000** uniques, identité 100 % · **> 92 %** de la base du tiers retrouvée dehors / **87,8 %** des positions expliquées dedans · **134 464 × 36**, limites écrites

Provenance — S29 conservée ; légendes suffixées (les deux pourcentages ne se confondent plus).

Bandeau de sortie (sur la dernière slide de l'étape) — **Réponse** : une table 134 464 × 36 · 79,6 % du corpus · limites écrites.

4 Les chiffres à retenir — et les règles anti-confusion

La liste est **fermée** : sept chiffres, chacun avec sa légende obligatoire (slide, tuile et oral). Tout autre chiffre est un chiffre de passage — il apparaît une fois, ne se retient pas.

Chiffre	Légende obligatoire
8 252	les déclarations officielles de transactions (PTR) de la Chambre 2014–2026 — toutes traitées (100 %)
169 000	transactions uniques extraites de tous les documents, chacune rattachée à un élu identifié (100 %)
$\approx 40\%$	le poids de 2 élus seulement (Khanna, McCaul) — tous deux 100 %
$> 92\%$	papier : l’OCR n’est pas un détail « plus de 9 trades sur 10 <i>du fournisseur commercial indépendant</i> sont aussi chez nous — nous sommes son sur-ensemble » (corroboration, <i>dehors</i>)
87,8 %	des positions de sortie expliquées comptablement : entrée + nos transactions = sortie (cohérence, <i>dedans</i>)
582	les PTR manuscrits écartés par règle écrite et rejouable — la limite assumée n° 1
134 464 × 36	la table de recherche livrée : 134 464 transactions exploitables × 36 colonnes documentées

Règles anti-confusion (paires proches repérées à l’audit) :

- **deux « 87,8 % »** — la cohérence garde l’exclusivité du chiffre, toujours suffixée « des positions expliquées » ; la couverture prix s’exprime en absolu (**118 029** trades valorisables, « $\approx 88\%$ ») et son « 87,8 % » est **banni** des tuiles, avec note « coïncidence numérique » sur la slide 5.2 ;
- **26 524 vs 26 115** — en corps de deck, seul le sur-ensemble Quiver apparaît, arrondi « $\approx 26\,500$ » ; le bloc 26 115 (gain net O/A/T) vit en annexe A5 uniquement, avec sa note « ne pas confondre » ;
- **134 464 vs 134 429** — 134 429 banni des titres et tuiles ; une seule ligne de réconciliation (slide 5.2), après traçage des 35 lignes ;
- « **100 %** » **toujours suffixé** — « 100 % *des 8 252 PTR* traités » / « 100 % *des lignes* identifiées » ;
- **372 vs 368** — toujours avec l’unité : « 372 *élus* » / « 368 *signatures* de fichiers » ;
- « **empreinte** » **réservé à la dédup** (fiche 3.2) — pour la non-régression, dire « *signature* de fichier » (fiche 4.8) : deux concepts, deux mots ;
- **173 vs 27 + 11** — deux « manques » différents : **173** = actions absentes du signal, mesurées *en interne* (hors-PTR) ; **27 + 11** = vrais trous face au tiers *externe* — ne jamais les additionner ni les confondre.

5 La carte des choix — un choix, une slide, une phrase

Encadré uniforme sur la slide porteuse : « **Choix : on a fait X parce que Y** ».

Choix méthodologique	Slide porteuse
1. Filtre type P (signal = PTR uniquement)	1.2 (promesse tenue en 4.2)
2. Index annuel officiel = autorité	1.1
3. Date de dépôt = date du signal (anti-look-ahead)	1.5 (écho en 4.3)
4. Quatre sous-corpus, un extracteur par voie	1.3
5. Deux gabarits Chambre, routés par document	2.2
6. Dédup non destructrice (empreinte 7 champs)	3.2
7. Cascade ticker ordonnée et tracée	3.1
8. Montant = milieu de fourchette	3.3
9. Réparations à la lecture, sources figées	2.5
10. Dates douteuses flaguées, jamais réécrites	1.5
11. Sources externes jamais réinjectées ; le PDF arbitre	4.7 (étendu en 4.8)
12. Gating manuscrit rejouable (582) — asymétrie Sénat assumée	2.3 + 2.4
13. Entonnoir : « on ne retire que l'avéré inutilisable » + ticker-first	5.1

Quatre encadrés *locaux* complètent ces 13 choix : 4.3 (hors-PTR → patrimoine, jamais signal) · 4.5 (chaque cas classé par preuve documentaire) · 4.6 (afficher le périmètre réel du test) · 5.2 (biais de survie écrit).

6 Le lexique — défini où, banni quoi

Chaque terme est défini à sa première apparition (règle : un spectateur neuf ne rencontre jamais un terme non défini) :

STOCK Act, PTR, dépôt	O1	Quiver (mètre externe)	2.3
index annuel, eFD	1.1	bioguide (identifiant officiel)	2.5
DocID (1 ligne, puis disparaît)	1.3	GICS, ETF proxy	3.1
OCR	1.4	empreinte (ex-« clé naturelle »)	3.2
date de dépôt vs date de transaction	1.5	Schedule A / Schedule B	4.2
photo (patrimoine) vs flux (transactions)	4.4	signature de fichier (non-régression)	4.8

Bannis du corps de deck (annexe uniquement, ou reformulés) : « read-time » (dire : réparé à la lecture) · « CSRF / jeton » (dire : accord obligatoire automatisé) · **occurrence_index** (dire : compteur d'occurrence) · **drop_duplicates()** · « tool_use / JSON strict » (dire : sortie structurée forcée) · « golden » nu (dire : re-run reproductible à l'octet près) · « quadrant » · « tuples / N1-N2-N3 / merge » (dire : exister → dater → concorder) · les noms de fichiers internes (sauf le CSV livrable, slide 5.3) · les numéros de notebooks.

7 Les annexes du deck — la réserve pour questions

A1 le PTR lisible, document exemple en grand (ex-S5a) ;

A2 captures détaillées : index XML (ex-S2b), formulaire et liste eFD (ex-S7b) ;

A3 la matrice des sections A→J du formulaire (ex-« Complétude 2/5 ») ;

A4 les 5 types administratifs + le blind trust (ex-« Complétude 5/5 ») ;

A5 le gain net O/A/T : 26 115 (22 216 annuels · 3 899 sorties/amendements · 374 j), **ré-ancré sur sa source** (lignée v1-house) + note « ne pas confondre avec ≈ 26 500 (corroboration) » ;

A6 les dates arbitrées au PDF : la table des coquilles (3031-04-30, 01/35/22, Khanna/COST, McCaul/GOOGL) + les 545 candidats ;

A7 les 11 ETF sectoriels, les cascades ticker/secteur détaillées, la couverture des entrées/sorties (470 / 463), pièges d'identité (Bob Casey, Angie Craig).

Disparaît sans annexe (redites et verbatims) : « 255/373 couchées » ($\times 2$), « l'orientation importe peu » ($\times 2$), la concentration Khanna répétée (gardée en 1.6, une ligne de rappel en 2.3), `report_types=[11]`, la fenêtre $[-90, +10]$ en corps de texte, les URLs complètes.

8 Errata & prérequis avant la réécriture

1. **McCaul : 27 154 $\rightarrow$ 27 123** (slide corpus, 1.461 du deck actuel) — seule erreur factuelle trouvée par l'audit ; le « trio 77,1 % » du deck n'est d'ailleurs vrai qu'avec 27 123.
2. **Tracer les 35 lignes** d'écart entre 134 464 (table livrée) et 134 429 (entrée du moteur aval) *avant* de rédiger la ligne de réconciliation de la slide 5.2 — la cause exacte n'est écrite nulle part dans docs/.
3. **Ré-ancrer le bloc 26 115** (annexe A5) sur sa source réelle, aujourd'hui citée sans ancrage vérifiable côté S3S4 : la lignée `v1-house, 01_v1_house/cache/` (table 16).
4. **Compléter l'énumération des « 12 champs garantis »** (fiche 3.3) : le deck actuel n'en liste que 11 — identifier le 12^e (détenteur ? chambre ?) contre le schéma de la table corpus, et vérifier au passage le stade exact où parti et commissions sont joints.
5. **Ajouter ces points au registre de corrections**, passe 2 (ouverte et vide), au moment de la réécriture : `CORRECTIONS_SLIDES_A_FAIRE.md`.

9 Hors périmètre — à signaler, sans agir

- la **PARTIE III (tables)** est compilée après `\appendix` dans le deck actuel : dans le PDF, les tables sont techniquement des annexes — à corriger lors d'une passe future sur la structure globale ;
- le télescopage « Partie 2 » (pipeline) / « PARTIE II » (backtest) sera réglé au niveau global plus tard — piste notée : rétro-installer un séparateur « PARTIE I » devant le deck données (dont la numérotation interne « Étape 1...5 » devient alors naturelle) ;
- les slides-ponts vers le backtest et les tables (passage de témoin, verdict annoncé) restent à concevoir quand leur position dans le récit global sera décidée.