

# Audit & réparation des données Congress Trading 2014-2026 — rapport final

Date : 2026-07-03 · Branche : 2014-2026-fab1e · Périmètre : couche données uniquement (le dossier

« 02\_recherche\_backtest/ » n'a pas été touché — ses corrections sont consignées dans

PATCHS\_S354\_A\_APPLIQUER.md, archivé sur la branche de travail presentation sous

02\_recherche\_backtest/\_archive/recherche\_v0/).

**Objet** : certifier que TOUTE la donnée nécessaire à la phase de recherche est récupérée, propre, corrigée — et livrer une table de recherche canonique documentée. Règle appliquée : **\*\*chaque erreur relevée est corrigée\*\*** ; ne restent ouvertes que les limites de fidélité-source (flaguées) ou hors de notre contrôle (documentées avec la direction du biais).

## 1. Méthode

- Audit interne** : 23 agents sur 10 dimensions (doublons, dates, tickers, montants, identité, secteurs, entonnoirs, champs, complétude vs officiel, exactitude des docs), chaque anomalie re-vérifiée par un agent sceptique indépendant + un juge cause-racine pour les critiques → **92 findings, 5 réfutés, 87 retenus** (3 critiques, 16 majeures, 35 mineures, 33 constats).
- Cross-validation externe** (indépendante de Quiver) : dump [senate-stock-watcher](#) (8 350 txns Sénat 2012-2020) + mirror house-stock-watcher reconstruit (23 568 txns 2012-2026, champs `owner / filing_id`) + index officiels annuels du House Clerk (`{Y}FD.xml`, 13 années, re-téléchargés). Les fichiers de réplcation de Belmont et al. 2022 (JPubE) ne sont pas publics.
- Sonde parser** : 140 documents pré-2018 re-parsés et comparés à un contrôle indépendant par paires de dates.
- Preuves, scripts reproductibles et listes de lignes : artefacts d'audit (scratchpad de session) ; chaque chiffre de ce rapport provient d'une exécution vérifiée.

## 2. Verdict global

| Avant l'audit                                               | Après réparation                                                                       |
|-------------------------------------------------------------|----------------------------------------------------------------------------------------|
| Corpus FINAL brut : 160 064 lignes (26 fichiers)            | <b>170 920 lignes</b> (+10 856, zéro ligne perdue — contrôle par clé sur chaque année) |
| Uniques après dédup cross-année : 158 172                   | <b>169 000</b>                                                                         |
| Table backtest : 125 984 × 18 colonnes                      | <b>134 464 × 36 colonnes</b> (canonique, invariants vérifiés par asserts)              |
| House pré-2020 (backtest, par date de transaction) : 49 957 | <b>56 706</b> (+13,5 % — la zone la plus déficitaire)                                  |
| Ventes digitales 2014 : 555 (biais vendeur)                 | <b>1 170</b> (parité achats/ventes restaurée)                                          |
| Golden : 224/137 — 1 test rouge                             | <b>Golden 230/138 — 10/10 tests verts</b>                                              |

**La donnée est complète au sens fort** : 100 % des PTR listés par les index officiels du Clerk 2014-2026 sont désormais soit parsés, soit OCRisés, soit écartés par une règle écrite (manuscrits) — plus aucun document « jamais entré dans le pipeline ».

## 3. Complétude — a-t-on tout ?

### 3.1 House vs l'univers officiel (index {Y}FD du Clerk, re-téléchargés le 2026-07-03)

- Univers officiel : **8 252 PTR** (FilingType=P, dédupliqués — zéro chevauchement de DocID entre années).
- Avant : 8 035 traités ; **217 jamais entrés** (205 listés dans {Y}FD mais déposés après le 31/12 — perdus par l'ancien filtre fenêtre année-civile, dont 149 déposés en janvier → biais systématique contre les trades de décembre — + 12 déposés après le gel de collecte 2026-06-19).
- Corrigé : `load_ptr_index` ne filtre plus par fenêtre (l'index annuel est l'autorité) ; les 217 + 75 anciens échecs de parse + 45 filings signalés par le mirror = **293 documents acquis** (227 téléchargés, 0 échec — y compris le 9107514 réputé 404) : 87 lisibles parsés, 136 scannés tapés OCRisés (551 pages, 0 échec), **70 manuscrits écartés par la politique de gating** (documentés, fidèles au census), 6 « nothing to report » (Harold Rogers).
- Il n'existe **plus aucun PTR House officiel non traité**. Cutoff de collecte : 2026-07-03.

### 3.2 Sénat vs census interne + source externe

- Census eFD interne : 2 153 dépôts (1 780 électroniques + 373 papier) ; 2 128 dans les FINAL ; les **25 sans transaction ont désormais chacun une raison écrite** (`data/senate/tables/06d_docs_sans_transaction.csv` : 15 doublons/amendements — 169/169 txns retrouvées sous un autre uuid —, 5 scans dont l'OCR n'a lu que la ligne-exemple pré-imprimée, 2 « nothing to report », 3 déposés après le gel).
- senate-stock-watcher (indépendant de Quiver)** : 6 231 transactions tickérisées 2014-2020 → **100,0 % retrouvées chez nous hors Exchange** (les 36 non-matchés = représentation : SSW éclate l'échange en 2 lignes, nous 1). Nous sommes un sur-ensemble strict de cette source. L'univers

3.3 Vs Quiver et vs le mirror House

• Mirror house-stock-watcher : 99,5 % de ses lignes 2018-2026 chez nous ; pré-2018, les manques qu'il révélait (1 065 lignes à ticker vide, 434 lignes absentes, 45 filings) sont **tous traités** (§4).

• Quiver reste couvert à ~88-92 % par nous (l'écart = papier/non-coté que Quiver n'a pas, et ses propres artefacts) ; ses « 13 715 doublons exacts » sont élucidés : \*\*85,6 % des groupes croisables = lots réels multi-comptes\*\* (owners Self/Spouse/Joint/Child différents, champ que Quiver ne publie pas) ; 755 groupes post-2020 (789 lignes, ~0,7 %) = probables doubles comptages côté Quiver (liste livrée pour flag côté S3/S4).

4. Erreurs trouvées → corrigées (traçabilité complète)

Critiques

| Erreur (preuve)                                                                                                                                                                         | Correction (commit)                                                                                                                                                                                                                                                 |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>205 PTR officiels jamais entrés</b> : filtre fenêtre année-civile de <code>load_ptr_index</code> ; 149/205 déposés en janvier → biais anti-décembre                                  | Cause racine corrigée (index = autorité) + 293 docs acquis et intégrés, zéro perte ( <code>a5b2e07</code> , <code>7d0e57a</code> , <code>d362940</code> )                                                                                                           |
| <b>7 996 fourchettes de montants tronquées à la borne basse</b> (le PDF imprime « \$15,001 ~↔\$50,000 », le parseur ne capturait que la 1re ligne) : montants sous-estimés x2, ~331 M\$ | Réparation read-time déterministe (borne basse → bracket complet, vrai milieu) : <code>AMOUNT_LOWER_BOUND_TO_BRACKET</code> dans <code>common/schema.py</code> , appliquée par <code>load_final</code> ( <code>a5b2e07</code> )                                     |
| <b>Aucun référentiel de renommages/délistages</b> : 18,9 % des lignes du backtest Quiver sans prix utilisable (FB/Meta, PCLN, ATVI...) ; risque de FAUX prix sur symboles recyclés      | <code>data/reference/ticker_renames.csv</code> (84 entrées typées : renommage / fusion-échange / rachat / faillite / recyclage, + validité d'historique du successeur vérifiée contre Yahoo) ( <code>8935805</code> , <code>afccb76</code> , <code>b76c003</code> ) |

Parser & pipeline House

| Erreur                                                                                                                                                                                               | Correction                                                                                                                                    |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Biais vendeur systématique pré-2018</b> : la police rend les majuscules en petites capitales, la regex legacy exigeait <code>[PSE]</code> majuscule → ~95 % des lignes perdues étaient des VENTES | Regex insensible aux petites capitales ; recette sur 140 docs : 100,0 % du contrôle indépendant, zéro sur-extraction ( <code>233d800</code> ) |
| <b>Routage dual perdait la moitié des lignes</b> des docs mixtes (les 2 gabarits coexistent ; « le parser qui extrait le plus » ignorait l'autre)                                                    | Union dédoublée en multiset — préserve les lots réels ( <code>7d0e57a</code> )                                                                |
| 75 PTR lisibles à 0 ligne extraite (58 avec de vrais montants dans le texte, dont Pelosi 20008699, Boehner)                                                                                          | Tous ré-acquis et re-parsés/OCRisés ( <code>7d0e57a</code> , <code>d362940</code> )                                                           |
| Gating des manuscrits non rejouable (33 docs C hérités 2020-2026 qu'un re-run aurait écartés)                                                                                                        | <code>DOCS_C_HERITES_2020_2026</code> : héritage explicite, corpus reproductible ( <code>0fc7d2f</code> )                                     |
| Palier « SP/DC over \$1,000,000 » : formule digitale ≠ convention canonique 1 000 001                                                                                                                | Cas explicite dans <code>amount_midpoint</code> , zéro ligne historique affectée ( <code>d362940</code> )                                     |
| <code>test_tenure</code> rouge à tort (assertion codée en dur : 14 fichiers de l'ère 2020-2026)                                                                                                      | 26 fichiers 2014-2026 ( <code>5051501</code> )                                                                                                |
| Rapport qualité non déterministe (§6.4 dépendait de PYTHONHASHSEED)                                                                                                                                  | Itération triée + tri multi-clés ( <code>a5b2e07</code> )                                                                                     |

Identité, dates, tickers

| Erreur                                                                                                                                                                                                                            | Correction                                                                                                                                                                                                                        |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>52 lignes sans bioguide</b> (Angie Craig 42, Van Hollen 7, Udall 3 — membres invisibles pour toute analyse par membre) + <b>collision d'homonymes</b> : le sénateur Bob Casey rattaché à C000228 (un représentant texan)       | <code>KNOWN_IDENTITY_FIXES_BY_DOC</code> read-time, scopé (doc, nom) : Craig C001119, Van Hollen V000128, Udall U000039, Casey C001070 ( <code>a5b2e07</code> )                                                                   |
| <b>1 065 lignes à ticker vide</b> alors que la description permettait de le résoudre                                                                                                                                              | Récupération par <b>double preuve</b> (notre résolution depuis la description × ticker du mirror concordants) : +403 clés → <b>2 540 lignes</b> récupérées read-time ; discordances et artefacts rejetés ( <code>e4592c3</code> ) |
| Parti = « dernier mandat » (24 lignes fausses : Amash, Mitchell, Manchin) ; commissions = photo 2026 appliquée à toutes les années (24,9 % de couverture en 2016) ; Congrès attribué par année seule (bascule réelle : 3 janvier) | Table canonique : <b>parti point-in-time</b> ( <code>party_affiliations</code> ), <b>commissions point-in-time</b> par Congrès 113-119 (99,1 % de couverture), <code>congress_of</code> au 3 janvier ( <code>50bd685</code> )     |
| Tickers primaires non canonisés (BRK.B/BRK-B scindés, 775 lignes non joignables Yahoo, artefacts OCR à chiffres) ; le littéral coté « NAN » (fonds Nuveen) confondu avec l'artefact pandas                                        | <code>canonical_ticker()</code> + <code>ticker_yahoo/flag_ticker</code> dans la table canonique ; le champ <code>ticker</code> reste fidèle à la déclaration ( <code>a5b2e07</code> , <code>50bd685</code> )                      |
| Dépôts tardifs invisibles (11,8 % > 45 j, 2,3 % > 365 j)                                                                                                                                                                          | Exportés + flagués ( <code>lag_days</code> , <code>flag_late_filing</code> , <code>flag_very_late_filing</code> ) — jamais retirés : l'info est réelle et exploitable à sa date de publication ( <code>50bd685</code> )           |
| Double convention de midpoint (.0 OCR vs .5 digital/Sénat, 85 416 lignes)                                                                                                                                                         | Milieu exact unique recalculé depuis <code>amount_range</code> au niveau de la table canonique ( <code>50bd685</code> )                                                                                                           |
| Secteurs : ETF diversifiés avec de faux secteurs LLM (IWD→XLF, GLD→XLB...), ticker recyclé résolu à l'occupant actuel (NP=Neenah Paper classé Financials)                                                                         | <code>data/reference/ticker_sector_map.csv</code> corrigée (97 ETF requalifiés <code>etf_broad</code> , NP redaté) ; secteur actions 100 % dans la table canonique ( <code>b76c003</code> , <code>50bd685</code> )                |
| Lots multi-comptes exposés à un <code>drop_duplicates()</code> destructeur (info d'occurrence perdue à l'export)                                                                                                                  | <code>owner</code> , <code>occurrence_index</code> , <code>lot_size</code> exportés + avertissement en tête de notebook ( <code>50bd685</code> )                                                                                  |
| Traçabilité Sénat : fichiers d'échecs vides, 25 docs sans-txn intraçables                                                                                                                                                         | <code>06d_docs_sans_transaction.csv</code> avec raison par uuid ( <code>c33ea7d</code> )                                                                                                                                          |
| Divers robustesse : NaN du merge manifest#index plantait le gating ; <code>years_in_office</code> perdu au re-assemblage                                                                                                          | Garde <code>pd.isna</code> ; ré-enrichissement <code>common.enrich_tenure</code> ( <code>d362940</code> )                                                                                                                         |

Restent ouvertes — par choix documenté

• **Fidélité-source (flaguées, pas corrigées)** : coquilles de dates du déposant (le PTR imprime littéralement « 01/35/22 ») ; montants = fourchettes STOCK Act (précision structurelle) ; ~758 lignes OCR nouvelles à ticker non résolu depuis le nom (candidates à une future passe LLM).

• **Hors de notre contrôle** : prix des titres délistés (Yahoo les a purgés, Stooq verrouillé) — traitement PAR TYPE via le référentiel (faillite ≈ perte totale, rachat = clôture à la date du deal ; la direction du biais est désormais explicite, pas « borne haute » générique) ; réplication Belmont et al. non publique ; univers officiel Sénat non re-vérifiable sans re-scraping.

## 5. La table de recherche canonique

`data/clean/transactions_backtest_2014_2026.csv` — **134 452 lignes × 39 colonnes** (134 464 × 36 au moment de l'audit — l'écart : tickers faux-positifs corrigés depuis, cf. `NOTE_DIFF_TABLE_CLEAN.md`), produite par `common/backtest_clean.py` — les étapes sont recensées au §7 de `RAPPORT_DONNEES.md` (entonnoir A→D documenté étape par étape, philosophie « on ne retire que l'avéré, tout le reste est flagué », invariants vérifiés par asserts à l'export : `bioguide/ticker/montant/direction/chronologie/hash` tous garantis).

| Entonnoir                                                                                   | Lignes         |
|---------------------------------------------------------------------------------------------|----------------|
| Départ ( <code>load_final</code> , corpus unique 2014-2026, réparations read-time incluses) | 169 000        |
| A — dates présentes & cohérentes                                                            | 165 748        |
| B — actions + ETF cotés (ticker-first ; ETF diversifiés GARDÉS et flagués)                  | 135 977        |
| C — direction achat/vente                                                                   | 135 151        |
| D — montant présent                                                                         | <b>134 464</b> |

La table Quiver ( `transactions_backtest_quiver_2014_2026.csv` , 108 916) reste disponible en **cross-check** ; la recherche doit basculer sur la canonique (cf. patchs S3/S4) : plus complète (notamment pré-2020), champs `owner/occurrence/doc_id`, corrections intégrales, provenance tracée.

## 6. Vérification finale

- Golden re-figé **House 230 / Sénat 138 fichiers** — `check_golden` + `senate_check_golden` : zéro écart.
- **10/10 tests** de régression verts ( `tests/regression/` ).
- Digital 2020-2026 : append-only prouvé (zéro ligne historique modifiée, `git diff --numstat`).
- Intégration : contrôle par clé (hash, occurrence) sur chacune des 13 années — **zéro perte**.
- Notebook canonique ré-exécuté offline de bout en bout, 0 erreur, asserts passés.