

Audit & réparation des données Congress Trading 2014-2026 — rapport final

Date : 2026-07-03 · Branche : 2014-2026-fab1e · Périmètre : couche données uniquement (le dossier

« 02_recherche_backtest/ » n'a pas été touché — ses corrections sont consignées dans

PATCHS_S354_A_APPLIQUER.md, archivé sur la branche de travail presentation sous

00_recuperation_donnees/_archive/_archive/).

Objet : certifier que TOUTE la donnée nécessaire à la phase de recherche est récupérée, propre, corrigée — et livrer une table de recherche canonique documentée. Règle appliquée : **chaque erreur relevée est corrigée** ; ne restent ouvertes que les limites de fidélité-source (flaguées) ou hors de notre contrôle (documentées avec la direction du biais).

1. Méthode

- Audit interne** : 23 agents sur 10 dimensions (doublons, dates, tickers, montants, identité, secteurs, entonnoirs, champs, complétude vs officiel, exactitude des docs), chaque anomalie re-vérifiée par un agent sceptique indépendant + un juge cause-racine pour les critiques → **92 findings, 5 réfutés, 87 retenus** (3 critiques, 16 majeures, 35 mineures, 33 constats).
- Cross-validation externe** (indépendante de Quiver) : dump [senate-stock-watcher](#) (8 350 txns Sénat 2012-2020) + mirror house-stock-watcher reconstruit (23 568 txns 2012-2026, champs owner / filing_id) + index officiels annuels du House Clerk ({Y}FD.xml, 13 années, re-téléchargés). Les fichiers de réplcation de Belmont et al. 2022 (JPubE) ne sont pas publics.
- Sonde parser** : 140 documents pré-2018 re-parsés et comparés à un contrôle indépendant par paires de dates.
- Preuves, scripts reproductibles et listes de lignes : artefacts d'audit (scratchpad de session) ; chaque chiffre de ce rapport provient d'une exécution vérifiée.

2. Verdict global

Avant l'audit	Après réparation
Corpus FINAL brut : 160 064 lignes (26 fichiers)	170 920 lignes (+10 856, zéro ligne perdue — contrôle par clé sur chaque année)
Uniques après dédup cross-année : 158 172	169 000
Table backtest : 125 984 × 18 colonnes	134 464 × 36 colonnes (canonique, invariants vérifiés par asserts)
House pré-2020 (backtest, par date de transaction) : 49 957	56 706 (+13,5 % — la zone la plus déficitaire)
Ventes digitales 2014 : 555 (biais vendeur)	1 170 (parité achats/ventes restaurée)
Golden : 224/137 — 1 test rouge	Golden 230/138 — 10/10 tests verts

La donnée est complète au sens fort : 100 % des PTR listés par les index officiels du Clerk 2014-2026 sont désormais soit parsés, soit OCRisés, soit écartés par une règle écrite (manuscrits) — plus aucun document « jamais entré dans le pipeline ».

3. Complétude — a-t-on tout ?

3.1 House vs l'univers officiel (index {Y}FD du Clerk, re-téléchargés le 2026-07-03)

- Univers officiel : **8 252 PTR** (FilingType=P, dédupliqués — zéro chevauchement de DocID entre années).
- Avant : 8 035 traités ; **217 jamais entrés** (205 listés dans {Y}FD mais déposés après le 31/12 — perdus par l'ancien filtre fenêtre année-civile, dont 149 déposés en janvier → biais systématique contre les trades de décembre — + 12 déposés après le gel de collecte 2026-06-19).
- Corrigé : load_ptr_index ne filtre plus par fenêtre (l'index annuel est l'autorité) ; les 217 + 75 anciens échecs de parse + 45 filings signalés par le mirror = **293 documents acquis** (227 téléchargés, 0 échec — y compris le 9107514 réputé 404) : 87 lisibles parsés, 136 scannés tapés OCRisés (551 pages, 0 échec), **70 manuscrits écartés par la politique de gating** (documentés, fidèles au census), 6 « nothing to report » (Harold Rogers).
- Il n'existe **plus aucun PTR House officiel non traité**. Cutoff de collecte : 2026-07-03.

3.2 Sénat vs census interne + source externe

- Census eFD interne : 2 153 dépôts (1 780 électroniques + 373 papier) ; 2 128 dans les FINAL ; les **25 sans transaction ont désormais chacun une raison écrite** (data/senate/tables/06d_docs_sans_transaction.csv : 15 doublons/amendements — 169/169 txns retrouvées sous un autre uuid —, 5 scans dont l'OCR n'a lu que la ligne-exemple pré-imprimée, 2 « nothing to report », 3 déposés après le gel).
- senate-stock-watcher (indépendant de Quiver)** : 6 231 transactions tickérisées 2014-2020 → **100,0 % retrouvées chez nous hors Exchange** (les 36 non-matchés = représentation : SSW éclate l'échange en 2 lignes, nous 1). Nous sommes un sur-ensemble strict de cette source. L'univers

3.3 Vs Quiver et vs le mirror House

• Mirror house-stock-watcher : 99,5 % de ses lignes 2018-2026 chez nous ; pré-2018, les manques qu'il révélait (1 065 lignes à ticker vide, 434 lignes absentes, 45 filings) sont **tous traités** (§4).

• Quiver reste couvert à ~88-92 % par nous (l'écart = papier/non-coté que Quiver n'a pas, et ses propres artefacts) ; ses « 13 715 doublons exacts » sont élucidés : **85,6 % des groupes croisables = lots réels multi-comptes** (owners Self/Spouse/Joint/Child différents, champ que Quiver ne publie pas) ; 755 groupes post-2020 (789 lignes, ~0,7 %) = probables doubles comptages côté Quiver (liste livrée pour flag côté S3/S4).

4. Erreurs trouvées → corrigées (traçabilité complète)

Critiques

Erreur (preuve)	Correction (commit)
205 PTR officiels jamais entrés : filtre fenêtre année-civile de <code>load_ptr_index</code> ; 149/205 déposés en janvier → biais anti-décembre	Cause racine corrigée (index = autorité) + 293 docs acquis et intégrés, zéro perte (<code>a5b2e07</code> , <code>7d0e57a</code> , <code>d362940</code>)
7 996 fourchettes de montants tronquées à la borne basse (le PDF imprime « \$15,001 ~↔\$50,000 », le parseur ne capturait que la 1re ligne) : montants sous-estimés x2, ~331 M\$	Réparation read-time déterministe (borne basse → bracket complet, vrai milieu) : <code>AMOUNT_LOWER_BOUND_TO_BRACKET</code> dans <code>common/schema.py</code> , appliquée par <code>load_final</code> (<code>a5b2e07</code>)
Aucun référentiel de renommages/délistages : 18,9 % des lignes du backtest Quiver sans prix utilisable (FB/Meta, PCLN, ATVI...) ; risque de FAUX prix sur symboles recyclés	<code>data/reference/ticker_renames.csv</code> (84 entrées typées : renommage / fusion-échange / rachat / faillite / recyclage, + validité d'historique du successeur vérifiée contre Yahoo) (<code>8935805</code> , <code>afccb76</code> , <code>b76c003</code>)

Parser & pipeline House

Erreur	Correction
Biais vendeur systématique pré-2018 : la police rend les majuscules en petites capitales, la regex legacy exigeait <code>[PSE]</code> majuscule → ~95 % des lignes perdues étaient des VENTES	Regex insensible aux petites capitales ; recette sur 140 docs : 100,0 % du contrôle indépendant, zéro sur-extraction (<code>233d800</code>)
Routage dual perdait la moitié des lignes des docs mixtes (les 2 gabarits coexistent ; « le parser qui extrait le plus » ignorait l'autre)	Union dédoublée en multiset — préserve les lots réels (<code>7d0e57a</code>)
75 PTR lisibles à 0 ligne extraite (58 avec de vrais montants dans le texte, dont Pelosi 20008699, Boehner)	Tous ré-acquis et re-parsés/OCRisés (<code>7d0e57a</code> , <code>d362940</code>)
Gating des manuscrits non rejouable (33 docs C hérités 2020-2026 qu'un re-run aurait écartés)	<code>DOCS_C_HERITES_2020_2026</code> : héritage explicite, corpus reproductible (<code>0fc7d2f</code>)
Palier « SP/DC over \$1,000,000 » : formule digitale ≠ convention canonique 1 000 001	Cas explicite dans <code>amount_midpoint</code> , zéro ligne historique affectée (<code>d362940</code>)
<code>test_tenure</code> rouge à tort (assertion codée en dur : 14 fichiers de l'ère 2020-2026)	26 fichiers 2014-2026 (<code>5051501</code>)
Rapport qualité non déterministe (§6.4 dépendait de PYTHONHASHSEED)	Itération triée + tri multi-clés (<code>a5b2e07</code>)

Identité, dates, tickers

Erreur	Correction
52 lignes sans bioguide (Angie Craig 42, Van Hollen 7, Udall 3 — membres invisibles pour toute analyse par membre) + collision d'homonymes : le sénateur Bob Casey rattaché à C000228 (un représentant texan)	<code>KNOWN_IDENTITY_FIXES_BY_DOC</code> read-time, scopé (doc, nom) : Craig C001119, Van Hollen V000128, Udall U000039, Casey C001070 (<code>a5b2e07</code>)
1 065 lignes à ticker vide alors que la description permettait de le résoudre	Récupération par double preuve (notre résolution depuis la description × ticker du mirror concordants) : +403 clés → 2 540 lignes récupérées read-time ; discordances et artefacts rejetés (<code>e4592c3</code>)
Parti = « dernier mandat » (24 lignes fausses : Amash, Mitchell, Manchin) ; commissions = photo 2026 appliquée à toutes les années (24,9 % de couverture en 2016) ; Congrès attribué par année seule (bascule réelle : 3 janvier)	Table canonique : parti point-in-time (<code>party_affiliations</code>), commissions point-in-time par Congrès 113-119 (99,1 % de couverture), <code>congress_of</code> au 3 janvier (<code>50bd685</code>)
Tickers primaires non canonisés (BRK.B/BRK-B scindés, 775 lignes non joignables Yahoo, artefacts OCR à chiffres) ; le littéral coté « NAN » (fonds Nuveen) confondu avec l'artefact pandas	<code>canonical_ticker()</code> + <code>ticker_yahoo/flag_ticker</code> dans la table canonique ; le champ <code>ticker</code> reste fidèle à la déclaration (<code>a5b2e07</code> , <code>50bd685</code>)
Dépôts tardifs invisibles (11,8 % > 45 j, 2,3 % > 365 j)	Exportés + flagués (<code>lag_days</code> , <code>flag_late_filing</code> , <code>flag_very_late_filing</code>) — jamais retirés : l'info est réelle et exploitable à sa date de publication (<code>50bd685</code>)
Double convention de midpoint (.0 OCR vs .5 digital/Sénat, 85 416 lignes)	Milieu exact unique recalculé depuis <code>amount_range</code> au niveau de la table canonique (<code>50bd685</code>)
Secteurs : ETF diversifiés avec de faux secteurs LLM (IWD→XLF, GLD→XLB...), ticker recyclé résolu à l'occupant actuel (NP=Neenah Paper classé Financials)	<code>data/reference/ticker_sector_map.csv</code> corrigée (97 ETF requalifiés <code>etf_broad</code> , NP redaté) ; secteur actions 100 % dans la table canonique (<code>b76c003</code> , <code>50bd685</code>)
Lots multi-comptes exposés à un <code>drop_duplicates()</code> destructeur (info d'occurrence perdue à l'export)	<code>owner</code> , <code>occurrence_index</code> , <code>lot_size</code> exportés + avertissement en tête de notebook (<code>50bd685</code>)
Traçabilité Sénat : fichiers d'échecs vides, 25 docs sans-txn intraçables	<code>06d_docs_sans_transaction.csv</code> avec raison par uuid (<code>c33ea7d</code>)
Divers robustesse : NaN du merge manifest#index plantait le gating ; <code>years_in_office</code> perdu au re-assemblage	Garde <code>pd.isna</code> ; ré-enrichissement <code>common.enrich_tenure</code> (<code>d362940</code>)

Restent ouvertes — par choix documenté

• **Fidélité-source (flaguées, pas corrigées)** : coquilles de dates du déposant (le PTR imprime littéralement « 01/35/22 ») ; montants = fourchettes STOCK Act (précision structurelle) ; ~758 lignes OCR nouvelles à ticker non résolu depuis le nom (candidates à une future passe LLM).

• **Hors de notre contrôle** : prix des titres délistés (Yahoo les a purgés, Stooq verrouillé) — traitement PAR TYPE via le référentiel (faillite ≈ perte totale, rachat = clôture à la date du deal ; la direction du biais est désormais explicite, pas « borne haute » générique) ; réplcation Belmont et al. non publique ; univers officiel Sénat non re-vérifiable sans re-scraping.

5. La table de recherche canonique

`data/clean/transactions_backtest_2014_2026.csv` — **134 464 lignes** × **36 colonnes**, produite par

[Nettoyage Backtest 2014_2026.ipynb](#) (entonnoir A→D documenté

étape par étape, philosophie « on ne retire que l'avéré, tout le reste est flagué », dictionnaire des colonnes en dernière cellule, invariants vérifiés par asserts à l'export : `bioguide/ticker/montant/direction/chronologie/hash` tous garantis).

Entonnoir	Lignes
Départ (<code>load_final</code> , corpus unique 2014-2026, réparations read-time incluses)	169 000
A — dates présentes & cohérentes	165 748
B — actions + ETF cotés (ticker-first ; ETF diversifiés GARDÉS et flagués)	135 977
C — direction achat/vente	135 151
D — montant présent	134 464

La table Quiver (`transactions_backtest_quiver_2014_2026.csv`, 108 916) reste disponible en

cross-check ; la recherche doit basculer sur la canonique (cf. patches S3/S4) : plus complète

(notamment pré-2020), champs `owner/occurrence/doc_id`, corrections intégrales, provenance tracée.

6. Vérification finale

- Golden re-figé **House 230 / Sénat 138 fichiers** — `check_golden + senate_check_golden` : zéro écart.
- **10/10 tests** de régression verts (`tests/regression/`).
- Digital 2020-2026 : append-only prouvé (zéro ligne historique modifiée, `git diff --numstat`).
- Intégration : contrôle par clé (hash, occurrence) sur chacune des 13 années — **zéro perte**.
- Notebook canonique ré-exécuté offline de bout en bout, 0 erreur, asserts passés.