

Congress Trading Signal

La couche données

Extraction, identification, enrichissement et validation honnête des déclarations
boursières du Congrès américain — Chambre et Sénat, 2014–2026

Alice Lemaire · 4 juillet 2026

Résumé

Les membres du Congrès américain déclarent leurs transactions boursières au titre du *STOCK Act*. Exploiter ces déclarations — par exemple via une stratégie de *copy-trading* — suppose au préalable une couche données propre, traçable et honnêtement validée. Ce rapport décrit cette couche, de l'acquisition des sources jusqu'à la table de recherche finale, pour les **deux chambres** du Congrès sur **treize ans (2014–2026)**. En bref :

- **Corpus** — **170 920** lignes brutes reconstruites depuis les sources officielles, soit **169 000 transactions uniques** après dédup cross-année des re-divulgations : **151 989** pour la **Chambre des représentants** (58 728 électroniques + 93 261 OCR) et **17 011** pour le **Sénat** (13 026 électroniques + 3 985 OCR papier).
- **Couverture** — **100 %** de l'univers officiel : les **8 252 PTR** listés par l'index annuel du *House Clerk* sont tous traités (7 568 avec transactions, 582 manuscrits écartés par une politique écrite et rejouable, 102 sans transaction retenue — chacun motivé).
- **Identité** — **100 %** des lignes rattachées à un `bioguide_id` officiel (**367** membres à la Chambre, **78** au Sénat), avec parti et commissions.
- **Enrichissement** — ticker, secteur **GICS**→**ETF SPDR**, type d'actif, montant *midpoint*, ancienneté : le **contrat de 12 champs métier** sur les deux chambres.
- **Validation externe** — **Quiver Quantitative**, vérité-terrain **jamais réinjectée** : dans notre fenêtre, on retrouve **93,5 %** (Chambre) et **92,1 %** (Sénat) des trades Quiver, et l'on est un **sur-ensemble** de Quiver (+**26 524** combinaisons cotées qu'il n'a pas, contre 38 trous inverses). Deux sources indépendantes corroborent : *senate-stock-watcher* (100 % retrouvé, 2014–2020) et un miroir *house-stock-watcher* (99,5 % sur 2018–2026).
- **Reproductibilité** — golden octet-à-octet (**230** fichiers Chambre + **138** Sénat), invariants assertés, chaque transformation reproduite depuis les colonnes figées.
- **Livrable de recherche** — la **table canonique** `data/clean/transactions_backtest_2014_2026.csv`, **134 464 lignes** × **36 colonnes** : entonnoir justifié A→D, enrichissements *point-in-time*, flags de traçabilité, invariants garantis (§7).

1 Introduction & contexte

Depuis le **STOCK Act** (2012), les membres du Congrès américain doivent divulguer publiquement leurs transactions sur titres dans un *Periodic Transaction Report* (PTR), en principe sous **45 jours**. L'intuition de recherche — documentée académiquement (Ziobrowski *et al.* 2004/2011, Karadas 2019) — est que ces personnes, par leur appartenance à des commissions clés (Finance, *Armed Services*, Intelligence) ou leur exposition à l'information, produisent par leurs déclarations un **signal potentiellement exploitable**. Une stratégie de *copy-trading* consiste à répliquer ces transactions *après* leur publication (anti-*look-ahead* : on date chaque transaction par sa date de divulgation, jamais par une date postérieure connue).

Avant toute stratégie, il faut une **couche données** irréprochable : extraire fidèlement les déclarations des deux chambres sur **treize ans (2014–2026)**, les rattacher à la bonne personne, les enrichir (ticker, secteur, montant) et les valider honnêtement. C'est l'objet de ce rapport. La stratégie et le backtest associés constituent un travail de recherche séparé, hors du périmètre traité ici.

2 Sources & acquisition

Le pipeline part de **sources publiques officielles**, complétées d'un **référentiel d'élus** et de **deux services externes** (un modèle de vision pour les scans, un agrégateur pour la validation). On indique ici où l'on récupère quoi ; le *traitement* de chaque source est détaillé au §4.


- **Chambre des représentants** — *House Clerk*. Source publique sans barrière : une archive ZIP annuelle contenant un **index XML** (`{an}FD.xml`) qui liste tous les dépôts. On retient les PTR (`FilingType=P`) et on télécharge le PDF de chacun (`house/acquire.py` porte le téléchargement des index et des PDF). L'index annuel fait **autorité** sur l'appartenance d'un document à son année : un dépôt tardif — jusqu'à trois ans après les transactions — reste rattaché à l'année de son formulaire. La couverture est **totale** : 100 % des **8 252 PTR** de l'univers officiel 2014–2026 sont traités (§5).
- **Sénat** — *eFD* (*Electronic Financial Disclosure*). L'API de recherche du Sénat (`report_types=[11]` = PTR), accessible après acceptation d'un formulaire d'accord. Chaque dépôt est soit une **page HTML** électronique, soit une **image papier** scannée.
- **Référentiel des élus** — *congress-legislators*. Une déclaration ne donne qu'un *nom* ; ce jeu de données ouvert fournit, pour chaque membre, son identifiant officiel (`bioguide_id`), son **parti** et ses **commissions** — avec un repli sur des YAML embarqués dans le dépôt pour rester reproductible hors-ligne.
- **Lecture des scans** — *Claude Vision*. Une part importante des déclarations de la Chambre et tout le papier du Sénat n'existent que comme **images**. On les lit avec l'API Claude Vision (`claudes-sonnet-4-6`), qui *lit et structure* directement le formulaire en transactions (sortie JSON stricte, cache versionné).
- **Validation** — *Quiver Quantitative*. Agrégateur commercial des transactions du Congrès, utilisé comme **vérité-terrain externe** : on mesure si notre extraction concorde, **sans jamais réinjecter** ses données.

Deux dates par déclaration. Chaque transaction porte une **date d'opération** (`transaction_date`, quand le trade a eu lieu) et une **date de divulgation** (`disclosure_date`, quand le dépôt devient public). Toute la chronologie s'appuie sur la divulgation — principe **anti-look-ahead** : une stratégie ne peut copier un trade qu'*après* sa publication, jamais à sa date d'opération, antérieure et inconnue du marché au moment du dépôt.

3 Architecture & méthodologie


3.1 Un contrat partagé et deux orchestrateurs jumeaux

Le code suit une **architecture symétrique** : un **contrat universel partagé** (`common/`, 11 modules) et **deux orchestrateurs jumeaux** (`house/` et `senate/`) qui s'appuient dessus. `common/` porte ce qui est commun aux deux chambres — schéma, référentiel, OCR de référence, secteur, ancienneté, validation, diagnostic Quiver, qualité, orchestration ; ce qui dépend de la source — acquisition, matcher d'identité, montants, ticker, OCR de production, réconciliation Quiver — vit dans `house/` et `senate/`. Les données et les tests complètent l'ensemble.



Les deux orchestrateurs portent les **mêmes rôles** (digital, ocr, identity, quiver...); seules leurs implémentations diffèrent, là où les sources l'imposent. Les quelques **asymétries de structure** sont assumées et toutes dictées par la source : au Sénat, la fusion et le moteur OCR forment leurs propres modules (`fusion.py`, `ocr_engine.py`) là où la Chambre les garde *en ligne* dans `house/ocr.py`; et le calcul des montants a un module dédié côté Chambre (`amounts.py`) quand le Sénat l'intègre à ses propres modules, chaque chambre gardant sa convention de fourchette. La fusion séparée du Sénat, elle, tient au **volume** : l'enrichissement y passe sur *tout* le corpus en une fois (§4.6), quand la Chambre traite année par année.

3.2 Le flux de bout en bout



3.3 À quoi ressemble la donnée

La couche finale, ce sont **26 fichiers** 06_{chambre}_{an}_FINAL.csv (13 ans × 2 chambres), rangés sous data/house/tables/{an}/ et data/senate/tables/{an}/. Chaque **ligne** est une transaction et porte **28 colonnes** (détail en annexe 12.3). Concrètement :

Une transaction cotée (Sénat). Le sénateur M000355 — *A. Mitchell McConnell, Jr.*, Républicain, KY — déclare l'achat de **WFC** (*Wells Fargo & Company*), une action (Stock) du secteur **Financials** mappé sur l'ETF **XLF**, pour **\$1 001–15 000**, détenue par le conjoint, date jugée *plausible*. Tous les champs « métier » sont renseignés.

Une transaction non cotée (Chambre des représentants), en contraste, montre les **trous légitimes** : le représentant *Jefferson Shreve* déclare une *JP Morgan 3-year auto callable buffer note* — un produit structuré qui n'a **ni ticker, ni secteur, ni ETF** (ces colonnes sont vides) parce qu'il n'est *pas* coté en Bourse. Ce n'est pas un défaut d'extraction : il n'existe pas de symbole à lui attribuer (§4.7).

Autour de ces tables, des fichiers intermédiaires préfixés par **rôle** — 03_index, 05_échecs de parsing, 06_électronique, 06b_OCR, 07*_réconciliation Quiver — tracent chaque étape et restent inspectables. S'y ajoutent les **référentiels transverses** de data/reference/ — renommages et délis-

tages de tickers, carte ticker → secteur, photos des commissions par Congrès (§7) — et la **table de recherche** `data/clean/` qui en dérive.

4 Construction de la donnée, étape par étape

Cette section déroule le **flux de bout en bout** (§3.2) dans l'ordre des dépendances : d'abord le référentiel d'identité (préalable partagé par toutes les pistes), puis le tri des formats, l'extraction de chaque piste (électronique *et* scannée, pour les deux chambres), enfin l'enrichissement et la table finale. Chaque étape en donne le **résultat chiffré**.

4.1 D'abord, savoir qui a déclaré : la résolution d'identité

Une déclaration n'identifie son auteur que par un *nom libre*, dont la graphie varie d'un dépôt à l'autre — « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi ». Sans clé stable, un même élu serait compté plusieurs fois et ne pourrait être rattaché ni à son parti ni à ses commissions. La résolution d'identité ramène donc chaque nom à l'**identifiant officiel** du membre, le `bioguide_id` attribué par le *Biographical Directory* du Congrès (par ex. P000197 pour Nancy Pelosi) : unique, il rend chaque ligne rattachable, déduplicable et joignable au référentiel des élus.

Ce référentiel est partagé par les deux chambres. `common/reference.py` charge les législateurs et leurs commissions (jeu *congress-legislators*, avec repli sur des YAML embarqués) et en dérive, pour chaque `bioguide_id`, le parti, les commissions et un drapeau « commission clé », ainsi qu'un **index de noms tolérant** qui enregistre plusieurs graphies par élu — nom de famille (y compris le dernier mot d'un nom composé), prénom, second prénom et surnom officiel. Chaque chambre construit ensuite son propre **matcher**, car les pièges diffèrent selon la source.

À la Chambre des représentants (`house.identity`), la résolution d'un couple (nom, prénom) suit une cascade à trois niveaux : un **override manuel**, réservé à un unique cas irréductible (« Nicholas V. Taylor », c'est-à-dire Van Taylor) ; à défaut, une **correspondance exacte** dans l'index, après normalisation des accents, des titres (*Hon.*, *Dr.*) et des suffixes, et en essayant les diminutifs usuels (*William* → *Bill*) ; en dernier recours, un **repli sur le nom de famille** lorsqu'il ne désigne qu'un seul élu. Au Sénat (`senate.identity`), où les homonymes sont plus fréquents, la cascade ajoute une **désambiguïsation** : à nom de famille égal, on privilégie d'abord un siège au Sénat, puis le titulaire *en exercice*, enfin une concordance de prénom ou d'initiale. Chaque chambre ne fige qu'un seul override (Van Taylor à la Chambre, J.D. Vance au Sénat). L'identité résolue, `house/digital.py:join_identity` et `senate/identity.py:enrich` y joignent le parti, les commissions et le drapeau de commission clé issus du référentiel partagé.

La résolution rattache **100 %** des lignes des deux chambres : toute ligne conservée porte un `bioguide_id` — **367** membres distincts à la Chambre, **78** au Sénat, sur les treize années ; les multiples graphies d'un même élu sont ramenées à un identifiant unique, précisément ce que la résolution garantit. Une *seule* déclaration manuscrite de 2023 a été **exclue du périmètre membres** : celle d'une **collaboratrice de commission** non-élue (Natalia Henriquez, *House Armed Services Committee*), identifiée en lisant le PDF source — les agents du Congrès n'ont pas de `bioguide_id`.

4.2 Ensuite, trier les formats : électronique ou scanné ?

Une même déclaration peut arriver sous deux formes qui n'appellent pas le même traitement : un *texte* directement exploitable, que l'on analyse ligne à ligne, ou une *image* qu'il faut d'abord lire par OCR. C'est ce tri qui commande toute la suite du pipeline.

À la Chambre des représentants, le format n'est pas annoncé : il faut le déterminer. La fonction `build_manifest` (`house/digital.py`) ouvre chaque PDF avec `pdfplumber` et applique un test binaire : la présence d'une couche de texte (`bool(text.strip())`). Un texte non vide classe le document comme *lisible*, un texte vide comme *non lisible* — donc destiné à l'OCR —, un fichier manquant comme *absent*. Le verdict, consigné dans `04_download_manifest.csv`, oriente tout le reste, et sa simplicité fait sa robustesse. Au Sénat, le tri n'a pas à être calculé : la recherche eFD le fournit déjà, chaque dépôt

portant son type — `ptr` pour une déclaration HTML électronique, `paper` pour une image scannée.

Ce tri d'apparence anodine est la **fourche** du pipeline : il fixe la composition finale du corpus — **58 728** transactions électroniques et **93 261** issues de l'OCR à la Chambre, **13 026** et **3 985** au Sénat (transactions uniques) — et dirige chaque document vers la piste d'extraction décrite dans les sous-sections suivantes.

4.3 La piste électronique de la Chambre (PDF lisibles)

Sur un PDF lisible du Clerk, les transactions ne se présentent pas comme un tableau régulier : une même opération peut s'étaler sur plusieurs lignes, son montant déborder sur la suivante, le ticker se glisser entre parenthèses et le libellé de l'actif courir sur des lignes de continuation. Un simple découpage ligne à ligne en raterait une bonne part ; l'extraction doit donc reconstruire chaque transaction avant de la lire.

`house/digital.py:run_year` enchaîne les étapes. `load_ptr_index` lit l'index XML de l'année et en tire la liste des dépôts (`03_ptr_index.csv`). Le cœur du travail revient à `parse_ptr`, en deux temps : il **recolle** d'abord les lignes coupées — un montant scindé et sa continuation sont réassemblés en une seule ligne (`_join_split_lines`) — puis repère chaque transaction par une expression régulière (`TXN_RE`) qui en fixe la signature : un code d'opération (achat **P**, vente **S**, échange **E**), deux dates et une fourchette de montant. La transaction localisée, il remonte de quelques lignes pour rattacher la description de l'actif et le ticker, imprimés à proximité. Les millésimes anciens, dont la mise en page diffère, sont lus par des **variantes dédiées** du parseur (`parse_ptr_legacy`, `parse_ptr_dual`), sélectionnées par année. `join_identity` joint ensuite l'identité et les métadonnées du dépôt, et `finalize` calcule la clé naturelle, numérote les lots répétés (`occurrence_index`) et déduplique (§4.8).

Le résultat est écrit dans `06_house_{an}_transactions.csv` ; tout PDF lisible ne rendant aucune ligne est consigné dans `05_parse_failures.csv` (aucun échec silencieux). Au total, la piste électronique de la Chambre fournit **58 728** transactions uniques ; sur les 8 252 PTR officiels de l'index, **102** seulement restent sans transaction retenue — vides réels (« *nothing to report* »), amendements sans lignes ou échecs consignés.

Dans la source. Un PTR électronique de la Chambre se lit comme un tableau propre (cf. annexe 12.1) :
« Amazon.com, Inc. — Common Stock (**AMZN**) [ST] · Purchase · 03/16/2018 · \$1 001–\$15 000 ». Le ticker est entre parenthèses, le type d'actif entre crochets — d'où le parsing déterministe.

4.4 La piste électronique du Sénat (HTML eFD)

Le Sénat ne publie pas de PDF mais des pages HTML (l'accès passe par l'accord eFD déjà décrit, §2). La difficulté d'extraction tient aux tableaux eux-mêmes, dont l'intitulé et l'ordre des colonnes varient d'une déclaration à l'autre.

La séquence est portée par `run_year`, qui interroge la liste des dépôts (`fetch_ptr_list`, `report_types=[11]`) puis récupère chaque déclaration (`fetch_report`, avec mise en cache sur disque — un re-run ne retélécharge rien). `parse_electronic` lit alors les tableaux avec `pd.read_html`, qui renvoie des *DataFrames* bruts ; c'est `_find_col` qui y retrouve les bonnes colonnes par **appariement flou** — on retient la colonne dont l'intitulé contient les bons mots-clés (« ticker », ou « asset » et « name ») —, seule approche robuste face à des en-têtes irréguliers. L'identité, la résolution du ticker et la déduplication sont ensuite déléguées à `senate/identity.py:enrich`, qui applique le matcher du Sénat (§4.1) et la même clé naturelle qu'à la Chambre. La sortie est `06_senate_{an}_transactions.csv`.

Cette piste fournit **13 026** transactions électroniques uniques pour le Sénat.

Dans la source. Une déclaration eFD du Sénat est une page web (cf. annexe 12.1) : « **YUM** · Yum! Brands · Sale (Full) · \$1 001–\$15 000 · Joint », avec le ticker cliquable et la date de transaction — d'où la lecture par `pd.read_html`.

4.5 La piste scannée de la Chambre (OCR Claude Vision)

L'autre part des déclarations de la Chambre n'existe que sous forme d'images. Un recensement des **2 424 PDF scannés** (`_scan_census.csv`) les répartit en trois familles : **74** documents tapés et droits (cluster A), **1 575** tapés mais dont l'image est *couchée* (cluster B, le gros du volume) et **775** manuscrits (cluster C). Un modèle de vision lit mal une page tournée, et plus mal encore une date écrite à la main — deux difficultés traitées séparément.

La première est l'orientation. Plutôt que de demander l'angle au modèle — peu fiable, il répond presque toujours « 90 » —, `detect_rotation` lui présente la page sous les quatre orientations (`ROT_CANDIDATES = [0, 90, 180, 270]`) et lui fait **reconnaître** celle qui est droite. Ce redressement améliore nettement la lecture ; le reliquat d'erreur tient à l'ambiguïté *intrinsèque* des dates manuscrites, non à la rotation.

L'extraction proprement dite, dans `house/ocr.py:run_ocr_year`, force un appel d'outil (`tool_use` sur `record_transactions`, modèle `claude-sonnet-4-6`, sept tentatives avec *backoff*) : le modèle répond dans un schéma JSON strict, sans texte libre à re-parser, et chaque résultat est mis en cache, versionné par `prompt_sha` — un re-run ne re-paie que les lots en erreur. Le prompt avait été durci en amont sur un échantillon stratifié des trois clusters (`house/echantillon.py`), pour mesurer la qualité avant le passage à l'échelle. Le ticker, absent des formulaires papier, est ré-associé à partir des symboles vus en électronique, puis complété par une passe LLM. Le volume étant considérable, la fusion électronique + OCR, l'enrichissement et la validation Quiver se font **année par année** pendant le run, qui écrit directement `06_house_{an}_FINAL.csv`.

Le cluster C manuscrit est écarté par une **politique écrite et rejouable** : **582** documents sont *gated* — leurs dates manuscrites sont trop incertaines pour une stratégie datée (un essai contrôlé avec un modèle de vision plus puissant n'améliore pas la lecture des dates : le goulot est l'écriture manuscrite, pas le modèle), et Quiver ne corrobore que **12,9 %** des trades manuscrits (annexe 12.4, D.4). Les exceptions sont explicites et constantes dans `house/ocr.py` : trois déposants à forte perte corroborée (`FILERS_C_A_RECUPERER`) et 33 documents curés à la main (`DOCS_C_HERITES_2020_2026`) — **193** documents C figurent ainsi dans les tables finales. Au total, la piste scannée fournit **93 261** lignes uniques, très concentrées : Rohit Khanna en représente à lui seul **44,0 %**, et le trio de tête (Khanna, McCaul, Harshbarger) **77,1 %** — de gros déposants qui déclarent exclusivement sur papier.

Dans la source. Un scan de la Chambre est un **formulaire à cases** (cf. annexe 12.1), souvent *couché* : une transaction = une ligne où l'on coche le type (Purchase/Sale), la date, et la **fourchette de montant** (une colonne à cocher) — d'où le besoin de deskew puis de Vision.

4.6 La piste papier du Sénat — et pourquoi la fusion y est séparée

Au Sénat, le papier est minoritaire — **quatorze** déposants sur treize ans — mais bien réel : des images `.gif`, cette fois *droites*, qui ne demandent pas de redressement. `senate/ocr.py` les lit avec le même moteur Vision (figé dans `senate/ocr_engine.py`) et écrit la table OCR 06b. La difficulté est ailleurs : avec si peu de données, un dictionnaire de tickers reconstruit année par année serait trop pauvre.

C'est ce qui motive la plus visible des **trois asymétries d'architecture** assumées (§3.1). Là où la Chambre, riche en volume, fusionne et enrichit *pendant* chaque année (§4.5), le Sénat confie ces étapes à un module dédié, `senate/fusion.py`, exécuté une fois toutes les années assemblées. Sa fonction `main` procède en deux temps : d'abord une fusion non destructrice *par année* (électronique + OCR, dédoublée sur le couple (`natural_key_hash`, `occurrence_index`)) ; puis un enrichissement sur le **corpus complet, en une seule passe** — `senate/ticker.py:resolve_tickers` puis `common/sector-enrich.py:enrich_sectors` sur toutes les années concaténées. Mutualiser ainsi le dictionnaire de tickers fait qu'un symbole vu une année sert aux autres.

La piste papier fournit **3 985** lignes uniques, concentrées : Richard Blumenthal en représente **38,7 %**. Ce papier est massivement composé d'actifs **non cotés** (obligations municipales et *corporate*, produits divers) : c'est lui qui explique la couverture ticker et secteur plus basse du Sénat, notamment en 2025–2026 (§5) — un effet de composition des actifs, non d'extraction.

Dans la source. Le papier du Sénat est un formulaire scanné (cf. annexe 12.1) : ex. « Microsoft, NASDAQ/OTC · 2/17/10 », fourchette de montant en colonnes cochées — comme la Chambre OCR, mais droit et sans symbole boursier imprimé (à ré-associer).

4.7 Donner un secteur à chaque ticker : GICS → ETF SPDR

La stratégie visée ne réplique pas les transactions action par action, mais **secteur par secteur**, au moyen d’ETF — des fonds cotés en Bourse qui répliquent tout un panier de titres, ici un secteur entier. Il faut donc, pour chaque ticker déclaré, déterminer son secteur. La référence est la classification **GICS** (*Global Industry Classification Standard*), qui range chaque société cotée dans l’un de onze secteurs ; chacun est associé un-à-un à l’ETF correspondant de la famille *Select Sector SPDR* :

Energy→XLE · Materials→XLB · Industrials→XLI · Consumer Discretionary→XLY · Consumer Staples→XLP · Health Care→XLV · Financials→XLF · Information Technology→XLK · Communication Services→XLC · Utilities→XLU · Real Estate→XLRE

`common/sector_enrich.py:enrich_sectors` résout le secteur par une cascade hybride qui **enregistre sa source** (`sector_source`) : d’abord un secteur factuel via `yfinance` ; à défaut, un LLM (`claude-sonnet-4-6`) contraint de répondre dans l’énumération GICS stricte et de poser un drapeau `is_listed` — garde-fou qui interdit d’attribuer un secteur à un actif **non coté** ; enfin des overrides manuels (les ETF de marché large comme SPY sont ainsi ramenés à *aucun* secteur). La table `GICS_TO ETF` fait la dernière marche. Le ticker lui-même est résolu en trois voies essayées en cascade : un symbole **explicite** déjà imprimé, un **dictionnaire** reliant un nom à un symbole vu ailleurs dans le corpus, puis un **LLM** muni d’un filtre « action » — pour ne jamais tickeriser une obligation ou une muni. Une passe de **recupération** depuis le libellé de l’actif, validée par double preuve et appliquée à la lecture, complète la cascade : **2 540** lignes d’actions y retrouvent leur symbole.

Une précision s’impose sur le mot **couverture** : c’est un *taux de remplissage*, non un taux d’exactitude. Les actifs non cotés — obligations, *munis*, fonds privés — n’ont, par nature, ni symbole ni secteur à recevoir ; une couverture inférieure à 100 % reflète donc avant tout la part d’actifs non cotés, et non un défaut d’extraction.

Au terme de l’enrichissement, le ticker est renseigné pour **84,1 %** des lignes à la Chambre et **77,9 %** au Sénat, le secteur pour **79,8 %** et **70,4 %** — les vides étant le non-coté. Les montants sont ramenés au milieu de leur fourchette (`house/amounts.py:amount_midpoint`), et l’ancienneté (`years_in_office`) couvre **99,9–100 %** des lignes des deux chambres — calculée hors ligne et *appendue* en dernière étape par `common/enrich_tenure.py`, de façon octet-préservante.

4.8 La table finale : le contrat « 12/12 »

Ce qui assemble les quatre pistes sans rien perdre tient en un module, `common/schema.py`, et en une **clé naturelle** de sept champs : `chamber`, `declarant_name`, `transaction_date`, `asset_description`, `operation_type`, `amount_range` et `owner`. Cette clé exclut délibérément deux informations : le `ticker`, ajouté plus tard à l’enrichissement, dont la présence la rendrait instable ; et la `disclosure_date` (§2), car un dépôt initial et son amendement portent le même trade et doivent rester *une* transaction, non deux. Dédupliquer sur cette seule clé écraserait pourtant des lots réels — un déposant peut légitimement déclarer le même titre plusieurs fois dans un même dépôt, via plusieurs comptes. Pour les préserver, `add_occurrence_index` numérote ces répétitions *au sein d’un dépôt* (`occurrence_index`), et `dedup_canonical` ne supprime alors que les vrais doublons d’un dépôt à l’autre : la déduplication est **non destructrice**, opérée sur le couple (`natural_key_hash`, `occurrence_index`). La même clé porte la **dédup cross-année** : une transaction re-divulguée une autre année (amendement, rapport annuel) ne compte qu’une fois — 1 920 re-divulgations sur 170 920 lignes, d’où les **169 000** transactions uniques.

La table finale compte **28 colonnes** — vingt-sept d’assemblage, plus `years_in_office` appendue en dernier. Les **douze champs « métier »** exigés sont exactement la constante `schema.CORE_FIELDS` :

`declarant_name · chamber · party · committee_membership · transaction_date · disclosure_date · ticker · sector_gics · etf_proxy · operation_type · amount_midpoint · asset_type`

Reste une nuance d’honnêteté : « présents » n’est pas « sans valeurs manquantes ». Les douze champs figurent au schéma des deux chambres, mais trois ont des trous **légitimes**, par nature et non par défaut d’extraction : `ticker`, `sector_gics` et `etf_proxy` sont vides pour les actifs non cotés, et `committee_membership` y est un instantané courant, non l’historique daté — la version *point-in-time* est portée par la table de recherche (§7). Les champs toujours renseignables — nom, chambre, parti, dates, opération, montant — sont, eux, quasi complets ; les taux de remplissage exacts (par champ et par sous-corpus) figurent en annexe 12.4.

5 Le rapport de qualité

Une table « pleine » n’est pas pour autant une table *saine* : ses dates peuvent être incohérentes, les délais légaux non respectés, son activité concentrée sur quelques déposants. `common/quality.py` (`build_report`) y répond en **lecture seule** des tables finales, sans aucun appel d’API (matplotlib en mode Agg) : il en tire la couverture de l’univers officiel, **six contrôles**, une décomposition par **sous-corpus** et les figures regroupées en fin de section (figure 1). **Sauf mention contraire, tout porte sur l’ensemble des 169 000 transactions finales uniques — électronique et OCR confondus, les deux chambres, 2014–2026.**

5.1 La couverture de l’univers officiel

L’index annuel du *House Clerk* liste *tous* les dépôts d’une année et fait **autorité** sur l’appartenance d’un document à son année (un dépôt tardif reste rattaché à son formulaire). **100 % des 8 252 PTR officiels 2014–2026 sont traités** — parsés, OCRisés, ou écartés par une règle écrite :

Année	PTR officiels	avec transactions	gated manuscrit	sans txn retenue	couverts %
2014	708	613	94	1	100,0
2015	728	627	97	4	100,0
2016	765	651	110	4	100,0
2017	801	708	82	11	100,0
2018	830	752	68	10	100,0
2019	683	616	52	15	100,0
2020	733	688	35	10	100,0
2021	680	653	15	12	100,0
2022	624	602	14	8	100,0
2023	460	447	2	11	100,0
2024	451	440	5	6	100,0
2025	515	503	6	6	100,0
2026	274	268	2	4	100,0
Total	8 252	7 568	582	102	100,0

PTR officiels = `FilingType='P'` de l’index du Clerk · *avec transactions* = documents présents dans le FINAL de l’année · *gated manuscrit* = cluster C hors exceptions (politique rejouable, §4.5) · *sans txn retenue* = vides réels (« *nothing to report* »), amendements sans lignes ou échecs consignés (`05_parse_failures`). Sénat : pas d’index public re-vérifiable sans re-scrapers eFD ; le census interne fait foi (25 dépôts sans transaction, tous motivés dans `06d_docs_sans_transaction.csv`).

5.2 Les six contrôles

— (a) **Cohérence des dates : 98,1 %** des dates de la Chambre sont exploitables (99,8 % au Sénat) ; parmi elles, **99,9 %** respectent `disclosure ≥ transaction` (99,7 % au Sénat). Une relecture ciblée de 12 PDF sources montre qu’environ la moitié des rares anomalies sont des coquilles du *déposant* lui-même (un PTR imprime littéralement 01/35/22), transcrites fidèlement : aucune date n’est fabriquée, les illisibles restent flaguées.

- (b) **Délai légal** : **87,3 %** (Chambre) et **86,9 %** (Sénat) des dépôts dans les 45 jours prévus par le STOCK Act ; délai médian **27 jours** (Chambre) et **24** (Sénat).
- (c) **Distribution des montants** : **99,4 %** renseignés (167 989 lignes) ; médiane **8 000 \$**, quartile supérieur **32 500 \$**, moyenne 58 314 \$, maximum 75 M\$.
- (d) **Couverture par membre** : **445** déposants distincts, dont **294** ayant déclaré au moins dix transactions et **236** actifs sur au moins trois années.
- (e) **Devenir des achats à +12 mois** : **67,7 %** des achats observables de la Chambre sont revendus (même membre, même ticker) dans les 12 mois suivant la divulgation, **48,3 %** au Sénat ; le solde serait clos d’office par une stratégie à horizon fixe.
- (f) **Validation externe contre Quiver** — développée à la section suivante (§6).


Le détail par an et par champ figure dans docs/RAPPORT_QUALITE.md ; l’essentiel en annexe 12.4.

5.3 Les quatre sous-corpus


Le bilan global masque des écarts marqués entre les **quatre sous-corpus** — Chambre et Sénat, chacun en électronique et en OCR papier. D’abord, la **couverture suit la composition d’actifs**, pas la voie d’acquisition : la part de ticker renseigné, voisine de 84 % sur trois sous-corpus, tombe à **57,4 %** au Sénat OCR — qui ne compte que **40 %** d’actions, le reste étant du non-coté (41 % « autre », munis, obligations) ou du non identifié ; sur un tel corpus, Quiver — restreint aux actions et qui ne référence guère ces déposants-papier — n’offre aucun appui (§6). Cette composition fait aussi baisser la couverture du Sénat en 2025–26 (montée des obligations municipales), sans dégradation de l’extraction. Ensuite, la **concentration** du volume est extrême et croît avec le papier : l’indice de Gini — **0** si tous les déposants pèsent autant, **1** si un seul concentre tout le volume — va de **0,753** (Sénat OCR — 14 déposants seulement, top-10 = 100 % du volume) à **0,953** pour l’OCR de la Chambre ; à la Chambre, la concentration croît nettement avec le papier (0,873 → 0,953), dont les dix premiers déposants captent **94,7 %** du volume. La fiabilité des dates de l’OCR, enfin, est suivie à part par *date_confidence* : une date est jugée *plausible* si le délai dépôt–transaction tombe dans une fenêtre de **75 jours** ; **99,6 %** des lignes OCR des scans tapés droits le sont, **96,4 %** des tapés tournés, **98,6 %** du manuscrit conservé (détail par cluster en annexe 12.4, D.4). Le tableau résume les quatre familles ; le détail (couverture, qualité, mix, concentration) est en annexe 12.4 (D.2–D.5).

Sous-corpus	n	ticker %	sect. %	médiane \$	Gini	top-10 %
Chambre électronique	58 728	83,8	77,7	8 000	0,873	57,6
Chambre OCR	93 261	84,3	81,1	8 000	0,953	94,7
Sénat électronique	13 026	84,1	77,8	8 000	0,826	79,5
Sénat OCR	3 985	57,4	46,2	32 500	0,753	100,0


Gini et *top-10 %* mesurent la **concentration** du volume entre déposants : le Gini va de 0 (tous pèsent autant) à 1 (un seul capte tout) ; *top-10 %* = part du volume détenue par les dix plus gros déposants du corpus. Couverture, qualité, mix et concentration par corpus en annexe 12.4 (D.2–D.5).




(a) Délai disclosure – transaction (0–200 j).




(b) Distribution des montants ($\log_{10}$).




(c) Transactions par année et par chambre.




(d) Top 12 déposants (nombre de transactions).




(e) Sens des opérations, *par sous-corpus*.



(f) Mix de types d'actifs, *par sous-corpus*.



(g) Volume par secteur GICS (top 12, ensemble).



(h) Concentration du volume (Lorenz, Gini ; ensemble).

FIGURE 1 – **Le rapport de qualité en images**, généré par `common/quality.py` (lecture seule, aucun appel API). (a)–(d) **vues d'ensemble** sur les 169 000 transactions finales uniques (électronique et OCR confondus, les deux chambres, 2014–2026 ; seule (c) est ventilée par chambre). (e)–(h) **décomposition** : (e, f) ventilées par sous-corpus ; (g) volume par secteur et (h) concentration du volume, sur l'ensemble.

6 La validation externe (Quiver)

Vérifier la justesse *et la complétude* de l'extraction suppose une source indépendante. On confronte donc le corpus final à Quiver (agrégateur commercial des mêmes déclarations) — **sans jamais le réinjecter** — par une clé normalisée `bioguide × ticker × sens`, en **trois niveaux de stricte** **croissante** (`common/quiver_diagnosis.py`, run offline déterministe) : *a-t-on le trade ?* (sans la date), *le même trade à la même date ?* (appariement 1-à-1), *que reste-t-il à corriger ?* Une limite commande toute la lecture : **Quiver ne suit que les actions cotées** — les lignes non cotées (obligations, *munis*, fonds privés) sont hors de son périmètre, ni validables ni en faute.

Niveau 1 — l'existence. Dans notre fenêtre, on retrouve **93,5 %** (Chambre) et **92,1 %** (Sénat) des combinaisons (membre, action, sens) de Quiver ; le résidu se décompose, et le vrai trou coté est minuscule :

	Quiver (fenêtre)	retrouvés	incl. %	résidu	recup. OCR	hors périm.	trou coté
Chambre	26 175	24 471	93,5	1 704	1 578	95	31
Sénat	4 540	4 180	92,1	360	7	353	0

recup. OCR = trade capté en OCR mais ticker non résolu (nom lisible) ; *hors périm.* = « ticker » Quiver non coté (CUSIP, fragment), ticker d'échange combiné, ou membre de l'autre chambre ; *trou coté* = manque au niveau **combinaison** (membre, ticker, sens — sans la date). La mesure complémentaire au **trade daté** (niveau 2) confirme **27** trous Chambre et **11** au Sénat : ces derniers sont des occurrences datées manquantes à l'intérieur de combinaisons par ailleurs retrouvées — les deux comptes ne s'emboîtent pas, et $27+11$ = les 38 trous inverses du résumé.

On est un sur-ensemble de Quiver. En sens inverse, on possède **23 562** (Chambre) et **2 962** (Sénat) actions cotées que Quiver n'a pas — **+26 524** combinaisons cotées, contre 38 trous inverses. L'électronique, lui, est quasi exact des deux côtés (98–99 % de concordance).

Niveau 2 — la date. L'appariement **1-à-1** à l'intérieur de chaque (membre, ticker, sens) — dates identiques d'abord, puis plus proche voisin plafonné à 90 jours, quantités respectées — classe chaque trade :

	apparié exact	proche (≤ 10 j)	candidats	nous-seul	quiver-seul
Chambre	70 265	845	2 202	39 207	9 899
Sénat	8 766	0	0	3 140	581

proche = voisin apparié à ≤ 10 j d'écart ; *candidats* = voisin entre 10 et 90 jours (date divergente, appariement incertain — parmi ces 2 202, seules les **545** paires issues de la *même déclaration* des deux côtés sont d'honnêtes candidats d'erreur de date, cf. ci-dessous) ; *nous-seul* = Quiver n'a pas le trade (on est plus complet) ; *quiver-seul* = absent de nos clés exactes (surtout OCR papier et non-coté). Les volumes « nous-seul » ne contredisent pas le niveau 1 : c'est le niveau de stricte qui change (trade daté *vs* combinaison). Les seuls candidats honnêtes d'erreur de date — les paires issues de la **même déclaration** des deux côtés — sont **545** à la Chambre et **0** au Sénat ; un petit delta peut être une convention de date de Quiver, et le vrai contrôle des dates reste la relecture des PDF sources (§5).

Niveau 3 — les autres champs. Sur les trades présents des deux côtés (membre + ticker + date), l'accord est de **96,8 %** sur le sens et **94,2 %** sur le montant à la Chambre (**99,9 / 99,8 %** au Sénat). La liste résiduelle « à revoir » tient en trois lignes — **27 / 11** vrais trous cotés (le seul chiffre dur), 3 378 lignes-papier absentes de nos clés exactes et $8 418 + 190$ « autre ticker le même jour » (bornes hautes ensemblistes, listées cas par cas dans `docs/quiver_validation/`, pas des taux d'erreur).

Honnêteté par ère. Le taux global lisse une hétérogénéité temporelle : au niveau action (Chambre), **87,2 %** de nos actions 2020–2026 sont corroborées par Quiver, contre **58,7 %** sur 2014–2019 (creux 2015–2016 : 16,6 %). L'écart ne signale pas une erreur de notre côté : nos actions « en plus » pré-2020 portent des tickers réels et d'époque (vérifiés), mais **Quiver est mince avant ≈ 2017** et ne peut pas les corroborer. Il y a donc *moins de vérité-terrain externe avant 2017* — à garder en tête pour tout usage aval. Détail par année en annexe 12.4 (D.4).

Cross-validation indépendante (hors Quiver). Deux sources tierces complètent le contrôle : *senate-stock-watcher* (6 231 transactions tickérisées 2014–2020) est couvert à **100 %** par notre corpus Sénat — hors représentation des échanges, que cette source éclate en deux lignes ; un miroir *house-stock-watcher* reconstruit est retrouvé à **99,5 %** sur 2018–2026. Le papier du Sénat, massivement non coté et absent de Quiver, se juge à ces contrôles internes et croisés, pas à Quiver.

7 Du corpus à la table de recherche (nettoyage backtest)

Le corpus final décrit jusqu'ici est *fidèle aux déclarations* : il contient aussi des actifs sans prix de marché, des dates illisibles et des opérations sans sens directionnel. Un backtest, lui, exige un **prix**, un **sens** et un **montant**. Une étape dédiée dérive donc la **table de recherche canonique** — `data/clean/transactions_backtest_2014_2026.csv`, **134 464 lignes** × **36 colonnes** — produite par le notebook `Nettoyage_Backtest_2014_2026.ipynb` : exécutable hors-ligne, sans logique dupliquée (il réutilise `load_final`, `canonical_ticker` et les référentiels transverses).

Philosophie : on ne retire que l'avéré inutilisable pour un backtest actions/ETF ; tout le reste est gardé et flagué — le doute se tranche en aval, jamais en silence.

7.1 L'entonnoir $A \rightarrow D$

Étape	Règle exacte	Retirées	Restantes
—	départ : le corpus unique (<code>load_final</code>)	—	169 000
A	dates présentes & cohérentes : les deux dates lisibles, $\text{divulgarion} \geq \text{transaction}$, année de transaction plausible (≥ 2012 et $\leq$ année de dépôt)	3 252	165 748
B	actions + ETF cotés , « ticker d'abord » : symbole normalisé non vide, réellement coté (ni CUSIP, ni préférentielle \$, ni fragment OCR), famille d'actif $\notin \{\text{obligation, muni, gouvernement, option, autre}\}$	29 771	135 977
C	direction exploitable : achat ou vente (les échanges, à l'économie ambiguë, sortent)	826	135 151
D	montant présent : <code>amount_midpoint</code> numérique	687	134 464

$169\,000 \rightarrow 134\,464 = \mathbf{79,6\%}$ du corpus conservé. Chaque retrait est motivé par l'impossibilité *matérielle* de backtester la ligne, jamais par un simple champ vide récupérable.

Pourquoi les lignes de l'étape B partent — ventilation prouvée par une cellule de contrôle (une seule cause par ligne) :

- **27 006** sans aucun ticker : actifs non cotés (munis, obligations, sociétés privées) qui n'ont légitimement pas de symbole — donc pas de prix ;
- **164** tickers malformés : préférentielles \$, deux symboles collés, fragments OCR, CUSIP ;
- **2 601** options / obligations : famille explicitement non cotée.

Le filtre raisonne « **ticker d'abord** » : **21 878** vraies actions/ETF au champ `asset_type` vide sont *gardées* grâce à leur ticker coté (un filtre « type d'abord » les jetterait à tort) ; contrôle d'étanchéité : **0** ligne de famille non cotée ne fuit parmi les gardées.

7.2 Montants : une convention unique

- `amount_midpoint` = **milieu exact de la fourchette** STOCK Act, $(\text{borne basse} + \text{borne haute})/2$, recalculé depuis `amount_range` sur tout le corpus — une seule convention ;
- un montant exact déclaré (ex. \$584) reste tel quel ;
- le palier ouvert « *Over \$50,000,000* » est posé à son **plancher** (50 M\$), pour ne jamais inventer de masse.

7.3 Enrichissements point-in-time et flags (aucune ligne retirée)

Tout ce qui suit *ajoute* de l'information, sans jamais filtrer :

- **Parti à la date de la transaction** — depuis les `party_affiliations` du référentiel officiel : les changements de parti *en cours de mandat* sont datés (Amash 2019, Mitchell 2018, Manchin 2024) ;
- **Commissions du Congrès de la transaction** — photos par Congrès (`committees_snapshots/` sous `data/reference/`, Congrès 113 à 119), bascule au 3 janvier des années impaires ; **99,1 %** des lignes résolues ; `committees_key_flag` (fiscalité, défense, renseignement, banque : 54,6 %) — la liste complète des commissions est exportée, la recherche peut redéfinir son propre flag sans re-générer la table ;
- **Ticker fidèle + ticker_yahoo** — `ticker` reste tel que déclaré ; `ticker_yahoo` est le symbole **canonique pour le join prix** (format Yahoo, renommages et fusions appliqués via `ticker_renames.csv`) : **2 817** lignes re-symbolisées, **3 542** lignes sur titres délistés *typés* (rachat, faillite...) au lieu de disparaître en silence, **505** lignes « prudence prix » (`flag_price_caution` : symbole recyclé ou jambe absorbée d'une fusion, dont l'historique du successeur ne vaut pas avant le deal) ;
- **Classe d'actif et secteur** — `asset_class` (stock 128 974 · `etf_broad` 2022 · `etf_sector` 168 · unknown 3 300) via la carte transverse `ticker_sector_map.csv` ; le secteur GICS est renseigné pour **100 %** des actions et `etf_proxy` pour **98,8 %** des lignes ; un **ETF diversifié n'a pas de secteur** (`etf_broad`, flagué `is_broad_etf`) — jamais de faux secteur ;
- **Flags de traçabilité** — dépôt tardif >45 j : **16 349** lignes (**12,2 %**) ; >365 j : **3 075** (**2,3 %**) — l'information reste réelle et exploitable à sa `disclosure_date`, on flague, on ne retire pas ; `lot_size` — **11 873** lignes appartiennent à des **lots multi-comptes réels** (mêmes 7 champs de clé : comptes Self/Spouse/Joint/Child) : **ne jamais drop_duplicates()** sur cette table.

7.4 Les référentiels transverses (data/reference/)

- `ticker_renames.csv` — **84 entrées** : renommages (21 : FB→META, PCLN→BKNG...), fusions-échanges (11), rachats avec délistage (43), faillites (5), recyclages de symbole (4) ; chaque entrée précise la **validité d'historique** du successeur (la jambe absorbée d'une fusion n'a pas de prix avant le deal) ;
- `ticker_sector_map.csv` — **4 848 tickers** → classe d'actif, secteur GICS, ETF proxy (4 330 actions, 97 ETF larges, 11 ETF sectoriels, 410 non tranchés) ;
- `committees_snapshots/113..119` — la composition des commissions à chaque Congrès (membres et intitulés), source du point-in-time.

7.5 Composition finale et garanties

	2014–2019	2020–2026	Total		
				Sens	n
Chambre des représentants	56 706	66 108	122 814		
Sénat	7 111	4 539	11 650	achats (buy)	68 250
				ventes (sell)	66 214
Total	63 817	70 647	134 464		

Par sous-corpus : Chambre OCR 75 205 · Chambre électronique 47 609 · Sénat électronique 9 729 · Sénat OCR 1 921.
Ères découpées sur l'année de la transaction.

Invariants garantis par assertions à l'export — la table est *certifiée* sur : `bioguide_id` présent · `ticker` présent · `amount_midpoint` présent · `direction` ∈ {buy, sell} · chronologie (`lag_days` ≥ 0) · `natural_key_hash` présent — sur 100 % des 134 464 lignes.

7.6 Dictionnaire des 36 colonnes

#	Colonne	Sens
	Identité du déposant	

#	Colonne	Sens
1	bioguide_id	identifiant officiel du membre (toujours rempli)
2	member_name	nom tel que déposé
3	party	parti à la date de la transaction (point-in-time, switches gérés)
4	chamber	house / senate
5	state_district	état + district
Mandat (point-in-time)		
6	committee_membership	commissions du Congrès de la transaction (snapshots 113–119)
7	committees_key_flag	commission « clé » (fiscalité / défense / renseignement / banque)
8	congress	numéro du Congrès de la transaction (bascule au 3 janvier)
Compte & lots		
9	owner	titulaire du compte (Self / Spouse / Joint / Child)
10	occurrence_index	rang du lot au sein du dépôt
11	lot_size	taille du lot de lignes identiques (mêmes 7 champs de clé) — ne jamais dédupliquer
Titre		
12	ticker	symbole fidèle à la déclaration
13	ticker_yahoo	symbole canonique pour le join prix (format Yahoo, renommages appliqués)
14	flag_ticker	statut de normalisation (ok / classe_convertie / contient_chiffre)
15	is_delisted	titre sorti de cote (booléen)
16	delist_type	type de sortie de cote (rachat, faillite, fusion-échange...)
17	flag_price_caution	prudence au join prix (symbole recyclé, jambe absorbée d'une fusion)
Classe & secteur		
18	asset_class	stock / etf_sector / etf_broad / unknown
19	asset_type	type d'actif déclaré à la source
20	is_broad_etf	ETF diversifié (sans secteur GICS, par nature)
21	sector_gics	secteur GICS (actions seulement)
22	etf_proxy	ETF SPDR du secteur
Opération		
23	direction	buy / sell
24	amount_midpoint	milieu exact de la fourchette (convention unique)
25	amount_range	fourchette source déclarée
26	amount_range_repaired	indicateur : borne haute de la fourchette reconstituée à la lecture
Dates		
27	transaction_date	date de la transaction
28	disclosure_date	date de divulgation — l'entrée anti-look-ahead
29	lag_days	divulgation – transaction (jours)
30	flag_late_filing	dépôt au-delà des 45 j légaux
31	flag_very_late_filing	dépôt au-delà de 365 j
Traçabilité		
32	doc_id	identifiant du document source (PTR / eFD)
33	provenance	piste d'acquisition (électronique / OCR, par chambre)
34	ticker_source	origine du ticker (explicite / dictionnaire / LLM / récupéré)
35	natural_key_hash	clé de déduplication (7 champs)
36	asset_description	libellé source de l'actif

8 Assurance qualité & reproductibilité

Le pipeline n'est pas rejouable hors ligne : le *scraping* exige le réseau, l'OCR une API, et rejouer une année électronique produirait même une table vide, puisque les PDF lisibles ont été parsés puis écartés. La correction ne peut donc se prouver par simple ré-exécution ; on l'établit, plus solidement, par **reproduction déterministe depuis les colonnes figées**.

Quatre garde-fous s'y emploient. D'abord, un **golden octet-à-octet** : l'empreinte SHA-256 de chacune des sorties est figée — **230** fichiers à la Chambre, **138** au Sénat, 368 tables CSV — et `check_golden.py` (respectivement `senate_check_golden.py`) doit afficher « ZÉRO ÉCART » à chaque exécution. Ensuite, des **reproductions fonction par fonction** : `test_senate_repro` recompose chaque hash de clé naturelle (8 841/8 841 sur les années 2020–2026) et réassocie identité et ticker à partir des seules colonnes figées ; côté Chambre, `test_schema`, `test_amounts_tickers`, `test_identity`, `test_tenure` et `test_crosscheck` jouent le même rôle. Troisièmement, `test_vision_sha` et `test_incremental` vérifient que le `prompt_sha` est stable — un second passage OCR ne déclenche aucun appel. Enfin, `audit_metrics.py` recompute l'ensemble des métriques et *assure* les invariants porteurs (totaux, identité 100 %, 367/78 bioguides) : c'est la source de vérité chiffrée de ce rapport. Au total, **dix scripts de régression**, tous au vert.

La **table de recherche canonique se recompose exactement** : le rapport qualité rejoue l'entonnoir A→D avec les mêmes primitives que le notebook et *assure* l'égalité (134 464 lignes) avec le fichier publié ; l'export du notebook vérifie ses six invariants (§7). Les réconciliations Quiver, déterministes grâce à un tri à départage stable, sont figées dans le golden au même titre que les tables.

9 Limites (honnêteté)

- **Manuscripts gated** : **582** documents manuscrits (cluster C) sont écartés par une **politique écrite et rejouable** (exceptions explicites dans `house/ocr.py`) : leurs dates sont trop incertaines pour une stratégie datée, et Quiver ne corrobore que 12,9 % des trades manuscrits. Choix assumé et documenté, listes rejouables.
- **ticker/sector_gics/etf_proxy structurellement absents** pour munis et obligations : les actifs **non cotés** n'ont ni symbole ni secteur, par nature. C'est aussi ce qui met une partie de l'OCR (le papier du Sénat surtout) **hors périmètre Quiver**.
- **Fourchettes STOCK Act** : les montants déclarés sont des *tranches*, pas des chiffres exacts. `amount_midpoint` en prend le milieu exact (convention unique ; palier ouvert >50 M\$ au plancher) : l'incertitude intra-tranche est irréductible.
- **Prix des délistés — traités par type** : via `ticker_renames.csv`, chaque titre sorti de cote porte son `delist_type` ; au backtest, une **faillite** $\approx$ perte totale, un **rachat** = clôture au prix du deal à sa date, une **fusion-échange** bascule sur le successeur (historique invalide avant le deal, `flag_price_caution`).
- **Commissions des tables FINAL = photo courante** ; l'historique daté (par Congrès) est porté par la table de recherche canonique (`committee_membership` point-in-time, §7).
- **Vérité-terrain mince avant $\approx$ 2017** : Quiver ne peut corroborer qu'une partie de nos lignes pré-2017 (réelles mais peu vérifiables par lui) ; *senate-stock-watcher* confirme le Sénat 2014–2020 à 100 %.
- **Dates OCR résiduellement imprécises** : quelques dates de transaction lues sur scan restent douteuses (flaguées `date_confidence`) ; tout usage aval entre sur `disclosure_date` — l'anti-*look-ahead* n'en dépend pas.
- **Cutoffs de collecte** : Chambre 2026-07-03, Sénat 2026-06-25 — les dépôts postérieurs ne figurent pas dans le corpus.

10 Périmètre & suite

La **couche données** décrite ici est livrée : **169 000** transactions uniques (170 920 lignes brutes) extraites, identifiées, enrichies (contrat 12/12), validées et reproductibles — et la **table de recherche canonique** (**134 464** × **36**) prête pour le backtest. La **stratégie et le backtest** associés (copy-trading actions puis ETF sectoriels) constituent un travail de recherche séparé, hors-périmètre de ce rapport.

11 Conclusion

Sur deux chambres et **treize ans**, le pipeline reconstruit **170 920** lignes (**169 000** transactions uniques) à partir des sources officielles, en traitant honnêtement les deux pistes (électronique déterministe *et* scannée par OCR Vision), et couvre **100 %** de l'univers officiel du Clerk (8 252 PTR). Chaque ligne est identifiée (100 %, 367/78 bioguides), enrichie (contrat 12/12 sur les deux chambres) et validée contre Quiver sans jamais le réinjecter : **93,5 %** (Chambre) et **92,1 %** (Sénat) des trades Quiver retrouvés dans la fenêtre, un **sur-ensemble** de Quiver (+26 524 combinaisons cotées), corroboré par deux sources indépendantes. La correction est figée (golden octet-à-octet, 230/138) et reproductible. Le livrable de recherche est la **table canonique** **134 464** × **36** : entonnoir justifié, montants à convention unique, parti et commissions *point-in-time*, tickers prêts pour le join prix, délistés typés — et chaque limite connue (manuscrits gated, non-coté, fourchettes, corroboration mince pré-2017) documentée et flaguée, jamais masquée. C'est une couche données sur laquelle une stratégie peut être bâtie *en connaissant ses limites*.

Module	Rôle	Fonctions clés
schema.py	clé naturelle + dédup	natural_key_hash (SHA-256 de 7 champs) · add_occurrence_index · dedup_canonical (non destructive) · canonical_ticker · CORE_FIELDS
sector_enrich.py	secteur GICS → ETF	resolve_yfinance · resolve_llm (is_listed) · enrich_sectors (+ sector_source) · GICS_TO ETF
vision_ocr.py	OCR Vision de référence	detect_rotation (deskew 4 rotations) · pdf_to_b64_images · VisionExtractor.prompt_sha · .extract_cached
crosscheck.py	statut par déposant	per_filer_status · add_external_counts · summary
quality.py	rapport qualité (six contrôles)	load_final · date_coherence · delay_buckets · amount_distribution · coverage_per_member · backtest_funnel · build_report
quiver_diagnosis.py	complétude vs Quiver (3 niveaux, §6)	ticker_inclusion (N1) · reconcile_dates (N2, 1-à-1) · field_disagreements (N3) · build_diagnosis
quiver_scopes.py	validation Quiver multi-scopes	reconcile_scopes (digital/ocr/both → 07c-07f) · match_breakdown (par actif & cluster → 07g/07h)
enrich_tenure.py	ancienneté	add_years_in_office (append years_in_office octet-préservant) · main
report_pdf.py	rapport qualité → PDF	md_to_html · build_pdf · main
pipeline.py	orchestrateur	build_steps (séquence en sous-processus) · main (-years, -dry-run)
house/ — orchestrateur Chambre (9)		
acquire.py	acquisition index + PDF	download_index · download_pdfs · main (-years)
digital.py	PTR électroniques	load_ptr_index (XML, FilingType=P) · build_manifest (tri lisible/non) · parse_ptr / parse_ptr_legacy / parse_ptr_dual · finalize · run_year
classify_scans.py	classement des scans (A/B/C)	classify_one (Vision, page 1) · main
ocr.py	scans → FINAL (par an)	run_ocr_year (Vision + fusion + ticker + secteur + Quiver) · FILERS_C_A_RECUPERER · DOCS_C_HERITES_2020_2026 (gating manuscrit)
identity.py	matcher Chambre	make_matcher (override→exact+urnoms→nom unique) · _MANUAL_BIO
amounts.py	montant & opération	amount_midpoint (milieu de fourchette) · operation_type_from_code (P/S/E) · HOUSE_OCR_AMOUNT_MAP
tickers.py	ticker + type d'actif	explicit_ticker · recover_ticker · infer_asset_type (par chambre)
quiver.py	réconciliation Quiver	reconcile · norm_ticker (robuste NaN/vide)
echantillon.py	pilote OCR stratifié	run_echantillon · compare_quiver
senate/ — orchestrateur Sénat (8)		
digital.py	eFD électronique	accept_agreement (CSRF) · fetch_ptr_list (report_types=[11]) · fetch_report · parse_electronic (pd.read_html, _find_col) · run_year
ocr.py	papier .gif → 06b	discover_index · ocr_one (un .gif → Vision) · build_table
ocr_engine.py	moteur OCR figé	extract_report · normalize · _infer_asset_type
fusion.py	fusion + enrich corpus	main (Étape 1 fusion/an · Étape 2 enrichissement corpus + Quiver) · date_confidence
identity.py	matcher Sénat	load_reference · make_matcher (désambiguïsation chambre, exclut délégués) · enrich
ticker.py	ticker 3 voies	resolve_tickers (explicit→dict→LLM) · llm_resolve_tickers
quiver.py	réconciliation Quiver	reconcile · norm_ticker · norm_sense
census_probe.py	census + sondage parser	parse_electronic · main

Les `__init__.py` (exports de paquet) et `tests/regression/` (golden + reproductions) complètent le

dépôt. Le secteur (*common/sector_enrich*) et la clé (*common/schema*) sont importés en direct par les deux orchestrateurs — d'où leur place dans *common/*.

12.3 Annexe C — le schéma FINAL (28 colonnes)

#	Colonne	Sens	Remplie par
1	bioguide_id	identifiant officiel du membre	identity
2	declarant_name	nom tel que déposé	parse / OCR
3	chamber	house / senate	enrich_identity
4	party	parti	Reference.party
5	state_district	état + district	03_ptr_index
6	committee_membership	commissions (liste)	Reference.committees
7	committees_key_flag	commission « clé » ?	reference
8	transaction_date	date de la transaction	parse / OCR
9	disclosure_date	date de divulgation (dépôt)	03_ptr_index / eFD
10	ticker	symbole boursier	tickers / ticker
11	asset_description	libellé de l'actif	parse / OCR
12	asset_type	type d'actif	infer_asset_type
13	sector_gics	secteur GICS	sector_enrich
14	etf_proxy	ETF SPDR du secteur	GICS_TO ETF
15	operation_type	Purchase / Sale / ...	operation_type_from_code
16	amount_range	fourchette déclarée	parse / OCR
17	amount_midpoint	milieu de la fourchette	amount_midpoint
18	amount_split_flag	lot multi-actifs ?	parse
19	owner	propriétaire (self/spouse...)	parse / OCR
20	doc_id	identifiant du PTR	03_ptr_index
21	source_url	URL de la source	03_ptr_index
22	natural_key_hash	clé de dédup (7 champs)	schema
23	occurrence_index	rang du lot intra-dépôt	add_occurrence_index
24	provenance	*-electronic / *-ocr	pipeline
25	date_confidence	plausible / implausible (75 j)	date_confidence
26	ticker_source	explicit / elec_dict / llm / none	tickers / ticker
27	sector_source	yfinance / llm / manual / none	sector_enrich
28	years_in_office	ancienneté à la date du trade	enrich_tenure

L'ordre exact diffère légèrement entre Chambre et Sénat (*date_confidence* plus tôt au Sénat); le contenu garanti — les 12 champs « métier » — est identique. Les 27 colonnes d'assemblage (*HOUSE_FINAL_SCHEMA* / *SENATE_FINAL_SCHEMA*) + *years_in_office* = 28. Le dictionnaire de la *table de recherche canonique* (36 colonnes) est au §7.

12.4 Annexe D — métriques vérifiées (recalculées depuis les FINAL)

Lue après le rapport, cette annexe dit si l'extraction a bien marché. Chaque tableau indique sa **source** : [A] chiffre *asserté* par le filet de non-régression *tests/regression/audit_metrics.py* (un écart le fait échouer); [Q] recalculé par *common/quality.py* (descriptif); [D] recalculé par *common/quiver_diagnosis.py* (diagnostic Quiver, offline déterministe). La version exhaustive — toutes les années, tous les champs — est le rapport qualité *docs/RAPPORT_QUALITE.md*, dont cette annexe ne retient que l'essentiel.

D.1 — Volumes par an & identité

[A] totaux & identité · [Q] ventilation par an

An	Chambre				Sénat			
	élec.	OCR	FINAL	dépos.	élec.	OCR	FINAL	dépos.
2014	2 340	8 389	10 729	101	651	241	892	19
2015	4 791	4 789	9 580	101	1 151	281	1 432	27
2016	4 655	2 907	7 562	107	995	427	1 422	30
2017	4 546	8 036	12 582	112	1 320	210	1 530	33
2018	4 437	10 190	14 627	97	1 236	641	1 877	31
2019	5 188	7 366	12 554	104	1 158	506	1 664	35
2020	6 885	9 207	16 092	111	1 655	255	1 910	33
2021	5 454	6 936	12 390	121	632	281	913	35
2022	3 601	11 857	15 458	112	912	182	1 094	27
2023	4 168	6 687	10 855	100	1 032	97	1 129	30
2024	2 701	6 948	9 649	98	946	84	1 030	24
2025	7 576	6 159	13 735	107	859	477	1 336	31
2026	2 386	3 790	6 176	85	479	303	782	22
Tot.	58 728	93 261	151 989	367*	13 026	3 985	17 011	78*

élec. = électronique; *dépos.* = **bioguide_id uniques** sur 13 ans (* total; la colonne annuelle recompte un élu chaque année). Le tableau compte les **transactions uniques** par année de dépôt (**file_year**); le brut fait **170 920** lignes (Chambre 152 081 + Sénat 18 839), ramenées à **169 000** par la dédup cross-année (1 920 re-divulgations). **Assertés [A]** : les totaux, l'identité (**367** bioguides Chambre, **78** Sénat; **0** ligne sans bioguide) et le golden octet-à-octet (**230** fichiers Chambre, **138** Sénat).

D.2 — Couverture & qualité, par sous-corpus

[Q]

Sous-corpus	n	ticker %	secteur %	commissions %	dates cohér. %	montant %
Chambre électronique	58 728	83,8	77,7	54,8	99,9	100,0
Chambre OCR	93 261	84,3	81,1	80,8	99,8	98,9
Sénat électronique	13 026	84,1	77,8	53,0	99,9	100,0
Sénat OCR	3 985	57,4	46,2	64,9	98,8	99,4

dates cohér. % = part où la divulgation suit la transaction (**disclosure** $\geq$ **transaction**, parmi les dates exploitables); *montant %* = montant renseigné. Identité = 100 % partout, ancienneté 99,9–100 %. Les **six contrôles globaux** (§5) en bref : délai médian **27 j** Chambre / **24 j** Sénat (≤ 45 j : 87,3 / 86,9 %); montant médian **8 000 \$** (quartile haut 32 500 \$, moyenne 58 314 \$); **445** déposants, dont **294** à ≥ 10 transactions et **236** sur ≥ 3 ans; achats revendus sous 12 mois 67,7 / 48,3 %. Détail **par année** dans **RAPPORT_QUALITE.md**.

D.3 — Composition des transactions, par sous-corpus

[Q] (% du corpus)

Sous-corpus	opération		détenteur du compte			
	achat	vente	soi-même	conjoint	joint	enfant
Chambre électronique	50,4	48,6	49,3	20,4	26,7	3,6
Chambre OCR	52,2	47,3	10,3	47,9	13,6	28,2
Sénat électronique	50,2	48,8	16,8	38,7	42,1	2,4
Sénat OCR	56,4	43,0	48,8	49,5	1,5	0,3

Type d'actif (%)	action	option	oblig. État	munis	oblig. corp.	fonds	autre	manquant
Chambre électronique	58,5	1,2	4,1	0,0	0,0	0,0	4,9	31,3
Chambre OCR	79,2	0,0	0,8	0,0	0,4	3,2	0,3	16,2
Sénat électronique	73,0	4,7	0,0	7,7	3,0	0,0	6,5	5,1
Sénat OCR	40,4	0,0	0,0	0,7	2,2	0,0	41,2	15,5

« munis » = obligations municipales ; « autre » et « manquant » = actifs non cotés ou non identifiés (une bonne part des « manquants » à ticker valide est récupérée *ticker d'abord* par la table de recherche, §7). Le Sénat OCR ($\approx 57\%$ de non-coté ou non identifié) est ce qui le met hors de portée de Quiver (§6).

D.4 — Validation Quiver : corroboration par année et par cluster

[D]

An	corrob.	only-nous	%	An	corrob.	only-nous	%
2014	1 930	3 984	32,6	2021	6 945	2 803	71,2
2015	540	2 711	16,6	2022	11 011	1 286	89,5
2016	291	1 458	16,6	2023	7 522	442	94,5
2017	3 729	2 241	62,5	2024	6 797	481	93,4
2018	7 243	2 722	72,7	2025	11 095	408	96,5
2019	7 630	1 899	80,1	2026	4 740	348	93,2
2020	10 025	2 801	78,2				

Corroboration au niveau **action** (Chambre, `asset_type=Stock`) : *corrob.* = actions appariées à Quiver (exact + date proche) ; *only-nous* = actions réelles qu'on a et que Quiver n'a pas (non corroboreables) ; % = corrob. / (corrob. + only-nous). Agrégé : **87,2 %** sur 2020–2026, **58,7 %** sur 2014–2019 — Quiver est mince avant ≈ 2017 (§6).

Cluster (Chambre OCR)	n lignes	n docs	date plaus. %	ticker %	Quiver a le trade %
A — tapé droit	5 956	59	99,6	84,5	88,0
B — tapé couché	84 787	1 517	96,4	84,3	65,2
C — manuscrit (conservé)	2 518	193	98,6	83,3	12,9

date plaus. % / *ticker %* = qualité interne (sans Quiver) ; *Quiver a le trade %* = part de nos trades cotés que Quiver possède aussi (membre + ticker + sens, avec ou sans date). Sur le manuscrit (C), la qualité interne reste haute mais la corroboration s'effondre : faute de pouvoir le confirmer contre la vérité-terrain, il est écarté par défaut — politique rejouable, exceptions explicites (§4.5).

D.5 — Concentration de l'activité

[Q]

Sous-corpus	n déposants	HHI	Gini	top-10 du volume %
Chambre électronique	309	432,4	0,873	57,6
Chambre OCR	125	2 561,1	0,953	94,7
Sénat électronique	75	943,7	0,826	79,5
Sénat OCR	14	2 671,5	0,753	100,0

HHI (indice de Herfindahl, $\in [0, 10\,000]$) et *Gini* ($\in [0, 1]$) mesurent la concentration du volume entre déposants : 0 = parts égales, maximum = un seul capte tout. Déposants-papier dominants : Khanna **41 080** transactions (44,0 % de l'OCR Chambre), McCaul 27 123, Harshbarger 3 665 ; au Sénat, Blumenthal 1 543 (38,7 % du papier). Top tickers par volume estimé : MSFT 550,1 M\$, AAPL 120,4, FDX 119,9.

12.5 Annexe E — reproduire / lancer

Installation

```
python3.12 -m venv .venv && ./venv/bin/pip install -e .
```

Pipeline complet (reseau + API Vision requis) ; --dry-run = voir la sequence

```
./venv/bin/python -m common.pipeline --years 2014-2026
```

```
./venv/bin/python -m common.pipeline --years 2014-2019 --acquire # re-telecharge index + PDF
```

```
./venv/bin/python -m common.pipeline --years 2024 --dry-run
```

Rapport de qualite (offline, lecture seule des FINAL)

```
# -> docs/RAPPORT_QUALITE.md + docs/quality/*.png
```

```
./venv/bin/python -m common.quality
```

```
# Table de recherche canonique (offline, depuis les FINAL)
# -> data/clean/transactions_backtest_2014_2026.csv (134 464 x 36)
# notebook : Nettoyage_Backtest_2014_2026.ipynb (executer toutes les cellules)

# Filet "zero changement" (doit afficher ZERO ECART)
./venv/bin/python tests/regression/check_golden.py          # Chambre, 230
./venv/bin/python tests/regression/senate_check_golden.py   # Senat, 138
./venv/bin/python tests/regression/test_senate_repro.py     # reproductions
```

Document dérivé et vérifié sur le code source réel, les tables FINAL et la table de recherche canonique du dépôt. Toute divergence avec une autre documentation doit être tranchée en faveur du code et des données. Quiver = vérification externe, jamais réinjecté.