

Du corpus brut à la table de backtest

Nettoyage, validations et garanties — fiche de synthèse (2014–2026)

Alice Lemaire — couche données, avant la phase recherche

6 juillet 2026

En une phrase

Le corpus source-primaire certifié (**169 000** transactions uniques, 100 % de l'index officiel House traité, census interne documenté côté Sénat) passe par un entonnoir de nettoyage en 4 étapes — **chaque retrait compté et justifié, tout doute gardé et flagué** — pour produire la table de recherche `transactions_backtest_2014_2026.csv` : **134 464 lignes** × **36 colonnes** (79,6 % de rétention), validée contre trois sources externes et sous filet de non-régression octet pour octet. La phase recherche démarre sur une donnée dont on connaît exactement le contenu, les forces et les limites.

1. D'où on part : un corpus complet, identifié, vérifié

Transactions uniques (2 chambres, 2014–2026)	169 000 (House 151 989 · Sénat 17 011)
dont : brutes 170 920, re-divulgations dédoublées	1 920
Index officiel House Clerk : PTR traités	100 % des 8 252 (7 568 avec transactions · 582 manuscrits gated · 102 vides documentés)
Identité rattachée (bioguide)	100 % (367 House + 78 Sénat)
Dates cohérentes / délai médian de publication	99,8 % / 27 jours
Montants renseignés	99,4 %

Validé contre trois sources indépendantes (validation seulement — aucune donnée n'y est copiée) :

- **Quiver Quant** : on retrouve chez nous **93,5 %** (House) / **92,1 %** (Sénat) de ses combinaisons (déposant, ticker, sens) — et on est **plus complet** que lui : **+23 535** trades cotés nets côté House, **+2 951** côté Sénat, pour seulement 27 + 11 « vrais trous » confirmés chez nous.
- Sur les paires appariées 1-à-1 (membre, ticker, date) : accord sur le **sens** 96,8 % (House) / 99,9 % (Sénat), sur le **montant** 94,2 % / 99,8 %.
- **senate-stock-watcher** (projet indépendant, 6 231 transactions tickées 2014–2020) : **100 %** retrouvées chez nous, hors différence de représentation des échanges (il éclate un échange en 2 lignes, nous 1) — sur-ensemble strict.
- **Mirror house-stock-watcher** reconstruit (23 568 transactions) : **99,5 %** de ses lignes 2018–2026 retrouvées chez nous ; il sert aussi de seconde jambe à la « double preuve » des tickers récupérés (§3).
- Corroboration *par ère*, honnête : Quiver ne corrobore que 16,6–32,6 % de nos actions 2014–2016 — parce que **Quiver est mince avant 2017**, pas parce que nous avons un trou : nos lignes « nous-seul » portent des tickers vérifiés sur les PDF officiels.

2. L'entonnoir de nettoyage : 4 retraits, tous justifiés

Philosophie (écrite en tête du notebook) : on ne retire que l'avéré inutilisable ; tout le doute est gardé et flagué — aucune ligne écartée en silence, la décision revient à la recherche, pas au nettoyage.

Étape	Règle (pourquoi)	retirées	restantes	%
—	Corpus unique (<code>load_final</code> , réparations incluses)	—	169 000	100,0
A	Dates présentes & cohérentes (impossible de dater l'entrée sinon)	3 252	165 748	98,1
B	Actions + ETF cotés (un backtest exige un prix de marché)	29 771	135 977	80,5
C	Direction claire achat/vente (les « échanges » n'ont pas de sens directionnel)	826	135 151	80,0
D	Montant présent (dimensionner une position exige un notionnel)	687	134 464	79,6

- **Étape A** : lignes sans date exploitable, publication *avant* transaction (impossible), années implausibles. Les *dépôts tardifs* (12,2 % > 45 j) sont GARDÉS et flagués : c'est de l'information réelle, jouable à sa date de publication.

- **Étape B, décomposée** : 27 006 lignes *sans aucun symbole* (munis, obligations, sociétés privées — pas de prix possible) + 164 tickers malformés (CUSIP, fragments OCR) + 2 601 familles non cotées (options, bons du Trésor). **Logique ticker-first** : 21 878 lignes au champ « type d'actif » vide sont *sauvées* par leur ticker valide — l'inverse du filtre naïf par champ déclaré (vide dans 16 à 31 % des cas selon le sous-corpus), qui avait écarté à tort une large part des trades exploitables dans une première version de la recherche ; bug trouvé, corrigé, et le nettoyage centralisé ici.
- **Ce que la table contient** : House 91,3 % / Sénat 8,7 % ; achats 68 250 / ventes 66 214 ; actions 128 974 (secteur GICS 100 %) + ETF diversifiés 2 022 + ETF sectoriels 168 + 3 300 cotés à classe non résolue (flagués) ; les deux ères couvertes (House : 56 706 en 2014–2019, 66 108 en 2020–2026).

3. Ce que l'audit a trouvé — et corrigé, preuve à l'appui

Trois erreurs **critiques** détectées par croisement avec l'index officiel et les sources tierces :

- **205 PTR n'étaient jamais entrés dans la base** : le filtre de téléchargement par année civile ratait les dépôts de janvier (biais systématique contre les trades de décembre). ⇒ 293 documents ré-acquis et intégrés ; zéro perte re-prouvée par clé unique sur chacune des 13 années.
- **7 996 fourchettes de montant tronquées** (borne haute absente → montants sous-estimés, ~331 M\$ d'écart cumulé). ⇒ réparation déterministe à la lecture (borne basse → fourchette STOCK Act complète, milieu exact recalculé).
- **Aucun référentiel de renommages/délistages** : FB→META, PCLN→BKNG... restaient sans prix. ⇒ `ticker_renames.csv` (84 entrées typées : renommage, fusion, rachat, faillite, symbole recyclé) ; 2 817 lignes re-symbolisées pour le join prix, 3 542 délistés *typés* au lieu de disparaître.

Et les corrections **majeures** (sélection) — symptôme → correction → preuve :

- **Biais vendeur avant 2018** : la police « petites capitales » des vieux PDF faisait rater des lignes au parseur — et ~95 % des lignes perdues étaient des *ventes*. Regex corrigée ; recette sur 140 documents = 100 % du contrôle indépendant ; les ventes digitales 2014 **doublent** (555 → 1 170). Sans cette correction, tout backtest pré-2018 aurait vu des achats sans leurs ventes.
- **52 lignes sans bioguide réparées**, plus une collision d'homonyme (Bob Casey Jr. rattaché au mauvais Casey) — réparations ciblées par document, pas de règle aveugle.
- **2 540 tickers récupérés** depuis la description de l'actif, à double preuve (le symbole manquait sur le formulaire mais l'actif est coté et identifiable).
- **Parti et commissions à la date du trade** (point-in-time) : la photo « 2026 » est remplacée par les référentiels datés (basculé des Congrès au 3 janvier) — 99,1 % des lignes résolues, 54,6 % portent le flag « commission clé » (finance/défense/renseignement). Indispensable pour tester la thèse « commissions » sans anachronisme.
- **Convention de montant unifiée** : 91 634 lignes avaient deux conventions de milieu de fourchette selon le pipeline (OCR vs digital) → recalcul unique exact depuis la fourchette.
- **Lots multi-comptes protégés** : 11 873 lignes identiques sont des lots *réels* (comptes Self/Spouse/Joint) identifiés par `owner/occurrence_index/lot_size` — **ne jamais appliquer `drop_duplicates()`** ; un doublon naïf détruirait de l'information réelle.

La règle d'ingénierie : les corrections *de lecture* (fourchettes, identités, dates, tickers récupérés) sont appliquées à la lecture (`common/schema.py`) — les fichiers extraits restent figés ; les réparations de *parser* ont été rejouées et le filet golden re-figé en conséquence ; les enrichissements (point-in-time, milieu de fourchette, renommages) vivent dans le notebook canonique. Dans tous les cas, on remonte du chiffre corrigé au document source.

4. Les garanties : rien ne bouge sans qu'on le voie

Doute flagué (jamais retiré)	lignes	usage en recherche
<code>flag_late_filing</code> — publication > 45 j	16 349 (12,2 %)	information réelle, jouable à sa date
<code>flag_very_late_filing</code> — > 365 j	3 075 (2,3 %)	amendements/régularisations, à filtrer si voulu
<code>is_delisted</code> — titre sorti de cote, typé	3 542 (2,6 %)	traitement par type (faillite ≠ rachat)
lots multi-comptes (<code>lot_size</code> > 1)	11 873 (8,8 %)	expositions réelles distinctes
<code>flag_price_caution</code> — symbole recyclé/fusion	505 (0,4 %)	join prix par période

- **Assertions finales sur 100 % des 134 464 lignes** : bioguide, ticker, montant, direction ∈ {buy, sell}, chronologie (publication ≥ transaction), clé naturelle — le notebook refuse de publier la table sinon.
- **Filet de non-régression** : 368 fichiers de référence figés SHA-256 (230 House + 138 Sénat), rejoués à **zéro écart** à chaque modification, + 11 tests de transformation déterministes.

- **Reproductible** : le notebook de nettoyage s'exécute hors-ligne et de façon déterministe ; le filet golden fige les tables amont octet pour octet ; chaque chiffre de cette fiche est tracé vers le rapport qualité, l'audit ou les notebooks.

5. Les limites, écrites *avant* la recherche

- **Montants = fourchettes STOCK Act** : le milieu de fourchette est exact, mais la loi ne donne pas de montant précis — limite structurelle, pas de nettoyage.
- **Fidélité au déposant** : les coquilles du déposant (dates littéralement impossibles sur le PTR) sont transcrites, pas inventées — elles tombent à l'étape A, documentées.
- **582 PTR manuscrits écartés** par décision de périmètre : la corroboration externe s'effondre sur les manuscrits (12,9 %), donc invérifiables contre une vérité-terrain — choix conservateur, documenté document par document ; 7,1 % de l'index, concentrés avant 2020.
- **Couverture prix 87,8 %** des trades (74 % en 2014 → 99 % en 2026) : Yahoo ne sert plus certains délistés sans successeur ⇒ léger biais de survie, à garder en tête dans l'interprétation des rendements (documenté dans le notebook de recherche).

6. Conclusion : on peut passer à la recherche

La table `transactions_backtest_2014_2026.csv` est **complète** (100 % de l'index officiel House traité, census Sénat documenté), **exacte** (validée contre trois sources indépendantes, accords > 94–99 % sur les paires), **réparée** (19 corrections documentées, chacune avec sa preuve), **honnête** (tout doute flagué, limites écrites) et **reproductible** (golden SHA-256 + assertions). Elle alimente déjà les notebooks de recherche (portefeuille par membre, stratégie du brief) sans accroc.

Pour aller plus loin : `docs/RAPPORT_QUALITE.md` (§7 : l'entonnoir rejoué par le code), `docs/AUDIT_DONNEES_2014_2026.md` (chaque correction tracée), `Nettoyage_Backtest_2014_2026.ipynb` (le notebook qui produit la table).