

Du corpus brut à la table de backtest

Nettoyage, validations et garanties — fiche de synthèse (2014–2026)

Alice Lemaire — couche données, avant la phase recherche

6 juillet 2026

1. D'où on part : un corpus complet, identifié, vérifié

La donnée est collectée à la source officielle, pas achetée à un agrégateur. Depuis le STOCK Act (2012), chaque membre du Congrès déclare ses transactions boursières sous 45 jours dans un *PTR* (*Periodic Transaction Report*). Nous partons des deux dépôts officiels : l'**index annuel du Clerk de la Chambre** — qui liste chaque PTR déposé, et sert donc d'univers de référence re-vérifiable — et l'**eFD du Sénat**. Chaque document est téléchargé puis lu : extraction directe pour les dépôts électroniques, lecture Vision (OCR) pour les PDF scannés. On contrôle ainsi toute la chaîne, du document officiel à la ligne de donnée, et chaque ligne garde l'identifiant de son document source.

Transactions uniques (2 chambres, 2014–2026)	169 000 (House 151 989 · Sénat 17 011)
dont : brutes 170 920, re-divulgations dédoublées	1 920
Index officiel House Clerk : PTR traités	100 % des 8 252 (7 568 avec transactions · 582 manuscrits gated · 102 vides documentés)
Identité rattachée (bioguide)	100 % (367 House + 78 Sénat)
Dates cohérentes / délai médian de publication	99,8 % / 27 jours
Montants renseignés	99,4 %

Lecture du tableau : « re-divulgations » = un même trade republié dans un amendement, dédoublonné par clé naturelle ; « manuscrits gated » = PTR remplis à la main, écartés par décision de périmètre (motivée au §5) ; « vides documentés » = dépôts officiels sans transaction, justifiés un par un.

La validation externe. Notre base est construite indépendamment ; pour la vérifier, on la confronte à **trois sources tierces** qui collectent la même information — l'agrégateur commercial *Quiver Quant* et deux projets open-source (*senate-stock-watcher*, *mirror house-stock-watcher*) — en validation seulement, aucune donnée n'y est copiée. Trois questions, dans l'ordre où elles rassurent :

- **A-t-on tout ce qu'eux ont ?** On retrouve chez nous **93,5 %** (House) / **92,1 %** (Sénat) des combinaisons de Quiver — une « combinaison » = ce déposant a bien déclaré au moins un trade sur ce titre dans ce sens (clé volontairement sans date, pour tolérer les différences de convention). Après enquête sur le résidu (lignes hors périmètre, manuscrits gated), il ne reste que **27 + 11 « vrais trous »** confirmés. Côté open-source : **100 %** des 6 231 transactions de *senate-stock-watcher* retrouvées (hors représentation des échanges : il les éclate en 2 lignes, nous 1) et **99,5 %** des lignes 2018–2026 du *mirror House* (23 568 transactions).
- **A-t-on plus qu'eux ?** Oui : **+23 535** trades cotés nets côté House, **+2 951** côté Sénat. Ce surplus est réel, pas un artefact : avant 2017 Quiver ne corrobore que 16,6–32,6 % de nos actions parce que **Quiver est mince avant 2017** — nos lignes « nous-seul » portent des tickers vérifiés sur les PDF officiels.
- **Quand on a tous les deux le même trade, dit-on la même chose ?** Sur les ~96 000 paires appariées 1-à-1 (membre, ticker, date) : accord sur le **sens** 96,8 % (House) / 99,9 % (Sénat), sur le **montant** 94,2 % / 99,8 %. Les désaccords échantillonnés ont été vérifiés sur les PDF officiels : notre transcription est fidèle au document.

2. L'entonnoir de nettoyage : 4 retraits, tous justifiés

Philosophie (écrite en tête du notebook) : **on ne retire que l'avéré inutilisable ; tout le doute est gardé et flagué** — aucune ligne écartée en silence, la décision revient à la recherche, pas au nettoyage.

Étape	Règle (pourquoi)	retirées	restantes	%
—	Corpus unique (<code>load_final</code> , réparations incluses)	—	169 000	100,0
A	Dates présentes & cohérentes (impossible de dater l'entrée sinon)	3 252	165 748	98,1
B	Actions + ETF cotés (un backtest exige un prix de marché)	29 771	135 977	80,5
C	Direction claire achat/vente (les « échanges » n'ont pas de sens directionnel)	826	135 151	80,0
D	Montant présent (dimensionner une position exige un notionnel)	687	134 464	79,6

- **Étape A** : lignes sans date exploitable, publication *avant* transaction (impossible), années implausibles. Les *dépôts tardifs* (12,2 % > 45 j) sont GARDÉS et flagués : c’est de l’information réelle, jouable à sa date de publication.
- **Étape B, décomposée** : 27 006 lignes *sans aucun symbole* (munis, obligations, sociétés privées — pas de prix possible) + 164 tickers malformés (CUSIP, fragments OCR) + 2 601 familles non cotées (options, bons du Trésor). **Logique ticker-first** : 21 878 lignes au champ « type d’actif » vide sont *sauvées* par leur ticker valide — l’inverse du filtre naïf par champ déclaré (vide dans 16 à 31 % des cas selon le sous-corpus), qui avait écarté à tort une large part des trades exploitables dans une première version de la recherche ; bug trouvé, corrigé, et le nettoyage centralisé ici.
- **Ce que la table contient** : House 91,3 % / Sénat 8,7 % ; achats 68 250 / ventes 66 214 ; actions 128 974 (secteur GICS 100 %) + ETF diversifiés 2 022 + ETF sectoriels 168 + 3 300 cotés à classe non résolue (flagués) ; les deux ères couvertes (House : 56 706 en 2014–2019, 66 108 en 2020–2026).

3. Ce que l’audit a trouvé — et corrigé, preuve à l’appui

Trois erreurs **critiques** détectées par croisement avec l’index officiel et les sources tierces :

- **205 PTR n’étaient jamais entrés dans la base** : le filtre de téléchargement par année civile ratait les dépôts de janvier (biais systématique contre les trades de décembre). ⇒ 293 documents ré-acquis et intégrés ; zéro perte re-prouvée par clé unique sur chacune des 13 années.
- **7 996 fourchettes de montant tronquées** (borne haute absente → montants sous-estimés, ~331 M\$ d’écart cumulé). ⇒ réparation déterministe à la lecture (borne basse → fourchette STOCK Act complète, milieu exact recalculé).
- **Aucun référentiel de renommages/délistages** : FB→META, PCLN→BKNG... restaient sans prix. ⇒ `ticker_renames.csv` (84 entrées typées : renommage, fusion, rachat, faillite, symbole recyclé) ; 2 817 lignes re-symbolisées pour le join prix, 3 542 délistés *typés* au lieu de disparaître.

Et les corrections **majeures** (sélection) — symptôme → correction → preuve :

- **Biais vendeur avant 2018** : la police « petites capitales » des vieux PDF faisait rater des lignes au parseur — et ~95 % des lignes perdues étaient des *ventes*. Regex corrigée ; recette sur 140 documents = 100 % du contrôle indépendant ; les ventes digitales 2014 **doublent** (555 → 1 170). Sans cette correction, tout backtest pré-2018 aurait vu des achats sans leurs ventes.
- **52 lignes sans bioguide réparées**, plus une collision d’homonyme (Bob Casey Jr. rattaché au mauvais Casey) — réparations ciblées par document, pas de règle aveugle.
- **2 540 tickers récupérés** depuis la description de l’actif, à double preuve (le symbole manquait sur le formulaire mais l’actif est coté et identifiable).
- **Parti et commissions à la date du trade** (point-in-time) : la photo « 2026 » est remplacée par les référentiels datés (basculé des Congrès au 3 janvier) — 99,1 % des lignes résolues, 54,6 % portent le flag « commission clé » (finance/défense/renseignement). Indispensable pour tester la thèse « commissions » sans anachronisme.
- **Convention de montant unifiée** : 91 634 lignes avaient deux conventions de milieu de fourchette selon le pipeline (OCR vs digital) → recalcul unique exact depuis la fourchette.
- **Lots multi-comptes protégés** : 11 873 lignes identiques sont des lots *réels* (comptes Self/Spouse/Joint) identifiés par `owner/occurrence_index/lot_size` — **ne jamais appliquer `drop_duplicates()`** ; un doublon naïf détruirait de l’information réelle.

La règle d’ingénierie : les corrections *de lecture* (fourchettes, identités, dates, tickers récupérés) sont appliquées à la lecture (`common/schema.py`) — les fichiers extraits restent figés ; les réparations de *parser* ont été rejouées et le filet golden re-figé en conséquence ; les enrichissements (point-in-time, milieu de fourchette, renommages) vivent dans le notebook canonique. Dans tous les cas, on remonte du chiffre corrigé au document source.

4. Les garanties : rien ne bouge sans qu’on le voie

Doute flagué (jamais retiré)	lignes	usage en recherche
<code>flag_late_filing</code> — publication > 45 j	16 349 (12,2 %)	information réelle, jouable à sa date
<code>flag_very_late_filing</code> — > 365 j	3 075 (2,3 %)	amendements/régularisations, à filtrer si voulu
<code>is_delisted</code> — titre sorti de cote, typé	3 542 (2,6 %)	traitement par type (faillite ≠ rachat)
lots multi-comptes (<code>lot_size</code> > 1)	11 873 (8,8 %)	expositions réelles distinctes
<code>flag_price_caution</code> — symbole recyclé/fusion	505 (0,4 %)	join prix par période

- **Assertions finales sur 100 % des 134 464 lignes** : bioguide, ticker, montant, direction ∈ {buy, sell},

chronologie (publication $\geq$ transaction), clé naturelle — le notebook refuse de publier la table sinon.

- **Filet de non-régression** : 368 fichiers de référence figés SHA-256 (230 House + 138 Sénat), rejoués à **zéro écart** à chaque modification, + 11 tests de transformation déterministes.
- **Reproductible** : le notebook de nettoyage s'exécute hors-ligne et de façon déterministe ; le filet golden fige les tables amont octet pour octet ; chaque chiffre de cette fiche est tracé vers le rapport qualité, l'audit ou les notebooks.

5. Les limites, écrites *avant* la recherche

- **Montants = fourchettes STOCK Act** : le milieu de fourchette est exact, mais la loi ne donne pas de montant précis — limite structurelle, pas de nettoyage.
- **Fidélité au déposant** : les coquilles du déposant (dates littéralement impossibles sur le PTR) sont transcrites, pas inventées — elles tombent à l'étape A, documentées.
- **582 PTR manuscrits écartés** par décision de périmètre : la corroboration externe s'effondre sur les manuscrits (12,9 %), donc invérifiables contre une vérité-terrain — choix conservateur, documenté document par document ; 7,1 % de l'index, concentrés avant 2020.
- **Couverture prix 87,8 %** des trades (74 % en 2014 $\rightarrow$ 99 % en 2026) : Yahoo ne sert plus certains délistés sans successeur $\Rightarrow$ léger biais de survie, à garder en tête dans l'interprétation des rendements (documenté dans le notebook de recherche).

6. Conclusion : on peut passer à la recherche

La table `transactions_backtest_2014_2026.csv` est **complète** (100 % de l'index officiel House traité, census Sénat documenté), **exacte** (validée contre trois sources indépendantes, accords $> 94\text{--}99\%$ sur les paires), **réparée** (19 corrections documentées, chacune avec sa preuve), **honnête** (tout doute flagué, limites écrites) et **reproductible** (golden SHA-256 + assertions). Elle alimente déjà les notebooks de recherche (portefeuille par membre, stratégie du brief) sans accroc.

Pour aller plus loin : `docs/RAPPORT_QUALITE.md` (§7 : l'entonnoir rejoué par le code), `docs/AUDIT_DONNEES_2014_2026.md` (chaque correction tracée), `Nettoyage_Backtest_2014_2026.ipynb` (le notebook qui produit la table).