

# Du corpus brut à la table de backtest

## Nettoyage, validations et garanties — fiche de synthèse (2014–2026)

Alice Lemaire — couche données, avant la phase recherche

6 juillet 2026

### 1. D'où on part : un corpus complet, identifié, vérifié

**La collecte : à la source officielle, pas chez un agrégateur.**

- STOCK Act (2012) : chaque élu déclare ses transactions sous 45 jours dans un *PTR* (*Periodic Transaction Report*).
- Deux dépôts officiels : l'**index annuel du Clerk** (House — liste chaque PTR déposé = univers de référence re-vérifiable) et l'**eFD du Sénat**.
- Chaque document est téléchargé puis lu : extraction directe (dépôts électroniques) ou OCR Vision (PDF scannés).
- Toute la chaîne est contrôlée : chaque ligne garde l'identifiant de son document source.

|                                                   |                                                                                                |
|---------------------------------------------------|------------------------------------------------------------------------------------------------|
| Transactions uniques (2 chambres, 2014–2026)      | <b>169 000</b> (House 151 989 · Sénat 17 011)                                                  |
| dont : brutes 170 920, re-divulgations dédoublées | 1 920                                                                                          |
| Index officiel House Clerk : PTR traités          | <b>100 % des 8 252</b> (7 568 avec transactions · 582 manuscrits gated · 102 vides documentés) |
| Identité rattachée (bioguide)                     | <b>100 %</b> (367 House + 78 Sénat)                                                            |
| Dates cohérentes / délai médian de publication    | 99,8 % / 27 jours                                                                              |
| Montants renseignés                               | 99,4 %                                                                                         |

*Lecture du tableau* : « re-divulgations » = trade republié dans un amendement (dédoublonné par clé naturelle) · « manuscrits gated » = PTR remplis à la main, écartés (motif au §4) · « vides documentés » = dépôts sans transaction, justifiés un par un.

**La validation : trois sources tierces** (*Quiver Quant* + deux projets open-source), en validation seulement — rien n'y est copié. Trois questions :

#### 1) A-t-on tout ce qu'eux ont ?

- Quiver, *sans* la date : **93,5 %** (House) / **92,1 %** (Sénat) de ses combinaisons retrouvées chez nous. (*Combinaison* = ce déposant a déclaré au moins un trade sur ce titre dans ce sens ; on compare d'abord sans la date, pour tolérer les conventions de date.)
- Quiver, *avec* la date : **70 265** (House) + **8 766** (Sénat) trades appariés **au jour exact**, + 845 à  $\leq 10$  jours.
- Les seuls candidats sérieux d'« erreur de date » : 545 paires issues d'une même déclaration (écart typique 11 j) — vérification faite, c'est une convention de date de Quiver ; le vrai contrôle des dates est l'audit des PDF officiels.
- Le résidu sans-date (1 704 + 360 combinaisons non retrouvées) s'explique poche par poche : 1 578 + 7 relèvent des manuscrits gated (écartés volontairement, pas perdus) · 95 + 353 sont hors périmètre (actifs non cotés, fragments) · reste une borne haute de 31 + 0 combinaisons cotées.
- Au trade daté, après tous les filtres : **27 + 11 manques confirmés**, en tout.
- senate-stock-watcher (projet GitHub indépendant qui a collecté le Sénat 2014–2020 ; 6 231 transactions tickées) : on cherche chacune de ses lignes chez nous (membre + ticker) → **100 %** retrouvées ; ses 36 « non-matchées » = représentation (il éclate un échange en 2 lignes, nous 1).
- Mirror house-stock-watcher (reconstruit indépendamment depuis les mêmes PDF officiels de la Chambre ; 23 568 transactions 2012–2026) : **99,5 %** de ses lignes 2018–2026 retrouvées chez nous ; avant 2018, ses écarts nous ont servi de détecteur de manques — tous ré-acquis et corrigés depuis.

#### 2) A-t-on plus qu'eux ?

- **+23 535** trades cotés nets côté House, **+2 951** côté Sénat ; au trade daté : 39 207 + 3 140 trades chez nous absents de Quiver.
- Le surplus est réel, pas un artefact : **Quiver est mince avant 2017** (il ne corrobore que 16,6–32,6 % de nos actions 2014–2016).

— Nos lignes « nous-seul » portent des tickers vérifiés sur les PDF officiels.

### 3) Sur les trades communs, dit-on la même chose ?

- ~96 000 paires appariées 1-à-1 (membre, ticker, date).
- Accord sur le **sens** : 96,8 % (House) / 99,9 % (Sénat) ; sur le **montant** : 94,2 % / 99,8 %.
- Désaccords échantillonnés vérifiés sur les PDF officiels : notre transcription est fidèle au document.

## 2. L'entonnoir de nettoyage : 4 retraits, tous justifiés

*Philosophie (écrite en tête du notebook) : on ne retire que l'avéré inutilisable ; tout le doute est gardé et flagué* — aucune ligne écartée en silence, la décision revient à la recherche, pas au nettoyage.

| Étape | Règle (pourquoi)                                                               | retirées | restantes      | %           |
|-------|--------------------------------------------------------------------------------|----------|----------------|-------------|
| —     | Corpus unique ( <code>load_final</code> , réparations incluses)                | —        | 169 000        | 100,0       |
| A     | Dates présentes & cohérentes (impossible de dater l'entrée sinon)              | 3 252    | 165 748        | 98,1        |
| B     | Actions + ETF <b>cotés</b> (un backtest exige un prix de marché)               | 29 771   | 135 977        | 80,5        |
| C     | Direction claire achat/vente (les « échanges » n'ont pas de sens directionnel) | 826      | 135 151        | 80,0        |
| D     | Montant présent (dimensionner une position exige un notionnel)                 | 687      | <b>134 464</b> | <b>79,6</b> |

### Étape A — les trois critères de retrait :

- dates illisibles ou absentes (impossible de dater l'entrée) ;
- publication *avant* la transaction — impossible, coquille du déposant ;
- année implausible : transaction avant 2012 (avant le STOCK Act) ou après l'année du dépôt ;
- en revanche, les *dépôts tardifs* (12,2 % > 45 j) sont GARDÉS et flagués : information réelle, jouable à sa date de publication.

### Étape B — décomposée :

- 27 006 lignes *sans aucun symbole* (munis, obligations, sociétés privées — pas de prix possible) ;
- 164 tickers malformés (CUSIP, fragments OCR) ;
- 2 601 familles non cotées (options, bons du Trésor) ;
- **rescue ticker-first** : 21 878 lignes au champ « type d'actif » vide sont *sauvées* par leur ticker validé ;
- la leçon : le filtre naïf par champ déclaré (vide dans 16 à 31 % des cas) avait écarté à tort une large part des trades exploitables dans une première version — bug trouvé, corrigé, nettoyage centralisé ici.

### Ce que la table contient :

- chambres : House 91,3 % / Sénat 8,7 % ; sens : achats 68 250 / ventes 66 214 ;
- classes : actions 128 974 (secteur GICS 100 %) · ETF diversifiés 2022 · ETF sectoriels 168 · 3 300 cotés à classe non résolue (flagués) ;
- les deux ères couvertes : House 56 706 en 2014–2019, 66 108 en 2020–2026.

## 3. Les garanties : rien ne bouge sans qu'on le voie

| Doute flagué (jamais retiré)                             | lignes          | usage en recherche                              |
|----------------------------------------------------------|-----------------|-------------------------------------------------|
| <code>flag_late_filing</code> — publication > 45 j       | 16 349 (12,2 %) | information réelle, jouable à sa date           |
| <code>flag_very_late_filing</code> — > 365 j             | 3 075 (2,3 %)   | amendements/régularisations, à filtrer si voulu |
| <code>is_delisted</code> — titre sorti de cote, typé     | 3 542 (2,6 %)   | traitement par type (faillite ≠ rachat)         |
| lots multi-comptes ( <code>lot_size</code> > 1)          | 11 873 (8,8 %)  | expositions réelles distinctes                  |
| <code>flag_price_caution</code> — symbole recyclé/fusion | 505 (0,4 %)     | join prix par période                           |

- **Assertions finales sur 100 % des 134 464 lignes** : bioguide, ticker, montant, direction  $\in \{\text{buy, sell}\}$ , chronologie (publication  $\geq$  transaction), clé naturelle — le notebook refuse de publier la table sinon.
- **Filet de non-régression** : 368 fichiers de référence figés SHA-256 (230 House + 138 Sénat), rejoués à **zéro écart** à chaque modification, + 11 tests de transformation déterministes ; le notebook s'exécute hors-ligne et de façon déterministe (deux runs = même table).

## 4. Les limites, écrites *avant* la recherche

- **Montants = fourchettes STOCK Act** : le milieu de fourchette est exact, mais la loi ne donne pas de montant précis — limite structurelle, pas de nettoyage.

- **Fidélité au déposant** : les coquilles du déposant (dates littéralement impossibles sur le PTR) sont transcrites, pas inventées — elles tombent à l'étape A, documentées.
- **582 PTR manuscrits écartés** par décision de périmètre : la corroboration externe s'effondre sur les manuscrits (12,9 %), donc invérifiables contre une vérité-terrain — choix conservateur, documenté document par document ; 7,1 % de l'index, concentrés avant 2020.
- **Couverture prix 87,8 %** des trades (74 % en 2014 → 99 % en 2026) : Yahoo ne sert plus certains délistés sans successeur ⇒ léger biais de survie, à garder en tête dans l'interprétation des rendements (documenté dans le notebook de recherche).

*Pour aller plus loin* : `docs/RAPPORT_QUALITE.md` (§7 : l'entonnoir rejoué par le code), `docs/AUDIT_DONNEES_2014_2026.md` (chaque correction tracée), `Nettoyage_Backtest_2014_2026.ipynb` (le notebook qui produit la table).