

Du corpus brut à la table de backtest : l'entonnoir et les résultats

Nettoyage backtest 2014–2026 — fiche de résultats
Nettoyage_Backtest_2014_2026.ipynb → transactions_backtest_2014_2026.csv

Alice Lemaire — 7 juillet 2026

1. L'essentiel

- Corpus source-primaire : **169 000** transactions uniques (100 % de l'index officiel House traité, census Sénat documenté).
- Entonnoir de nettoyage en **4 retraits justifiés** → table de recherche **134 464 lignes** × **36 colonnes** (**79,6 %** conservées).
- Validée en externe : **93,5 %** (House) / **92,1 %** (Sénat) des combinaisons de Quiver retrouvées; **100 %** de senate-stock-watcher; **99,5 %** du mirror House 2018–2026.
- Tout le doute est **gardé et flagué** (jamais retiré en silence).
- Déjà consommée telle quelle par les notebooks de recherche 05 et 06.

2. L'entonnoir

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)




FIGURE 1 — Chaque retrait est compté ; aucun autre filtre n'est appliqué.

Les critères, dans l'ordre :

- A — dates cohérentes** : $\text{lag} = t_{\text{publication}} - t_{\text{transaction}} \geq 0$ et $2012 \leq \text{année} \leq \text{année du dépôt}$ (si non impossible de dater l'entrée) ;
- B — actions + ETF cotés** : un backtest exige un prix de marché. Retirées : 27 006 sans aucun symbole (munis, obligations, sociétés privées) + 164 malformés (CUSIP, fragments OCR) + 2 601 familles non cotées (options, bons du Trésor) ;
- C — direction claire** : $\text{direction} \in \{\text{buy}, \text{sell}\}$ (les « échanges » n'ont pas de sens directionnel) ;
- D — montant présent** : $\text{montant} = \frac{lo+hi}{2}$, milieu exact de la fourchette STOCK Act.

Rescue « ticker-first » : **21 878** lignes gardées dont la case « type d'actif » est vide mais dont le ticker est une action cotée valide — on décide sur le *ticker*, pas sur la case déclarée (vide dans 16–31 % des cas).

3. La table finale — aperçu

membre	ticker	sens	transaction	montant \$	secteur
Bob Gibbs	INTC	buy	2014-12-30	8 000,5	Info. Tech.
Greg Gianforte	BBAVY	sell	2018-12-12	32 500,5	Cons. Staples
Kim Dr Schrier	AAPL	sell	2021-11-15	375 000,5	Info. Tech.
Tim Moore	HOG	buy	2025-12-09	32 500,5	Cons. Discr.

TABLE 1 — 4 lignes réelles (extrait ; 36 colonnes au total, dont *disclosure_date*, parti et commissions à la *date du trade*, *etf_proxy*, flags).

Les 36 colonnes, par famille :

- identité** : *bioguide_id*, nom, chambre, parti et commissions *point-in-time* (résolues à 99,1 % ; flag « commission clé » : 54,6 %) ;
- dates** : *transaction*, *publication*, lag en jours (médiane **27 j**) ;
- montant** : milieu exact de fourchette (renseigné à 99,4 %) ;
- instrument** : *ticker_yahoo* (renommages appliqués : FB→META...), secteur GICS (100 % des actions), *etf_proxy* (98,8 %) ;
- flags et traçabilité** (document source par ligne).

4. Composition

	n	part
House / Sénat	122 814 / 11 650	91,3 % / 8,7 %
achats / ventes	68 250 / 66 214	50,8 % / 49,2 %
actions	128 974	95,9 %
ETF diversifiés	2 022	1,5 %
ETF sectoriels	168	0,1 %
cotés, classe non résolue (flagués)	3 300	2,5 %
2014–2019 / 2020–2026 (House)	56 706 / 66 108	—

TABLE 2 — Composition des 134 464 transactions.




FIGURE 2 — Transactions par année (corpus complet).




FIGURE 3 – Distribution des montants (fourchettes STOCK Act).

5. Qualité et flags

- Identité rattachée : **100 %** · dates cohérentes : **99,8 %**
· montants : **99,4 %**.
- Assertions bloquantes à l’export (bioguide, ticker, montant, direction, chronologie, clé naturelle) : le notebook refuse de publier sinon.

doute flagué (jamais retiré)	lignes	part
publication > 45 j (<code>late_filing</code>)	16 349	12,2 %
publication > 365 j	3 075	2,3 %
titre sorti de cote, typé (<code>is_delisted</code>)	3 542	2,6 %
lots multi-comptes (<code>lot_size</code> > 1)	11 873	8,8 %
symbole recyclé/fusion (<code>price_caution</code>)	505	0,4 %

TABLE 3 – Le doute est signalé, la recherche décide.

6. Validation externe (résultats)

- **Quiver Quant** : 93,5 % / 92,1 % de ses combinaisons retrouvées ; au trade daté, 70 265 + 8 766 appariés **au jour exact** ; après enquête, **31 + 0** combinaisons cotées au plus restent inexpliquées. Et on a **+23 535 / +2 951** trades cotés nets de plus que lui.
- **senate-stock-watcher** : **100 %** de ses 6 231 transactions retrouvées.
- **Mirror house-stock-watcher** (mêmes PDF officiels, lecture indépendante) : **99,5 %** de ses lignes 2018–2026 retrouvées.

7. Limites

- **582 PTR manuscrits écartés** par décision de périmètre (7,1 % de l’index, concentrés avant 2020) — documentés un par un.
- Côté recherche : couverture prix **87,8 %** des trades (74 % en 2014 → 99 % en 2026) ⇒ léger biais de survie.