

Rapport qualité — Données de trading du Congrès américain

Chambre des représentants + Sénat · 2014–2026 · généré par python -m common.quality (lecture seule des tables FINAL, aucun appel API) · Quiver Quantitative = vérité-terrain externe, **jamais réinjectée**. Les % sont arrondis à 0,1 pt ; une somme de colonnes peut afficher 100,1.

Résumé exécutif

En un clin d'œil :

Transactions uniques (2 chambres, 2014–2026)	169 000 (House 151 989 · Sénat 17 011)
Couverture de l'univers officiel (index House Clerk)	100 % des 8 252 PTR traités
Identité rattachée (bioguide)	100.0 % (367 membres House · 78 Sénat)
Dates cohérentes / délai médian de divulgation	99.8 % / 27 j
Montants renseignés	99.4 %
Combinaisons Quiver retrouvées (déposant, ticker, sens — fenêtre commune)	93.5 % House · 92.1 % Sénat
Table de recherche backtest (§7)	134 464 lignes × 36 colonnes
Filet de non-régression	golden 230 + 138 fichiers (SHA256), zéro écart

- **Périmètre** — 169 000 transactions uniques de membres élus (House 151 989 + Sénat 17 011), 2014–2026, en **4 sous-corpus** (chambre × voie d'acquisition : électronique déterministe / scan OCR).
- **Complétude vs Quiver (§6)** — dans notre fenêtre, on retrouve **93.5 % (House) / 92.1 % (Sénat)** des trades Quiver au niveau (déposant, ticker, sens). Le **trou coté est minuscule** — ≤ 31 House / 0 Sénat au niveau ticker (borne haute) ; une mesure COMPLÉMENTAIRE au trade daté (§6.5, clé différente — les deux comptes ne s'emboîtent pas) confirme **27 House / 11 Sénat vrais trous** ; le reste du résidu est de l'OCR récupérable ou du hors-périmètre.
- **On est plus complet que Quiver — +26 524 combinaisons cotées (déposant, ticker, sens)** qu'on a et que Quiver n'a pas, contre 38 trous inverses → **sur-ensemble** de Quiver. △ Cette avance est **inéga**le dans le temps : bien corroborée après ~2017, elle repose avant sur des trades réels que **Quiver (mince pré-2017) ne peut pas confirmer** — détail par année en §6.2.
- **Les « écarts » de date ne sont pas des erreurs** — la réconciliation 1-à-1 (§6.3) montre que l'essentiel est du « nous-seul » (Quiver n'a pas le trade) ; seuls 545 candidats House (même déclaration) méritent l'œil, et le vrai contrôle des dates reste l'audit PDF (§3).
- **Données propres** — identité rattachée à 100.0 %, dates cohérentes 99.8 %, délai de divulgation médian 27 j, montants renseignés 99.4 %. *Anti-look-ahead : tout usage aval (backtest) entre sur `disclosure_date` (date de dépôt imprimée, fiable), jamais sur la `transaction_date` OCR — quelques dates OCR restent imprécises (§3).*

Plan : §1 construction & validation · §2 composition & complétude · §3 qualité des dates · §4 montants · §5 activité & concentration · §6 complétude vs Quiver (vérité-terrain) · §7 du corpus à la table de recherche (nettoyage backtest).

1. Construction & validation du corpus

Avant toute statistique, voici **comment le corpus est construit**, dans l'ordre :

1. **Sources** — déclarations officielles : Chambre (PTR — *Periodic Transaction Report*) et Sénat (eFD — *electronic Financial Disclosure*), chacune en deux voies — **électronique** (formulaire structuré, lecture déterministe) et **papier scanné** (PDF → **OCR** par modèle de vision).
2. **Extraction** — une ligne = une transaction (membre, date, actif, sens, fourchette de montant, détenteur).
3. **Enrichissement** — ticker (explicite dans la source · repris de l'électronique · résolu par LLM), secteur GICS (yfinance · LLM), identité (`bioguide_id`), ancienneté.
4. **Déduplication cross-année** — une même transaction re-divulguée une autre année (amendement, rapport annuel) ne compte qu'**une fois** (clé naturelle + rang d'occurrence).

Réconciliation — des lignes brutes aux transactions uniques (c'est notre corpus, pas Quiver) :

chambre	lignes brutes	re-divulgations (dédup)	transactions uniques
house	152081	92	151989
senate	18839	1828	17011
TOTAL	170920	1920	169000

lignes brutes = FINAL concaténé 2014–2026 · *re-divulgations* = doublons cross-année retirés · *transactions uniques* = le corpus analysé dans tout ce rapport

Couverture vs l'univers officiel (House Clerk)

Chaque index annuel `{Y}FD.xml` du Clerk liste TOUS les dépôts de l'année ; les PTR ont `FilingType='P'`. **L'index annuel est l'autorité d'appartenance** d'un document à son année : un PTR déposé tardivement (jusqu'à +3 ans après l'année du formulaire) reste rattaché à son index. **100 % des PTR officiels sont traités** — parsés, OCRisés, ou écartés par une règle écrite (manuscrits, cf. §6.6).

année	PTR officiels	avec transactions	gated manuscrit	sans txn retenue	couverts %
2014	708	613	94	1	100.0
2015	728	627	97	4	100.0
2016	765	651	110	4	100.0
2017	801	708	82	11	100.0
2018	830	752	68	10	100.0
2019	683	616	52	15	100.0
2020	733	688	35	10	100.0
2021	680	653	15	12	100.0
2022	624	602	14	8	100.0
2023	460	447	2	11	100.0
2024	451	440	5	6	100.0
2025	515	503	6	6	100.0
2026	274	268	2	4	100.0
TOTAL	8252	7568	582	102	100.0

PTR officiels = FilingType='P' de l'index du Clerk · avec transactions = docs présents dans le FINAL de l'année · gated manuscrit = cluster C du census hors exceptions (politique §6.6, listes rejouables) · sans txn retenue = vides réels (« nothing to report »), amendements sans lignes ou échecs documentés (05_parse_failures). Sénat : pas d'index public re-vérifiable sans re-scraping eFD — le census interne fait foi (25 dépôts sans transaction tous motivés dans 06d_docs_sans_transaction.csv).

Validation & reproductibilité

Tout est **rejouable hors-ligne** (lecture seule des tables FINAL, **0 appel API**), adossé à trois filets automatiques :

- **Golden octet-à-octet** — 368 tables CSV figées par SHA256 (230 House + 138 Sénat), rejouées à **zéro écart** (tests/regression/check_golden.py, senate_check_golden.py).
- **Invariants porteurs** — pour chaque chambre digital + OCR = FINAL, identité rattachée à **100.0 %**, 367 bioguides (House) / 78 (Sénat) recomptés (tests/regression/audit_metrics.py).
- **Transformations déterministes** — 11 tests reproduisent chaque étape (clé naturelle, montants, tickers, identité, ancienneté, cache Vision) depuis les colonnes figées.

Les quatre sous-corpus

Toute la suite distingue **quatre familles** (chambre × voie), car leur qualité et leur composition diffèrent :

sous-corpus	n	part %
House électronique	58728	34.8
House OCR	93261	55.2
Sénat électronique	13026	7.7
Sénat OCR	3985	2.4

sous-corpus = chambre × voie (électronique déterministe / scan OCR) · n = transactions uniques · part % du total


2. Composition & complétude

Ce que contient le corpus (opérations, détenteur, familles d'actifs), puis à quel point les champs sont remplis.

Sens des opérations

sous-corpus	n	achat %	vente %	échange %	autre %
House électronique	58728	50.4	48.6	1.0	0.0
House OCR	93261	52.2	47.3	0.5	0.0
Sénat électronique	13026	50.2	48.8	1.0	0.0
Sénat OCR	3985	56.4	43.0	0.6	0.0

achat = operation_type contient « Purchase » · vente = contient « Sale » (inclut Sale (Partial) et (Full)) · échange = « Exchange » · autre = reste



Détenteur déclaré

sous-corpus	n	perso %	conjoint %	joint %	enfant %	autre %
House électronique	58728	49.3	20.4	26.7	3.6	0.0
House OCR	93261	10.3	47.9	13.6	28.2	0.0
Sénat électronique	13026	16.8	38.7	42.1	2.4	0.0
Sénat OCR	3985	48.8	49.5	1.5	0.3	0.0


titulaire du compte : perso = Self · conjoint = Spouse/SP · joint = Joint/JT · enfant = Dependent/Child/DC · autre = reste ou non déclaré

Familles d'actifs

L'OCR du Sénat se distingue : la part d'actions y tombe et la catégorie « autre » (essentiellement du non-coté : parts de sociétés privées, produits divers) domine :

sous-corpus	n	action %	option %	oblig. État %	muni %	oblig. corp. %	fonds %	autre %	manquant %
House électronique	58728	58.5	1.2	4.1	0.0	0.0	0.0	4.9	31.3
House OCR	93261	79.2	0.0	0.8	0.0	0.4	3.2	0.3	16.2
Sénat électronique	13026	73.0	4.7	0.0	7.7	3.0	0.0	6.5	5.1
Sénat OCR	3985	40.4	0.0	0.0	0.7	2.2	0.0	41.2	15.5

familles d'asset_type : action = Stock · option · oblig. État = Gov/Treasury · muni = Municipal · oblig. corp. = Bond · fonds = Fund/ETF · manquant = vide



Couverture des champs enrichis (taux de remplissage)

sous-corpus	n	ticker %	secteur %	ETF %	commission %	identité %	ancienneté %	montant renseigné %
House électronique	58728	83.8	77.7	77.7	54.8	100.0	100.0	100.0
House OCR	93261	84.3	81.1	81.1	80.8	100.0	99.9	98.9
Sénat électronique	13026	84.1	77.8	77.8	53.0	100.0	99.9	100.0
Sénat OCR	3985	57.4	46.2	46.2	64.9	100.0	100.0	99.4

% de lignes où le champ est renseigné · identité = rattachée à un bioguide_id · montant renseigné = amount_midpoint non vide · ticker/secteur/ETF vides = actif non coté (normal, pas un défaut)

Secteurs & origine des champs résolus

sous-corpus	n	secteur renseigné %	ETF %	top 3 secteurs
House électronique	58728	77.7	77.7	Information Technology 18%, Financials 14%, Health Care 13%
House OCR	93261	81.1	81.1	Information Technology 17%, Financials 15%, Health Care 13%
Sénat électronique	13026	77.8	77.8	Information Technology 19%, Financials 14%, Health Care 11%
Sénat OCR	3985	46.2	46.2	Financials 16%, Industrials 15%, Health Care 12%

secteur renseigné % / ETF % = taux de remplissage (vide = non coté) · top 3 = secteurs GICS dominants

Origine du ticker (ticker_source) :


sous-corpus	n	dico élec %	LLM %	nom d'actif %	récupéré %	explicite %	aucune %
House électronique	58728	0.0	0.0	0.0	3.2	80.5	16.2
House OCR	93261	35.9	40.2	0.0	0.7	7.5	15.7
Sénat électronique	13026	2.6	3.0	1.9	0.0	76.7	15.9
Sénat OCR	3985	21.0	25.7	0.0	0.0	10.6	42.6

dico élec = repris de l'électronique · LLM = résolu par LLM · nom d'actif = déduit du nom d'actif · récupéré = rendu par la passe nom→ticker vérifiée (cf. §6.2) · explicite = déjà présent dans la source · aucune = non résolu

Origine du secteur (sector_source) :

sous-corpus	n	yfinance %	LLM %	manuel %	aucune %
House électronique	58728	66.6	11.1	0.2	22.0
House OCR	93261	69.2	11.9	0.1	18.8
Sénat électronique	13026	62.7	14.9	0.8	21.6
Sénat OCR	3985	32.8	13.5	0.6	53.2

yfinance = base factuelle · LLM = correction vérifiée à la main · aucune



3. Qualité des dates

Trois questions, de la plus faible à la plus forte : les dates sont-elles **lisibles et cohérentes** (divulgaration $\geq$ transaction) ? le **délai légal** (STOCK Act ~45 j) est-il respecté ? reste-t-il des **anomalies** ?

Cohérence (disclosure_date $\geq$ transaction_date)

chambre	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
house	151989	98.1	99.9	219	101	2916
senate	17011	99.8	99.7	55	0	38

Par sous-corpus :

sous-corpus	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
House électronique	58728	100.0	99.9	69	4	0
House OCR	93261	96.9	99.8	150	97	2916
Sénat électronique	13026	100.0	99.9	9	0	0
Sénat OCR	3985	99.0	98.8	46	0	38

dates exploitables = parseables (% du total ; le reste = OCR illisible) · cohérentes = divulgation $\geq$ transaction, % **parmi les exploitables** (dénominateur = exploitables, pas le total → ce % peut dépasser « dates exploitables % ») · incohérentes = divulgation AVANT transaction (amendement/antidaté) · année aberrante = année suspecte par défaut (postérieure au dépôt, ou < 2012) · date manquante = illisible. Δ Colonnes NON additives : une même ligne peut cumuler « incohérente » ET « année aberrante » (le décompte disjoint est plus petit que la somme). Des transactions 2013–2019 sont légitimes (divulgations tardives).


Délai légal de divulgation (STOCK Act ~45 j)

chambre	n dates valides	$\leq 45j$ légal %	45–75j %	>75j %	négatif %	délai médian (j)
house	149073	87.3	6.3	6.2	0.1	27
senate	16973	86.9	3.0	9.8	0.3	24

Par sous-corpus :

sous-corpus	n dates valides	$\leq 45j$ légal %	45–75j %	>75j %	négatif %	délai médian (j)
House électronique	58728	83.5	5.0	11.3	0.1	28
House OCR	90345	89.8	7.1	2.9	0.2	27
Sénat électronique	13026	90.6	1.6	7.7	0.1	23
Sénat OCR	3947	74.5	7.7	16.6	1.2	31

n dates valides = transactions dont le délai est CALCULABLE (les deux dates présentes et lisibles ; « valide » = mesurable, pas « juste ») · délai = divulgation – transaction (j) · $\leq 45j$ = délai légal STOCK Act · 45–75 j = marge tolérée · >75 j = retard · négatif = anomalie (divulgation avant transaction), comptée dans n dates valides · délai médian en j



Divulgations les plus tardives (> 365 j)

déposant	chambre	date txn	date divulg.	délai (j)	ticker	opération
Jefferson Shreve	house	2015-05-08	2025-06-22	3698	DAL	Purchase
Jefferson Shreve	house	2015-05-08	2025-06-22	3698	DHR	Purchase
Mike Kelly	house	2007-08-31	2017-09-27	3680		Purchase
Diane Black	house	2006-02-06	2015-03-27	3336		Sale
Richard W. Allen	house	2017-02-03	2023-08-10	2379		Purchase
Richard W. Allen	house	2017-02-13	2023-08-10	2369	O	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331	BBT	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331	BBT	Sale (Partial)
Richard W. Allen	house	2017-04-27	2023-08-10	2296	COST	Purchase
Richard W. Allen	house	2017-04-27	2023-08-10	2296	XOM	Sale
Richard W. Allen	house	2017-05-16	2023-08-10	2277	FDX	Purchase
Richard W. Allen	house	2017-05-16	2023-08-10	2277	GE	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174	COO	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174	PCLN	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174	DFS	Sale

délai (j) = divulgation – transaction · divulgations > 1 an après la transaction (souvent des amendements ou de vieux comptes régularisés)


Audit des anomalies (échantillon de 12 PDF re-lus à la source). ~½ sont FIDÈLES : coquilles du **déposant lui-même** (un PTR imprime littéralement 01/35/22), cellules vides ou parts de société sans date de transaction — on les transcrit sans les inventer. ~⅓ = **notre OCR** (mois/jour mal lu), corrigé à la lecture **quand le formulaire est lisible** (4 dates vérifiées, clé doc+date, figé inchangé). ~⅙ = **provenance** (hallucination OCR ou pièce jointe absente du PDF). **On ne fabrique aucune date** : les illisibles restent flaguées.

4. Montants (amount_midpoint)

Le montant = **midpoint** de la fourchette déclarée (les déclarations donnent des tranches, pas un chiffre exact). Vue par sous-corpus :


sous-corpus	n	médiane \$	moyenne \$	P25_\$	P75_\$	P95_\$	volume total M\$
House électronique	58728	8000	59205	8000	32500	175000	3477.0
House OCR	93261	8000	44018	8000	32500	175000	4061.7
Sénat électronique	13026	8000	81666	8000	32500	175000	1063.8
Sénat OCR	3985	32500	301252	8000	175000	750000	1193.6

médiane/moyenne/P25/P75/P95 en \$ · volume total = Σ midpoint (M\$) · midpoint = milieu de la fourchette déclarée



la plus petite tranche (≤ 15 k\$, midpoint 8 000 \$) domine → dès qu'elle dépasse 50 %, le P25 ET la médiane y tombent ensemble (cas House/Sénat élec). Sénat OCR < 50 % → médiane 32 500 ≠ P25 8 000.

Ensemble — 167 989 montants renseignés · médiane 8 000 \$ · moyenne 58 314 \$ · P90 75 000 \$ · max 75 000 000 \$.




5. Activité & concentration

Qui trade, à quel point l'activité est concentrée, et ce que deviennent les positions.

Concentration du volume

sous-corpus	n déposants	HHI	Gini	top10 volume %
House électronique	309	432.4	0.873	57.6
House OCR	125	2561.1	0.953	94.7
Sénat électronique	75	943.7	0.826	79.5
Sénat OCR	14	2671.5	0.753	100.0

$HHI \in [0, 10000]$ et $Gini \in [0, 1]$ mesurent la concentration du volume par déposant (plus c'est haut, plus quelques déposants dominant).



Où va le volume

Top tickers par volume estimé :

ticker	n trades	volume M\$
MSFT	1516	550.1
AAPL	1297	120.4
FDX	366	119.9
ICE	209	94.5
BRP	7	87.8
MET	222	77.9
T	594	69.7
AMZN	1026	60.8
NVDA	692	57.6
WFM	127	52.9
BRK.B	450	49.9
BOKF	25	44.9
GOOGL	913	43.8
DFS	114	43.5
MMM	270	43.3

$volume\ M\$ = \sum midpoint\ des\ trades\ du\ ticker \cdot n\ trades = nombre\ de\ transactions$

Volume par secteur GICS :

secteur	n trades	volume M\$
Information Technology	22687	1236.8
Financials	19451	875.8
Industrials	16003	525.0
Health Care	17233	478.1
Consumer Discretionary	15551	434.2
Communication Services	10545	425.8
Energy	8618	351.7
Consumer Staples	9547	291.2
Materials	5700	124.3
Real Estate	4649	104.2
Utilities	2574	59.4

Top déposants

Par volume estimé ($\sum$ midpoint) :


déposant	chambre	n trades	volume estimé M\$
Michael T. McCaul	house	26938	1766.3
Rohit Khanna	house	40716	891.9
Diana Harshbarger	house	3274	467.8
RICHARD BLUMENTHAL	senate	1527	452.5
Josh Gottheimer	house	3574	347.8
Suzan K. DelBene	house	861	338.1
MARK R WARNER	senate	145	275.3
DIANNE FEINSTEIN	senate	705	254.1
Darrell E. Issa	house	20	250.5
Rick Scott	senate	357	240.7
Nancy Pelosi	house	220	227.8
Scott H. Peters	house	992	213.5
Jefferson Shreve	house	631	192.9
Scott Franklin	house	68	188.2
RICHARD M BURR	senate	525	188.0


volume estimé M\$ = Σ midpoint des transactions du déposant $\cdot$ n trades = transactions à montant renseigné (effectif légèrement inférieur au tableau par nombre ci-dessous)

Par nombre de transactions — 445 déposants distincts, dont **294** avec ≥ 10 transactions (éligibles au backtest) et **236** actifs sur ≥ 3 années :

nom	total	dont OCR	OCR %	n années	1re année	dern. année
Rohit Khanna	41080	41080	100	10	2017	2026
Michael T. McCaul	27123	27123	100	14	2013	2026
James B. Renacci	5453	5453	100	6	2013	2018
Thomas MacArthur	4995	0	0	5	2015	2019
David P. Roe	4680	4680	100	8	2013	2020
Diana Harshbarger	3666	3665	100	4	2021	2026
Josh Gottheimer	3574	21	1	10	2017	2026
David A Perdue , Jr	2611	0	0	6	2015	2020
Gilbert Cisneros	2597	0	0	4	2019	2026
Kurt Schrader	1899	1899	100	10	2013	2022
Lois Frankel	1725	54	3	11	2013	2023
Alan S. Lowenthal	1593	0	0	11	2012	2022
K. Michael Conaway	1593	3	0	8	2013	2020
Thomas R Carper	1557	9	1	13	2012	2024
RICHARD BLUMENTHAL	1543	1543	100	13	2014	2026
Francis Rooney	1536	1536	100	4	2017	2020
Lisa McClain	1532	109	7	3	2024	2026
Greg Gianforte	1490	0	0	4	2017	2020
Thomas H Tuberville	1369	0	0	5	2021	2025
Daniel Goldman	1291	0	0	2	2023	2025

total = nb transactions $\cdot$ dont OCR / OCR % = part scannée $\cdot$ n années = années actives $\cdot$ 1re/dern. année = première/dernière année de transaction (une 1re année < 2014 = vieilles transactions régularisées dans un dépôt 2014+)





Devenir des achats à +12 mois (revente vs fermeture forcée, pour la stratégie)

Pour chaque achat (avec ticker), on suit la position : est-elle **revendue par le même membre sur le même ticker dans les 12 mois** (l'horizon de fermeture forcée de la stratégie) ? L'appariement se fait sur la **date de divulgation** — ce que la stratégie peut observer. Les achats divulgués il y a **moins de 12 mois** (après 2025-07-02) n'ont pas assez de recul pour juger : marqués *trop récents* et exclus des taux.

chambre	achats (avec ticker)	trop récents	observables	revendu ≤12m	revendu ≤12m %	fermé de force	fermé de force +12m %
house	63652	2486	61166	41428	67.7	19738	32.3
senate	6328	236	6092	2944	48.3	3148	51.7

Par sous-corpus :

sous-corpus	achats (avec ticker)	trop récents	observables	revendu ≤12m	revendu ≤12m %	fermé de force	fermé de force +12m %
House électronique	24362	1741	22621	11710	51.8	10911	48.2
House OCR	39290	745	38545	29718	77.1	8827	22.9
Sénat électronique	5188	231	4957	2358	47.6	2599	52.4
Sénat OCR	1140	5	1135	586	51.6	549	48.4

achats (avec ticker) · trop récents = <12 mois de recul depuis la divulgation (indéterminé, hors dénominateur) · *observables* = *achats* – *trop récents* · *revendu ≤12m* = une vente du même ticker divulguée dans les 12 mois · *fermé de force +12m* = aucune vente sous 12 mois → la stratégie clôt la position · les deux % portent sur les observables

6. Complétude vs Quiver (vérité-terrain externe)

Section clé. Quiver est un fournisseur commercial des mêmes données = notre **juge externe**. But : montrer qu'on a **au moins tout ce que Quiver a** (Quiver $\subseteq$ nous), qu'on est même **plus complet**, et que nos différences ne sont **pas des erreurs**. On procède comme un **entonnoir, de stricteesse croissante** : Niveau 1 → 2 → 3. Chiffres recalculés par `common/quiver_diagnosis.py`, **jamais réinjectés**.

6.1 Méthode

Chaque transaction est confrontée à Quiver par une clé normalisée, en **trois niveaux de plus en plus stricts** : **N1** a-t-on le trade ? (*sans la date*, §6.2) → **N2** le même trade à la même date ? (§6.3) → **N3** qui corrige quoi ? (§6.5).

élément	définition
univers comparé	tous les trades Quiver Filed ∈ 2014–2026 (notre fenêtre de scrape)
clé d'appariement	(bioguide, ticker normalisé, sens) — + date au Niveau 2, sans date au Niveau 1
normalisation ticker	MAJ + trim ; rejette {vide, NAN, NONE, --} ; retire PUT / CALL ; . / - → _
normalisation sens	1re lettre p/s/e → Purchase / Sale / Exchange

Périmètre : le corpus FINAL dédoublé cross-année (169 000 transactions uniques, cf. §1 « Construction & validation du corpus »).

Réf. : `house/quiver.py` (norm_ticker, norm_sense), `common/quiver_diagnosis.py`.

6.2 Niveau 1 — A-t-on le trade ? (sans la date)

On compare des **combinaisons** (membre, action, sens), en **ignorant volontairement la date ET le nombre** : (Khanna, AAPL, Achat) compte pour un, qu'il l'ait acheté 1 fois ou 50. La question est donc grossière **exprès** : « a-t-on raté une combinaison **ENTIÈRE** que Quiver connaît ? » — le comptage trade par trade, c'est le Niveau 2 (§6.3).

On retrouve **93.5 % (House)** et **92.1 % (Sénat)** des combinaisons Quiver. Le **trou coté** est minuscule (31 House / 0 Sénat) — c'est une **borne haute (sans date)** ; au trade DATÉ (§6.5, clé différente — les deux comptes ne s'emboîtent pas), la mesure complémentaire confirme les vrais trous. Le reste du résidu est récupérable ou hors périmètre :

chambre	combinaisons Quiver (fenêtre)	qu'on a	inclusion %	résidu	récupérable (OCR)	hors périmètre	trou coté (borne haute)
house	26175	24471	93.5	1704	1578	95	31
senate	4540	4180	92.1	360	7	353	0

Le résidu se lit ainsi : **récupérable (OCR)** = membre lu en OCR papier dont on a capté le trade mais **pas résolu le ticker** (nom lisible → récupérable, cf. note ; sinon non-coté déguisé/charabia OCR) · **hors périmètre** = « ticker » Quiver non-coté (CUSIP/fragment) + trade sous un ticker d'échange combiné (« PFE VTRS » couvre PFE) + membre de l'autre chambre polluant le cache · **trou coté (borne haute)** = combos manquants au niveau ticker (sans date) ; au trade DATÉ (§6.5, mesure complémentaire à clé différente), NOTRE_MANQUE compte de vrais trous confirmés.

Note : une passe de **récupération nom→ticker** (vérifiée, **hors Quiver**, appliquée à la lecture — golden intact) a rendu leur ticker à **2540 trades** d'actions que l'OCR/LLM avaient laissés vides (faux négatifs, ex. NEENAH PAPER→NP, TENCENT→TCEHY). Le « récupérable OCR » restant est surtout des **non-cotés déguisés** (préférentielles, fonds) et du **charabia OCR**, non mappables.

Bilan net (au trade près) — actions cotées qu'on a et que Quiver n'a PAS vs **vrais trous** (NOTRE_MANQUE, mesure au trade daté — clé différente de la borne ticker-niveau ci-dessus, les deux comptes ne s'emboîtent pas réellement absents au trade près) → on est un **sur-ensemble** de Quiver :

chambre	actions qu'on a en +	vrais trous	solde net
house	23562	27	23535
senate	2962	11	2951

⚠ **Honnêteté par ère (corroboration au niveau ACTION, House asset_type=Stock).** Le taux global lisse une forte hétérogénéité : **2020-2026 = 87.2 %** d'actions corroborées par Quiver, mais **2014-2019 = 58.7 %** seulement (creux **2015-2016** ≈ 17 %). L'écart **ne reflète PAS une erreur de notre côté** : nos 15 015 actions « en plus » pré-2020 portent des **tickers réels et d'époque** (vérifiés), mais **Quiver est mince avant ~2017** et ne peut pas les corroborer. En clair : **moins de vérité-terrain externe avant 2017**, à garder en tête pour tout usage aval (backtest).

année	actions_corroborées	actions_only_nous	corroboration_pct
2014	1930	3984	32.6
2015	540	2711	16.6
2016	291	1458	16.6
2017	3729	2241	62.5
2018	7243	2722	72.7
2019	7630	1899	80.1
2020	10025	2801	78.2
2021	6945	2803	71.2
2022	11011	1286	89.5
2023	7522	442	94.5
2024	6797	481	93.4
2025	11095	408	96.5
2026	4740	348	93.2

actions_corroborées = appariées à Quiver (exact + date proche) · *actions_only_nous* = actions réelles qu'on a et que Quiver n'a pas (non corroborables) · *corroboration_pct* = corroborées / (corroborées + only_nous).

6.3 Niveau 2 — Le même trade, à la même date ?

On descend au trade près. Comme un membre peut trader le même titre **plusieurs fois**, on ne demande PAS « ma date est-elle dans l'ensemble Quiver ? » : on **apparie 1-à-1** nos trades à ceux de Quiver, à l'intérieur de chaque (membre, ticker, sens). Exemple :

Khanna, AAPL, Achat – dates :
NOUS : 08-jan-2020 · 13-fév-2020 · 01-juin-2020 · 10-mars-2023
QUIVER : 08-jan-2020 · 12-fév-2020 · 10-mars-2023

Étape 1 – on retire les dates IDENTIQUES (une par une) :
08-jan ↔ 08-jan et 10-mars-2023 ↔ 10-mars-2023 → 2 « apparié exact »
(le trade 2023 s'apparie à SON 2023, jamais à un 2020)

Étape 2 – on apparie les RESTES au plus proche (plafond 90 j) :
13-fév (nous) ↔ 12-fév (Quiver) = 1 j → « apparié proche » (≤ 10 j, bruit de date)
01-juin (nous) : aucun reste Quiver à < 90 j → « NOUS-SEUL » (trade en plus)

Deux garde-fous répondent à « comment gérer qu'un membre ait plusieurs trades » : l'appariement **1-à-1 respecte les quantités** (si on a 50 trades et Quiver 40, **≥ 10 restent forcément en « nous-seul »**) ; le **plafond de 90 j** + l'**ancrage au dépôt** empêchent mécaniquement de confondre un trade 2020 et un trade 2023. Chaque trade tombe alors dans **une** catégorie :

chambre	apparié exact	apparié proche (≤10j)	candidat écart	dont même déclaration	nous-seul	quiver-seul	candidat %
house	70265	845	2202	545	39207	9899	2.0
senate	8766	0	0	0	3140	581	0.0

apparié exact = même date · *apparié proche* = écart des dates de TRANSACTION ≤ 10 j (bruit/convention de date Quiver, même trade) · *candidat écart* = paire à 10–90 j, à inspecter (§6.4) · *dont même déclaration* = les deux trades viennent du MÊME formulaire de déclaration (PTR) — notre *disclosure* ≈ *Filed* Quiver ≤ 10 j → même trade, donc l'écart de date est un vrai désaccord (seul signal fort) · *nous-seul* = Quiver n'a PAS le trade (on est plus complet) · *quiver-seul* = on a raté.

Pourquoi les chiffres semblent contredire le §6.2 : c'est le niveau de strictesse. Au Niveau 1 (sans date), le trou coté (borne haute) est 31/0 ; au Niveau 2 (trade + date), on compte 39207 trades « nous-seul » — normal, on trade plus souvent que Quiver ne capte au trade près. **Les deux disent la même chose : on est plus complet.**

6.4 Les candidats d'écart de date (même déclaration)

Les **seuls** candidats honnêtes d'erreur de date = les paires issues de la **même déclaration (PTR)** (545 House / 0 Sénat). Prudence : un petit delta peut être une **convention de date Quiver**, pas notre erreur. Le **vrai contrôle des dates reste l'audit PDF (§3)**, pas Quiver. *doc_id* = pièce consultable :

chambre	déposant	ticker	sens	notre date	date Quiver	delta (j)	doc_id
house	Michael T. McCaul	GOOGL	Purchase	2018-07-26	2018-08-06	11	9113676
house	Michael T. McCaul	PEP	Purchase	2018-05-24	2018-06-04	11	9113406
house	Michael T. McCaul	SIRI	Sale	2018-06-25	2018-07-06	11	9113580
house	Rohit Khanna	ADBE	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	AMT	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	BX	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	CDNS	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	CHTR	Sale	2022-09-08	2022-09-19	11	8219242
house	Rohit Khanna	CMG	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	DHR	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	DXC	Sale	2020-03-25	2020-04-05	11	8217164
house	Rohit Khanna	ETR	Sale	2020-04-07	2020-04-18	11	8217213

(Top 12 par delta croissant ; les 545 candidats sont dans `quiver_validation/candidats_ecart_date_meme_depot.csv`.)

6.5 Niveau 3 — Que reste-t-il à corriger ?

On a vérifié l'existence (§6.2) et la date (§6.3). Restent deux choses : les autres champs des trades qu'on partage avec Quiver (sens, montant), et la liste de ce qui est vraiment à corriger.

Autres champs — sens & montant. Pour les trades qu'on a tous les deux (mêmes membre + ticker + date), est-on d'accord sur le sens (achat/vente) et le montant ?

chambre	n paires	accord sens %	accord montant %
house	86090	96.8	94.2
senate	9775	99.9	99.8

on apparie les cellules (membre, ticker, date) présentes des DEUX côtés ; un désaccord = vraie erreur d'extraction, listée dans `desaccord_champ_*.csv`.

La to-do (à corriger). Un seul chiffre est dur — les vrais trous NOTRE_MANQUE (le résidu après tous les filtres) ; les deux autres sont des bornes hautes ensemblistes = des listes à revoir cas par cas dans `docs/quiver_validation/`, pas des taux d'erreur :

à corriger	House	Sénat	nature	annexe
vrais trous cotés (NOTRE_MANQUE)	27	11	DUR — vrai trou confirmé au trade près (mesure au trade DATÉ, clé différente de la borne ticker-niveau du §6.2 : les deux comptes ne s'emboîtent pas)	notre_manque_*
lignes OCR papier (MANQUANT_PAPIER)	3378	0	borne haute — trades Quiver de déposants qu'on OCR, absents de nos clés exactes	manquant_papier_*
tickers à revoir (ECART_TICKER)	8418	190	borne haute — autre ticker ce jour-là (gonflée par la multiplicité, PAS un taux d'erreur)	ecart_ticker_*

Qui ? — top 12 des déposants derrière les vrais trous (NOTRE_MANQUE ; liste complète ligne à ligne : `docs/quiver_validation/notre_manque_*.csv`) :

chambre	bioguide	nom	n trous
house	T000475	David A. Trott	8
house	B001327	Rob Bresnahan	5
house	W000797	Debbie Wasserman Schultz	3
house	M001193	Thomas MacArthur	2
house	S000250	Pete Sessions	2
house	C001101	Katherine M. Clark	1
house	F000461	Bill Flores	1
house	J000307	John James	1
senate	C001075	William Cassidy	5
senate	M001198	Roger W Marshall	3
senate	R000608	Jacklyn S Rosen	2
senate	D000622	Tammy Duckworth	1

6.6 Annexe

Les tables figées du golden (`data/house/tables/*/07c_*`, `07g_*`, `07h_*` et équivalents Sénat) reproduisent la même comparaison en *exact-date* (elles sous-comptent, cf. §6.3) ; conservées comme jeux de référence de non-régression, non re-rendues ici. Les autres tables `07*/06d` de chaque année sont des sorties historiques du pipeline.

Profil des clusters de scan (House OCR) — pourquoi le manuscrit est exclu (A = tapé droit, B = tapé tourné, C = manuscrit) :

cluster	n lignes	n docs	date plausible %	ticker %	Quiver a le trade %
A_tape_droit	5956	59	99.6	84.5	88.0
B_tape_tourne	84787	1517	96.4	84.3	65.2
C_manuscrit	2518	193	98.6	83.3	12.9

`date plausible % / ticker %` = qualité INTERNE (sans Quiver) · `Quiver a le trade %` = part de nos trades cotés que Quiver possède AUSSI (appariée sur membre+ticker+sens, date ou non). Sur le manuscrit (C), la qualité interne reste haute mais `Quiver a le trade %` s'effondre (ticker/identité mal lus, ou Quiver mince sur le papier) → faute de pouvoir le confirmer contre la vérité-terrain, on l'exclut par défaut (conservateur). Exceptions explicites et REJOUABLES (`house/ocr.py`) : 3 déposants à forte perte corroborée (FILERS_C_A_RECUPERER) + 33 documents curés manuellement (DOCS_C_HERITES_2020_2026).

Listes actionnables complètes (ligne à ligne) → `docs/quiver_validation/` (`ecart_ticker_*`, `notre_manque_*`, `manquant_papier_*`, `desaccord_champ_*` [typé], `on_est_plus_complet_*`, `quiver_non_cote_*`, `candidats_ecart_date_meme_depot`). Hors golden.

7. Du corpus à la table de recherche (nettoyage backtest)

Le corpus validé ci-dessus contient TOUT ce qui est déclaré (y compris obligations, munis, options, lignes sans ticker) — un backtest, lui, exige un prix, un sens et un montant. Le notebook `Nettoyage_Backtest_2014_2026.ipynb` dérive la table de recherche canonique `data/clean/transactions_backtest_2014_2026.csv` (134 464 lignes x 36 colonnes) par un entonnoir en 4 étapes.

Principe : on ne retire que l'AVÉRÉ inutilisable pour un backtest ; tout le doute est GARDÉ et FLAGUÉ (le tableau des flags ci-dessous) — aucune ligne n'est écartée en silence. Les comptes ci-dessous sont REJOUÉS par ce rapport avec les mêmes règles que le notebook, puis confrontés au fichier publié (égalité vérifiée par assertion à chaque run).

L'entonnoir

étape	règle	retirées	restantes
—	corpus unique (load_final)	0	169000
A	dates présentes & cohérentes (divulgarion ≥ transaction, année plausible)	3252	165748
B	actions + ETF cotés (ticker exploitable, réellement coté, famille cotée)	29771	135977
C	direction claire (achat / vente — les échanges sortent)	826	135151
D	montant présent (fourchette STOCK Act → point milieu)	687	134464

169 000 → 134 464 = 79.6 % du corpus conservé. Chaque retrait est motivé par l'impossibilité MATÉRIELLE de backtester la ligne, jamais par un simple champ vide récupérable.

Pourquoi les lignes de l'étape B partent (une seule cause par ligne)

cause	lignes
ticker vide (aucun symbole → pas de prix)	27006
ticker malformé / non coté (CUSIP, fragment OCR...)	164
famille non cotée (option, obligation, muni, gouvernement)	2601

ticker vide = actifs non cotés (munis, obligations, sociétés privées) qui n'ont légitimement pas de symbole · malformé/non coté = CUSIP, fragments OCR, préférentielles non joignables à un prix · famille non cotée = options, obligations, bons du Trésor (classes détectées ticker-first : une action au type déclaré vide est GARDÉE grâce à son ticker).

Composition de la table publiée

Par chambre et par ère :

chambre	ère	transactions
house	2014-2019	56706
house	2020-2026	66108
senate	2014-2019	7111
senate	2020-2026	4539

Par sens :

sens	transactions
buy	68250
sell	66214

Par classe d'actif :

classe d'actif	transactions
stock	128974
unknown	3300
etf_broad	2022
etf_sector	168

stock = action avec secteur GICS (rempli à 100 % sur les actions) · etf_sector = SPDR sectoriel (son propre proxy) · etf_broad = ETF diversifié coté, GARDÉ et flagué (pas de secteur GICS par nature) · unknown = coté mais classe non résolue, flagué.

Ce qui est flagué (gardé, jamais retiré)

flag	lignes	%
flag_late_filing — divulgation > 45 j (l'info reste exploitable à sa date de publication)	16349	12.2
flag_very_late_filing — divulgation > 365 j	3075	2.3
is_delisted — titre sorti de cote (rachat/faillite, typé via data/reference/ticker_renames.csv)	3542	2.6
lot_size > 1 — lots multi-comptes réels (Self/Spouse/Joint) — ne JAMAIS dédupliquer	11873	8.8
flag_price_caution — symbole recyclé / jambe absorbée d'une fusion (join prix par période)	505	0.4

Ce que la table ajoute au corpus (enrichissements)

- **Parti à la date de la transaction** (les changements de parti en cours de mandat sont datés — party_affiliations du référentiel officiel).
- **Commissions du Congrès de la transaction** (snapshots par Congrès 113-119, data/reference/committees_snapshots/ ; bascule au 3 janvier) + committees_key_flag (fiscalité / défense / renseignement / banque) — la liste complète est exportée, la recherche peut redéfinir son propre flag.
- **ticker fidèle à la déclaration + ticker_yahoo prêt pour le join prix** (format Yahoo, renommages et fusions appliqués via data/reference/ticker_renames.csv ; les titres délistés sont typés — faillite, rachat — au lieu de disparaître en silence).
- **amount_midpoint = milieu exact de la fourchette STOCK Act** (convention unique sur tout le corpus) ; owner, occurrence_index, lot_size, doc_id, natural_key_hash pour la traçabilité ligne à ligne.
- **Invariants garantis à l'export** (assertions) : bioguide, ticker, montant, direction, chronologie (divulgarion ≥ transaction) et clé naturelle remplis sur 100 % des lignes.