

Rapport qualité — Données de trading du Congrès américain

Chambre des représentants + Sénat · 2014–2026 · généré par python -m common.quality (lecture seule des tables FINAL, aucun appel API) · Quiver Quantitative = vérité-terrain externe, **jamais réinjectée**. Les % sont arrondis à 0,1 pt ; une somme de colonnes peut afficher 100,1.

Résumé exécutif

- **Périmètre** — 167 593 transactions uniques de membres élus (House 150 582 + Sénat 17 011), 2014–2026, en **4 sous-corpus** (chambre × voie d'acquisition : électronique déterministe / scan OCR).
- **Complétude vs Quiver (§6)** — dans notre fenêtre, on retrouve **88.3 % (House) / 92.1 % (Sénat)** des trades Quiver au niveau (déposant, ticker, sens). Le **trou coté est minuscule** — ≤ 753 House / 0 Sénat au niveau ticker (borne haute), dont **918 / 11 vrais trous confirmés au trade près** (§6.5) ; le reste du résidu est de l'OCR récupérable ou du hors-périmètre.
- **On est plus complet que Quiver** — **+27204 actions cotées qu'on a et que Quiver n'a pas, contre 929 trous inverses**. La base est, en pratique, un **sur-ensemble** de Quiver.
- **Les « écarts » de date ne sont pas des erreurs** — la réconciliation 1-à-1 (§6.3) montre que l'essentiel est du « nous-seul » (Quiver n'a pas le trade) ; seuls 586 candidats House (même déclaration) méritent l'œil, et le vrai contrôle des dates reste l'audit PDF (§3).
- **Données propres** — identité rattachée à 100.0 %, dates cohérentes 99.8 %, délai de divulgation médian 27 j, montants renseignés 99.4 %.

Plan : §1 construction & validation · §2 composition & complétude · §3 qualité des dates · §4 montants · §5 activité & concentration · §6 complétude vs Quiver (vérité-terrain).

1. Construction & validation du corpus

Avant toute statistique, voici **comment le corpus est construit**, dans l'ordre :

1. **Sources** — déclarations officielles : Chambre (*PTR*) et Sénat (*eFD*), chacune en deux voies — **électronique** (formulaire structuré, lecture déterministe) et **papier scanné** (PDF → **OCR** par modèle de vision).
2. **Extraction** — une ligne = une transaction (membre, date, actif, sens, fourchette de montant, détenteur).
3. **Enrichissement** — ticker (explicite dans la source · repris de l'électronique · résolu par LLM), secteur GICS (yfinance · LLM), identité (*bioguide_id*), ancienneté.
4. **Déduplication cross-année** — une même transaction re-divulguée une autre année (amendement, rapport annuel) ne compte qu'**une fois** (clé naturelle + rang d'occurrence).

Réconciliation — des lignes brutes aux transactions uniques (c'est notre corpus, pas Quiver) :

chambre	lignes brutes	re-divulgations (dédup)	transactions uniques
house	150647	65	150582
senate	18839	1828	17011
TOTAL	169486	1893	167593

lignes brutes = FINAL concaténé 2014–2026 · *re-divulgations* = doublons cross-année retirés · *transactions uniques* = le corpus analysé dans tout ce rapport

Validation & reproductibilité

Tout est **rejouable hors-ligne** (lecture seule des tables FINAL, **0 appel API**), adossé à trois filets automatiques :

- **Golden octet-à-octet** — 354 tables CSV figées par SHA256 (217 House + 137 Sénat), rejouées à **zéro écart** (*tests/regression/check_golden.py*, *senate_check_golden.py*).
- **Invariants porteurs** — pour chaque chambre *digital* + *OCR* = FINAL, identité rattachée à **100.0 %**, 378 bioguides (House) / 76 (Sénat) recomptés (*tests/regression/audit_metrics.py*).
- **Transformations déterministes** — 11 tests reproduisent chaque étape (clé naturelle, montants, tickers, identité, ancienneté, cache Vision) depuis les colonnes figées.

Les quatre sous-corpus

Toute la suite distingue **quatre familles** (chambre × voie), car leur qualité et leur composition diffèrent :

sous-corpus	n	part %
House électronique	54150	32.3
House OCR	96432	57.5
Sénat électronique	13026	7.8
Sénat OCR	3985	2.4

sous-corpus = chambre × voie (électronique déterministe / scan OCR) · *n* = transactions uniques · *part %* du total


2. Composition & complétude

Ce que contient le corpus (opérations, détenteur, familles d'actifs), puis à quel point les champs sont remplis.

Sens des opérations

sous-corpus	n	achat %	vente %	échange %	autre %
House électronique	54150	51.6	47.3	1.0	0.0
House OCR	96432	52.6	46.9	0.5	0.0
Sénat électronique	13026	50.2	48.8	1.0	0.0
Sénat OCR	3985	56.4	43.0	0.6	0.0

achat = *operation_type* contient « Purchase » · *vente* = contient « Sale » (**inclut Sale (Partial) et (Full)**) · *échange* = « Exchange » · *autre* = reste



Détenteur déclaré

sous-corpus	n	perso %	conjoint %	joint %	enfant %	autre %
House électronique	54150	48.8	20.4	27.3	3.5	0.0
House OCR	96432	10.7	47.0	14.5	27.8	0.0
Sénat électronique	13026	16.8	38.7	42.1	2.4	0.0
Sénat OCR	3985	48.8	49.5	1.5	0.3	0.0


titulaire du compte : perso = Self · conjoint = Spouse/SP · joint = Joint/JT · enfant = Dependent/Child/DC · autre = reste ou non déclaré

Familles d'actifs

Le non-coté (oblig. d'État, munis, obligations) domine l'OCR du Sénat :

sous-corpus	n	action %	option %	oblig. État %	muni %	oblig. corp. %	fonds %	autre %	manquant %
House électronique	54150	63.3	1.3	4.4	0.0	0.0	0.0	5.3	25.6
House OCR	96432	77.3	0.0	0.7	0.0	0.4	3.3	0.3	18.0
Sénat électronique	13026	73.0	4.7	0.0	7.7	3.0	0.0	6.5	5.1
Sénat OCR	3985	40.4	0.0	0.0	0.7	2.2	0.0	41.2	15.5

familles d' *asset_type* : action = Stock · option · oblig. État = Gov/Treasury · muni = Municipal · oblig. corp. = Bond · fonds = Fund/ETF · manquant = vide



Couverture des champs enrichis (taux de remplissage)

sous-corpus	n	ticker %	secteur %	ETF %	commission %	identité %	ancienneté %	montant renseigné %
House électronique	54150	80.3	78.0	78.0	57.5	100.0	100.0	100.0
House OCR	96432	83.8	80.6	80.6	79.7	100.0	100.0	98.9
Sénat électronique	13026	84.1	77.8	77.8	53.0	99.9	99.9	100.0
Sénat OCR	3985	57.4	46.2	46.2	64.9	100.0	100.0	99.4

% de lignes où le champ est renseigné · identité = rattachée à un *bioguide_id* · montant renseigné = *amount_midpoint* non vide · ticker/secteur/ETF vides = actif non coté (normal, pas un défaut)

Secteurs & origine des champs résolus

sous-corpus	n	secteur renseigné %	ETF %	top 3 secteurs
House électronique	54150	78.0	78.0	Information Technology 18%, Financials 14%, Health Care 13%
House OCR	96432	80.6	80.6	Information Technology 16%, Financials 15%, Health Care 13%
Sénat électronique	13026	77.8	77.8	Information Technology 19%, Financials 14%, Health Care 11%
Sénat OCR	3985	46.2	46.2	Financials 16%, Industrials 15%, Health Care 12%

secteur renseigné % / ETF % = taux de remplissage (vide = non coté) · top 3 = secteurs GICS dominants

Origine du ticker (*ticker_source*) :


sous-corpus	n	dico élec %	LLM %	nom d'actif %	récupéré %	explicite %	aucune %
House électronique	54150	0.0	0.0	0.0	0.0	80.3	19.7
House OCR	96432	34.5	41.7	0.0	0.7	7.0	16.2
Sénat électronique	13026	2.6	3.0	1.9	0.0	76.7	15.9
Sénat OCR	3985	21.0	25.7	0.0	0.0	10.6	42.6

dico élec = repris de l'électronique · LLM = résolu par LLM · nom d'actif = déduit du nom d'actif · récupéré = rendu par la passe nom→ticker vérifiée (cf. §6.2) · explicite = déjà présent dans la source · aucune = non résolu

Origine du secteur (sector_source) :

sous-corpus	n	yfinance %	LLM %	manuel %	aucune %
House électronique	54150	67.9	10.1	0.3	21.8
House OCR	96432	68.2	12.5	0.1	19.3
Sénat électronique	13026	62.7	14.9	0.8	21.6
Sénat OCR	3985	32.8	13.5	0.6	53.2

yfinance = base factuelle · LLM = manuel = correction d'audit · aucune



3. Qualité des dates

Trois questions, de la plus faible à la plus forte : les dates sont-elles lisibles et cohérentes (divulgaration ≥ transaction) ? le délai légal (STOCK Act ~45 j) est-il respecté ? reste-t-il des anomalies ?

Cohérence (disclosure_date ≥ transaction_date)

chambre	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
house	150582	99.8	99.9	221	7	307
senate	17011	99.8	99.7	55	0	38

Par sous-corpus :

sous-corpus	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
House électronique	54150	100.0	99.9	56	3	0
House OCR	96432	99.7	99.8	165	4	307
Sénat électronique	13026	100.0	99.9	9	0	0
Sénat OCR	3985	99.0	98.8	46	0	38

dates exploitables = parseables (% du total ; le reste = OCR illisible) · cohérentes = divulgation ≥ transaction, % parmi les exploitables (dénominateur = exploitables, pas le total → ce % peut dépasser « dates exploitables % ») · incohérentes = divulgation AVANT transaction (amendement/antidaté) · année aberrante = année impossible (postérieure au dépôt, ou < 2012) · date manquante = illisible. Des transactions 2013–2019 sont légitimes (divulgations tardives).


Délai légal de divulgation (STOCK Act ~45 j)

chambre	n dates valides	≤45j légal %	45–75j %	>75j %	négatif %	délai médian (j)
house	150275	87.6	6.3	6.0	0.1	28
senate	16973	86.9	3.0	9.8	0.3	24

Par sous-corpus :

sous-corpus	n dates valides	≤45j légal %	45–75j %	>75j %	négatif %	délai médian (j)
House électronique	54150	82.9	5.2	11.8	0.1	28
House OCR	96125	90.2	6.9	2.7	0.2	28
Sénat électronique	13026	90.6	1.6	7.7	0.1	23
Sénat OCR	3947	74.5	7.7	16.6	1.2	31

n dates valides = transactions dont le délai est CALCULABLE (les deux dates présentes et lisibles ; « valide » = mesurable, pas « juste ») · délai = divulgation – transaction (j) · ≤45 j = délai légal STOCK Act · 45–75 j = marge tolérée · >75 j = retard · négatif = anomalie (divulgation avant transaction), comptée dans n dates valides · délai médian en j



Divulgations les plus tardives (> 365 j)

déposant	chambre	date txn	date divulg.	délai (j)	ticker	opération
Jefferson Shreve	house	2015-05-08	2025-06-22	3698.0	DHR	Purchase
Jefferson Shreve	house	2015-05-08	2025-06-22	3698.0	DAL	Purchase
Mike Kelly	house	2007-08-31	2017-09-27	3680.0		Purchase
Diane Black	house	2006-02-06	2015-03-27	3336.0		Sale
Richard W. Allen	house	2017-02-03	2023-08-10	2379.0		Purchase
Richard W. Allen	house	2017-02-13	2023-08-10	2369.0	O	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331.0	BBT	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331.0	BBT	Sale (Partial)
Richard W. Allen	house	2017-04-27	2023-08-10	2296.0	XOM	Sale
Richard W. Allen	house	2017-04-27	2023-08-10	2296.0	COST	Purchase
Richard W. Allen	house	2017-05-16	2023-08-10	2277.0	GE	Sale
Richard W. Allen	house	2017-05-16	2023-08-10	2277.0	FDX	Purchase
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	BLK	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	FB	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	CME	Sale

délai (j) = divulgation – transaction · divulgations > 1 an après la transaction (souvent des amendements ou de vieux comptes régularisés)


Audit des anomalies (échantillon de 12 PDF re-lus à la source). ~½ sont FIDÈLES : coquilles du **déposant lui-même** (un PTR imprime littéralement 01/35/22), cellules vides ou parts de société sans date de transaction — on les transcrit sans les inventer. ~⅓ = **notre OCR** (mois/jour mal lu), corrigé à la lecture **quand le formulaire est lisible** (4 dates vérifiées, clé doc+date, figé inchangé). ~⅙ = **provenance** (hallucination OCR ou pièce jointe absente du PDF). **On ne fabrique aucune date** : les illisibles restent flaggées.

4. Montants (amount_midpoint)

Le montant = **midpoint** de la fourchette déclarée (les déclarations donnent des tranches, pas un chiffre exact). Vue par sous-corpus :


sous-corpus	n	médiane \$	moyenne \$	P25_\$	P75_\$	P95_\$	volume total M\$
House électronique	54150	8000	46863	8000	15001	100001	2537.6
House OCR	96432	8000	45390	8000	32500	175000	4331.0
Sénat électronique	13026	8000	81666	8000	32500	175000	1063.8
Sénat OCR	3985	32500	301252	8000	175000	750000	1193.6

médiane/moyenne/P25/P75/P95 en \$ · volume total = $\sum \text{midpoint (M\$)} \cdot \text{midpoint} = \text{milieu de la fourchette déclarée}$



la plus petite tranche (≤ 15 k\$, midpoint 8 000 \$) domine → dès qu'elle dépasse 50 %, le P25 ET la médiane y tombent ensemble (cas House/Sénat élec). Sénat OCR < 50 % → médiane 32 500 ≠ P25 8 000.

Ensemble — 166 554 montants renseignés · médiane 8 000 \$ · moyenne 54 793 \$ · P90 75 000 \$ · max 75 000 000 \$.




5. Activité & concentration

Qui trade, à quel point l'activité est concentrée, et ce que deviennent les positions.

Concentration du volume

sous-corpus	n déposants	HHI	Gini	top10 volume %
House électronique	302	439.3	0.871	58.2
House OCR	153	2472.3	0.953	91.1
Sénat électronique	73	944.0	0.821	79.5
Sénat OCR	14	2671.5	0.753	100.0

$HHI \in [0, 10000]$ et $Gini \in [0, 1]$ mesurent la concentration du volume par déposant (plus c'est haut, plus quelques déposants dominent).



Où va le volume

Top tickers par volume estimé :

ticker	n trades	volume M\$
MSFT	1529	302.7
FDX	357	118.2
AAPL	1310	96.6
ICE	208	94.5
ADP	296	88.7
BRP	7	81.8
MET	216	77.7
T	574	68.5
AMZN	1030	52.6
WFM	134	52.3
BRK.B	450	49.4
LAZ	24	48.6
NVDA	687	48.1
DFS	114	43.5
MMM	256	43.2

$\text{volume M\$} = \sum \text{midpoint des trades du ticker} \cdot n \text{ trades} = \text{nombre de transactions}$

Volume par secteur GICS :

secteur	n trades	volume M\$
Information Technology	22334	1003.6
Financials	19355	835.8
Industrials	15934	507.9
Health Care	16944	473.4
Consumer Discretionary	15713	414.6
Communication Services	10444	393.6
Energy	8588	302.4
Consumer Staples	9382	280.0
Materials	5599	117.8
Real Estate	4502	96.6
Utilities	2472	55.8

Top déposants

Par volume estimé (Σ midpoint) :



déposant	chambre	n trades	volume estimé M\$
Michael T. McCaul	house	29016	1890.6
Rohit Khanna	house	39176	867.1
Diana Harshbarger	house	3124	464.5
RICHARD BLUMENTHAL	senate	1527	452.5
MARK R WARNER	senate	145	275.3
DIANNE FEINSTEIN	senate	705	254.1
Darrell E. Issa	house	20	250.5
Rick Scott	senate	357	240.7
Josh Gottheimer	house	3578	217.2
Suzan K. DelBene	house	835	209.8
Jefferson Shreve	house	631	191.7
RICHARD M BURR	senate	525	188.0
Scott Franklin	house	68	182.1
Scott H. Peters	house	937	158.2
Nancy Pelosi	house	199	153.6

volume estimé M\$ = Σ midpoint des transactions du déposant · n trades = nombre de transactions

Par nombre de transactions — 454 déposants distincts, dont **299** avec ≥ 10 transactions (éligibles au backtest) et **243** actifs sur ≥ 3 années :

nom	total	dont OCR	OCR %	n années	1re année	dern. année
Rohit Khanna	39538	39538	100	10	2017	2026
Michael T. McCaul	29200	29200	100	14	2013	2026
James B. Renacci	5201	5201	100	6	2013	2018
David P. Roe	4192	4192	100	8	2013	2020
Thomas MacArthur	4185	0	0	5	2015	2019
Josh Gottheimer	3578	25	1	10	2017	2026
Diana Harshbarger	3515	3514	100	4	2021	2026
David A Perdue , Jr	2611	0	0	6	2015	2020
Gilbert Cisneros	2535	0	0	4	2019	2026
Kurt Schrader	1754	1754	100	10	2013	2022
Thomas R Carper	1557	9	1	13	2012	2024
RICHARD BLUMENTHAL	1543	1543	100	13	2014	2026
Lisa McClain	1532	109	7	3	2024	2026
Kenny Marchant	1509	1509	100	6	2014	2019
Alan S. Lowenthal	1505	0	0	11	2012	2022
Francis Rooney	1460	1460	100	4	2017	2020
Greg Gianforte	1415	0	0	4	2017	2020
Thomas H Tuberville	1369	0	0	5	2021	2025
Lois Frankel	1297	54	4	11	2013	2023
Daniel Goldman	1291	0	0	2	2023	2025

total = nb transactions · dont OCR / OCR % = part scannée · n années = années actives · 1re/dern. année = première/dernière année de transaction



Devenir des achats à +12 mois (revente vs fermeture forcée, pour la stratégie)

Pour chaque achat (avec ticker), on suit la position : est-elle **revendue par le même membre sur le même ticker dans les 12 mois** (l'horizon de fermeture forcée de la stratégie) ? L'appariement se fait sur la **date de divulgation** — ce que la stratégie peut observer. Les achats divulgués il y a **moins de 12 mois** (après 2025-06-25) n'ont pas assez de recul pour juger : marqués *trop récents* et exclus des taux.

chambre	achats (avec ticker)	trop récents	observables	revendu ≤12m	revendu ≤12m %	fermé de force	fermé de force +12m %
house	63349	2509	60840	40355	66.3	20485	33.7
senate	6328	236	6092	2944	48.3	3148	51.7

Par sous-corpus :

sous-corpus	achats (avec ticker)	trop récents	observables	revendu ≤12m	revendu ≤12m %	fermé de force	fermé de force +12m %
House électronique	21894	1764	20130	10006	49.7	10124	50.3
House OCR	41455	745	40710	30349	74.5	10361	25.5
Sénat électronique	5188	231	4957	2358	47.6	2599	52.4
Sénat OCR	1140	5	1135	586	51.6	549	48.4

achats (avec ticker) · trop récents = <12 mois de recul depuis la divulgation (indéterminé, hors dénominateur) · observables = achats – trop récents · revendu ≤12m = une vente du même ticker divulguée dans les 12 mois · fermé de force +12m = aucune vente sous 12 mois → la stratégie clôt la position · les deux % portent sur les observables

6. Complétude vs Quiver (vérité-terrain externe)

Section clé. Quiver est un fournisseur commercial des mêmes données = notre **juge externe**. But : montrer qu'on a **au moins tout ce que Quiver a** (Quiver $\subseteq$ nous), qu'on est même **plus complet**, et que nos différences ne sont **pas des erreurs**. On procède comme un **entonnoir, de stricte croissante** : Niveau 1 → 2 → 3. Chiffres recalculés par `common/quiver_diagnosis.py`, **jamais réinjectés**.

6.1 Méthode

Chaque transaction est confrontée à Quiver par une clé normalisée, en **trois niveaux de plus en plus stricts** : **N1** a-t-on le trade ? (*sans la date*, §6.2) → **N2** le même trade à la même date ? (§6.3) → **N3** qui corrige quoi ? (§6.5).

élément	définition
univers comparé	tous les trades Quiver Filed ∈ 2014–2026 (notre fenêtre de scrape)
clé d'appariement	(bioguide, ticker normalisé, sens) — + date au Niveau 2, sans date au Niveau 1
normalisation ticker	MAJ + trim ; rejette {vide, NAN, NONE, --} ; retire PUT / CALL ; . / - → _
normalisation sens	1re lettre p/s/e → Purchase / Sale / Exchange

Périmètre : le corpus **FINAL** dédoublé cross-année (167 593 transactions uniques, cf. §1 « Construction & validation du corpus »).

Réf. : `house/quiver.py` (`norm_ticker`, `norm_sense`), `common/quiver_diagnosis.py`.

6.2 Niveau 1 — A-t-on le trade ? (sans la date)

On compare des **combinaisons** (membre, action, sens), en **ignorant volontairement la date ET le nombre** : (Khanna, AAPL, Achat) compte pour **un**, qu'il l'ait acheté 1 fois ou 50. La question est donc grossière **exprès** : « *a-t-on raté une combinaison ENTÈRE que Quiver connaît ?* » — le comptage trade par trade, c'est le Niveau 2 (§6.3).

On retrouve **88.3 % (House)** et **92.1 % (Sénat)** des combinaisons Quiver. Le **trou coté** est minuscule (753 House / 0 Sénat) — c'est une **borne haute (sans date)** ; au trade près (§6.5), seule une partie sont de vrais trous confirmés. Le reste du résidu est récupérable ou hors périmètre :

chambre	trades Quiver (fenêtre)	qu'on a	inclusion %	résidu	récupérable (OCR)	hors périmètre	trou coté (borne haute)
house	26169	23116	88.3	3053	2209	91	753
senate	4540	4180	92.1	360	7	353	0

Le *résidu se lit ainsi* : **récupérable (OCR)** = membre lu en OCR papier dont on a capté le trade mais **pas résolu le ticker** (nom lisible → récupérable, cf. note ; sinon non-coté déguisé/charabia OCR) · **hors périmètre** = « ticker » Quiver non-coté (CUSIP/fragment) + trade sous un ticker d'échange combiné (« PFE VTRS » couvre PFE) + membre de l'autre chambre polluant le cache · **trou coté (borne haute)** = combos manquants au niveau ticker (sans date) ; au trade près (§6.5), seul un sous-ensemble (NOTRE_MANQUE) sont de vrais trous confirmés.

Note : une passe de **récupération nom→ticker** (vérifiée, **hors Quiver**, appliquée à la lecture — golden intact) a rendu leur ticker à **680 trades** d'actions que l'OCR/LLM avaient laissés vides (faux négatifs, ex. NEENAH PAPER→NP, TENCENT→TCEHY). Le « récupérable OCR » restant est surtout des **non-cotés déguisés** (préférentielles, fonds) et du **charabia OCR**, non mappables.

Bilan net (au trade près) — actions cotées qu'on a et que Quiver n'a PAS vs **vrais trous** (NOTRE_MANQUE = le sous-ensemble des « trous borne haute » ci-dessus réellement absents au trade près) → on est un **sur-ensemble** de Quiver :

chambre	actions qu'on a en +	vrais trous	solde net
house	24242	918	23324
senate	2962	11	2951

6.3 Niveau 2 — Le même trade, à la même date ?

On descend au trade près. Comme un membre peut trader le même titre **plusieurs fois**, on ne demande PAS « ma date est-elle dans l'ensemble Quiver ? » : on **apparie 1-à-1** nos trades à ceux de Quiver, à l'intérieur de chaque (membre, ticker, sens). Exemple :

Khanna, AAPL, Achat — dates :
NOUS : 08-jan-2020 · 13-fév-2020 · 01-juin-2020 · 10-mars-2023
QUIVER : 08-jan-2020 · 12-fév-2020 · 10-mars-2023

Étape 1 — on retire les dates IDENTIQUES (une par une) :
08-jan ↔ 08-jan et 10-mars-2023 ↔ 10-mars-2023 → 2 « apparié exact »
(le trade 2023 s'apparie à SON 2023, jamais à un 2020)

Étape 2 — on apparie les RESTES au plus proche (plafond 90 j) :
13-fév (nous) ↔ 12-fév (Quiver) = 1 j → « apparié proche » (≤ 10 j, bruit de date)
01-juin (nous) : aucun reste Quiver à < 90 j → « NOUS-SEUL » (trade en plus)

Deux garde-fous répondent à « comment gérer qu'un membre ait plusieurs trades » : l'appariement **1-à-1 respecte les quantités** (si on a 50 trades et Quiver 40, **≥ 10 restent forcément en « nous-seul »**) ; le **plafond de 90 j** + l'**ancrage au dépôt** empêchent mécaniquement de confondre un trade 2020 et un trade 2023. Chaque trade tombe alors dans **une** catégorie :

chambre	apparié exact	apparié proche (≤10j)	candidat écart	dont même déclaration	nous-seul	quiver-seul	candidat %
house	67064	891	2711	586	37582	12539	2.5
senate	8766	0	0	0	3140	581	0.0

apparié exact = même date · apparié proche = écart des dates de TRANSACTION ≤ 10 j (bruit/convention de date Quiver, même trade) · candidat écart = paire à 10–90 j, à inspecter (§6.4) · dont même déclaration = les deux trades viennent du MÊME formulaire de déclaration (PTR) — notre disclosure ≈ Filed Quiver ≤ 10 j → même trade, donc l'écart de date est un vrai désaccord (seul signal fort) · nous-seul = Quiver n'a PAS le trade (on est plus complet) · quiver-seul = on a raté.

Pourquoi les chiffres semblent contredire le §6.2 : c'est le niveau de stricteesse. Au Niveau 1 (sans date), le trou coté (borne haute) est 753/0 ; au Niveau 2 (trade + date), on compte 37582 trades « nous-seul » — normal, on trade plus souvent que Quiver ne capte au trade près. **Les deux disent la même chose : on est plus complet.**

6.4 Les candidats d'écart de date (même déclaration)

Les **seuls** candidats honnêtes d'erreur de date = les paires issues de la **même déclaration (PTR)** (586 House / 0 Sénat). Prudence : un petit delta peut être une **convention de date Quiver**, pas notre erreur. **Le vrai contrôle des dates reste l'audit PDF (§3)**, pas Quiver. doc_id = pièce consultable :

chambre	déposant	ticker	sens	notre date	date Quiver	delta (j)	doc_id
house	Rohit Khanna	IDXX	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	VRSK	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	EW	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	AMT	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	CHTR	Sale	2022-09-08	2022-09-19	11	8219242
house	Rohit Khanna	ADBE	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	WST	Sale	2023-10-26	2023-11-06	11	8220039
house	Michael T. McCaul	GOOGL	Purchase	2018-07-26	2018-08-06	11	9113676
house	Rohit Khanna	MPWR	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	LMT	Sale	2020-04-24	2020-04-13	11	8217213
house	Rohit Khanna	DXC	Sale	2020-03-25	2020-04-05	11	8217164
house	Rohit Khanna	FTV	Sale	2023-10-26	2023-11-06	11	8220039

(Top 12 par delta croissant ; les 586 candidats sont dans quiver_validation/candidats_ecart_date_meme_depot.csv.)

6.5 Niveau 3 — Que reste-t-il à corriger ?

On a vérifié l'**existence** (§6.2) et la **date** (§6.3). Restent deux choses : les **autres champs** des trades qu'on partage avec Quiver (sens, montant), et la **liste de ce qui est vraiment à corriger**.

Autres champs — sens & montant. Pour les trades qu'on a **tous les deux** (mêmes membre + ticker + date), est-on d'accord sur le sens (achat/vente) et le montant ?

chambre	n paires	accord sens %	accord montant %
house	83311	96.6	93.7
senate	9775	99.9	99.8

on apparie les cellules (membre, ticker, date) présentes des DEUX côtés ; un désaccord = vraie erreur d'extraction, listée dans `desaccord_champ_*.csv`.

La to-do (à corriger). Un seul chiffre est **dur** — les vrais trous NOTRE_MANQUE (le résidu après tous les filtres) ; les deux autres sont des **bornes hautes** ensemblistes = des listes à revoir cas par cas dans `docs/quiver_validation/`, pas des taux d'erreur :

à corriger	House	Sénat	nature	annexe
vrais trous cotés (NOTRE_MANQUE)	918	11	DUR — vrai trou confirmé au trade près (le sous-ensemble des « trous borne haute » du §6.2 réellement absents)	notre_manque_*
lignes OCR papier (MANQUANT_PAPIER)	2523	0	borne haute — trades Quiver de déposants qu'on OCR, absents de nos clés exactes	manquant_papier_*
tickers à revoir (ECART_TICKER)	9290	190	borne haute — autre ticker ce jour-là (gonflée par la multiplicité, PAS un taux d'erreur)	ecart_ticker_*

Qui ? — les déposants derrière les vrais trous (NOTRE_MANQUE), à investiguer :

chambre	bioguide	nom	n trous
house	M001193	Thomas MacArthur	228
house	T000475	David A. Trott	172
house	F000461	Bill Flores	152
house	S000583	Lamar Smith	58
house	R000583	Thomas J. Rooney	45
house	L000579	Alan S. Lowenthal	44
house	H001051	Richard L. Hanna	28
house	C001105	Barbara J. Comstock	23
senate	C001075	William Cassidy	5
senate	M001198	Roger W Marshall	3
senate	R000608	Jacklyn S Rosen	2
senate	D000622	Tammy Duckworth	1

6.6 Annexe

Les tables **figées** `07c/07g/07h` reproduisent la même comparaison en *exact-date* (elles **sous-comptent**, cf. §6.3) ; conservées pour la lignée/régression, non re-rendues ici. Les autres figées (`07/07b/07d/07e/07f/06d`) sont des sorties historiques du pipeline.

Profil des clusters de scan (House OCR) — pourquoi le manuscrit est exclu (A = tapé droit, B = tapé tourné, C = manuscrit) :

cluster	n lignes	n docs	date plausible %	ticker %	Quiver a le trade %
A_tape_droit	5957	59	99.6	84.5	88.0
B_tape_tourne	42123	295	94.7	83.5	77.9
C_manuscrit	858	80	97.4	89.0	35.3

date plausible % / ticker % = qualité INTERNE (sans Quiver) · Quiver a le trade % = part de nos trades cotés que Quiver possède AUSSI (appariée sur membre+ticker+sens, date ou non). Sur le manuscrit (C), la qualité interne reste haute mais Quiver a le trade % s'effondre (ticker/identité mal lus, ou Quiver mince sur le papier) → faute de pouvoir le confirmer contre la vérité-terrain, on l'exclut par défaut (conservateur).

Listes actionnables complètes (ligne à ligne) → `docs/quiver_validation/` (`ecart_ticker_*`, `notre_manque_*`, `manquant_papier_*`, `desaccord_champ_*` [typé], `on_est_plus_complet_*`, `quiver_non_cote_*`, `candidats_ecart_date_meme_depot`). Hors golden.