

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Le plan — cinq étapes, une promesse



à la fin : vous saurez **ce que contient la table, comment elle a été construite, et pourquoi on peut lui faire confiance** — limites comprises.

cadre légal : STOCK Act 2012 — chaque élu du Congrès doit déclarer ses transactions boursières sous **45 jours** (*Periodic Transaction Report*, « PTR »)

Partie 1 — Ce qu'on a récupéré : la donnée brute



Où vivent ces données, et à quoi ressemblent-elles vraiment ?

La Chambre — tout part d'un index XML public


le site public du *House Clerk*
une archive par année, 2014 → 2026

on télécharge l'archive
2024FD.zip


on la dézippe → l'index annuel
2024FD.xml

un bloc <Member>
par dépôt déclaré

disclosures-clerk.house.gov (cliquable)



12 types de dépôts — le backtest n'en lit qu'un : P




P = *Periodic Transaction Report* (les « PTR ») — les **déclarations de transactions boursières**, datées, sous 45 jours.

et les 11 autres types ? on les ouvre TOUS en Partie 4 — Vérification


35 315 dépôts au total · 8 252

PTR

Un DocID, un PDF — et deux mondes



lisible — 71 %



scanné — 29 %

Le monde lisible : propre... sauf les multilignes

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/17/2018	04/17/2018	\$15,001 - \$50,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	S	04/17/2018	04/17/2018	\$15,001 - \$50,000	
	Microsoft Corporation (MSFT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$50,000	
	Spectra Energy Partners, LP Common Units representing Limited Partner Interests (SEP) [ST] une seule transaction, libellé sur 4 lignes SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

extrait réel (Hon. Bob Gibbs, OH07) — cadres ajoutés

DocID en 2... → couche texte

- le ticker est **imprimé** : (BA), le type d'actif : [ST], 2 dates + fourchette
- mais le PDF n'est **pas un tableau régulier** : le **montant** déborde sur la ligne suivante, un **libellé** court sur 4 lignes

→ on **reconstruit** chaque transaction (recollage) avant de la lire

le montant coupé à lui seul : **7 996** lignes réparées

Le monde scanné : trois formes de difficulté

un scan n'est pas du texte, c'est une **image** — et il arrive sous trois formes (pages réelles) :

[illegible]

Tapé, droit

dactylographié, lisible tel quel

[illegible]

Tapé, couché

tapé mais **tourné à 90°**

(le plus courant)

[illegible]


Manuscrit

rempli à la main, en cursif

93 261 transactions — 55,2 % du corpus

lues par OCR (Claude Vision) — détail en Partie 2 — le pipeline

Le Sénat — un portail à apprivoiser, un cas électronique propre



UNITED STATES SENATE
FINANCIAL DISCLOSURES

Return to the search tab to select another report.

Periodic Transaction Report for 03/10/2025
The Honorable James Banks (Banks, James E.)
Filed 03/10/2025 @ 12:54 PM
[Print Report](#)

The following statements were checked before filing:

- ☒ I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
- ☒ I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

Transactions (1 transaction total) 0 Self 1 Joint 0 Spouse 0 Dependent Child

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	YUMCZ	Yum! Brands Company: Yum (Louisville, KY) Description: Food	Other	Sale (Full)	\$1,001 - \$15,000	--

13 026 transactions électroniques

- 1 705 rapports « Sénateur × PTR » listés
- un gabarit de table **stable sur 13 ans** (détail en Partie 2)
- seul le contenu change : amendements (10 %), ticker « - » = non-coté, cellules parfois vides

le portail **eFD** (*electronic Financial Disclosure*) : table propre, ticker cliquable

Le Sénat papier : un formulaire unique, trois écritures

un seul modèle depuis 2014 (la grille A→L) — cliquer une vignette ouvre le vrai scan :

[illegible]

tapé, droit

3 985 transactions

[illegible]

tapé, couché — 255/373

"This Report Discloses the Past Only."

Continuity of the Florida
Office of Public Records
Division
100 Washington St.
Tallahassee, FL 32301

ANNUAL DISCLOSURE OF FINANCIAL TRANSACTIONS

RECEIVED
TALLAHASSEE OFFICE OF PUBLIC RECORDS
DIVISION

FILE NO. A-10-2-57

DATE OF REPORT

LA NUMBER

REPORT OF: (Name & Title Position)

FILE NO.

S. A. R. L. 10-2-57

Report on financial transactions of an employee within the past calendar year, including all compensation, benefits, and other financial transactions, including any outside income, investments, and other financial transactions, and any other information that may be relevant to the position. The report should be completed by the employee and submitted to the appropriate authority. The report should be completed by the employee and submitted to the appropriate authority. The report should be completed by the employee and submitted to the appropriate authority.

Transaction Type		Amount of Transaction	
Transaction Type	Amount	Transaction Date	Amount
Salary	\$10,000.00	10/01/2010	\$10,000.00
Benefits	\$1,000.00	10/01/2010	\$1,000.00
Outside Income	\$1,000.00	10/01/2010	\$1,000.00
Investments	\$1,000.00	10/01/2010	\$1,000.00
Other	\$1,000.00	10/01/2010	\$1,000.00
Total	\$14,000.00	10/01/2010	\$14,000.00
Salary	\$10,000.00	10/01/2010	\$10,000.00
Benefits	\$1,000.00	10/01/2010	\$1,000.00
Outside Income	\$1,000.00	10/01/2010	\$1,000.00
Investments	\$1,000.00	10/01/2010	\$1,000.00
Other	\$1,000.00	10/01/2010	\$1,000.00
Total	\$14,000.00	10/01/2010	\$14,000.00

10-2-57-10-2-57

manuscrit (Roberts)


[illegible]

annexe « courtier » —

format libre

cas à part : page de garde (lettre d'avocat) sans données, ignorée

Sénat papier — le piège des dates : deux natures, deux traitements



date de dépôt → métadonnée eFD

écrite de façons variées (tampon encre, en-tête imprimé)
— mais **jamais OCRisée** : on la lit sur la **fiche eFD**, donc
fiable

→ la date de la **divulgarion** (celle de l'anti-look-ahead) est la fiable — délai médian **24 j** au Sénat ; l'OCR ne touche
qu'au trade

X		10/23/20	2/3	X
	X	10/30/20	2/6	X
X		11/6/20	2/6	X
			2/7	X
			2/7	X
			2/12	X
X		10/23/20	2/13	X
	X	10/30/20	2/26	X
X		11/6/20	2/7	X

tapee MM/DD/YY (Blume) manuscrite + année |



date de transaction → OCRisée

formats variés (tapée · manuscrite · annexe) →
garde-fou : fenêtre **[dépôt -90 j, +10 j]**

Le corpus en un coup d'œil : quatre voies — et une forte concentration

169 000 transactions uniques (2014–2026), quatre sous-corpus :

Sénat OCR 2,4 %



445 déposants distincts — dont 294 avec ≥ 10 transactions

très concentré — Khanna (41 080 txns) et McCaul (27 123) pèsent à eux deux $\sim 40\%$ du corpus, et déclarent **exclusivement sur papier** (100 % OCR)


le papier n'est pas un détail : c'est la majorité du corpus

Partie 2 — Comment on la récupère : le pipeline




Comment passe-t-on de $\sim 10\,000$ documents hétérogènes à une seule table ?


Le flux de bout en bout, en une image




Le flux de bout en bout, en une image



Le flux de bout en bout, en une image




Le flux de bout en bout, en une image



L'identité : chaque nom devient un bioguide

le même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → il faut un **identifiant unique**



100 % des lignes rattachées

367 membres Chambre · 78 Sénat

```
legislators-current.yaml - référentiel congress-legislators
12608 - id:
12609   bioguide: P000197 ← l'identifiant officiel unique
      - (autres identifiants) -
12625   name:
12626     first: Nancy
12627     last: Pelosi
12628     official_full: Nancy Pelosi
12629   bio:
12630     birthday: '1940-03-26'
12631     gender: F
      - mandats successifs -
12661     state: CA
12662     district: 5
12663     party: Democrat
```

le référentiel public *congress-legislators*

Pièges réels, réparés : l'homonyme Bob Casey (C000228 → C001070) · 42 lignes d'Angie Craig sans identifiant, réparées read-time

Les deux pistes électroniques : déterministes de bout en bout

Chambre — 58 728 transactions

1. recoller les lignes coupées

2. repérer la **signature** : opération (P/S/E) + 2 **dates** + fourchette

3. **rattacher** actif et ticker imprimés à proximité

pièges déjoués — le **gabarit change en 2018** → deux **parseurs** routés par signature (sans ça, ≈ 72 ventes perdues rien qu'en 2014) · **205 PTR** déposés après le 31/12 récupérés (l'index annuel fait autorité)

Sénat — 13 026 transactions

1. **liste des dépôts** — recherche paginée, barrière CSRF


2. **page HTML par dépôt** — cache disque (re-run : zéro téléchargement)

3. **lecture des tableaux** — colonnes repérées par mots-clés

en pratique le gabarit est **stable** : les **9 mêmes colonnes** sur les 1 777 pages HTML 2014→2026 (vérifié) — le repérage par mots-clés est une **robustesse**, pas une nécessité

zéro échec silencieux : 102 dépôts sans transaction retenue, tous consignés (vides réels, amendements sans ligne, échecs tracés)

Lire le scanné Chambre : OCR Vision, et un garde-fou



1. redresser — reconnaissance d'orientation (4 candidates)
2. classer — census **2 424 scans** : 74 droits · 1 575 tournés · **775 manuscrits**
3. lire — `tool_use` forcé, JSON strict, **cache versionné** (un re-run ne re-paie rien), prompt durci sur échantillon

gating manuscrit — Quiver (fournisseur commercial des mêmes données — Partie 4) ne corrobore que **12,9 %** du manuscrit (88 % du tapé droit) : dates cursives trop incertaines → **582 écartés**, règle écrite **rejouable**, exceptions explicites (3 déposants + 33 docs curés)

93 261 lignes — très concentrées

Khanna à lui seul **44,0 %** · trio Khanna, McCaul, Harshbarger **77,1 %** — les gros déposants « 100 % papier » vus en Partie 1

Lire le papier Sénat : du formulaire au structuré

l'image .gif, déjà droite

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

actif	Apple Computer Inc
opération	Sale
date du trade	2022-03-14
détenteur	Self
fourchette	code A (1 001–15 000 \$)

3 985 lignes — 14 déposants

- même moteur Vision que la Chambre, sans redressement
 - fusion + enrichissement **en une passe** (dictionnaire de tickers mutualisé)
 - Blumenthal = 38,7 % de la piste, massivement du **non-coté**
- couverture ticker plus basse = **composition, pas défaut**

Partie 3 — Enrichir : les tickers, et le reste



Que faut-il ajouter pour qu'un backtest puisse s'en servir ?

Un ticker, un secteur, un ETF : la cascade

résoudre le ticker (cascade, source tracée) :

1. **explicite** — déjà imprimé dans la source

2. **dictionnaire** — nom vu ailleurs dans le corpus

3. **LLM filtré** « action » — jamais d'obligation/muni tickerisée

4. **récupération** validée par double preuve
— **2 540 lignes** retrouvent leur symbole

puis le secteur : yfinance (factuel) → LLM contraint
GICS (+ garde-fou `is_listed`) → overrides manuels

11 secteurs GICS → **11 ETF** *Select Sector SPDR* :

Energy→XLE · Materials→XLB ·

Industrials→XLI · Cons. Discr.→XLY · Cons.

Staples→XLP · Health Care→XLV ·

Financials→XLF · Info. Tech.→XLK · Comm.

Services→XLC · Utilities→XLU · Real

Estate→XLRE

couverture = remplissage, pas exactitude : ticker
renseigné **84,1 %** Chambre / **77,9 %** Sénat ; secteur
79,8 % / **70,4 %** — les vides sont le **non-coté légitime**
(munis, obligations, fonds privés), pas des défauts
d'extraction

La table du corpus : le contrat « 12/12 » et la clé naturelle

une clé naturelle de 7 champs :


déclarant · date du trade · actif · opération · fourchette ·
détenteur · chambre

elle exclut **délibérément** :

- le **ticker** — ajouté plus tard (enrichissement), sa présence rendrait la clé instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction


dédup non destructrice :

- les **lots réels** (même titre déclaré plusieurs fois dans un dépôt, comptes Self/Spouse/Joint) sont **préservés** (`occurrence_index`) — jamais de `drop_duplicates()` aveugle
- **dédup cross-année** : une re-divulgation (amendement, rapport annuel) ne compte qu'une fois → -1 920



12 champs métier garantis sur les 2
chambres : qui, quoi, quand (2 dates),
sens, montant, ticker, secteur, ETF, parti,
commissions

Partie 4 — Vérification : rien raté, rien inventé



*Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?*

Vérifier, c'est répondre à trois questions

1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

on ouvre les **11 autres types** de dépôts (C, H, O, T, A...) et on mesure le trou

173

actions résiduelles

2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie

80 %

du portefeuille de sortie reconstruit

3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver + stock-watchers + univers officiel — jamais réinjectés


93,5 %

des combinaisons Quiver retrouvées (Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

Complétude (1/4) — la vie déclarative d'un élu

Question 1 · Complétude



chaque étape a son dépôt — même formulaire à **sections A→J** : la **B** = les transactions ; la **A** (patrimoine) servira à *vérifier*

Complétude (2/4) — la famille « patrimoine », en une planche

cinq types, cinq rôles — les transactions (Schedule B) n'existent que dans O, T et leurs amendements :

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00001

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Bradley Adams
Status: Member
House: House
Party: REP

FILING INFORMATION
Filing Type: Annual Report
Filing Year: 2020
Filing Date: 06/15/2021
Period Covered: 01/01/2019 - 12/31/2020

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Adams • John • David	See Defined	None	\$0.00	0
First Fidelity Asset Manager (2)	Adams • John • David	See Defined	None	\$0.00	0

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0.00

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00002

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Bradley Adams
Status: Member
House: House
Party: REP

FILING INFORMATION
Filing Type: Candidate Report
Filing Year: 2020
Filing Date: 06/15/2021
Period Covered: 01/01/2019 - 12/31/2020

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Adams • John • David	See Defined	None	\$0.00	0
First Fidelity Asset Manager (2)	Adams • John • David	See Defined	None	\$0.00	0

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0.00

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00003

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Bradley Adams
Status: Member
House: House
Party: REP

FILING INFORMATION
Filing Type: New Filer Report
Filing Year: 2020
Filing Date: 06/15/2021
Period Covered: 01/01/2019 - 12/31/2020

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Adams • John • David	See Defined	None	\$0.00	0
First Fidelity Asset Manager (2)	Adams • John • David	See Defined	None	\$0.00	0

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0.00

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00004

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Bradley Adams
Status: Member
House: House
Party: REP

FILING INFORMATION
Filing Type: Termination Report
Filing Year: 2020
Filing Date: 06/15/2021
Period Covered: 01/01/2019 - 12/31/2020

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Adams • John • David	See Defined	None	\$0.00	0
First Fidelity Asset Manager (2)	Adams • John • David	See Defined	None	\$0.00	0

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0.00

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00005

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Bradley Adams
Status: Member
House: House
Party: REP

FILING INFORMATION
Filing Type: Amendment Report
Filing Year: 2020
Filing Date: 06/15/2021
Period Covered: 01/01/2019 - 12/31/2020

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Adams • John • David	See Defined	None	\$0.00	0
First Fidelity Asset Manager (2)	Adams • John • David	See Defined	None	\$0.00	0

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0.00

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

O — Annual
bilan annuel

C — Candidate
photo du candidat

H — New Filer
photo d'entrée

T — Termination
photo de sortie

A — Amendment
corrige un dépôt

4 625 · 31 % avec
txns

10 105 · 77 % jamais
élus

395 · 0 txn

392 · 28 % avec txns

2 298 · suit le corrigé

chaque vignette est cliquable → ouvre le vrai document

H et T (les « photos ») serviront à la question 2 —

Cohérence

Complétude (3/4) — ce qu'on y a trouvé : des surprises et des pièges

type O — Annual Report 2015, Nancy Pelosi

SCHEDULE B: TRANSACTIONS

Asset	Owner	Date	Tx. Type	Amount	Cap. Gains > \$200?
Hertz Global Holdings, Inc (HTZ)		07/15/2015	P	\$15,001 - \$50,000	
DESCRIPTION: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16					
Hertz Global Holdings, Inc (HTZ)		07/16/2015	P	\$100,001 - \$250,000	
DESCRIPTION: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16					

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

la **Schedule B** d'un annuel récapitule les trades de l'année — au total **57 259** transactions vivent hors des PTR ([ouvrir ce rapport](#))


piège 1 — la répétition : l'amendement re-déclare les trades de l'annuel qu'il corrige (Pelosi 2014 : le même trade **3 fois**, O+A+A) → dédoublonné par la clé naturelle

piège 2 — le blind trust (B, 23 dépôts) : la banque du *trust* liste de vraies ventes (eBay, Meta, Tesla...) — mais **pas décidées par l'élu** → jamais dans le signal


les 5 types administratifs (X, D, W, E, G) : zéro transaction, vérifié

Complétude (4/4) — que rate-t-on ? Mesuré, pas supposé


Ce que contiennent les rapports annuels & assimilés (O/H/T/A, 2014-2026)



Transactions « annuel-seul » par année couverte



Délai médian trade → divulgation (jours)



mesure : les **5 779** rapports numériques O/H/T/A des membres, réconciliés **ligne à ligne** contre nos PTR

67 % déjà dans nos PTR


le reste : surtout des fonds/ETF

actions manquantes : 173, toutes 2014-2017


et surtout : divulgation médiane 406 j après le trade (vs 27 j via PTR) → de la complétude d'archive, pas du signal — le filtre P est le bon choix

Cohérence — entrée + transactions = sortie ?

Question 2 · Cohérence



Les 1 116 actions détenues à la sortie (33 élus entrés ET sortis, 2014-2026)
Invisibles au départ-de-zéro de S3
→ récupérés en partant du patrimoine d'entrée (H)




- testé sur les **33 élus** entrés et sortis 2014-2026
- **80 % cohérent** → le flux PTR est largement complet
- **27 % détenus tout du long**, jamais tradés → invisibles au flux seul

méthode : **57 890** lignes de patrimoine (Schedule A)
extraites de 2 621 rapports — nouveau parseur · ex.
M. T. Greene : BMY & MCD à l'entrée et à la sortie —
BMY : 0 PTR

Corroboration — le mécanisme : des tuples et des ensembles


Question 3 · Corroboration

Quiver = fournisseur commercial, vérité-terrain externe — **jamais réinjecté**




comparer les deux corpus = tester l'**appartenance à un ensemble de tuples** — jamais un *merge*

NOUS (169 000) **QUIVER**



au tuple (élu, ticker, sens), fenêtre 2014-2026 — c'est le niveau 1 ; les niveaux 2 et 3 : slide suivante

Corroboration — trois niveaux de stricteesse, et qui a raison sur les dates



on serre la vis cran par cran — chaque écart reçoit un verdict :

CONCORDANT · **ÉCART DATE** · **ÉCART TICKER**

NON-COTÉ · **NOUS SEULS** · **MANQUANT**

PAPIER · **NOTRE MANQUE (vrai trou)**

N3 — sens : 96,8 % Ch. · 99,9 % Sén.

N3 — montant : 94,2 % · 99,8 %

N2, les dates : quand elles divergent au sein d'un même (élu, ticker, sens), seuls **545 candidats** issus du **même dépôt** méritent l'œil → **arbitrage au PDF source** :

le PDF montre...	exemple réel	traitement
coquille du déposant, prouvable	3031-04-30	corrigée → 2021
coquille littérale	01/35/22	transcrite telle quelle
notre OCR s'est trompé	Khanna/COST 09-31	re-lue au PDF → 08-16
désaccord Quiver	McCaul/GOOGL Δ11 j	arbitré au PDF

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

Corroboration — cinq preuves de plus, et un principe

Univers officiel

index du *House Clerk* re-téléchargé :
100 % des **8 252 PTR** traités — par-
sés, OCRisés ou écartés par règle
écrite

senate-stock-watcher

collecte indépendante, 6 231 txns
2014-2020 : **100 %** retrouvées (hors
36 échanges, comptés en 2 lignes
chez eux) — sur-ensemble strict

house-stock-watcher

miroir indépendant 2018-2026 :
99,5 % de ses lignes chez nous ; ses
manques pré-2018 → tous traités

Kadoa

agrégateur tiers : comptes par dé-
posant, triangulation automatisée
(test_crosscheck) — confirme les
déposants où notre OCR est l'**unique**
source


Golden interne

368 tables figées SHA-256 (230
Chambre + 138 Sénat), rejouées oc-
tet à octet à **zéro écart** ; + **10 scripts**
de régression au vert (chaque trans-

le principe

aucune source externe n'est **réinjec-**
tée dans les tables — elles ne servent
qu'à **mesurer** ce qu'on a


Partie 5 — Le livrable



Qu'est-ce qu'on livre, et avec quelles limites ?

Du corpus à la table de recherche : l'entonnoir

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



le principe : on ne retire que l'**avéré inutilisable** pour un backtest (pas de date, pas de prix, pas de sens, pas de montant) —

tout le doute est GARDÉ et FLAGUÉ

les flags (jamais retirés) :

- `flag_late_filing` — divulgué > 45 j : **12,2 %**
- `is_delisted` — titre sorti de cote, typé (faillite/rachat) : **2,6 %**
- `lot_size > 1` — lots multi-comptes réels : **8,8 %**
- `flag_price_caution` — symbole recyclé : **0,4 %**

134 464 × 36 : les garanties, ET les limites

data/clean/transactions_backtest_2014_2026.csv

134 464 lignes × 36 colonnes

372 membres · 57 % issu d'OCR · parti & commissions *point-in-time* · traçable ligne à ligne (doc_id)


Ce qu'on garantit

- ✓ complet : 100 % de l'univers officiel
- ✓ identifié : 100 % des lignes rattachées
- ✓ validé : Quiver + 3 sources indépendantes
- ✓ reproductible : golden octet à octet

Limites assumées

- 582 PTR manuscrits écartés (règle rejouable)
- **corroboracion externe mince avant 2017** :
87,2 % (2020-26) vs 58,7 % (2014-19)
- montants = fourchettes (milieu), pas des prix exacts
- non-coté sans ticker ni secteur (composition, pas défaut)

Ce qu'il faut retenir



100 %

de l'univers officiel
(8 252 PTR) traité

169 000

transactions uniques,
identifiées à 100 %

> 92 %


corroborés dehors —
80 % cohérents dedans

134 464

lignes × 36 colonnes,
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites

Annexe — volumes par année et par voie



totaux contrôlés = 169 000 transactions uniques ; non tracées : 1 064 antérieures à 2014 (régularisations tardives) + 317 sans date lisible

Annexe — l'index du Clerk et les deux extrêmes

l'index annuel (extrait réel, 2024FD.xml) :

```
<Member>
  <Prefix>Hon.</Prefix>
  <Last>Allen</Last>
  <First>Richard W.</First>
  <FilingType>P</FilingType>
  <StateDst>GA12</StateDst>
  <Year>2024</Year>
  <FilingDate>1/11/2024</FilingDate>
  <DocID>20024277</DocID>
</Member>
```

P = PTR; les autres types (rapports annuels, candidatures...) sont ignorés

The image shows a printed form titled "PERIODIC TRANSACTION REPORT" for the Clerk of the House of Representatives. It is for the year 2014. The filer is Richard W. Allen, a Member. The form includes a table for transactions with columns for ID, Owner Asset, Transaction Date, and Notification Amount. There is a section for "Initial Public Offerings" and a "Certification and Signature" section at the bottom where the filer certifies the accuracy of the report.

électronique 2014


doc 20000077 — ancien gabarit

The image shows a handwritten form titled "PERIODIC TRANSACTION REPORT" for the year 2020. The filer is Richard W. Allen, a Member. The form is filled out with handwritten entries, including the filing date of 1/11/2024 and the document ID 20024277. The form includes a table for transactions and a "Certification and Signature" section at the bottom where the filer certifies the accuracy of the report.

manuscrit 2020

doc 8217474 — écarté (gating)

Annexe — les sources externes, en vrai



quiverquant.com (vérité-terrain externe)...



ces sources servent à **identifier** et à **mesurer**
—
jamais réinjectées dans nos tables

le référentiel d'identité *congress-legislators* (nom
→ `bioguide_id`) : montré en Partie 2

```
..._quiver_house_cache.csv - vérité-terrain externe
1 bioguide_id, Name, Ticker, Transaction, traded, filed, disclosure_year, Trade_Size_USD, Party, District
2 V000139, Matthew Robert Van Epps, XOM, Sale, 2026-06-16, 2026-06-17, 2026, 1001.0, Republican, 7.0
3 V000139, Matthew Robert Van Epps, IBM, Sale, 2026-06-16, 2026-06-17, 2026, 1001.0, Republican, 7.0
4 V000139, Matthew Robert Van Epps, AMZN, Sale, 2026-06-16, 2026-06-17, 2026, 1001.0, Republican, 7.0
- 100 334 lignes (cache local, jamais réinjecté) -
```

... et son export brut dans notre cache

Annexe — portrait statistique du corpus



montants renseignés **99,4 %** — médiane **8 000 \$** · moyenne 58 314 \$ · max 75 M\$ · délai médian de divulgation : **27 j** Chambre / **24 j** Sénat · dates cohérentes **99,8 %**