

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

En un clin d'œil — et le plan

1. Contexte & sources
2. À quoi ressemble la donnée brute
3. Le flux de bout en bout
4. Construction de la donnée, étape par étape
5. Validation
6. Le livrable


169 000 transactions uniques

13 ans 2014 → 2026


445 élus (367 Chambre + 78 Sénat)

4 voies 2 chambres × 2 formats

Pourquoi ce projet ?



signal documenté académiquement :
Ziobrowski *et al.* 2004/2011 · Karadas 2019



délai médian réel : 27 j · 24 j

avant toute stratégie :
une couche de données **irréprochable**

Les sources : où on récupère quoi

Chambre — *House Clerk*

archive ZIP annuelle → index XML ({an}FD.xml) → PDF de chaque PTR. L'index fait **autorité** : **8 252 PTR**, 100 % traités

Sénat — *eFD*

accord + jeton CSRF → recherche paginée → page **HTML** ou **image papier** (.gif)

Référentiel d'élus

congress-legislators : nom → bioguide_id officiel, parti, commissions (repli YAML embarqué, hors-ligne)

Claude Vision

lit les scans : formulaire → transactions JSON structurées (cache versionné)

Quiver Quantitative

agrégateur commercial = **vérité-terrain** externe, **jamais réinjectée**

Sources indépendantes

senate-stock-watcher · miroir house-stock-watcher · **Kadoa** — triangulation, jamais réinjectées

deux dates par déclaration : date du **trade** · date de **divulgarion** — tout l'aval s'appuie sur la divulgation (anti-look-ahead)

Le chemin Chambre (1/4) — le site officiel

CLERK UNITED STATES HOUSE of REPRESENTATIVES

FIND YOUR REPRESENTATIVE

★ LEGISLATIVE INFORMATION MEMBER INFORMATION COMMITTEE INFORMATION DISCLOSURES ABOUT THE CLERK ★

REPORTS

- Overview
- [Download Financial Disclosure Reports](#)
- [For Members And Staff](#)
- [For Congressional Candidates](#)
- [Search](#)

FINANCIAL DISCLOSURE REPORTS

WHAT ARE FINANCIAL DISCLOSURE REPORTS?

Financial Disclosure Reports include information about the source, type, amount, or value of the incomes of Members, officers, certain employees of the U.S. House of Representatives and related offices, and candidates for the U.S. House of Representatives.

These reports are filed with the Clerk of the House as required by Title I of the Ethics in Government Act of 1978, as amended. 5 U.S.C. app. § 101 et seq.

Section 8 of the STOCK Act of 2012, as amended, requires the Clerk of the House of Representatives to provide online public access to financial disclosure reports filed by Members of Congress and candidates for Congress.

DOWNLOAD FINANCIAL DISCLOSURE REPORTS BY YEAR

★ 2008 ★ 2009 ★ 2010 ★ 2011 ★ 2012 ★ 2013 ★ 2014 ★ 2015 ★ 2016 ★ 2017 ★ 2018 ★ 2019 ★ 2020 ★ 2021 ★ 2022 ★ 2023 ★ 2024 ★ 2025 ★ 2026

FOR MEMBERS AND STAFF

Obtain instruction booklet, forms and instructions for filing:

- Financial Disclosure Online Reporting Application
- Instruction Guide for Financial Disclosure Statements and Periodic Transmittal Reports

1 archive ZIP par année

- la zone encadrée : le téléchargement **par année** (2008 → 2026)
- on prend **13 années** : 2014 → 2026
- chaque ZIP contient l'**index XML** de l'année → slide suivante
- au total, ces index listent **8 252 PTR**

disclosures-clerk.house.gov — page publique « *Financial Disclosure Reports* »
(capture réelle)

Le chemin Chambre (2/4) — dedans : l'index XML

2024FD.xml — index annuel du House Clerk

```
3  <Member>
4    <Prefix />
5    <Last>Abel</Last>
6    <First>William</First>
7    <Suffix />
8    <FilingType>C</FilingType> ← type C : pas un PTR, ignoré
9    <StateDst>TX31</StateDst>
10   <Year>2024</Year>
11   <FilingDate>5/12/2024</FilingDate>
12   <DocID>10060658</DocID>
13 </Member>
  - 2 256 dépôts dans l'index 2024 -
245 <Member>
246   <Prefix>Hon.</Prefix>
247   <Last>Allen</Last>
248   <First>Richard W.</First>
249   <Suffix />
250   <FilingType>P</FilingType> ← type P : un PTR, on le garde
251   <StateDst>GA12</StateDst>
252   <Year>2024</Year>
253   <FilingDate>1/11/2024</FilingDate>
254   <DocID>20024277</DocID> ← le n° → l'URL du PDF
255 </Member>
```

- un bloc `<Member>` par dépôt — **2 256** dans l'index 2024

- **FilingType : P = PTR**, on le garde ; les autres types (rapports annuels, candidatures...) sont ignorés

- le DocID donne l'**URL du PDF** :
.../ptr-pdfs/2024/20024277.pdf

l'index fait **autorité** :
100 % des 8 252 PTR traités

Le chemin Chambre (3/4) — le document : PTR électronique

**PERIODIC TRANSACTION REPORT**

Filing ID #20009426

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

FILER INFORMATION

Name: Hon. John A. Yarmuth
Status: Member
State/District: KY03

TRANSACTIONS

ID	Owner Asset	Transaction Type	Transaction Date	Notification Date	Amount	Cap. Gains > \$200?
	Altria Group, Inc. (MO) [ST] Filing Status: New	S (partial)	03/23/2018	04/07/2018	\$1,001 - \$15,000	☒
	Boeing Company (BA) [ST] Filing Status: New	S (partial)	03/15/2018	04/07/2018	\$1,001 - \$15,000	☒
	Micron Technology, Inc. (MU) [ST] Filing Status: New	P	03/27/2018	04/07/2018	\$1,001 - \$15,000	☐
	Wells Fargo & Company (WFC) [ST] Filing Status: New	S (partial)	03/20/2018	04/07/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

INITIAL PUBLIC OFFERINGS

☐ Yes ☒ No

CERTIFICATION AND SIGNATURE

☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.

Digitally Signed: Hon. John A. Yarmuth , 05/02/2018

58 728 transactions — 34,8 % du corpus

- un PDF **avec couche texte** : lisible machine
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification) + fourchette de montant
- lisible... mais pas si régulier : **le défi** sur la slide suivante

Le chemin Chambre (3/4) — le défi de l'extraction

TRANSACTIONS

ID	Owner Asset	Transaction Type	Transaction Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/17/2018	04/17/2018	\$15,001 - \$50,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	S	04/17/2018	04/17/2018	\$15,001 - \$50,000	☐
	Microsoft Corporation (MSFT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$50,000	☐
	Spectra Energy Partners, LP Common Units representing Limited Partner Interests (SEP) [ST] une seule transaction, libellé sur 4 lignes SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

le PDF n'est **pas** un **tableau régulier** :

- le **montant** déborde sur la ligne suivante (\$15,001 – puis \$50,000)
- le **libellé** d'un actif court sur **4 lignes**
- un découpage ligne à ligne raterait la moitié

→ on **reconstruit** chaque transaction
(recollage des lignes coupées)
avant de la lire

le montant coupé à lui seul : **7 996** lignes
réparées

extrait réel (Hon. Bob Gibbs, OH07) — cadres ajoutés

Le chemin Chambre (4/4) — le document : PTR scanné

un scan n'est pas du texte, c'est une **image** — et il arrive sous trois formes (pages réelles) :

UNITED STATES HOUSE OF REPRESENTATIVES
Partide Transaction Report

NAME: Adam Bernice Schiff OFFICE TELEPHONE: 202-225-4176

LEGISLATIVE FINANCE CENTER
2001 JUL -9 04 10-05

Member of the U.S. House of Representatives
State: CA District: 28

Office or Employee
Employing Office: _____
File an original and 1 copy

Did you purchase any shares that were obtained as a part of an initial public offering? ☐ Yes ☒ No

Please indicate whether this is an initial report or an amended report. For amendments, please provide the date of the report you are amending: ☒ Initial Report ☐ Amendment

A PTR usually shall be submitted against anyone who files more than 30 days late.

FULL ASSET NAME	TYPE OF TRANSACTION	DATE OF TRANSACTION	DATE NOTIFIED OF TRANSACTION	AMOUNT OF TRANSACTION																
				A	B	C	D	E	F	G	H	I	J	K	L					
Apple Inc	✓	7/8/20	7/8/20	✓																

Tapé, droit

dactylographié, lisible tel quel

93 261 transactions — 55,2 % du corpus

UNITED STATES HOUSE OF REPRESENTATIVES
Partide Transaction Report

NAME: George E. Holding OFFICE TELEPHONE: 202-225-3032

LEGISLATIVE FINANCE CENTER
2001 JUL -9 04 10-05

Member of the U.S. House of Representatives
State: NC District: 7

Office or Employee
Employing Office: _____
File an original and 1 copy

Did you purchase any shares that were obtained as a part of an initial public offering? ☐ Yes ☒ No

Please indicate whether this is an initial report or an amended report. For amendments, please provide the date of the report you are amending: ☒ Initial Report ☐ Amendment

A PTR usually shall be submitted against anyone who files more than 30 days late.

FULL ASSET NAME	TYPE OF TRANSACTION	DATE OF TRANSACTION	DATE NOTIFIED OF TRANSACTION	AMOUNT OF TRANSACTION															
				A	B	C	D	E	F	G	H	I	J	K	L				
Apple Inc	✓	7/8/20	7/8/20	✓															

Tapé, couché

tapé mais **tourné à 90°**

(le plus courant)

UNITED STATES HOUSE OF REPRESENTATIVES
Partide Transaction Report

NAME: George E. Holding OFFICE TELEPHONE: 202-225-3032

LEGISLATIVE FINANCE CENTER
2001 JUL -9 04 10-05

Member of the U.S. House of Representatives
State: NC District: 7

Office or Employee
Employing Office: _____
File an original and 1 copy

Did you purchase any shares that were obtained as a part of an initial public offering? ☐ Yes ☒ No

Please indicate whether this is an initial report or an amended report. For amendments, please provide the date of the report you are amending: ☒ Initial Report ☐ Amendment

A PTR usually shall be submitted against anyone who files more than 30 days late.

FULL ASSET NAME	TYPE OF TRANSACTION	DATE OF TRANSACTION	DATE NOTIFIED OF TRANSACTION	AMOUNT OF TRANSACTION															
				A	B	C	D	E	F	G	H	I	J	K	L				
Apple Inc	✓	7/8/20	7/8/20	✓															

Manuscrit

rempli à la main, en cursif

lues par OCR (Claude Vision) — *détail : étape 5*

Le chemin Sénat (1/4) — le site eFD et sa barrière



United States Senate Financial Disclosures (eFD)

Public disclosure of a government official's personal financial interests is a key component to an effective code of conduct. For more information on filing, including who files, and the types of reports filed, see the [United States Senate's Select Committee on Ethics website](#).

Select Reports are Available

This site includes financial disclosure reports for Senators, former Senators and Senate candidates filed from 2012 to present. Senator reports are available for six years from the date a Senator ceases to be a Member of Congress. Candidate reports are available for one year after the individual is no longer a candidate.

Additional Reports

All financial disclosure reports are available through the Office of the Secretary of the Senate kiosk:

Office of Public Records
144 Hart Senate Office Building
Washington, D.C. 20510-7116
phone (202) 224-0322

Q Get Access

You must agree to the following to be able to search reports.

Title 1 of the Ethics in Government Act of 1978, as amended, 5 U.S.C. app. § 105(c), states that:

1. It shall be unlawful for any person to obtain or use a report:
 1. for any unlawful purpose;
 2. for any commercial purpose, other than by news and communications media for dissemination to the general public;
 3. for determining or establishing the credit rating of any individual; or
 4. for use, directly or indirectly, in the solicitation of money for any political, charitable, or other purpose.
2. The Attorney General may bring a civil action against any person who obtains or uses a report for any purpose prohibited in paragraph (1) of this subsection. The court in which such action is brought may assess against such person a penalty in any amount not to exceed \$10,000. Such remedy shall be in addition to any other remedy available under statutory or common law.

☐ I understand the prohibitions on obtaining and use of financial disclosure reports.

la barrière : accord + jeton CSRF

- la case encadrée : l'**accord obligatoire** avant toute recherche
- notre collecteur l'accepte et récupère le **jeton de session**
- ensuite seulement : on peut **chercher** (slide suivante)

efdsearch.senate.gov — la page d'accès (capture réelle)

Le chemin Sénat (2/4) — la liste des rapports

 UNITED STATES SENATE
FINANCIAL DISCLOSURES



① Note Reports will display in the format they were filed: either **electronically (text)** or on **paper (images)**.



Search Results
Reports will open in a new tab or window.

Filter list by Showing 1 to 25 of 1,705 entries

First Name (Middle)	Last Name (Suffix)	Office (Filer Type)	Report Type	Date Received/Filed
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 06/26/2025	06/26/2025
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 08/10/2025	08/10/2025
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 03/10/2025	03/10/2025
John A	Barrasso	Barrasso, John (Senator)	Periodic Transaction Report for 05/24/2018	05/24/2018
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 07/12/2021	07/12/2021
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 05/16/2023	05/16/2023
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 02/07/2017	02/07/2017
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 04/02/2019	04/02/2019
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 09/02/2020	09/02/2020
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 10/18/2022	10/18/2022

une liste, un lien par dépôt

- chaque ligne = un rapport à cliquer

- un dépôt s'ouvre dans son format d'origine :

« Reports will display... either **electronically (text)** or on **paper (images)** »

→ soit une **page HTML**, soit un **PDF** scanné (les deux slides suivantes)

résultats d'une recherche « Sénateur × PTR » (page réelle, 1 705 rapports)

Le chemin Sénat (3/4) — le clic ouvre... une page HTML

 UNITED STATES SENATE
FINANCIAL DISCLOSURES

Return to the search tab to select another report.

Periodic Transaction Report for 03/10/2025
The Honorable James Banks (Banks, James E.)
Filed 03/10/2025 @ 12:54 PM

Print Report

The following statements were checked before filing:

☐ I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
☐ I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

 **Transactions** (1 transaction total) 0 Self 1 Joint 0 Spouse 0 Dependent Child

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	YUM	Yum! Brands Company: Yum (Louisville, KY) Description: Food	Other	Sale (Full)	\$1,001 - \$15,000	--

cas électronique — 13 026 · 7,7 %

- dépôt **électronique** → une **page web** (texte)
- table propre, ticker **cliquable** — mais intitulés et ordre des colonnes **varient** d'une déclaration à l'autre
- type d'actif et détenteur (Self / Joint / Spouse) déclarés


Le chemin Sénat (4/4) — ...ou un PDF scanné

This Report Should Be Filed With:		PERIODIC DISCLOSURE OF FINANCIAL TRANSACTIONS		(Time/Date)	
Secretary of the Senate Office of Public Records Hart Building, Suite 232 Washington, DC 20510					
Reporting Individual's Name Richard Blumenthal		Senate Office / Agency in Which Employed United States Senate		Page No. 1	
Report any purchase, sale, or exchange by you, your spouse, or dependent child within 30 days of receiving written notification of such transaction. Report any stocks, bonds, commodity futures, and other securities when the amount of the transaction exceeded \$1,000. Include transactions that resulted in a loss. Do not report a transaction involving an exempt investment fund, any real property, or a transaction between you, your spouse, or dependent child. Please clarify which two assets are involved in any reportable exchange. In no event may this disclosure be filed more than 45 days after such transaction.		Amount of Transaction (x)			
Transaction Type (x)		Transaction Date (Mo., Day, Yr.)			
Purchase	Sale	Exchange	\$1,001 - \$15,000	\$15,001 - \$50,000	\$50,001 - \$100,000
			\$100,001 - \$250,000	\$250,001 - \$500,000	\$500,001 - \$1,000,000
			\$1,000,001 - \$5,000,000	\$5,000,001 - \$25,000,000	\$25,000,001 - \$50,000,000
			Over \$50,000,000		
Identification of Assets					
Example: (S) IBM Corp (stock) NYSE (DC) Microsoft (stock) (J) NASDAQ/OTC	IBM Corp (stock) NYSE		2/7/11X		
(S) 3M's Partners LLC					
(S) Four Winds LLC	X		11/4/25	X	
(S) ELCM2 LLC	X		11/13/25	X	
(S) Peter L. Malin Family 9 LLC - 3M's Partners LLC					
(S) Four Winds LLC	X		11/4/25	X	
(S) ELCM2 LLC	X		11/13/25	X	

cas papier — 3 985 · 2,4 %

- dépôt **papier** → une **image** scannée (.gif), **déjà droite** (pas de redressement)
- grille de **montants en colonnes cochées** (A→L), propriétaire en préfixe (S)/(DC)/(J)
- **14 déposants** sur 13 ans, massivement du **non-coté** (obligations municipales) — Blumenthal en tête
- aucun symbole boursier imprimé → ticker à ré-associer

Les autres sources, en vrai



Congress Trading Dashboard

The Stock Trading on Congressional Knowledge Act requires U.S. Senators and U.S. Representatives to publicly file and disclose any financial transaction within 45 days of its occurrence. We download those disclosures, parse them for stock trades, fetch the stock's performance in the time following the transaction, and calculate each politician's cumulative return from their trades.

Politician Search
View Congress trading activity by:

Stock Search
View trading activity in Congress involving:

New:
Track the returns and profits of stock portfolios held by U.S. politicians in Congress on our Politician Stock Portfolio Leaderboard. Available to Quiver Premium subscribers.
[View Politician Stock Portfolio Leaderboard](#)

Recent Trades - U.S. Congress
Click on a trade for more details
Estimated excess return of the underlying stock since the transaction.

Stock	Transaction	Politician	Filed	Traded	Description	
CDI CROWN CASTLE INC. CD. IT	Sale \$1,001 - \$15,000	Robert J. Wilman House / R	Jul 18, 2026	Jun 22, 2026	-	4.16%
ALLOCAUT ALPHA FUND L. IT	Purchase \$15,001 - \$50,000	Scott H. Peters House / D	Jul 18, 2026	Jun 24, 2026	POOLED INVESTMENT FU.	-

quiverquant.com (vérité-terrain externe)...



```
legislators-current.yaml - référentiel congress-legislators

12608 - id:
12609   bioguide: P000197 + l'identifiant officiel unique
      - (autres identifiants) -
12625   name:
12626     first: Nancy
12627     last: Pelosi
12628     official_full: Nancy Pelosi
12629   bio:
12630     birthday: '1940-03-26'
12631     gender: F
      - mandats successifs -
12661   state: CA
12662   district: 5
12663   party: Democrat
```

le référentiel d'identité *congress-legislators* (nom
→ bioguide_id, parti, mandats)

ces sources servent à **identifier** et à **mesurer**
—
jamais réinjectées dans nos tables




```
_quiver_house_cache.csv - vérité-terrain externe

1 bioguide_id,Name,Ticker,Transaction,traded,filed,dislosure_year,Trade_Size_USD,Party,District
2 V000139,Matthew Robert Van Epps,XOM,Sale,2026-06-16,2026-06-17,2026,1001.0,Republican,7.0
3 V000139,Matthew Robert Van Epps,IBM,Sale,2026-06-16,2026-06-17,2026,1001.0,Republican,7.0
4 V000139,Matthew Robert Van Epps,AMZN,Sale,2026-06-16,2026-06-17,2026,1001.0,Republican,7.0
- 100 334 lignes (cache local, jamais réinjecté) -
```


... et son export brut dans notre cache

Le flux de bout en bout



Étape 1 — d'abord, savoir qui a déclaré (identité)

le même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → il faut un **identifiant unique**




100 % des lignes rattachées

367 membres Chambre · **78** Sénat


Pièges réels, réparés :

- homonymie : le sénateur Bob Casey rattaché à tort à C000228 (un représentant texan) → C001070
- **42 lignes** d'Angie Craig sans identifiant → réparées (read-time, figé intact)
- 1 seule déclaration **exclue** : une collaboratrice de commission (pas un élu — vérifié au PDF)

Étape 2 — trier : électronique ou scanné ?



la composition qui en résulte (169 000 transactions uniques) :



plus de la moitié du corpus vient de **scans** — le papier n'est pas un détail, c'est la majorité

Étape 3 — la piste électronique de la Chambre

58 728 transactions uniques

zéro échec silencieux : tout PDF sans ligne est consigné
(05_parse_failures) — 102 « nothing to report » réels

le PDF ne donne pas un tableau régulier : une transaction s'étale sur **plusieurs lignes**, montants coupés

1. **recoller** les lignes coupées (`_join_split_lines`)

2. **repérer la signature** de chaque transaction : opération (P/S/E) + **2 dates** + fourchette

3. **rattacher** actif et ticker imprimés à proximité

Pièges déjoués


- le **gabarit change en 2018** (casse, codes, mise en page) → **deux parseurs** routés par signature, union dédoublée ; sans ça, **≈ 72 ventes** perdues rien qu'en 2014 (biais vendeur)
- **205 PTR** déposés après le 31/12 étaient perdus → l'index annuel du Clerk fait désormais **autorité**

dans la source :

Amazon.com, Inc. - Common Stock
(AMZN) [ST] · Purchase · 03/16/2018 ·
\$1,001-\$15,000

Étape 4 — la piste électronique du Sénat


13 026 transactions uniques



pourquoi « flou » ? **l'intitulé et l'ordre des colonnes varient** d'une déclaration à l'autre — on retient la colonne dont l'en-tête contient les bons mots-clés, seule approche robuste

identité, ticker et déduplication : délégués au tronc commun — même clé naturelle que la Chambre

Étape 5 — la piste scannée de la Chambre (OCR Vision)



1. redresser — reconnaissance d'orientation (4 candidates)
2. classer — census **2 424 scans** : 74 droits · 1 575 tournés · **775 manuscrits**
3. lire — `tool_use` forcé, JSON strict, **cache versionné** (un re-run ne re-paie rien), prompt durci sur échantillon

gating manuscrit — Quiver ne corrobore que **12,9 %** du manuscrit (88 % du tapé droit) : dates cursives trop incertaines → **582 écartés**, règle écrite **rejouable**, exceptions explicites (3 déposants + 33 docs curés)

93 261 lignes — très concentrées

Khanna à lui seul **44,0 %** · trio Khanna, McCaul, Harshbarger **77,1 %** — de gros déposants qui déclarent **exclusivement sur papier**

Étape 6 — la piste papier du Sénat

3 985 lignes — 14 déposants

- images **déjà droites** : pas de redressement, même moteur Vision
- particularité : fusion + enrichissement **en une passe sur tout le corpus** (peu de données par année → le dictionnaire de tickers est mutualisé entre les années)
- Blumenthal = **38,7 %** de la piste ; massivement du **non-coté** (munis, produits structurés) → couverture ticker plus basse = **composition, pas défaut d'extraction**

ce que rend l'OCR (extrait réel — John Boozman) :

```
{ "member": "JOHN BOOZMAN",  
  "status": "ok", "n_pages": 2,  
  "transactions": [  
    { "asset_description":  
      "Apple Computer Inc",  
      "transaction_type": "Sale",  
      "owner": "Self",  
      "transaction_date": "2022-03-14",  
      "amount_code": "A" }, ... ] }
```

Étape 7 — un secteur pour chaque ticker : GICS → ETF SPDR

résoudre le ticker (cascade, source tracée) :

1. **explicite** — déjà imprimé dans la source

2. **dictionnaire** — nom vu ailleurs dans le corpus

3. **LLM filtré** « action » — jamais d'obligation/muni tickerisée

4. **récupération** validée par double preuve
— **2 540 lignes** retrouvent leur symbole

puis le secteur : yfinance (factuel) → LLM contraint
GICS (+ garde-fou `is_listed`) → overrides manuels

11 secteurs GICS → **11 ETF *Select Sector SPDR*** :

Energy→XLE · Materials→XLB ·

Industrials→XLI · Cons. Discr.→XLY · Cons.

Staples→XLP · Health Care→XLV ·

Financials→XLF · Info. Tech.→XLK · Comm.

Services→XLC · Utilities→XLU · Real

Estate→XLRE

couverture = remplissage, pas exactitude : ticker
renseigné **84,1 %** Chambre / **77,9 %** Sénat ; secteur
79,8 % / 70,4 % — les vides sont le **non-coté légitime**
(munis, obligations, fonds privés), pas des défauts
d'extraction

Étape 8 — la table finale : le contrat « 12/12 »

une clé naturelle de 7 champs :

déclarant · date du trade · actif · opération · fourchette ·
détenteur · chambre

elle exclut **délibérément** :

- le **ticker** — ajouté plus tard (enrichissement), sa présence rendrait la clé instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction

dédup non destructrice :

- les **lots réels** (même titre déclaré plusieurs fois dans un dépôt, comptes Self/Spouse/Joint) sont **préservés** (`occurrence_index`) — jamais de `drop_duplicates()` aveugle
- **dédup cross-année** : une re-divulgation (amendement, rapport annuel) ne compte qu'une fois → -1 920

170 920 lignes brutes
(26 fichiers FINAL, 28 colonnes)

dédup cross-année -1 920

169 000 transactions uniques

12 champs métier garantis sur les 2
chambres : qui, quoi, quand (2 dates),
sens, montant, ticker, secteur, ETF, parti,
commissions


Validation (1/3) — Quiver, niveau 1 : a-t-on tout ?

la méthode : chaque trade
confronté à Quiver par clé
normalisée (élu × ticker × sens), en
3 niveaux de stricte — existence
→ date → champs

trades Quiver retrouvés
93,5 % Chambre · **92,1 %**
Sénat

sur-ensemble de Quiver
+26 524 combinaisons en plus
contre **38** trous inverses

vrais trous confirmés
27 Chambre · **11** Sénat



Validation (2/3) — les dates : qui a raison ?

niveau 2 — appariement **1-à-1** des dates, au sein de chaque (élu, ticker, sens) :

Khanna, AAPL, Achat :

NOUS : 08-jan · 13-fév · 01-juin

QUIVER : 08-jan · 12-fév

1. dates **identiques** retirées une à une (08-jan ↔ 08-jan)

2. restes appariés au plus proche : 13-fév ↔ 12-fév = *bruit* (≤ 10 j)

3. 01-juin sans vis-à-vis → **nous-seul** (on est plus complet)

→ seuls **545 candidats** issus du **même dépôt** méritent l'œil → **arbitrage au PDF source** :

**le PDF
montre...**

exemple réel

traitement

coquille du déposant,
prouvable

3031-04-30

corrigée → 2021

coquille littérale

le PTR imprime
01/35/22

**transcrite telle
quelle**

notre OCR s'est
trompé

Khanna/COST
09-31

re-lue au PDF →
08-16

désaccord Quiver

McCaul/GOOGL
 $\Delta 11$ j

arbitré au PDF
(doc 9113676)

niveau 3 — sur les trades partagés, accord des **autres
champs** :

sens : 96,8 % Chambre · 99,9 % Sénat

montant : 94,2 % · 99,8 %

Validation (3/3) — les preuves indépendantes de Quiver

Univers officiel

index du *House Clerk* re-téléchargé :
100 % des **8 252 PTR** traités — par-
sés, OCRisés ou écartés par règle
écrite

senate-stock-watcher

collecte indépendante, 6 231 txns
2014-2020 : **100 %** retrouvées chez
nous — on est un sur-ensemble strict

house-stock-watcher

miroir indépendant 2018-2026 :
99,5 % de ses lignes chez nous ; ses
manques pré-2018 → tous traités

Kadoa

agrégateur tiers : comptes par dé-
posant, triangulation automatisée
(test_crosscheck) — confirme les
déposants où notre OCR est l'**unique**
source

Golden interne


368 tables figées SHA-256, rejouées
octet à octet à **zéro écart** ; invariants
recomptés (digital + OCR = FINAL,
identité 100 %)

le principe

aucune source externe n'est **réinjec-
tée** dans les tables — elles ne servent
qu'à **mesurer** ce qu'on a

Du corpus à la table de recherche : l'entonnoir

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



le principe : on ne retire que l'**avéré inutilisable** pour un backtest (pas de date, pas de prix, pas de sens, pas de montant) —

tout le doute est GARDÉ et FLAGUÉ

les flags (jamais retirés) :

- `flag_late_filing` — divulgué > 45 j : **12,2 %**
- `is_delisted` — titre sorti de cote, typé (faillite/rachat) : **2,6 %**
- `lot_size > 1` — lots multi-comptes réels : **8,8 %**
- `flag_price_caution` — symbole recyclé : **0,4 %**

`data/clean/transactions_backtest_2014_2026.csv`

134 464 lignes × 36 colonnes

372 membres · 57 % issu d'OCR · parti & commissions *point-in-time* · traçable ligne à ligne (`doc_id`)


Ce qu'on garantit

- ✓ complet : 100 % de l'univers officiel
- ✓ identifié : 100 % des lignes rattachées
- ✓ validé : Quiver + 3 sources indépendantes
- ✓ reproductible : golden octet à octet

Limites assumées

- 582 PTR manuscrits écartés (règle rejouable)
- corroboration externe plus faible avant 2017
- montants = fourchettes (milieu), pas des prix exacts

Annexe — volumes par année et par voie



totaux contrôlés = 169 000 transactions uniques ; 1 381 transactions antérieures à 2014 (régularisations tardives) non tracées

Annexe — l'index du Clerk et les deux extrêmes

l'index annuel (extrait réel, 2024FD.xml) :

```
<Member>
  <Prefix>Hon.</Prefix>
  <Last>Allen</Last>
  <First>Richard W.</First>
  <FilingType>P</FilingType>
  <StateDst>GA12</StateDst>
  <Year>2024</Year>
  <FilingDate>1/11/2024</FilingDate>
  <DocID>20024277</DocID>
</Member>
```

P = PTR; les autres types (rapports annuels, candidatures...) sont ignorés

The image shows a 'PERIODIC TRANSACTION REPORT' form for the year 2024. The filer is Richard W. Allen, a Member of the House of Representatives from Georgia's 12th district. The report is filed electronically on 1/11/2024. The form includes a table for transactions with columns for ID, Owner Asset, Transaction Date, and Notification Amount. The filer has checked the box indicating that the report is true, complete, and correct to the best of their knowledge.

électronique 2014

doc 20000077 — ancien gabarit

The image shows a handwritten 'PERIODIC TRANSACTION REPORT' form for the year 2024. The filer is Richard W. Allen, a Member of the House of Representatives from Georgia's 12th district. The report is filed on 1/11/2024. The form includes a table for transactions with columns for ID, Owner Asset, Transaction Date, and Notification Amount. The filer has checked the box indicating that the report is true, complete, and correct to the best of their knowledge.

manuscrit 2020

doc 8217474 — écarté (gating)