

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

En un clin d'œil — et le plan

1. Contexte & sources
2. À quoi ressemble la donnée brute
3. Le flux de bout en bout
4. Construction de la donnée, étape par étape
5. Validation
6. Le livrable


169 000 transactions uniques

13 ans 2014 → 2026


445 élus (367 Chambre + 78 Sénat)

4 voies 2 chambres × 2 formats

Pourquoi ce projet ?



signal documenté académiquement :
Ziobrowski *et al.* 2004/2011 · Karadas 2019



délai médian réel : 27 j · 24 j

avant toute stratégie :
une couche de données **irréprochable**

Les sources : où on récupère quoi

Chambre — *House Clerk*

archive ZIP annuelle → index XML
(`{an}FD.xml`) → PDF de chaque
PTR. L'index fait **autorité** : **8 252**
PTR, 100 % traités

Sénat — *eFD*

accord + jeton CSRF → recherche
paginée → page **HTML** ou **image pa-**
pier (.gif)

Référentiel d'élus

congress-legislators : nom →
`bioguide_id` officiel, parti, com-
missions (repli YAML embarqué,
hors-ligne)

Claude Vision

lit les scans : formulaire → transac-
tions JSON structurées (cache ver-
sionné)

Quiver Quantitative

agrégateur commercial = **vérité-**
terrain externe, **jamais réinjectée**

Sources indépendantes

senate-stock-watcher · miroir house-
stock-watcher · **Kadoa** — triangula-
tion, jamais réinjectées

deux dates par déclaration : date du **trade** · date de **divulgarion** — tout l'aval s'appuie sur la
divulgarion (anti-look-ahead)

À quoi ça ressemble (1/4) — Chambre, PTR électronique

 **PERIODIC TRANSACTION REPORT**

Clerk of the House of Representatives • Legislative Resource Center • BB1 Cannon Building • Washington, DC 20515

R INFORMATION

1 Hon. Mark Alford
a Member
District: MO04

SACTIONS

Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$2007
Amazon.com, Inc. - Common Stock (AMZN) [ST] FILING STATUS: New SECURITIES OR: Petram Investments DISCLOSURE: The full transaction included the following sales: T - 37,426 shares sold @ \$27.645/share BHK/R - 3 shares sold @ \$493.42/share SPY - 8,318 shares sold @ \$670.024/share DIA - 8,426 shares sold @ \$470.982/share SPYD - 37,383 shares sold @ \$46.04/share AMZN - 25 shares sold @ \$209.40/share AAPL - 20,313 shares sold @ \$253.45/share QQQ - 4,305 shares sold @ \$601.68/share PFTL - 9,021 shares sold @ \$47.735/share	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☒
Apple Inc. - Common Stock (AAPL) [ST] FILING STATUS: New SECURITIES OR: Petram Investments DISCLOSURE: The full transaction included the following sales: T - 37,426 shares sold @ \$27.645/share BHK/R - 3 shares sold @ \$493.42/share SPY - 8,318 shares sold @ \$670.024/share DIA - 8,426 shares sold @ \$470.982/share SPYD - 37,383 shares sold @ \$46.04/share AMZN - 25 shares sold @ \$209.40/share AAPL - 20,313 shares sold @ \$253.45/share QQQ - 4,305 shares sold @ \$601.68/share PFTL - 9,021 shares sold @ \$47.735/share	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☒
AT&T Inc. (T) [ST] FILING STATUS: New SECURITIES OR: Petram Investments DISCLOSURE: The full transaction included the following sales: T - 37,426 shares sold @ \$27.645/share BHK/R - 3 shares sold @ \$493.42/share SPY - 8,318 shares sold @ \$670.024/share DIA - 8,426 shares sold @ \$470.982/share SPYD - 37,383 shares sold @ \$46.04/share AMZN - 25 shares sold @ \$209.40/share AAPL - 20,313 shares sold @ \$253.45/share QQQ - 4,305 shares sold @ \$601.68/share PFTL - 9,021 shares sold @ \$47.735/share	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☒
Berkshire Hathaway Inc. New Common Stock (BHK.B) [ST] FILING STATUS: New	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☐

58 728 transactions — 34,8 % du corpus

- un PDF avec **couche texte** : lisible machine
- le ticker est imprimé **entre parenthèses** : (AMZN), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification) + fourchette de montant
- le **défi** : une transaction s'étale sur **plusieurs lignes** (descriptions, montants coupés)

À quoi ça ressemble (2/4) — Chambre, PTR scanné

[illegible]

scan tapé, **couché**, tampon *HAND DELIVERED* (Anna P. Luna)

93 261 transactions — 55,2 % du corpus

- une **image**, pas de texte : formulaire à **cases cochées** (type, fourchette A→K)
- souvent **tourné à 90°**, déposé à la main
- **le cas extrême** : le **manuscrit cursif** →

[illegible]

écarté — règle rejouable (→ étape 5)

À quoi ça ressemble (3/4) — Sénat, déclaration eFD

 UNITED STATES SENATE
FINANCIAL DISCLOSURES

Return to the search tab to select another report.

Periodic Transaction Report for 03/10/2025
The Honorable James Banks (Banks, James E.)
Filed 03/10/2025 @ 12:54 PM

Print Report

The following statements were checked before filing:

☐ I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
☐ I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

 **Transactions** (1 transaction total) 0 Self 1 Joint 0 Spouse 0 Dependent Child

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	YUM	Yum! Brands Company: Yum (Louisville, KY) Description: Food	Other	Sale (Full)	\$1,001 - \$15,000	--

13 026 transactions — 7,7 %

- pas de PDF : une **page web** derrière la barrière CSRF
- table propre, ticker **cliquable** — mais intitulés et ordre des colonnes **varient** d'une déclaration à l'autre
- type d'actif et détenteur (Self / Joint / Spouse) déclarés


À quoi ça ressemble (4/4) — Sénat, papier scanné

This Report Should Be Filed With:		PERIODIC DISCLOSURE OF FINANCIAL TRANSACTIONS		(Time/Date)												
Secretary of the Senate Office of Public Records Hart Building, Suite 232 Washington, DC 20510																
Reporting Individual's Name Richard Blumenthal		Senate Office / Agency in Which Employed United States Senate		Page No. 1												
Report any purchase, sale, or exchange by you, your spouse, or dependent child within 30 days of receiving written notification of such transaction. Report any stocks, bonds, commodity futures, and other securities when the amount of the transaction exceeded \$1,000. Include transactions that resulted in a loss. Do not report a transaction involving an exempt investment fund, any real property, or a transaction between you, your spouse, or dependent child. Please clearly identify two assets are involved in any reportable exchange. In no event may this disclosure be filed more than 45 days after such transaction.		Transaction Type (X)		Amount of Transaction (X)												
Identification of Assets		Purchase	Sale	Exchange	Transaction Date (Mo., Day, Yr.)	\$1,001 - \$15,000	\$15,001 - \$50,000	\$50,001 - \$100,000	\$100,001 - \$250,000	\$250,001 - \$500,000	\$500,001 - \$1,000,000	Over \$1,000,000***	\$1,000,001 - \$5,000,000	\$5,000,001 - \$25,000,000	\$25,000,001 - \$50,000,000	Over \$50,000,000
Example: (S) Spouse (DC) Dependent Child (J) Joint		IBM Corp (ibm) NYSE		X	2/17/1X		X									
		(DC) Microsoft (stock) NASDAQ:QTC		X	2/27/1X			X	E	X	A	M	P	L	E	
1 (S) 3M's Partners LLC																
2 (S) Four Winds LLC		X			11/4/25		X									
3 (S) ELCM2 LLC			X		11/13/25	X										
4																
5 (S) Peter L. Malin Family 9 LLC - 3M's Partners LLC																
6 (S) Four Winds LLC		X			11/4/25		X									
7 (S) ELCM2 LLC			X		11/13/25	X										
8																

3 985 transactions — 2,4 % du corpus


- images .gif servies hors barrière — **déjà droites** (pas de redressement)
- grille de **montants en colonnes cochées** (A→L), propriétaire en préfixe (S)/(DC)/(J)
- **14 déposants** sur 13 ans, massivement du **non-coté** (obligations municipales) — Blumenthal en tête
- aucun symbole boursier imprimé → ticker à ré-associer

Le flux de bout en bout



Étape 1 — d'abord, savoir qui a déclaré (identité)

le même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → il faut un **identifiant unique**




100 % des lignes rattachées

367 membres Chambre · **78** Sénat


Pièges réels, réparés :

- homonymie : le sénateur Bob Casey rattaché à tort à C000228 (un représentant texan) → C001070
- **42 lignes** d'Angie Craig sans identifiant → réparées (read-time, figé intact)
- 1 seule déclaration **exclue** : une collaboratrice de commission (pas un élu — vérifié au PDF)

Étape 2 — trier : électronique ou scanné ?



la composition qui en résulte (169 000 transactions uniques) :



plus de la moitié du corpus vient de **scans** — le papier n'est pas un détail, c'est la majorité

Étape 3 — la piste électronique de la Chambre

58 728 transactions uniques

zéro échec silencieux : tout PDF sans ligne est consigné
(05_parse_failures) — 102 « nothing to report » réels

le PDF ne donne pas un tableau régulier : une transaction s'étale sur **plusieurs lignes**, montants coupés

1. **recoller** les lignes coupées (`_join_split_lines`)

2. **repérer la signature** de chaque transaction : opération (P/S/E) + **2 dates** + fourchette

3. **rattacher** actif et ticker imprimés à proximité

Pièges déjoués


- le **gabarit change en 2018** (casse, codes, mise en page) → **deux parseurs** routés par signature, union dédoublée ; sans ça, **≈ 72 ventes** perdues rien qu'en 2014 (biais vendeur)
- **205 PTR** déposés après le 31/12 étaient perdus → l'index annuel du Clerk fait désormais **autorité**

dans la source :

Amazon.com, Inc. - Common Stock
(AMZN) [ST] · Purchase · 03/16/2018 ·
\$1,001-\$15,000

Étape 4 — la piste électronique du Sénat


13 026 transactions uniques



pourquoi « flou » ? **l'intitulé et l'ordre des colonnes varient** d'une déclaration à l'autre — on retient la colonne dont l'en-tête contient les bons mots-clés, seule approche robuste

identité, ticker et déduplication : délégués au tronc commun — même clé naturelle que la Chambre

Étape 5 — la piste scannée de la Chambre (OCR Vision)



1. redresser — reconnaissance d'orientation (4 candidates)
2. classer — census **2 424 scans** : 74 droits · 1 575 tournés · **775 manuscrits**
3. lire — `tool_use` forcé, JSON strict, **cache versionné** (un re-run ne re-paie rien), prompt durci sur échantillon

gating manuscrit — Quiver ne corrobore que **12,9 %** du manuscrit (88 % du tapé droit) : dates cursives trop incertaines → **582 écartés**, règle écrite **rejouable**, exceptions explicites (3 déposants + 33 docs curés)

93 261 lignes — très concentrées

Khanna à lui seul **44,0 %** · trio Khanna, McCaul, Harshbarger **77,1 %** — de gros déposants qui déclarent **exclusivement sur papier**

Étape 6 — la piste papier du Sénat

3 985 lignes — 14 déposants

- images **déjà droites** : pas de redressement, même moteur Vision
- particularité : fusion + enrichissement **en une passe sur tout le corpus** (peu de données par année → le dictionnaire de tickers est mutualisé entre les années)
- Blumenthal = **38,7 %** de la piste ; massivement du **non-coté** (munis, produits structurés) → couverture ticker plus basse = **composition, pas défaut d'extraction**

ce que rend l'OCR (extrait réel — John Boozman) :

```
{ "member": "JOHN BOOZMAN",  
  "status": "ok", "n_pages": 2,  
  "transactions": [  
    { "asset_description":  
      "Apple Computer Inc",  
      "transaction_type": "Sale",  
      "owner": "Self",  
      "transaction_date": "2022-03-14",  
      "amount_code": "A" }, ... ] }
```

Étape 7 — un secteur pour chaque ticker : GICS → ETF SPDR

résoudre le ticker (cascade, source tracée) :

1. **explicite** — déjà imprimé dans la source

2. **dictionnaire** — nom vu ailleurs dans le corpus

3. **LLM filtré** « action » — jamais d'obligation/muni tickerisée

4. **récupération** validée par double preuve
— **2 540 lignes** retrouvent leur symbole

puis le secteur : yfinance (factuel) → LLM contraint
GICS (+ garde-fou `is_listed`) → overrides manuels

11 secteurs GICS → **11 ETF *Select Sector SPDR*** :

Energy→XLE · Materials→XLB ·

Industrials→XLI · Cons. Discr.→XLY · Cons.

Staples→XLP · Health Care→XLV ·

Financials→XLF · Info. Tech.→XLK · Comm.

Services→XLC · Utilities→XLU · Real

Estate→XLRE

couverture = remplissage, pas exactitude : ticker
renseigné **84,1 %** Chambre / **77,9 %** Sénat ; secteur
79,8 % / 70,4 % — les vides sont le **non-coté légitime**
(munis, obligations, fonds privés), pas des défauts
d'extraction

Étape 8 — la table finale : le contrat « 12/12 »

une clé naturelle de 7 champs :


déclarant · date du trade · actif · opération · fourchette ·
détenteur · chambre

elle exclut **délibérément** :

- le **ticker** — ajouté plus tard (enrichissement), sa présence rendrait la clé instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction

dédup non destructrice :

- les **lots réels** (même titre déclaré plusieurs fois dans un dépôt, comptes Self/Spouse/Joint) sont **préservés** (`occurrence_index`) — jamais de `drop_duplicates()` aveugle
- **dédup cross-année** : une re-divulgation (amendement, rapport annuel) ne compte qu'une fois → -1 920



12 champs métier garantis sur les 2
chambres : qui, quoi, quand (2 dates),
sens, montant, ticker, secteur, ETF, parti,
commissions


Validation (1/3) — Quiver, niveau 1 : a-t-on tout ?

la méthode : chaque trade
confronté à Quiver par clé
normalisée (élu × ticker × sens), en
3 niveaux de stricte — existence
→ date → champs

trades Quiver retrouvés
93,5 % Chambre · **92,1 %**
Sénat

sur-ensemble de Quiver
+26 524 combinaisons en plus
contre **38** trous inverses

vrais trous confirmés
27 Chambre · **11** Sénat



Validation (2/3) — les dates : qui a raison ?

niveau 2 — appariement **1-à-1** des dates, au sein de chaque (élu, ticker, sens) :

Khanna, AAPL, Achat :

NOUS : 08-jan · 13-fév · 01-juin

QUIVER : 08-jan · 12-fév

1. dates **identiques** retirées une à une (08-jan ↔ 08-jan)

2. restes appariés au plus proche : 13-fév ↔ 12-fév = *bruit* (≤ 10 j)

3. 01-juin sans vis-à-vis → **nous-seul** (on est plus complet)

→ seuls **545 candidats** issus du **même dépôt** méritent l'œil → **arbitrage au PDF source** :

**le PDF
montre...**

exemple réel

traitement

coquille du déposant,
prouvable

3031-04-30

corrigée → 2021

coquille littérale

le PTR imprime
01/35/22

**transcrite telle
quelle**

notre OCR s'est
trompé

Khanna/COST
09-31

re-lue au PDF →
08-16

désaccord Quiver

McCaul/GOOGL
 $\Delta 11$ j

arbitré au PDF
(doc 9113676)

niveau 3 — sur les trades partagés, accord des **autres
champs** :

sens : 96,8 % Chambre · 99,9 % Sénat

montant : 94,2 % · 99,8 %

Validation (3/3) — les preuves indépendantes de Quiver

Univers officiel

index du *House Clerk* re-téléchargé :
100 % des **8 252 PTR** traités — par-
sés, OCRisés ou écartés par règle
écrite

senate-stock-watcher

collecte indépendante, 6 231 txns
2014-2020 : **100 %** retrouvées chez
nous — on est un sur-ensemble strict

house-stock-watcher

miroir indépendant 2018-2026 :
99,5 % de ses lignes chez nous ; ses
manques pré-2018 → tous traités

Kadoa

agrégateur tiers : comptes par dé-
posant, triangulation automatisée
(test_crosscheck) — confirme les
déposants où notre OCR est l'**unique**
source

Golden interne


368 tables figées SHA-256, rejouées
octet à octet à **zéro écart** ; invariants
recomptés (digital + OCR = FINAL,
identité 100 %)

le principe

aucune source externe n'est **réinjec-
tée** dans les tables — elles ne servent
qu'à **mesurer** ce qu'on a

Du corpus à la table de recherche : l'entonnoir

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



le principe : on ne retire que l'**avéré inutilisable** pour un backtest (pas de date, pas de prix, pas de sens, pas de montant) —

tout le doute est GARDÉ et FLAGUÉ

les flags (jamais retirés) :

- `flag_late_filing` — divulgué > 45 j : **12,2 %**
- `is_delisted` — titre sorti de cote, typé (faillite/rachat) : **2,6 %**
- `lot_size > 1` — lots multi-comptes réels : **8,8 %**
- `flag_price_caution` — symbole recyclé : **0,4 %**

`data/clean/transactions_backtest_2014_2026.csv`

134 464 lignes × 36 colonnes

372 membres · 57 % issu d'OCR · parti & commissions *point-in-time* · traçable ligne à ligne (`doc_id`)


Ce qu'on garantit

- ✓ complet : 100 % de l'univers officiel
- ✓ identifié : 100 % des lignes rattachées
- ✓ validé : Quiver + 3 sources indépendantes
- ✓ reproductible : golden octet à octet

Limites assumées

- 582 PTR manuscrits écartés (règle rejouable)
- corroboration externe plus faible avant 2017
- montants = fourchettes (milieu), pas des prix exacts

Annexe — volumes par année et par voie



totaux contrôlés = 169 000 transactions uniques ; 1 381 transactions antérieures à 2014 (régularisations tardives) non tracées

Annexe — l'index du Clerk et les deux extrêmes

l'index annuel (extrait réel, 2024FD.xml) :

```
<Member>
  <Prefix>Hon.</Prefix>
  <Last>Allen</Last>
  <First>Richard W.</First>
  <FilingType>P</FilingType>
  <StateDst>GA12</StateDst>
  <Year>2024</Year>
  <FilingDate>1/11/2024</FilingDate>
  <DocID>20024277</DocID>
</Member>
```

P = PTR; les autres types (rapports annuels, candidatures...) sont ignorés

The image shows a printed form titled "PERIODIC TRANSACTION REPORT" for the Clerk of the House of Representatives. It is for Member Richard W. Allen, filed on 1/11/2024. The form includes a table for transactions with columns for ID, Owner Asset, Transaction Date, and Notification Amount. The "Initial Public Offerings" section is checked. The "Certification and Signature" section is signed by Richard W. Allen on 1/11/2024.

électronique 2014

doc 20000077 — ancien gabarit

The image shows a handwritten form titled "PERIODIC TRANSACTION REPORT" for the Clerk of the House of Representatives. It is for Member Richard W. Allen, filed on 1/11/2024. The form includes a table for transactions with columns for ID, Owner Asset, Transaction Date, and Notification Amount. The "Initial Public Offerings" section is checked. The "Certification and Signature" section is signed by Richard W. Allen on 1/11/2024.

manuscrit 2020

doc 8217474 — écarté (gating)