

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire · juillet 2026

169 000

transactions uniques

13 ans

2014 → 2026


445

élus identifiés
(367 Chambre + 78
Sénat)


4 voies

2 chambres × 2
formats
(électronique /
papier scanné)

Pourquoi ce projet ?



signal documenté académiquement :
Ziobrowski *et al.* 2004/2011 · Karadas 2019



délai médian réel : 27 j · 24 j

avant toute stratégie :
une couche de données **irréprochable**

Les sources : où on récupère quoi

Chambre — *House Clerk*

archive ZIP annuelle → index XML ({an}FD.xml) → PDF de chaque PTR. L'index fait **autorité** : 8 252 PTR, 100 % traités

Sénat — *eFD*

accord + jeton CSRF → recherche paginée → page **HTML** ou **image papier** (.gif)

Référentiel d'élus

congress-legislators : nom → bioguide_id officiel, parti, commissions (repli YAML embarqué, hors-ligne)

Claude Vision

lit les scans : formulaire → transactions JSON structurées (cache versionné)

Quiver Quantitative

agrégateur commercial = **vérité-terrain externe**, jamais réinjectée

Sources indépendantes

senate-stock-watcher · miroir
house-stock-watcher · **Kadoa** — triangulation, jamais réinjectées

deux dates par déclaration : date du **trade** · date de **divulgarion** — tout l'aval s'appuie sur la divulgation (anti-look-ahead)

À quoi ça ressemble (1/4) — Chambre, PTR électronique



PERIODIC TRANSACTION REPORT

Clerk of the House of Representatives • Legislative Resource Center • 881 Cannon Building • Washington, DC 20515

R INFORMATION

r Hon. Mark Alford
a Member
District MO04

SACTIONS

Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
Amazon.com, Inc. - Common Stock (AMZN) [ST]	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☒
FILING STATUS: New SUBORDINATING OR: Putnam Investments DESCRIPTION: The full transaction included the following sales: T - 37,496 shares sold @ \$27.642/share BRK/B - 3 shares sold @ \$493.42/share SPY - 8,318 shares sold @ \$670.024/share DIA - 8,426 shares sold @ \$470.982/share SPYD - 37,383 shares sold @ \$49.04/share AMZN - 25 shares sold @ \$299.40/share AAPL - 20,313 shares sold @ \$253.45/share QQQ - 4,305 shares sold @ \$401.68/share PFTL - 9,021 shares sold @ \$47.722/share					
Apple Inc. - Common Stock (AAPL) [ST]	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☒
FILING STATUS: New SUBORDINATING OR: Putnam Investments DESCRIPTION: The full transaction included the following sales: T - 37,496 shares sold @ \$27.642/share BRK/B - 3 shares sold @ \$493.42/share SPY - 8,318 shares sold @ \$670.024/share DIA - 8,426 shares sold @ \$470.982/share SPYD - 37,383 shares sold @ \$49.04/share AMZN - 25 shares sold @ \$299.40/share AAPL - 20,313 shares sold @ \$253.45/share QQQ - 4,305 shares sold @ \$401.68/share PFTL - 9,021 shares sold @ \$47.722/share					
AT&T Inc. (T) [ST]	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☒
FILING STATUS: New SUBORDINATING OR: Putnam Investments DESCRIPTION: The full transaction included the following sales: T - 37,496 shares sold @ \$27.642/share BRK/B - 3 shares sold @ \$493.42/share SPY - 8,318 shares sold @ \$670.024/share DIA - 8,426 shares sold @ \$470.982/share SPYD - 37,383 shares sold @ \$49.04/share AMZN - 25 shares sold @ \$299.40/share AAPL - 20,313 shares sold @ \$253.45/share QQQ - 4,305 shares sold @ \$401.68/share PFTL - 9,021 shares sold @ \$47.722/share					
Berkshire Hathaway Inc. New Common Stock (BRK.B) [ST]	S (partial)	03/06/2026	03/16/2026	\$1,001 - \$15,000	☐
FILING STATUS: New					

58 728 transactions — 34,8 % du corpus

- un PDF avec couche texte : lisible machine
- le ticker est imprimé **entre parenthèses** : (AMZN), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification) + fourchette de montant
- le **défi** : une transaction s'étale sur **plusieurs lignes** (descriptions, montants coupés)

À quoi ça ressemble (2/4) — Chambre, PTR scanné

Public Transaction Sheet

NAME: Anna P. Luna

Address: 123 Main St, Apt 4B, New York, NY 10001

Phone: (212) 555-1234

DATE: 2024-01-29

TIME: 14:30

TYPE OF TRANSACTION:

TYPE OF TRANSACTION	DATE	TIME	AMOUNT
Full Asset Sale	2024-01-29	14:30	10000.00
Partial Sale			
Exchange			
Other			

Hand Delivered (see back)

Signature of Agent: [Signature]

Signature of Client: [Signature]

Witness: [Signature]

Notary: [Signature]

Stamp: HAND DELIVERED

Stamp: 2024 JAN 29 14:30

Stamp: Anna P. Luna

scan tapé, **couché**, tampon *HAND DELIVERED* (Anna P. Luna)

93 261 transactions — 55,2 % du corpus

- une **image**, pas de texte : formulaire à **cases cochées** (type, fourchette A→K)
- souvent **tourné à 90°**, déposé à la main
- le **cas extrême** : le **manuscrit cursif** →

Public Transaction Sheet

NAME: Anna P. Luna

Address: 123 Main St, Apt 4B, New York, NY 10001

Phone: (212) 555-1234

DATE: 2024-01-29

TIME: 14:30

TYPE OF TRANSACTION:

TYPE OF TRANSACTION	DATE	TIME	AMOUNT
Full Asset Sale	2024-01-29	14:30	10000.00
Partial Sale			
Exchange			
Other			

Hand Delivered (see back)

Signature of Agent: [Signature]

Signature of Client: [Signature]

Witness: [Signature]

Notary: [Signature]

Stamp: HAND DELIVERED

Stamp: 2024 JAN 29 14:30

Stamp: Anna P. Luna

écarté — règle rejouable (→ étape 5)

À quoi ça ressemble (3/4) — Sénat, déclaration eFD

 UNITED STATES SENATE
FINANCIAL DISCLOSURES

Return to the search tab to select another report.

Periodic Transaction Report for 03/10/2025
The Honorable James Banks (Banks, James E.)
Filed 03/10/2025 @ 12:54 PM
[Print Report](#)

The following statements were checked before filing:
☒ I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
☐ I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

Transactions (1 transaction total) 0 Self 1 Joint 0 Spouse 0 Dependent Child

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	YUM	Yum! Brands Company: Yum (Louisville, KY) Description: Food	Other	Sale (Full)	\$1,001 - \$15,000	--

13 026 transactions — 7,7 %

- pas de PDF : une **page web** derrière la barrière CSRF
- table propre, ticker **cliquable** — mais intitulés et ordre des colonnes **varient** d'une déclaration à l'autre
- type d'actif et détenteur (Self / Joint / Spouse) déclarés


À quoi ça ressemble (4/4) — Sénat, papier scanné

This Report Should Be Filed With: Secretary of the Senate Office of Public Records Hart Building, Suite 232 Washington, DC 20510		PERIODIC DISCLOSURE OF FINANCIAL TRANSACTIONS			
Reporting Individual's Name Richard Blumenthal		Senate Office / Agency in Which Employed United States Senate		(Time/Date)	
Report any purchase, sale, or exchange by you, your spouse, or dependent child within 30 days of receiving written notification of such transaction. Report any stocks, bonds, commodity futures, and other securities when the amount of the transaction exceeded \$1,000. Include transactions that resulted in a loss. Do not report a transaction involving an excepted investment fund, any real property, or a transaction between you, your spouse, or dependent child. Please clarify which two assets are involved in any reportable exchange. In no event may this disclosure be filed more than 45 days after such transaction.		Transaction Type (x) Purchase Sale Exchange		Amount of Transaction (x) \$1,001 - \$15,000 \$15,001 - \$50,000 \$50,001 - \$100,000 \$100,001 - \$250,000 \$250,001 - \$500,000 \$500,001 - \$1,000,000 Over \$1,000,000***	
Identification of Assets Example: (S) Google (NYSE) X (DC) Microsoft (abck) X (A) Intel (NASDAQ:QVTC) X		Transaction Date (Mo., Day, Yr.) 2/17/1X 2/27/1X		\$1,001 - \$15,000 \$15,001 - \$50,000 \$50,001 - \$100,000 \$100,001 - \$250,000 \$250,001 - \$500,000 \$500,001 - \$1,000,000 Over \$1,000,000***	
1 (S) 3M's Partners LLC:					
2 (S) Four Winds LLC		X 11/4/25		X	
3 (S) ELCM2 LLC		X 11/13/25		X	
4					
5 (S) Peter L. Makin Family 9 LLC - 3M's Partners LLC:					
6 (S) Four Winds LLC		X 11/4/25		X	
7 (S) ELCM2 LLC		X 11/13/25		X	
8					

3 985 transactions — 2,4 % du corpus


- images .gif servies hors barrière — déjà droites (pas de redressement)
- grille de montants en colonnes cochées (A→L), propriétaire en préfixe (S)/(DC)/(J)
- 14 déposants sur 13 ans, massivement du non-coté (obligations municipales) — Blumenthal en tête
- aucun symbole boursier imprimé → ticker à ré-associer

Le flux de bout en bout



Étape 1 — d'abord, savoir qui a déclaré (identité)

le même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → il faut un **identifiant unique**




100 % des lignes rattachées

367 membres Chambre · **78** Sénat


Pièges réels, réparés :

- homonymie : le sénateur Bob Casey rattaché à tort à C000228 (un représentant texan) → C001070
- **42 lignes** d'Angie Craig sans identifiant → réparées (read-time, figé intact)
- 1 seule déclaration **exclue** : une collaboratrice de commission (pas un élu — vérifié au PDF)

Étape 2 — trier : électronique ou scanné ?



la composition qui en résulte (169 000 transactions uniques) :



plus de la moitié du corpus vient de **scans** — le papier n'est pas un détail, c'est la majorité

Étape 3 — la piste électronique de la Chambre

58 728 transactions uniques

zéro échec silencieux : tout PDF sans ligne est consigné

(05_parse_failures) — 102 « nothing to report » réels

le PDF ne donne pas un tableau régulier : une transaction s'étale sur **plusieurs lignes**, montants coupés

1. **recoller** les lignes coupées (`_join_split_lines`)

2. **repérer la signature** de chaque transaction : opération (P/S/E) + **2 dates** + fourchette

3. **rattacher** actif et ticker imprimés à proximité

Pièges déjoués


- le **gabarit change en 2018** (casse, codes, mise en page) → **deux parseurs** routés par signature, union dédoublée ; sans ça, **≈ 72 ventes** perdues rien qu'en 2014 (biais vendeur)
- **205 PTR** déposés après le 31/12 étaient perdus → l'index annuel du Clerk fait désormais **autorité**

dans la source :

Amazon.com, Inc. - Common Stock
(AMZN) [ST] · Purchase · 03/16/2018 ·
\$1,001-\$15,000

Étape 4 — la piste électronique du Sénat





13 026 transactions uniques



pourquoi « flou » ? **l'intitulé et l'ordre des colonnes varient** d'une déclaration à l'autre — on retient la colonne dont l'en-tête contient les bons mots-clés, seule approche robuste

identité, ticker et déduplication : délégués au tronc commun — même clé naturelle que la Chambre

Étape 5 — la piste scannée de la Chambre (OCR Vision)



1. redresser — reconnaissance d'orientation (4 candidates)

2. classer — census **2 424 scans** : 74 droits · 1 575 tournés · **775 manuscrits**

3. lire — tool_use forcé, JSON strict, **cache versionné** (un re-run ne re-paie rien), prompt durci sur échantillon

gating manuscrit — Quiver ne corrobore que **12,9 %** du manuscrit (88 % du tapé droit) : dates cursives trop incertaines → **582 écartés**, règle écrite **rejouable**, exceptions explicites (3 déposants + 33 docs curés)

93 261 lignes — très concentrées

Khanna à lui seul **44,0 %** · trio Khanna, McCaul, Harshbarger **77,1 %** — de gros déposants qui déclarent **exclusivement sur papier**

Étape 6 — la piste papier du Sénat

3 985 lignes — 14 déposants

- images **déjà droites** : pas de redressement, même moteur Vision
- particularité : fusion + enrichissement **en une passe sur tout le corpus** (peu de données par année → le dictionnaire de tickers est mutualisé entre les années)
- Blumenthal = **38,7 %** de la piste ; massivement du **non-coté** (munis, produits structurés) → couverture ticker plus basse = **composition, pas défaut d'extraction**

ce que rend l'OCR (extrait réel — John Boozman) :

```
{ "member": "JOHN BOOZMAN",  
  "status": "ok", "n_pages": 2,  
  "transactions": [  
    { "asset_description":  
        "Apple Computer Inc",  
      "transaction_type": "Sale",  
      "owner": "Self",  
      "transaction_date": "2022-03-14",  
      "amount_code": "A" }, ... ] }
```

Étape 7 — un secteur pour chaque ticker : GICS → ETF SPDR

résoudre le ticker (cascade, source tracée) :

1. **explicite** — déjà imprimé dans la source



2. **dictionnaire** — nom vu ailleurs dans le corpus



3. **LLM** filtré « action » — jamais d'obligation/muni tickerisée



4. **récupération** validée par double preuve
— **2 540 lignes** retrouvent leur symbole

puis le secteur : yfinance (factuel) → LLM contraint GICS (+ garde-fou is_listed) → overrides manuels

11 secteurs GICS → 11 ETF *Select Sector SPDR* :

Energy→XLE · Materials→XLB ·
Industrials→XLI · Cons. Discr.→XLY ·
Cons. Staples→XLP · Health Care→XLV ·
Financials→XLF · Info. Tech.→XLK · Comm.
Services→XLC · Utilities→XLU · Real
Estate→XLRE

couverture = remplissage, pas exactitude : ticker
renseigné **84,1 %** Chambre / **77,9 %** Sénat ; sec-
teur **79,8 %** / **70,4 %** — les vides sont le **non-coté**
légitime (munis, obligations, fonds privés), pas des
défauts d'extraction

Étape 8 — la table finale : le contrat « 12/12 »

une clé naturelle de 7 champs :


déclarant · date du trade · actif · opération · fourchette
· détenteur · chambre

elle exclut **délibérément** :

- le **ticker** — ajouté plus tard (enrichissement), sa présence rendrait la clé instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction

dédup non destructrice :

- les **lots réels** (même titre déclaré plusieurs fois dans un dépôt, comptes Self/Spouse/Joint) sont **préservés** (`occurrence_index`) — jamais de `drop_duplicates()` aveugle
- **dédup cross-année** : une re-divulgation (amendement, rapport annuel) ne compte qu'une fois → -1 920



Validation (1/3) — Quiver, niveau 1 : a-t-on tout ?

la méthode : chaque trade
confronté à Quiver par clé
normalisée (élu × ticker × sens),
en **3 niveaux de stricte** —
existence → date → champs


trades Quiver retrouvés

93,5 % Chambre ·

92,1 % Sénat

sur-ensemble de Quiver
+26 524 combinaisons en
plus
contre **38** trous inverses

vrais trous confirmés
27 Chambre · **11** Sénat



Validation (2/3) — les dates : qui a raison ?

niveau 2 — appariement **1-à-1** des dates, au sein de chaque (élu, ticker, sens) :

Khanna, AAPL, Achat :

NOUS : 08-jan · 13-fév · 01-juin

QUIVER : 08-jan · 12-fév

1. dates **identiques** retirées une à une (08-jan ↔ 08-jan)

2. restes appariés au plus proche : 13-fév ↔ 12-fév = *bruit* (≤ 10 j)

3. 01-juin sans vis-à-vis → **nous-seul** (on est plus complet)

→ seuls **545 candidats** issus du **même dépôt** méritent l'il → **arbitrage au PDF source** :

**le PDF
montre...**

exemple réel

traitement

coquille du
déposant, prouvable

3031-04-30

corrigée → 2021

coquille littérale

le PTR imprime
01/35/22

**transcrite telle
quelle**

notre OCR s'est
trompé

Khanna/COST
09-31

re-lue au PDF →
08-16

désaccord Quiver

McCaul/GOOGL
 $\Delta 11$ j

arbitré au PDF
(doc 9113676)

niveau 3 — sur les trades partagés, accord des **autres champs** :

sens : 96,8 % Chambre · 99,9 % Sénat

montant : 94,2 % · 99,8 %

Validation (3/3) — les preuves indépendantes de Quiver

Univers officiel

index du *House Clerk* re-téléchargé : **100 %** des **8 252 PTR** traités — parsés, OCRisés ou écartés par règle écrite

house-stock-watcher

miroir indépendant 2018-2026 : **99,5 %** de ses lignes chez nous ; ses manques pré-2018 → tous traités

Golden interne

368 tables figées SHA-256, rejouées octet à octet à **zéro écart** ; invariants recomptés (digital + OCR = FINAL, identité 100 %)

senate-stock-watcher

collecte indépendante, 6 231 txns 2014-2020 : **100 %** retrouvées chez nous — on est un sur-ensemble strict

Kadoa


agrégateur tiers : comptes par déposant, triangulation automatisée (test_crosscheck) — confirme les déposants où notre OCR est l'**unique source**

le principe

aucune source externe n'est **réinjectée** dans les tables — elles ne servent qu'à **mesurer** ce qu'on a

Du corpus à la table de recherche : l'entonnoir

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



le principe : on ne retire que l'**avéré inutilisable** pour un backtest (pas de date, pas de prix, pas de sens, pas de montant) —

tout le doute est GARDÉ et FLAGUÉ

les flags (jamais retirés) :

- `flag_late_filing` — divulgué > 45 j : **12,2 %**
- `is_delisted` — titre sorti de cote, typé (faillite/rachat) : **2,6 %**
- `lot_size > 1` — lots multi-comptes réels : **8,8 %**
- `flag_price_caution` — symbole recyclé : **0,4 %**

`data/clean/transactions_backtest_2014_2026.csv`

134 464 lignes × 36 colonnes

372 membres · 57 % issu d'OCR · parti & commissions *point-in-time* · traçable
ligne à ligne (`doc_id`)


Ce qu'on garantit

- ✓ complet : 100 % de l'univers officiel
- ✓ identifié : 100 % des lignes rattachées
- ✓ validé : Quiver + 3 sources indépendantes
- ✓ reproductible : golden octet à octet

Limites assumées

- 582 PTR manuscrits écartés (règle rejouable)
- corroboration externe plus faible avant 2017
- montants = fourchettes (milieu), pas des prix
exacts

Annexe — volumes par année et par voie



totaux contrôlés = 169 000 transactions uniques ; 1 381 transactions antérieures à 2014 (régularisations tardives)
non tracées

Annexe — l'index du Clerk et les deux extrêmes

l'index annuel (extrait réel, 2024FD.xml) :

```
<Member>
  <Prefix>Hon.</Prefix>
  <Last>Allen</Last>
  <First>Richard W.</First>
  <FilingType>P</FilingType>
  <StateDst>GA12</StateDst>
  <Year>2024</Year>
  <FilingDate>1/11/2024</FilingDate>
  <DocID>20024277</DocID>
</Member>
```

P = PTR; les autres types (rapports annuels, candidatures...) sont ignorés

The image shows a printed version of a "PERIODIC TRANSACTION REPORT" form. At the top, it says "Filing (1) statement(s)". The title is "PERIODIC TRANSACTION REPORT" with a small eagle logo. Below the title, it says "Clerk of the House of Representatives • Legislative Resource Center • 5000 Cannon Building • Washington, DC 20543". The "FILER INFORMATION" section includes: Name: Mr. Robert E. Andrews, Position: Member, State: District - NC. The "TRANSACTIONS" table has columns: ID, Owner Asset, Transaction Date, and Notification Amount Date. It lists one transaction: ID 01, Owner Asset H&M International, Inc. (H&M), Transaction Date 11/01/2013, and Notification Amount Date 01/01/2014. The "INITIAL PUBLIC OVERSIGHT" section has a "Yes" box checked. The "CERTIFICATION AND SIGNATURE" section includes a statement of truth and a signature line for Robert E. Andrews dated 01/11/2014.

électronique 2014

doc 20000077 — ancien gabarit

The image shows a handwritten version of a "PERIODIC TRANSACTION REPORT" form. At the top, it says "Filing (1) statement(s)". The title is "PERIODIC TRANSACTION REPORT" with a small eagle logo. Below the title, it says "Clerk of the House of Representatives • Legislative Resource Center • 5000 Cannon Building • Washington, DC 20543". The "FILER INFORMATION" section includes: Name: Mr. Robert E. Andrews, Position: Member, State: District - NC. The "TRANSACTIONS" table has columns: ID, Owner Asset, Transaction Date, and Notification Amount Date. It lists one transaction: ID 01, Owner Asset H&M International, Inc. (H&M), Transaction Date 11/01/2013, and Notification Amount Date 01/01/2014. The "INITIAL PUBLIC OVERSIGHT" section has a "Yes" box checked. The "CERTIFICATION AND SIGNATURE" section includes a statement of truth and a signature line for Robert E. Andrews dated 01/11/2014. The form is filled out with handwritten text and has a "RECEIVED" stamp from the Clerk of the House of Representatives dated 01/11/2014.

manuscrit 2020

doc 8217474 — écarté (gating)