

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Le plan — cinq étapes, une promesse



à la fin : vous saurez **ce que contient la table, comment elle a été construite, et pourquoi on peut lui faire confiance** — limites comprises.

cadre légal : STOCK Act 2012 — chaque élu du Congrès doit déclarer ses transactions boursières sous **45 jours** (*Periodic Transaction Report*, « PTR »)

Partie 1 — Ce qu'on a récupéré : la donnée brute



Où vivent ces données, et à quoi ressemblent-elles vraiment ?

La Chambre — le point de départ : le site officiel


The screenshot shows the official website of the Clerk of the U.S. House of Representatives. The header includes the Clerk's logo and the text "UNITED STATES HOUSE of REPRESENTATIVES". A navigation bar contains links: LEGISLATIVE INFORMATION, MEMBER INFORMATION, COMMITTEE INFORMATION, DISCLOSURES, and ABOUT THE CLERK. The left sidebar lists "REPORTS" with sub-links: Overview, Download Financial Disclosure Reports, For Members And Staff, For Congressional Candidates, and Search. The main content area is titled "FINANCIAL DISCLOSURE REPORTS" and includes the heading "WHAT ARE FINANCIAL DISCLOSURE REPORTS?". The text explains that these reports include information about the source, type, amount, or value of the incomes of Members, officers, certain employees of the U.S. House of Representatives and related offices, and candidates for the U.S. House of Representatives. It also mentions that these reports are filed with the Clerk of the House as required by Title I of the Ethics in Government Act of 1978, as amended. A section titled "DOWNLOAD FINANCIAL DISCLOSURE REPORTS BY YEAR" is highlighted with a red box, showing a list of years from 2008 to 2026, each preceded by a star icon. Below this, there is a section titled "FOR MEMBERS AND STAFF" with a link to "Obtain instruction booklet, forms and instructions for filing:" and two bullet points: "Financial Disclosure Online Reporting Application" and "Instruction Guide for Financial Disclosure Statements and Derivative Transaction Reports".

disclosures-clerk.house.gov (clicable)

on part du site public de la Chambre :

- une **liste de téléchargements**
- une **archive par année** (zone encadrée)
- on prend les années **2014 → 2026**


La Chambre — l'archive ZIP contient l'index XML



```
2024FD.xml — index annuel du House Clerk

3  <Member>
4  <Prefix />
5  <Last>Abel</Last>
6  <First>William</First>
7  <Suffix />
8  <FilingType>C</FilingType>  ← type C : pas un PTR, ignoré
9  <StateDst>TX31</StateDst>
10 <Year>2024</Year>
11 <FilingDate>5/12/2024</FilingDate>
12 <DocID>10060658</DocID>
13 </Member>
- 2 256 dépôts dans l'index 2024 -
245 <Member>
246 <Prefix>Hon.</Prefix>
247 <Last>Allen</Last>
248 <First>Richard W.</First>
249 <Suffix />
250 <FilingType>P</FilingType>  ← type P : un PTR, on le garde
251 <StateDst>GA12</StateDst>
252 <Year>2024</Year>
253 <FilingDate>1/11/2024</FilingDate>
254 <DocID>20024277</DocID>  ← le n° → l'URL du PDF
255 </Member>
```

12 types de dépôts — le backtest n'en lit qu'un : P




P = *Periodic Transaction Report* (les « PTR ») — les **déclarations de transactions boursières**, datées, sous 45 jours.

et les 11 autres types ? on les ouvre TOUS en Partie 4 — Vérification


35 315 dépôts au total · 8 252

PTR

Un DocID, un PDF — et deux mondes



lisible — 71 %



scanné — 29 %

Le document lisible : un PTR électronique



Filing ID #20009426

PERIODIC TRANSACTION REPORT

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

FILER INFORMATION

Name: Hon. John A. Yarmuth
Status: Member
State/District: KY03

TRANSACTIONS

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Altria Group, Inc. (MO) [ST] FILING STATUS: New	S (partial)	03/23/2018	04/07/2018	\$1,001 - \$15,000	☒
	Boeing Company (BA) [ST] FILING STATUS: New	S (partial)	03/15/2018	04/07/2018	\$1,001 - \$15,000	☒
	Micron Technology, Inc. (MU) [ST] FILING STATUS: New	P	03/27/2018	04/07/2018	\$1,001 - \$15,000	☐
	Wells Fargo & Company (WFC) [ST] FILING STATUS: New	S (partial)	03/20/2018	04/07/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

INITIAL PUBLIC OFFERINGS

☒ Yes ☐ No

CERTIFICATION AND SIGNATURE

☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.

Digitally Signed: Hon. John A. Yarmuth , 05/02/2018

DocID en 2... → couche texte

- un PDF **lisible par machine**
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification) + fourchette de montant
- lisible... mais pas si régulier : **le défi** sur la slide suivante

Le défi : un PDF lisible n'est pas un tableau régulier

TRANSACTIONS						
ID	Owner Asset	Transaction Type	Transaction Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/17/2018	04/17/2018	\$15,001 - \$50,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	S	04/17/2018	04/17/2018	\$15,001 - \$50,000	☐
	Microsoft Corporation (MSFT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$50,000	☐
	Spectra Energy Partners, LP Common Units representing Limited Partner Interests (SEP) [ST] une seule transaction, libellé sur 4 lignes SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

le PDF n'est **pas** un **tableau régulier** :

- le **montant** déborde sur la ligne suivante (\$15,001 – puis \$50,000)
- le **libellé** d'un actif court sur **4 lignes**
- un découpage ligne à ligne raterait la moitié

→ on **reconstruit** chaque transaction
(recollage des lignes coupées)
avant de la lire

le montant coupé à lui seul : **7 996** lignes réparées

extrait réel (Hon. Bob Gibbs, OH07) — cadres ajoutés

Le monde scanné : tapé (Vision lit) ou manuscrit (le point dur)

un scan n'est pas du texte, c'est une **image** — ce qui compte n'est pas l'orientation mais **tapé vs manuscrit**
(pages réelles) :

[illegible]

Tapé, droit

dactylographié, lisible tel quel

NAME (LAST, FIRST, MIDDLE) JAMES E. L. TAYLOR, JR.		DATE OF BIRTH 01/22/1979		ADDRESS (STREET, CITY, STATE, ZIP) 1000 N. 10TH ST. # 100 TAMPA, FL 33604		TELEPHONE (AREA CODE, NUMBER) (813) 288-1100		MAILING ADDRESS (STREET, CITY, STATE, ZIP) 1000 N. 10TH ST. # 100 TAMPA, FL 33604	
☐ MALE ☐ FEMALE		☐ WHITE ☐ BLACK ☐ OTHER		☐ U.S. BORN ☐ FOREIGN BORN		☐ U.S. CITIZEN ☐ ALIEN		☐ U.S. BORN ☐ FOREIGN BORN	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐ YES	
☐ NO ☐ YES		☐ NO ☐ YES		☐ NO ☐					

Tapé, couché

tourné à 90° — **Vision lit**
quand même

[illegible]

Manuscrit

à la main, cursif — le vrai point dur

93 261 transactions — 55,2 % du corpus

l'orientation importe peu ; le **manuscrit** est le point dur — *Partie 2*

United States Senate Financial Disclosures (eFD)

Public disclosure of a government official's personal financial interests is a key component to an effective code of conduct. For more information on filing, including who files, and the types of reports filed, see the [United States Senate's Select Committee on Ethics website](#).

Select Reports are Available

This site includes financial disclosure reports for Senators, former Senators and Senate candidates filed from 2012 to present. Senator reports are available for six years from the date a Senator ceases to be a Member of Congress. Candidate reports are available for one year after the individual is no longer a candidate.

Additional Reports

All financial disclosure reports are available through the Office of the Secretary of the Senate kiosk:

Office of Public Records
144 Hart Senate Office Building
Washington, D.C. 20510-7116
phone (202) 224-0322

Q Get Access

You must agree to the following to be able to search reports.

Title 1 of the Ethics in Government Act of 1978, as amended, 5 U.S.C. app. § 105(c), states that:

1. It shall be unlawful for any person to obtain or use a report:
 1. for any unlawful purpose;
 2. for any commercial purpose, other than by news and communications media for dissemination to the general public;
 3. for determining or establishing the credit rating of any individual; or
 4. for use, directly or indirectly, in the solicitation of money for any political, charitable, or other purpose.
2. The Attorney General may bring a civil action against any person who obtains or uses a report for any purpose prohibited in paragraph (1) of this subsection. The court in which such action is brought may assess against such person a penalty in any amount not to exceed \$10,000. Such remedy shall be in addition to any other remedy available under statutory or common law.

☐ I understand the prohibitions on obtaining and use of financial disclosure reports.

la barrière : accord + jeton (CSRF)

- la case encadrée : l'**accord obligatoire** avant toute recherche
- notre collecteur l'accepte et récupère le **jeton de session**
- ensuite seulement : on peut **chercher** (slide suivante)

efdsearch.senate.gov — la page d'accès (capture réelle)

Le Sénat — chercher (Senator × PTR), puis la liste

UNITED STATES SENATE
FINANCIAL DISCLOSURES

Find Reports

Find Reports

Note Reports will display in the format they were filed: either electronically (text) or on paper (images).

Search Options

Filer Name ? First name (starts with) Last name (starts with)

Filer Type ☒ Senator ☐ Candidate ☐ Former Senator

All States All States

Report Types ? ☐ Annual ☐ Due Date Extension ☐ Other Documents ☒ Periodic Transactions ☐ Blind Trusts

Date Filed/Received ? From To

When selected, reports will open in a new tab or window.

Search Reports

le formulaire : on coche **Senator × PTR**

UNITED STATES SENATE
FINANCIAL DISCLOSURES

Find Reports

Note Reports will display in the format they were filed: either electronically (text) or on paper (images).

Search Again

Search Results

Reports will open in a new tab or window.

Filter list by name, office, report type, date


Showing 1 to 25 of 1,705 entries

First Name (Middle)	Last Name (Suffix)	Office (Filer Type)	Report Type	Date Received/Filed
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 06/26/2025	06/26/2025
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 08/10/2025	08/10/2025
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 03/10/2025	03/10/2025
John A	Barrasso	Barrasso, John (Senator)	Periodic Transaction Report for 05/24/2018	05/24/2018
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 07/12/2021	07/12/2021
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 05/16/2023	05/16/2023
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 02/07/2017	02/07/2017
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 04/02/2019	04/02/2019
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 09/02/2020	09/02/2020
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 10/18/2022	10/18/2022

la liste réelle : **1 705** rapports, un lien par dépôt

les PTR sont **un type parmi d'autres** (Annual, Blind Trusts, Extensions. . .) — on envoie `report_types=[11]` ;
un dépôt s'ouvre dans son format : **page HTML** (texte) ou **scan** (image)

Le Sénat électronique : une table propre



The screenshot shows the 'UNITED STATES SENATE FINANCIAL DISCLOSURES' page. It features a header with the Senate seal and a link to 'Return to the search tab to select another report.' The main content area is titled 'Periodic Transaction Report for 03/10/2025' for 'The Honorable James Banks (Banks, James E.)', filed on 03/10/2025 at 12:54 PM. A 'Print Report' button is visible. Below this, a section titled 'Transactions' shows a table with one transaction. The table has columns for #, Transaction Date, Owner, Ticker, Asset Name, Asset Type, Type, Amount, and Comment. The transaction is dated 02/18/2025, is a 'Sale (Full)' of 'Yum! Brands' stock, with an amount of '\$1,001 - \$15,000'.

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	YUM!CZ	Yum! Brands Company: Yum (Louisville, KY) Description: Food	Other	Sale (Full)	\$1,001 - \$15,000	--

le cas électronique : table propre, ticker cliquable

13 026 transactions électroniques

- un gabarit de table **stable sur 13 ans** (les 9 mêmes colonnes, détail en Partie 2)
- seul le contenu change : amendements (10 %), ticker « - » = non-coté, cellules parfois vides

Le Sénat papier : un formulaire unique, trois écritures

un seul modèle depuis 2014 — cliquer une vignette ouvre le vrai scan :

[illegible]

tapé, droit

3 985 transactions

[illegible]

tapé, couché — 255/373

"This Report Should Be Filed with:"

Secretary of the Florida
Office of Public Access Records
1901 E. Bay Street
Tallahassee, FL 32304

DATE

FINANCIAL DISCLOSURE **OF FINANCIAL** **TRANSACTIONS**

RECEIVED
THE FLORIDA OFFICE OF PUBLIC ACCESS
RECORDS

FL PRF- A PD 2-7

Report On: (Agent's or Agent's Spouse)

Sun-Pat Reynolds

4550 Swate

Page: 1

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Report Period: (Start Date) 1/1/2015

Report Period: (End Date) 12/31/2015

Transaction Type	Transaction Date (MM/DD/YYYY)	Amount of Transaction (\$)
Income	1/1/2015	\$1,000.00
Income	2/1/2015	\$1,000.00
Income	3/1/2015	\$1,000.00
Income	4/1/2015	\$1,000.00
Income	5/1/2015	\$1,000.00
Income	6/1/2015	\$1,000.00
Income	7/1/2015	\$1,000.00
Income	8/1/2015	\$1,000.00
Income	9/1/2015	\$1,000.00
Income	10/1/2015	\$1,000.00
Income	11/1/2015	\$1,000.00
Income	12/1/2015	\$1,000.00
Income	1/1/2016	\$1,000.00
Income	2/1/2016	\$1,000.00
Income	3/1/2016	\$1,000.00
Income	4/1/2016	\$1,000.00
Income	5/1/2016	\$1,000.00
Income	6/1/2016	\$1,000.00
Income	7/1/2016	\$1,000.00
Income	8/1/2016	\$1,000.00
Income	9/1/2016	\$1,000.00
Income	10/1/2016	\$1,000.00
Income	11/1/2016	\$1,000.00
Income	12/1/2016	\$1,000.00
Income	1/1/2017	\$1,000.00
Income	2/1/2017	\$1,000.00
Income	3/1/2017	\$1,000.00
Income	4/1/2017	\$1,000.00
Income	5/1/2017	\$1,000.00
Income	6/1/2017	\$1,000.00
Income	7/1/2017	\$1,000.00
Income	8/1/2017	\$1,000.00
Income	9/1/2017	\$1,000.00
Income	10/1/2017	\$1,000.00
Income	11/1/2017	\$1,000.00
Income	12/1/2017	\$1,000.00
Income	1/1/2018	\$1,000.00
Income	2/1/2018	\$1,000.00
Income	3/1/2018	\$1,000.00
Income	4/1/2018	\$1,000.00
Income	5/1/2018	\$1,000.00
Income	6/1/2018	\$1,000.00
Income	7/1/2018	\$1,000.00
Income	8/1/2018	\$1,000.00
Income	9/1/2018	\$1,000.00
Income	10/1/2018	\$1,000.00
Income	1	

manuscrit (Roberts)

[illegible]

annexe « courtier » —

format libre

cas à part : page de garde (lettre d'avocat) sans données, ignorée

Les dates : ce qu'on reçoit tout fait, ce qu'on va lire

Date de DÉPÔT (divulgaration)

toujours une métadonnée — jamais OCRisée, jamais lue sur le document ; **fiable** → c'est la date **signal** (anti-look-ahead)

(la troisième date — la « notification » du PTR Chambre — est **jetée** ; le tampon de réception du papier Sénat n'est **pas** OCRisé)

Date de TRANSACTION

lue dans le document (texte ou OCR) ; la **seule** **risquée** → garde-fous + flag, jamais inventée



Voie	Date de dépôt vient de...	Date de transaction vient de...
Chambre électronique	l'index XML (FilingDate)	le texte du PDF
Chambre scannée	l'index XML (même source)	l' OCR (Claude Vision)
Sénat électronique	la fiche eFD (le listing)	le tableau HTML
Sénat papier	la fiche eFD (le listing)	l' OCR de la grille

garde-fou transaction : hors **[dépôt -90 j, +10 j]** → année recalée / ligne **flaguée**, jamais réécrite au hasard · délai médian de divulgation **27 j** Chambre · **24 j** Sénat

Le corpus en un coup d'œil : quatre voies — et une forte concentration

169 000 transactions uniques (2014–2026), quatre sous-corpus :

Sénat OCR 2,4 %



445 déposants distincts — dont 294 avec ≥ 10 transactions

très concentré — Khanna (41 080 txns) et McCaul (27 154), tous deux à la Chambre, pèsent à eux deux $\sim 40\%$ du corpus, et déclarent **exclusivement sur papier** (100 % OCR)


le papier n'est pas un détail : c'est la majorité du corpus

Partie 2 — Comment on la récupère : le pipeline




Comment passe-t-on de $\sim 10\,000$ documents hétérogènes à une seule table ?


Le flux de bout en bout, en une image




Le flux de bout en bout, en une image



Le flux de bout en bout, en une image




Le flux de bout en bout, en une image



L'identité : chaque nom devient un bioguide

un même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → on relie ce **nom libre** à un **identifiant unique**, par une cascade d'essais :



100 % des lignes rattachées

367 membres Chambre · 78 Sénat

```
legislators-current.yaml - référentiel congress-legislators
12608 - id:
12609   bioguide: P000197 - l'identifiant officiel unique
      - (autres identifiants) -
12625   name:
12626     first: Nancy
12627     last: Pelosi
12628     official_full: Nancy Pelosi
12629   bio:
12630     birthday: '1940-03-26'
12631     gender: F
      - mandats successifs -
12661     state: CA
12662     district: 5
12663     party: Democrat
```

congress-legislators = l'annuaire public officiel des élus (nom → identifiant + parti + commissions)

Pièges réels, réparés : l'homonyme Bob Casey (C000228 → C001070) · 42 lignes d'Angie Craig sans identifiant, réparées read-time

Les deux pistes électroniques : déterministes de bout en bout

Chambre — 58 728 transactions

1. **recoller** les lignes coupées

2. **repérer la signature** : opération (P/S/E) + **2 dates** + fourchette

3. **rattacher** actif et ticker imprimés à proximité

gère **deux gabarits de formulaire** (2014-2019 et 2020+) et s'ancre sur l'**index officiel de l'année** → **couvre 2014-2026** sans trou

Sénat — 13 026 transactions

1. **liste des dépôts** — recherche paginée, barrière CSRF


2. **page HTML par dépôt** — cache disque (re-run : zéro téléchargement)

3. **lecture des tableaux** — colonnes repérées par mots-clés

en pratique le gabarit est **stable** : les **9 mêmes colonnes** sur les 1 777 pages HTML 2014→2026 (vérifié) — rien à déjouer côté format

zéro échec silencieux : 102 dépôts sans transaction retenue, tous consignés (vides réels, amendements sans ligne, échecs tracés)

Lire le scanné Chambre : Vision lit tout — le point dur, c'est le manuscrit



1. redresser — pré-traitement léger (4 orientations ; **Vision lit de toute façon**)

2. classer — census **2 424 scans** : 74 droits · 1 575 tournés · **775 manuscrits**

3. lire — `tool_use` forcé, JSON strict, **cache versionné** (un re-run ne re-paie rien), prompt durci sur échantillon

gating manuscrit — Quiver (fournisseur commercial des mêmes données — Partie 4) ne corrobore que **12,9 %** du manuscrit (88 % du tapé droit) : dates cursives trop incertaines → **582 écartés**, règle écrite **rejouable**, exceptions explicites (3 déposants + 33 docs curés)

93 261 lignes — très concentrées

Khanna à lui seul **44,0 %** · trio Khanna, McCaul, Harshbarger **77,1 %** — les gros déposants « 100 % papier » vus en Partie 1

Lire le papier Sénat : du formulaire au structuré

[illegible]

l'image .gif, déjà droite

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

actif	Apple Computer Inc
opération	Sale
date du trade	2022-03-14
détenteur	Self
fourchette	code A (1 001–15 000 \$)

3 985 lignes — 14 déposants

- **même moteur Vision** que la Chambre, mais **plus simple** : l'image est déjà droite (aucun redressement)
 - fusion + enrichissement **en une passe** (dictionnaire de tickers mutualisé)
 - Blumenthal = 38,7 % de la piste, massivement du **non-coté**
- couverture ticker plus basse = **composition, pas défaut**

Partie 3 — Enrichir : les tickers, et le reste



Que faut-il ajouter pour qu'un backtest puisse s'en servir ?

D'abord : résoudre le ticker (une cascade tracée)

1. **explicite** — déjà imprimé
dans la source (l'électronique)



2. **dictionnaire** — le nom vu
ailleurs dans le corpus (le papier)



3. **LLM** filtré « action » — ja-
mais d'obligation/muni tickerisée



4. **récupération** validée par double preuve
— **2 540 lignes** retrouvent leur symbole

ticker renseigné

84,1 % Chambre · **77,9 %** Sénat

couverture = remplissage, pas exactitude —
les vides sont le **non-coté légitime** (munis, obli-
gations, fonds privés), pas des défauts d'extrac-
tion

Ensuite : un secteur GICS, et son ETF

donner un secteur (cascade indépendante) :

1. **yfinance** — le secteur factuel de l'entreprise

2. **LLM** contrainte GICS
(+ garde-fou `is_listed`)

3. **overrides** manuels — les cas connus

secteur renseigné **79,8 % Ch.** · **70,4 % Sén.**

11 secteurs GICS → **11 ETF *Select Sector SPDR*** :

Energy→XLE · Materials→XLB · Industrials→XLI
· Cons. Discr.→XLY · Cons. Staples→XLP ·
Health Care→XLV · Financials→XLF · Info.
Tech.→XLK · Comm. Services→XLC ·
Utilities→XLU · Real Estate→XLRE

l'ETF proxy sert de « panier secteur » quand on veut
exposer un thème plutôt qu'un titre

La table du corpus : le contrat « 12/12 » et la clé naturelle

une clé naturelle de 7 champs :

déclarant · date du trade · actif · opération · fourchette ·
détenteur · chambre

elle exclut **délibérément** :

- le **ticker** — ajouté plus tard (enrichissement), sa présence rendrait la clé instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction

dédup non destructrice :

- les **lots réels** (même titre déclaré plusieurs fois dans un dépôt, comptes Self/Spouse/Joint) sont **préservés** (`occurrence_index`) — jamais de `drop_duplicates()` aveugle
- **dédup cross-année** : une re-divulgation (amendement, rapport annuel) ne compte qu'une fois → -1 920

170 920 lignes brutes
(26 fichiers FINAL, 28 colonnes)

dédup cross-année -1 920

169 000 transactions uniques

12 champs métier garantis sur les 2
chambres : qui, quoi, quand (2 dates),
sens, montant, ticker, secteur, ETF, parti,
commissions

Partie 4 — Vérification : rien raté, rien inventé



*Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?*

Vérifier, c'est répondre à trois questions

1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

on ouvre les **11 autres types** de dépôts (C, H, O, T, A...) et on mesure le trou

173

actions résiduelles

2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie

87,8 %

du portefeuille de sortie reconstruit (Chambre)

3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver + stock-watchers + univers officiel — jamais réinjectés


93,5 %

des combinaisons Quiver retrouvées (Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

Complétude (1/5) — la vie déclarative d'un élu, et sa loi

Question 1 · Complétude



chaque étape a son dépôt **et son délai légal** — Schedule **A** = le patrimoine (les photos), Schedule **B** = les transactions ; deux dérogations : un C dispense du H, partir au Sénat/exécutif dispense du T

Complétude (2/5) — le même formulaire, des sections en commun

Question 1 · Complétude

Les sections A→J, et lesquelles apparaissent dans chaque type de document

	P	identiques		identiques		T
	PTR	C	H	O		T
		candidat	entrée	annuel		sortie
A	Actifs & revenus de placement	☒	☒	☒		☒
B	TRANSACTIONS	☒	☐	☒		☒
C	Revenus du travail	☐	☒	☒		☒
D	Dettes	☐	☒	☒		☒
E	Postes occupés	☐	☒	☒		☒
F	Accords	☐	☒	☒		☒
G	Cadeaux	☐	☐	☒		☒
H	Voyages payés	☐	☐	☒		☒
I	Dons à une œuvre (au lieu d'honoraires)	☐	☐	☒		☒
J	Compensation > 5 000 \$ d'une source	☐	☒	☐		☐

socle commun A · C · D · E · F (dans tous sauf le PTR) — seule la section B (transactions) nous intéresse

→ B n'existe que dans le PTR, l'annuel (O) et la sortie (T)

l'amendement A reprend les sections du document qu'il corrige (C-H ou O-T)

la **section B** = les transactions (on trade ça) ; le reste (A · C · D · E · F) est un socle commun, la **A** sert à *vérifier*

Complétude (3/5) — la famille « patrimoine », en une planche

cinq types, cinq rôles — les transactions (Schedule B) n'existent que dans O, T et leurs amendements :

FINANCIAL DISCLOSURE REPORT

FILE INFORMATION

NAME: John Doe
STATUS: Member
FILING TYPE: Annual Report

FILE INFORMATION

FILING TYPE: Annual Report
FILING YEAR: 2023
FILING DATE: 05/15/2024

SCHEDULE A: ASSETS AND "UNEARNED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it Earned?
North Carolina Legislative Retirement System Plan (1)	Equity	\$10,000	Retirement	\$1,000	Yes
First Fidelity Asset Manager (2)	Equity	\$50,000	Retirement	\$5,000	Yes

SCHEDULE B: TRANSACTIONS

None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement	\$1,000
First Fidelity Asset Manager	Retirement	\$5,000

SCHEDULE D: LIABILITIES

None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT

FILE INFORMATION

NAME: John Doe
STATUS: Member
FILING TYPE: Annual Report

FILE INFORMATION

FILING TYPE: Annual Report
FILING YEAR: 2023
FILING DATE: 05/15/2024

SCHEDULE A: ASSETS AND "UNEARNED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it Earned?
North Carolina Legislative Retirement System Plan (1)	Equity	\$10,000	Retirement	\$1,000	Yes
First Fidelity Asset Manager (2)	Equity	\$50,000	Retirement	\$5,000	Yes

SCHEDULE B: TRANSACTIONS

None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement	\$1,000
First Fidelity Asset Manager	Retirement	\$5,000

SCHEDULE D: LIABILITIES

None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT

FILE INFORMATION

NAME: John Doe
STATUS: Member
FILING TYPE: Annual Report

FILE INFORMATION

FILING TYPE: Annual Report
FILING YEAR: 2023
FILING DATE: 05/15/2024

SCHEDULE A: ASSETS AND "UNEARNED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it Earned?
North Carolina Legislative Retirement System Plan (1)	Equity	\$10,000	Retirement	\$1,000	Yes
First Fidelity Asset Manager (2)	Equity	\$50,000	Retirement	\$5,000	Yes

SCHEDULE B: TRANSACTIONS

None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement	\$1,000
First Fidelity Asset Manager	Retirement	\$5,000

SCHEDULE D: LIABILITIES

None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT

FILE INFORMATION

NAME: John Doe
STATUS: Member
FILING TYPE: Annual Report

FILE INFORMATION

FILING TYPE: Annual Report
FILING YEAR: 2023
FILING DATE: 05/15/2024

SCHEDULE A: ASSETS AND "UNEARNED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it Earned?
North Carolina Legislative Retirement System Plan (1)	Equity	\$10,000	Retirement	\$1,000	Yes
First Fidelity Asset Manager (2)	Equity	\$50,000	Retirement	\$5,000	Yes

SCHEDULE B: TRANSACTIONS

None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement	\$1,000
First Fidelity Asset Manager	Retirement	\$5,000

SCHEDULE D: LIABILITIES

None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT

FILE INFORMATION

NAME: John Doe
STATUS: Member
FILING TYPE: Annual Report

FILE INFORMATION

FILING TYPE: Annual Report
FILING YEAR: 2023
FILING DATE: 05/15/2024

SCHEDULE A: ASSETS AND "UNEARNED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it Earned?
North Carolina Legislative Retirement System Plan (1)	Equity	\$10,000	Retirement	\$1,000	Yes
First Fidelity Asset Manager (2)	Equity	\$50,000	Retirement	\$5,000	Yes

SCHEDULE B: TRANSACTIONS

None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement	\$1,000
First Fidelity Asset Manager	Retirement	\$5,000

SCHEDULE D: LIABILITIES

None Reported

SCHEDULE E: POSITIONS

O — Annual
bilan annuel

C — Candidate
photo du candidat

H — New Filer
photo d'entrée

T — Termination
photo de sortie

A — Amendment
corrige un dépôt

4 625 · 31 % avec
txns

10 105 · 77 % jamais
élus

395 · 0 txn

392 · 28 % avec txns

2 298 · suit le corrigé

chaque vignette est cliquable → ouvre le vrai document

H et T (les « photos ») serviront à la question 2 —

Cohérence

Complétude (4/5) — ce qu'on y a trouvé : des surprises et des pièges

type O — Annual Report 2015, Nancy Pelosi

SCHEDULE B: TRANSACTIONS

Asset	Owner	Date	Tx. Type	Amount	Cap. Gains > \$200?
Hertz Global Holdings, Inc (HTZ)		07/15/2015	P	\$15,001 - \$50,000	
DESCRIPTION: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16					
Hertz Global Holdings, Inc (HTZ)		07/16/2015	P	\$100,001 - \$250,000	
DESCRIPTION: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16					

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

piège 1 — la répétition : l'amendement re-déclare les trades de l'annuel qu'il corrige (Pelosi 2014 : le même trade **3 fois**, O+A+A) → dédoublonné par la clé naturelle

et les types qui ne portent **aucune** transaction (les 5 administratifs X/D/W/E/G + le blind trust) → *slide suivante*

la **Schedule B** d'un annuel **récapitule les trades de l'année** — au total **57 259** transactions vivent hors des PTR ([ouvrir ce rapport](#))

Complétude (5/5) — les administratifs, et le cas à part

Question 1 · Complétude

cinq types sans aucune transaction : chaque vignette ouvre le vrai PDF



FINANCIAL DISCLOSURE EXTENSION REQUEST

Check of the House of Representatives - Legislative Resource Center - 1100 Cannon Building - Washington, DC 20545

Candidates who are required to file a Financial Disclosure Statement (FDS) under the Ethics in Government Act are permitted to defer filing the report until a later date. This form allows the candidate to request a deferral. The deferral request must be filed with the Clerk of the House of Representatives no later than 30 days before the applicable filing deadline. The Clerk of the House of Representatives will review the request and determine if a deferral is appropriate. If a deferral is granted, the candidate must file the FDS by the extended deadline.


FILER INFORMATION

Name: George A. Brown
State: Ohio

EXTENSION REQUEST DETAILS

Request Date: 11/11/2014
Extension Length: 90 days
New Due Date: 01/11/2015
Report Type Date: Candidate Report
Filing Year: 2015
Original Due Date: 11/11/2014

X — Extension
demande de délai



CAMPAIGN NOTICE REGARDING FINANCIAL DISCLOSURE REQUIREMENT

Check of the House of Representatives - Legislative Resource Center - 1100 Cannon Building - Washington, DC 20545

The Honorable George A. Brown
Office of the Clerk, U.S. House of Representatives
Legislative Resource Center
1100 Cannon Building
Washington, DC 20545

Dear Mr. Brown:

This is to notify you that I have not yet received sufficient contributions or income from myself or others to require the filing of a report for the 2015 campaign for the U.S. House of Representatives.

I understand that when I do raise or spend in excess of \$5,000 for my campaign, I must file a Financial Disclosure Statement with the Clerk of the House of Representatives within the deadline set out in page 2 and 3 of the Financial Disclosure Instruction booklet, a copy of which has been provided to me by the Clerk.

NAME: William A. Brown
STATE/DEPARTMENT: Ohio

SIGNATURE
Digitally signed by William A. Brown, dn: cn=William A. Brown

D — Campaign Notice
« < 5 000 \$ »



CAMPAIGN NOTICE REGARDING FINANCIAL DISCLOSURE REQUIREMENT

Check of the House of Representatives - Legislative Resource Center - 1100 Cannon Building - Washington, DC 20545

The Honorable George A. Brown
Office of the Clerk, U.S. House of Representatives
Legislative Resource Center
1100 Cannon Building
Washington, DC 20545

Dear Mr. Brown:

This is to notify you that I have not yet received sufficient contributions or income from myself or others to require the filing of a report for the 2015 campaign for the U.S. House of Representatives.

I understand that when I do raise or spend in excess of \$5,000 for my campaign, I must file a Financial Disclosure Statement with the Clerk of the House of Representatives within the deadline set out in page 2 and 3 of the Financial Disclosure Instruction booklet, a copy of which has been provided to me by the Clerk.

NAME: William A. Brown
STATE/DEPARTMENT: Ohio

SIGNATURE
Digitally signed by William A. Brown, dn: cn=William A. Brown

W — idem, papier
(ou retrait)



TERMINATED EMPLOYEE TO FILING EXTENSION

Check of the House of Representatives - Legislative Resource Center - 1100 Cannon Building - Washington, DC 20545

The Honorable George A. Brown
Office of the Clerk, U.S. House of Representatives
Legislative Resource Center
1100 Cannon Building
Washington, DC 20545

Dear Mr. Brown:

This is to notify you that I have not yet received sufficient contributions or income from myself or others to require the filing of a report for the 2015 campaign for the U.S. House of Representatives.

I understand that when I do raise or spend in excess of \$5,000 for my campaign, I must file a Financial Disclosure Statement with the Clerk of the House of Representatives within the deadline set out in page 2 and 3 of the Financial Disclosure Instruction booklet, a copy of which has been provided to me by the Clerk.

NAME: William A. Brown
STATE/DEPARTMENT: Ohio

SIGNATURE
Digitally signed by William A. Brown, dn: cn=William A. Brown

E — Exemption
départ, poste fédéral



GIFT WAIVER

Check of the House of Representatives - Legislative Resource Center - 1100 Cannon Building - Washington, DC 20545

The Honorable George A. Brown
Office of the Clerk, U.S. House of Representatives
Legislative Resource Center
1100 Cannon Building
Washington, DC 20545

Dear Mr. Brown:

This is to notify you that I have not yet received sufficient contributions or income from myself or others to require the filing of a report for the 2015 campaign for the U.S. House of Representatives.

I understand that when I do raise or spend in excess of \$5,000 for my campaign, I must file a Financial Disclosure Statement with the Clerk of the House of Representatives within the deadline set out in page 2 and 3 of the Financial Disclosure Instruction booklet, a copy of which has been provided to me by the Clerk.

NAME: William A. Brown
STATE/DEPARTMENT: Ohio

SIGNATURE
Digitally signed by William A. Brown, dn: cn=William A. Brown

G — Gift Waiver
dérogation cadeau



BSC Trust

Check of the House of Representatives - Legislative Resource Center - 1100 Cannon Building - Washington, DC 20545

The Honorable George A. Brown
Office of the Clerk, U.S. House of Representatives
Legislative Resource Center
1100 Cannon Building
Washington, DC 20545

Dear Mr. Brown:

This is to notify you that I have not yet received sufficient contributions or income from myself or others to require the filing of a report for the 2015 campaign for the U.S. House of Representatives.

I understand that when I do raise or spend in excess of \$5,000 for my campaign, I must file a Financial Disclosure Statement with the Clerk of the House of Representatives within the deadline set out in page 2 and 3 of the Financial Disclosure Instruction booklet, a copy of which has been provided to me by the Clerk.

NAME: William A. Brown
STATE/DEPARTMENT: Ohio

SIGNATURE
Digitally signed by William A. Brown, dn: cn=William A. Brown

B — Blind Trust (23 dépôts) : la banque du *trust* liste de vraies ventes (eBay, Meta, Tesla...), mais pas décidées par l'élu : la fiducie aveugle (cf. Phillips en Cohérence).

Cohérence (1/6) — qui dépose quoi : la couverture réelle

Question 2 · Cohérence

Chambre uniquement

470 entrées au Congrès
(depuis 2014)

82 % ont déposé un **H** (déclaration d'entrée)
16 % un **C** à la place (la loi les dispense du H)
2 % ni l'un ni l'autre → **98 % couverts**

463 sorties définitives

81 % ont déposé un **T** (déclaration de sortie)
86 sans T : partis au Sénat ou à l'exécutif (dispensés),
décès, départs très récents


presque chaque entrée a sa **photo de patrimoine** — mais une entrée sur cinq qui ressort ne laisse **pas de photo de sortie**

c'est cette disponibilité, et elle seule, qui décide de qui sera vérifiable de bout en bout

Cohérence (2/6) — les 900 de la fenêtre : qui est testable de bout en bout ?

Question 2 · Cohérence

Chambre uniquement




439 déjà en poste en 2014 (pas de photo d'entrée) · **437** encore en poste en 2026 (pas de photo de sortie) → seuls les **149 entrés PUIS sortis** peuvent avoir les **deux** photos

Cohérence (3/6) — de 149 cycles complets à 56 réellement testables

Question 2 · Cohérence

Chambre uniquement



la moitié des membres à double photo **ne détient aucune action cotée** (fonds, comptes gérés, immobilier)

la photo d'entrée : 252 ancrés par un **H** · 32 par un **C** (dispensés de H) = **284** portefeuilles d'entrée datés · les **616** autres sans **photo d'entrée** (435 déjà là en 2014 + 181 entrés depuis, tous sans H/C)

Cohérence (4/6) — le résultat : les portefeuilles se recourent

Question 2 · Cohérence

Chambre uniquement

entrée + transactions reconstruisent la sortie ;
on part à **78,7 %** (~21 % manquant) et on
monte l'escalier :

- PTR électroniques **78,7 %**
- + PTR papier **78,8 %**
- + annuels O/A **84,2 %**
- + Schedule B du T **87,8 %**


résidu vraiment inexpliqué : 3,3 %

= 45 positions chez 14 membres · le reste des
« trous » = du **non-filing documenté** (l'élue a
déclaré ailleurs), pas un trou de collecte


blind trust **Phillips** : 284 positions à l'entrée → 1 à
la sortie = 0 faux trou

Les portefeuilles se recourent : entrée (H) + PTR ≥ sortie (T), et année par année via les annuels (O)

C-a : la sortie (T) expliquée à 78,7 %
position-ticker · cohorte HAT élec (45 membres)



C-b : l'annuel N+1 expliqué par N + achats — 85,0 %
position-ticker · 2508 paires d'annuels élec (533 membres)



Cohérence (5/6) — ce que les O/A/T ajoutent : du patrimoine, pas du signal

Question 2 · Cohérence

Chambre uniquement

les annuels (O), amendements (A) et sorties (T) déclarent **aussi** des transactions — souvent les mêmes, re-déclarées ; une fois les doublons **et** les échos PTR retirés, il reste :

26 115

trades jamais vus dans
un P

22 216

via les annuels O

3 899

via sorties +
amendements

374 j

délai médian trade →
pub.

ces trades **comblent des trous du portefeuille** (l'élue oublie son P mais l'inscrit à l'annuel) —
découverts **~1 an trop tard** : ils nourrissent le **patrimoine**, jamais le **signal**

les 26 115 sont surtout des **ETF/fonds cotés**, pas un sous-total des 57 259 Schedule B (deux mesures parallèles) ; les
vraies **actions** manquantes au signal = **173**, toutes pré-2018

Cohérence (6/6) — reconstruire n'est pas vérifier

Question 2 · Cohérence

Chambre uniquement

900 · membres passés par la Chambre, 2014–2026

825 · RECONSTRUITS

photo d'entrée + transactions → série datée par membre

56 · VÉRIFIÉS

... et confirmés par la photo de sortie
(entrée + flux $\supseteq$ sortie, réellement testé)


les autres :
reconstruits, mais
pas vérifiables
(photo de sortie
manquante,
ou rien de côté)

on **reconstruit** une série datée pour **825** membres ; on ne peut la **prouver** de bout en bout que pour **56** — le petit est *dans* le grand, les deux ne s'additionnent jamais

Corroboration — le mécanisme : des tuples et des ensembles


Question 3 · Corroboration

Quiver = fournisseur commercial, vérité-terrain externe — **jamais réinjecté**




comparer les deux corpus = tester l'**appartenance à un ensemble de tuples** — jamais un *merge*

NOUS (169 000) **QUIVER**



au tuple (élu, ticker, sens), fenêtre 2014-2026 — c'est le niveau 1 ; les niveaux 2 et 3 : slide suivante

Corroboration — trois niveaux de stricteesse, et qui a raison sur les dates



on serre la vis cran par cran — chaque écart reçoit un verdict :

CONCORDANT · **ÉCART DATE** · **ÉCART TICKER**
NON-COTÉ · **NOUS SEULS** · **MANQUANT**
PAPIER · **NOTRE MANQUE (vrai trou)**

N3 — sens : 96,8 % Ch. · 99,9 % Sén.

N3 — montant : 94,2 % · 99,8 %

N2 — les dates : pour un même (élu, ticker, sens), on apparie **notre date** à **celle de Quiver** (≤ 10 j) ; quand elles divergent dans un **même dépôt**, **545 candidats** méritent l'œil → on **rouvre le PDF** :

le PDF montre. . .	exemple réel	traitement
coquille du déposant, prouvable	3031-04-30	corrigée → 2021
coquille littérale	01/35/22	transcrite telle quelle
notre OCR s'est trompé	Khanna/COST 09-31	re-lue au PDF → 08-16
désaccord Quiver	McCaul/GOOGL $\Delta 11$ j	arbitré au PDF

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

Corroboration — cinq preuves de plus, et un principe

Univers officiel

index du *House Clerk* re-téléchargé :
100 % des **8 252 PTR** traités — par-
sés, OCRisés ou écartés par règle
écrite

senate-stock-watcher

collecte indépendante, 6 231 txns
2014-2020 : **100 %** retrouvées (hors
36 échanges, comptés en 2 lignes
chez eux) — sur-ensemble strict

house-stock-watcher

miroir indépendant 2018-2026 :
99,5 % de ses lignes chez nous ; ses
manques pré-2018 → tous traités

Kadoa

agrégateur tiers : comptes par dé-
posant, triangulation automatisée
(test_crosscheck) — confirme les
déposants où notre OCR est l'**unique**
source


Golden = non-régression

on fige une **empreinte SHA-256** de
chaque table livrée (**368** : 230 Ch. +
138 Sén.) ; à chaque re-run on la re-
calcule et on exige **le même octet** →

le principe

aucune source externe n'est **réinjec-
tée** dans les tables — elles ne servent
qu'à **mesurer** ce qu'on a


Partie 5 — Le livrable



Qu'est-ce qu'on livre, et avec quelles limites ?

Du corpus à la table de recherche : l'entonnoir A→D

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



le principe : on ne retire que l'**avéré inutilisable** — **169 000** → **134 464** (79,6 % conservées) :

A — dates cohérentes (trade daté avant sa publication) : -3 252

B — actions + ETF cotés (un backtest exige un prix de marché ; munis, obligations, non-coté retirés) : -29 771

C — direction claire (achat ou vente ; les « échanges » n'ont pas de sens directionnel) : -826

D — montant présent (milieu de fourchette) : -687

sauvetage « ticker-first » — **21 878** lignes à case « type d'actif » vide **gardées** : le **ticker coté** fait foi, pas la case déclarée (vide dans 16-31 % des cas)

le doute est **flagué**, jamais retiré : late filing **12,2 %** · délistés **2,6 %** · lots multi-comptes **8,8 %** · symbole recyclé **0,4 %**

Du symbole au prix : la couverture, et son biais assumé

4 618 symboles distincts dans la table
ticker_yahoo — 84 renommages appliqués (FB→META...)

3 350 servis par Yahoo
— 1 268 **délistés sans successeur coté**

3 289 exploitables
— 61 séries corrompues (garde-fou : prix < 0,10 \$, saut > 300 %)

87,8 % des trades ont un prix fiable

118 029 trades couverts sur 134 429

biais de survie assumé — un titre mort depuis (faillite, rachat sans successeur) ne peut plus être valorisé : couverture **74 %** en 2014 → **99 %** en 2026

la limite est **écrite**, pas cachée — les lignes non couvertes restent dans la table, flaguées

La table finale : 134 464 × 36 — ce qu'il y a dedans

data/clean/transactions_backtest_2014_2026.csv — 134 464 lignes × 36 colonnes · 372 membres · traçable ligne à ligne (doc_id)

membre	ticker	sens	transaction	montant \$	secteur
Bob Gibbs	INTC	buy	2014-12-30	8 000,5	Info. Tech.
Greg Gianforte	BBAVY	sell	2018-12-12	32 500,5	Cons. Staples
Kim Schrier	AAPL	buy	2021-11-15	375 000,5	Info. Tech.
Tim Moore	HOG	buy	2025-12-09	32 500,5	Cons. Discr.

4 lignes réelles — le montant est le **milieu exact de la fourchette** STOCK Act (d'où les « ,5 »)

les 36 colonnes, par famille :

- **identité** — bioguide_id, chambre, parti & commissions à la date du trade
- **dates** — transaction, publication, retard (médiane 27 j)
- **montant** — milieu de fourchette, renseigné à **99,4 %**
- **instrument** — ticker_yahoo, secteur GICS, etf_proxy
- **flags + traçabilité** — document source par ligne


composition

Chambre **91,3 %** · Sénat 8,7 % · achats **50,8 %** / ventes 49,2 % · actions **95,9 %**

limites écrites

- **582 PTR manuscrits** écartés (7,1 % de l'index, avant 2020)
- **biais de survie** prix (slide précédente)
- validée de l'extérieur : *Partie 4 — Corroboration*

Ce qu'il faut retenir



100 %

de l'univers officiel
(8 252 PTR) traité

169 000

transactions uniques,
identifiées à 100 %

> 92 %

corroborés dehors —
87,8 % cohérents
dedans

134 464

lignes × 36 colonnes,
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites


PARTIE II

Le backtest

reconstruire les portefeuilles, copier les meilleurs, mesurer l'alpha face au SPY

Le plan : deux stratégies, un même verdict

la donnée est prête — **copier les élus rapporte-t-il de l'alpha ?**



une seule chose distingue les deux stratégies : **QUI** on copie (talent vs Sharpe). Le reste — **COMBIEN** (K) · **QUAND** (cadence) · **COMMENT** (pondération) — n'est qu'un **réglage**, testé à l'identique sur les deux.

même moteur de portefeuille, mêmes réglages — seule la règle de sélection change

Chapitre A

Construire le portefeuille

un flux de trades → une NAV valorisée jour par jour

Le moteur — un flux de trades devient un portefeuille en parts

entrée : **118 029** trades exploitables (sur 134 429 ; prix Yahoo blindés) ; montant = milieu de fourchette STOCK Act ; $\tau = 1^{\text{re}}$ séance cotée $\geq$ date du trade

acheter → recevoir des parts

$$q = \frac{\text{montant}}{P_i(\tau)}$$

vendre → en rendre (short interdit)

$$q^- = \min\left(\frac{\text{montant}}{P_i(\tau)}, n_i\right)$$

cumuler, puis valoriser

$$n_i(t) = \sum_{\text{trades} \leq t} \pm q \quad V(t) = \sum_i n_i(t) P_i(t)$$

Nancy Pelosi — valeur du portefeuille $V(t)$: 135 trades (pointillés gris = les achats)




$V(t)$ mélange apports et performance → il faut un rendement qui les sépare

Le rendement time-weighted : un apport n'est jamais une performance

on valorise **les parts d'hier** aux prix d'aujourd'hui — l'argent frais n'entre qu'au lendemain (winsor \$50 %/jour)

$$r_P(t) = \frac{\sum_i n_i(t-1) P_i(t)}{\sum_i n_i(t-1) P_i(t-1)} - 1 \quad \text{NAV}(t) = \prod_{s \leq t} (1 + r_P(s))$$

les 266 portefeuilles reconstruits, chacun base 100 à son premier jour actif — médianes : CAGR 12,8 %, Sharpe 0,71, maxDD -36 %



266 portefeuilles reconstruits — médianes : CAGR 12,8 %, Sharpe 0,71


Chapitre B · Stratégie 1

Repérer et copier les « talents »

qui bat le SPY ? on classe par l'IR et l'alpha, on copie le top- K

La porte d'entrée : 223 membres sur 266 sont jugeables

éligible $\iff n_{\text{trades}} \geq 10$ et $n_{\text{jours}} \geq 126$ (~ 6 mois de bourse)



sous les seuils : trop court pour distinguer chance et talent — **exclus du jugement**, pas des données

Deux mètres pour « battre le SPY » : l'écart brut (IR) ou l'alpha ajusté du β

Mètre 1 · IR — suppose $\beta = 1$ (x = excès quotidien / SPY)

$$x(t) = r_P(t) - r_{SPY}(t) \quad IR = \frac{\bar{x}}{\sigma(x)} \sqrt{252}$$


Mètre 2 · appraisal — estime β (MCO), le retire

$$r_P = \alpha + \beta r_{SPY} + \varepsilon$$

$$\beta = \frac{\text{Cov}(r_P, r_{SPY})}{\text{Var}(r_{SPY})} \quad \text{appr} = \frac{\alpha}{\sigma(\varepsilon)} \sqrt{252}$$

Le test (n = jours de bourse du membre ; unilatéral)


$$t_{IR} = IR \sqrt{\frac{n}{252}} \quad t_{appr} = \frac{\alpha}{\sigma(\varepsilon)} \sqrt{n} \quad \text{seuil } t > 1,645$$



la pente absorbe le marché ; l'ordonnée à l'origine,
c'est le talent

La mesure ne trouve presque rien : 20 « gagnants », 12 après le β , 11 par hasard

diagnostic **rétrospectif** (*in-sample*) : tout l'historique jugé d'un coup ($\approx 2014 \rightarrow$ mi-2026), sur les **223 éligibles**
— *pas* encore de walk-forward




20 membres battent le SPY à l'IR, **12** seulement une fois le β retiré (appraisal) — pour ≈ 11 attendus par pur hasard (5 % de 223)

On copie le top- K en parts — sans jamais regarder le futur

walk-forward : à chaque coupe fin Y , on classe les éligibles ($t_{\text{crit}} > 1,645$) et on tient le top- K toute l'année $Y+1$ — **aucune info postérieure à la coupe**

en parts : chaque élu k = un fonds de prix NAV^k ; à la coupe on **redéploie** le capital W sur la nouvelle sélection, puis buy-and-hold jusqu'à la coupe suivante


11 coupes, fin 2015 → fin 2025 ; autofinancé (la NAV est continue) — la mécanique en 3 temps, ci-après



le vivier à chaque coupe : de quoi alimenter un top- K
chaque année

Le moteur en parts, en détail : compter, redéployer, tenir

membre k = un fonds au prix de part $\text{NAV}^k(t) = \prod_{s \leq t} (1 + r_k(s))$; on en détient nbr^k parts; poids cibles $w_k = 1/|S_Y|$; capital initial $W = 100$




autofinancé — aucun apport, aucun retrait : la NAV est continue

entre deux coupes les poids DÉRIVENT (buy-and-hold, pas constant-mix)

Top-4 : +3,1 %/an d'excès... mais $t = 0,94$, et l'alpha dit zéro

Stratégie 1 · réglage de base — $K = 4$ fixe, équipondéré, annuel

1 année civile = 1 observation : $x_Y = \prod_{t \in Y} (1 + r_{\text{strat}}) - \prod_{t \in Y} (1 + r_{\text{SPY}})$; $t = \bar{x}/\sigma(x) \cdot \sqrt{11}$; seuil $t_{10} \approx 1,81$



+3,1 %/an
excès brut
7/11 années

$t = 0,94$
< 1,81 —
indiscernable du hasard


$\beta = 1,20$
l'excès = du style,
pas du talent

$\alpha \approx 0$
 $t_{\text{appr}} -0,13$;
appraisal -2,5 %/an

On pousse : optimiser le nombre K , accélérer la cadence

Stratégie 1 · on fait varier **COMBIEN** (K) et **QUAND** (cadence)

le top-4 ne passe pas → on laisse K s'ajuster chaque année ($K^*(Y) = \arg \max_{K \in [4, 20]}$ score sur le passé, walk-forward) et on rebalance tous les 6 mois



COMBIEN — K walk-forward, annuel : +4,1 %/an, $t = 1,58$

QUAND — top-4 fixe, 6 mois : +0,4 %/an, $t = 0,14$

plus de liberté sur K et la cadence — le t monte un peu, ne passe jamais le seuil (1.81)

On pousse encore : changer la répartition du capital

jusqu'ici capital à parts égales ($1/K$). Mêmes K membres — on change seulement le découpage du capital, par le risque

(cadre : $w_k \geq 0$, $\sum_k w_k = 1$; $\Sigma_{ij} = \rho_{ij} \sigma_i \sigma_j$)

inverse-vol $\sigma_k = \text{std}(r_k) \sqrt{252}$

$$w_k = \frac{1/\sigma_k}{\sum_j 1/\sigma_j}$$

ERC contributions au risque égales


$$w_k(\sum w)_k = w_j(\sum w)_j \quad \forall k, j$$

GMV variance minimale, long-only

$$w^* = \arg \min_{\sum w=1, w \geq 0} w^\top \Sigma w$$

+ Σ stabilisée par shrinkage (Ledoit-Wolf) — annexe

t et t_{appr} par pondération en légende de la figure ; GMV $\times$ sél. appraisal **sur-ajuste** ($-4,5 \%$ /an) — **max** $t_{\text{appr}} = +0,48$,



Chapitre C · Stratégie 2

Changer de règle : le Sharpe


ni K , ni la cadence, ni les poids n'ont passé le seuil — on change la règle de sélection

Nouvelle règle : classer au Sharpe brut, sans test de significativité

Stratégie 2 · on change **QUI** (la règle de sélection) — les réglages restent les mêmes

$$\text{Sharpe} = \frac{\overline{r_P}}{\sigma(r_P)} \sqrt{252}; \quad \text{éligible v2} \iff n_{\text{jours}} \geq 126 \text{ et } \text{Sharpe} > 0,4 \text{ — plus aucun test t}$$


les 263 membres à ≥ 126 jours : 224 éligibles v2 (Sharpe > 0,4) — plus aucun test t



224 éligibles (vs 223 en stratégie 1 — presque les mêmes) ; **même moteur** de copie en parts, seule la règle de classement change

au prix d'admettre des historiques courts en tête (Fetterman 284 j, Sewell 4 trades)

Même résultat : le t plafonne à 1,22, loin du seuil



balayage K de 2 à 20 (poids $1/K$, annuel), plus 5 pondérations $\times 2$ cadences ($K = 5/10/20$) : le meilleur cas reste $K = 6, t = 1,22 (< 1,81)$; l'excès se dilue quand K grandit

Sharpe 0,93 vs SPY 0,87 (fenêtre de tenue) — le couple rendement/risque ne bouge pas ; pas mieux que la stratégie 1

Conclusion : un β de style $\approx 1,2$ — et zéro alpha, sous tous les réglages

ni *qui* (talent vs Sharpe), ni *combien* (K), ni *quand* (cadence), ni *comment* (pondération) — **aucun réglage ne fait apparaître d' α**

$$t = 1,58$$

max, stratégie 1
(K walk-forward ; seuil
1,81)

$$t = 1,22$$

max, stratégie 2
(Sharpe $K=6$; seuil
1,81)

$$t_{\text{appr}} + 0,99$$

max ajusté du β ,
toutes stratégies (seuil
1,645)

$$\beta \approx 1,20$$

l'excès brut n'était
que du style

savoir que ça ne marche pas — **et pouvoir le prouver** — est déjà un actif de recherche

Annexe · Partie II

Sous le capot

le détail technique : shrinkage de Σ , et la contre-preuve membre par membre

Le shrinkage répare l'estimateur de Σ — pas la stratégie

$$\Sigma_{\text{shrink}} = \delta F + (1 - \delta) \Sigma_{\text{emp}}, \quad \delta = \frac{\pi - \rho}{T\gamma} \text{ borné à } [0, 1] \text{ — 3 cibles } F : \text{ diagonale (LW 2004)} \cdot \text{ single-factor (LW 2001)} \cdot \text{ corrélation constante (LW 2003)}$$

top-4 (sélection IR) : le GMV sous 4 estimateurs de Σ — les courbes se confondent presque



—4,5 → —4,3

%/an : l'artefact GMV
(sél. appr) tempéré

—2,76 →
—2,46

le t remonte...
sans devenir positif

50 → 25


conditionnement
de Σ (LW diag)

0,67 → 0,55

concentration HHI
du panier GMV

intensité mesurée $\delta_{\text{LW}} \approx 0,05$ — verdict invariant à l'estimateur : β de style $\approx 1,20$, zéro α

La contre-preuve point par point : la queue droite de l'IR, c'était du β



au-dessus de la diagonale : classé par l'IR **grâce à son β** — l'ajustement dégonfle la queue droite
c'est la version « membre par membre » du 20 → 12 : on juge chaque stratégie en excès brut **et** en t_{appr}

PARTIE III

Tables de données

membres · tickers · panel annuel — la donnée comprise avant toute stratégie

Quatre tables livrées — chaque colonne a une histoire

372 × 94

membres.csv

1 ligne = 1 élu

4 618 × 40

tickers.csv

1 ligne = 1 titre

2 628 × 11

membres_annees.csv


1 ligne = (élu, année)

145

colonnes documentées
(le dictionnaire)

aucune stratégie ici : de la donnée **propre, comprise et auditable** — cette partie raconte l'histoire visuelle
derrière ces colonnes, une figure par famille

Rien n'entre dans les tables sans passer l'entonnoir



des 169 000 dépôts bruts, seuls les trades à **prix exploitable** alimentent les quatre tables — et la chaîne des élus
suit : 372 → 359 → 266 reconstruits → 223 éligibles

118 029 trades exploitables

223 élus éligibles (≥ 10 trades, ≥ 126 j)

Nancy Pelosi

Democrat · house · état CA · congrès 113→119 · 39 ans de mandat

leader : OUI — House Minority Leader|Speaker of the House

comités : —


secteurs sous juridiction : —

94 colonnes en **6 familles** (identité, activité, portefeuille, durées, risque-perf, comportement) ; pour les incarner,
un fil rouge : Nancy Pelosi

372 fiches


6 familles de colonnes

Toute son activité tient en une figure



chaque point est un trade daté et monté — **achats en vert**, **ventes en rouge**, montants en échelle log ; en bas, le rythme par année


Son portefeuille, reconstruit jour après jour



la reconstruction **FIFO datée** donne la valeur $V_m(t)$ et les poids de chaque titre à chaque instant — le rendement est **time-weighted**, jamais estimé

un portefeuille en parts, valorisé jour par jour


Les élus gardent : une position sur deux vit plus de 910 jours



l'estimateur de **Kaplan-Meier** traite honnêtement les positions jamais revendues : **censurées**, pas ignorées —
sinon les durées seraient sous-estimées

44 % des parts jamais revendues (tous élus)

100 \$ investis « comme elle » : devant le SPY, mais sans certitude




+3,4 % de croissance par an au-dessus du SPY... mais ni l'alpha ($t = 0,64$) ni l'IR ($t = 1,06$) ne passent le seuil de 2 : **indiscernable de la chance**

+3,4 %/an vs SPY

aucun $t \geq 2$ — non significatif


Le même duel, ligne par ligne : le panel annuel



chaque barre est une ligne de `membres_annees.csv` — 2 628 couples (élu, année) prêts pour l'économétrie

2 628 × 11


Le comportement aussi devient des colonnes



alignement avec ses comités, répétition, co-achat : trois signaux mesurés pour chaque élu, comparés à la médiane des 223

16,4 % des achats alignés comité (tous élus)


Le même récit, vu du ticker : NVDA sous l'œil du Congrès



tickers.csv renverse la perspective : pour 4 618 titres, **qui achète, qui vend, et quand** — triangles proportionnels aux montants

4 618 × 40


D'une élue aux 223 : les distributions derrière les fiches



volatilité, durées de détention, notionnels par titre : chaque statistique individuelle se lit dans sa distribution

223 élus éligibles

Le verdict, trade par trade — 58 926 achats notés face au SPY



même pour elle — 63 % d'achats gagnants, médiane +5,0 % — le t reste **sous 2** ; et l'élus médian, lui, sous-performe : **-1,62 %** sur l'ensemble des 58 926 achats évalués

elle : $t = 1,89 < 2$

tous élus : excès médian **-1,62 %**

8 contrôles sur 8 — la valeur de ces tables, c'est leur transparence

8 / 8

contrôles croisés
entre les 3 tables

4 CSV

livrés, chaque colonne
documentée

3 preuves

recalcul à la main ·
2^e méthode ·
recoupements

0 alpha

significatif dans
les fiches

un seul contrôle échoue → **aucun CSV n'est écrit**

nous ne livrons pas un alpha, nous livrons des **données comprises** — la stratégie peut maintenant commencer