

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Le plan — cinq étapes, une promesse



à la fin : vous saurez **ce que contient la table, comment elle a été construite, et pourquoi on peut lui faire confiance** — limites comprises.

cadre légal : STOCK Act 2012 — chaque élu du Congrès doit déclarer ses transactions boursières sous **45 jours** (*Periodic Transaction Report*, « PTR »)

Partie 1 — Ce qu'on a récupéré : la donnée brute



Où vivent ces données, et à quoi ressemblent-elles vraiment ?

La Chambre — le point de départ : le site officiel


The screenshot shows the official website of the Clerk of the U.S. House of Representatives. The header includes the Clerk's logo and the text 'UNITED STATES HOUSE of REPRESENTATIVES'. A navigation bar contains links for LEGISLATIVE INFORMATION, MEMBER INFORMATION, COMMITTEE INFORMATION, DISCLOSURES, and ABOUT THE CLERK. The main content area is titled 'FINANCIAL DISCLOSURE REPORTS' and includes a section 'WHAT ARE FINANCIAL DISCLOSURE REPORTS?'. A red box highlights the 'DOWNLOAD FINANCIAL DISCLOSURE REPORTS BY YEAR' link and the list of years from 2008 to 2026. Below this, there is a section 'FOR MEMBERS AND STAFF' with links to 'Financial Disclosure Online Reporting Application' and 'Instruction Guide for Financial Disclosure Statements and Derivative Transaction Reports'.

disclosures-clerk.house.gov (clicable)

on part du site public de la Chambre :

- une **liste de téléchargements**
- une **archive par année** (zone encadrée)
- on prend les années **2014 → 2026**


La Chambre — l'archive ZIP contient l'index XML



```
2024FD.xml — index annuel du House Clerk

3  <Member>
4  <Prefix />
5  <Last>Abel</Last>
6  <First>William</First>
7  <Suffix />
8  <FilingType>C</FilingType>  ← type C : pas un PTR, ignoré
9  <StateDst>TX31</StateDst>
10 <Year>2024</Year>
11 <FilingDate>5/12/2024</FilingDate>
12 <DocID>10060658</DocID>
13 </Member>
- 2 256 dépôts dans l'index 2024 -
245 <Member>
246 <Prefix>Hon.</Prefix>
247 <Last>Allen</Last>
248 <First>Richard W.</First>
249 <Suffix />
250 <FilingType>P</FilingType>  ← type P : un PTR, on le garde
251 <StateDst>GA12</StateDst>
252 <Year>2024</Year>
253 <FilingDate>1/11/2024</FilingDate>
254 <DocID>20024277</DocID>  ← le n° → l'URL du PDF
255 </Member>
```

12 types de dépôts — le backtest n'en lit qu'un : P




P = *Periodic Transaction Report* (les « PTR ») — les **déclarations de transactions boursières**, datées, sous 45 jours.

et les 11 autres types ? on les ouvre TOUS en Partie 4 — Vérification


35 315 dépôts au total · 8 252

PTR

Un DocID, un PDF — et deux mondes



lisible — 71 %



scanné — 29 %

Le document lisible : un PTR électronique



Filing ID #20009426

PERIODIC TRANSACTION REPORT

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

FILER INFORMATION

Name: Hon. John A. Yarmuth
Status: Member
State/District: KY03

TRANSACTIONS

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Altria Group, Inc. (MO) [ST] FILING STATUS: New	S (partial)	03/23/2018	04/07/2018	\$1,001 - \$15,000	☒
	Boeing Company (BA) [ST] FILING STATUS: New	S (partial)	03/15/2018	04/07/2018	\$1,001 - \$15,000	☒
	Micron Technology, Inc. (MU) [ST] FILING STATUS: New	P	03/27/2018	04/07/2018	\$1,001 - \$15,000	☐
	Wells Fargo & Company (WFC) [ST] FILING STATUS: New	S (partial)	03/20/2018	04/07/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

INITIAL PUBLIC OFFERINGS

☒ Yes ☐ No

CERTIFICATION AND SIGNATURE

☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.

Digitally Signed: Hon. John A. Yarmuth , 05/02/2018

DocID en 2... → couche texte

- un PDF **lisible par machine**
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification) + fourchette de montant
- lisible... mais pas si régulier : **le défi** sur la slide suivante

Le défi : un PDF lisible n'est pas un tableau régulier

TRANSACTIONS						
ID	Owner Asset	Transaction Type	Transaction Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/17/2018	04/17/2018	\$15,001 - \$50,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	S	04/17/2018	04/17/2018	\$15,001 - \$50,000	☐
	Microsoft Corporation (MSFT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$50,000	☐
	Spectra Energy Partners, LP Common Units representing Limited Partner Interests (SEP) [ST] une seule transaction, libellé sur 4 lignes SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

le PDF n'est **pas** un **tableau régulier** :

- le **montant** déborde sur la ligne suivante (\$15,001 – puis \$50,000)
- le **libellé** d'un actif court sur **4 lignes**
- un découpage ligne à ligne raterait la moitié

→ on **reconstruit** chaque transaction
(recollage des lignes coupées)
avant de la lire

le montant coupé à lui seul : **7 996** lignes réparées

extrait réel (Hon. Bob Gibbs, OH07) — cadres ajoutés

Le monde scanné : trois formes de difficulté

un scan n'est pas du texte, c'est une **image** — et il arrive sous trois formes (pages réelles) :

This is a scanned image of a typed form from the United States House of Representatives. The form is titled "PARTIAL TRANSACTION REPORT" and contains fields for NAME, OFFICE TELEPHONE, and LEGISLATIVE FINANCE CENTER. It includes checkboxes for "Member of the U.S. House of Representatives" and "Office or Employee". The form is filled out with typed text, including "Adam Bernice Schiff" and "202-225-4176".

Tapé, droit

dactylographié, lisible tel quel

This is a scanned image of a typed form from the United States House of Representatives, oriented vertically. The form is titled "PARTIAL TRANSACTION REPORT" and contains fields for NAME, OFFICE TELEPHONE, and LEGISLATIVE FINANCE CENTER. It includes checkboxes for "Member of the U.S. House of Representatives" and "Office or Employee". The form is filled out with typed text, including "Adam Bernice Schiff" and "202-225-4176".

Tapé, couché

tapé mais **tourné à 90°**

(le plus courant)

This is a scanned image of a handwritten form from the United States House of Representatives. The form is titled "PARTIAL TRANSACTION REPORT" and contains fields for NAME, OFFICE TELEPHONE, and LEGISLATIVE FINANCE CENTER. It includes checkboxes for "Member of the U.S. House of Representatives" and "Office or Employee". The form is filled out with handwritten text, including "George E. Holding" and "202-225-3032".

Manuscrit

rempli à la main, en cursif

93 261 transactions — 55,2 % du corpus

lues par OCR (Claude Vision) — *détail en Partie 2 — le pipeline*

 UNITED STATES SENATE
FINANCIAL DISCLOSURES

United States Senate Financial Disclosures (eFD)

Public disclosure of a government official's personal financial interests is a key component to an effective code of conduct. For more information on filing, including who files, and the types of reports filed, see the [United States Senate's Select Committee on Ethics website](#).

Select Reports are Available

This site includes financial disclosure reports for Senators, former Senators and Senate candidates filed from 2012 to present. Senator reports are available for six years from the date a Senator ceases to be a Member of Congress. Candidate reports are available for one year after the individual is no longer a candidate.

Additional Reports

All financial disclosure reports are available through the Office of the Secretary of the Senate kiosk:

Office of Public Records
144 Hart Senate Office Building
Washington, D.C. 20510-7116
phone (202) 224-0322

Get Access

You must agree to the following to be able to search reports.

Title 1 of the Ethics in Government Act of 1978, as amended, 5 U.S.C. app. § 105(c), states that:

1. It shall be unlawful for any person to obtain or use a report:
 1. for any unlawful purpose;
 2. for any commercial purpose, other than by news and communications media for dissemination to the general public;
 3. for determining or establishing the credit rating of any individual; or
 4. for use, directly or indirectly, in the solicitation of money for any political, charitable, or other purpose.
2. The Attorney General may bring a civil action against any person who obtains or uses a report for any purpose prohibited in paragraph (1) of this subsection. The court in which such action is brought may assess against such person a penalty in any amount not to exceed \$10,000. Such remedy shall be in addition to any other remedy available under statutory or common law.

☐ I understand the prohibitions on obtaining and use of financial disclosure reports.

la barrière : accord + jeton (CSRF)

- la case encadrée : l'**accord obligatoire** avant toute recherche
- notre collecteur l'accepte et récupère le **jeton de session**
- ensuite seulement : on peut **chercher** (slide suivante)

efdsearch.senate.gov — la page d'accès (capture réelle)

Le Sénat — chercher (Senator × PTR), puis la liste

UNITED STATES SENATE
FINANCIAL DISCLOSURES

Find Reports

Find Reports

Note: Reports will display in the format they were filed: either electronically (text) or on paper (images).

Search Options

Filer Name ? First name (starts with) Last name (starts with)

Filer Type ☒ Senator ☐ Candidate ☐ Former Senator

All States All States

Report Types ? ☐ Annual ☐ Due Date Extension ☐ Other Documents ☒ Periodic Transactions ☐ Blind Trusts

Date Filed/Received ? From To

When selected, reports will open in a new tab or window.

Search Reports

le formulaire : on coche **Senator × PTR**

UNITED STATES SENATE
FINANCIAL DISCLOSURES

Find Reports

Note: Reports will display in the format they were filed: either electronically (text) or on paper (images).

Search Again

Search Results

Reports will open in a new tab or window.

Filter list by name, office, report type, date

Showing 1 to 25 of 1,705 entries

First Name (Middle)	Last Name (Suffix)	Office (Filer Type)	Report Type	Date Received/Filed
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 06/26/2025	06/26/2025
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 08/10/2025	08/10/2025
James	Banks	Banks, James E. (Senator)	Periodic Transaction Report for 03/10/2025	03/10/2025
John A	Barrasso	Barrasso, John (Senator)	Periodic Transaction Report for 05/24/2018	05/24/2018
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 07/12/2021	07/12/2021
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 05/16/2023	05/16/2023
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 02/07/2017	02/07/2017
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 04/02/2019	04/02/2019
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 09/02/2020	09/02/2020
Michael F	Bennet	Bennet, Michael (Senator)	Periodic Transaction Report for 10/18/2022	10/18/2022

la liste réelle : **1 705** rapports, un lien par dépôt

les PTR sont **un type parmi d'autres** (Annual, Blind Trusts, Extensions. . .) — on envoie `report_types=[11]` ;
un dépôt s'ouvre **dans son format** : **page HTML** (texte) ou **scan** (image)

Le Sénat électronique : une table propre

UNITED STATES SENATE
FINANCIAL DISCLOSURES

Return to the search tab to select another report.

Periodic Transaction Report for 03/10/2025
The Honorable James Banks (Banks, James E.)
Filed 03/10/2025 @ 12:54 PM
[Print Report](#)

The following statements were checked before filing:

- ☒ I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
- ☒ I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

Transactions (1 transaction total) 0 Self 1 Joint 0 Spouse 0 Dependent Child

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	YUM	Yum! Brands Company: Yum (Louisville, KY) Description: Food	Other	Sale (Full)	\$1,001 - \$15,000	--

le cas électronique : table propre, ticker cliquable

13 026 transactions électroniques

- un gabarit de table **stable sur 13 ans** (les 9 mêmes colonnes, détail en Partie 2)
- seul le contenu change : amendements (10 %), ticker « - » = non-coté, cellules parfois vides

Le Sénat papier : un formulaire unique, trois écritures

un seul modèle depuis 2014 (la grille A→L) — cliquer une vignette ouvre le vrai scan :

REGISTRATION STATEMENT OF THE UNITED STATES OF AMERICA December 31, 2013

Section 100: General Information

Secretary of the Society
for the Study of the
History of the
United States
Washington, DC, USA

**REGISTRATION STATEMENT
OF FINANCIAL
TRANSACTIONS**

(Continued)

Record Information

File Number: **13-0000000000** (13-0000000000)

Initial Date: **12/31/2013** (12/31/2013)

Label: **United States Dollars**

Page Number: **1**

Transaction Type	Transaction Date	Transaction Amount	Transaction Description	Account or Transactions (1)									
				Transaction Date	Transaction Amount	Transaction Description	Transaction Date	Transaction Amount	Transaction Description	Transaction Date	Transaction Amount	Transaction Description	Transaction Date
1	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
2	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
3	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
4	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
5	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
6	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
7	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
8	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
9	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
10	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
11	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
12	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
13	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
14	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
15	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013
16	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	1000000000	12/31/2013	1000000000	100				

tapé, droit

3 985 transactions

[illegible]

tapé, couché — 255/373

[illegible]

manuscrit (Roberts)


[illegible]

annexe « courtier » —

format libre

cas à part : page de garde (lettre d'avocat) sans données, ignorée

Sénat papier — le piège des dates : deux natures, deux traitements



date de dépôt → métadonnée eFD

écrite de façons variées (tampon encre, en-tête imprimé)
— mais **jamais OCRisée** : on la lit sur la **fiche eFD**, donc
fiable

→ la date de la **divulgation** (celle de l'anti-look-ahead) est la fiable — délai médian **24 j** au Sénat ; l'OCR ne touche qu'au trade

X		10/23/20	2/3	X
	X	10/30/20	2/6	X
X		11/6/20	2/6	X
			2/7	X
			2/7	X
			2/12	X
X		10/23/20	2/13	X
	X	10/30/20	2/26	X
X		11/6/20	2/7	X

tapee MM/DD/YY (Blumenthal 2025) manuscrite + année



date de transaction → OCRisée

formats variés (tapée · manuscrite · annexe) →
garde-fou : fenêtre **[dépôt -90 j, +10 j]**

Le corpus en un coup d'œil : quatre voies — et une forte concentration

169 000 transactions uniques (2014–2026), quatre sous-corpus :

Sénat OCR 2,4 %



445 déposants distincts — dont 294 avec ≥ 10 transactions

très concentré — Khanna (41 080 txns) et McCaul (27 123) pèsent à eux deux $\sim 40\%$ du corpus, et déclarent **exclusivement sur papier** (100 % OCR)


le papier n'est pas un détail : c'est la majorité du corpus

Partie 2 — Comment on la récupère : le pipeline




Comment passe-t-on de $\sim 10\,000$ documents hétérogènes à une seule table ?


Le flux de bout en bout, en une image




Le flux de bout en bout, en une image



Le flux de bout en bout, en une image




Le flux de bout en bout, en une image



L'identité : chaque nom devient un bioguide

le même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → il faut un **identifiant unique**



100 % des lignes rattachées

367 membres Chambre · 78 Sénat

```
legislators-current.yaml - référentiel congress-legislators
12608 - id:
12609   bioguide: P000197 ← l'identifiant officiel unique
      - (autres identifiants) -
12625   name:
12626     first: Nancy
12627     last: Pelosi
12628     official_full: Nancy Pelosi
12629   bio:
12630     birthday: '1940-03-26'
12631     gender: F
      - mandats successifs -
12661     state: CA
12662     district: 5
12663     party: Democrat
```

le référentiel public *congress-legislators*

Pièges réels, réparés : l'homonyme Bob Casey (C000228 → C001070) · 42 lignes d'Angie Craig sans identifiant, réparées read-time

Les deux pistes électroniques : déterministes de bout en bout

Chambre — 58 728 transactions

1. recoller les lignes coupées

2. repérer la **signature** : opération (P/S/E) + 2 **dates** + fourchette

3. **rattacher** actif et ticker imprimés à proximité

pièges déjoués — le **gabarit change en 2018** → deux **parseurs** routés par signature (sans ça, ≈ 72 ventes perdues rien qu'en 2014) · **205 PTR** déposés après le 31/12 récupérés (l'index annuel fait autorité)

Sénat — 13 026 transactions

1. **liste des dépôts** — recherche paginée, barrière CSRF


2. **page HTML par dépôt** — cache disque (re-run : zéro téléchargement)

3. **lecture des tableaux** — colonnes repérées par mots-clés

en pratique le gabarit est **stable** : les **9 mêmes colonnes** sur les 1 777 pages HTML 2014→2026 (vérifié) — le repérage par mots-clés est une **robustesse**, pas une nécessité

zéro échec silencieux : 102 dépôts sans transaction retenue, tous consignés (vides réels, amendements sans ligne, échecs tracés)

Lire le scanné Chambre : OCR Vision, et un garde-fou



1. redresser — reconnaissance d'orientation (4 candidates)
2. classer — census **2 424 scans** : 74 droits · 1 575 tournés · **775 manuscrits**
3. lire — `tool_use` forcé, JSON strict, **cache versionné** (un re-run ne re-paie rien), prompt durci sur échantillon

gating manuscrit — Quiver (fournisseur commercial des mêmes données — Partie 4) ne corrobore que **12,9 %** du manuscrit (88 % du tapé droit) : dates cursives trop incertaines → **582 écartés**, règle écrite **rejouable**, exceptions explicites (3 déposants + 33 docs curés)

93 261 lignes — très concentrées

Khanna à lui seul **44,0 %** · trio Khanna, McCaul, Harshbarger **77,1 %** — les gros déposants « 100 % papier » vus en Partie 1

Lire le papier Sénat : du formulaire au structuré

[illegible]

l'image .gif, déjà droite

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

actif	Apple Computer Inc
opération	Sale
date du trade	2022-03-14
détenteur	Self
fourchette	code A (1 001–15 000 \$)

3 985 lignes — 14 déposants

- même moteur Vision que la Chambre, sans redressement
 - fusion + enrichissement **en une passe** (dictionnaire de tickers mutualisé)
 - Blumenthal = 38,7 % de la piste, massivement du **non-coté**
- couverture ticker plus basse = **composition, pas défaut**

Partie 3 — Enrichir : les tickers, et le reste



Que faut-il ajouter pour qu'un backtest puisse s'en servir ?

D'abord : résoudre le ticker (une cascade tracée)

1. **explicite** — déjà imprimé
dans la source (l'électronique)



2. **dictionnaire** — le nom vu
ailleurs dans le corpus (le papier)



3. **LLM** filtré « action » — ja-
mais d'obligation/muni tickerisée



4. **récupération** validée par double preuve
— **2 540 lignes** retrouvent leur symbole

ticker renseigné

84,1 % Chambre · **77,9 %** Sénat

couverture = remplissage, pas exactitude —
les vides sont le **non-coté légitime** (munis, obli-
gations, fonds privés), pas des défauts d'extrac-
tion

Ensuite : un secteur GICS, et son ETF

donner un secteur (cascade indépendante) :

1. **yfinance** — le secteur factuel de l'entreprise

2. **LLM** contrainte GICS
(+ garde-fou `is_listed`)

3. **overrides** manuels — les cas connus

secteur renseigné **79,8 %** Ch. · **70,4 %** Sén.

11 secteurs GICS → **11 ETF *Select Sector SPDR*** :

Energy→XLE · Materials→XLB · Industrials→XLI
· Cons. Discr.→XLY · Cons. Staples→XLP ·
Health Care→XLV · Financials→XLF · Info.
Tech.→XLK · Comm. Services→XLC ·
Utilities→XLU · Real Estate→XLRE

l'ETF proxy sert de « panier secteur » quand on veut
exposer un thème plutôt qu'un titre

La table du corpus : le contrat « 12/12 » et la clé naturelle

une clé naturelle de 7 champs :


déclarant · date du trade · actif · opération · fourchette ·
détenteur · chambre

elle exclut **délibérément** :

- le **ticker** — ajouté plus tard (enrichissement), sa présence rendrait la clé instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction

dédup non destructrice :

- les **lots réels** (même titre déclaré plusieurs fois dans un dépôt, comptes Self/Spouse/Joint) sont **préservés** (`occurrence_index`) — jamais de `drop_duplicates()` aveugle
- **dédup cross-année** : une re-divulgation (amendement, rapport annuel) ne compte qu'une fois → -1 920



12 champs métier garantis sur les 2
chambres : qui, quoi, quand (2 dates),
sens, montant, ticker, secteur, ETF, parti,
commissions

Partie 4 — Vérification : rien raté, rien inventé



*Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?*

Vérifier, c'est répondre à trois questions

1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

on ouvre les **11 autres types** de dépôts (C, H, O, T, A...) et on mesure le trou

173

actions résiduelles

2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie

87,8 %

du portefeuille de sortie reconstruit (Chambre)

3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver + stock-watchers + univers officiel — jamais réinjectés


93,5 %

des combinaisons Quiver retrouvées (Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

Complétude (1/4) — la vie déclarative d'un élu, et sa loi

Question 1 · Complétude



chaque étape a son dépôt **et son délai légal** — Schedule **A** = le patrimoine (les photos), Schedule **B** = les transactions ; deux dérogations : un C dispense du H, partir au Sénat/exécutif dispense du T

Complétude (2/4) — la famille « patrimoine », en une planche

cinq types, cinq rôles — les transactions (Schedule B) n'existent que dans O, T et leurs amendements :

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00001

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Ramifery Adams
Status: Member
Party: REP
House: 115

FILING INFORMATION
Filing Type: Annual Report
Filing Year: 2018
Filing Date: 06/15/2018
Period Covered: 01/01/2017 - 12/31/2018

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Employee - John Adams	See Defined	None	\$0	Yes
First Fidelity Asset Manager (2)	Employee - John Adams	See Defined	None	\$0	Yes

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00002

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Ramifery Adams
Status: Member
Party: REP
House: 115

FILING INFORMATION
Filing Type: Candidate Report
Filing Year: 2018
Filing Date: 06/15/2018
Period Covered: 01/01/2017 - 12/31/2018

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Employee - John Adams	See Defined	None	\$0	Yes
First Fidelity Asset Manager (2)	Employee - John Adams	See Defined	None	\$0	Yes

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00003

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Ramifery Adams
Status: Member
Party: REP
House: 115

FILING INFORMATION
Filing Type: New Filer Report
Filing Year: 2018
Filing Date: 06/15/2018
Period Covered: 01/01/2017 - 12/31/2018

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Employee - John Adams	See Defined	None	\$0	Yes
First Fidelity Asset Manager (2)	Employee - John Adams	See Defined	None	\$0	Yes

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00004

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Ramifery Adams
Status: Member
Party: REP
House: 115

FILING INFORMATION
Filing Type: Termination Report
Filing Year: 2018
Filing Date: 06/15/2018
Period Covered: 01/01/2017 - 12/31/2018

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Employee - John Adams	See Defined	None	\$0	Yes
First Fidelity Asset Manager (2)	Employee - John Adams	See Defined	None	\$0	Yes

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

FINANCIAL DISCLOSURE REPORT Filing ID: KAN00005

Chief of the House of Representatives • Legislative Resource Center • 100 Cannon Building • Washington, DC 20540

FILE INFORMATION
Name: John, David Ramifery Adams
Status: Member
Party: REP
House: 115

FILING INFORMATION
Filing Type: Amendment Report
Filing Year: 2018
Filing Date: 06/15/2018
Period Covered: 01/01/2017 - 12/31/2018

SCHEDULE A: ASSETS AND "UNDISBURSED" INCOME

Asset	Owner	Value of Asset	Income Type(s)	Income	Is it an Asset?
North Carolina Legislative Retirement System Plan (1)	Employee - John Adams	See Defined	None	\$0	Yes
First Fidelity Asset Manager (2)	Employee - John Adams	See Defined	None	\$0	Yes

SCHEDULE B: TRANSACTIONS
None Reported

SCHEDULE C: EARNED INCOME

Source	Type	Amount
NC Legislative Retirement System Plan	Retirement Income	\$0

SCHEDULE D: LIABILITIES
None Reported

SCHEDULE E: POSITIONS

O — Annual
bilan annuel

4 625 · 31 % avec
txns

C — Candidate
photo du candidat

10 105 · 77 % jamais
élus

H — New Filer
photo d'entrée

395 · 0 txn

T — Termination
photo de sortie

392 · 28 % avec txns

A — Amendment
corrige un dépôt

2 298 · suit le corrigé

chaque vignette est cliquable → ouvre le vrai document

H et T (les « photos ») serviront à la question 2 —

Cohérence

Complétude (3/4) — ce qu'on y a trouvé : des surprises et des pièges

type O — Annual Report 2015, Nancy Pelosi

SCHEDULE B: TRANSACTIONS

Asset	Owner	Date	Tx. Type	Amount	Cap. Gains > \$200?
Hertz Global Holdings, Inc (HTZ)		07/15/2015	P	\$15,001 - \$50,000	
DESCRIPTION: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16					
Hertz Global Holdings, Inc (HTZ)		07/16/2015	P	\$100,001 - \$250,000	
DESCRIPTION: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16					

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

la **Schedule B** d'un annuel récapitule les trades de l'année — au total **57 259** transactions vivent hors des PTR ([ouvrir ce rapport](#))


piège 1 — la répétition : l'amendement re-déclare les trades de l'annuel qu'il corrige (Pelosi 2014 : le même trade **3 fois**, O+A+A) → dédoublonné par la clé naturelle

piège 2 — le blind trust (B, 23 dépôts) : la banque du *trust* liste de vraies ventes (eBay, Meta, Tesla...) — mais **pas décidées par l'élu** → jamais dans le signal


les 5 types administratifs (X, D, W, E, G) : zéro transaction, vérifié

Complétude (4/4) — que rate-t-on ? Mesuré, pas supposé


Ce que contiennent les rapports annuels & assimilés (O/H/T/A, 2014-2026)



Transactions « annuel-seul » par année couverte



Délai médian trade → divulgation (jours)



mesure : les **5 779** rapports numériques O/H/T/A des membres, réconciliés **ligne à ligne** contre nos PTR

67 % déjà dans nos PTR

le reste : surtout des fonds/ETF

actions manquantes : 173, toutes 2014-2017

et surtout : divulgation médiane **406 j** après le trade (vs **27 j** via PTR) → de la **complétude d'archive**, pas du signal — le filtre P est le bon choix

Cohérence (1/6) — qui dépose quoi : la couverture réelle

Question 2 · Cohérence

Chambre uniquement

470 entrées au Congrès
(depuis 2014)

82 % ont déposé un **H** (déclaration d'entrée)
16 % un **C** à la place (la loi les dispense du H)
2 % ni l'un ni l'autre → **98 % couverts**

463 sorties définitives

81 % ont déposé un **T** (déclaration de sortie)
86 sans T : partis au Sénat ou à l'exécutif (dispensés),
décès, départs très récents


presque chaque entrée a sa **photo de patrimoine** — mais une entrée sur cinq qui ressort ne laisse **pas de photo de sortie**

c'est cette disponibilité, et elle seule, qui décide de qui sera vérifiable de bout en bout

Cohérence (2/6) — les 900 de la fenêtre : qui est testable de bout en bout ?

Question 2 · Cohérence

Chambre uniquement



439 déjà en poste en 2014 (pas de photo d'entrée) · **437** encore en poste en 2026 (pas de photo de sortie) → seuls les **149 entrés PUIS sortis** peuvent avoir les **deux** photos

Cohérence (3/6) — de 149 cycles complets à 56 réellement testables

Question 2 · Cohérence

Chambre uniquement



la moitié des membres à double photo **ne détient aucune action cotée** (fonds, comptes gérés, immobilier)



la photo d'entrée : 252 ancrés par un **H** · 32 par un **C** (dispensés de H) = 284 portefeuilles d'entrée datés · 616 déjà en poste en 2014 n'en ont pas

Cohérence (4/6) — le résultat : les portefeuilles se recoupent

Question 2 · Cohérence

Chambre uniquement

Les portefeuilles se recoupent : entrée (H) + PTR $\geq$ sortie (T), et année par année via les annuels (O)



entrée + transactions reconstruisent le
portefeuille de sortie — l'escalier :

- PTR électroniques **78,7 %**
- + PTR papier **78,8 %**
- + annuels O/A **84,2 %**
- + Schedule B du T **87,8 %**

résidu vraiment inexpliqué : 3,3 %

= 45 positions chez 14 membres · le reste des
« trous » = du **non-filing documenté** (l'écu a
déclaré ailleurs), pas un trou de collecte

blind trust **Phillips** : 284 positions à l'entrée → 1 à
la sortie = 0 faux trou

Cohérence (5/6) — ce que les O/A/T ajoutent : du patrimoine, pas du signal

Question 2 · Cohérence

Chambre uniquement

les annuels (O), amendements (A) et sorties (T) déclarent **aussi** des transactions — souvent les mêmes, re-déclarées ; une fois les doublons **et** les échos PTR retirés, il reste :

26 115

trades jamais vus dans
un P

22 216

via les annuels O

3 899

via sorties +
amendements

374 j

délai médian trade →
pub.

ces trades **comblent des trous du portefeuille** (l'écu oublie son P mais l'inscrit à l'annuel) —
découverts **~1 an trop tard** : ils nourrissent le **patrimoine**, jamais le **signal**

les 26 115 sont surtout des **ETF/fonds cotés** ; les vraies **actions** manquantes au signal = **173**, toutes pré-2018 (cf.

Complétude 4/4)

Cohérence (6/6) — reconstruire n'est pas vérifier

Question 2 · Cohérence

Chambre uniquement

900 · membres passés par la Chambre, 2014–2026

825 · RECONSTRUITS

photo d'entrée + transactions → série datée par membre

56 · VÉRIFIÉS

... et confirmés par la photo de sortie
(entrée + flux $\supseteq$ sortie, réellement testé)


les autres :
reconstruits, mais
pas vérifiables
(photo de sortie
manquante,
ou rien de côté)

on **reconstruit** une série datée pour **825** membres ; on ne peut la **prouver** de bout en bout que pour **56** — le petit est *dans* le grand, les deux ne s'additionnent jamais

Corroboration — le mécanisme : des tuples et des ensembles


Question 3 · Corroboration

Quiver = fournisseur commercial, vérité-terrain externe — **jamais réinjecté**




comparer les deux corpus = tester l'**appartenance à un ensemble de tuples** — jamais un *merge*

NOUS (169 000) **QUIVER**



au tuple (élu, ticker, sens), fenêtre 2014-2026 — c'est le niveau 1 ; les niveaux 2 et 3 : slide suivante

Corroboration — trois niveaux de stricteesse, et qui a raison sur les dates



on serre la vis cran par cran — chaque écart reçoit un verdict :

CONCORDANT · **ÉCART DATE** · **ÉCART TICKER**

NON-COTÉ · **NOUS SEULS** · **MANQUANT**

PAPIER · **NOTRE MANQUE (vrai trou)**

N3 — sens : 96,8 % Ch. · 99,9 % Sén.

N3 — montant : 94,2 % · 99,8 %

N2, les dates : quand elles divergent au sein d'un même (élu, ticker, sens), seuls **545 candidats** issus du **même dépôt** méritent l'œil → **arbitrage au PDF source** :

le PDF montre...	exemple réel	traitement
coquille du déposant, prouvable	3031-04-30	corrigée → 2021
coquille littérale	01/35/22	transcrite telle quelle
notre OCR s'est trompé	Khanna/COST 09-31	re-lue au PDF → 08-16
désaccord Quiver	McCaul/GOOGL Δ11 j	arbitré au PDF

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

Corroboration — cinq preuves de plus, et un principe

Univers officiel

index du *House Clerk* re-téléchargé :
100 % des **8 252 PTR** traités — par-
sés, OCRisés ou écartés par règle
écrite

senate-stock-watcher

collecte indépendante, 6 231 txns
2014-2020 : **100 %** retrouvées (hors
36 échanges, comptés en 2 lignes
chez eux) — sur-ensemble strict

house-stock-watcher

miroir indépendant 2018-2026 :
99,5 % de ses lignes chez nous ; ses
manques pré-2018 → tous traités

Kadoa

agrégateur tiers : comptes par dé-
posant, triangulation automatisée
(`test_crosscheck`) — confirme les
déposants où notre OCR est l'**unique**
source


Golden interne

368 tables figées SHA-256 (230
Chambre + 138 Sénat), rejouées oc-
tet à octet à **zéro écart** ; + **10 scripts**
de régression au vert (chaque trans-

le principe

aucune source externe n'est **réinjec-
tée** dans les tables — elles ne servent
qu'à **mesurer** ce qu'on a


Partie 5 — Le livrable



Qu'est-ce qu'on livre, et avec quelles limites ?

Du corpus à la table de recherche : l'entonnoir

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



le principe : on ne retire que l'**avéré inutilisable** pour un backtest (pas de date, pas de prix, pas de sens, pas de montant) —

tout le doute est GARDÉ et FLAGUÉ

les flags (jamais retirés) :

- `flag_late_filing` — divulgué > 45 j : **12,2 %**
- `is_delisted` — titre sorti de cote, typé (faillite/rachat) : **2,6 %**
- `lot_size > 1` — lots multi-comptes réels : **8,8 %**
- `flag_price_caution` — symbole recyclé : **0,4 %**

134 464 × 36 : les garanties, ET les limites

data/clean/transactions_backtest_2014_2026.csv

134 464 lignes × 36 colonnes

372 membres · 57 % issu d'OCR · parti & commissions *point-in-time* · traçable ligne à ligne (doc_id)


Ce qu'on garantit

- ✓ complet : 100 % de l'univers officiel
- ✓ identifié : 100 % des lignes rattachées
- ✓ validé : Quiver + 3 sources indépendantes
- ✓ reproductible : golden octet à octet

Limites assumées

- 582 PTR manuscrits écartés (règle rejouable)
- **corroboracion externe mince avant 2017** :
87,2 % (2020-26) vs 58,7 % (2014-19)
- montants = fourchettes (milieu), pas des prix exacts
- non-coté sans ticker ni secteur (composition, pas défaut)

Ce qu'il faut retenir



100 %

de l'univers officiel
(8 252 PTR) traité

169 000

transactions uniques,
identifiées à 100 %

> 92 %


corroborés dehors —
80 % cohérents dedans

134 464

lignes × 36 colonnes,
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites

Annexe — volumes par année et par voie



totaux contrôlés = 169 000 transactions uniques ; non tracées : 1 064 antérieures à 2014 (régularisations tardives) + 317 sans date lisible

Annexe — l'index du Clerk et les deux extrêmes

l'index annuel (extrait réel, 2024FD.xml) :

```
<Member>
  <Prefix>Hon.</Prefix>
  <Last>Allen</Last>
  <First>Richard W.</First>
  <FilingType>P</FilingType>
  <StateDst>GA12</StateDst>
  <Year>2024</Year>
  <FilingDate>1/11/2024</FilingDate>
  <DocID>20024277</DocID>
</Member>
```

P = PTR; les autres types (rapports annuels, candidatures...) sont ignorés

The image shows a digital version of a "PERIODIC TRANSACTION REPORT" form. At the top, it says "Filing ID: 20024277". The form is titled "PERIODIC TRANSACTION REPORT" and includes the text "Club of the House of Representatives • Legislative Resource Center • 900 Capitol Building • Washington, DC 20540". The filer information is: Name: Mr. Richard W. Allen, Status: Member, State/Office: N/A. The transactions table has one entry: ID: 100, Owner Asset: H&M International, Inc. (H&I), Transaction Date: 10/10/2023, Notification Amount: \$100,000, and a note: "Regiment - Expense". The filer certifies that the report is true, complete, and correct to the best of their knowledge and belief. The form is signed by Richard W. Allen on 1/11/2024.

électronique 2014


doc 20000077 — ancien gabarit

The image shows a handwritten version of a "PERIODIC TRANSACTION REPORT" form. The form is titled "PERIODIC TRANSACTION REPORT" and includes the text "Club of the House of Representatives • Legislative Resource Center • 900 Capitol Building • Washington, DC 20540". The filer information is: Name: Mr. Richard W. Allen, Status: Member, State/Office: N/A. The transactions table has one entry: ID: 100, Owner Asset: H&M International, Inc. (H&I), Transaction Date: 10/10/2023, Notification Amount: \$100,000, and a note: "Regiment - Expense". The filer certifies that the report is true, complete, and correct to the best of their knowledge and belief. The form is signed by Richard W. Allen on 1/11/2024.

manuscrit 2020

doc 8217474 — écarté (gating)

Annexe — les sources externes, en vrai



quiverquant.com (vérité-terrain externe)...



ces sources servent à **identifier** et à **mesurer**
—
jamais réinjectées dans nos tables

le référentiel d'identité *congress-legislators* (nom
→ `bioguide_id`) : montré en Partie 2

```
..._quiver_house_cache.csv - vérité-terrain externe
1 bioguide_id, Name, Ticker, Transaction, traded, filed, disclosure_year, Trade_Size_USD, Party, District
2 V000139, Matthew Robert Van Epps, XOM, Sale, 2026-06-16, 2026-06-17, 2026, 1001.0, Republican, 7.0
3 V000139, Matthew Robert Van Epps, IBM, Sale, 2026-06-16, 2026-06-17, 2026, 1001.0, Republican, 7.0
4 V000139, Matthew Robert Van Epps, AMZN, Sale, 2026-06-16, 2026-06-17, 2026, 1001.0, Republican, 7.0
- 100 334 lignes (cache local, jamais réinjecté) -
```

... et son export brut dans notre cache

Annexe — portrait statistique du corpus



montants renseignés **99,4 %** — médiane **8 000 \$** · moyenne 58 314 \$ · max 75 M\$ · délai médian de divulgation : **27 j** Chambre / **24 j** Sénat · dates cohérentes **99,8 %**