

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Depuis 2012, chaque élu du Congrès doit déclarer ses transactions en bourse

le **STOCK Act** (2012) : toute transaction boursière de plus de 1 000 \$ d'un élu doit être déclarée dans un
Periodic Transaction Report (« **PTR** ») — public, daté, sous **45 jours**

45 j

le délai légal pour
déclarer un trade

2014–2026

la fenêtre étudiée
(la loi date de 2012)

2 chambres

435 représentants
+ 100 sénateurs

la question de recherche : ces déclarations publiques peuvent-elles nourrir une stratégie d'investissement ?
avant d'y répondre, il faut une donnée **complète, propre et prouvée** — c'est l'objet de cette présentation

La couche données, en quatre résultats

169 000

transactions uniques,
identité rattachée à
100 %

100 %

des 8 252 déclarations
officielles (PTR)
traitées

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

la table de recherche
livrée, limites écrites

comment peut-on affirmer tout ça ? — c'est l'objet de la présentation : chaque étape prouve son chiffre

Le plan — cinq étapes, une promesse




chaque étape s'ouvre sur une **question** et se ferme sur une **réponse chiffrée** — les choix faits sont encadrés **CHOIX** au fil des slides

Étape 1 — La donnée brute



À quoi ressemble la matière première — et pourquoi ce n'est pas juste télécharger un CSV ?

Tout est public : deux guichets, treize années



La Chambre — disclosures-clerk.house.gov

une archive par année, avec l'index de tous les dépôts


Le Sénat — efdsearch.senate.gov (portail eFD)

un accord obligatoire, puis une recherche : la liste des dépôts, un lien chacun

35 315 dépôts de tous types dans l'index Chambre · 13 années couvertes (2014–2026) · collecte automatisée des deux côtés

CHOIX — l'index annuel officiel est notre autorité : c'est lui qui définit l'univers des documents à traiter — pas ce qu'on a réussi à lire.

Sur douze types de dépôts, un seul porte le signal : le P



P = *Periodic Transaction Report* (les « PTR ») — les seules **déclarations de transactions datées**, sous 45 jours · **8 252** PTR parmi les 35 315 dépôts

CHOIX — on ne construit le signal qu'avec les dépôts de type **P**, parce qu'eux seuls déclarent des transactions datées sous 45 jours — les **11 autres types seront tous ouverts** à l'Étape 4 (Vérification).


Chaque dépôt s'ouvre dans un des deux mondes — texte ou image : quatre sous-corpus

chaque dépôt pointe vers son document (son numéro donne l'URL) — la même donnée réglementaire existe sous **4 formats** :




Chambre · PDF lisible

couche texte — **71 %** des
dépôts




Chambre · PDF scanné

image — **29 %** des dépôts



Sénat · page HTML

table propre, en ligne



Sénat · papier scanné

formulaire, image

CHOIX — on découpe le corpus en **4 sous-corpus** (chambre × format) et chaque voie reçoit son **extracteur dédié** — un traitement uniforme raterait la moitié · au final, **57,6 %** du corpus viendra d'images.

Le vrai point dur n'est pas le scan : c'est le manuscrit

un scan n'est pas du texte, c'est une **image** (à lire par **OCR** : lecture automatique) — ce qui compte n'est pas l'orientation mais **tapé vs manuscrit** :

UNITED STATES HOUSE OF REPRESENTATIVES
Financial Disclosure Report

NAME: Adam Barnett Schiff
OFFICE TELEPHONE: 202.225.4176
LEGISLATIVE TERRITORY: 2013 JUL -9 BR ID 05

Handwritten: HAND DELIVERED

FULL ASSET NAME	TYPE OF TRADING ACTION	DATE OF TRADING ACTION	DATE OF TRADING ACTION	AMOUNT OF TRANSACTION																
				A	B	C	D	E	F	G	H	I	J							
Apple Inc	Buy	7/6/20	7/8/20																	

Tapé, droit

dactylographié, lisible tel quel

UNITED STATES HOUSE OF REPRESENTATIVES
Financial Disclosure Report

NAME: George E.B. Holding
OFFICE TELEPHONE: 202.225.3072
LEGISLATIVE TERRITORY: 2013 JUL 12 BR ID 12

Handwritten: HAND DELIVERED

FULL ASSET NAME	TYPE OF TRADING ACTION	DATE OF TRADING ACTION	DATE OF TRADING ACTION	AMOUNT OF TRANSACTION																
				A	B	C	D	E	F	G	H	I	J							
Apple Inc	Buy	7/6/20	7/8/20																	

Tapé, couché

tourné à 90° — lu quand même

UNITED STATES HOUSE OF REPRESENTATIVES
Financial Disclosure Report

NAME: George E.B. Holding
OFFICE TELEPHONE: 202.225.3072
LEGISLATIVE TERRITORY: 2013 JUL 12 BR ID 12

Handwritten: HAND DELIVERED

FULL ASSET NAME	TYPE OF TRADING ACTION	DATE OF TRADING ACTION	DATE OF TRADING ACTION	AMOUNT OF TRANSACTION																
				A	B	C	D	E	F	G	H	I	J							
Apple Inc	Buy	7/6/20	7/8/20																	

Manuscrit

à la main, cursif — le vrai point dur

775 scans manuscrits sur les 2 424 scans Chambre recensés

le papier existe aussi au Sénat, en faible volume

— il faudra une **politique** pour le manuscrit : *tranchée à l'Étape 2*

Deux dates par transaction — seule la date de dépôt est fiable : c'est elle le signal

Date de DÉPÔT (divulgaration)

toujours une métadonnée — jamais lue dans le document, jamais OCRisée ; **fiable** → c'est la date **signal**

délai médian de divulgation : 27 j Chambre · 24 j Sénat

CHOIX — le signal est daté à la **date de dépôt** (divulgaration), jamais à la date du trade : c'est ce qu'un investisseur réel aurait su, quand il l'aurait su (**anti-look-ahead**) — et toute date de transaction douteuse est **flaguée, jamais réécrite au hasard**.

Date de TRANSACTION

lue dans le document (texte ou OCR) ; la **seule risquée** → garde-fous + flag, **jamais inventée**



même schéma sur les 4 voies : le dépôt vient de l'index/du listing, la transaction du document

garde-fou : une date de transaction hors de la fenêtre de plausibilité [dépôt − 90j, +10j] → année recalée ou ligne flaguée

169 000 transactions — dont $\sim 40\%$ viennent de deux élus, exclusivement sur papier

169 000 transactions uniques (2014–2026) — ce que les étapes 2–3 vont extraire — en quatre sous-corpus :

Sénat OCR 2,4 %



très concentré — Khanna (41 080 txns) et McCaul (27 123) pèsent à eux deux $\sim 40\%$ du corpus, et déclarent **exclusivement sur papier** (100 % OCR)

le papier n'est pas un détail : c'est **la majorité du corpus** (55,2 % rien que pour les scans Chambre)


Réponse — 2 guichets publics · 4 formats · 8 252 PTR — une matière majoritairement papier.

Étape 2 — Le pipeline




Comment passe-t-on de $\sim 10\,000$ documents hétérogènes à une seule table ?


Le flux de bout en bout tient en une image




Le flux de bout en bout tient en une image



Le flux de bout en bout tient en une image



Le flux de bout en bout tient en une image



Les deux voies électroniques : du parsing déterministe de bout en bout

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/17/2018	04/17/2018	\$15,001 - \$50,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	S	04/17/2018	04/17/2018	\$15,001 - \$50,000	
	Microsoft Corporation (MSFT) [ST] FILING STATUS: New SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$50,000	
	Spectra Energy Partners, LP Common Units representing Limited Partner Interests (SEP) [ST] une seule transaction, libellé sur 4 lignes SUBHOLDING OF: CHARLES SWABB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

extrait réel — le montant déborde sur la ligne suivante, le libellé court sur 4 lignes : **un parseur naïf raterait la moitié** → on **reconstruit** chaque transaction avant de la lire

CHOIX — la Chambre a **deux gabarits** de formulaire (l'ancien sans code type d'actif, le moderne avec [ST], apparu vers 2018) — **routés document par document**, jamais par année fixe.

Chambre — 58 728 transactions


recoller les lignes coupées → repérer la signature (opération + 2 dates + fourchette) → rattacher l'actif

Sénat — 13 026 transactions

liste des dépôts → page HTML par dépôt → lecture des tableaux (gabarit stable sur 13 ans)

pour le texte, **pas d'IA** : du code déterministe, rejouable à l'identique · zéro échec silencieux (les dépôts sans transaction sont tous consignés)

Les scans Chambre : Vision lit tout — le manuscrit est écarté par une règle mesurée



- l'**OCR par IA** (Claude Vision) lit le tapé, même tourné à 90°
- **93 261 transactions extraites des scans**
- très concentrées : les gros déposants « 100 % papier » de l'Étape 1

la mesure — **Quiver Quantitative** (fournisseur commercial des mêmes données, notre mètre externe — détail Étape 4), *même sans exiger la date*, ne corrobore que **12,9 %** du manuscrit, contre **88 %** du tapé droit

582 PTR manuscrits écartés — 7,1 % de l'index

CHOIX — on ne met en table que ce qu'on sait lire : les 582 PTR manuscrits sont écartés par une règle écrite et rejouable, avec exceptions explicites — pas de lectures douteuses injectées dans la donnée.

Le papier Sénat : gardé — faute de mètre externe pour le mesurer

2025 RELEASE UNDER E.O. 14176

le formulaire papier Sénat

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

actif · opération Apple Computer Inc · **Sale**
 date du trade · fourchette 2022-03-14 · code A (1 001–15 000 \$)

3 985 transactions — 14 déposants — 2,4 % du corpus

même moteur de lecture que la Chambre — mais **politique inverse** :
Quiver est **aveugle au papier du Sénat** → aucune mesure d'exclusion
possible → on **garde**, sous garde-fous internes, et on l'écrit


couverture ticker plus basse sur cette voie = **composition**, pas défaut :

Blumenthal porte 38,7 % de la voie, massivement du non-côté

CHOIX — on n'écarte que ce qu'on a pu **mesurer** — l'asymétrie Chambre/Sénat (écarté ici, gardé là) est **documentée**, **pas cachée**; le risque est borné (2,4 % du corpus).

Chaque ligne est rattachée à un élu officiel : identité 100 %

un même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → on relie ce **nom libre** à un **identifiant unique**, par une cascade d'essais :



100 % des lignes rattachées

367 membres Chambre · **78** Sénat

le *bioguide* = l'identifiant officiel unique d'un élu au Congrès (annuaire public *congress-legislators*)

CHOIX — les fichiers extraits sont **figés** ; toute réparation (coquille, identifiant manquant) est appliquée à **la lecture**, jamais en réécrivant la source — l'audit reste possible à l'octet près.

Réponse — $58\,728 + 93\,261 + 13\,026 + 3\,985 = 169\,000$ transactions extraites, **100 %** identifiées.

Étape 3 — Enrichir



Que faut-il ajouter pour qu'un backtest puisse s'en servir ?

Chaque transaction reçoit un ticker et un secteur — par deux cascades tracées

1. **explicite** — déjà imprimé dans la source (l'électronique)



2. **dictionnaire** — le nom vu ailleurs dans le corpus (le papier)



3. **LLM** contraint « actions seulement »



4. **récupération** validée par double preuve — **2 540** lignes retrouvent leur symbole

même logique pour le **secteur** (11 secteurs GICS, la classification standard — chacun adossé à son ETF sectoriel) : **79,8 %** Ch. · **70,4 %** Sén.

ticker renseigné

84,1 % Chambre · **77,9 %** Sénat

couverture = remplissage, pas exactitude — les vides sont le **non-coté légitime** (munis, obligations, fonds privés), pas des défauts d'extraction

CHOIX — cascade **ordonnée et tracée**, du plus sûr au moins sûr — chaque étage est enregistré ligne à ligne : jamais une devinette silencieuse.

Une transaction = 7 champs : l'empreinte dédouble sans jamais détruire


l'empreinte d'une transaction — 7 champs :

qui (déclarant) · **quand** (date du trade) · **quoi** (actif) · **sens** ·
montant (fourchette) · **pour qui** (détenteur) · **chambre**

elle exclut **délibérément** :

- le **ticker** — ajouté après coup (Étape 3), sa présence rendrait l'empreinte instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction

CHOIX — dédup **non destructrice** : deux dépôts, même empreinte = un seul trade — mais un **vrai lot répété** (même titre, plusieurs comptes) est **préservé** par un compteur d'occurrence. Jamais de dédoublement aveugle.



Le contrat de la table corpus : 12 champs garantis, montant = milieu de fourchette

12 champs garantis sur chaque ligne, pour les 2 chambres :

déclarant · chambre · parti · commissions · date du trade · date de divulgation · sens ·
montant · type d'actif · ticker · secteur · ETF

la convention de montant :

la loi ne donne qu'une **fourchette** (ex. 15 001–50 000 \$) — on prend son **milieu exact** : 32 500,5 \$ (d'où les « ,5 » dans la table)

CHOIX — une convention **unique et documentée** (le milieu de fourchette) plutôt qu'une fausse précision — le montant est renseigné à 99,4 %.

la table du corpus :

169 000 lignes × 28 colonnes

chaque ligne garde aussi sa **traçabilité** : le document source, l'empreinte, la voie d'extraction

Réponse — 169 000 transactions uniques · 12 champs garantis · chaque enrichissement tracé.

Étape 4 — Vérification



*Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?*

Vérifier, c'est répondre à trois questions

1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

on ouvre les **11 autres types** de dépôts et on mesure le trou

173

actions résiduelles échappant au signal

2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie

87,8 %

des positions de sortie expliquées (Chambre)

3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver + collectes indépendantes — jamais réinjectés


93,5 %

des combinaisons du tiers retrouvées chez nous
(Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

Complétude : on ouvre les 11 autres types — les transactions ne vivent que dans P, O, T

Question 1 · Complétude



la vie déclarative d'un élu : chaque étape a son dépôt — Schedule **A** = la **photo du patrimoine** · Schedule **B** = la **liste des transactions** ; hors PTR, les transactions ne vivent que dans l'annuel **O** (4 625 dépôts, **31 %** avec transactions), la sortie **T** et leurs amendements — **57 259** lignes brutes au total (verdict slide suivante)

les photos H/T serviront à la question 2 (Cohérence)

Verdict complétude : le hors-PTR est du patrimoine découvert trop tard — le signal ne perd que 173 actions

Question 1 · Complétude

SCHEDULE B: TRANSACTIONS

Asset	Owner	Date	Tx. Type	Amount	Cap. Gains > \$200?
Hertz Global Holdings, Inc (HTZ)		07/15/2015	P	\$15,001 - \$50,000	
Disclosures: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16					
Hertz Global Holdings, Inc (HTZ)		07/16/2015	P	\$100,001 - \$250,000	
Disclosures: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16					

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

la Schedule B d'un **annuel** (Pelosi 2015) récapitule les trades de l'année — souvent déjà déclarés en PTR

57 259 lignes brutes hors PTR (doublons compris)

doublons et échos des PTR retirés → le net jamais vu en PTR : surtout des **ETF/fonds** (détail : annexe A5)

173 vraies actions absentes du signal — toutes pré-2018

374 j de délai médian (vs 27 j en PTR)


CHOIX — les transactions hors PTR alimentent le **patri-moine** (vérification), jamais le **signal** — découvertes ~1 an trop tard : cohérent avec l'anti-look-ahead de l'Étape 1.

Cohérence : le test comptable — patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie

Question 2 · Cohérence

Chambre uniquement (~90 % du corpus)

photo = le patrimoine déclaré (Schedule A, aux entrées/sorties) · **flux** = nos transactions — l'équation ne se teste que si l'on a **les deux photos** :




la loi elle-même limite l'échantillon : **439** étaient déjà en poste en 2014 (pas de photo d'entrée), **437** sont encore en poste (pas de photo de sortie); la moitié des 106 ne détient **aucune action cotée**

Cohérence : 87,8 % des positions de sortie expliquées — 3,3 % inexpliquées

Question 2 · Cohérence

Les portefeuilles se recoupent : entrée (H) + PTR ≥ sortie (T), et année par année via les annuels (O)



premier passage : entrée + achats PTR expliquent
78,7 % des 1 371 positions de sortie → 292
inexpliquées

Chambre uniquement

292 positions inexpliquées (21,3 %)
— instruites une par une :

—125 déclarées **AILLEURS** (an-
nuels, sorties, PTR papier)
le taux monte : 78,7 → 87,8 %

—122 **structurelles** (comptes gé-
rés, petites lignes, ETF exemptés)

45 vraiment inexpliquées = 3,3 % (14 membres)

CHOIX — chaque position inexpliquée est **classée par preuve documentaire** (table nominative conservée), pas éliminée statistiquement.

—125 = 74 annuels + 49 sorties + 2 PTR papier · —122 = 59
gérés + 32 ≤ 15 k\$ + 30 ETF + 1 renommage

Reconstruire n'est pas vérifier : 9 portefeuilles reconstruits sur 10 restent sans preuve

Question 2 · Cohérence

Chambre uniquement

chacun des **900** membres reçoit **un seul statut** — du moins au plus exigeant :

20 hors d'atteinte — rien d'exploitable (patrimoine 100 % non coté, blind trust)

715 restructurable partiel — au moins une photo **ou** des transactions → des **morceaux datés**

109 restructurable complet — série datée de bout en bout... mais pas de photo de **sortie** : non testable

56 vérifiable strict — les deux photos + actions cotées → l'équation **réellement testée** (le 87,8 %)


$20 + 715 + 109 + 56 = 900$ — une partition, rien ne se recouvre

CHOIX — on affiche le **périmètre réel du test** (56 membres) plutôt que de laisser croire à une vérification universelle — ~9 reconstruits sur 10 restent **sans preuve**.

Corroboration : nous retrouvons > 92 % de la base du tiers — et nous sommes son sur-ensemble

Question 3 · Corroboration

Quiver = fournisseur commercial, vérité-terrain externe



au niveau (élu, ticker, sens) : 93,5 % / 92,1 % des combinaisons de *Quiver* sont retrouvées chez nous

trois crans de stricte — on serre la vis :

- 1 · **exister** même élu, même titre, même sens
- 2 · **dater** même date (≤ 10 j) — appariés un à un
- 3 · **concorde** sens 96,8 % · montant 94,2 % (Chambre)

CHOIX — Quiver est une **vérité-terrain jamais réinjectée** : il mesure la table, ne la remplit jamais — et en cas de désaccord de date, le **PDF officiel arbitre toujours** (annexe A6).

Cinq preuves de plus, un principe : rien n'est réinjecté

Question 3 · Corroboration

Univers officiel

index du *House Clerk* re-traversé :
100 % des **8 252 PTR** traités — par-
sés, lus par OCR, ou écartés par règle
écrite

Collectes indépendantes

deux projets tiers ayant collecté les
mêmes sources : **100 %** et **99,5 %** de
leurs lignes retrouvées chez nous (+
un agrégateur tiers en triangulation)

Re-run reproductible

368 signatures de fichiers figées :
chaque nouvelle exécution doit repro-
duire les tables livrées à l'**octet près**
— aucune régression silencieuse

le principe — aucune source externe n'est **réinjectée** dans les tables : elles ne servent qu'à
mesurer ce qu'on a

Réponse — rien raté (173 actions résiduelles côté patrimoine · 27 + 11 vrais trous face au tiers) · cohérent dedans
(87,8 % des positions expliquées) · sur-ensemble dehors (> 92 % de la base du tiers retrouvée).


Étape 5 — Le livrable



Qu'est-ce qu'on livre, et avec quelles limites ?

De 169 000 à 134 464 : on ne retire que l'avéré inutilisable

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



quatre portes objectives — **169 000** → **134 464** (79,6 % conservées) :

A — dates cohérentes : −3 252

B — actions + ETF cotés (un backtest exige un prix de marché) : −29 771


C — direction claire (achat ou vente) : −826

D — montant présent : −687

sauvetage « ticker-first » — 21 878 lignes à case « type d'actif » vide **gardées** : le **ticker coté** fait foi, pas la case déclarée

CHOIX — on ne retire que l'**avéré inutilisable** ; le doute est **flagué, jamais retiré** (late filing 12,2 %, délistés, lots multi-comptes) — la recherche décide.

Du symbole au prix : 118 029 trades valorisables — et un biais de survie assumé



118 029 trades avec un prix fiable ($\approx 88\%$)

même valeur numérique que le taux de cohérence de l'Étape 4 : **pure coïncidence**, aucun lien

biais de survie assumé — un titre mort depuis (faillite, rachat sans successeur) ne peut plus être valorisé : couverture **74 %** en 2014 → **99 %** en 2026

CHOIX — la limite est **écrite**, pas cachée — les lignes non couvertes **restent** dans la table, flaguées.

note : le moteur d'analyse aval filtre l'année du trade à 2013–2026 → il travaille sur **134 429** lignes (134 464 — 35 trades à année aberrante, coquilles fidèlement transcrites)

La table livrée : 134 464 lignes × 36 colonnes, traçables au document près

la table de recherche — 134 464 lignes × 36 colonnes · 372 élus · chaque ligne traçable à son document source

membre	ticker	sens	transaction	montant \$	secteur
Bob Gibbs	INTC	buy	2014-12-30	8 000,5	Info. Tech.
Greg Gianforte	BBAVY	sell	2018-12-12	32 500,5	Cons. Staples
Kim Schrier	AAPL	buy	2021-11-15	375 000,5	Info. Tech.
Tim Moore	HOG	buy	2025-12-09	32 500,5	Cons. Discr.

4 lignes réelles — le montant est le milieu exact de la fourchette (d'où les « ,5 »)

les 36 colonnes, en 3 familles

- **qui & quand** — élu, parti & commissions à la date du trade, 2 dates
- **quoi & combien** — ticker, secteur, ETF, montant (99,4 %)
- **flags & traçabilité** — document source par ligne

limites écrites, dans le livrable

- **582 PTR manuscrits** écartés (7,1 % de l'index)
- **biais de survie** prix (slide précédente)
- composition : Chambre **91,3 %** · achats **50,8 %**

La couche données, en quatre chiffres



100 %

de l'univers officiel
(8 252 PTR) traité

169 000

transactions uniques,
identifiées à 100 %

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

lignes × colonnes,
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites

Réponse — une table 134 464 × 36 · 79,6 % du corpus · limites écrites.

Annexes

La réserve pour questions

A1–A7 : documents exemples · détails des cascades · cas particuliers

A1 — Le document lisible : un PTR électronique

**PERIODIC TRANSACTION REPORT**

Filing ID #20009426

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

FILER INFORMATION
Name: Hon. John A. Yarmuth
Status: Member
State/District: KY03

TRANSACTIONS

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Altria Group, Inc. (MO) [ST] Filing Status: New	S (partial)	03/23/2018	04/07/2018	\$1,001 - \$15,000	☒
	Boeing Company (BA) [ST] Filing Status: New	S (partial)	03/15/2018	04/07/2018	\$1,001 - \$15,000	☒
	Micron Technology, Inc. (MU) [ST] Filing Status: New	P	03/27/2018	04/07/2018	\$1,001 - \$15,000	☐
	Wells Fargo & Company (WFC) [ST] Filing Status: New	S (partial)	03/20/2018	04/07/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

INITIAL PUBLIC OFFERINGS
☒ Yes ☐ No

CERTIFICATION AND SIGNATURE
☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.
Digitally Signed: Hon. John A. Yarmuth , 05/02/2018

- un PDF **lisible par machine** (couche texte)
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification — cette dernière est jetée) + fourchette de montant
- **7 996** lignes au montant coupé en deux, recollées avant lecture

PTR électronique complet (Hon. John A. Yarmuth, KY03)

A2 — L'index annuel de la Chambre, la recherche eFD du Sénat

```
2024FD.xml - index annuel du House Clerk
3  <Member>
4  <Prefix />
5  <Last>Abel</Last>
6  <First>William</First>
7  <Suffix />
8  <FilingType>C</FilingType> ← type C : pas un PTR, ignoré
9  <StateDst>TX31</StateDst>
10 <Year>2024</Year>
11 <FilingDate>5/12/2024</FilingDate>
12 <DocID>10060658</DocID>
13 </Member>
  ← 2 256 dépôts dans l'index 2024 -
245 <Member>
246 <Prefix>Hon.</Prefix>
247 <Last>Allen</Last>
248 <First>Richard W.</First>
249 <Suffix />
250 <FilingType>P</FilingType> ← type P : un PTR, on le garde
251 <StateDst>GA12</StateDst>
252 <Year>2024</Year>
253 <FilingDate>1/11/2024</FilingDate>
254 <DocID>20024277</DocID> ← le n° → l'URL du PDF
255 </Member>
```

eFD : on coche **Senator** × **PTR**

Filer Name (linked)	Last Name (linked)	Office (linked)	Report Type	Date Received/Filed
James Hanks	Hanks, James D. (Senator)	Senator, Texas District 10	Periodic Transaction Report (SR 26/05/2024)	10/05/2024
James Hanks	Hanks, James D. (Senator)	Senator, Texas District 10	Periodic Transaction Report (SR 26/10/2024)	26/10/2024
John A. Hancock	Hancock, John (Senator)	Senator, Texas District 18	Periodic Transaction Report (SR 26/10/2024)	09/10/2024
Michael F. Dorsett	Dorsett, Michael (Senator)	Senator, Texas District 21	Periodic Transaction Report (SR 21/12/2023)	07/12/2023
Michael F. Dorsett	Dorsett, Michael (Senator)	Senator, Texas District 21	Periodic Transaction Report (SR 26/12/2023)	05/10/2023
Michael F. Dorsett	Dorsett, Michael (Senator)	Senator, Texas District 21	Periodic Transaction Report (SR 26/12/2023)	09/10/2023
Michael F. Dorsett	Dorsett, Michael (Senator)	Senator, Texas District 21	Periodic Transaction Report (SR 26/05/2024)	09/05/2024
Michael F. Dorsett	Dorsett, Michael (Senator)	Senator, Texas District 21	Periodic Transaction Report (SR 12/05/2024)	13/05/2024

la liste de dépôts, un lien chacun
— chaque dépôt s'ouvre en HTML
ou en scan

l'index annuel : un bloc par dépôt (archive

2024FD.zip → 2024FD.xml)

zéro échec silencieux : 102 dépôts sans transaction retenue, tous consignés (vides réels, amendements sans ligne, échecs tracés)

A3 — Le même formulaire, des sections en commun

Les sections A→J, et lesquelles apparaissent dans chaque type de document

	P	Identiques		Identiques	
		C	H	O	T
	PTR	candidat	entrée	annuel	sortie
A	Actifs & revenus de placement	✓	✓	✓	✓
B	TRANSACTIONS	✓		✓	✓
C	Revenus du travail	✓	✓	✓	✓
D	Dettes	✓	✓	✓	✓
E	Postes occupés	✓	✓	✓	✓
F	Accords	✓	✓	✓	✓
G	Cadeaux			✓	✓
H	Voyages payés			✓	✓
I	Dons à une œuvre (au lieu d'honoraires)			✓	✓
J	Compensation > 5 000 \$ d'une source	✓	✓		

socle commun A · C · D · E · F (dans tous sauf le PTR) — seule la section B (transactions) nous intéresse

→ B n'existe que dans le PTR, l'annuel (O) et la sortie (T)

l'amendement A reprend les sections du document qu'il corrige (C-H ou O-T)

la **section B** = les transactions ; le reste est un socle commun, la **A** (patrimoine) sert à *vérifier*

A4 — Les types administratifs, et le cas à part

cinq types sans aucune transaction :

X — Extension
demande de délai

D — Campaign Notice
« < 5 000 \$ »

W — idem, papier
(ou retrait)

E — Exemption
départ, poste fédéral

G — Gift Waiver
dérogation cadeau

B — Blind Trust (23 dépôts) : la banque du *trust* liste de vraies ventes, mais **pas** décidées par l'élu : la fiducie aveugle.

et les candidats **C** : 10 105 dépôts, 77 % jamais élus — une photo de patrimoine qui peut servir de photo d'entrée

A5 — Ce que les O/A/T ajoutent : du patrimoine, pas du signal

une fois doublons **et** échos des PTR retirés, il reste dans les annuels (O), sorties (T) et amendements (A) :

26 115

trades jamais vus
dans un PTR

22 216

via les annuels O

3 899

via sorties T
+ amendements A

374 j

délai médian
trade → publication

ces trades **comblent des trous du portefeuille** (l'élú oublie son PTR mais l'inscrit à l'annuel) —
découverts **~1 an trop tard** : ils nourrissent le **patrimoine**, jamais le **signal**

les 26 115 sont surtout des **ETF/fonds cotés** — les vraies **actions** manquantes au signal = **173**, toutes pré-2018

ne pas confondre : **26 115** (net hors-PTR, cohérence interne) $\neq$ $\approx$ **26 500** (combinaisons présentes chez nous et absentes chez Quiver, corroboration) — source : audit patrimoine Chambre, table de flux nette (lignée v1-house)

A6 — Qui a raison sur les dates ? Le PDF officiel arbitre toujours

pour un même (élu, ticker, sens), quand notre date et celle de Quiver divergent dans un même dépôt, **545**
candidats méritent l'œil → on **rouvre le PDF** :

le PDF montre...	exemple réel	traitement
coquille du déposant, prouvable	3031-04-30	corrigée → 2021
coquille littérale	01/35/22	transcrite telle quelle
notre OCR s'est trompé	Khanna/COST 09-31	re-lue au PDF → 08-16
désaccord Quiver	McCaul/GOOGL Δ11 j	arbitré au PDF

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

A7 — Détails : les 11 ETF, la couverture des entrées/sorties, les pièges d'identité

11 secteurs GICS → 11 ETF *Select Sector SPDR* :

Energy→XLE · Materials→XLB · Industrials→XLI
· Cons. Discr.→XLY · Cons. Staples→XLP ·
Health Care→XLV · Financials→XLF · Info.
Tech.→XLK · Comm. Services→XLC ·
Utilities→XLU · Real Estate→XLRE

cascade secteur : yfinance (factuel) → LLM
contraint GICS → overrides manuels

pièges d'identité réels, réparés : l'homonyme Bob
Casey (C000228 → C001070) · 42 lignes d'Angie
Craig sans identifiant, réparées à la lecture

couverture des entrées/sorties (Chambre) :

470 entrées depuis 2014	82 % ont déposé un H (photo d'entrée) · 16 % un C à la place → 98 % couverts
--------------------------------	--

463 sorties définitives	81 % ont déposé un T (photo de sortie) ; les 86 sans T : partis au Sénat/exécutif (dispensés), décès
--------------------------------	---

la photo d'entrée : **252** ancrés par un H · **32** par un C =
284 portefeuilles d'entrée datés