

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Depuis 2012, chaque élu du Congrès doit déclarer ses transactions en bourse

le **STOCK Act** (2012) : toute transaction boursière de plus de 1 000 \$ d'un élu doit être déclarée dans un *Periodic Transaction Report* (« **PTR** ») — public, daté, sous **45 jours**

45 j

le délai légal pour
déclarer un trade

2014–2026

la fenêtre étudiée
(la loi date de 2012)

2 chambres

435 représentants
+ 100 sénateurs

la question de recherche : ces déclarations publiques peuvent-elles nourrir une stratégie d'investissement ?

La couche données, en quatre résultats

169 000

transactions uniques,
identité rattachée à
100 %

100 %

des 8 252 déclarations
officielles (PTR) de la
Chambre traitées

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

la table de recherche
livrée, limites écrites

Le plan — deux parties : on construit, puis on prouve

PARTIE I — Construire la table

de la source publique au CSV livré

- I.0 **Le pipeline** le flux complet, en une image
- I.1 **Acquisition & Tri** la Chambre en entier, puis le Sénat en entier
- I.2 **Extraction** 4 voies · les 2 dates · le corpus
- I.3 **Identité** le nom → l'élus officiel
- I.4 **Tickers** le symbole boursier
- I.5 **Secteurs** GICS → ETF
- I.6 **Dédup** l'empreinte 7 champs
- I.7 **Entonnoir** ce qu'on retire, et pourquoi
- I.8 **Table finale** à quoi ressemble la valeur

PARTIE II — Vérifier la table

rien raté, rien inventé


- II.0 **Trois questions** le cadre de la preuve
- II.1 **L'univers** a-t-on tout traité ?
- II.2 **Les autres types** les 11 dépôts hors PTR
- II.3 **La cohérence** les flux se recollent-ils ?
- II.4 **Quiver** le mètre externe
- II.5 **Les autres preuves** et le principe

PARTIE I


Construire la table

De $\sim 10\,000$ documents publics hétérogènes à une seule table

1.0 · Le pipeline complet — tout le trajet de la donnée




1.1 · Acquisition & Tri — on est ici



Où vivent ces déclarations, lesquelles faut-il lire — et dans quel état arrivent-elles ?

ce qu'on en sort : l'univers à traiter — **8 252 PTR** à la **Chambre**, que l'index officiel *déclare* · **2 153** au **Sénat**, qu'il faut *recenser* — répartis en **4 sous-corpus** (chambre × format)

1.1a · Acquisition Chambre — un index annuel qui fait autorité




disclosures-clerk.house.gov

une archive par année, 2014→2026

elle contient l'**index annuel**


un bloc par **dépôt** → son PDF



l'index réel : chaque dépôt y déclare son type, sa date et son numéro de document

35 315 dépôts de tous types · 13 années couvertes · téléchargement automatisé

I.1b · Tri Chambre — douze types dans l'index, un seul porte le signal



P = *Periodic Transaction Report* (les « PTR ») — les seules **déclarations de transactions datées**, sous 45 jours

8 252 PTR sur 35 315 dépôts


et ils arrivent en **deux formats** :



PDF lisible

texte

71 %




PDF scanné

image

29 %

CHOIX — on ne construit le signal qu'avec les dépôts de type **P**, parce qu'eux seuls déclarent des transactions datées sous 45 jours — les **11 autres types seront tous ouverts en Partie II**.

1.1c · Acquisition Sénat — pas d'index : un portail à interroger



1. accord accepté → session ouverte

2. recherche paginée : type = PTR

3. la liste des dépôts, un lien chacun

4. chaque dépôt s'ouvre en page web ou en image

le portail **eFD** (*electronic Financial Disclosure*) —
l'accès exige d'**accepter un accord** : notre collecteur le
fait, puis interroge

2 153 dépôts recensés : **1 780** électroniques · **373** papier

Chambre ≠ **Sénat** — la **Chambre** publie la liste de ce qui existe ; le **Sénat** oblige à la **reconstituer** par la recherche —
d'où un contrôle de couverture différent (II.1).

l'angle mort, annoncé tout de suite — le fournisseur commercial qui nous servira de mètre externe (Quiver, Partie II)
ne voit **pas** le papier du Sénat : cette voie ne sera validable qu'en **interne** (I.2d).

I.1d · Tri Sénat — pas de lettres à lire : le type se demande au portail

The screenshot shows the 'Find Reports' search interface on the United States Senate Financial Disclosures website. It includes fields for 'First name (starts with)' and 'Last name (starts with)', a 'Filer Type' dropdown with 'Senator' selected, and a 'Report Types' section with 'Periodic Transactions' selected. A 'Search Reports' button is at the bottom.

la recherche eFD : on coche **Senator** et le type **PTR** — c'est le filtre, il n'y a pas d'index à lire

Chambre ≠ Sénat — la **Chambre** déclare le type dans son index (une lettre à lire) ; au **Sénat**, le type est un **critère de recherche** — même filtre au final (les PTR seuls), deux mécanismes.

2 153 dépôts PTR recensés

eux aussi arrivent en **deux formats** :

The screenshot shows a web page titled 'Periodic Transaction Report for Q3/Q4 2025' for 'The Honorable James Banks (Banks, James E.)'. It includes a table with columns for 'Transaction Date', 'Amount', 'Type', 'Category', 'Sub-category', and 'Amount'. The table contains several rows of data.

page web

texte

1 780

The screenshot shows a scanned paper document titled 'Periodic Transaction Report for Q3/Q4 2025' for 'The Honorable James Banks (Banks, James E.)'. It contains a table with columns for 'Transaction Date', 'Amount', 'Type', 'Category', 'Sub-category', and 'Amount'. The table contains several rows of data.

papier scanné

image

373

I.1e · Bilan du tri : quatre sous-corpus, quatre extracteurs

la même donnée réglementaire arrive donc sous **4 formats** — deux mondes **texte**, deux mondes **image** :

Chambre · PDF lisible

texte

→ parsing (I.2a)

Chambre · PDF scanné

image

→ OCR (I.2b)

Sénat · page web

texte

→ lecture (I.2c)

Sénat · papier scanné

image

→ OCR (I.2d)

Chambre ≠ Sénat — texte ou image, **comment le sait-on ?** — à la **Chambre** on **essaie de lire** le PDF (du texte en sort → c'est du texte, sinon une image) ; au **Sénat** le **lien du portail** le dit déjà (/ptr/ ou /paper/).

Chambre = Sénat — **chaque chambre a son monde texte et son monde image** — c'est la seule chose qu'elles partagent ici ; au final, **57,5 %** du corpus viendra d'images.

CHOIX — on découpe le corpus en **4 sous-corpus** (chambre × format) et chaque voie reçoit son **extracteur dédié** — un traitement uniforme raterait la moitié. C'est le plan des quatre slides d'Extraction qui suivent.

I.1f · Dans l'image, le vrai point dur n'est pas le scan : c'est le manuscrit

un scan n'est pas du texte, c'est une **image** (à lire par **OCR** : lecture automatique) — ce qui compte n'est pas l'orientation mais **tapé vs manuscrit** :

Tapé, droit

dactylographié, lisible tel quel

Tapé, couché

tourné à 90° — lu quand
même

Manuscrit

à la main, cursif — le vrai point dur

775 scans manuscrits sur les 2 424 scans Chambre recensés

Chambre ≠ Sénat — le manuscrit existe des **deux** côtés — mais il sera **écarté** à la Chambre et **gardé** au Sénat : la raison, et elle seule, est la **vérifiabilité** (I.2b et I.2d).

1.2 · Extraction — on est ici



Comment fait-on sortir des transactions d'un PDF, d'une page web, d'une image ?

ce qu'on en sort : les 4 voies lues : $58\,756 + 93\,325 + 14\,813 + 4\,026 = 170\,920$ lignes (avant dédoublement)

I.2a · Extraction Chambre · texte — un PDF n'est pas un tableau

ID	Owner Asset	Transaction Type	Transaction Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] FUND STATUS: New \$100,000.00 On: CHARLES SWARB ACCOUNT	P	04/17/2018	04/17/2018	\$15,001 - \$50,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] FUND STATUS: New \$100,000.00 On: CHARLES SWARB ACCOUNT	S	04/17/2018	04/17/2018	\$15,001 - \$50,000	
	Microsoft Corporation (MSFT) [ST] FUND STATUS: New \$100,000.00 On: CHARLES SWARB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$50,000	
	Spectra Energy Partners, LP Common Units representing Limited Partner Interests (SEPI) [ST] \$100,000.00 On: CHARLES SWARB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	une seule transaction, libellé sur 4 lignes

* For the complete list of asset true abbreviations, please visit <https://fd.house.gov/reference/asset-true-codes.aspx>.

58 756 lignes extraites → 58 728 uniques


1. recoller les lignes coupées
2. repérer la **signature** d'une transaction : opération + 2 dates + fourchette
3. rattacher l'actif et le ticker imprimés à proximité

extrait réel — le montant déborde sur la ligne suivante, le libellé court sur 4 lignes : **un parseur naïf raterait la moitié**

pas d'IA ici : du code déterministe, rejouable à l'identique

CHOIX — deux gabarits de formulaire coexistent (l'ancien sans code type d'actif, le moderne avec [ST], apparu vers 2018) : ils sont **routés document par document**, jamais par année fixe.

I.2b · Extraction Chambre · image — Vision lit tout, le manuscrit est écarté




- l'**OCR par IA** (Claude Vision) lit le tapé, même tourné à 90°
- **93 325 lignes extraites → 93 261 uniques**
- très concentrées : les gros déposants « 100 % papier » (I.2f)

la mesure — Quiver Quantitative (fournisseur commercial des mêmes données, notre mètre externe — Partie II), *même sans exiger la date*, ne corrobore que **12,9 %** du manuscrit, contre **88 %** du tapé droit

582 PTR manuscrits écartés — 7,1 % de l'index

CHOIX — on ne met en table que ce qu'on sait lire : les 582 PTR manuscrits sont écartés par une **règle écrite et rejouable**, avec exceptions explicites — pas de lectures douteuses injectées dans la donnée.

I.2c · Extraction Sénat · texte — une table déjà propre, stable sur 13 ans



UNITED STATES SENATE
FINANCIAL DISCLOSURES

Return to the search tab to select another report.

Periodic Transaction Report for 03/10/2025
The Honorable James Banks (Banks, James E.)
Filed 03/10/2025 @ 12:54 PM
[Print Report]

The following statements were checked before filing:
[X] I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
[X] I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

Transactions (1 transaction total, 0 Self, 1 Joint, 0 Spouse, 0 Dependent Child)

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	YUMCZ	Yum! Brands Company Yum (Louisville, KY) Description Food	Other	Sale (PUB)	\$1,001 - \$15,000	...

la déclaration électronique : une vraie table, ticker cliquable — rien à reconstruire

14 813 lignes extraites → 13 026 uniques

1. une **page par dépôt**, mise en cache
2. **lecture des tableaux** : colonnes repérées par leurs intitulés
3. rien d'autre — le gabarit ne change pas

les 9 mêmes colonnes sur toutes les pages 2014→2026 (vérifié) : ce qui varie, ce sont les *amendements* et le *non-coté*, pas le format

c'est ici que la dédup travaille — 1 787 des 14 813 lignes (12 %) sont des **re-dépôts annuels** : cette seule voie porte **93 %** du dédoublement (1.6)

Chambre ≠ Sénat — là où la **Chambre** impose de **reconstruire** un PDF (I.2a), le **Sénat** électronique se lit **directement** — **déterministe et sans IA** des deux côtés, mais il **re-déclare** bien plus (12 %, contre 0,05 % à la Chambre électronique).

I.2d · Extraction Sénat · image — le papier est gardé, faute de mètre externe

PERSONAL INFORMATION OF TRANSACTIONS

Section	Page
1. Introduction	1
2. Personal Information of Transactions	2
3. Conclusion	3

le formulaire papier Sénat

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

actif · opération Apple Computer Inc · Sale
date du trade · fourchette 2022-03-14 · code A (1001-15 000 \$)

4 026 lignes → 3 985 uniques — 14 déposants — 2,4 % du corpus

même moteur qu'à la Chambre (I.2b) — mais **politique inverse** : Quiver est **aveugle au papier du Sénat** → aucune mesure d'exclusion possible
→ on **garde**, sous garde-fous internes, et on l'écrit

couverture ticker plus basse sur cette voie = **composition**, pas défaut :


Blumenthal porte 38,7 % de la voie, massivement du non-coté

CHOIX — on n'écarte que ce qu'on a pu **mesurer** — l'asymétrie Chambre/Sénat (écarté là, gardé ici) est **documentée**, pas cachée ; le risque est borné (2,4 % du corpus).

1.2e · Ce qu'on extrait de chaque ligne : deux dates, une seule est fiable

Date de DÉPÔT (divulgarion)

toujours une métadonnée — jamais lue dans le document, jamais OCRisée ; **fiable** → c'est la date **signal**



CHOIX — le signal est daté à la **date de dépôt**, jamais à la date du trade : c'est ce qu'un investisseur réel aurait su, quand il l'aurait su (**anti-look-ahead**) — et toute date de transaction douteuse est **flaguée, jamais réécrite au hasard**.

Date de TRANSACTION

lue dans le document (texte ou OCR) ; la **seule risquée** → garde-fous + flag, **jamais inventée**



l'écart entre les deux, c'est le **délai de divulgation** :

médiane 27 j Chambre · 24 j Sénat

Chambre = Sénat — sur les 4 voies, même schéma : la date de dépôt vient de l'index (Chambre) ou du listing (Sénat) ; celle du trade, du document.

I.2f · Le corpus extrait : 169 000 transactions — dont ~40 % de deux élus


les quatre voies réunies donnent **169 000 transactions uniques** (2014–2026) — et cette matière est **très déséquilibrée** :



très concentré — Khanna (**41 080 txns**) et McCaul (**27 123**) pèsent à eux deux ~40 % du corpus, et déclarent **exclusivement sur papier** (100 % OCR)

le papier n'est pas un détail : c'est **la majorité du corpus** — d'où l'effort d'OCR de I.2b et I.2d

1.3 · Identité — on est ici




À qui appartient chaque ligne, quand le formulaire n'offre qu'un nom libre ?

ce qu'on en sort : 100 % des lignes rattachées à un élu officiel

I.3 · Identité — chaque ligne est rattachée à un élu officiel : 100 %

un même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → on relie ce **nom libre** à un **identifiant unique**, par une cascade d'essais :



100 % des lignes rattachées


367 membres Chambre · 78 Sénat

le *bioguide* = l'identifiant officiel unique d'un élu au Congrès (annuaire public *congress-legislators*)

Chambre = Sénat — même cascade, même annuaire des deux côtés — d'où une seule slide ; le **Sénat** ajoute seulement une désambiguïsation (siège, titulaire en exercice).

CHOIX — les fichiers extraits sont **figés** ; toute réparation est appliquée **à la lecture**, jamais en réécrivant la source.

1.4 · Tickers — on est ici



« Apple Computer Inc » : comment retrouver le symbole boursier derrière un nom écrit à la main ?

ce qu'on en sort : le ticker sur **84,1 %** des lignes Chambre · **77,9 %** Sénat

I.4a · Tickers — du nom de l'actif au symbole boursier, par une cascade tracée

1. **explicite** — déjà imprimé dans la source (l'électronique)



2. **dictionnaire** — le nom vu ailleurs dans le corpus (le papier)



3. **LLM** contraint « actions seulement »



4. **récupération** validée par double preuve — 2 540 lignes retrouvent leur symbole

Chambre = Sénat — même cascade des deux côtés — ce qui change est la **source** : l'électronique imprime souvent le symbole (étage 1), le papier dépend des étages 2–3.

ticker renseigné


84,1 % Chambre · **77,9 %** Sénat

les trois premiers étages couvrent **82,4 %** ; le 4^e (récupération) porte à **84,1 %**

couverture = remplissage, pas exactitude — les vides sont le **non-coté légitime** (munis, obligations, fonds privés), pas des défauts d'extraction ; l'écart Chambre/Sénat vient de la **composition** des portefeuilles

CHOIX — cascade **ordonnée et tracée**, du plus sûr au moins sûr — chaque étage est enregistré ligne à ligne : jamais une devinette silencieuse.

1.4b · Tickers — avant 2019, pas de code d'actif à la Chambre : c'est le symbole qui décide



part des lignes portant un code « type d'actif » ([ST], [OP]...) —
voies **électroniques**, là où le champ est *déclaré* à la source


Chambre ≠ Sénat — le trou est propre à la **Chambre** (formulaire tardif) ; le choix qui en découle est pourtant **commun aux deux voies** — on n'ancre jamais un actif sur un champ qui peut manquer.

le formulaire de la **Chambre** n'a **pas de case « type d'actif »** avant 2019 : ~0 % jusqu'en 2016, **99 %** dès 2019 — le **Sénat**, lui, l'a depuis 2015.

trier les actions sur ce champ rendrait **aveugles les archives anciennes** : **près de 13 000** actions de la Chambre déclarées **avant 2019** n'ont *que* leur **symbole** pour être reconnues.

CHOIX — « **ticker-first** » — c'est le **symbole coté** qui établit qu'une ligne est une action, **jamais** le champ déclaré (le tri l'applique en 1.7a).

1.5 · Secteurs — on est ici



Dans quel secteur joue chaque titre — et par quel panier coté peut-on l'approcher ?

ce qu'on en sort : le secteur sur **79,8 %** des lignes Chambre · **70,4 %** Sénat

1.5 · Secteurs — chaque titre reçoit un secteur GICS, et son ETF

une cascade indépendante de celle du ticker :

1. **yfinance** — le secteur factuel de l'entreprise



2. **LLM** contraint GICS (+
garde-fou « est-ce coté ? »)



3. **overrides** manuels — les cas connus


secteur renseigné 79,8 % Ch. · 70,4 % Sén.

GICS = la classification sectorielle standard du marché — **11 secteurs**, chacun adossé à son **ETF Select Sector SPDR** (le panier coté du secteur) :

Energy→XLE · Materials→XLB · Industrials→XLI
· Cons. Discr.→XLY · Cons. Staples→XLP ·
Health Care→XLV · Financials→XLF · Info.
Tech.→XLK · Comm. Services→XLC ·
Utilities→XLU · Real Estate→XLRE

Chambre = Sénat — même cascade, même table de correspondance des deux côtés — l'écart de couverture vient de la **composition** des portefeuilles, pas de la méthode.

1.6 · Dédup — on est ici



Un trade re-déclaré dans un amendement : comment le compter une fois — sans effacer les vrais lots ?

ce qu'on en sort : **169 000** transactions uniques (170 920 lignes brutes, —1 920)

I.6 · Dédup — une transaction = 7 champs : l’empreinte dédoublonne sans détruire


l’empreinte d’une transaction — 7 champs :

qui (déclarant) · **quand** (date du trade) · **quoi** (actif) · **sens** · **montant** (fourchette) · **pour qui** (détenteur) · **chambre**

elle exclut **délibérément** :

- le **ticker** — ajouté après coup (I.4), sa présence rendrait l’empreinte instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction


CHOIX — dédup **non destructrice** : deux dépôts, même empreinte = un seul trade — mais un **vrai lot répété** (même titre, plusieurs comptes) est **préservé** par un compteur d’occurrence. Jamais de dédoublonnage aveugle.



Chambre = Sénat — une seule empreinte pour les deux chambres — c’est elle qui permet de **fusionner les 4 voies** sans compter deux fois. Seul le *taux* diffère : **93 %** des 1 920 re-divulgations viennent du **Sénat** électronique (I.2c).

au même moment, à la lecture : les **réparations** (7 996 montants tronqués rétablis · 2 540 tickers récupérés · 7 identités · 3 dates) — le **fichier extrait, lui, reste figé** (I.3)

1.7 · Entonnoir — on est ici




Un backtest exige un prix de marché : que faut-il retirer, et sur quelle preuve ?

ce qu'on en sort : **deux entonnoirs, deux axes** — les **lignes** : **134 464** exploitables, 79,6 % du corpus (c'est le livrable) · puis, en aval, les **symboles** : **3 289** avec un prix → **118 029** trades backtestables, **sans retirer une seule ligne**

I.7a · Entonnoir — de 169 000 à 134 464 : on ne retire que l'avéré inutilisable

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



quatre portes objectives — **169 000** → **134 464** (79,6 % conservées) :

A — dates cohérentes : -3 252

B — actions + ETF cotés (un backtest exige un prix de marché) : -29 771


C — direction claire (achat ou vente) : -826

D — montant présent : -687

sauvetage « ticker-first » — 21 878 lignes à case « type d'actif » vide **gardées** : le **ticker coté** fait foi, pas la case déclarée (*pourquoi : I.4b*)

CHOIX — on ne retire que l'**avéré inutilisable** ; le doute est **flagué, jamais retiré** (late filing 12,2 %, délistés, lots multi-comptes) — la recherche décide.

I.7b · Entonnoir (suite) — du symbole au prix : 118 029 trades valorisables



118 029 trades avec un prix fiable ($\approx 88\%$)


même valeur numérique que le taux de cohérence de la
Partie II : **pure coïncidence**, aucun lien

biais de survie assumé — un titre mort depuis
(faillite, rachat sans successeur) ne peut plus être
valorisé : couverture **74 %** en 2014 → **99 %** en
2026

CHOIX — la limite est **écrite**, pas cachée — les lignes
non couvertes **restent** dans la table, flaguées.

note : le moteur d'analyse aval filtre l'année du trade à 2013–2026 → il travaille sur **134 429** lignes (134 464 — 35 trades
à année aberrante, coquilles fidèlement transcrites)

I.8 · Table finale — on est ici



Au bout du pipeline : à quoi ressemble, concrètement, une ligne livrée ?

ce qu'on en sort : la table de recherche — **134 464 × 36**, limites écrites

I.8 · À quoi ressemble la valeur finale : 134 464 lignes × 36 colonnes

la table de recherche — 134 464 lignes × 36 colonnes · 372 élus · chaque ligne traçable à son document source

membre	ticker	sens	transaction	montant \$	secteur
Bob Gibbs	INTC	buy	2014-12-30	8 000,5	Info. Tech.
Greg Gianforte	BBAVY	sell	2018-12-12	32 500,5	Cons. Staples
Kim Schrier	AAPL	buy	2021-11-15	375 000,5	Info. Tech.
Tim Moore	HOG	buy	2025-12-09	32 500,5	Cons. Discr.

CHOIX — la loi ne donne qu'une **tranche** de montant (ex. 15 001–50 000 \$) : on retient son **milieu exact** (d'où les « ,5 ») — convention **unique et documentée** plutôt que fausse précision ; renseigné à **99,4 %**.

12 champs garantis sur chaque ligne, 2 chambres

déclarant · chambre · parti · commissions · date du trade

· date de divulgation · sens · montant · type d'actif ·

ticker · secteur · ETF

limites écrites, dans le livrable

· **582 PTR manuscrits** écartés (7,1 % de l'index)

· **biais de survie** prix (1.7b)

· composition : Chambre **91,3 %** · achats **50,8 %**

Réponse — une table **134 464 × 36** · 79,6 % du corpus conservé · limites écrites — reste à **prouver** qu'on peut lui faire confiance : **Partie II**.

PARTIE II

Vérifier la table

Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?

II.0 Trois questions · II.1 L'univers · II.2 Les autres types de dépôts · II.3 La cohérence ·
II.4 Quiver · II.5 Les autres preuves

II.0 · Vérifier, c'est répondre à trois questions

1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

l'univers officiel (II.1), puis les **11 autres types** de dépôts (II.2)

173

actions résiduelles échappant au signal

2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie (II.3)

87,8 %

des positions de sortie expliquées (Chambre)

3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver (II.4), collectes indépendantes (II.5) — jamais réinjectés

93,5 %

des combinaisons du tiers retrouvées chez nous

(Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

II.1 · L'univers — 100 % des 8 252 PTR officiels sont traités

l'index officiel dit combien de PTR existent : **8 252**. Chacun est **traité**, ou **écarté par une règle écrite** — aucun n'est ignoré en silence :




7 568 + 102 + 582 = 8 252 — la couverture est **prouvée par l'index**, pas déclarée

les **102** : dépôts vides réels, amendements sans ligne, et **échecs de lecture documentés** — aucun n'est perdu en silence

Chambre ≠ Sénat — côté **Sénat**, pas d'index public à re-télécharger : le contrôle passe par le **recensement** du portail — où **25** dépôts sans transaction retenue sont consignés de la même façon.

II.2a · Les autres types — où vivent les transactions, hors des PTR ?



la vie déclarative d'un élu : chaque étape a son dépôt — Schedule **A** = la **photo du patrimoine** · Schedule **B** = la **liste des transactions** ; hors PTR, les transactions ne vivent que dans l'annuel **O** (4 625 dépôts, **31 %** avec transactions), la sortie **T** et leurs amendements — **57 259** lignes brutes au total

les photos d'entrée (**H**) et de sortie (**T**) serviront à la cohérence (II.3) — verdict de complétude : slide suivante

II.2b · Verdict — le hors-PTR est du patrimoine découvert trop tard : 173 actions

SCHEDULE B: TRANSACTIONS

Asset	Owner	Date	Tx. Type	Amount	Cap. Gains > \$200?
Hertz Global Holdings, Inc (HTZ)		07/15/2015	P	\$15,001 - \$50,000	
Discussions: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16					
Hertz Global Holdings, Inc (HTZ)		07/16/2015	P	\$100,001 - \$250,000	
Discussions: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16					

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

la Schedule B d'un **annuel** (Pelosi 2015) récapitule les trades de l'année — souvent déjà déclarés en PTR

57 259 lignes brutes hors PTR (doublons compris)

doublons et échos des PTR retirés → le net jamais vu en PTR : surtout des **ETF/fonds** (détail : annexe A5)

173 vraies actions absentes du signal — toutes pré-2018

374 j de délai médian (vs 27 j en PTR)


CHOIX — les transactions hors PTR alimentent le **patri-moine** (vérification), jamais le **signal** — découvertes ~1 an trop tard : cohérent avec l'anti-look-ahead de I.2e.

les deux mesures portent sur des populations distinctes : **57 259** = les lignes brutes hors PTR · **374 j** = le délai des trades nets jamais vus en PTR

II.3a · Cohérence — l'équation : entrée + nos transactions $\stackrel{?}{=}$ sortie

Chambre uniquement ($\sim 90\%$ du corpus)


photo = le patrimoine déclaré (Schedule A, aux entrées/sorties) · **flux** = nos transactions — l'équation ne se teste que si l'on a **les deux photos** :



la loi elle-même limite l'échantillon : **439** étaient déjà en poste en 2014 (pas de photo d'entrée), **437** sont encore en poste (pas de photo de sortie) ; la moitié des 106 ne détient **aucune action cotée**

11.3b · Cohérence — le résultat : 87,8 % des positions expliquées, 3,3 % non

Les portefeuilles se recoupent : entrée (H) + PTR ≥ sortie (T), et année par année via les annuels (O)



premier passage : entrée + achats PTR expliquent
78,7 % des 1 371 positions de sortie → 292
inexpliquées

Chambre uniquement

292 positions inexpliquées (21,3 %)
— instruites une par une :

—125 déclarées **AILLEURS** (an-
nuels, sorties, PTR papier)
le taux monte : 78,7 → 87,8 %

—122 **structurelles** (comptes gé-
rés, petites lignes, ETF exemptés)

45 vraiment inexpliquées = 3,3 % (14 membres)

CHOIX — chaque position inexpliquée est classée par preuve documentaire (table nominative conservée), pas éliminée statistiquement.

—125 = 74 annuels + 49 sorties + 2 PTR papier · —122 = 59
gérés + 32 ≤ 15 k\$ + 30 ETF + 1 renommage

II.3c · Cohérence — reconstruire n'est pas vérifier : 9 sur 10 sans preuve

Chambre uniquement

chacun des **900** membres reçoit **un seul statut** — du moins au plus exigeant :

20 hors d'atteinte — rien d'exploitable (patrimoine 100 % non coté, blind trust)

715 restructurable partiel — au moins une photo **ou** des transactions → des **morceaux datés**


109 restructurable complet — série datée de bout en bout... mais pas de photo de **sortie** : non testable

56 vérifiable strict — les deux photos + actions cotées → l'équation **réellement testée** (le 87,8 %)

$20 + 715 + 109 + 56 = 900$ — une partition, rien ne se recouvre

CHOIX — on affiche le **périmètre réel du test** (56 membres) plutôt que de laisser croire à une vérification universelle — ~9 reconstruits sur 10 restent **sans preuve**.

II.4 · Quiver — nous retrouvons > 92 % de sa base, et nous en sommes le sur-ensemble



au niveau (élu, ticker, sens) : 93,5 % / 92,1 % des combinaisons *de Quiver* sont retrouvées *chez nous*

Quiver = fournisseur commercial des mêmes données — notre mètre externe

trois crans de stricte — on serre la vis :

- 1 · **exister** même élu, même titre, même sens
- 2 · **dater** même date (≤ 10 j) — appariés un à un
- 3 · **concor** sens **96,8 %** · montant **94,2 %** (Chambre)

Chambre $\neq$ Sénat — Quiver **voit** le papier de la Chambre (d'où le gating de I.2b) mais est **aveugle** au papier du Sénat (d'où I.2d).

CHOIX — Quiver est une **vérité-terrain jamais réinjectée** : il **mesure** la table, ne la remplit jamais — et en cas de désaccord de date, le **PDF officiel arbitre toujours** (annexe A6).

11.5 · Les autres preuves, et le principe : rien n'est réinjecté

Collectes indépendantes

deux projets tiers ayant collecté les mêmes sources publiques : **100 %** et **99,5 %** de leurs lignes retrouvées chez nous

Agrégateur tiers

comptes par déposant recoupés automatiquement — confirme les déposants où notre OCR est l'**unique source**

Re-run reproductible

368 signatures de fichiers figées : chaque nouvelle exécution doit reproduire les tables livrées à l'**octet près** — aucune régression silencieuse

le principe — aucune source externe n'est **réinjectée** dans les tables : elles ne servent qu'à **mesurer** ce qu'on a

Réponse — rien raté (100 % de l'univers · 173 actions résiduelles côté patrimoine · 27 + 11 vrais trous face au tiers) · cohérent dedans (87,8 % des positions expliquées) · sur-ensemble dehors (> 92 % de la base du tiers retrouvée).

La couche données, en quatre chiffres

PARTIE I — construire

acquisition → tri → extraction → identité → tickers →
secteurs → dédup → entonnoir → table

PARTIE II — prouver

univers → autres types → cohérence → Quiver →
autres preuves

100 %

de l'univers officiel
(8 252 PTR Chambre)
traité

169 000

transactions uniques,
identifiées à 100 %

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

lignes × colonnes,
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites

Annexes

La réserve pour questions

A1–A7 : documents exemples · détails des cascades · cas particuliers

A1 — Le document lisible : un PTR électronique

**PERIODIC TRANSACTION REPORT**

Filing ID #20009426

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

FILER INFORMATION
Name: Hon. John A. Yarmuth
Status: Member
State/District: KY03

TRANSACTIONS

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Altria Group, Inc. (MO) [ST] Filing Status: New	S (partial)	03/23/2018	04/07/2018	\$1,001 - \$15,000	☒
	Boeing Company (BA) [ST] Filing Status: New	S (partial)	03/15/2018	04/07/2018	\$1,001 - \$15,000	☒
	Micron Technology, Inc. (MU) [ST] Filing Status: New	P	03/27/2018	04/07/2018	\$1,001 - \$15,000	☐
	Wells Fargo & Company (WFC) [ST] Filing Status: New	S (partial)	03/20/2018	04/07/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

INITIAL PUBLIC OFFERINGS
☒ Yes ☐ No

CERTIFICATION AND SIGNATURE
☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.
Digitally Signed: Hon. John A. Yarmuth , 05/02/2018

- un PDF **lisible par machine** (couche texte)
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification — cette dernière est jetée) + fourchette de montant
- **7 996** lignes au montant coupé en deux, recollées avant lecture

PTR électronique complet (Hon. John A. Yarmuth, KY03)

A2 — Le portail du Sénat : ce que rend la recherche

 UNITED STATES SENATE
FINANCIAL DISCLOSURES

 Find Reports

 Search Again

la liste réelle des dépôts (I.1c) — **un lien par dépôt** : chacun s'ouvre en **page web** ou en **papier scanné**, c'est là que se décide la voie d'extraction

les PTR sont **un type parmi d'autres** au Sénat aussi (annuels, extensions, *blind trusts*...) — on ne demande que les PTR

A3 — Le même formulaire, des sections en commun

Les sections A→J, et lesquelles apparaissent dans chaque type de document

	P	Identiques		Identiques	
		C	H	O	T
	PTR	candidat	entrée	annuel	sortie
A	Actifs & revenus de placement	✓	✓	✓	✓
B	TRANSACTIONS	✓		✓	✓
C	Revenus du travail	✓	✓	✓	✓
D	Dettes	✓	✓	✓	✓
E	Postes occupés	✓	✓	✓	✓
F	Accords	✓	✓	✓	✓
G	Cadeaux			✓	✓
H	Voyages payés			✓	✓
I	Dons à une œuvre (au lieu d'honoraires)			✓	✓
J	Compensation > 5 000 \$ d'une source	✓	✓		

socle commun A · C · D · E · F (dans tous sauf le PTR) — seule la section B (transactions) nous intéresse

→ B n'existe que dans le PTR, l'annuel (O) et la sortie (T)

l'amendement A reprend les sections du document qu'il corrige (C-H ou O-T)

la **section B** = les transactions ; le reste est un socle commun, la **A** (patrimoine) sert à *vérifier*

A4 — Les types administratifs, et le cas à part

cinq types sans aucune transaction :



X — Extension
demande de délai



D — Campaign Notice
« < 5 000 \$ »



W — idem, papier
(ou retrait)



E — Exemption
départ, poste fédéral



G — Gift Waiver
dérogation cadeau



B — Blind Trust (23 dépôts) : la banque du *trust* liste de vraies ventes, mais **pas** décidées par l'élu : la fiducie aveugle.

et les candidats **C** : 10 105 dépôts, 77 % jamais élus — une photo de patrimoine qui peut servir de photo d'entrée

A5 — Ce que les O/A/T ajoutent : du patrimoine, pas du signal

une fois doublons **et** échos des PTR retirés, il reste dans les annuels (O), sorties (T) et amendements (A) :

26 115

trades jamais vus
dans un PTR

22 216

via les annuels O

3 899

via sorties T
+ amendements A

374 j

délai médian
trade → publication

ces trades **comblent des trous du portefeuille** (l'élú oublie son PTR mais l'inscrit à l'annuel) —
découverts **~1 an trop tard** : ils nourrissent le **patrimoine**, jamais le **signal**

les 26 115 sont surtout des **ETF/fonds cotés** — les vraies **actions** manquantes au signal = **173**, toutes pré-2018

ne pas confondre : **26 115** (net hors-PTR, cohérence interne) $\neq$ $\approx$ **26 500** (combinaisons présentes chez nous et absentes chez Quiver, corroboration) — source : audit patrimoine Chambre, table de flux nette (lignée v1-house)

A6 — Qui a raison sur les dates ? Le PDF officiel arbitre toujours

pour un même (élu, ticker, sens), quand notre date et celle de Quiver divergent dans un même dépôt, **545**
candidats méritent l'œil → on **rouvre le PDF** :

le PDF montre...	exemple réel	traitement
coquille du déposant, prouvable	3031-04-30	corrigée → 2021
coquille littérale	01/35/22	transcrite telle quelle
notre OCR s'est trompé	Khanna/COST 09-31	re-lue au PDF → 08-16
désaccord Quiver	McCaul/GOOGL Δ11 j	arbitré au PDF

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

A7 — Détails : la couverture des entrées/sorties, les pièges d'identité

couverture des entrées/sorties (Chambre) :

470 entrées depuis 2014 · 82 % ont déposé un **H** (photo d'entrée) · 16 % un **C** à la place → **98 % couverts**

463 sorties définitives · 81 % ont déposé un **T** (photo de sortie) ; les 86 sans **T** : partis au Sénat/exécutif (dispensés), décès

la photo d'entrée : **252** ancrés par un **H** · **32** par un **C** = **284** portefeuilles d'entrée datés

pièges d'identité réels, réparés (I.3) :

- l'homonyme **Bob Casey** (C000228 → C001070) : deux vraies personnes — un représentant du Texas, un sénateur de Pennsylvanie
- **42 lignes d'Angie Craig** sans identifiant, réparées à la lecture — le fichier extrait, lui, reste figé

cascade secteur (I.5) :

yfinance (le secteur factuel) → LLM contraint GICS → overrides manuels pour les cas connus