

# La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

# Depuis 2012, chaque élu du Congrès doit déclarer ses transactions en bourse

le **STOCK Act** (2012) : toute transaction boursière de plus de 1 000 \$ d'un élu doit être déclarée dans un  
*Periodic Transaction Report* (« **PTR** ») — public, daté, sous **45 jours**

**45 j**

le délai légal pour  
déclarer un trade

**2014–2026**

la fenêtre étudiée  
(la loi date de 2012)

**2 chambres**

435 représentants  
+ 100 sénateurs

**la question de recherche** : ces déclarations publiques peuvent-elles nourrir une stratégie d'investissement ?  
avant d'y répondre, il faut une donnée **complète, propre et prouvée** — c'est l'objet de cette présentation

# La couche données, en quatre résultats

**169 000**

transactions uniques,  
identité rattachée à  
100 %

**100 %**

des 8 252 déclarations  
officielles (PTR) de la  
Chambre traitées

**> 92 %**

base du tiers retrouvée  
· 87,8 %  
des positions expliquées

**134 464 × 36**

la table de recherche  
livrée, limites écrites

comment peut-on affirmer tout ça ? — c'est l'objet de la présentation : chaque étape prouve son chiffre

# Le plan — deux parties : on construit, puis on prouve

## PARTIE I — Construire la table

de la source publique au CSV livré

|     |                     |                                   |
|-----|---------------------|-----------------------------------|
| I.0 | <b>Le pipeline</b>  | le flux complet, en une image     |
| I.1 | <b>Acquisition</b>  | Chambre, puis Sénat               |
| I.2 | <b>Tri</b>          | par type, puis par format         |
| I.3 | <b>Extraction</b>   | 4 voies · les 2 dates · le corpus |
| I.4 | <b>Identité</b>     | le nom → l'élus officiel          |
| I.5 | <b>Tickers</b>      | le symbole boursier               |
| I.6 | <b>Secteurs</b>     | GICS → ETF                        |
| I.7 | <b>Dédup</b>        | l'empreinte 7 champs              |
| I.8 | <b>Entonnoir</b>    | ce qu'on retire, et pourquoi      |
| I.9 | <b>Table finale</b> | à quoi ressemble la valeur        |

## PARTIE II — Vérifier la table

rien raté, rien inventé

|      |                           |                             |
|------|---------------------------|-----------------------------|
| II.0 | <b>Trois questions</b>    | le cadre de la preuve       |
| II.1 | <b>L'univers</b>          | a-t-on tout traité ?        |
| II.2 | <b>Les autres types</b>   | les 11 dépôts hors PTR      |
| II.3 | <b>La cohérence</b>       | les flux se recollent-ils ? |
| II.4 | <b>Quiver</b>             | le mètre externe            |
| II.5 | <b>Les autres preuves</b> | et le principe              |

**Chambre et Sénat** : une slide chacun **là où ils diffèrent** (I.1, I.3), une seule slide **là où c'est identique**

les **choix** méthodologiques sont encadrés **CHOIX** au fil des slides

## PARTIE I

# Construire la table


---

De ~10 000 documents publics hétérogènes à une seule table


le **pipeline** revient avant chaque étape : on verra toujours où l'on est

# I.0 · Le pipeline complet — tout le trajet de la donnée

ce schéma revient avant chaque étape, l'étape en cours allumée · **OCR** = lecture automatique d'une image (I.2c)




# I.1 · Acquisition — on est ici



*Où vivent ces déclarations, et comment les récupérer sans en rater ?*

ce qu'on en sort : l'univers des documents à traiter — **8 252 PTR** côté Chambre

# 1.1a · Acquisition Chambre — un index annuel qui fait autorité




disclosures-clerk.house.gov

une archive par année, 2014→2026

elle contient l'**index annuel**

un bloc par **dépôt** → son PDF




l'index réel : chaque dépôt y déclare son type, sa date et son numéro de document

**35 315** dépôts de tous types · **13 années** couvertes · téléchargement **automatisé**

**CHOIX** — l'**index annuel officiel** est **notre autorité** : c'est lui qui définit l'univers des documents à traiter — pas ce qu'on a réussi à lire. C'est ce qui rendra la couverture **prouvable** (II.1).

# 1.1b · Acquisition Sénat — pas d'index : un portail à interroger



1. accord accepté → session ouverte

2. recherche paginée : type = PTR

3. la liste des dépôts, un lien chacun

4. chaque dépôt s'ouvre en page web ou en image


le portail **eFD** (*electronic Financial Disclosure*) —  
l'accès exige d'**accepter un accord** : notre collecteur le  
fait, puis interroge

**2 153** dépôts recensés : **1 780** électroniques · **373** papier

**Chambre** ≠ **Sénat** — la **Chambre** publie la liste de ce qui existe ; le **Sénat** oblige à la **reconstituer** par la recherche —  
d'où un contrôle de couverture différent (II.1).

**l'angle mort, annoncé tout de suite** — le fournisseur commercial qui nous servira de mètre externe (Quiver, Partie II)  
ne voit **pas** le papier du Sénat : cette voie ne sera validable qu'en **interne** (I.3d).


## I.2 · Tri — on est ici



*Parmi tous ces dépôts, lesquels lire — et dans quel état arrivent-ils ?*

ce qu'on en sort : les PTR à lire (8 252 Chambre · 2 153 Sénat), répartis en 4 sous-corpus (chambre × format)

## I.2a · Tri par type — sur douze types de dépôts, un seul porte le signal : le P



**P** = *Periodic Transaction Report* (les « PTR ») — les seules **déclarations de transactions datées**, sous 45 jours · **8 252** PTR parmi les 35 315 dépôts

**Chambre = Sénat** — le Sénat a une typologie **analogue** (annuels, extensions, *blind trusts*...) — on ne demande au portail que les **PTR**.

**CHOIX** — on ne construit le signal qu'avec les dépôts de type **P**, parce qu'eux seuls déclarent des transactions datées sous 45 jours — les **11 autres types seront tous ouverts en Partie II**.

# 1.2b · Tri par format — texte ou image : quatre sous-corpus


chaque dépôt pointe vers son document (son numéro donne l'URL) — la même donnée réglementaire existe sous 4 formats :



**Chambre · lisible**

PDF à couche texte


71 % des dépôts



**Chambre · scanné**

PDF image

29 % des dépôts



**Sénat · HTML**

page web, table propre



**Sénat · papier**

formulaire scanné, image

**Chambre = Sénat** — les deux chambres ont leur monde **texte** et leur monde **image** — au final, **57,5 %** du corpus viendra d'images.

**CHOIX** — on découpe le corpus en **4 sous-corpus** (chambre × format) et chaque voie reçoit son **extracteur dédié** — un traitement uniforme raterait la moitié.

# I.2c · Dans l'image, le vrai point dur n'est pas le scan : c'est le manuscrit

un scan n'est pas du texte, c'est une **image** (à lire par **OCR** : lecture automatique) — ce qui compte n'est pas l'orientation mais **tapé vs manuscrit** :

**Tapé, droit**

dactylographié, lisible tel quel

**Tapé, couché**

tourné à 90° — lu quand  
même


**Manuscrit**

à la main, cursif — le vrai point dur

**775 scans manuscrits sur les 2 424 scans Chambre recensés**

**Chambre ≠ Sénat** — le manuscrit existe des **deux** côtés — mais il sera **écarté** à la Chambre et **gardé** au Sénat : la raison, et elle seule, est la **vérifiabilité** (I.3b et I.3d).

## I.3 · Extraction — on est ici



*Comment fait-on sortir des transactions d'un PDF, d'une page web, d'une image ?*

ce qu'on en sort : les **4 voies** lues : 58 728 + 93 261 + 13 026 + 3 985

# I.3a · Extraction Chambre · texte — un PDF n'est pas un tableau

| ID | Owner Asset                                                                                                                              | Transaction Type | Date       | Notification Date | Amount              | Cap. Gains > \$500?                         |
|----|------------------------------------------------------------------------------------------------------------------------------------------|------------------|------------|-------------------|---------------------|---------------------------------------------|
|    | Caterpillar, Inc. (CAT) [ST]<br>Folio System New<br>\$100,000 On: CHARLES SWABB ACCOUNT                                                  | P                | 04/17/2018 | 04/17/2018        | \$15,001 - \$50,000 | montant coupé sur 2 lignes                  |
|    | Coca-Cola Company (KO) [ST]<br>Folio System New<br>\$100,000 On: CHARLES SWABB ACCOUNT                                                   | S                | 04/17/2018 | 04/17/2018        | \$15,001 - \$50,000 |                                             |
|    | Microsoft Corporation (MSFT) [ST]<br>Folio System New<br>\$100,000 On: CHARLES SWABB ACCOUNT                                             | P                | 04/11/2018 | 04/11/2018        | \$15,001 - \$50,000 |                                             |
|    | Spectra Energy Partners, LP<br>Common Units representing<br>Limited Partner Interests (SEPI) [ST]<br>\$100,000 On: CHARLES SWABB ACCOUNT | P                | 04/20/2018 | 04/20/2018        | \$1,001 - \$15,000  | une seule transaction, libellé sur 4 lignes |

\* For the complete list of asset true abbreviations, please visit <https://fd.house.gov/reference/asset-true-codes.aspx>.

58 728 transactions


1. recoller les lignes coupées
2. repérer la **signature** d'une transaction : opération + 2 dates + fourchette
3. **rattacher** l'actif et le ticker imprimés à proximité

extrait réel — le montant déborde sur la ligne suivante, le libellé court sur 4 lignes : **un parseur naïf raterait la moitié**

**pas d'IA** ici : du code déterministe, rejouable à l'identique

**CHOIX** — deux gabarits de formulaire coexistent (l'ancien sans code type d'actif, le moderne avec [ST], apparu vers 2018) : ils sont **routés document par document**, jamais par année fixe.

## I.3b · Extraction Chambre · image — Vision lit tout, le manuscrit est écarté



- l'**OCR par IA** (Claude Vision) lit le tapé, même tourné à 90°
- **93 261 transactions extraites des scans**
- très concentrées : les gros déposants « 100 % papier » (I.3f)

**la mesure — Quiver Quantitative** (fournisseur commercial des mêmes données, notre mètre externe — Partie II), *même sans exiger la date*, ne corrobore que **12,9 %** du manuscrit, contre **88 %** du tapé droit

**582 PTR manuscrits écartés — 7,1 % de l'index**

**CHOIX** — on ne met en table que ce qu'on sait lire : les 582 PTR manuscrits sont écartés par une **règle écrite et rejouable**, avec exceptions explicites — pas de lectures douteuses injectées dans la donnée.

# I.3c · Extraction Sénat · texte — une table déjà propre, stable sur 13 ans

UNITED STATES SENATE  
FINANCIAL DISCLOSURES

Return to the search tab to select another report.

**Periodic Transaction Report for 03/10/2025**  
The Honorable James Banks (Banks, James E.)  
Filed 03/10/2025 @ 12:54 PM  
[Print Report](#)

The following statements were checked before filing:

- ☒ I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
- ☒ I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

**Transactions** (1 transaction total) 0 Self 1 Joint 0 Spouse 0 Dependent Child

| # | Transaction Date | Owner | Ticker               | Asset Name                                                    | Asset Type | Type        | Amount             | Comment |
|---|------------------|-------|----------------------|---------------------------------------------------------------|------------|-------------|--------------------|---------|
| 1 | 02/18/2025       | Joint | <a href="#">YUMZ</a> | Yum Brands Company, Yum (Louisville, KY)<br>Description: Food | Other      | Sale (Full) | \$1,001 - \$15,000 | --      |

la déclaration électronique : une vraie table, ticker cliquable — rien à reconstruire

13 026 transactions

1. une **page par dépôt**, mise en cache
2. **lecture des tableaux** : les colonnes repérées par leurs intitulés
3. rien d'autre — le gabarit ne change pas

les 9 mêmes colonnes sur toutes les pages  
2014→2026 (vérifié) : ce qui varie, ce sont les *amendements* et le non-coté, pas le format

**Chambre ≠ Sénat** — là où la **Chambre** impose de **reconstruire** un PDF (I.3a), le **Sénat** électronique se lit **directement** — même exigence pourtant : **déterministe, sans IA**, zéro échec silencieux, chaque dépôt sans transaction consigné.

# I.3d · Extraction Sénat · image — le papier est gardé, faute de mètre externe

PERSONAL INFORMATION OF TRANSACTIONS

Transaction Type: 1

Transaction Date: 2011-03-14

Transaction Amount: 1001-15000

Transaction Code: A

Transaction Description: Apple Computer Inc · Sale

Transaction Date: 2011-03-14

Transaction Amount: 1001-15000

Transaction Code: A

Transaction Description: Apple Computer Inc · Sale

le formulaire papier Sénat

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

actif · opération Apple Computer Inc · Sale  
date du trade · fourchette 2022-03-14 · code A (1001-15 000 \$)

3 985 transactions — 14 déposants — 2,4 % du corpus

même moteur qu'à la Chambre (I.3b) — mais **politique inverse** : Quiver est **aveugle au papier du Sénat** → aucune mesure d'exclusion possible  
→ on **garde**, sous garde-fous internes, et on l'écrit

couverture ticker plus basse sur cette voie = **composition, pas défaut** :


Blumenthal porte 38,7 % de la voie, massivement du non-coté

**CHOIX** — on n'écarte que ce qu'on a pu **mesurer** — l'asymétrie Chambre/Sénat (écarté là, gardé ici) est **documentée, pas cachée** ; le risque est borné (2,4 % du corpus).

# 1.3e · Ce qu'on extrait de chaque ligne : deux dates, une seule est fiable

## Date de DÉPÔT (divulgarion)

**toujours une métadonnée** — jamais lue dans le document, jamais OCRisée ; **fiable** → c'est la date **signal**



**CHOIX** — le signal est daté à la **date de dépôt**, jamais à la date du trade : c'est ce qu'un investisseur réel aurait su, quand il l'aurait su (**anti-look-ahead**) — et toute date de transaction douteuse est **flaguée**, jamais réécrite au hasard.

## Date de TRANSACTION

**lue dans le document** (texte ou OCR) ; la seule **risquée** → garde-fous + flag, **jamais inventée**



l'écart entre les deux, c'est le **délai de divulgation** :

**médiane 27 j Chambre · 24 j Sénat**

**Chambre = Sénat** — sur les 4 voies, même schéma : la date de dépôt vient de l'index (Chambre) ou du listing (Sénat) ; celle du trade, du document.

## I.3f · Le corpus extrait : 169 000 transactions — dont ~40 % de deux élus


les quatre voies réunies donnent **169 000 transactions uniques** (2014–2026) — et cette matière est **très déséquilibrée** :



**très concentré** — Khanna (**41 080 txns**) et McCaul (**27 123**) pèsent à eux deux ~40 % du corpus, et déclarent **exclusivement sur papier** (100 % OCR)

le papier n'est pas un détail : c'est **la majorité du corpus** — d'où l'effort d'OCR de I.3b et I.3d

## I.4 · Identité — on est ici




À qui appartient chaque ligne, quand le formulaire n'offre qu'un nom libre ?

ce qu'on en sort : 100 % des lignes rattachées à un élu officiel

## I.4 · Identité — chaque ligne est rattachée à un élu officiel : 100 %

un même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → on relie ce **nom libre** à un **identifiant unique**, par une cascade d'essais :



100 % des lignes rattachées


367 membres Chambre · 78 Sénat

le *bioguide* = l'identifiant officiel unique d'un élu au Congrès (annuaire public *congress-legislators*)

**Chambre = Sénat** — même cascade, même annuaire des deux côtés — d'où une seule slide ; le **Sénat** ajoute seulement une désambiguïsation (siège, titulaire en exercice).

**CHOIX** — les fichiers extraits sont **figés** ; toute réparation est appliquée **à la lecture**, jamais en réécrivant la source.

## I.5 · Tickers — on est ici



« Apple Computer Inc » : comment retrouver le symbole boursier derrière un nom écrit à la main ?  
ce qu'on en sort : le ticker sur **84,1 %** des lignes Chambre · **77,9 %** Sénat

## 1.5 · Tickers — du nom de l'actif au symbole boursier, par une cascade tracée

1. **explicite** — déjà imprimé dans la source (l'électronique)



2. **dictionnaire** — le nom vu ailleurs dans le corpus (le papier)



3. **LLM** contraint « actions seulement »



4. **récupération** validée par double preuve — 2 540 lignes retrouvent leur symbole

**Chambre = Sénat** — même cascade des deux côtés — ce qui change est la **source** : l'électronique imprime souvent le symbole (étage 1), le papier dépend des étages 2–3.


**ticker renseigné**

**84,1 %** Chambre · **77,9 %** Sénat

**couverture = remplissage, pas exactitude** — les vides sont le **non-coté légitime** (munis, obligations, fonds privés), pas des défauts d'extraction ; l'écart Chambre/Sénat vient de la **composition** des portefeuilles

**CHOIX** — cascade **ordonnée et tracée**, du plus sûr au moins sûr — chaque étage est enregistré ligne à ligne : jamais une devinette silencieuse.

## I.6 · Secteurs — on est ici



*Dans quel secteur joue chaque titre — et par quel panier coté peut-on l'approcher ?*

ce qu'on en sort : le secteur sur **79,8 %** des lignes Chambre · **70,4 %** Sénat

## 1.6 · Secteurs — chaque titre reçoit un secteur GICS, et son ETF

une cascade indépendante de celle du ticker :

1. **yfinance** — le secteur factuel de l'entreprise



2. **LLM** contraint GICS (+  
garde-fou « est-ce coté ? »)



3. **overrides** manuels — les cas connus


**secteur renseigné**    **79,8 %** Ch. · **70,4 %** Sén.

**GICS** = la classification sectorielle standard du marché — **11 secteurs**, chacun adossé à son **ETF Select Sector SPDR** (le panier coté du secteur) :

Energy→XLE · Materials→XLB · Industrials→XLI  
· Cons. Discr.→XLY · Cons. Staples→XLP ·  
Health Care→XLV · Financials→XLF · Info.  
Tech.→XLK · Comm. Services→XLC ·  
Utilities→XLU · Real Estate→XLRE

**Chambre = Sénat** — même cascade, même table de correspondance des deux côtés — l'écart de couverture vient de la **composition** des portefeuilles, pas de la méthode.

## 1.7 · Dédup — on est ici



*Un trade re-déclaré dans un amendement : comment le compter une fois — sans effacer les vrais lots ?*  
ce qu'on en sort : **169 000** transactions uniques (170 920 lignes brutes)

## 1.7 · Dédup — une transaction = 7 champs : l’empreinte dédouble sans détruire


**l’empreinte d’une transaction — 7 champs :**

**qui** (déclarant) · **quand** (date du trade) · **quoi** (actif) · **sens** ·  
**montant** (fourchette) · **pour qui** (détenteur) · **chambre**

elle exclut **délibérément** :


- le **ticker** — ajouté après coup (1.5), sa présence rendrait l’empreinte instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction

**CHOIX** — dédup **non destructrice** : deux dépôts, même empreinte = un seul trade — mais un **vrai lot répété** (même titre, plusieurs comptes) est **préservé** par un compteur d’occurrence. Jamais de dédoublement aveugle.



**Chambre = Sénat** — une seule empreinte pour les deux chambres — c’est elle qui permet de **fusionner les 4 voies** sans compter deux fois.

## I.8 · Entonnoir — on est ici




*Un backtest exige un prix de marché : que faut-il retirer, et sur quelle preuve ?*

ce qu'on en sort : **134 464** transactions exploitables — 79,6 % du corpus conservé

# I.8a · Entonnoir — de 169 000 à 134 464 : on ne retire que l'avéré inutilisable

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



quatre portes objectives — **169 000** → **134 464** (79,6 % conservées) :

**A** — dates cohérentes : -3 252

**B** — actions + ETF cotés (un backtest exige un prix de marché) : -29 771


**C** — direction claire (achat ou vente) : -826

**D** — montant présent : -687

**sauvetage « ticker-first »** — 21 878 lignes à case « type d'actif » vide **gardées** : le **ticker coté** fait foi, pas la case déclarée

**CHOIX** — on ne retire que l'**avéré inutilisable** ; le doute est **flagué, jamais retiré** (late filing 12,2 %, délistés, lots multi-comptes) — la recherche décide.

## I.8b · Entonnoir (suite) — du symbole au prix : 118 029 trades valorisables



118 029 trades avec un prix fiable ( $\approx 88\%$ )


même valeur numérique que le taux de cohérence de la  
Partie II : **pure coïncidence**, aucun lien

**biais de survie assumé** — un titre mort depuis  
(faillite, rachat sans successeur) ne peut plus être  
valorisé : couverture **74 %** en 2014 → **99 %** en  
2026

**CHOIX** — la limite est **écrite**, pas cachée — les lignes  
non couvertes **restent** dans la table, flaguées.

note : le moteur d'analyse aval filtre l'année du trade à 2013–2026 → il travaille sur **134 429** lignes (134 464 — 35 trades  
à année aberrante, coquilles fidèlement transcrites)

## I.9 · Table finale — on est ici



*Au bout du pipeline : à quoi ressemble, concrètement, une ligne livrée ?*

ce qu'on en sort : la table de recherche — **134 464 × 36**, limites écrites

## 1.9 · À quoi ressemble la valeur finale : 134 464 lignes × 36 colonnes

la table de recherche — 134 464 lignes × 36 colonnes · 372 élus · chaque ligne traçable à son document source

| membre         | ticker | sens | transaction | montant \$ | secteur       |
|----------------|--------|------|-------------|------------|---------------|
| Bob Gibbs      | INTC   | buy  | 2014-12-30  | 8 000,5    | Info. Tech.   |
| Greg Gianforte | BBAVY  | sell | 2018-12-12  | 32 500,5   | Cons. Staples |
| Kim Schrier    | AAPL   | buy  | 2021-11-15  | 375 000,5  | Info. Tech.   |
| Tim Moore      | HOG    | buy  | 2025-12-09  | 32 500,5   | Cons. Discr.  |

**CHOIX** — la loi ne donne qu'une **tranche** de montant (ex. 15 001–50 000 \$) : on retient son **milieu exact** (d'où les « ,5 ») — convention **unique et documentée** plutôt que fausse précision ; renseigné à **99,4 %**.

**12 champs garantis** sur chaque ligne, 2 chambres

déclarant · chambre · parti · commissions · date du trade

· date de divulgation · sens · montant · type d'actif ·

ticker · secteur · ETF

**limites écrites, dans le livrable**

· **582 PTR manuscrits** écartés (7,1 % de l'index)

· **biais de survie** prix (1.8b)

· composition : Chambre **91,3 %** · achats **50,8 %**

**Réponse** — une table **134 464 × 36** · 79,6 % du corpus conservé · limites écrites — reste à **prouver** qu'on peut lui faire confiance : **Partie II**.

## PARTIE II

# Vérifier la table

---

Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?

II.0 Trois questions · II.1 L'univers · II.2 Les autres types de dépôts · II.3 La cohérence ·  
II.4 Quiver · II.5 Les autres preuves

## II.0 · Vérifier, c'est répondre à trois questions

### 1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

l'univers officiel (II.1), puis les **11 autres types** de dépôts (II.2)

**173**

actions résiduelles échappant au signal

### 2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions  $\stackrel{?}{=}$  patrimoine de sortie (II.3)

**87,8 %**

des positions de sortie expliquées (Chambre)

### 3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver (II.4), collectes indépendantes (II.5) — jamais réinjectés

**93,5 %**

des combinaisons du tiers retrouvées chez nous

(Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

## II.1 · L'univers — 100 % des 8 252 PTR officiels sont traités

l'index officiel dit combien de PTR existent : **8 252**. Chacun est **traité**, ou **écarté par une règle écrite** — aucun n'est ignoré en silence :




**7 568 + 102 + 582 = 8 252** — la couverture est **prouvée par l'index**, pas déclarée

les **102** : dépôts vides réels, amendements sans ligne, et **échecs de lecture documentés** — aucun n'est perdu en silence

**Chambre ≠ Sénat** — côté **Sénat**, pas d'index public à re-télécharger : le contrôle passe par le **recensement** du portail — où **25** dépôts sans transaction retenue sont consignés de la même façon.

## II.2a · Les autres types — où vivent les transactions, hors des PTR ?



la vie déclarative d'un élu : chaque étape a son dépôt — Schedule **A** = la **photo du patrimoine** · Schedule **B** = la **liste des transactions** ; hors PTR, les transactions ne vivent que dans l'annuel **O** (4 625 dépôts, **31 %** avec transactions), la sortie **T** et leurs amendements — **57 259** lignes brutes au total

les photos d'entrée (**H**) et de sortie (**T**) serviront à la cohérence (II.3) — verdict de complétude : slide suivante

## II.2b · Verdict — le hors-PTR est du patrimoine découvert trop tard : 173 actions

### SCHEDULE B: TRANSACTIONS

| Asset                                                                                                   | Owner | Date       | Tx. Type | Amount                | Cap. Gains > \$200? |
|---------------------------------------------------------------------------------------------------------|-------|------------|----------|-----------------------|---------------------|
| Hertz Global Holdings, Inc (HTZ)                                                                        |       | 07/15/2015 | P        | \$15,001 - \$50,000   |                     |
| Discussions: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16  |       |            |          |                       |                     |
| Hertz Global Holdings, Inc (HTZ)                                                                        |       | 07/16/2015 | P        | \$100,001 - \$250,000 |                     |
| Discussions: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16 |       |            |          |                       |                     |

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

la Schedule B d'un **annuel** (Pelosi 2015) récapitule les trades de l'année — souvent déjà déclarés en PTR

57 259 lignes brutes hors PTR (doublons compris)

doublons et échos des PTR retirés → le net jamais vu en PTR : surtout des **ETF/fonds** (détail : annexe A5)

173 vraies actions absentes du signal — toutes pré-2018

374 j de délai médian (vs 27 j en PTR)


**CHOIX** — les transactions hors PTR alimentent le **patri-moine** (vérification), jamais le **signal** — découvertes ~1 an trop tard : cohérent avec l'anti-look-ahead de I.3e.

les deux mesures portent sur des populations distinctes : **57 259** = les lignes brutes hors PTR · **374 j** = le délai des trades nets jamais vus en PTR

## II.3a · Cohérence — l'équation : entrée + nos transactions $\stackrel{?}{=}$ sortie

Chambre uniquement ( $\sim 90\%$  du corpus)


**photo** = le patrimoine déclaré (Schedule A, aux entrées/sorties) · **flux** = nos transactions — l'équation ne se teste que si l'on a **les deux photos** :



la loi elle-même limite l'échantillon : **439** étaient déjà en poste en 2014 (pas de photo d'entrée), **437** sont encore en poste (pas de photo de sortie) ; la moitié des 106 ne détient **aucune action cotée**

# 11.3b · Cohérence — le résultat : 87,8 % des positions expliquées, 3,3 % non

Les portefeuilles se recoupent : entrée (H) + PTR ≥ sortie (T), et année par année via les annuels (O)



premier passage : entrée + achats PTR expliquent  
78,7 % des 1 371 positions de sortie → 292  
inexpliquées

Chambre uniquement

292 positions inexpliquées (21,3 %)  
— instruites une par une :

—125 déclarées **AILLEURS** (an-  
nuels, sorties, PTR papier)  
le taux monte : 78,7 → **87,8 %**

—122 **structurelles** (comptes gé-  
rés, petites lignes, ETF exemptés)

**45 vraiment inexpliquées = 3,3 % (14 membres)**

**CHOIX** — chaque position inexpliquée est **classée par preuve documentaire** (table nominative conservée), pas éliminée statistiquement.

—125 = 74 annuels + 49 sorties + 2 PTR papier · —122 = 59  
gérés + 32 ≤ 15 k\$ + 30 ETF + 1 renommage

## II.3c · Cohérence — reconstruire n'est pas vérifier : 9 sur 10 sans preuve

Chambre uniquement

chacun des **900** membres reçoit **un seul statut** — du moins au plus exigeant :

**20** hors d'atteinte — rien d'exploitable (patrimoine 100 % non coté, blind trust)

**715** restructurable partiel — au moins une photo **ou** des transactions → des **morceaux datés**


**109** restructurable complet — série datée de bout en bout... mais pas de photo de **sortie** : non testable

**56** vérifiable strict — les deux photos + actions cotées → l'équation **réellement testée** (le 87,8 %)

$20 + 715 + 109 + 56 = 900$  — une partition, rien ne se recouvre

**CHOIX** — on affiche le **périmètre réel du test** (56 membres) plutôt que de laisser croire à une vérification universelle — ~9 reconstruits sur 10 restent **sans preuve**.

## II.4 · Quiver — nous retrouvons > 92 % de sa base, et nous en sommes le sur-ensemble



au niveau (élu, ticker, sens) : 93,5 % / 92,1 % des combinaisons *de Quiver* sont retrouvées *chez nous*

Quiver = fournisseur commercial des mêmes données — notre mètre externe

**trois crans de stricte** — on serre la vis :

- 1 · **exister** même élu, même titre, même sens
- 2 · **dater** même date ( $\leq 10$  j) — appariés un à un
- 3 · **concorde** sens 96,8 % · montant 94,2 % (Chambre)

**Chambre  $\neq$  Sénat** — Quiver **voit** le papier de la Chambre (d'où le gating de I.3b) mais est **aveugle** au papier du Sénat (d'où I.3d).

**CHOIX** — Quiver est une **vérité-terrain jamais réinjectée** : il **mesure** la table, ne la remplit jamais — et en cas de désaccord de date, le **PDF officiel arbitre toujours** (annexe A6).

## 11.5 · Les autres preuves, et le principe : rien n'est réinjecté

### Collectes indépendantes

deux projets tiers ayant collecté les mêmes sources publiques : **100 %** et **99,5 %** de leurs lignes retrouvées chez nous

### Agrégateur tiers

comptes par déposant recoupés automatiquement — confirme les déposants où notre OCR est l'**unique source**

### Re-run reproductible

**368** signatures de fichiers figées : chaque nouvelle exécution doit reproduire les tables livrées à l'**octet près** — aucune régression silencieuse

**le principe** — aucune source externe n'est **réinjectée** dans les tables : elles ne servent qu'à **mesurer** ce qu'on a

**Réponse** — rien raté (100 % de l'univers · 173 actions résiduelles côté patrimoine · 27 + 11 vrais trous face au tiers) · cohérent dedans (87,8 % des positions expliquées) · sur-ensemble dehors (> 92 % de la base du tiers retrouvée).

# La couche données, en quatre chiffres

## PARTIE I — construire

acquisition → tri → extraction → identité → tickers →  
secteurs → dédup → entonnoir → table

## PARTIE II — prouver

univers → autres types → cohérence → Quiver →  
autres preuves

**100 %**

de l'univers officiel  
(8 252 PTR Chambre)  
traité

**169 000**

transactions uniques,  
identifiées à 100 %

**> 92 %**

base du tiers retrouvée  
· 87,8 %  
des positions expliquées

**134 464 × 36**

lignes × colonnes,  
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites

Annexes

# La réserve pour questions

---

A1–A7 : documents exemples · détails des cascades · cas particuliers

# A1 — Le document lisible : un PTR électronique

**PERIODIC TRANSACTION REPORT**

Filing ID #20009426

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

**FILER INFORMATION**  
**Name:** Hon. John A. Yarmuth  
**Status:** Member  
**State/District:** KY03

**TRANSACTIONS**

| ID | Owner Asset                                             | Transaction Type | Date       | Notification Date | Amount             | Cap. Gains > \$200?                 |
|----|---------------------------------------------------------|------------------|------------|-------------------|--------------------|-------------------------------------|
|    | Altria Group, Inc. (MO) [ST]<br>Filing Status: New      | S (partial)      | 03/23/2018 | 04/07/2018        | \$1,001 - \$15,000 | <input checked="" type="checkbox"/> |
|    | Boeing Company (BA) [ST]<br>Filing Status: New          | S (partial)      | 03/15/2018 | 04/07/2018        | \$1,001 - \$15,000 | <input checked="" type="checkbox"/> |
|    | Micron Technology, Inc. (MU) [ST]<br>Filing Status: New | P                | 03/27/2018 | 04/07/2018        | \$1,001 - \$15,000 | <input type="checkbox"/>            |
|    | Wells Fargo & Company (WFC) [ST]<br>Filing Status: New  | S (partial)      | 03/20/2018 | 04/07/2018        | \$1,001 - \$15,000 | <input type="checkbox"/>            |

\* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

**INITIAL PUBLIC OFFERINGS**  
☒ Yes ☐ No

**CERTIFICATION AND SIGNATURE**  
☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.  
**Digitally Signed:** Hon. John A. Yarmuth , 05/02/2018

- un PDF **lisible par machine** (couche texte)
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification — cette dernière est jetée) + fourchette de montant
- **7 996** lignes au montant coupé en deux, recollées avant lecture

PTR électronique complet (Hon. John A. Yarmuth, KY03)

# A2 — Le portail du Sénat : la recherche, puis la liste

UNITED STATES SENATE  
FINANCIAL DISCLOSURES

Find Reports

### Find Reports

Note Reports will display in the format they were filed: either **electronically (text)** or on **paper (images)**.

#### Search Options

Filer Name ? First name (starts with) Last name (starts with)

Filer Type ☒ Senator ☐ Candidate

All States All States ☐ Former Senator

Report Types ? ☐ Annual ☐ Due Date Extension ☐ Other Documents

☒ Periodic Transactions ☐ Blind Trusts

Date Filed/Received ? From To

When selected, reports will open in a new tab or window.

Search Reports

le formulaire : on coche **Senator** × **PTR** — c'est ce qui remplace l'index de la Chambre

UNITED STATES SENATE  
FINANCIAL DISCLOSURES

Find Reports

Note Reports will display in the format they were filed: either **electronically (text)** or on **paper (images)**.

Search Again

### Search Results

Reports will open in a new tab or window.

Filter list by name, office, report type, date

Showing 1 to 25 of 1,705 entries

| First Name (Middle) | Last Name (Suffix) | Office (Filer Type)       | Report Type                                                | Date Received/Filed |
|---------------------|--------------------|---------------------------|------------------------------------------------------------|---------------------|
| James               | Banks              | Banks, James E. (Senator) | <a href="#">Periodic Transaction Report for 06/26/2025</a> | 06/26/2025          |
| James               | Banks              | Banks, James E. (Senator) | <a href="#">Periodic Transaction Report for 08/10/2025</a> | 08/10/2025          |
| James               | Banks              | Banks, James E. (Senator) | <a href="#">Periodic Transaction Report for 03/10/2025</a> | 03/10/2025          |
| John A              | Barrasso           | Barrasso, John (Senator)  | <a href="#">Periodic Transaction Report for 05/24/2018</a> | 05/24/2018          |
| Michael F           | Bennet             | Bennet, Michael (Senator) | <a href="#">Periodic Transaction Report for 07/12/2021</a> | 07/12/2021          |
| Michael F           | Bennet             | Bennet, Michael (Senator) | <a href="#">Periodic Transaction Report for 05/18/2023</a> | 05/18/2023          |
| Michael F           | Bennet             | Bennet, Michael (Senator) | <a href="#">Periodic Transaction Report for 02/07/2017</a> | 02/07/2017          |
| Michael F           | Bennet             | Bennet, Michael (Senator) | <a href="#">Periodic Transaction Report for 04/03/2019</a> | 04/03/2019          |
| Michael F           | Bennet             | Bennet, Michael (Senator) | <a href="#">Periodic Transaction Report for 09/02/2020</a> | 09/02/2020          |
| Michael F           | Bennet             | Bennet, Michael (Senator) | <a href="#">Periodic Transaction Report for 10/18/2022</a> | 10/18/2022          |

la liste réelle : un lien par dépôt — chacun s'ouvre en page web ou en scan

les PTR sont **un type parmi d'autres** au Sénat aussi (annuels, extensions, *blind trusts*. . .) — on ne demande que les PTR

# A3 — Le même formulaire, des sections en commun

Les sections A→J, et lesquelles apparaissent dans chaque type de document

|   | P                                       | Identiques |        | Identiques |        |
|---|-----------------------------------------|------------|--------|------------|--------|
|   |                                         | C          | H      | O          | T      |
|   | PTR                                     | candidat   | entrée | annuel     | sortie |
| A | Actifs & revenus de placement           | ✓          | ✓      | ✓          | ✓      |
| B | TRANSACTIONS                            | ✓          |        | ✓          | ✓      |
| C | Revenus du travail                      | ✓          | ✓      | ✓          | ✓      |
| D | Dettes                                  | ✓          | ✓      | ✓          | ✓      |
| E | Postes occupés                          | ✓          | ✓      | ✓          | ✓      |
| F | Accords                                 | ✓          | ✓      | ✓          | ✓      |
| G | Cadeaux                                 |            |        | ✓          | ✓      |
| H | Voyages payés                           |            |        | ✓          | ✓      |
| I | Dons à une œuvre (au lieu d'honoraires) |            |        | ✓          | ✓      |
| J | Compensation > 5 000 \$ d'une source    | ✓          | ✓      |            |        |

socle commun A · C · D · E · F (dans tous sauf le PTR) — seule la section B (transactions) nous intéresse

→ B n'existe que dans le PTR, l'annuel (O) et la sortie (T)

*l'amendement A reprend les sections du document qu'il corrige (C-H ou O-T)*

la **section B** = les transactions ; le reste est un socle commun, la **A** (patrimoine) sert à *vérifier*

# A4 — Les types administratifs, et le cas à part

cinq types sans aucune transaction :



**X — Extension**  
demande de délai



**D — Campaign Notice**  
« < 5 000 \$ »



**W — idem, papier**  
(ou retrait)



**E — Exemption**  
départ, poste fédéral



**G — Gift Waiver**  
dérogation cadeau



**B — Blind Trust** (23 dépôts) : la banque du *trust* liste de vraies ventes, mais **pas** décidées par l'élu : la fiducie aveugle.

et les candidats **C** : 10 105 dépôts, 77 % jamais élus — une photo de patrimoine qui peut servir de photo d'entrée

# A5 — Ce que les O/A/T ajoutent : du patrimoine, pas du signal

une fois doublons **et** échos des PTR retirés, il reste dans les annuels (O), sorties (T) et amendements (A) :

26 115

trades jamais vus  
dans un PTR

22 216

via les annuels O

3 899

via sorties T  
+ amendements A

374 j

délai médian  
trade → publication

ces trades **comblent des trous du portefeuille** (l'élú oublie son PTR mais l'inscrit à l'annuel) —  
découverts **~1 an trop tard** : ils nourrissent le **patrimoine**, jamais le **signal**

les 26 115 sont surtout des **ETF/fonds cotés** — les vraies **actions** manquantes au signal = **173**, toutes pré-2018

ne pas confondre : **26 115** (net hors-PTR, cohérence interne)  $\neq$   $\approx$  **26 500** (combinaisons présentes chez nous et absentes chez Quiver, corroboration) — source : audit patrimoine Chambre, table de flux nette (lignée v1-house)

## A6 — Qui a raison sur les dates ? Le PDF officiel arbitre toujours

pour un même (élu, ticker, sens), quand notre date et celle de Quiver divergent dans un même dépôt, **545**  
**candidats** méritent l'œil → on **rouvre le PDF** :

| le PDF montre...                | exemple réel       | traitement                     |
|---------------------------------|--------------------|--------------------------------|
| coquille du déposant, prouvable | 3031-04-30         | corrigée → 2021                |
| coquille littérale              | 01/35/22           | <b>transcrite telle quelle</b> |
| notre OCR s'est trompé          | Khanna/COST 09-31  | re-lue au PDF → 08-16          |
| désaccord Quiver                | McCaul/GOOGL Δ11 j | arbitré au PDF                 |

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

# A7 — Détails : la couverture des entrées/sorties, les pièges d'identité

## couverture des entrées/sorties (Chambre) :

---

**470 entrées** depuis 2014 · 82 % ont déposé un **H** (photo d'entrée) · 16 % un **C** à la place → **98 % couverts**

---

**463 sorties** définitives · 81 % ont déposé un **T** (photo de sortie) ; les 86 sans **T** : partis au Sénat/exécutif (dispensés), décès

---

la photo d'entrée : **252** ancrés par un **H** · **32** par un **C** = **284** portefeuilles d'entrée datés

## pièges d'identité réels, réparés (l.4) :

- l'homonyme **Bob Casey** (C000228 → C001070) : deux vraies personnes — un représentant du Texas, un sénateur de Pennsylvanie
- **42 lignes d'Angie Craig** sans identifiant, réparées à la lecture — le fichier extrait, lui, reste figé

## cascade secteur (l.6) :

yfinance (le secteur factuel) → LLM contraint GICS → overrides manuels pour les cas connus