

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Depuis 2012, chaque élu du Congrès doit déclarer ses transactions en bourse

le **STOCK Act** (2012) : toute transaction boursière de plus de 1 000 \$ d'un élu doit être déclarée dans un *Periodic Transaction Report* (« **PTR** »)

45 j

le délai légal pour
déclarer un trade

2014–2026

la fenêtre étudiée
(la loi date de 2012)

2 chambres

435 représentants
+ 100 sénateurs

la question de recherche : ces déclarations publiques peuvent-elles nourrir une stratégie d'investissement ?

La couche données, en quatre résultats

169 000

transactions uniques,
identité rattachée à
100 %

100 %

des 8 252 déclarations
officielles (PTR) de la
Chambre traitées

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

la table de recherche
livrée, limites écrites

Le plan — deux parties : on construit, puis on prouve

PARTIE I — Construire la table

de la source publique au CSV livré

0	Le pipeline	le flux complet, en une image
1	Acquisition & Tri	la Chambre en entier, puis le Sénat en entier
2	Extraction	4 voies · les 2 dates · le corpus
3	Identité	le nom → l'élue officiel
4	Tickers	le symbole boursier
5	Secteurs	GICS → ETF
6	Dédup	l'empreinte 7 champs
7	Entonnoir	ce qu'on retire, et pourquoi
8	Table finale	à quoi ressemble la valeur

PARTIE II — Vérifier la table

rien raté, rien inventé


II.0	Trois questions	le cadre de la preuve
II.1	L'univers	a-t-on tout traité ?
II.2	Les autres types	les 11 dépôts hors PTR
II.3	La cohérence	les flux se recollent-ils ?
II.4	Quiver	le mètre externe
II.5	Les autres preuves	et le principe

PARTIE I


Construire la table

De $\sim 10\,000$ documents publics hétérogènes à une seule table

0 · Le pipeline complet — tout le trajet de la donnée



1 · Acquisition & Tri



Où vivent ces déclarations, lesquelles faut-il lire — et dans quel état arrivent-elles ?

ce qu'on en sort : l'univers à traiter — 8 252 PTR à la **Chambre**, que l'index officiel *déclare* · 2 153 au **Sénat**, qu'il faut *recenser* — répartis en 4 sous-corpus (chambre × format)

1a · Acquisition Chambre — récupérer les dépôts depuis l'index annuel




disclosures-clerk.house.gov

une **archive par année**, 2014→2026

elle contient l'**index annuel**

un bloc par **dépôt**

le **n° (DocID)** donne l'**URL** du PDF




l'index réel : chaque dépôt y déclare son type, sa **date de dépôt** (**divulgarion**) et son numéro de document

exemple — le dépôt surligné (n° 20024277) s'ouvre à :

https://disclosures-clerk.house.gov/public_disc/ptr-pdfs/2024/20024277.pdf

35 315 dépôts de tous types · **13 années** couvertes

1b · Tri Chambre — choisir les PTR : on lit la lettre P dans l'index



l'index déclare le **type** de chaque dépôt — on ne garde que le type **P** (les **PTR**, les seules transactions datées) :
8 252 sur 35 315

les **11 autres types** pourraient être intéressants — on les **regardera** dans une autre partie


1c · Tri Chambre — distinguer les PTR lisibles des scannés

le **DocID** annonce déjà le format — il commence par 2... = **lisible**, ou par 8.../9... = **scanné** :

Symbol	Asset	Transaction Type	Transaction Date	Transaction Amount	Cap. Amount
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00
AMSTOCK	American Stock	Buy	10/1/2010	100.00	100.00

PDF lisible — 71 %

couche texte, lu directement · DocID en 2...



PDF scanné — 29 %

image, à lire par **OCR** · DocID en 8.../9...

deux mondes, deux extracteurs : le texte se **parse** (2a), l'image passe par l'**OCR** (2b)

1d · Acquisition Sénat — accéder au portail eFD

UNITED STATES SENATE
FINANCIAL DISCLOSURES

United States Senate Financial Disclosures (eFD)

Public disclosure of a government official's personal financial interests is a key component to an effective code of conduct. For more information on filing, including who files, and the types of reports filed, see the [United States Senate's Select Committee on Ethics website](#).

Select Reports are Available

This site includes financial disclosure reports for Senators, former Senators and Senate candidates filed from 2012 to present. Senator reports are available for six years from the date a Senator ceases to be a Member of Congress. Candidate reports are available for one year after the individual is no longer a candidate.

Additional Reports

All financial disclosure reports are available through the Office of the Secretary of the Senate kiosk:

Office of Public Records
144 Hart Senate Office Building
Washington, D.C. 20510-7196
phone (202) 224-0332

Q Get Access

You must agree to the following to be able to search reports.

Title 1 of the Ethics in Government Act of 1976, as amended, 5 U.S.C. app. § 105(c), states that:

1. It shall be unlawful for any person to obtain or use a report:
 1. for any unlawful purpose;
 2. for any commercial purpose, other than by news and communications media for dissemination to the general public;
 3. for determining or establishing the credit rating of any individual; or
 4. for use, directly or indirectly, in the solicitation of money for any political, charitable, or other purpose.
2. The Attorney General may bring a civil action against any person who obtains or uses a report for any purpose prohibited in paragraph (1) of this subsection. The court in which such action is brought may assess against such person a penalty in any amount not to exceed \$10,000. Such remedy shall be in addition to any other remedy available under statutory or common law.

☐ I understand the prohibitions on obtaining and use of financial disclosure reports.

efdsearch.senate.gov — la page d'accès

la barrière : accord + jeton (CSRF)

- une **case obligatoire** : accepter l'accord avant toute recherche
- notre collecteur l'accepte, récupère le **jeton de session**
- ensuite seulement : on peut **interroger** le portail

l'angle mort, annoncé tout de suite — le fournisseur commercial qui nous servira de mètre externe (Quiver, Partie II) ne voit **pas** le papier du Sénat : cette voie ne sera validable qu'**en interne** (2d).

1e · Tri Sénat — choisir les PTR : Senator × PTR, puis la liste

The screenshot shows the 'Find Reports' search interface on the United States Senate Financial Disclosures website. It includes search options for Filer Name, Filer Type (Senator, Candidate, Former Senator), Report Types (Annual, Periodic Transactions, Due Date Extension, Blind Trusts, Other Documents), and Date Filed/Received. A 'Search Reports' button is at the bottom.

on coche **Senator** × **PTR** → la liste des dépôts

2 160 Periodic Transactions = 42 % des 5 096 dépôts

corpus 2014-2026 — tous types

par **Report Type** (somme = 100 %)


Annual  2 165 · 42 %

Periodic Transactions  2 160 · 42 %

Due Date Extension  753 · 15 %

Blind Trusts · Other < 1 %

par **Filer Type** (tous déposants · somme = 5 096)

 Senator 66 %  Former 24 % Candidate 10 %

le PTR est **un type parmi d'autres** — on **choisit les PTR**, les autres **dans une autre partie** · les candidats ne trahent quasi pas (13 PTR) ; **31 %** des PTR = anciens sénateurs

1f · Tri Sénat — distinguer page web et papier scanné

au **Sénat**, chaque dépôt s'ouvre soit en **page web** (texte), soit en **image scannée** (à lire par OCR) :


UNITED STATES HOUSE OF REPRESENTATIVES
FINANCIAL DISCLOSURES

[Return to the search box to select another report.](#)

Periodic Disclosure Report for 03/10/2018

The Honorable James Banks (Banks, James E.)

Filed 03/10/2018 @ 12:04 PM

[View Full Report](#)

The following statements were checked before filing:

- ☒ I certify that the statements I have made on this form are true, complete and correct to the best of my knowledge and belief.
- ☒ I understand that reports cannot be edited once filed. To make corrections, I will submit an electronic amendment to this report.

Transactions (1 transaction total) 0 Self 1 Spouse 3 Dependent Child

#	Transaction Date	Donor	Filer	Asset Name	Asset Type	Type	Amount	Comment
1	03/10/2018	Joint	JMB/EJB	Yacht 6 weeks Chaparral Yacht (Lansdowne, KY) Description: Yacht	Other	Sale (Full)	\$1,001 - \$75,000	--

page web — 1780

table déjà propre, lue directement

JANUARY 2008	MINUTES OF THE MEETING OF THE BOARD	Date: December 26, 2007
--------------	-------------------------------------	-------------------------

Meeting of the Board
Agenda Item 10
Resolution of the Board
Resolution of the Board
Resolution of the Board

RESOLUTION OF THE BOARD

OF THE BOARD

OF THE BOARD

Page 1 of 1

Resolution Number	Resolution Title	Effective Date	Status	Action	Comments
1	Resolution of the Board				
2	Resolution of the Board				
3	Resolution of the Board				
4	Resolution of the Board				
5	Resolution of the Board				
6	Resolution of the Board				
7	Resolution of the Board				
8	Resolution of the Board				
9	Resolution of the Board				
10	Resolution of the Board				
11	Resolution of the Board				
12	Resolution of the Board				
13	Resolution of the Board				
14	Resolution of the Board				
15	Resolution of the Board				
16	Resolution of the Board				
17	Resolution of the Board				
18	Resolution of the Board				
19	Resolution of the Board				
20	Resolution of the Board				
21	Resolution of the Board				
22	Resolution of the Board				
23	Resolution of the Board				
24	Resolution of the Board				
25	Resolution of the Board				
26	Resolution of the Board				
27	Resolution of the Board				
28	Resolution of the Board				
29	Resolution of the Board				
30	Resolution of the Board				
31	Resolution of the Board				
32	Resolution of the Board				
33	Resolution of the Board				
34	Resolution of the Board				
35	Resolution of the Board				
36	Resolution of the Board				
37	Resolution of the Board				
38	Resolution of the Board				
39	Resolution of the Board				
40	Resolution of the Board				
41	Resolution of the Board				
42	Resolution of the Board				
43	Resolution of the Board				
44	Resolution of the Board				
45	Resolution of the Board				
46	Resolution of the Board				
47	Resolution of the Board				
48	Resolution of the Board				
49	Resolution of the Board				
50	Resolution of the Board				
51	Resolution of the Board				
52	Resolution of the Board				
53	Resolution of the Board				
54	Resolution of the Board				
55	Resolution of the Board				
56	Resolution of the Board				
57	Resolution of the Board				
58	Resolution of the Board				
59	Resolution of the Board				
60	Resolution of the Board				
61	Resolution of the Board				
62	Resolution of the Board				
63	Resolution of the Board				
64	Resolution of the Board				
65	Resolution of the Board				
66	Resolution of the Board				
67	Resolution of the Board				
68	Resolution of the Board				
69	Resolution of the Board				
70	Resolution of the Board				
71	Resolution of the Board				
72	Resolution of the Board				
73	Resolution of the Board				
74	Resolution of the Board				
75	Resolution of the Board				
76	Resolution of the Board				
77	Resolution of the Board				
78	Resolution of the Board				
79	Resolution of the Board				
80	Resolution of the Board				
81	Resolution of the Board				

papier scanné — 373

image, à lire par **OCR**

1g · Le manuscrit — le vrai point dur de l'image scannée

un scan n'est pas du texte, c'est une **image** (à lire par **OCR** : lecture automatique) — ce qui compte n'est pas l'orientation mais **tapé vs manuscrit** :

Tapé, droit

dactylographié, lisible tel quel

Tapé, couché

tourné à 90° — lu quand même

Manuscrit

à la main, cursif — le vrai point dur

775 scans manuscrits sur les 2 424 scans Chambre recensés

Chambre ≠ Sénat — le manuscrit existe des **deux** côtés — mais il sera écarté à la Chambre et **gardé** au Sénat : la raison, et elle seule, est la **vérifiabilité** (2b et 2d).

1h · Bilan du tri — quatre sous-corpus, quatre extracteurs

la même donnée réglementaire arrive sous **4 formats** (chambre × format) — deux mondes **texte**, deux mondes **image** :

Chambre · PDF lisible

texte

→ parsing (2a)

Chambre · PDF scanné

image

→ OCR (2b)

Sénat · page web

texte

→ lecture (2c)


Sénat · papier scanné

image

→ OCR (2d)

Chambre = Sénat — chaque chambre a son monde texte et son monde image — au final **57,5 %** du corpus vient d'**images** (le gros des transactions), et chaque voie reçoit son **extracteur dédié** : c'est le plan des **4 slides d'Extraction** qui suivent.

2 · Extraction



Comment fait-on sortir des transactions d'un PDF, d'une page web, d'une image ?

ce qu'on en sort : les **4 voies** lues : $58\,756 + 93\,325 + 14\,813 + 4\,026 = 170\,920$ transactions extraites (avant dédoublonnage) — **tous types d'actifs** gardés ; le tri par type ne vient qu'à l'entonnoir (7)

2a · Extraction Chambre · texte — un PDF n'est pas un tableau

ID	Owner Asset	Transaction Type	Transaction Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] FILING STATUS: New SCHEDULED ON: CHARLES SWARB ACCOUNT	P	04/17/2018	04/17/2018	\$15,001 - \$50,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] FILING STATUS: New SCHEDULED ON: CHARLES SWARB ACCOUNT	S	04/17/2018	04/17/2018	\$15,001 - \$50,000	
	Microsoft Corporation (MSFT) [ST] FILING STATUS: New SCHEDULED ON: CHARLES SWARB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$50,000	
	Spectro Energy Partners, LP Common Units representing Limited Partner Interests (SEP) [ST] une seule transaction, libellé sur 4 lignes SCHEDULED ON: CHARLES SWARB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	

* For the complete list of asset true abbreviations, please visit <https://fd.house.gov/reference/asset-true-codes.aspx>.

58 756 lignes extraites → 58 728 uniques


1. recoller les lignes coupées
2. repérer la **signature** d'une transaction : opération + 2 dates + fourchette
3. rattacher l'actif et le ticker imprimés à proximité

extrait réel — le montant déborde sur la ligne suivante, le libellé court sur 4 lignes : **un parseur naïf raterait la moitié**

pas d'IA ici : du code déterministe, rejouable à l'identique

CHOIX — deux gabarits de formulaire coexistent (l'ancien sans code type d'actif, le moderne avec [ST], apparu vers 2018) : ils sont **routés document par document**, jamais par année fixe.

2b · Extraction Chambre · image — Vision lit tout, le manuscrit est écarté




- l'**OCR par IA** (Claude Vision) lit le tapé, même tourné à 90°
- **93 325 lignes extraites → 93 261 uniques**
- très concentrées : les gros déposants « 100 % papier » (2f)

la mesure — Quiver Quantitative (fournisseur commercial des mêmes données, notre mètre externe — Partie II), *même sans exiger la date*, ne corrobore que **12,9 %** du manuscrit, contre **88 %** du tapé droit

582 PTR manuscrits écartés — 7,1 % de l'index

CHOIX — on ne met en table que ce qu'on sait lire : les 582 PTR manuscrits sont écartés par une **règle écrite et rejouable**, avec exceptions explicites — pas de lectures douteuses injectées dans la donnée.

2c · Extraction Sénat · texte — une table déjà propre, stable sur 13 ans



The screenshot shows a 'Periodic Transaction Report for 03/10/2025' for 'The Honorable James Banks (Banks, James E.)'. It includes a 'Print Report' button and a disclaimer. Below is a table of transactions.

#	Transaction Date	Owner	Ticker	Asset Name	Asset Type	Type	Amount	Comment
1	02/18/2025	Joint	ZUMZ	Yum Brands Company Yum (Louisville, KY) Description Food	Other	Sale (PUB)	\$1,001 - \$15,000	...

la déclaration électronique : une vraie table, ticker cliquable — rien à reconstruire

14 813 lignes extraites → 13 026 uniques

1. une **page par dépôt**, mise en cache
2. **lecture des tableaux** : colonnes repérées par leurs intitulés
3. rien d'autre — le gabarit ne change pas

les 9 mêmes colonnes sur toutes les pages 2014→2026 (vérifié) : ce qui varie, ce sont les *amendements* et le *non-coté*, pas le format

c'est ici que la dédup travaille — 1 787 des 14 813 lignes (12 %) sont des **re-dépôts annuels** : cette seule voie porte **93 %** du dédoublement (6)

Chambre ≠ Sénat — là où la **Chambre** impose de **reconstruire** un PDF (2a), le **Sénat** électronique se lit **directement** — **déterministe et sans IA** des deux côtés, mais il **re-déclare** bien plus (12 %, contre 0,05 % à la Chambre électronique).

2d · Extraction Sénat · image — le papier est gardé, faute de
mètre externe

1040-1070SS (2012)	NOLAN, JEFFREY D.	FEDERAL OF NEW YORK	Date: December 01, 2013																																																																																																																																																																																																															
This Report Should Be Filed With: Secretary of State 140 Nassau Street New York, NY 10038 Washington, DC 20540 FILING INFORMATION OF FINANCIAL TRANSACTIONS (Check one)																																																																																																																																																																																																																		
Registration Number: 1040-1070SS ☒ Amended		United States Person or Foreign? ☒ United States Person																																																																																																																																																																																																																
Richard Sumner III		Page Number: 1																																																																																																																																																																																																																
Insert any additions, deletions, or corrections to the information previously reported on this filing. If days of missing information are requested, explain the reason below. Insert any additions, deletions, or corrections to the information previously reported on this filing. If days of missing information are requested, explain the reason below. Insert any additions, deletions, or corrections to the information previously reported on this filing. If days of missing information are requested, explain the reason below. Insert any additions, deletions, or corrections to the information previously reported on this filing. If days of missing information are requested, explain the reason below. Insert any additions, deletions, or corrections to the information previously reported on this filing. If days of missing information are requested, explain the reason below.																																																																																																																																																																																																																		
Declaration of Accuracy: I, the undersigned, declare under penalty of perjury that the information furnished on this filing is true and correct to the best of my knowledge and belief, and that I am a United States Person. Signature: _____ Date: _____		Amount of Transaction(s) <table border="1" style="width: 100%; border-collapse: collapse;"> <tr> <th>Transaction Type</th> <th>Transaction Date (mm, day, year)</th> <th>Transaction Amount</th> </tr> <tr> <td>1. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>2. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>3. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>4. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>5. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>6. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>7. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>8. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>9. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>10. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>11. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>12. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>13. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>14. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>15. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>16. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>17. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>18. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>19. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>20. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>21. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>22. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>23. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>24. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>25. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>26. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>27. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>28. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>29. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>30. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>31. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>32. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>33. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>34. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>35. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>36. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>37. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>38. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>39. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>40. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>41. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>42. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>43. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>44. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>45. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>46. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>47. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>48. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>49. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>50. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>51. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>52. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>53. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>54. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>55. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>56. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>57. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>58. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>59. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>60. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>61. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>62. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>63. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>64. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>65. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>66. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>67. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td> </tr> <tr> <td>68. Cash</td> <td>12/01/2012</td> <td>\$10,000.00</td></tr></table>		Transaction Type	Transaction Date (mm, day, year)	Transaction Amount	1. Cash	12/01/2012	\$10,000.00	2. Cash	12/01/2012	\$10,000.00	3. Cash	12/01/2012	\$10,000.00	4. Cash	12/01/2012	\$10,000.00	5. Cash	12/01/2012	\$10,000.00	6. Cash	12/01/2012	\$10,000.00	7. Cash	12/01/2012	\$10,000.00	8. Cash	12/01/2012	\$10,000.00	9. Cash	12/01/2012	\$10,000.00	10. Cash	12/01/2012	\$10,000.00	11. Cash	12/01/2012	\$10,000.00	12. Cash	12/01/2012	\$10,000.00	13. Cash	12/01/2012	\$10,000.00	14. Cash	12/01/2012	\$10,000.00	15. Cash	12/01/2012	\$10,000.00	16. Cash	12/01/2012	\$10,000.00	17. Cash	12/01/2012	\$10,000.00	18. Cash	12/01/2012	\$10,000.00	19. Cash	12/01/2012	\$10,000.00	20. Cash	12/01/2012	\$10,000.00	21. Cash	12/01/2012	\$10,000.00	22. Cash	12/01/2012	\$10,000.00	23. Cash	12/01/2012	\$10,000.00	24. Cash	12/01/2012	\$10,000.00	25. Cash	12/01/2012	\$10,000.00	26. Cash	12/01/2012	\$10,000.00	27. Cash	12/01/2012	\$10,000.00	28. Cash	12/01/2012	\$10,000.00	29. Cash	12/01/2012	\$10,000.00	30. Cash	12/01/2012	\$10,000.00	31. Cash	12/01/2012	\$10,000.00	32. Cash	12/01/2012	\$10,000.00	33. Cash	12/01/2012	\$10,000.00	34. Cash	12/01/2012	\$10,000.00	35. Cash	12/01/2012	\$10,000.00	36. Cash	12/01/2012	\$10,000.00	37. Cash	12/01/2012	\$10,000.00	38. Cash	12/01/2012	\$10,000.00	39. Cash	12/01/2012	\$10,000.00	40. Cash	12/01/2012	\$10,000.00	41. Cash	12/01/2012	\$10,000.00	42. Cash	12/01/2012	\$10,000.00	43. Cash	12/01/2012	\$10,000.00	44. Cash	12/01/2012	\$10,000.00	45. Cash	12/01/2012	\$10,000.00	46. Cash	12/01/2012	\$10,000.00	47. Cash	12/01/2012	\$10,000.00	48. Cash	12/01/2012	\$10,000.00	49. Cash	12/01/2012	\$10,000.00	50. Cash	12/01/2012	\$10,000.00	51. Cash	12/01/2012	\$10,000.00	52. Cash	12/01/2012	\$10,000.00	53. Cash	12/01/2012	\$10,000.00	54. Cash	12/01/2012	\$10,000.00	55. Cash	12/01/2012	\$10,000.00	56. Cash	12/01/2012	\$10,000.00	57. Cash	12/01/2012	\$10,000.00	58. Cash	12/01/2012	\$10,000.00	59. Cash	12/01/2012	\$10,000.00	60. Cash	12/01/2012	\$10,000.00	61. Cash	12/01/2012	\$10,000.00	62. Cash	12/01/2012	\$10,000.00	63. Cash	12/01/2012	\$10,000.00	64. Cash	12/01/2012	\$10,000.00	65. Cash	12/01/2012	\$10,000.00	66. Cash	12/01/2012	\$10,000.00	67. Cash	12/01/2012	\$10,000.00	68. Cash	12/01/2012	\$10,000.00
Transaction Type	Transaction Date (mm, day, year)	Transaction Amount																																																																																																																																																																																																																
1. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
2. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
3. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
4. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
5. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
6. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
7. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
8. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
9. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
10. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
11. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
12. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
13. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
14. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
15. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
16. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
17. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
18. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
19. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
20. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
21. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
22. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
23. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
24. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
25. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
26. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
27. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
28. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
29. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
30. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
31. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
32. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
33. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
34. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
35. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
36. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
37. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
38. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
39. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
40. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
41. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
42. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
43. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
44. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
45. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
46. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
47. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
48. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
49. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
50. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
51. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
52. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
53. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
54. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
55. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
56. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
57. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
58. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
59. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
60. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
61. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
62. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
63. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
64. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
65. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
66. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
67. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																
68. Cash	12/01/2012	\$10,000.00																																																																																																																																																																																																																

le formulaire papier Sénat

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

Apple Computer Inc · **Sale**
 2022-03-14 · code A (1 001–15 000 \$)

4 026 lignes → 3 985 uniques — 14 déposants — 2,4 % du corpus

même moteur qu'à la Chambre (2b) — mais **politique inverse** : Quiver est **aveugle au papier du Sénat** → aucune mesure d'exclusion possible → on **garde**, sous garde-fous internes, et on l'écrit

couverture ticker plus basse sur cette voie = **composition**, pas défaut :


Blumenthal porte 38,7 % de la voie, massivement du non-côté

CHOIX — on n'écarte que ce qu'on a pu **mesurer** — l'asymétrie Chambre/Sénat (écarté là, gardé ici) est **documentée**, **pas cachée**; le risque est borné (2,4 % du corpus).

2e · Ce qu'on extrait de chaque ligne : deux dates, une seule est fiable

Date de DÉPÔT (divulgarion)

toujours une métadonnée — jamais lue dans le document, jamais OCRisée ; **fiable** → c'est la date **signal**



CHOIX — le signal est daté à la **date de dépôt**, jamais à la date du trade : c'est ce qu'un investisseur réel aurait su, quand il l'aurait su (**anti-look-ahead**) — et toute date de transaction douteuse est **flaguée, jamais réécrite au hasard**.

Date de TRANSACTION

lue dans le document (texte ou OCR) ; la **seule risquée** → garde-fous + flag, **jamais inventée**

l'écart entre les deux, c'est le **délai de divulgation** :


médiane 27 j Chambre · 24 j Sénat

Chambre = Sénat — sur les 4 voies, même schéma : la date de dépôt vient de l'index (Chambre) ou du listing (Sénat) ; celle du trade, du document.

2f · Le corpus extrait : 170 920 transactions — dont ~40 % de deux élus

les quatre voies réunies donnent **170 920 transactions extraites** (2014–2026), ramenées à **169 000 uniques** au dédoublonnage (6) — et cette matière est **très déséquilibrée** :


Sénat OCR 2,4 %



très concentré — Khanna (**41 080 txns**) et McCaul (**27 123**) pèsent à eux deux ~40 % du corpus, et déclarent **exclusivement sur papier** (100 % OCR)

le papier n'est pas un détail : c'est **la majorité du corpus** — d'où l'effort d'OCR de 2b et 2d


3 · Identité



À qui appartient chaque ligne, quand le formulaire n'offre qu'un nom libre ?
ce qu'on en sort : 100 % des lignes rattachées à un élu officiel

3 · Identité — chaque ligne est rattachée à un élu officiel : 100 %

un même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → on relie ce **nom libre** à un **identifiant unique**, par une cascade d'essais :



100 % des lignes rattachées


367 membres Chambre · 78 Sénat

le *bioguide* = l'identifiant officiel unique d'un élu au Congrès (annuaire public *congress-legislators*)

Chambre = Sénat — même cascade, même annuaire des deux côtés — d'où une seule slide ; le **Sénat** ajoute seulement une désambiguïsation (siège, titulaire en exercice).

CHOIX — les fichiers extraits sont **figés** ; toute réparation est appliquée **à la lecture**, jamais en réécrivant la source.

4 · Tickers



« Apple Computer Inc » : comment retrouver le symbole boursier derrière un nom écrit à la main ?

ce qu'on en sort : le ticker sur **84,1 %** des lignes Chambre · **77,9 %** Sénat

4a · Tickers — du nom de l'actif au symbole boursier, par une cascade tracée

1. **explicite** — déjà imprimé dans la source (l'électronique)



2. **dictionnaire** — le nom vu ailleurs dans le corpus (le papier)



3. **LLM** contraint « actions seulement »



4. **récupération** validée par double preuve — 2 540 lignes retrouvent leur symbole

Chambre = Sénat — même cascade des deux côtés — ce qui change est la **source** : l'électronique imprime souvent le symbole (étage 1), le papier dépend des étages 2–3.

ticker renseigné


84,1 % Chambre · **77,9 %** Sénat

les trois premiers étages couvrent **82,4 %** ; le 4^e (récupération) porte à **84,1 %**

couverture = remplissage, pas exactitude — les vides sont le **non-coté légitime** (munis, obligations, fonds privés), pas des défauts d'extraction ; l'écart Chambre/Sénat vient de la **composition** des portefeuilles

CHOIX — cascade **ordonnée et tracée**, du plus sûr au moins sûr — chaque étage est enregistré ligne à ligne : jamais une devinette silencieuse.

4b · Tickers — avant 2019, pas de code d'actif à la Chambre : c'est le symbole qui décide



part des lignes portant un code « type d'actif » ([ST], [OP]...) —
voies **électroniques**, là où le champ est *déclaré* à la source


Chambre ≠ Sénat — le trou est propre à la **Chambre** (formulaire tardif) ; le choix qui en découle est pourtant **commun aux deux voies** — on n'ancre jamais un actif sur un champ qui peut manquer.

le formulaire de la **Chambre** n'a **pas de case « type d'actif »** avant 2019 : ~0 % jusqu'en 2016, **99 %** dès 2019 — le **Sénat**, lui, l'a depuis 2015.

trier les actions sur ce champ rendrait **aveugles les archives anciennes** : **près de 13 000** actions de la Chambre déclarées **avant 2019** n'ont *que* leur **symbole** pour être reconnues.

CHOIX — « **ticker-first** » — c'est le **symbole coté** qui établit qu'une ligne est une action, **jamais** le champ déclaré (le tri l'applique en 7a).

5 · Secteurs



Dans quel secteur joue chaque titre — et par quel panier coté peut-on l'approcher ?

ce qu'on en sort : le secteur sur **79,8 %** des lignes Chambre · **70,4 %** Sénat

5 · Secteurs — chaque titre reçoit un secteur GICS, et son ETF

une cascade indépendante de celle du ticker :

1. **yfinance** — le secteur factuel de l'entreprise



2. **LLM** contraint GICS (+
garde-fou « est-ce coté ? »)



3. **overrides** manuels — les cas connus


secteur renseigné 79,8 % Ch. · 70,4 % Sén.

GICS = la classification sectorielle standard du marché — **11 secteurs**, chacun adossé à son **ETF Select Sector SPDR** (le panier coté du secteur) :

Energy→XLE · Materials→XLB · Industrials→XLI
· Cons. Discr.→XLY · Cons. Staples→XLP ·
Health Care→XLV · Financials→XLF · Info.
Tech.→XLK · Comm. Services→XLC ·
Utilities→XLU · Real Estate→XLRE

Chambre = Sénat — même cascade, même table de correspondance des deux côtés — l'écart de couverture vient de la **composition** des portefeuilles, pas de la méthode.

6 · Dédup



Un trade re-déclaré dans un amendement : comment le compter une fois — sans effacer les vrais lots ?
ce qu'on en sort : **169 000** transactions uniques (170 920 lignes brutes, —1 920)

6 · Dédup — une transaction = 7 champs : l’empreinte dédoublonne sans détruire


l’empreinte d’une transaction — 7 champs :

qui (déclarant) · **quand** (date du trade) · **quoi** (actif) · **sens** · **montant** (fourchette) · **pour qui** (détenteur) · **chambre**

elle exclut **délibérément** :

- le **ticker** — ajouté après coup (4), sa présence rendrait l’empreinte instable
- la **date de divulgation** — un dépôt et son amendement portent *de la même* trade → une seule transaction


CHOIX — dédup **non destructrice** : deux dépôts, même empreinte = un seul trade — mais un **vrai lot répété** (même titre, plusieurs comptes) est **préservé** par un compteur d’occurrence. Jamais de dédoublonnage aveugle.



Chambre = Sénat — **une seule empreinte** pour les deux chambres — c’est elle qui permet de **fusionner les 4 voies** sans compter deux fois. Seul le *taux* diffère : **93 %** des 1 920 re-divulgations viennent du **Sénat** électronique (2c).

au même moment, à la lecture : les **réparations** (7 996 montants tronqués rétablis · 2 540 tickers récupérés · 7 identités · 3 dates) — le **fichier extrait, lui, reste figé** (3)

7 · Entonnoir




Un backtest exige un prix de marché : que faut-il retirer, et sur quelle preuve ?

ce qu'on en sort : **deux entonnoirs, deux axes** — les **lignes** : **134 464** exploitables, 79,6 % du corpus (c'est le livrable) · puis, **en aval**, les **symboles** : **3 289** avec un prix → **118 029** trades backtestables, **sans retirer une seule ligne**

7a · Entonnoir — de 169 000 à 134 464 : on ne retire que l'avéré inutilisable

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



quatre portes objectives — **169 000** → **134 464** (79,6 % conservées) :

A — dates cohérentes : -3 252

B — actions + ETF cotés (un backtest exige un prix de marché) : -29 771


C — direction claire (achat ou vente) : -826

D — montant présent : -687

sauvetage « ticker-first » — 21 878 lignes à case « type d'actif » vide **gardées** : le **ticker coté** fait foi, pas la case déclarée (*pourquoi : 4b*)

CHOIX — on ne retire que l'**avéré inutilisable** ; le doute est **flagué, jamais retiré** (late filing 12,2 %, délistés, lots multi-comptes) — la recherche décide.

7b · Entonnoir (suite) — du symbole au prix : 118 029 trades valorisables



118 029 trades avec un prix fiable ($\approx 88\%$)


même valeur numérique que le taux de cohérence de la
Partie II : **pure coïncidence**, aucun lien

biais de survie assumé — un titre mort depuis
(faillite, rachat sans successeur) ne peut plus être
valorisé : couverture **74 %** en 2014 → **99 %** en
2026

CHOIX — la limite est **écrite**, pas cachée — les lignes
non couvertes **restent** dans la table, flaguées.

note : le moteur d'analyse aval filtre l'année du trade à 2013–2026 → il travaille sur **134 429** lignes (134 464 — 35 trades
à année aberrante, coquilles fidèlement transcrites)

8 · Table finale



Au bout du pipeline : à quoi ressemble, concrètement, une ligne livrée ?

ce qu'on en sort : la table de recherche — 134 464 × 36, limites écrites

8 · À quoi ressemble la valeur finale : 134 464 lignes × 36 colonnes

la table de recherche — 134 464 lignes × 36 colonnes · 372 élus · chaque ligne traçable à son document source

membre	ticker	sens	transaction	montant \$	secteur
Bob Gibbs	INTC	buy	2014-12-30	8 000,5	Info. Tech.
Greg Gianforte	BBAVY	sell	2018-12-12	32 500,5	Cons. Staples
Kim Schrier	AAPL	buy	2021-11-15	375 000,5	Info. Tech.
Tim Moore	HOG	buy	2025-12-09	32 500,5	Cons. Discr.

CHOIX — la loi ne donne qu'une **tranche** de montant (ex. 15 001–50 000 \$) : on retient son **milieu exact** (d'où les « ,5 ») — convention **unique et documentée** plutôt que fausse précision ; renseigné à **99,4 %**.

12 champs garantis sur chaque ligne, 2 chambres

déclarant · chambre · parti · commissions · date du trade

· date de divulgation · sens · montant · type d'actif ·

ticker · secteur · ETF

limites écrites, dans le livrable

· **582 PTR manuscrits** écartés (7,1 % de l'index)

· **biais de survie** prix (7b)

· composition : Chambre **91,3 %** · achats **50,8 %**

Réponse — une table **134 464 × 36** · 79,6 % du corpus conservé · limites écrites — reste à **prouver** qu'on peut lui faire confiance : **Partie II**.

PARTIE II

Vérifier la table

Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?

II.0 Trois questions · II.1 L'univers · II.2 Les autres types de dépôts · II.3 La cohérence ·
II.4 Quiver · II.5 Les autres preuves

II.0 · Vérifier, c'est répondre à trois questions

1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

l'univers officiel (II.1), puis les **11 autres types** de dépôts (II.2)

173

actions résiduelles échappant au signal

2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie (II.3)

87,8 %

des positions de sortie expliquées (Chambre)

3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver (II.4), collectes indépendantes (II.5) — jamais réinjectés

93,5 %

des combinaisons du tiers retrouvées chez nous

(Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

II.1 · L'univers — 100 % des 8 252 PTR officiels sont traités

l'index officiel dit combien de PTR existent : **8 252**. Chacun est **traité**, ou **écarté par une règle écrite** — aucun n'est ignoré en silence :




7 568 + 102 + 582 = 8 252 — la couverture est **prouvée par l'index**, pas déclarée

les **102** : dépôts vides réels, amendements sans ligne, et **échecs de lecture documentés** — aucun n'est perdu en silence

Chambre ≠ Sénat — côté **Sénat**, pas d'index public à re-télécharger : le contrôle passe par le **recensement** du portail — où **25** dépôts sans transaction retenue sont consignés de la même façon.

II.2a · Les autres types — où vivent les transactions, hors des PTR ?



la vie déclarative d'un élu : chaque étape a son dépôt — Schedule **A** = la **photo du patrimoine** · Schedule **B** = la **liste des transactions** ; hors PTR, les transactions ne vivent que dans l'annuel **O** (4 625 dépôts, **31 %** avec transactions), la sortie **T** et leurs amendements — **57 259** lignes brutes au total

les photos d'entrée (**H**) et de sortie (**T**) serviront à la cohérence (II.3) — verdict de complétude : slide suivante

11.2b · Verdict — le hors-PTR est du patrimoine découvert trop tard : 173 actions

SCHEDULE B: TRANSACTIONS

Asset	Owner	Date	Tx. Type	Amount	Cap. Gains > \$200?
Hertz Global Holdings, Inc (HTZ)		07/15/2015	P	\$15,001 - \$50,000	
Discussions: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16					
Hertz Global Holdings, Inc (HTZ)		07/16/2015	P	\$100,001 - \$250,000	
Discussions: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16					

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

la Schedule B d'un **annuel** (Pelosi 2015) récapitule les trades de l'année — souvent déjà déclarés en PTR

57 259 lignes brutes hors PTR (doublons compris)

doublons et échos des PTR retirés → le net jamais vu en PTR : surtout des **ETF/fonds** (détail : annexe A5)

173 vraies actions absentes du signal — toutes pré-2018

374 j de délai médian (vs 27 j en PTR)


CHOIX — les transactions hors PTR alimentent le **patri-moine** (vérification), jamais le **signal** — découvertes ~1 an trop tard : cohérent avec l'anti-look-ahead de 2e.

les deux mesures portent sur des populations distinctes : **57 259** = les lignes brutes hors PTR · **374 j** = le délai des trades nets jamais vus en PTR

II.3a · Cohérence — l'équation : entrée + nos transactions $\stackrel{?}{=}$ sortie

Chambre uniquement ($\sim 90\%$ du corpus)


photo = le patrimoine déclaré (Schedule A, aux entrées/sorties) · **flux** = nos transactions — l'équation ne se teste que si l'on a **les deux photos** :



la loi elle-même limite l'échantillon : **439** étaient déjà en poste en 2014 (pas de photo d'entrée), **437** sont encore en poste (pas de photo de sortie) ; la moitié des 106 ne détient **aucune action cotée**

11.3b · Cohérence — le résultat : 87,8 % des positions expliquées, 3,3 % non

Les portefeuilles se recoupent : entrée (H) + PTR ≥ sortie (T), et année par année via les annuels (O)



premier passage : entrée + achats PTR expliquent
78,7 % des 1 371 positions de sortie → 292
inexpliquées

Chambre uniquement

292 positions inexpliquées (21,3 %)
— instruites une par une :

—125 déclarées **AILLEURS** (an-
nuels, sorties, PTR papier)
le taux monte : 78,7 → 87,8 %

—122 **structurelles** (comptes gé-
rés, petites lignes, ETF exemptés)

45 vraiment inexpliquées = 3,3 % (14 membres)

CHOIX — chaque position inexpliquée est classée par preuve documentaire (table nominative conservée), pas éliminée statistiquement.

—125 = 74 annuels + 49 sorties + 2 PTR papier · —122 = 59
gérés + 32 ≤ 15 k\$ + 30 ETF + 1 renommage

II.3c · Cohérence — reconstruire n'est pas vérifier : 9 sur 10 sans preuve

Chambre uniquement

chacun des **900** membres reçoit **un seul statut** — du moins au plus exigeant :

20 hors d'atteinte — rien d'exploitable (patrimoine 100 % non coté, blind trust)

715 restructurable partiel — au moins une photo **ou** des transactions → des **morceaux datés**


109 restructurable complet — série datée de bout en bout... mais pas de photo de **sortie** : non testable

56 vérifiable strict — les deux photos + actions cotées → l'équation **réellement testée** (le 87,8 %)

$20 + 715 + 109 + 56 = 900$ — une partition, rien ne se recouvre

CHOIX — on affiche le **périmètre réel du test** (56 membres) plutôt que de laisser croire à une vérification universelle — ~9 reconstruits sur 10 restent **sans preuve**.

II.4 · Quiver — nous retrouvons > 92 % de sa base, et nous en sommes le sur-ensemble



au niveau (élu, ticker, sens) : 93,5 % / 92,1 % des combinaisons *de Quiver* sont retrouvées *chez nous*

Quiver = fournisseur commercial des mêmes données — notre mètre externe


trois crans de stricte — on serre la vis :

- 1 · **exister** même élu, même titre, même sens
- 2 · **dater** même date (≤ 10 j) — appariés un à un
- 3 · **concorder** sens **96,8 %** · montant **94,2 %** (Chambre)

Chambre $\neq$ Sénat — Quiver **voit** le papier de la Chambre (d'où le gating de 2b) mais est **aveugle** au papier du Sénat (d'où 2d).

CHOIX — Quiver est une **vérité-terrain jamais réinjectée** : il **mesure** la table, ne la remplit jamais — et en cas de désaccord de date, le **PDF officiel arbitre toujours** (annexe A6).

II.4b · Quiver — la corroboration monte avec le temps : peu de vérité-terrain avant 2017



part de **nos** actions (Chambre, Stock) que Quiver possède aussi — par
année civile de dépôt

l'autre sens que la slide précédente : II.4
mesurait « combien de Quiver **retrouve-t-on** ? »
(92 %) ; ici, « combien de **nos** actions Quiver
confirme-t-il ? »

le taux global lisse une forte hétérogénéité :
58,7 % avant 2020, **87,2 %** depuis — creux
2015-16 à ~17 %.

ce **n'est pas notre erreur** : nos **15 015** actions
« en plus » d'avant 2020 portent des **tickers**
réels et d'époque (vérifiés) — c'est **Quiver** qui
est mince avant ~2017.

à retenir pour le backtest — moins de **vérité-**
terrain externe sur la période ancienne.

11.5 · Les autres preuves, et le principe : rien n'est réinjecté

Collectes indépendantes

deux projets tiers ayant collecté les mêmes sources publiques : **100 %** et **99,5 %** de leurs lignes retrouvées chez nous

Agrégateur tiers

comptes par déposant recoupés automatiquement — confirme les déposants où notre OCR est l'**unique source**

Re-run reproductible

368 signatures de fichiers figées : chaque nouvelle exécution doit reproduire les tables livrées à l'**octet près** — aucune régression silencieuse

le principe — aucune source externe n'est **réinjectée** dans les tables : elles ne servent qu'à **mesurer** ce qu'on a

Réponse — rien raté (100 % de l'univers · 173 actions résiduelles côté patrimoine · 27 + 11 vrais trous face au tiers) · cohérent dedans (87,8 % des positions expliquées) · sur-ensemble dehors (> 92 % de la base du tiers retrouvée).

La couche données, en quatre chiffres

PARTIE I — construire

acquisition → tri → extraction → identité → tickers →
secteurs → dédup → entonnoir → table

PARTIE II — prouver

univers → autres types → cohérence → Quiver →
autres preuves

100 %

de l'univers officiel
(8 252 PTR Chambre)
traité

169 000

transactions uniques,
identifiées à 100 %

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

lignes × colonnes,
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites

Annexes

La réserve pour questions

A1–A7 : documents exemples · détails des cascades · cas particuliers

A1 — Le document lisible : un PTR électronique

**PERIODIC TRANSACTION REPORT**

Filing ID #20009426

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

FILER INFORMATION
Name: Hon. John A. Yarmuth
Status: Member
State/District: KY03

TRANSACTIONS

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Altria Group, Inc. (MO) [ST] FILING STATUS: New	S (partial)	03/23/2018	04/07/2018	\$1,001 - \$15,000	☒
	Boeing Company (BA) [ST] FILING STATUS: New	S (partial)	03/15/2018	04/07/2018	\$1,001 - \$15,000	☒
	Micron Technology, Inc. (MU) [ST] FILING STATUS: New	P	03/27/2018	04/07/2018	\$1,001 - \$15,000	☐
	Wells Fargo & Company (WFC) [ST] FILING STATUS: New	S (partial)	03/20/2018	04/07/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

INITIAL PUBLIC OFFERINGS
☒ Yes ☐ No

CERTIFICATION AND SIGNATURE
☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.
Digitally Signed: Hon. John A. Yarmuth , 05/02/2018

- un PDF **lisible par machine** (couche texte)
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification — cette dernière est jetée) + fourchette de montant
- **7 996** lignes au montant coupé en deux, recollées avant lecture

PTR électronique complet (Hon. John A. Yarmuth, KY03)

A2 — Le portail du Sénat : ce que rend la recherche

 UNITED STATES SENATE
FINANCIAL DISCLOSURES

 Find Reports

 Search Again

la liste réelle des dépôts (1d) — **un lien par dépôt** : chacun s'ouvre en **page web** ou en **papier scanné**, c'est là que se décide la voie d'extraction

les PTR sont **un type parmi d'autres** au Sénat aussi (annuels, extensions, *blind trusts*...) — on ne demande que les PTR

A3 — Le même formulaire, des sections en commun

Les sections A→J, et lesquelles apparaissent dans chaque type de document

	P	Identiques		Identiques	
		C	H	O	T
	PTR	candidat	entrée	annuel	sortie
A	Actifs & revenus de placement	✓	✓	✓	✓
B	TRANSACTIONS	✓		✓	✓
C	Revenus du travail	✓	✓	✓	✓
D	Dettes	✓	✓	✓	✓
E	Postes occupés	✓	✓	✓	✓
F	Accords	✓	✓	✓	✓
G	Cadeaux			✓	✓
H	Voyages payés			✓	✓
I	Dons à une œuvre (au lieu d'honoraires)			✓	✓
J	Compensation > 5 000 \$ d'une source	✓	✓		

socle commun A · C · D · E · F (dans tous sauf le PTR) — seule la section B (transactions) nous intéresse

→ B n'existe que dans le PTR, l'annuel (O) et la sortie (T)

l'amendement A reprend les sections du document qu'il corrige (C-H ou O-T)

la **section B** = les transactions ; le reste est un socle commun, la **A** (patrimoine) sert à *vérifier*

A4 — Les types administratifs, et le cas à part

cinq types sans aucune transaction :

X — Extension
demande de délai

D — Campaign Notice
« < 5 000 \$ »

W — idem, papier
(ou retrait)

E — Exemption
départ, poste fédéral

G — Gift Waiver
dérogation cadeau

B — Blind Trust (23 dépôts) : la banque du *trust* liste de vraies ventes, mais **pas** décidées par l'élu : la fiducie aveugle.

et les candidats **C** : 10 105 dépôts, 77 % jamais élus — une photo de patrimoine qui peut servir de photo d'entrée

A5 — Ce que les O/A/T ajoutent : du patrimoine, pas du signal

une fois doublons **et** échos des PTR retirés, il reste dans les annuels (O), sorties (T) et amendements (A) :

26 115

trades jamais vus
dans un PTR

22 216

via les annuels O

3 899

via sorties T
+ amendements A

374 j

délai médian
trade → publication

ces trades **comblent des trous du portefeuille** (l'élú oublie son PTR mais l'inscrit à l'annuel) —
découverts **~1 an trop tard** : ils nourrissent le **patrimoine**, jamais le **signal**

les 26 115 sont surtout des **ETF/fonds cotés** — les vraies **actions** manquantes au signal = **173**, toutes pré-2018

ne pas confondre : **26 115** (net hors-PTR, cohérence interne) $\neq$ $\approx$ **26 500** (combinaisons présentes chez nous et absentes chez Quiver, corroboration) — source : audit patrimoine Chambre, table de flux nette (lignée v1-house)

A6 — Qui a raison sur les dates ? Le PDF officiel arbitre toujours

pour un même (élu, ticker, sens), quand notre date et celle de Quiver divergent dans un même dépôt, **545**
candidats méritent l'œil → on **rouvre le PDF** :

le PDF montre...	exemple réel	traitement
coquille du déposant, prouvable	3031-04-30	corrigée → 2021
coquille littérale	01/35/22	transcrite telle quelle
notre OCR s'est trompé	Khanna/COST 09-31	re-lue au PDF → 08-16
désaccord Quiver	McCaul/GOOGL $\Delta 11$ j	arbitré au PDF

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

A7 — Détails : la couverture des entrées/sorties, les pièges d'identité

couverture des entrées/sorties (Chambre) :

470 entrées depuis 2014 82 % ont déposé un **H** (photo d'entrée) · 16 % un **C** à la place → **98 % couverts**

463 sorties définitives 81 % ont déposé un **T** (photo de sortie) ; les 86 sans T : partis au Sénat/exécutif (dispensés), décès

la photo d'entrée : **252** ancrés par un H · **32** par un C = **284** portefeuilles d'entrée datés

pièges d'identité réels, réparés (3) :

- l'homonyme **Bob Casey** (C000228 → C001070) : deux vraies personnes — un représentant du Texas, un sénateur de Pennsylvanie
- **42 lignes d'Angie Craig** sans identifiant, réparées à la lecture — le fichier extrait, lui, reste figé

cascade secteur (5) :

yfinance (le secteur factuel) → LLM contraint GICS → overrides manuels pour les cas connus