

La couche données — collecte & validation

Transactions boursières du Congrès américain · Chambre & Sénat · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Depuis 2012, chaque élu du Congrès doit déclarer ses transactions en bourse

le **STOCK Act** (2012) : toute transaction boursière de plus de 1 000 \$ d'un élu doit être déclarée dans un
Periodic Transaction Report (« **PTR** ») — public, daté, sous **45 jours**

45 j

le délai légal pour
déclarer un trade

2014–2026

la fenêtre étudiée
(la loi date de 2012)

2 chambres

435 représentants
+ 100 sénateurs

la question de recherche : ces déclarations publiques peuvent-elles nourrir une stratégie d'investissement ?
avant d'y répondre, il faut une donnée **complète, propre et prouvée** — c'est l'objet de cette présentation

La couche données, en quatre résultats

169 000

transactions uniques,
identité rattachée à
100 %

100 %

des 8 252 déclarations
officielles (PTR)
traitées

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

la table de recherche
livrée, limites écrites

comment peut-on affirmer tout ça ? — c'est l'objet de la présentation : chaque étape prouve son chiffre

Le plan — deux parties : on construit, puis on prouve

PARTIE I — Construire la table

de la source publique au CSV livré

I.0	Vision globale	le flux en une image
I.1	Acquisition	2 guichets publics
I.2	Tri	par type, puis par format
I.3	Extraction	4 voies · les 2 dates · le corpus
I.4	Identité	le nom → l'élus officiel
I.5	Tickers	le symbole boursier
I.6	Secteurs	GICS → ETF
I.7	Dédup	l'empreinte 7 champs
I.8	Entonnoir	ce qu'on retire, et pourquoi
I.9	Table finale	à quoi ressemble la valeur

PARTIE II — Vérifier la table

rien raté, rien inventé

II.0	Trois questions	le cadre de la preuve
II.1	L'univers	a-t-on tout traité ?
II.2	Les autres types	les 11 dépôts hors PTR
II.3	La cohérence	les flux se recollent-ils ?
II.4	Quiver	le mètre externe
II.5	Les autres preuves	et le principe

Chambre et Sénat sont traités **ensemble** à chaque étape — côte à côte quand ils diffèrent

les **choix** méthodologiques sont encadrés **CHOIX** au fil des slides

PARTIE I


Construire la table

De ~10 000 documents publics hétérogènes à une seule table

I.0 Vision globale · **I.1** Acquisition · **I.2** Tri · **I.3** Extraction · **I.4** Identité · **I.5** Tickers ·
I.6 Secteurs · **I.7** Dédup · **I.8** Entonnoir · **I.9** Table finale


I.0 · La vision globale : tout le trajet de la donnée en une image

OCR = lecture automatique d'une image (détail : I.2c)




I.0 · La vision globale : tout le trajet de la donnée en une image

OCR = lecture automatique d'une image (détail : I.2c)




I.0 · La vision globale : tout le trajet de la donnée en une image

OCR = lecture automatique d'une image (détail : I.2c)




I.0 · La vision globale : tout le trajet de la donnée en une image

OCR = lecture automatique d'une image (détail : I.2c)



1.1 · Acquisition — tout est public : deux guichets, treize années



Chambre — disclosures-clerk.house.gov

une **archive par année**, avec l'**index** de tous les dépôts

Sénat — efdsearch.senate.gov (portail eFD)


un **accord obligatoire**, puis une recherche : la liste des dépôts

Chambre ≠ Sénat — la Chambre publie un **index annuel exhaustif** (on sait ce qu'on doit traiter) ; le Sénat n'expose qu'une **recherche** — même donnée, deux portes.

35 315 dépôts dans l'index Chambre · **13 années** (2014–2026) · collecte **automatisée** des deux côtés

CHOIX — l'**index annuel officiel** est notre **autorité** : c'est lui qui définit l'univers des documents à traiter — pas ce qu'on a réussi à lire.

I.2a · Tri par type — sur douze types de dépôts, un seul porte le signal : le P



P = *Periodic Transaction Report* (les « PTR ») — les seules **déclarations de transactions datées**, sous 45 jours · **8 252** PTR parmi les 35 315 dépôts

Chambre = Sénat — le Sénat a la même typologie — on ne demande au portail que les **PTR**.

CHOIX — on ne construit le signal qu'avec les dépôts de type **P**, parce qu'eux seuls déclarent des transactions datées sous 45 jours — les **11 autres types seront tous ouverts** en **Partie II**.

1.2b · Tri par format — texte ou image : quatre sous-corpus


chaque dépôt pointe vers son document (son numéro donne l'URL) — la même donnée réglementaire existe sous 4 formats :



Chambre · lisible

PDF à couche texte


71 % des dépôts



Chambre · scanné


PDF image

29 % des dépôts



Sénat · HTML

page web, table propre



Sénat · papier

formulaire scanné, image

Chambre = Sénat — les deux chambres ont leur monde **texte** et leur monde **image** — au final, **57,6 %** du corpus viendra d'images.

CHOIX — on découpe le corpus en **4 sous-corpus** (chambre × format) et chaque voie reçoit son **extracteur dédié** — un traitement uniforme raterait la moitié.

I.2c · Dans l'image, le vrai point dur n'est pas le scan : c'est le manuscrit

un scan n'est pas du texte, c'est une **image** (à lire par **OCR** : lecture automatique) — ce qui compte n'est pas l'orientation mais **tapé vs manuscrit** :

Tapé, droit

dactylographié, lisible tel quel

Tapé, couché

tourné à 90° — lu quand
même

Manuscrit

à la main, cursif — le vrai point dur

775 scans manuscrits sur les 2424 scans Chambre recensés

Chambre ≠ Sénat — le manuscrit existe des **deux** côtés — mais il sera **écarté** à la Chambre et **gardé** au Sénat : la raison, et elle seule, est la **vérifiabilité** (I.3b et I.3c).

1.3a · Extraction (texte) — les deux voies électroniques, déterministes

ID	Owner Asset	Transaction Type	Transaction Date	Notification Date	Amount	Cap. Gains > \$200?
	Caterpillar, Inc. (CAT) [ST] Folio Street: New Source: CHARLES SWAIB ACCOUNT	P	04/07/2018	04/17/2018	\$15,001 - \$20,000	montant coupé sur 2 lignes
	Coca-Cola Company (KO) [ST] Folio Street: New Source: CHARLES SWAIB ACCOUNT	S	04/07/2018	04/17/2018	\$15,001 - \$20,000	
	Microsoft Corporation (MSFT) [ST] Folio Street: New Source: CHARLES SWAIB ACCOUNT	P	04/11/2018	04/11/2018	\$15,001 - \$20,000	
	Spectra Energy Partners, LP Common Units representing Limited Partner Interests (SEEP) [ST] une seule transaction, libellé sur 4 lignes Source: CHARLES SWAIB ACCOUNT	P	04/20/2018	04/20/2018	\$1,001 - \$15,000	

* For the complete list of asset type abbreviations, please visit <https://hl.bepco.com/reference/asset-type-codes.aspx>.

extrait réel — le montant déborde sur la ligne suivante, le libellé court sur 4 lignes : **un parseur naïf raterait la moitié** → on **reconstruit** chaque transaction avant de la lire

Chambre ≠ **Sénat** — la **Chambre** est un **PDF** à reconstruire (mise en page libre) ; le **Sénat** est un **tableau HTML** déjà propre.

CHOIX — côté Chambre, deux gabarits de formulaire coexistent (l'ancien sans code type d'actif, le moderne avec [ST], apparu vers 2018) : ils sont **routés document par document**, jamais par année fixe.

Chambre — 58 728 transactions


recoller les lignes coupées → repérer la signature (opération + 2 dates + fourchette) → rattacher l'actif

Sénat — 13 026 transactions

liste des dépôts → page HTML par dépôt → lecture des tableaux

pour le texte, **pas d'IA** : du code déterministe, rejouable à l'identique

I.3b · Extraction (image, Chambre) — Vision lit tout, le manuscrit est écarté



- l'**OCR par IA** (Claude Vision) lit le tapé, même tourné à 90°
- **93 261 transactions extraites des scans**
- très concentrées : les gros déposants « 100 % papier » (I.3e)

la mesure — Quiver Quantitative (fournisseur commercial des mêmes données, notre mètre externe — Partie II), *même sans exiger la date*, ne corrobore que **12,9 %** du manuscrit, contre **88 %** du tapé droit

582 PTR manuscrits écartés — 7,1 % de l'index

CHOIX — on ne met en table que ce qu'on sait lire : les 582 PTR manuscrits sont écartés par une **règle écrite et rejouable**, avec exceptions explicites — pas de lectures douteuses injectées dans la donnée.

I.3c · Extraction (image, Sénat) — le papier est gardé, faute de mètre externe

PERSONNEL FINANCIER DE L'ASSEMBLÉE NATIONALE

Nom	Date	Montant	Code
Apple Computer Inc	2022-03-14	1001-15 000 \$	A
Sale	2022-03-14	1001-15 000 \$	A

le formulaire papier Sénat

ce que rend l'OCR, transaction par transaction (extrait réel — John Boozman) :

actif · opération Apple Computer Inc · Sale
date du trade · fourchette 2022-03-14 · code A (1001–15 000 \$)

3 985 transactions — 14 déposants — 2,4 % du corpus

même moteur de lecture qu'à la Chambre — mais **politique inverse** :

Quiver est **aveugle au papier du Sénat** → aucune mesure d'exclusion possible → on **garde**, sous garde-fous internes, et on l'écrit

couverture ticker plus basse sur cette voie = **composition, pas défaut** :

Blumenthal porte 38,7 % de la voie, massivement du non-coté

CHOIX — on n'écarte que ce qu'on a pu **mesurer** — l'asymétrie Chambre/Sénat (écarté là, gardé ici) est **documentée, pas cachée** ; le risque est borné (2,4 % du corpus).

1.3d · Ce qu'on extrait de chaque ligne : deux dates, une seule est fiable

Date de DÉPÔT (divulgaration)

toujours une métadonnée — jamais lue dans le document, jamais OCRisée; **fiable** → c'est la date **signal**

délai médian de divulgation : **27 j** Chambre · **24 j** Sénat

Chambre = Sénat — **sur les 4 voies**, même schéma : la date de dépôt vient de l'index (Chambre) ou du listing (Sénat); la date de transaction vient du document.

CHOIX — le signal est daté à la **date de dépôt**, jamais à la date du trade : c'est ce qu'un investisseur réel aurait su, quand il l'aurait su (**anti-look-ahead**) — et toute date de transaction douteuse est **flaguée, jamais réécrite au hasard**.

Date de TRANSACTION



lue dans le document (texte ou OCR); la **seule risquée** → garde-fous + flag, **jamais inventée**

garde-fou : hors de la fenêtre de plausibilité

[dépôt - 90 j, +10 j] → année recalée ou ligne flaguée

I.3e · Le corpus extrait : 169 000 transactions — dont ~40 % de deux élus

les quatre voies réunies donnent **169 000 transactions uniques** (2014–2026) — et cette matière est **très déséquilibrée** :




très concentré — Khanna (**41 080 txns**) et McCaul (**27 123**) pèsent à eux deux ~40 % du corpus, et déclarent **exclusivement sur papier** (100 % OCR)

le papier n'est pas un détail : c'est **la majorité du corpus** — d'où l'effort d'OCR de I.3b–I.3c

I.4 · Identité — chaque ligne est rattachée à un élu officiel : 100 %

un même élu signe « Hon. Earl L. Carter », « Buddy Carter », « N. Pelosi »... → on relie ce **nom libre** à un **identifiant unique**, par une cascade d'essais :



100 % des lignes rattachées

367 membres Chambre · **78** Sénat

le *bioguide* = l'identifiant officiel unique d'un élu au Congrès (annuaire public *congress-legislators*)

Chambre ≠ **Sénat** — même cascade des deux côtés — le **Sénat** ajoute une **désambiguïsation** (siège, titulaire en exercice).

CHOIX — les fichiers extraits sont **figés** ; toute réparation est appliquée **à la lecture**, jamais en réécrivant la source.

1.5 · Tickers — du nom de l'actif au symbole boursier, par une cascade tracée

1. **explicite** — déjà imprimé dans la source (l'électronique)



2. **dictionnaire** — le nom vu ailleurs dans le corpus (le papier)



3. **LLM** contraint « actions seulement »



4. **récupération** validée par double preuve — 2 540 lignes retrouvent leur symbole

Chambre = Sénat — même cascade des deux côtés — ce qui change est la **source** : l'électronique imprime souvent le symbole (étage 1), le papier dépend des étages 2–3.

ticker renseigné

84,1 % Chambre · **77,9 %** Sénat

couverture = remplissage, pas exactitude — les vides sont le **non-coté légitime** (munis, obligations, fonds privés), pas des défauts d'extraction ; l'écart Chambre/Sénat vient de la **composition** des portefeuilles

CHOIX — cascade **ordonnée et tracée**, du plus sûr au moins sûr — chaque étage est enregistré ligne à ligne : jamais une devinette silencieuse.

1.6 · Secteurs — chaque titre reçoit un secteur GICS, et son ETF

une cascade indépendante de celle du ticker :

1. **yfinance** — le secteur factuel de l'entreprise



2. **LLM** contraint GICS (+
garde-fou « est-ce coté ? »)



3. **overrides** manuels — les cas connus

secteur renseigné 79,8 % Ch. · 70,4 % Sén.

GICS = la classification sectorielle standard du marché — **11 secteurs**, chacun adossé à son **ETF Select Sector SPDR** (le panier coté du secteur) :

Energy→XLE · Materials→XLB · Industrials→XLI
· Cons. Discr.→XLY · Cons. Staples→XLP ·
Health Care→XLV · Financials→XLF · Info.
Tech.→XLK · Comm. Services→XLC ·
Utilities→XLU · Real Estate→XLRE

Chambre = Sénat — même cascade, même table de correspondance des deux côtés — l'écart de couverture vient de la **composition** des portefeuilles, pas de la méthode.

1.7 · Dédup — une transaction = 7 champs : l'empreinte dédouble sans détruire


l'empreinte d'une transaction — 7 champs :

qui (déclarant) · **quand** (date du trade) · **quoi** (actif) · **sens** ·
montant (fourchette) · **pour qui** (détenteur) · **chambre**

elle exclut **délibérément** :

- le **ticker** — ajouté après coup (1.5), sa présence rendrait l'empreinte instable
- la **date de divulgation** — un dépôt et son amendement portent le *même* trade → une seule transaction


CHOIX — dédup **non destructrice** : deux dépôts, même empreinte = un seul trade — mais un **vrai lot répété** (même titre, plusieurs comptes) est **préservé** par un compteur d'occurrence. Jamais de dédoublement aveugle.



Chambre = Sénat — une seule empreinte pour les deux chambres — c'est elle qui permet de **fusionner les 4 voies** sans compter deux fois.

I.8a · Entonnoir — de 169 000 à 134 464 : on ne retire que l'avéré inutilisable

L'entonnoir du nettoyage backtest : 169 000 → 134 464 transactions (79,6 % conservées)



quatre portes objectives — **169 000** → **134 464** (79,6 % conservées) :

A — dates cohérentes : -3 252

B — actions + ETF cotés (un backtest exige un prix de marché) : -29 771


C — direction claire (achat ou vente) : -826

D — montant présent : -687

sauvetage « ticker-first » — 21 878 lignes à case « type d'actif » vide **gardées** : le **ticker coté** fait foi, pas la case déclarée

CHOIX — on ne retire que l'**avéré inutilisable** ; le doute est **flagué, jamais retiré** (late filing 12,2 %, délistés, lots multi-comptes) — la recherche décide.

I.8b · Entonnoir (suite) — du symbole au prix : 118 029 trades valorisables



118 029 trades avec un prix fiable ($\approx 88\%$)

même valeur numérique que le taux de cohérence de la
Partie II : **pure coïncidence**, aucun lien

biais de survie assumé — un titre mort depuis
(faillite, rachat sans successeur) ne peut plus être
valorisé : couverture **74 %** en 2014 → **99 %** en
2026

CHOIX — la limite est **écrite**, pas cachée — les lignes
non couvertes **restent** dans la table, flaguées.

note : le moteur d'analyse aval filtre l'année du trade à 2013–2026 → il travaille sur **134 429** lignes (134 464 — 35 trades
à année aberrante, coquilles fidèlement transcrites)

1.9 · À quoi ressemble la valeur finale : 134 464 lignes × 36 colonnes

la table de recherche — 134 464 lignes × 36 colonnes · 372 élus · chaque ligne traçable à son document source

membre	ticker	sens	transaction	montant \$	secteur
Bob Gibbs	INTC	buy	2014-12-30	8 000,5	Info. Tech.
Greg Gianforte	BBAVY	sell	2018-12-12	32 500,5	Cons. Staples
Kim Schrier	AAPL	buy	2021-11-15	375 000,5	Info. Tech.
Tim Moore	HOG	buy	2025-12-09	32 500,5	Cons. Discr.

CHOIX — la loi ne donne qu'une **tranche** de montant (ex. 15 001–50 000 \$) : on retient son **milieu exact** (d'où les « ,5 ») — convention **unique et documentée** plutôt que fausse précision ; renseigné à **99,4 %**.

12 champs garantis sur chaque ligne, 2 chambres

déclarant · chambre · parti · commissions · date du trade

· date de divulgation · sens · montant · type d'actif ·

ticker · secteur · ETF

limites écrites, dans le livrable

· **582 PTR manuscrits** écartés (7,1 % de l'index)

· **biais de survie** prix (1.8b)

· composition : Chambre **91,3 %** · achats **50,8 %**

Réponse — une table **134 464 × 36** · 79,6 % du corpus conservé · limites écrites — reste à **prouver** qu'on peut lui faire confiance : **Partie II**.

PARTIE II

Vérifier la table

Comment sait-on qu'on n'a **rien raté** — ni **rien inventé** ?

II.0 Trois questions · II.1 L'univers · II.2 Les autres types de dépôts · II.3 La cohérence ·
II.4 Quiver · II.5 Les autres preuves

II.0 · Vérifier, c'est répondre à trois questions

1 · Complétude

« A-t-on couvert **tout** le périmètre ? »

l'univers officiel (II.1), puis les **11 autres types** de dépôts (II.2)

173

actions résiduelles échappant au signal

2 · Cohérence

« Les flux se **recollent**-ils comptablement ? »

patrimoine d'entrée + nos transactions $\stackrel{?}{=}$ patrimoine de sortie (II.3)

87,8 %

des positions de sortie expliquées (Chambre)

3 · Corroboration

« Des **tiers indépendants** voient-ils la même chose ? »

Quiver (II.4), collectes indépendantes (II.5) — jamais réinjectés

93,5 %

des combinaisons du tiers retrouvées chez nous

(Chambre)

une seule question, en réalité — **peut-on faire confiance à la table ?** — posée **de l'intérieur** (1, 2) puis **de l'extérieur** (3)

II.1 · L'univers — 100 % des 8 252 PTR officiels sont traités

l'index officiel dit combien de PTR existent : **8 252**. Chacun est **traité**, ou **écarté par une règle écrite** — aucun n'est ignoré en silence :




7 568 + 102 + 582 = 8 252 — la couverture est **prouvée par l'index**, pas déclarée

les **102** : dépôts vides réels, amendements sans ligne, et **échecs de lecture documentés** — aucun n'est perdu en silence

Chambre ≠ Sénat — côté **Sénat**, pas d'index public à re-télécharger : le contrôle passe par le **recensement** du portail — où **25** dépôts sans transaction retenue sont consignés de la même façon.

II.2a · Les autres types — où vivent les transactions, hors des PTR ?



la vie déclarative d'un élu : chaque étape a son dépôt — Schedule **A** = la **photo du patrimoine** · Schedule **B** = la **liste des transactions** ; hors PTR, les transactions ne vivent que dans l'annuel **O** (4 625 dépôts, **31 %** avec transactions), la sortie **T** et leurs amendements — **57 259** lignes brutes au total

les photos d'entrée (**H**) et de sortie (**T**) serviront à la cohérence (II.3) — verdict de complétude : slide suivante

II.2b · Verdict — le hors-PTR est du patrimoine découvert trop tard : 173 actions

SCHEDULE B: TRANSACTIONS

Asset	Owner	Date	Tx. Type	Amount	Cap. Gains > \$200?
Hertz Global Holdings, Inc (HTZ)		07/15/2015	P	\$15,001 - \$50,000	
Discussions: Purchase of 42 call options with a strike price of \$14 and an expiration date of 1/15/16					
Hertz Global Holdings, Inc (HTZ)		07/16/2015	P	\$100,001 - \$250,000	
Discussions: Purchase of 258 call options with a strike price of \$14 and an expiration date of 1/15/16					

2 achats d'options Hertz (HTZ), juillet 2015 — rendus publics avec l'annuel, en mai 2016

la Schedule B d'un **annuel** (Pelosi 2015) récapitule les trades de l'année — souvent déjà déclarés en PTR

57 259 lignes brutes hors PTR (doublons compris)

doublons et échos des PTR retirés → le net jamais vu en PTR : surtout des **ETF/fonds** (détail : annexe A5)

173 vraies actions absentes du signal — toutes pré-2018

374 j de délai médian (vs 27 j en PTR)


CHOIX — les transactions hors PTR alimentent le **patri-moine** (vérification), jamais le **signal** — découvertes ~1 an trop tard : cohérent avec l'anti-look-ahead de I.3d.

les deux mesures portent sur des populations distinctes : **57 259** = les lignes brutes hors PTR · **374 j** = le délai des trades nets jamais vus en PTR

II.3a · Cohérence — l'équation : entrée + nos transactions $\stackrel{?}{=}$ sortie

Chambre uniquement ($\sim 90\%$ du corpus)


photo = le patrimoine déclaré (Schedule A, aux entrées/sorties) · **flux** = nos transactions — l'équation ne se teste que si l'on a **les deux photos** :



la loi elle-même limite l'échantillon : **439** étaient déjà en poste en 2014 (pas de photo d'entrée), **437** sont encore en poste (pas de photo de sortie) ; la moitié des 106 ne détient **aucune action cotée**

11.3b · Cohérence — le résultat : 87,8 % des positions expliquées, 3,3 % non

Les portefeuilles se recoupent : entrée (H) + PTR ≥ sortie (T), et année par année via les annuels (O)



premier passage : entrée + achats PTR expliquent
78,7 % des 1 371 positions de sortie → 292
inexpliquées

Chambre uniquement

292 positions inexpliquées (21,3 %)
— instruites une par une :

—125 déclarées **AILLEURS** (an-
nuels, sorties, PTR papier)
le taux monte : 78,7 → **87,8 %**

—122 **structurelles** (comptes gé-
rés, petites lignes, ETF exemptés)

45 vraiment inexpliquées = 3,3 % (14 membres)

CHOIX — chaque position inexpliquée est **classée par preuve documentaire** (table nominative conservée), pas éliminée statistiquement.

—125 = 74 annuels + 49 sorties + 2 PTR papier · —122 = 59
gérés + 32 ≤ 15 k\$ + 30 ETF + 1 renommage

II.3c · Cohérence — reconstruire n'est pas vérifier : 9 sur 10 sans preuve

Chambre uniquement

chacun des **900** membres reçoit **un seul statut** — du moins au plus exigeant :

20 hors d'atteinte — rien d'exploitable (patrimoine 100 % non coté, blind trust)

715 restructurable partiel — au moins une photo **ou** des transactions → des **morceaux datés**


109 restructurable complet — série datée de bout en bout... mais pas de photo de **sortie** : non testable

56 vérifiable strict — les deux photos + actions cotées → l'équation **réellement testée** (le 87,8 %)

$20 + 715 + 109 + 56 = 900$ — une partition, rien ne se recouvre

CHOIX — on affiche le **périmètre réel du test** (56 membres) plutôt que de laisser croire à une vérification universelle — ~9 reconstruits sur 10 restent **sans preuve**.

II.4 · Quiver — nous retrouvons > 92 % de sa base, et nous en sommes le sur-ensemble



au niveau (élu, ticker, sens) : 93,5 % / 92,1 % des combinaisons *de Quiver* sont retrouvées *chez nous*

Quiver = fournisseur commercial des mêmes données — notre mètre externe

trois crans de stricteesse — on serre la vis :

- 1 · **exister** même élu, même titre, même sens
- 2 · **dater** même date (≤ 10 j) — appariés un à un
- 3 · **concorder** sens **96,8 %** · montant **94,2 %** (Chambre)

Chambre $\neq$ Sénat — Quiver **voit** le papier de la Chambre (d'où le gating de I.3b) mais est **aveugle** au papier du Sénat (d'où I.3c).

CHOIX — Quiver est une **vérité-terrain jamais réinjectée** : il **mesure** la table, ne la remplit jamais — et en cas de désaccord de date, le **PDF officiel arbitre toujours** (annexe A6).

11.5 · Les autres preuves, et le principe : rien n'est réinjecté

Collectes indépendantes

deux projets tiers ayant collecté les mêmes sources publiques : **100 %** et **99,5 %** de leurs lignes retrouvées chez nous

Agrégateur tiers

comptes par déposant recoupés automatiquement — confirme les déposants où notre OCR est l'**unique source**

Re-run reproductible

368 signatures de fichiers figées : chaque nouvelle exécution doit reproduire les tables livrées à l'**octet près** — aucune régression silencieuse

le principe — aucune source externe n'est **réinjectée** dans les tables : elles ne servent qu'à **mesurer** ce qu'on a

Réponse — rien raté (100 % de l'univers · 173 actions résiduelles côté patrimoine · 27 + 11 vrais trous face au tiers) · cohérent dedans (87,8 % des positions expliquées) · sur-ensemble dehors (> 92 % de la base du tiers retrouvée).

La couche données, en quatre chiffres

PARTIE I — construire

acquisition → tri → extraction → identité → tickers →
secteurs → dédup → entonnoir → table

PARTIE II — prouver

univers → autres types → cohérence → Quiver →
autres preuves

100 %

de l'univers officiel
(8 252 PTR) traité

169 000

transactions uniques,
identifiées à 100 %

> 92 %

base du tiers retrouvée
· 87,8 %
des positions expliquées

134 464 × 36

lignes × colonnes,
limites écrites

une couche données **vérifiée de l'intérieur et de l'extérieur** — sur laquelle bâtir en connaissant ses limites

Annexes

La réserve pour questions

A1–A7 : documents exemples · détails des cascades · cas particuliers

A1 — Le document lisible : un PTR électronique

**PERIODIC TRANSACTION REPORT**

Filing ID #20009426

Clerk of the House of Representatives • Legislative Resource Center • 135 Cannon Building • Washington, DC 20515

FILER INFORMATION
Name: Hon. John A. Yarmuth
Status: Member
State/District: KY03

TRANSACTIONS

ID	Owner Asset	Transaction Type	Date	Notification Date	Amount	Cap. Gains > \$200?
	Altria Group, Inc. (MO) [ST] Filing Status: New	S (partial)	03/23/2018	04/07/2018	\$1,001 - \$15,000	☒
	Boeing Company (BA) [ST] Filing Status: New	S (partial)	03/15/2018	04/07/2018	\$1,001 - \$15,000	☒
	Micron Technology, Inc. (MU) [ST] Filing Status: New	P	03/27/2018	04/07/2018	\$1,001 - \$15,000	☐
	Wells Fargo & Company (WFC) [ST] Filing Status: New	S (partial)	03/20/2018	04/07/2018	\$1,001 - \$15,000	☐

* For the complete list of asset type abbreviations, please visit <https://fd.house.gov/reference/asset-type-codes.aspx>.

INITIAL PUBLIC OFFERINGS
☒ Yes ☐ No

CERTIFICATION AND SIGNATURE
☒ I CERTIFY that the statements I have made on the attached Periodic Transaction Report are true, complete, and correct to the best of my knowledge and belief.
Digitally Signed: Hon. John A. Yarmuth , 05/02/2018

- un PDF **lisible par machine** (couche texte)
- le ticker est imprimé **entre parenthèses** : (BA), le type d'actif entre crochets : [ST]
- deux dates par ligne (trade / notification — cette dernière est jetée) + fourchette de montant
- **7 996** lignes au montant coupé en deux, recollées avant lecture

PTR électronique complet (Hon. John A. Yarmuth, KY03)

A2 — L'index annuel de la Chambre, la recherche eFD du Sénat

```
2024FD.xml - index annuel du House Clerk
3  <Member>
4  <Prefix />
5  <Last>Abel</Last>
6  <First>William</First>
7  <Suffix />
8  <FilingType>C</FilingType> ← type C : pas un PTR, ignoré
9  <StateOst>TX31</StateOst>
10 <Year>2024</Year>
11 <FilingDate>5/12/2024</FilingDate>
12 <DocID>10060658</DocID>
13 </Member>
  ← 2 256 dépôts dans l'index 2024 -
245 <Member>
246 <Prefix>Hon.</Prefix>
247 <Last>Allen</Last>
248 <First>Richard W.</First>
249 <Suffix />
250 <FilingType>P</FilingType> ← type P : un PTR, on le garde
251 <StateOst>GA12</StateOst>
252 <Year>2024</Year>
253 <FilingDate>1/11/2024</FilingDate>
254 <DocID>20024277</DocID> ← le n° → l'URL du PDF
255 </Member>
```

eFD : on coche **Senator** × **PTR**

Filer Name (State)	Last Name (Suffix)	Office (Filer Type)	Report Type	Date Received/Filed
James	Hanks	Hanks, James D. (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/26/2024
James	Hanks	Hanks, James D. (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/1/2024
John A.	Harwood	Harwood, John (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/1/2024
Michael F.	Demont	Demont, Michael (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/1/2024
Michael F.	Demont	Demont, Michael (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/1/2024
Michael F.	Demont	Demont, Michael (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/1/2024
Michael F.	Demont	Demont, Michael (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/1/2024
Michael F.	Demont	Demont, Michael (Senator)	Periodic Transaction Report (a) (26)(5)(2)(8)	10/1/2024

la liste de dépôts, un lien chacun
— chaque dépôt s'ouvre en HTML
ou en scan

l'index annuel : un bloc par dépôt (archive

2024FD.zip → 2024FD.xml)

zéro échec silencieux : 102 dépôts sans transaction retenue, tous consignés (vides réels, amendements sans ligne, échecs tracés)

A3 — Le même formulaire, des sections en commun

Les sections A→J, et lesquelles apparaissent dans chaque type de document

	P	Identiques		Identiques	
		C	H	O	T
	PTR	candidat	entrée	annuel	sortie
A	Actifs & revenus de placement	✓	✓	✓	✓
B	TRANSACTIONS	✓		✓	✓
C	Revenus du travail	✓	✓	✓	✓
D	Dettes	✓	✓	✓	✓
E	Postes occupés	✓	✓	✓	✓
F	Accords	✓	✓	✓	✓
G	Cadeaux			✓	✓
H	Voyages payés			✓	✓
I	Dons à une œuvre (au lieu d'honoraires)			✓	✓
J	Compensation > 5 000 \$ d'une source	✓	✓		

socle commun A · C · D · E · F (dans tous sauf le PTR) — seule la section B (transactions) nous intéresse

→ B n'existe que dans le PTR, l'annuel (O) et la sortie (T)

l'amendement A reprend les sections du document qu'il corrige (C-H ou O-T)

la **section B** = les transactions ; le reste est un socle commun, la **A** (patrimoine) sert à vérifier

A4 — Les types administratifs, et le cas à part

cinq types sans aucune transaction :

X — Extension
demande de délai

D — Campaign Notice
« < 5 000 \$ »

W — idem, papier
(ou retrait)

E — Exemption
départ, poste fédéral

G — Gift Waiver
dérogation cadeau

B — Blind Trust (23 dépôts) : la banque du *trust* liste de vraies ventes, mais **pas** décidées par l'élu : la fiducie aveugle.

et les candidats **C** : 10 105 dépôts, 77 % jamais élus — une photo de patrimoine qui peut servir de photo d'entrée

A5 — Ce que les O/A/T ajoutent : du patrimoine, pas du signal

une fois doublons **et** échos des PTR retirés, il reste dans les annuels (O), sorties (T) et amendements (A) :

26 115

trades jamais vus
dans un PTR

22 216

via les annuels O

3 899

via sorties T
+ amendements A

374 j

délai médian
trade → publication

ces trades **comblent des trous du portefeuille** (l'élú oublie son PTR mais l'inscrit à l'annuel) —
découverts **~1 an trop tard** : ils nourrissent le **patrimoine**, jamais le **signal**

les 26 115 sont surtout des **ETF/fonds cotés** — les vraies **actions** manquantes au signal = **173**, toutes pré-2018

ne pas confondre : **26 115** (net hors-PTR, cohérence interne) $\neq$ $\approx$ **26 500** (combinaisons présentes chez nous et absentes chez Quiver, corroboration) — source : audit patrimoine Chambre, table de flux nette (lignée v1-house)

A6 — Qui a raison sur les dates ? Le PDF officiel arbitre toujours

pour un même (élu, ticker, sens), quand notre date et celle de Quiver divergent dans un même dépôt, **545**
candidats méritent l'œil → on **rouvre le PDF** :

le PDF montre...	exemple réel	traitement
coquille du déposant, prouvable	3031-04-30	corrigée → 2021
coquille littérale	01/35/22	transcrite telle quelle
notre OCR s'est trompé	Khanna/COST 09-31	re-lue au PDF → 08-16
désaccord Quiver	McCaul/GOOGL Δ11 j	arbitré au PDF

principe : le **PDF officiel** arbitre toujours — on reste fidèle à la source, même à ses coquilles littérales

A7 — Détails : la couverture des entrées/sorties, les pièges d'identité

couverture des entrées/sorties (Chambre) :

470 entrées depuis 2014 82 % ont déposé un **H** (photo d'entrée) · 16 % un **C** à la place → **98 % couverts**

463 sorties définitives 81 % ont déposé un **T** (photo de sortie) ; les 86 sans T : partis au Sénat/exécutif (dispensés), décès

la photo d'entrée : **252** ancrés par un H · **32** par un C = **284** portefeuilles d'entrée datés

pièges d'identité réels, réparés (I.4) :

- l'homonyme **Bob Casey** (C000228 → C001070) : deux vraies personnes — un représentant du Texas, un sénateur de Pennsylvanie
- **42 lignes d'Angie Craig** sans identifiant, réparées à la lecture — le fichier extrait, lui, reste figé

cascade secteur (I.6) :

yfinance (le secteur factuel) → LLM contraint GICS → overrides manuels pour les cas connus