



La donnée House — tout comprendre, tout vérifier

le doc à ouvrir en premier · House 2013–2026 · chiffres du notebook Portefeuilles_House_Complet, recoupés cellule par cellule

Ce qu'on a fait. Extraire *proprement* toutes les transactions boursières *exploitables* des élus de la Chambre (2013–2026), et les reconstruire en portefeuilles quotidiens, pour pouvoir **backtester**. Le trajet, en 2 actes / 9 étapes :



Un dépôt de patrimoine porte **deux sections**, qui ne servent pas à la même chose :



CE QU'ON A, EN QUATRE CHIFFRES

129 538

transactions valo-
risées, 3 sources

408 / 900

membres qui tradent
/ au registre

609 886

lignes de patrimoine déclaré

12×

empilé 104 130 vs
stock 8 887 M\$

De **900** membres et **6** types de dépôts, on tire un flux de **129 538** transactions exploitables chez **408** membres — reconstruites jour après jour en portefeuilles, puis **jugées** par des documents qui n'ont pas servi à les construire.

CE QU'ON A EXTRAIT — le flux de transactions, par source			
source	trades	montant	publié après l'opération
● déclarations rapides <i>P</i> (fil de l'eau)	107 976	fourchette, milieu	médiane 27 j
● rapports annuels <i>O/A/T</i> (électronique)	14 084	fourchette, milieu	médiane 374 j
● Schedule B scanné (océrisé)	7 478	forfait 8 000 \$	médiane 393 j
flux unifié F	129 538	chez 408 membres · traçable ligne à ligne	
Chaque ligne porte sa date d'opération ET sa date de divulgation (flux_house_2dates.csv).			

A-T-ON TOUT PRIS ? — taux d'exploitation par type de document (le <i>récall</i> <i>z</i>)			
type de document	exploité	lu, 0 ligne	papier jamais océrisé
● <i>P</i> — déclaration rapide (transactions)	100 %	—	—
● <i>O</i> — rapport annuel	74,7 %	450	721
● <i>T / H</i> — photos entrée/sortie	~65 %	lues 0 ligne + papier	
● <i>C</i> — photo de candidat	39,7 %	4 515	1 583
La transaction est prise à 100 %. Ce qui se perd, c'est la <i>photo</i> du patrimoine (point de départ) — surtout du papier jamais océrisé.			

POURQUOI ÇA MANQUE — réalité (jamais déposé) / source (illisible) / nous (perdu)				
le manque	membres	RÉALITÉ rien déposé	SOURCE déposé, illisible	NOUS exploité puis perdu
photo d'entrée absente	142	9	102	31
photo de sortie absente	96	86	9	1
aucun rapport annuel couvert	79	66	13	0
L'immense majorité des manques = jamais déposé ou papier illisible : on n'a laissé sur la table quasiment rien d' <i>automatiquement</i> extractible.				

2. Est-ce BACKTESTABLE ?

FEU PAR DIMENSION		
●	le flux de transactions	complet, traçable, décomposable ligne à ligne, chez 408 membres.
●	le point de départ	166 des 408 membres partent d'un portefeuille connu ; les 242 autres démarrent de zéro.
●	l'horloge (dates)	reconstruit à la date d'opération = borne haute. La date de divulgation est portée dans le flux ⇒ le rejeu réaliste (27 j / 374 j plus tard) se lance en une ligne, quand tu veux.
●	les prix	12,1 % des lignes tombent faute de cours (1 234 tickers) — confirmé réel (re-test 22/07).
●	l'échantillon	11 années civiles ⇒ écart minimal détectable 4,6 %/an .
VERDICT		
L'extraction est propre, vérifiée et essentiellement complète pour tout ce qui est automatiquement extractible. Le flux de 129 538 transactions (3 sources, 408 membres, 3 défauts corrigés, recoupé au notebook, jugé à 9 → 57 % par un juge indépendant) EST backtestable dès maintenant . Le test <i>réaliste</i> z (rejeu à la publication) est déjà outillé — les deux dates sont dans le flux — mais pas encore joué, <i>par choix</i> . Les manques restants sont soit structurels (jamais déposé / papier illisible), soit des limites de méthode connues , pas des erreurs.		
À FAIRE — pour extraire plus / rendre le backtest plus réaliste		
1	rejeu à la date de divulgation (test réaliste)	<i>données prêtes</i> — <code>flux_house_2dates.csv</code>
2	Schedule A des rapports annuels comme départs	460 membres exploitables vs 243 aujourd'hui
3	récupérer les lignes sans-ticker récupérables	10 416 + 59 948 sur 337 593
4	autre source de cours pour les 1 455 tickers morts	ou l'accepter comme limite
5	(<i>optionnel, risqué</i>) gisement OCR des rapides	+2 510 trades, mais 81 % des symboles viennent d'un LLM

3. Pourquoi croire ces chiffres, et où trouver le reste

COMMENT ON SAIT QUE C'EST JUSTE

- les 5 tables de départ sont **gelées** (empreinte sha256 conforme au manifeste) — rien n'a bougé sous nos pieds.
- la population est **re-croisée** avec le référentiel officiel des mandats : **98,9 %** de concordance.
- **chaque cascade et chaque tableau croisé** sont vérifiés par un **assert** (la somme doit boucler, sinon le notebook s'arrête).
- la **classe** d'un actif (action / fonds / monétaire) est décidée **avant** tout prix — pas de fonds déguisé en action.
- la reconstruction est **jugée** par des positions déclarées qui n'ont *jamaïs* servi à la construire : rappel médian **9** → **57 %**, + 5 recomptes à la main (écarts 10^{-9} à 10^{-15}).
- **aucun chiffre n'est écrit en dur** : tout se régénère en ré-exécutant le notebook.

OÙ TROUVER QUOI — les 4 documents de cette donnée

document	pages	à quoi ça sert
ce doc (SYNTHESE_EXTRACTION)	4	l'entrée unique : comprendre + être sûre que tout est bon
la fiche (FICHE_DONNEES_HOUSE)	5	comprendre en détail , étape par étape
le deck (SLIDES_DONNEE_HOUSE_court)	39	présenter à un public
le notebook (Portefeuilles_House_Complet)	—	la preuve : tous les chiffres, rejouable · produit <code>flux_house_2dates.csv</code>

L'ancien deck long (80 p.) est **archivé** : le deck court 39 p. le remplace.