

Les autres dépôts — le patrimoine, sa reconstruction, et ce qu'il change au backtest

Déclarations boursières du Congrès américain · Chambre · 2014–2026

Alice Lemaire

Document de recherche — livrable Ramify

Juillet 2026

Le fil — quatre actes, dans l'ordre

ACTE 1

De la source aux tables

comment on **récupère** & extrait la donnée : électronique vs scanné, l'OCR, les 18 tables

ACTE 2

Les chiffres au clair

le catalogue des 12 types + les nombres, sans se perdre

ACTE 3

La population : qui a quoi

portefeuille d'entrée, vérifiable, annuels — 822 reconstruits, 56 prouvés

ACTE 4

Changer le portefeuille

partir du patrimoine d'entrée — ce que ça change vraiment


Périmètre : **Chambre** uniquement · un seul millésime de comptage (**union**, 35 377 dépôts) · chaque chiffre sort d'un notebook exécuté (V1-House, notebook 10).

ACTE 1

De la source aux tables

comment on récupère la donnée déclarative — avant de parler de population ou de backtest

Le trajet — le même pipeline que le PTR, sauf un geste



les gestes **1 à 3** (recenser · router · identifier) et le **mécanisme d'OCR** sont **identiques au PTR** — déjà vus.

Le seul qui **change** est le geste **4 · extraire** : on ne lit pas la même chose *dans* le document.


CHOIX — on ne re-raconte donc pas le pipeline du PTR : on va droit à **ce qui diffère** — les *schedules* du formulaire FD.

Rappel — recenser, router, identifier : c'est le pipeline du PTR

- 1 **Recenser** : 13 index annuels → **35 377** dépôts (dont 27 110 « autres »).
- 2 **Router** : le 1^{er} chiffre du DocID → **lisible** (1-4) ou **scanné** (7-9).
- 3 **Identifier** : nom imprimé → bioguide (rattachement 99 %).

CHOIX — rien de neuf ici — **c'est le pipeline du PTR**. Une seule nuance : les FD ont une part **scannée plus lourde** (annuels papier) → plus d'OCR.

Part des PTR scannés, par année (document · P · House) — le papier s'éteint : 60 % en 2014, 10 % en 2026



part scannée par année (2014–2019 surtout).

4 · Extraire — la vraie différence : un formulaire à dix sections



le **PTR** n'a qu'une section — B (transactions). Un **FD** (C/O/H/T/A) en a **dix** :

PTR : B seul → transactions

FD : A B C D E F G H I J

on les **distingue** par leurs **en-têtes** SCHEDULE A: ...

SCHEDULE J: — un découpage qui gère deux mises en page (« ScHeDule b : » ≤ 2020, « S B : » 2021+).

Les sections A–J, et lesquelles apparaissent dans chaque type de document

	P	Identiques		Identiques	
		C	H	O	T
	PTR	candidat	entrée	annuel	sortie
A Actifs & revenus de placement		✓	✓	✓	✓
B TRANSACTIONS	✓			✓	✓
C Revenus du travail		✓	✓	✓	✓
D Dettes		✓	✓	✓	✓
E Postes occupés		✓	✓	✓	✓
F Accords		✓	✓	✓	✓
G Cadeaux				✓	✓
H Voyages payés				✓	✓
I Dans à une œuvre (au lieu d'honoraires)				✓	✓
J Compensation > 5 000 \$ d'une source		✓	✓		

socle commun A · C · D · E · F (dans tous sauf le PTR) — seule la section B (transactions) nous intéresse

→ B n'existe que dans le PTR, l'annuel (O) et la sortie (T)

L'amendement A reprend les sections du document qu'il corrige (C·H ou O·T)

les sections présentes selon le type de dépôt.

4 · Extraire — on ne garde que deux sections : A et B

Schedule A — patrimoine (le NOUVEAU)

les **actifs détenus** (fourchette de valeur, sans date) — *la photo* du portefeuille. Le PTR ne l'a **pas** : c'est ce qui rend possible toute la reconstruction (Acte 3).

Schedule B — transactions

les mêmes trades que le PTR, mais **format différent** (ordre *date · type · montant*) → un **parseur séparé**.

CHOIX — les huit autres sections (C revenus · D dettes · E positions · F accords · G cadeaux · H voyages · I paiements · J rémunérations) sont **ignorées** — hors sujet portefeuille. Et on ne garde que les lignes **tickérisées** (le non-coté est compté, pas utilisé).

4 · Extraire — l'OCR des FD scannés : quasi complet, limites vérifiées

Couverture — quasi complète

l'OCR (claude-sonnet-5, contrat record_fd) extrait **Schedule A + B. 2 842 / 2 851** FD scannés OCRisés ; les **9** manquants = reliquats **2014** (PDF morts). Même les annexes de courtier (jusqu'à **797 p. / 51 048 lignes**) sont passées.

Deux limites — vérifiées

(1) les **312 « vides »** sont des **formulaires blancs** (vérifié en ouvrant les PDF : Schedule A vierge) — l'OCR a *raison*, pas des ratés. **(2)** **5 185** valeurs mal lues (2,7 %) — **sans effet sur le backtest** (tables FD hors périmètre) ; un fix parseur en récupère **1 667**.

CHOIX — ce qui justifie la dépense : **29 %** des documents (scannés) portent **65 %** des transactions — l'OCR payant est **rentable**. Cache versionné → re-run **0 \$** (26 JSON rendus en chaîne, réparés au caractère près).

5 · Les 18 tables — le résultat de la collecte



Récupérer / router

01 recensement · 02 ledger · 03 inventaire PDF

Identifier

06 identités

Extraire — électronique

04 transactions (dédup) · 05 holdings (FD élec)

Extraire — OCR scanné

07 transactions PTR · OCR · 08 holdings FD · OCR · 09 transactions FD · OCR

Comptabilité

10 comptabilité du traitement

Reconstruire (Acte 3)

11 holdings complets · 12 portefeuilles datés · 13 · 17 recalages · 14 registre · 15 portefeuille d'entrée · 16 flux O/A/T · 18 churn


chaque table est **numérotée**, **versionnée**, **re-jouable** — c'est ce qui empêche la donnée de « partir dans tous les sens ».

6 · La boucle — chaque dépôt a un traitement, la somme boucle



sur les **35 377** recensés :

- **20 457** → **données extraites** (15 190 élec + 2 842 OCR FD + 2 425 OCR PTR)
- **14 869** recensés, **rien à extraire** (administratifs X/D/W/G/E + lignes vides)
- **33** hors périmètre (23 blind trust + 10 PDF morts, tracés)
- **18** doublons d'index (retirés)



75 contrôles automatiques, 0 rouge · somme vérifiée par *assert* bloquant.

Réponse — chacun des **27 110** « autres » dépôts a reçu **exactement un** traitement — rien perdu, rien inventé.

ACTE 2

Les autres dépôts : les chiffres au clair

un type lu sur douze — et de quoi parlent tous ces nombres

Le problème — on n'avait lu qu'un type de dépôt sur douze

8 267 dépôts **PTR** lus

le seul type exploité jusqu'ici — « ce que l'élu *fait* »

27 110 autres dépôts, **11 types**

jamais lus — « ce que l'élu *possède* »

sur **35 377** dépôts recensés (Chambre, 2014–2026).

Décomposition du **patrimoine de sortie** d'un élu :

33,2% déjà détenu à l'**entrée**
— invisible d'un départ de zéro

45,5% acheté **pendant le mandat** — vu par les PTR

21,3% restait à **expliquer**

CHOIX — les « autres dépôts » sont la matière qui rend visible le **tiers déjà là** — c'est tout l'enjeu.

Le catalogue — douze types de dépôt, trois familles

Le signal — ce que l'élu *fait*

P	Periodic Transaction Report	8 267	les transactions datées (notre backtest)
---	-----------------------------	-------	--

Les photos du patrimoine — ce que l'élu *possède*

C	Candidate Report	10 129	patrimoine au moment de la candidature
O	Annual Report	4 626	bilan annuel
H	New Filer Report	395	photo d'entrée en fonction
T	Terminated Filer Report	394	photo de sortie
A	Amendment	2 305	correction d'un O/C/H/T

Administratif — ni signal ni patrimoine

XDWGE	extensions, avis de campagne, dérogations	~9 240	aucune transaction
B	Blind Trust	23	géré à l'aveugle (cas Phillips)

chaque chiffre = un **nombre de dépôts** (millésime union) · total = 35 377.

Les chiffres, une bonne fois — et les pièges

Les dépôts & les transactions


35 377	dépôts recensés (12 types)
8 267	dont PTR (le signal)
27 110	dont autres (11 types)
161 076	<i>transactions</i> PTR datées
57 259	<i>transactions</i> dans les annuels

Les gens & leurs portefeuilles

900	membres passés par la Chambre
470 / 463	entrées / sorties (depuis 2014)
284	photos d'entrée (252 H + 32 C)
822	portefeuilles reconstruits
56	vérifiés de bout en bout

CHOIX — trois pièges : **(1)** un *dépôt* $\neq$ une *transaction* $\neq$ un *membre* — on ne les additionne jamais ; **(2)** « 45 » désigne 45 *membres* (la cohorte testée) *ou* 45 *positions* inexpliquées, selon le contexte ; **(3)** « 21,3% » a deux sens (du patrimoine de sortie / des positions inexpliquées).

La vie déclarative d'un élu — photos contre signal



les **photos** (C, H, O, T) disent **ce qu'il possède** (Schedule A) — le P dit **ce qu'il fait** (Schedule B). On traduit le P ; on va se servir des **photos**.

La couverture des entrées et des sorties

470 entrées au Congrès depuis 2014	82% ont déposé un H, 16% un C — 98% couvertes par une photo d'entrée
---	---

463 sorties définitives	81% ont déposé un T ; les 86 sans T = partis au Sénat/exécutif (dispensés), décès
--------------------------------	---

la **photo de départ** : **252** ancrés par un H · **32** par un C = **284** portefeuilles d'entrée datés

CHOIX — on distingue **dépôts** et **membres** : il y a 395 *dépôts* H mais 252 *membres* ancrés par un H (un membre peut en déposer plusieurs ; on ne garde qu'une photo d'entrée).

Ce que rate le filtre PTR — et pourquoi c'est quand même le bon choix

Les Schedule B des annuels (O/H/T/A) contiennent **57 259** transactions :

- **79,5%** *sans ticker* (fonds nommés, immobilier, non coté)
- parmi les tickérisées, **67,1%** déjà dans nos PTR
- reliquat : **173** actions « annuel-seul » en 13 ans (0,1%), concentrées 2014–2017

Le délai tue le signal

divulgaration médiane **406 j** (annuels) contre **27 j** (PTR)
— impossible à jouer sans regarder l'avenir.

Réponse — le filtre P reste le bon choix pour le **signal** ; les annuels ne sont pas un signal — ils servent de **vue patrimoine**, ce que l'Acte 2 exploite.

ACTE 3

La population — qui a quoi

quatre questions sur les 900 : portefeuille d'entrée, vérifiabilité, annuels — puis le pont vers le backtest

La population en une carte — 900 membres, quatre questions

900 membres

Chambre · 2014–2026

Q1 · Portefeuille d'entrée ?

284 OUI (252 H + 32 C, datés)
616 NON (435 déjà-là 2014 + 181 arrivés non ancrés)

Q2 · Vérifiable de bout en bout ?

900 → 149 cycle complet → 106 deux photos → 56 testables
entrée + flux ≥ sortie : 87,8 % expliqué · 3,3 % non

Q3 · Rôle des annuels (O) ?

119 membres n'existent QUE via l'annuel
O = photos de recalage (66,7 % stables) + achats (→ 84,2 %)


Backtest · qui peut-on copier ?

424 tradent (305 PTR + 119 annuel-seul)
→ 165 G-photo / 259 G-zéro · 159 photos injectées

deux lectures d'un même corps : « quelles données a-t-on » (Q1–Q3) et « peut-on le backtester » (bas)

deux lentilles sur le même corps : **quelles données a-t-on** (Q1–Q3) et **peut-on le backtester** (bas) — chaque slide qui suit détaille une branche.

Q1 · Qui a un portefeuille d'entrée ? — 284



chaque flèche = une perte *mesurée* : −84 sans H (75 ont un C, 9 rien) · −134 H **scannés/OCR** ou patrimoine **non coté** · +32 par la **porte C** (candidat élec, tickérisé, ≤ 1 an avant la prise de poste).

CHOIX — « 385 dépôts H » serait trompeur : il y a 395 *dépôts bruts*, 387 *bioguides*, 386 *entrants* avec H — mais seulement **252** donnent une *photo exploitable*. On compte des **membres**, pas des dépôts.

Q2 · Qui n'a pas de portefeuille d'entrée ? — 616

435 structurels

déjà en poste en **2014** : aucune photo d'entrée *possible* dans la fenêtre. Ce n'est pas un trou de collecte.

181 arrivés non ancrés

entrés après 2014 mais H **scanné** / **sans ticker**, ou aucun dépôt exploitable.

$435 + 181 = 616$ et $284 + 616 = 900$. Pour ces 616, la reconstruction ne peut pas s'ancrer à l'entrée — elle part d'une photo plus tardive, ou de rien.

Comment on reconstruit — la mécanique, maths à l'appui

Reconstruire un portefeuille — la mécanique, pas à pas (un titre suivi : XYZ)

1 Ancrer la photo d'entrée

$$h_0(i) = \tilde{v}_i / P_i(\tau_0)$$

XYZ : 50-100 k\$ $\rightarrow \tilde{v} = 75$ k\$; / 150 \$ = **500** parts

milieu de fourchette, converti en parts au prix du jour du dépôt

2 Appliquer un achat déclaré

$$h_i \leftarrow h_i + \tilde{v} / P_i(\tau)$$

achat 32,5 k\$ / 160 \$ = +203 $\Rightarrow$ **703** parts

PTR ou annuel O/A/T : même règle, provenance tracée

3 Appliquer une vente déclarée

$$h_i \leftarrow h_i - \min(q, h_i)$$

vente 175 k\$ $\rightarrow q = 1250$; $\min(1250, 703) = 703 \Rightarrow$ **0**

sans la photo, on n'aurait vendu que 203 (la troncature corrigée)

4 Recaler, puis valoriser

$$V(t) = \sum_i h_i(t-1) P_i(t)$$

à chaque photo : $h \leftarrow \text{Schedule A}$ · test : $H + \Sigma P \supseteq T$

le document fait foi ; le rendement porte sur les parts de la veille

en **parts** (fourchette $\rightarrow$ milieu $\rightarrow$ parts au prix du dépôt) · **66,7 %** des positions se confirment d'une photo à la suivante (patrimoine **stable**, le « churn » = renommage) $\rightarrow$ **822** portefeuilles datés.

...et sur du vrai — le portefeuille reconstruit de Dean Phillips





photo d'entrée (H, 2019) → flux datés → recalage à chaque photo → photo de sortie (T, 2025) : une **trajectoire datée** par élu.

Q3 · Qui peut-on vérifier ? — le test : entrée + achats $\supseteq$ sortie


$$\underbrace{H}_{\text{photo d'entrée}} + \underbrace{\sum P}_{\text{achats déclarés}} \supseteq \underbrace{T}_{\text{photo de sortie}}$$



la **loi** borne l'échantillon : **439** déjà en poste en 2014 (pas de photo d'entrée), **437** encore en poste (pas de photo de sortie) ; la moitié des 106 ne détient **aucune action cotée**.

CHOIX — une **identité comptable** : si la collecte était trouée, elle casserait ici. Un détecteur de trous, pas une statistique.

Q3 · Le résultat — 78,7 → 84,2 → 87,8%, et 3,3% non



sur **1 371** positions de sortie (cohorte H^T électronique) :

entrée + achats **PTR** → **78,7%**

+ Schedule B des **annuels** (O/A) → **84,2%**

+ Schedule B de la **sortie** (T) → **87,8%**

–122 structurelles (comptes gérés, ETF, petites lignes)

45 positions / 14 membres
= **3,3%** inexpliquées

CHOIX — chaque écart est classé par preuve documentaire, jamais éliminé statistiquement.

Q4 · Le rôle des annuels (0) — « sur l'annualisé »

1 · des trades qu'on n'aurait pas

flux annuel net **26 115** (0 = 85 %) → 14 970 ajoutés.
119 membres n'ont *aucun* trade PTR : leurs seules actions cotées n'existent que **dans l'annuel**. La population passe de **305 à 424**.

2 · des points de recalage

les photos 0 **recalent** le portefeuille entre l'entrée et la sortie (**66,7 %** stables), et leur Schedule B fournit le pas **78,7 → 84,2 %** du test.

CHOIX — « vérifier sur l'annualisé » = les trades 0/A/T *plus* le patrimoine d'entrée. Le **backtest** (Acte 3), lui, ne part que de la **photo d'entrée** — pas des photos annuelles intermédiaires.

Deux compteurs, deux partitions — et le croisement

Deux questions, jamais confondues :

RECONSTRUIRE → 822

≥ 2 photos datées

VÉRIFIER → 56

cycle complet, testable

registre *par force de preuve* : 56 + 109 complet + 715 partiel + 20 hors = 900. 822 et 56 ne s'additionnent pas ; $822 \subset 880 (= 900 - 20)$.

Réponse — ~9 reconstruits sur 10 restent sans preuve de bout en bout — on l'assume. Fil rouge : Dean Phillips, l'un des 56.

Les 424 qui tradent — portefeuille d'entrée x type de trade

284 photos d'entrée → 248 exploitables → 165 appartiennent à un trader (G-photo) → 159 injectées

	trade PTR	annuel-seul	total
avec photo (G-photo)	120	45	165
sans photo (G-zéro)	185	74	259
total	305	119	424

sur les 165 G-photo, 159 sont réellement injectées (117 PTR + 42 annuel-seul) ; 6 photos non pricables au jour du dépôt

ACTE 4

Changer la construction du portefeuille


partir du patrimoine d'entrée au lieu de zéro — ce que ça change, vraiment

L'idée — partir du patrimoine d'entrée, pas de zéro

Le mécanisme, sur un titre suivi (XYZ) :

- ▶ la **photo d'entrée** donne **500 parts** (fourchette convertie au prix du jour du dépôt)
- ▶ un achat déclaré ajoute **203 parts** → **703**
- ▶ une vente de **1 250 parts** : avec la photo on solde $\min(1\,250, 703)$; **sans** photo le moteur n'aurait vendu que les **203** achetées — **la troncature qu'on corrige**

CHOIX — le rendement se calcule sur les parts de la **veille** : **un apport n'est jamais une performance** ($r = 0$ le jour de l'injection, vérifié numériquement).



ventes non couvertes, tronquées par $\min(q, h)$, en M\$ par run.

Le dispositif — quatre runs, même moteur, seules les données changent


A PTR seuls, départ zéro — **le témoin**

B A + photos d'entrée (B-A = **l'effet photo**)

C A + trades O/A/T (C-A = **l'effet O/A/T**)

D A + photos + O/A/T — **la stratégie adaptée**


Population : **900** membres → **424 tradent** = **305** vus par les PTR + **119** *uniquement* via O/A/T → **165** avec photo exploitable (G_photo) / **259** sans (G_zéro).



Ce que ça change concrètement — qui entre dans le jeu

run	membres	photos inj.	tronqué
A témoin	226	0	937 M\$
B +photo	257	117	897 M\$
C +oat	362	0	1 179 M\$
D adaptée	385	159	1 121 M\$

- la photo **ressuscite 77 vendeurs purs** (31 rendus dès B)
- 42** membres « O/A/T-seuls » enfin servis (D injecte 159 photos, pas 117)
- la **sélection change à 11/11 coupes** annuelles




sélections par année : vert = A et D · rouge = A seul · orange = D seul.

Le tableau — excès vs SPY, sur 11 années civiles

run · poids	excès/an	t	gagn.	β	t_{ap}
A · 1/K	+0,9	0,37	4/11	0,99	0,28
A · i-v	-0,3	-0,11	4/11	1,00	-0,27
B · 1/K	+6,6	0,85	5/11	0,98	1,55
B · i-v	+3,1	0,60	5/11	0,93	1,33
C · 1/K	-0,0	-0,02	4/11	0,92	0,54
C · i-v	-1,4	-0,81	5/11	0,83	0,48
D · 1/K	+0,7	0,31	4/11	0,89	0,96
D · i-v	-0,6	-0,31	4/11	0,82	0,87

seuil de significativité : $t_{10} \approx 1,81$ · l'inverse-vol (i-v) perd sur toutes les lignes.



NAV témoin (A) vs adaptée (D) vs SPY, poids 1/K.


Le mélange des deux groupes — surveillé, pas ignoré

Le risque : le Sharpe de G_{photo} (portefeuille complet, NAV lisse) et de $G_{\text{zéro}}$ (base étroite, bruitée) ne se mesurent pas pareil — le top- K pourrait préférer un groupe pour des raisons de *mesure*, pas de talent.

S1 le top- K sur-représente G_{photo} certaines années (2020 : **80%** vs 30% des éligibles) — et 0% d'autres années : le mélange pèse réellement

S2 jouée *dans chaque groupe séparément*, aucune strate ne contredit le verdict mixte

CHOIX — honnêteté : un t_{ap} de 1,76 vu avant réparation était en partie un **artefact d'étiquetage** (40 membres à photo classés « zéro ») — corrigé.



Le verdict — plus propre, mais pas d'alpha

Pas d'alpha démontrable

aucune configuration ne franchit le seuil : **max** $t = 0,85$, $\max t_{ap} = 1,59$ en strate. Robuste au poids, à la strate, au mélange et au périmètre.

Mais un backtest plus propre

l'adaptée resserre le β (**0,99** $\rightarrow$ **0,89**) et remonte le t_{ap} ($+0,28 \rightarrow +0,96$); l'**effet photo** (B) est la meilleure ligne, **+6,6%/an**.

Caveats assumés : O/A/T datés à la transaction mais divulgués ~ 374 j après · double comptage possible avant le dépôt
· non-coté hors périmètre · `prices_v2` jamais modifié.

Réponse — partir du patrimoine d'entrée est un gain de **propreté et de robustesse** (moins de bruit de mesure, β vers 1) — pas un alpha nouveau.

Ce qu'on retient

- 1 on n'avait lu qu'un dépôt sur douze ; les **27 110 autres** rendent visible le **tiers** du patrimoine « déjà là, jamais tradé ».
- 2 on **reconstruit 822** portefeuilles datés et on en **vérifie 56** de bout en bout : **87,8%** des positions de sortie s'expliquent, **3,3%** restent, classées par preuve.
- 3 initialiser le backtest au **patrimoine d'entrée** corrige les ventes tronquées et change les élus copiés — le résultat est plus **propre** ($\beta \rightarrow 1$), **pas** un alpha nouveau.

Chambre uniquement · chiffres issus des notebooks V1-House & 10 · millésime union (35 377 dépôts).