

L'extraction House, d'un coup d'il : propre ? complète ? backtestable ?

House 2013–2026 · chiffres du notebook Portefeuilles_House_Complet, recoupés cellule par cellule · ● solide ● limite connue ● manque structurel

129 538

transactions valorisées

408

membres qui tradent

243

portefeuilles de départ

9 → 57 %

rappel vérifié (juge indép.)

CE QU'ON A EXTRAIT — le flux de transactions, par source

source	trades	montant	publié après l'opération
● déclarations rapides <i>P</i> (fil de l'eau)	107 976	fourchette, milieu	médiane 27 j (q90 49 j)
● rapports annuels <i>O/A/T</i> (électronique)	14 084	fourchette, milieu	médiane 374 j
● Schedule B scanné (océrisé)	7 478	forfait 8 000 \$	médiane 393 j
flux unifié F	129 538	chez 408 membres · traçable ligne à ligne, 3 sources	

Chaque ligne porte désormais **sa date d'opération ET sa date de divulgation** (export flux_house_2dates.csv). La reconstruction reste à la date d'opération.

A-T-ON TOUT PRIS ? — taux d'exploitation par type de document (le <i>récall</i> ž)			
type de document	exploité	lu, 0 ligne	papier jamais océrisé
● <i>P</i> — déclaration rapide (transactions)	100 %	—	—
● <i>O</i> — rapport annuel	74,7 %	450	721
● <i>A</i> — amendement	59,2 %	507	433
● <i>T / H</i> — photos entrée/sortie	65 %	~125 lues 0 ligne + papier	
● <i>C</i> — photo de candidat	39,7 %	4 515	1 583
La transaction est prise à 100 % ; ce qui se perd, c'est la <i>photo</i> du patrimoine (point de départ) — surtout du papier jamais océrisé , pas notre traitement.			

POURQUOI ÇA MANQUE — réalité (jamais déposé) / source (illisible) / nous (perdu)				
le manque	membres	RÉALITÉ	SOURCE	NOUS
		rien déposé	déposé, illisible	exploité puis perdu
photo d'entrée absente	142	9	102	31
photo de sortie absente	96	86	9	1
aucun rapport annuel couvert	79	66	13	0
L'immense majorité des manques = jamais déposé ou papier illisible : on n'a laissé sur la table quasiment rien d' <i>automatiquement</i> extractible.				

EST-CE BACKTESTABLE ? — feu par dimension	
● le flux de transactions	complet, traçable, décomposable ligne à ligne, chez 408 membres.
● le point de départ	166 des 408 membres partent d'un portefeuille connu ; les 242 autres démarrent de zéro (patrimoine d'entrée inconnu).
● l'horloge (dates)	reconstruit à la date d'opération = borne haute assumée. La date de divulgation est portée dans le flux ⇒ le rejeu réaliste (27 j / 374 j plus tard) se lance en une ligne, quand tu veux.
● les prix	12,1 % des lignes tombent faute de cours (1 234 tickers) — confirmé réel (re-test 22/07, ces titres n'ont pas de série).
● l'échantillon	11 années civiles ⇒ écart minimal détectable 4,6 %/an (un edge plus petit reste invisible).

VERDICT
L'extraction est propre, vérifiée et essentiellement complète pour tout ce qui est automatiquement extractible. Le flux de **129 538 transactions** (3 sources, 408 membres, 3 défauts corrigés, recoupé au notebook, jugé à 9 → 57 % par un juge indépendant) **EST backtestable dès maintenant**. Le test n réaliste z (rejeu à la publication) est **déjà outillé** — les deux dates sont dans le flux — mais pas encore joué, *par choix*. Les manques restants sont soit **structurels** (jamais déposé / papier illisible), soit des **limites de méthode connues**, pas des erreurs.

À FAIRE — pour extraire plus / rendre le backtest plus réaliste	
1 rejeu à la date de divulgation (test réaliste)	<i>données prêtes</i> — flux_house_2dates.csv
2 Schedule A des rapports annuels comme départs	460 membres exploitables vs 243 aujourd'hui
3 récupérer les lignes sans-ticker récupérables	10 416 + 59 948 sur 337 593
4 autre source de cours pour les 1 455 tickers morts	ou l'accepter comme limite
5 (<i>optionnel, risqué</i>) gisement OCR des rapides	+2 510 trades, mais 81 % des symboles viennent d'un LLM

Pourquoi croire ces chiffres. Tables gelées (sha256) ; mandats re-croisés au référentiel officiel (98,9 %) ; chaque cascade et tableau croisé vérifiés par assert ; classe d'un actif décidée avant tout prix ; reconstruction jugée par des positions qui n'ont jamais servi à la construire ; aucun chiffre écrit en dur — tout se régénère en ré-exécutant le notebook.