

Les remarques du chef, transformées en mesures

backtest **par membre** (Partie II du deck) · six remarques, six hypothèses silencieuses, six mesures
chaque chantier : le défaut *formel* · l'objet mathématique · le test · ce que ça décide

Le fil rouge. Les six remarques disent la même chose : **une hypothèse a été posée là où il fallait une mesure.** Aucune n'est défendue ici — chacune est remplacée par une quantité qu'on estime.

remarque (page)	l'hypothèse silencieuse	ce qu'on mesure à la place
C1 « holdings stables → discounter » (48)	une position dormante informe autant	α par tranche d'âge → le noyau
C2 « long vs short ? »	vendre = acheter au signe près	γ^+ et γ^- séparés
C3 « le β est trop naïf » (53, 60)	β constant, <i>ex-post</i> , 1 facteur	β_t <i>ex-ante</i> + tests de rupture
C4 « délégation : à supprimer » (40)	tous les comptes informent pareil	3 périmètres emboîtés
C5 « avec et sans winsor » (47)	un saut > 50%/j est du bruit	le saut validé par le volume
C6 « $n_{\text{trades}} \geq 10$: à relaxer » (52)	le seuil dur est la bonne porte	balayage + shrinkage

C1 — Les positions dormantes — l'information se périme

« si les holdings sont stables pendant trop longtemps, ce ne peut être considéré comme de l'inside trading : il faut les discounter et les faire tendre vers 0 » + p. 48 : « retirer les trades qui sont là depuis plus de 1 an, 2 ans, 3 ans, 5 ans »

Le défaut, formellement. Le moteur construit la position $n_i(t) = \sum_{\text{achats} \leq t} q - \sum_{\text{ventes} \leq t} q^-$, et cette position vit **indéfiniment** : elle pèse autant le jour de l'achat que douze ans après. Or le rendement mesuré, $r_P(t) = \sum_i w_i(t-1) r_i(t)$, y attribue son plein poids. **L' α de l'élue inclut donc le rendement de lignes qu'il n'a pas touchées depuis des années** — du buy-and-hold, pas de l'information. Ce n'est pas marginal : **durée médiane de détention 390 j et 44 % des positions ne sont jamais revendues** (deck p. 49).

L'objet à définir : l'âge d'une ligne. Pour le membre m et le titre i ,

$$\ell_{m,i}(t) = t - \max\{\tau_j : j \text{ trade de } m \text{ sur } i, \tau_j \leq t\} \quad (\text{âge du dernier mouvement, en jours de bourse})$$

Deux traitements, emboîtés. (a) *la coupe* — ce que le chef demande littéralement : $A_L(t) = \{i : \ell_{m,i}(t) \leq L\}$, poids renormalisés sur A_L , balayage $L \in \{252, 504, 756, 1260\}$ j (1, 2, 3, 5 ans). (b) *le discount* — ce qu'il préfère : $\psi_H(\ell) = 2^{-\ell/H}$, $\tilde{n}_i(t) = n_i(t) \psi_H(\ell_i(t))$, puis

$$\tilde{w}_i(t) = \frac{\tilde{n}_i(t) P_i(t)}{\sum_j \tilde{n}_j(t) P_j(t)}, \quad r_P^{(H)}(t) = \sum_i \tilde{w}_i(t-1) r_i(t), \quad H \in \{63, 126, 252, 504\} \text{ j.}$$

(a) est le cas particulier de (b) avec $\psi = \mathbf{1}_{[0,L]}$; et $L, H \rightarrow \infty$ redonnent **exactement** le moteur actuel. Le backtest présenté est donc un *point* de la famille — la comparaison est honnête, ce n'est pas un autre modèle.

Le test qui tranche : la structure par terme de l' α . On ne postule pas la décroissance, on la lit. Tranches d'âge disjointes $A_1 = [0, 63)$, $A_2 = [63, 252)$, $A_3 = [252, 756)$, $A_4 = [756, \infty)$; chacune est un sous-portefeuille dont on mesure α_g . Puis test de tendance

$$\alpha_g = a + b \bar{a}_g + u_g, \quad H_0 : b = 0 \quad \text{contre} \quad b < 0$$

($\bar{a}_g$ = âge médian de la tranche ; version non paramétrique : Jonckheere-Terpstra). Et la décomposition qui répond en un chiffre : $\alpha_P \simeq \sum_g \bar{\kappa}_g \alpha_g$ où $\bar{\kappa}_g$ = part du portefeuille dans la tranche g — **quelle fraction de l' α vient des décisions récentes, quelle fraction du stock dormant.**

→ **ce que ça décide** : si $b < 0$, la forme de (α_g) dicte H (on lit la demi-vie au lieu de la choisir) ; si $b \approx 0$, la thèse est infirmée — et c'est un résultat, chiffré.

C2 — Achat contre vente — l'asymétrie jamais testée

« j'aurais envie de savoir s'il y a une différence d'information // de valeur entre les long et les short positions »

D'abord, la réponse honnête. Sur 134 464 lignes, **405 (0,30 %)** portent une sémantique short/option (put 172 · short 122 · call 61 · bear 52 · warrant 8 · inverse 4), et la direction déclarée est binaire (buy 68 250 / sell 66 214). **La comparaison « position longue vs position courte » n'est pas estimable**

chez nous — c'est l'angle mort exact où Molk & Partnoy (*Indiana LJ*, 2025) trouvent l'information, sur 587 trades négatifs. À déclarer comme limite, pas à simuler.

Ce qui est estimable — et que le moteur assume sans le tester. Deux troncatures, l'une dans le moteur, l'autre dans le signal :

$$\underbrace{q^- = \min(a/P_i(\tau), n_i(\tau^-))}_{\text{moteur : « short interdit »}} \quad \underbrace{\text{NetBuy} = [\text{Buy} - \text{Sell}]^+}_{\text{signal agrégé}}$$

Ce que ça coûte, **mesuré** : côté moteur, **937 M\$ de ventes tronquées** sur le seul run témoin (notebook House). Côté agrégat, sur les 57 496 couples (ticker, mois de divulgation) actifs : achats seuls 22 063 (38,4 %) · **ventes seules 22 374 (38,9 %)** · les deux, net > 0 : 4 443 · les deux, net ≤ 0 : 8 616. **La troncature annule 53,9 % des couples actifs**, dont 38,9 points de *pure vente*. Et la jambe vente est aussi fournie que la jambe achat : **6 126** couples à ≥ 2 vendeurs distincts contre **6 077** à ≥ 2 acheteurs.

Le trou dans les tables actuelles. Le track-record par trade du notebook 09 — taux de réussite, excès moyen, *profit factor* — est calculé **sur les achats seulement** : le dictionnaire le dit, « # achats avec x_j calculable ». **La moitié vente n'a jamais été calculée.**

Le test. On symétrise l'excès par trade, avec le signe qui convient :

$$x_j^{\text{buy}} = R_i(\delta_j \rightarrow \delta_j + h) - R_{\text{SPY}}(\cdot), \quad x_j^{\text{sell}} = -[R_i(\delta_j \rightarrow \delta_j + h) - R_{\text{SPY}}(\cdot)]$$

(une vente est « réussie » si le titre sous-performe ensuite), $h \in \{21, 63, 126, 252\}$ j. Puis, en coupe (Fama-MacBeth), avec $b^\pm$ les intensités z-scorées et x les contrôles (taille, β , momentum 12-1, secteur) :

$$r_{i,t \rightarrow t+h} = \gamma_{0,t} + \gamma_t^+ b_{i,t}^+ + \gamma_t^- b_{i,t}^- + \delta_t' x_{i,t} + \varepsilon_{i,t} \quad \bar{\gamma}^\pm \text{ et } t_{\text{NW}}(\bar{\gamma}^\pm)$$

Trois hypothèses emboîtées, chacune dit quoi faire :

- $H_A : \bar{\gamma}^+ = -\bar{\gamma}^-$ — symétrie parfaite : netter 1:1 est justifié (*l'hypothèse actuelle*);
- $H_B : \bar{\gamma}^- = 0$ — **il ne faut pas netter** : retrancher les ventes n'ajoute que du bruit (*ce que suggèrent Pyun 2026, et notre 08 : jambe vente +0,59%/an, t 0,35*);
- $H_C : \bar{\gamma}^- < 0$ — le netting est justifié, et un long-short devient légitime (*Lazzaretto 2024 : -0,64 % à 20 j*).

Le taux de substitution se *lit* au lieu d'être imposé : $\theta^* = -\bar{\gamma}^-/\bar{\gamma}^+$, signal $\Psi_{i,t} = \text{Buy}_{i,t} - \theta^* \text{Sell}_{i,t}$ ($\theta^* = 1$ redonne l'actuel, $\theta^* = 0$ dit « ignore les ventes »).

La motivation de la vente (le fond du sujet) : un achat est un acte de conviction, une vente peut être de l'information, un besoin de liquidité, ou un rebalancement. Deux marqueurs les séparent, tous deux calculables : *solde total* ($n_i \rightarrow 0$, plus probablement informationnelle) et *vente groupée* (≥ 3 titres vendus le même jour par le même membre = liquidité). Prédiction falsifiable : $\bar{\gamma}^-(\text{info}) < \bar{\gamma}^-(\text{liq}) \approx 0$.

→ **ce que ça décide** : s'il faut netter ou non, avec quel θ^* , et si la jambe vente mérite un portefeuille à elle.

C3 — Le β — *ex-post* et unique, donc ni implémentable ni interprétable

p. 53 : « **bon test mais s'il est seul, est trop naïf. Le beta est-il stable dans le temps ?** » +

p. 60 : « **stable dans le temps ?** »

Les cinq défauts de $r_P(t) = \alpha + \beta r_{SPY}(t) + \varepsilon(t)$ (MCO, échantillon complet).

1. **Il est *ex-post*** : le β qui « corrige » 2016 est estimé avec des données de 2025. Un gérant en 2016 ne le connaît pas $\Rightarrow$ la correction n'est pas implémentable, et si β covarie avec le marché, $\hat{\alpha}$ est biaisé.
2. **Il est unique alors que le portefeuille tourne** : la sélection change **11 années sur 11** (notebook House). Un β unique moyenne des paniers qui n'ont aucun titre en commun.
3. **Un seul facteur** : le panier est mégacap-tech (top-10 = 86 % du portefeuille en 2026, NVDA 22 % — 05b). Le SPY ne capte ni taille, ni value, ni momentum. Hanousek 2023 : *le benchmark crée l' α* (+4,9 % market-adjusted $\rightarrow$ -0,1 % industry-adjusted, mêmes trades).
4. **Inférence i.i.d.** : rendements quotidiens autocorrélés (positions chevauchantes) et hétéroscédastiques $\Rightarrow$ écarts-types MCO faux.
5. **Le β est une conséquence de la sélection, pas une propriété** : l'univers a $\beta \approx 1,0$, le top-4 a $\beta = 1,20$. *C'est le classement qui va chercher des membres à fort β* — donc β bouge mécaniquement à chaque coupe.

L'estimateur : β *ex-ante*, bottom-up. Le β du portefeuille est **connu à l'avance** — on connaît les poids et les β des lignes :

$$\beta_t^P = \sum_i w_{i,t} \hat{\beta}_{i,t}^{\text{shr}}, \quad \hat{\beta}_{i,t}^{\text{shr}} = \omega_i \hat{\beta}_{i,t} + (1 - \omega_i) \cdot 1, \quad \omega_i = \frac{\sigma_{\text{cross}}^2}{\sigma_{\text{cross}}^2 + s^2(\hat{\beta}_{i,t})}$$

$\hat{\beta}_{i,t}$ estimé sur les 252 jours $\leq t$ (point-in-time), puis shrinké vers 1 (Vasicek) : un titre peu liquide a un $s(\hat{\beta})$ énorme, ω_i le pondère automatiquement par sa précision. Trois gains : **implémentable** (connu à t , donc on peut couvrir) · **stable par construction** · **décomposable** —

$$\Delta \beta^P = \underbrace{\sum_i \Delta w_i \bar{\beta}_i}_{\text{effet composition}} + \underbrace{\sum_i \bar{w}_i \Delta \beta_i}_{\text{effet marché}}$$

on sait dire *pourquoi* β bouge.

Cadragé mesuré. Le β moyen des titres à ≥ 2 acheteurs dérive de **0,94 (2016) à 1,05 (2026)** — modeste — pendant que la part *Information Technology* double, de **10 % à 24 %**. Donc : la dérive du β de marché est faible, celle de **l'exposition de style** est massive $\Rightarrow$ l'argument « un facteur ne suffit pas » est plus fort encore que « le β bouge ». (Honnêteté : ces β sont plein-échantillon, ils *sous-estiment* la variation ; et un top-4 concentré bouge bien plus qu'un univers de 300 titres.)

Les tests de stabilité — la question littérale du chef.

- β_t roulant 252 j avec bande de confiance — la figure qui répond à l'œil ;
- **Chow** sur rupture datée (COVID, 02/2020) : $H_0 : \beta_1 = \beta_2$;
- **CUSUM / CUSUM²** (Brown-Durbin-Evans) : rupture *non datée a priori* — le test propre, il ne suppose pas où chercher ;
- β **asymétrique** : $r_P - r_f = \alpha + \beta^-(r_M - r_f)\mathbf{1}_{r_M < 0} + \beta^+(r_M - r_f)\mathbf{1}_{r_M \geq 0} + \varepsilon$, $H_0 : \beta^+ = \beta^-$. Si $\beta^- > \beta^+$, le portefeuille prend *plus* de marché quand ça baisse — un β moyen le cache.

Le modèle d'évaluation. Carhart-4 au minimum (les facteurs sont en cache : `ff_factors.csv`), plus le panier sectoriel auto-répliquant $\omega_{s,t} = \sum_{i \in s} w_{i,t}$:

$$r_P^{\text{net}}(t) - r_f(t) = \alpha + \beta_M(r_M - r_f) + \beta_S \text{SMB} + \beta_H \text{HML} + \beta_U \text{MOM} + \beta_\Sigma (r^{\text{sect}}(t) - r_f(t)) + \varepsilon(t)$$

Inférence **Newey-West** $L = 21$. Et, si les tests ci-dessus rejettent la stabilité, l' α **conditionnel** de Ferson-Schadt (1996) — la réponse académique de référence à « β varie » :

$$r_{P,t+1} - r_f = \alpha + b_0(r_{M,t+1} - r_f) + b_1' [z_t \otimes (r_{M,t+1} - r_f)] + \varepsilon, \quad z_t = \text{états retardés (pente, VIX, dividend yield)}$$

$\rightarrow$ **ce que ça décide** : un α qui survit à Carhart+secteur+ β conditionnel est robuste ; sinon, on saura *exactement* quelle exposition le produisait.

C4 — Les comptes délégués — partitionner avant de mesurer

p. 40 : « **quand on délègue c’est notamment pour ne pas faire de l’inside trading. À supprimer de l’analyse assez rapidement** »

Le problème. owner est déclaré (Spouse 40 582 · SELF 34 268 · Dependent Child 20 837 · Joint 27 019 · ...) mais « délégué à un gérant » n’est **pas** un champ : il faut le construire.

Le score de délégation (toutes les colonnes existent déjà dans `membres.csv`) — un compte géré a une signature quantitative : rythme n_m /an très au-dessus de la médiane (Khanna $\sim 3\,700$ /an, McCaul $\sim 1\,600$ /an, contre Pelosi ~ 12 /an) · taille médiane collée à la borne basse (`pct_1re_fourchette`, 8 000 \$ = rebalancement automatique) · diversification extrême (`n_tickers` : 1 195 et 776, contre 38) · part non-élu $\approx 100\%$ (`part_self` : 2,3 % et 0,0 %).

$$\delta_m = \frac{1}{4} \sum_{v \in \{\text{rythme}, 1^{\text{re}} \text{ tranche}, n_{\text{tickers}}, 1 - \text{part_self}\}} \text{rang}_{\text{norm}}(v_m) \in [0, 1]$$

(moyenne de rangs normalisés — sans seuil arbitraire dans la *définition* ; le seuil est balayé, pas choisi).

Le test — trois périmètres emboîtés, et c’est lui qui vaut l’argument : $\mathcal{P}_0$ tous les trades (témoin) $\subset \mathcal{P}_1$ hors délégation présumée (δ_m au-dessus du quantile q , balayé) $\subset \mathcal{P}_2$ owner = SELF (34 268 lignes).

$$\text{Validité convergente : } \alpha(\mathcal{P}_0) < \alpha(\mathcal{P}_1) < \alpha(\mathcal{P}_2)$$

Si le signal est vraiment de l’information privée, il doit **se renforcer** quand on resserre. S’il s’affaiblit, ce qu’on capture n’est pas de l’information d’initié mais un effet de style ou de flux — et il faut le dire. Ce n’est pas cosmétique : **41,2 % des lignes** viennent de 2 membres dont $\sim 100\%$ en délégation.

→ **ce que ça décide** : une prédiction directionnelle *falsifiable*, bien plus forte qu’une exclusion décrétée.

C5 — La winsorisation — elle coupe peut-être le signal lui-même

p. 47 : « **avoir avec et sans winsor : s’il y a justement de l’inside trading, ça peut aussi être pour capturer ces micro-événements qui ont un gros impact** »

Le chef a raison sur le fond : $r_P \leftarrow \text{clip}(r_P, -50\%, +50\%)$ est un garde-fou anti-donnée-corrompue, mais il coupe **exactement** ce qu’un initié chercherait — le saut sur annonce (rachat, essai clinique, contrat).

Le remède : ne pas plafonner, mais valider le saut. Un $|r_i(t)| > 50\%$ est de deux natures, séparables par deux marqueurs indépendants (le volume est en cache, `volume_v1`) :

saut **vrai** : $V_i(t) > 3 \text{ med}_{63j}(V_i)$ et $\left| \sum_{u=t+1}^{t+5} r_i(u) \right| \ll |r_i(t)|$ (volume anormal, et le prix ne revient pas)

Le saut **infirmé** (pas de volume, prix qui revient) est corrigé et journalisé ; le saut validé est **gardé**.

Ce qu’on publie : α avec et sans winsorisation côte à côte, plus la quantité qui répond vraiment — $\Delta\alpha = \alpha_{\text{sans}} - \alpha_{\text{avec}}$ et le **nombre de jours concernés**. Si l’ α vit dans les jours coupés, ce n’est pas un détail de robustesse : c’est le résultat principal.

C6 — Le seuil $n_{\text{trades}} \geq 10$ — le remplacer, pas le déplacer

p. 52 : « **assumption à relax** »

Le défaut. Un seuil dur *jette* l’information des membres peu actifs, et il ne règle qu’imparfaitement le bruit qu’il vise : **les deux seuls $|t| > 2$ de la galerie sont Fetterman ($t\,2,38$) et Ruiz ($t\,2,40$), tous deux sur exactement 10 trades** — donc *au-dessus* du seuil. Le seuil ne les a pas arrêtés.

Le remède : le shrinkage bayésien, qui n’exclut personne.

$$\hat{\alpha}_m^{\text{shr}} = \omega_m \hat{\alpha}_m + (1 - \omega_m) \bar{\alpha}, \quad \omega_m = \frac{\tau^2}{\tau^2 + s_m^2}$$

s_m^2 = variance d’estimation de $\hat{\alpha}_m$ (grande si peu de trades), τ^2 = dispersion vraie entre membres (estimée en coupe, *empirical Bayes*). Un membre à 3 trades n’est plus exclu : il est **tiré vers la moyenne** à proportion de son imprécision. **L’argument décisif** : le shrinkage aurait *automatiquement* dégonflé Fetterman et Ruiz — sans qu’on ait à les écarter à la main, et sans perdre les membres peu actifs mais réguliers. On publie en complément le balayage $n_{\text{min}} \in \{1, 3, 5, 10, 20\}$ en entier (pas seulement le meilleur).

L’ordre d’exécution — et pourquoi il n’est pas commutatif

étape	ce qu'elle fixe pour la suite
É1 les périmètres (C4)	construire δ_m , figer $\mathcal{P}_0/\mathcal{P}_1/\mathcal{P}_2$ — <i>rien ne se mesure avant de savoir sur qui</i>
É2 les prix (C5)	valider les sauts, produire les séries avec/sans winsor — le moteur en dépend
É3 l'âge (C1)	α par tranche $\rightarrow$ <i>la forme du noyau ψ</i> et la demi-vie H^*
É4 l'asymétrie (C2)	$\bar{\gamma}^+, \bar{\gamma}^- \rightarrow \theta^*$: faut-il netter, et la jambe vente mérite-t-elle un portefeuille
É5 le moteur v2	rejouer la reconstruction avec ψ_{H^*} et θ^* <i>issus de É3-É4</i> , pas choisis
É6 le β (C3)	β_t^P bottom-up <i>ex-ante</i> , tests de rupture, couverture optionnelle
É7 l'évaluation	Carhart-4 + secteur, NW, α conditionnel — sur les 3 périmètres $\times$ avec/sans winsor
É8 le verdict	gates chiffrés, <i>écrits avant</i> , avec la multiplicité recomptée

Le piège à ne pas manquer. É3 et É4 *estiment* H^* et θ^* **sur les données**. Les réinjecter tels quels en É5 serait du data-mining, et le Deflated Sharpe le punira. Deux sorties, à choisir *avant* : soit on les estime en **walk-forward** (sur $\leq t$ seulement, comme K^*), soit on les fige sur une période d'apprentissage et on ne juge que sur le reste. **C'est la seule vraie difficulté du plan** — et la grille s'agrandissant, $E[\max t | H_0]$ monte : il faut le recompter, pas l'oublier.

Ce que ce plan ne dira toujours pas. Les **positions courtes et les options** (0,30 % des lignes) restent hors d'atteinte — or c'est là que la littérature trouve l'information (Molk & Partnoy) et là que vit l'écart Pelosi actions/dérivés. Les **coûts de transaction** ne sont pas dans le backtest membre. Et la **puissance** borne tout : $MDE \approx 4,6\%/an$ (House) à 80 % — un t faible *borne* ce qu'on peut voir, il ne prouve pas qu'il n'y a rien.