

Pipeline House — Transactions boursières des représentants

Volume 2 : années 2020→2026 — synthèse complète

25 juin 2026

1 Résultat à utiliser

Les tables finales.


- **Électronique (total)** — `data_v1/tables/{année}/06_house_{année}_transactions.csv` × 7 : **32 676 transactions** 2020→2026. Complètes, validées.
- **OCR (échantillon)** — `data_v1/tables/_ocr_echantillon_resultats.csv` : **4 103 transactions** sur 70 docs. Sert à mesurer la qualité de la méthode OCR, pas à remplacer le digital.

Table des matières

1	Résultat à utiliser	1
2	Vue d'ensemble	2
3	Électronique 2020→2026	2
4	OCR — census + échantillon	3
5	Validation contre QuiverQuant	3
6	Limites connues	4
7	Reproductibilité & fichiers	5

2 Vue d'ensemble

Le flux en un schéma



Les chiffres en un coup d'œil

Indicateur	Valeur
Période	2020 → 2026 (7 années)
Transactions électroniques (TOTAL)	32 676
Concordance Quiver (élec, transaction)	99,01 %
Trades vraiment absents (6 ans)	9
PDF scannés recensés	547 (clusters A / B / C : 74 / 322 / 151)
OCR : échantillon traité	70 docs (10/an)
transactions OCR	4 067
couverture ticker	80 %
concordance Quiver (deskew + tol. $\pm 3j$)	65,4 %

3 Électronique 2020→2026

Extraction texte (pdfplumber + regex), concordance mesurée par la **méthode honnête** « **standard Q1** » : dédup des amendements Quiver, exclusion des déposants papier des deux côtés, cross-check « ticker raté » vs « vraiment absent ». Reproduite par `notebook_digital.ipynb`.

Année	txns	déclarants	ticker %	concordance Quiver	vrais-absents
2020	6 886	96	91,0	99,71 %	0
2021	5 457	105	91,1	99,68 %	1
2022	3 601	97	86,8	98,88 %	0
2023	4 161	88	86,9	98,10 %	3
2024	2 694	90	81,8	98,01 %	2
2025	7 577	96	90,5	98,93 %	1
2026	2 300	79	84,0	98,64 %	2
Total	32 676	—	88,6	99,01 %	9

Les **9 vrais-absents** (sur 6 ans) sont tous expliqués : Malinowski (ANIK 2020), Schrader (VRNG/ELN/MSCI2022), Calhoun (AFRM/IBM 2024), Gottheimer (IFNNY 2025), Pelosi (INTC/UBER 2026). Causes : dépôt papier→OCR, snapshot post-dépôt, variante de date $\pm 1j$, étiquetage Quiver. Le reste de l'écart **only-Quiver** (≈ 232) = ticker raté (préférentielles DUK\$A, Trésor, fonds) — cosmétique.

Électronique = prêt. 32 676 transactions 2020→2026, concordance Quiver **99,01 %** ($\geq 98\%$ chaque année), **9 vrais-absents** sur 6 ans. Quiver n'est jamais réinjecté.

4 OCR — census + échantillon

Census complet des 547 PDF scannés

Cluster	docs	part	Profil OCR
A — tapé droit	74	13,5 %	le plus propre ; lecture directe
B — tapé tourné 90°	322	58,9 %	le gros du corpus ; lisible une fois redressé
C — manuscrit	151	27,6 %	le point dur ; concentré 2020–2021

543/547 sont le même formulaire officiel House. 81 % des scans sont tournés. 6 sont réellement illisibles.

Volumétrie de l'échantillon OCR

70 docs (10/an : 2 A / 6 B / 2 C ; 2026 = 8 A / 2 C faute de cluster B), **4 067 transactions** (echantillon_ocr.py : prompt durci + garde-fou date, **deskew par page**, cap 8 pages, cache dédié ocr_cache_echantillon/ versionné **deskew_v1**).

Champ	Couverture
Transactions totales	4 067
ticker (avec passe LLM)	3 266 / 4 067 = 80 %
explicit	174
elec_dict	2 235
llm	857
none (non-cotés : munis, obligations, options)	801

Deskew — redressement des scans tournés

525/547 scans sont couchés (rotated90/mixed/rotated180) avec `page.rotation=0` et canevas portrait : **aucun signal métadonnée**. L'ancien pipeline envoyait l'image *couchée* au modèle. On détecte désormais l'orientation par une pré-passe Vision « montage 4-rotations » (le modèle *choisit* l'image droite parmi les 4 angles — tâche de reconnaissance, fiable), **page par page** (les *mixed* ont des pages d'orientations différentes), puis on redresse géométriquement (PIL) *avant* extraction. Sur l'échantillon : 170 pages tournées, 90 déjà droites ; le détecteur discrimine correctement les 4 orientations (contrôle déjà-droite→0°, +180°→180°).

5 Validation contre QuiverQuant

Côté électronique

Voir tableau §3 : concordance $\geq 98\%$ sur chaque année, 99,01 % global. **0 cas** où Quiver a plus de transactions que nous.

Côté OCR — diff transaction par transaction

Chaque transaction avec ticker est classée (`_ocr_echantillon_diff.csv`, notebook_ocr.ipynb §4b). **Deux correctifs** vs version précédente : le **deskew** et une **tolérance de date $\pm 3j$** (Quiver bruite la date de $\pm 1-2j$; l'égalité stricte comptait ces écarts comme erreurs). Colonne `date_delta_days` = écart signé gradué.

Cluster	vérif.	match	date fausse	ticker absent	Q.	match %	(avant)
A — tapé droit	1 164	930	167		67	79,9 %	75,8
B — tapé tourné	1 916	1 196	528		192	62,4 %	54,2
C — manuscrit	173	2	125		46	1,2 %	0,6
Total	3 253	2 128	820		305	65,4 %	59,7

Lecture. Concordance globale **59,7 %** → **65,4 %** ; tous les clusters montent (B tourné +8 pts). Le deskew seul (à tolérance nulle) fait 59,7 % → 64,3 %. *Ticker absent Quiver* : 340 → **305** (le deskew lit mieux les noms). **Honnêteté** : le gain vient surtout d'une *extraction plus complète et de meilleurs tickers*, **pas** d'une meilleure lecture des dates — voir §5.

Concordance (ticker, date) par cluster et par année

Cluster	préc. ticker	préc. (ticker, date)	Année	préc. (ticker, date)
A — tapé droit	0,79	0,61	2020	0,54
B — tapé tourné	0,72	0,54	2021	0,45
C — manuscrit	0,83	0,02 *	2022	0,28
			2023	0,46
			2024	0,38
			2025	0,51
			2026	0,79

* Cluster C : Quiver quasi absent sur ces petits déposants → non vérifiable (et non un échec OCR).

La **précision ticker reste haute partout** (0,72–0,83 : on n'invente pas d'instrument). La précision (ticker, date) progresse mais **plafonne sur les vieux scans**. Mode d'échec résiduel dominant : la *confusion de chiffre d'année* (date lue à plusieurs années d'écart) — **5 % des lignes vérifiables, persistant MÊME après redressement**, donc *pas* un artefact de rotation. Le mode « date répliquée sur toutes les lignes » supposé auparavant est marginal (mesuré : 1 cas sur ~880). 2026 propre (0,79).

Audit de la passe LLM ticker (`_ocr_echantillon_diff.csv`)

Sur les **857 tickers LLM**, tous rapprochables d'un bioguide Quiver, concordance $\approx$ **83 %** (pilote 2025 : 93 %). L'écart de 10 pts s'explique par les membres absents de Quiver (trusts familiaux Harshbarger) et les tickers delistés (XLNX absorbé par AMD 2022, CTL rebrandé LUMN) — **aucun faux ticker LLM détecté**.

À retenir. Côté électronique : **0 cas** où Quiver a plus que nous ; 9 vrais-absents expliqués. Côté OCR : la **précision ticker est fiable** (0,72–0,83) ; concordance globale **65,4 %** après deskew + tolérance $\pm 3j$ (était 59,7 %). La **date** reste le point dur : *ambiguïté OCR intrinsèque*, pas la rotation.

6 Limites connues

- **OCR = échantillon, pas exhaustif.** Les 547 scannés ne sont *pas* tous extraits. Livrable OCR = 70 docs pour *mesurer* la qualité, pas fournir tous les trades papier.

- **Cluster C non vérifiable.** Quiver couvre quasi-aucun petit déposant manuscrit : prec. date 0,02 reflète l'absence de vérité-terrain, pas un échec OCR mesurable.
- **Dates = ambiguïté OCR intrinsèque, PAS un artefact de rotation.** Le deskew a été implémenté et testé : il améliore l'extraction et les tickers, mais **ne corrige pas les dates** — $\sim 5\%$ de confusion de chiffre d'année persistent sur images parfaitement droites. Le mode « date répliquée » suspecté auparavant est marginal (1 cas / ~ 880). Non corrigé heuristiquement pour ne pas masquer de vraies erreurs.
- **Tickers non-cotés laissés vides.** Munis, obligations, options, trusts privés : **ticker** null à dessein, jamais deviné.
- **Passé LLM ticker tributaire du crédit API.** Le re-run OCR redressé est complet (cache) ; la passe nom $\rightarrow$ ticker dépend du crédit/cache LLM — couverture obtenue 80 %.

7 Reproductibilité & fichiers

Dossier autonome : `.venv` local + kernel `jupyter-house-toutes-annees`, `.env` / `.env.example` / `requirements.txt` ; 547 PDF scannés + index + YAML + baseline + cache Quiver dans `data_v1/` ; moteurs `house_multiyear.py` / `house_ocr_multiyear.py` à la racine.

Deux notebooks (source de vérité) :

1. `notebook_digital.ipynb` — électronique total + concordance Quiver.
2. `notebook_ocr.ipynb` — census + aperçus A/B/C + OCR échantillon + diff Quiver (§ 4b–4d).

Fichier	Rôle
<code>tables/{an}/06_house_{an}_transactions.csv</code> $\times 7$	Tables digitales finales
<code>tables/_ocr_echantillon_resultats.csv</code> (4 067)	Transactions OCR échantillon (redressées)
<code>tables/_ocr_echantillon_diff.csv</code>	Diff Quiver par txn (+ <code>date_delta_days</code> , tol. $\pm 3j$)
<code>tables/_ocr_echantillon_quiver_doc.csv</code>	Concordance par doc
<code>tables/_scan_census_547.csv</code>	Census des 547 scannés
<code>ocr_cache/</code> & <code>ocr_cache_echantillon/</code>	Caches versionnés (re-run gratuit)

Message en une ligne. Électronique **complet** 2020 $\rightarrow$ 2026 : **32 676 transactions**, **99,01 %** concordance Quiver, 9 vrais-absents. OCR échantillon : **4 067 transactions**, ticker **80 %**, concordance Quiver **65,4 %** (deskew + tolérance $\pm 3j$; était 59,7 %). Point dur résiduel : lecture des **dates** = ambiguïté OCR intrinsèque ($\approx 5\%$ de confusion d'année même redressé), *pas* la rotation.