

Congress Trading Signal — Rapport complet

Extraction et validation des transactions boursières du Congrès américain
Chambre (House) et Sénat, électronique + OCR, 2020–2026

Pipeline congress_core + house + senate

26 juin 2026

Comment lire ce rapport

On suit le **déroulé réel du pipeline**, étape par étape, de l'acquisition des déclarations jusqu'aux métriques finales. À chaque étape : (a) à quoi elle sert, (b) comment elle marche, (c) le choix fait et **pourquoi** (souvent : un premier essai échoue → on ajoute une règle), (d) le résultat chiffré. **Chaque métrique est définie en langage simple avant d'être chiffrée**. On traite d'abord le **mécanisme partagé** (le cœur congress_core), puis les spécificités **House**, puis **Sénat**. Aucune connaissance préalable d'OCR ou de finance n'est supposée.

Chiffres clés (résumé exécutif)

House : FINAL **81 646** transactions = 32 676 électronique + 48 970 OCR. Identité **99,99 %** (256 BioGuideID, 275 noms). Concordance Quiver **85,9 %**. Ticker 85,3 %, secteur 83,2 %, **table 12/12 champs**. Vrais-absents : **9** sur 81 646.

Sénat : FINAL **8 841** = 7 161 électronique + 1 680 OCR papier. Identité **100 %** (64 BioGuideID, 67 noms). Concordance Quiver **98–100 %/an**, **0 vrai raté**. Ticker 71,4 %, secteur 62,1 %, **table 12/12 champs**.

Quiver = **vérification externe uniquement**, jamais réinjecté dans les tables. Verdict : **la donnée concorde bien** ; le papier (OCR) est validé en interne car aucun agrégateur ne le voit.

Table des matières

1	Vue d'ensemble et structure	2
1.1	Schéma du pipeline (colonne vertébrale chronologique)	2
1.2	Carte des dossiers	3
1.3	Convention de numérotation des tables	3
2	Acquisition des données	3
3	Identité : du nom au BioGuideID	3
4	Schéma et clé naturelle	4
5	Manifeste : lisible, non lisible, absent	4
6	Piste électronique (digital)	4


7	OCR : clusters, skew, Vision, normalisation	5
7.1	Les trois clusters et le pilote (House)	5
7.2	Skew : redresser avant de lire	5
7.3	Vision et normalisation	5
8	Résolution des tickers	5
9	Enrichissement secteur (GICS → ETF)	6
10	Fusion digital + OCR et volumes finaux	6
11	Validation Quiver — la méthode honnête	6
12	Métriques finales — chacune définie	7
12.1	date_confidence (House, lignes OCR)	8
12.2	Clusters OCR et concentration (House)	8
12.3	Statut de validation par déposant (crosscheck)	8
13	Reproductibilité (à zéro changement)	8
14	Limites et imperfections (honnêteté)	9
15	Synthèse et verdict	9

1 Vue d'ensemble et structure

Mission. Reconstituer, pour chaque membre du Congrès, ses *Periodic Transaction Reports* (PTR) — les achats/ventes de titres déclarés sous le *STOCK Act* — de 2020 à 2026, sur les deux chambres. But applicatif : alimenter une stratégie de *copy-trading*. Exigence transverse : la donnée doit être **traçable, reproductible et honnêtement validée**.

Deux pistes par chambre. Les déclarations existent en deux formes : **électronique** (PDF au texte sélectionnable, parsing déterministe) et **scannée** (image, traitée par OCR via un modèle de vision). Le pipeline traite les deux puis les fusionne.

1.1 Schéma du pipeline (colonne vertébrale chronologique)



Vert = logique **partagée** (`congress_core`) ; bleu = orchestration par chambre ; orange = spécificités House/Sénat. Le principe directeur : **le cœur tient la logique commune, chaque chambre n'orchestre que ses différences**.

1.2 Carte des dossiers

Dossier	Rôle
congress_core/	Cœur partagé (11 modules) : <code>schema</code> (clé naturelle), <code>identity</code> (bioguide), <code>tickers</code> , <code>amounts</code> , <code>vision_ocr</code> (deskew + Vision), <code>llm_resolve</code> (cache LLM), <code>quiver</code> (validation), <code>crosscheck</code> , <code>sector_enrich</code> , <code>reporting</code> , <code>paths</code> .
house/	Pipeline House : <code>digital.py</code> (électronique), <code>ocr.py</code> (scanné + fusion), <code>echantillon.py</code> (mesure).
senate/	Pipeline Sénat (miroir de House) : <code>digital</code> , <code>ocr</code> , <code>fusion</code> , <code>identity</code> , <code>ticker_resolve</code> , <code>quiver_audit</code> , <code>ocr_engine</code> (prompt français)...
data/	Données : <code>house/tables/{an}/</code> , <code>senate/{an}/</code> , <code>external/</code> (Kadua).
tests/regression/	Filet à zéro changement : <code>golden</code> (empreintes), preuves de reproduction, <code>audit_metrics.py</code> (recompute des métriques).
docs/	Ce rapport, <code>RAPPORT_HOUSE.pdf</code> , <code>REFONTE_HOUSE/SENATE.md</code> .

1.3 Convention de numérotation des tables

Chaque année produit une série numérotée, identique d'une chambre à l'autre :

03 index PTR	04 manifeste	05 échecs parsing	06 électronique
06b OCR	06_FINAL fusion	06c/06d QA / OCR↔Quiver	07/07c-07f validation Quiver
00_* tableaux de bord (statut annuel, statut FINAL).			

Quiver Quantitative (agrégateur commercial de trades du Congrès) sert **uniquement de vérification externe**. Il n'est *jamais* réinjecté dans nos tables : on s'en sert pour mesurer si notre extraction concorde, pas pour la compléter.

2 Acquisition des données

À quoi ça sert. Récupérer les déclarations à la source officielle, sans intermédiaire, de façon polie et reproductible (cache disque). **Anti-look-ahead** : on date chaque transaction par sa *date de divulgation* (`disclosure_date = FilingDate`), jamais par une date postérieure connue — une stratégie ne peut copier qu'après publication.

House — House Clerk. Un index XML par année (`{an}FD.xml`) liste les dépôts ; on filtre `FilingType=P` (les PTR) puis on télécharge le PDF de chaque dépôt. Source publique, sans barrière.

Sénat — eFD (*Electronic Financial Disclosure*). Plus fermé : un **piège CSRF**. Il faut d'abord accepter un formulaire d'accord (`accept_agreement` : GET pour obtenir un `csrftoken`, puis POST `prohibition_agreement` avec `csrfmiddlewaretoken` et l'en-tête `X-CSRFToken`). On interroge ensuite l'API de recherche (`report_types=[11] = PTR`). Les déclarations électroniques sont en **HTML** ; les déclarations papier renvoient des **images .gif** servies par `efd-media-public.senate.gov` (serveur public, hors barrière). *Choix & pourquoi* : on reste à poli à (pause entre requêtes, aucun contournement agressif) et on **cache tout sur disque** — un re-run ne re-télécharge rien.

3 Identité : du nom au BioGuideID

Définition — BioGuideID

Identifiant unique et stable d'un parlementaire (ex. P000197 = Nancy Pelosi). C'est la clé qui relie une transaction à une personne, son parti, son État, ses commissions — et qui **évite de compter deux fois la même personne** écrite de deux façons.

À quoi ça sert. Une déclaration donne un nom libre (ñ Hon. Earl L. Carter ž, ñ Buddy Carter ž). On doit le rattacher au bon BioGuideID. **Comment.** Le module `identity` charge le référentiel public `congress-legislators` (12 767 personnes, actuelles + historiques) et construit un *matcher* : normalisation (accents, casse), retrait des suffixes (Jr./III), table de **36 surnoms**, gestion des seconds prénoms, et quelques **overrides manuels** pour les cas irréductibles (ñ Van Taylor ž, ñ JD Vance ž). **Désambiguïsation** : à nom égal, on privilégie la bonne chambre puis le titulaire en exercice. Les **délégués** (non-votants) sont exclus côté Sénat pour ne pas créer de faux ñ présents chez Quiver, absents chez nous ž.

Résultats. House : **99,99 %** des lignes ont un BioGuideID — 4 lignes seulement n'en ont pas (ñ Ada Norah Henriquez ž, un document manuscrit de 2023, doc 8219483). Sénat : **100 %** (0 manquant).

4 Schéma et clé naturelle

Définition — clé naturelle (`natural_key_hash`)

Empreinte SHA-256 de 7 champs : `chambre | declarant_name | transaction_date | asset_description | operation_type | amount_range | owner`. **Sans le ticker** : le symbole boursier est enrichi *après*, donc l'inclure rendrait la clé instable. Deux lignes identiques sur ces 7 champs sont ñ la même transaction ž.

Le piège de la déduplication. Un même PTR liste parfois *légitimement* plusieurs lots identiques le même jour (ex. trois ventes du même titre via trois comptes). Dédupliquer sur la seule clé naturelle les écraserait. **Solution** : `occurrence_index = cumcount(doc_id, natural_key_hash)` numérote ces répétitions *intra-document* ; la déduplication se fait sur le couple (`natural_key_hash`, `occurrence_index`). Elle est donc **non destructrice** : elle retire les vrais doublons *entre* documents (amendements re-déposés) mais **préserve les lots multi-comptes réels** — concrètement, **2 425 lignes du déposant Khanna** qui auraient sauté avec une dedup naïve.

Table FINALE : 27 colonnes pour les deux chambres (identité, dates, ticker, secteur, montant, *owner*, provenance, clés...). L'ordre des colonnes diffère légèrement entre House et Sénat, mais le **contenu garanti est le même : 12/12 champs**.

5 Manifeste : lisible, non lisible, absent

Critère exact

Pour chaque PDF, `pdfplumber.extract_text()` ; puis `bool(text.strip())`. Vrai $\Rightarrow$ **lisible** (couche texte $\Rightarrow$ parsing déterministe). Faux $\Rightarrow$ **non lisible** (scan image $\Rightarrow$ OCR). Fichier introuvable $\Rightarrow$ **absent**.

Ce tri **pilote tout le reste** : un PDF lisible part en piste électronique, un scan part en OCR. C'est un test binaire simple, pas une heuristique floue — d'où sa fiabilité.

6 Piste électronique (digital)

Comment. `parse_ptr` lit la couche texte et extrait, par expressions régulières, chaque ligne : type d'opération (P/S/E = Achat/Vente/Échange), date, description d'actif, fourchette de montant, propriétaire. Rendement très élevé (99–100 % des lignes parsées ; les rares échecs sont tracés dans `05_parse_failures`).

Volumes électroniques. House : **32 676** transactions. Sénat : **7 161**. (Détail par année dans les tableaux ğ10.)

7 OCR : clusters, deskew, Vision, normalisation

7.1 Les trois clusters et le pilote (House)

Les scans House se répartissent en trois familles, qu'on a caractérisées sur le **census des 547 PDF scannés** :

- **A** — **tapé droit** (74 docs) : machine, bien orienté. Facile.
- **B** — **tapé tourné** (322 docs) : machine, mais l'image est *couchée*. Gros volume.
- **C** — **manuscrit** (151 docs) : écrit à la main. Lecture des dates peu fiable.

Pourquoi un pilote d'abord ? Avant le run complet, on a OCR-isé un **échantillon stratifié** des trois clusters (echantillon.py, prompt durci, tolérance de date $\pm 3j$) pour *comprendre* les modes d'échec et adapter le prompt. **Décision** : le **cluster C est exclu par défaut** (ses dates manuscrites sont trop incertaines pour une stratégie datée), avec **recupération ciblée** de 3 déposants à fort enjeu. Côté Sénat, pas de clusters : seulement **5 sénateurs** déposent sur papier.

7.2 Deskew : redresser avant de lire

Problème. Les scans du cluster B sont couchés ; un modèle de vision lit mal une page tournée. **Première idée écartée** : demander au modèle *n* de combien faut-il tourner ? *z* — tâche spatiale peu fiable (il répond presque toujours *n* 90 *z*). **Solution retenue** : on lui montre la page aux **4 orientations** (ROT_CANDIDATES = [0, 90, 180, 270]) en basse résolution et il *reconnaît* laquelle est droite — une tâche de reconnaissance, bien plus robuste — puis on redresse géométriquement (PIL) avant l'extraction. **Avant/après** : la concordance OCR passe de **59,7 % à 69,0 %**.

7.3 Vision et *n* normalize *z*

Vision. Modèle claude-sonnet-4-6, tool_choice *forcé* sur l'outil record_transactions (le modèle *doit* répondre en JSON structuré), max_tokens 16 000, 7 tentatives, **cache versionné par PROMPT_SHA** (re-run = 0 appel si le prompt n'a pas changé), reprise au batch. Garde-fous du prompt : ignorer la **ligne-exemple** pré-imprimée du formulaire, et borner l'année lue à l'année de dépôt.

Définition — *n* normalize *z*

Mise au format commun des lignes brutes OCR : fourchette de montant lettrée (A-K) $\rightarrow$ intervalle \$ et **milieu** (ex. B $\rightarrow$ *n* \$15 001–\$50 000 *z*, milieu 32 500) ; propriétaire ; et un drapeau date_confidence (voir §12).

Volumes OCR. House : **48 970**. Sénat : **1 680** (papier).

8 Résolution des tickers

Définition — couverture ticker

Part des lignes pour lesquelles on a identifié un symbole boursier (AAPL...). Les actifs *non cotés* (obligations, munis, fonds privés) restent **none à dessein**.

Trois voies, ajoutées par échecs successifs : **(1) explicite** (le symbole est écrit dans la description) ; **(2) dictionnaire électronique** (on propage les symboles vus dans l'électronique vers le papier qui ne les imprime pas) ; **(3) passe LLM** (claude-sonnet-4-6, filtre is_equity, cache versionné) pour le reliquat. **Pourquoi le LLM ?** Le dictionnaire seul plafonne ($\sim 46\%$) ; le LLM le porte à $\sim 90\%$.

Résultats. House **85,3 %**. Sénat **71,4 %** : son reliquat est surtout des *munis/Treasuries* de Blumenthal — non cotés, donc **none légitimement**, pas une perte.

9 Enrichissement secteur (GICS → ETF)

À quoi ça sert. Donner à chaque ligne tickée un **secteur** (classification GICS) et un **ETF sectoriel** de référence (SPDR Select Sector), pour une exposition par secteur. **Comment.** yfinance (factuel) en source primaire, **repli LLM** pour les tickers délistés/introuvables, cache versionné. Mapping 1 :1 des 11 secteurs :

Energy XLE ù Materials XLB ù Industrials XLI ù Cons. Disc. XLY ù Cons. Staples XLP ù Health Care XLV ù Financials XLF ù IT XLK ù Comm. Services XLC ù Utilities XLU ù Real Estate XLRE.

Résultats. House **83,2 %** (67 932/81 646). Sénat **62,1 %** (le Sénat tient plus d'obligations, non sectorisables). Les deux chambres atteignent ainsi la **table 12/12 champs**.

10 Fusion digital + OCR et volumes finaux

Comment. On concatène électronique + OCR puis on déduplique sur (natural_key_hash, occurrence_index). House : **405 doublons cross-document** (amendements re-dépôtés) retirés, sans toucher aux lots multi-comptes. Sénat : 0.

Pourquoi plus d'OCR que de digital côté House (l'inverse au Sénat) ? C'est **normal** : côté House, quelques très gros déposants déclarent exclusivement sur *papier* (Khanna domine l'OCR), donc le volume scanné dépasse l'électronique. Au Sénat, le papier est marginal (5 sénateurs) : l'électronique domine largement.

House — volumes par année						Sénat — volumes par année				
An	Digital	OCR	FINAL	dépôts	sans bio	An	Dig.	OCR	FINAL	sén.
2020	6 886	8 791	15 677	109	0	2020	1 706	255	1 961	33
2021	5 457	6 816	12 273	120	0	2021	1 098	281	1 379	35
2022	3 601	10 900	14 501	110	0	2022	919	182	1 101	27
2023	4 161	6 329	10 490	100	4	2023	1 062	97	1 159	30
2024	2 694	6 277	8 971	97	0	2024	946	84	1 030	24
2025	7 577	6 067	13 644	107	0	2025	943	478	1 421	31
2026	2 300	3 790	6 090	84	0	2026	487	303	790	22
Total	32 676	48 970	81 646	256 uniq.	4	Total	7 161	1 680	8 841	64

Note. La somme des déposants par an (727 House) dépasse 256 : un même déposant réapparaît plusieurs années ; **256** est le nombre de BioGuideID *uniques* sur 7 ans (275 noms distincts, la différence venant de variantes orthographiques rattachées au même identifiant).

Sénat — répartition du papier. L'OCR Sénat est concentré : Blumenthal ~1 233 lignes (≈73 %), Boozman ~379, Burr ~52, Feinstein ~47, Fetterman ~2.

11 Validation Quiver — la méthode honnête

On compare notre FINAL à Quiver sur **deux axes**, sans jamais réinjecter Quiver :

Les deux axes

(1) **Comptes par déposant** (per-lot) : combien de lignes chez nous vs chez Quiver, par personne. (2) **Recouvrement transaction-niveau** : part des transactions Quiver qu'on retrouve, via la clé bioguide | ticker | date | type. **Couverture** = transactions Quiver retrouvées / total Quiver. La date appariée est le *Traded* de Quiver (la date de trade), pas le *Filed* (date de dépôt, qui n'apparie que ~1 %).

House — concordance Quiver par année					
An	couv. %	sens %	montant %	nous $\geq$ Q / nous $<$ Q	déficits $>$ 30
2020	85,0	94,6	89,0	103 / 6	0
2021	88,6	94,4	90,1	115 / 5	1
2022	80,7	88,8	89,1	108 / 2	0
2023	81,0	94,1	93,8	98 / 3	0
2024	85,8	92,2	94,0	96 / 1	0
2025	91,3	93,8	98,6	104 / 3	0
2026	88,0	95,8	98,4	81 / 3	0
Global	85,9	~93	~93	—	2

Sénat. Couverture digitale **98–100 %**/an, accord de sens $\sim 95,7\%$, date (Traded) $\sim 99,4\%$, montant $\sim 93,2\%$. **554 amendements** Quiver dédupliqués (un trade re-déposé apparaît plusieurs fois chez Quiver). 25 `only_quiver` (tickers composites / transitions de chambre). **0 vrai raté** (audit adversarial relisant les PTR bruts).

Le papier se valide hors Quiver. Quiver — comme Kadoa et House Stock Watcher — **ne voit aucun scan** : 0 ligne pour les gros déposants-papier (Khanna, Harshbarger, Blumenthal). Notre OCR est donc la **source unique** de ces données; on les valide en interne (cohérence, stabilité run-à-run, `date_confidence`).

12 Métriques finales — chacune définie

Couverture (Quiver)

part des transactions Quiver retrouvées. House **85,9 %**; Sénat **98–100 %**/an.

Accord de sens

sur les transactions appariées, part où le type (achat/vente) coïncide : House **~93 %**, Sénat **~95,7 %**.

Accord de montant

part où la fourchette coïncide : **~93 %** (deux chambres).

`only_ours` / `only_quiver`

transactions chez nous mais pas chez Quiver (et inverse). House `only_ours` = **16 166** = le **papier que Quiver ne voit pas** (ce n'est pas une erreur, c'est notre valeur ajoutée).

Vrais-absents

transactions Quiver réellement manquantes chez nous, *après* avoir expliqué les artefacts. House : **248 bruts** $\rightarrow$ **9 réels** (voir ci-dessous). Sénat : **0**.

Identité / ticker / secteur

House 99,99 / 85,3 / 83,2 %; Sénat 100 / 71,4 / 62,1 %.

`date_confidence`

drapeau *plausible/implausible* selon la fenêtre légale de 75 jours entre transaction et dépôt (voir tableau).

Les 9 vrais-absents House (décomposition). 2021 Malinowski $\times 1$ (date ± 1 j); 2023 Schrader $\times 3$ (papier, cluster C exclu); 2024 $\acute{n}$ Calhoun $\acute{z}$ $\times 2$ (étiquetage Quiver de J. James); 2025 Gottheimer $\times 1$ (déposé après notre snapshot); 2026 Pelosi $\times 2$ (idem). **Aucun bug d'extraction.** Le reste des 248 = artefacts (tickers Quiver, amendements, dates ± 1 j, obligations/options).

Le $\acute{n}$ verdict 35–74 % $\acute{z}$ expliqué. On lit parfois que la couverture est $\acute{n}$ 35–74 % $\acute{z}$: c'est la couverture Quiver du **numérique seul**, par année. La fourchette est large car la *part de déposants-papier* varie fortement d'une année à l'autre (et le papier, Quiver ne le voit pas). Ce **n'est pas** un verdict de qualité sur le FINAL : avec l'OCR, le FINAL monte à **81–91 %** (85,9 % global).

12.1 date_confidence (House, lignes OCR)

An	n OCR	plausible %	implausible
2020	8 791	98,6	120
2021	6 816	79,6	1 389
2022	10 900	96,4	394
2023	6 329	99,2	50
2024	6 277	96,5	220
2025	6 067	98,1	118
2026	3 790	100,0	0
Total	48 970	95,3	2 291

Le **pic 2021** (79,6 %) est entièrement Diana Harshbarger : **1 389 lignes implausibles sur 2 documents** manuscrits denses. Anomalie **localisée**, non systémique — une ambiguïté de lecture des chiffres manuscrits, pas un défaut de pipeline. (*Le digital ne porte pas ce drapeau ; le 95,3 % est donc le taux sur les seules lignes OCR.*) Côté Sénat (OCR) : plausible 1 654 (**98,5 %**), implausible 18 (le lot Perdue 2021 = divulgations tardives *réelles*).

12.2 Clusters OCR et concentration (House)

Cluster	docs census	docs avec txns	txns	ticker %	plausible %
A (tapé droit)	74	59	5 957	84,2	99,6
B (tapé tourné)	322	295	42 151	82,8	94,7
C (manuscrit)	151	81	862	88,4	97,4

B représente **86 %** du volume OCR. **Concentration** par déposant : Khanna **63,0 %**, McCaul 22,2 %, Harshbarger 7,2 % (top 3 = 92,4 % ; top 10 = 99,0 %).

12.3 Statut de validation par déposant (crosscheck)

Statut	dépôts	transactions	dont OCR
quiver_validable	212	78 530	47 004
ocr_unique (source unique)	13	1 957	1 949
digital	31	1 155	13

Les 13 déposants ocr_unique : Quiver = 0, OCR $\geq 50\%$ $\Rightarrow$ notre OCR est la **seule source** (matériels : David P. Roe 1 686 ; Francis Rooney 189).

13 Reproductibilité (à zéro changement z)

Le pipeline n'est **pas re-jouable hors-ligne** (le scraping exige le réseau ; seuls les artefacts figés sont embarqués). On prouve donc la correction par **reproduction depuis les colonnes figées** :

- **Golden** : empreintes sha256 de toutes les sorties — House **108** fichiers, Sénat **68**. `check_golden / senate_check_golden` : **zéro écart**.
- **Preuves de reproduction** : `test_senate_repro` reconstruit, depuis les seules colonnes figées, `natural_key_hash` **8 841/8 841**, l'identité **67/67**, le ticker **65/65**. Idem côté House (clé, montant, type d'actif, bioguide).
- `audit_metrics.py` : recompute toutes les métriques des deux chambres et *asserte* les invariants (totaux, identité, déposants). **C'est la source de vérité chiffrée de ce rapport**.

14 Limites et imperfections (honnêteté)

- **Validation papier externe impossible** : aucun agrégateur ne voit les scans $\Rightarrow$ pas de taux d'exactitude *externe* sur le papier (seulement des contrôles internes).
- **Cluster C manuscrit exclu par défaut** : dates trop incertaines ; récupération seulement ciblée. Choix assumé, pas une lacune cachée.
- **Dates Harshbarger 2021** : ambiguïté de lecture *intrinsèque* au manuscrit, non corrigeable par re-OCR ; signalée par `date_confidence`.
- **Comités non $\dot{\text{a}}$ point-in-time $\dot{\text{z}}$** : l'appartenance aux commissions est un *snapshot* actuel, pas l'historique daté — un croisement $\dot{\text{a}}$ conflit d'intérêt à la date du trade $\dot{\text{z}}$ serait donc approximatif.
- **Pas de tolérance de date dans l'appariement House** (clé sur date brute) : la couverture 85,9 % est un **plancher** (elle sous-estime sur les dates OCR bruitées).
- `asset_type` rempli à **91,1 %** ; `only_quiver` non décomposé automatiquement ; `date_confidence` = heuristique binaire (fenêtre 75 j), pas une vérité-terrain.

15 Synthèse et verdict

La donnée concorde bien. Sur deux chambres et sept ans, 90 487 transactions (81 646 House + 8 841 Sénat) sont extraites, identifiées (99,99 / 100 %), enrichies (**table 12/12** des deux côtés) et honnêtement validées (Quiver 85,9 % House, 98–100 % Sénat, **9 et 0** vrais-absents). Le papier — invisible aux agrégateurs — est une **valeur ajoutée** propre, validée en interne.

Fait / différé.

- **fait** : acquisition + identité + électronique + OCR complet (deskew, Vision, cache) + tickers + **secteur (12/12 sur les deux chambres)** + fusion + validation Quiver + filet de reproduction.
- **fait** : restructuration en cœur partagé `congress_core` + packages `house/senate`, données `data/`, une seule version propre.
- **différé** : cluster C manuscrit (qualité dates) ; comités point-in-time ; tolérance de date dans l'appariement House ; **stratégie + backtest** (hors périmètre $\dot{\text{a}}$ données $\dot{\text{z}}$).

Tous les chiffres de ce rapport sont recalculés par `tests/regression/audit_metrics.py` et figés par le golden (`check_golden`). Quiver = vérification externe, jamais réinjecté.