

Phase House — Rapport de données

Congress Trading Signal : pipeline électronique + OCR, 2020–2026

Pipeline `congress_core` + `house` (branche `refonte/house-core`)

26 juin 2026

Chiffres clés

FINAL = 81 646 transactions = 32 676 électronique + 48 970 OCR. 256 bioguides (275 noms distincts), identité **99,99 %**.

Concordance Quiver (FINAL) : **85,9 %** (81–91 %/an). Accord sens **93 %**, montant **93 %**.

Vrais-absents Quiver, après explication : **9 transactions sur 81 646**. Table **12/12 champs** : ticker **85,3 %**, secteur GICS→ETF **83,2 %**.

Verdict : **la donnée concorde bien**.

Table des matières

1	Résumé exécutif	2
2	Objectif et périmètre	2
3	Architecture et structure	2
3.1	<code>congress_core/</code> — le cur partagé (12 modules)	2
3.2	<code>house/</code> — pipeline House	3
3.3	<code>data/house/</code> et numérotation des tables	3
3.4	<code>tests/regression/</code> et docs/	4
4	Pipeline étape par étape	4
4.1	Piste électronique (<code>house/digital.py</code>)	4
4.2	Piste OCR (<code>house/ocr.py</code>)	4
5	Résultats et métriques	4
5.1	Volumes	4
5.2	Concordance Quiver (FINAL contre Quiver)	5
5.3	Identité, ticker, dates	5
5.4	Clusters OCR et concentration	5
5.5	Statut de validation par déposant (<code>crosscheck</code>)	6
6	Validation : concorde-t-on bien ?	6

7	Décisions et justifications	6
8	Fait / Pas fait / Différé	7
9	Limites et métriques manquantes	7
10	Reproductibilité	7
11	Annexes	8
11.1	Carte des fichiers	8
11.2	Glossaire	8

1 Résumé exécutif

La phase House est terminée. On extrait les déclarations boursières (PTR, STOCK Act) des membres de la Chambre des représentants, 2020–2026. Deux pistes : **électronique** (PDF lisibles, parsing déterministe) et **OCR** (PDF scannés, Claude Vision). Le résultat est une table unique de **81 646 transactions**.

Quiver Quantitative sert de vérification externe, jamais de source. La concordance FINAL contre Quiver est de **85,9 %** au niveau transaction. Le numérique seul plafonne à 35–74 % : c’est l’OCR qui ferme l’écart. Après explication des artefacts (tickers Quiver, amendements, dates ± 1 j), seules **9 transactions** sur 81 646 sont réellement absentes. L’identité (BioGuideID) est à **99,99 %**. Le code est factorisé dans un cur partagé `congress_core` réutilisable par le Sénat, avec un filet de non-régression de 108 fichiers.

2 Objectif et périmètre

But. Construire une stratégie de *copy-trading* répliquant les transactions déclarées par le Congrès, puis la backtester. Le présent rapport couvre la **couche données House**.

Sources. Primaire : House Clerk (`disclosures-clerk.house.gov`, index XML + PDF). Vérification : Quiver (licence R&D, jamais réinjecté). Référentiel identité : `unitedstates/congress-legislators`.

Périmètre. House, 2020–2026, électronique *et* scanné. `disclosure_date` = *FilingDate* de l’index (anti look-ahead). Hors périmètre : Sénat (à venir), stratégie et backtest.

Plafond de complétude annoncé. ŕ Êre électronique niveau Member, complète et vérifiée ; OCR des scans tapés (clusters A+B) complet ; manuscrit (C) récupéré de façon ciblée ; chaque exclusion comptée et expliquée. ž

3 Architecture et structure

Deux structures coexistent. La **refonte** (objet du rapport) : `congress_core/` + `house/` + données sous `data/house/`. L’ancien 0 `HOUSE/2025_test/` reste le pilote figé de référence. La refonte est un refactor ŕ **zéro changement de résultat ž** : même logique, mêmes chiffres, factorisés dans un cur partagé.

3.1 `congress_core/` — le cur partagé (12 modules)

Module	Rôle et symboles publics clés
--------	-------------------------------

<code>paths.py</code>	Bootstrap chemins + secrets (source unique). <code>find_base_dir</code> , <code>load_env</code> , <code>get_secret</code> , classe <code>DataRoot</code> .
<code>identity.py</code> ★	Priorité #1 : Doc ID → bioguide. Classe <code>Reference</code> , <code>load_reference</code> , <code>make_matcher</code> , <code>enrich_identity</code> , <code>split_name</code> . Surnoms, suffixes, override Van Taylor.
<code>schema.py</code>	Schéma canonique + clé naturelle 7 champs + dédup per-lot. <code>natural_key_hash</code> , <code>add_occurrence_index</code> , <code>dedup_canonical</code> , <code>CORE_FIELDS</code> (12).
<code>amounts.py</code>	Montants/owner/opération par chambre. <code>AMOUNT_MAP[chamber]</code> , <code>OWNER_MAP[chamber]</code> , <code>amount_midpoint</code> , <code>operation_type_from_code</code> .
<code>tickers.py</code>	Normalisation/récupération ticker + type d'actif. <code>recover_ticker</code> , <code>explicit_ticker</code> , <code>norm_asset</code> , <code>infer_asset_type</code> .
<code>quiver.py</code>	Vérification externe. <code>fetch_quiver</code> , <code>validate_quiver_house</code> (clé House brute), <code>reconcile</code> (audit champs).
<code>crosscheck.py</code>	Statut de validation par déposant. <code>per_filer_status</code> , <code>load_kadoa_house</code> , <code>load_hsw_counts</code> , <code>summary</code> .
<code>vision_ocr.py</code>	Moteur OCR Vision. Classe <code>VisionExtractor</code> (<code>prompt_sha</code> , cache versionné), <code>deskew</code> (<code>detect_rotation</code> , montage 4-rotations).
<code>llm_resolve.py</code>	Résolveur LLM à cache versionné. <code>VersionedLLMCache</code> , <code>map_batch</code> , <code>resolve_names_to_tickers</code> .
<code>sector_enrich.py</code>	Ticker → GICS → ETF SPDR. <code>enrich_sectors</code> , <code>GICS_TO_ETF</code> , hybride yfinance + LLM.
<code>reporting.py</code>	Sorties partagées. <code>TABLE_NUMBERING</code> , <code>qa_flags</code> , <code>write_excel</code> , <code>upsert_status</code> .

3.2 house/ — pipeline House

- `digital.py` : piste électronique (parsing `pdfplumber`+regex, identité, dédup, Quiver, backlog OCR).
- `ocr.py` : piste OCR (Vision, skew, cache, passe LLM ticker, politique cluster, fusion digital+OCR).
- `echantillon.py` : harnais de mesure (échantillon stratifié, prompt durci, tolérance date $\pm 3j$).
- `notebooks/notebook_house.ipynb` : notebook final exécuté (démonstration).

Tout ce qui est partageable est **délégué au cur** ; `house/` ne garde que l'orchestration.

3.3 data/house/ et numérotation des tables

Sous-dossiers : `tables/` (par année), `pdfs/` (547 PDF scannés embarqués), `index/` (`{an}FD.xml`), `reference/` (YAML législateurs/comités), `ocr_cache/` (546 JSON versionnés), `ocr_cache_echantillon/` (70 JSON).

Nř	Table	Nř	Table
01	référentiel législateurs	06c	qa_flags / ocr_failures
02	membres commissions clés	06d	OCR vs Quiver
03	index PTR (03_ptr_index)	07	Quiver comparison (FINAL)
04	manifest (lisible/non/absent)	07b	truly_absent (résidu curé)
05	échecs de parsing	08	cross-check baseline
06	transactions digital ; 06_FINAL = digital+OCR	00	dashboards / 00_concordance_finale
06b	transactions OCR		

3.4 tests/regression/ et docs/

Filet n  zero changement   : `golden_manifest.json` (108 fichiers empreint s sha256), `check_golden.py` (assertion centrale), et les preuves `test_schema/amounts_tickers/ identity/vision_sha/crosscheck.py`. Docs : `REFONTE_HOUSE.md` (architecture), `SYNTHESE_house_detail.md` (synth se d taill e). Pilote fig  : 0 HOUSE/2025_test/ (Q1 2025, 2 272 txns, table 12/12 champs avec `sector_gics/etf_proxy`).

4 Pipeline  tape par  tape

4.1 Piste  lectronique (`house/digital.py`)

1. **R f rentiel** : `build_reference` (d l gu  au cur) $\rightarrow$ 12 767 l gislateurs.
2. **Index** : `load_ptr_index` filtre `FilingType=P` + fen tre $\rightarrow$ `03_ptr_index`.
3. **Manifest** : `build_manifest` route lisible/non_lisible/absent $\rightarrow$ `04_download_manifest`.
4. **Parsing** : `parse_ptr` (regex marqueurs) ;  checs $\rightarrow$ `05_parse_failures`. Rendement 99–100 %.
5. **Identit ** : `join_identity` $\rightarrow$ bioguide, parti, commissions.
6. **Finalize** : `natural_key_hash` + `occurrence_index` (d dup per-lot) $\rightarrow$ `06_transactions` (digital). **32 676 txns**.
7. **Cross-check** baseline $\rightarrow$ 08. **Quiver** : `validate_quiver_house` $\rightarrow$ 07 + 07b.

4.2 Piste OCR (`house/ocr.py`)

1. **S lection** : scann s (`non_lisible`) $\cap$ census. Cluster C exclu par d faut (sauf 3 filers cibl s).
2. **Deskew** : pr -passe Vision n  montage 4-rotations  , page par page, redressement PIL.
3. **Vision** : Claude `sonnet-4-6`, `tool_use` for  , cache versionn  (`PROMPT_SHA`, reprise au batch).
4. **Normalize** : montant A–K, owner, `date_confidence` (fen tre l gale 75 j), filtre ligne-exemple.
5. **Ticker** : explicit $\rightarrow$ dict  lectronique $\rightarrow$ passe LLM (cache global). $\rightarrow$ **06b. 48 970 txns**.
6. **Fusion** : digital + OCR, d dup inter-sources (collision hash) $\rightarrow$ **06_FINAL. 81 646 txns**.
7. **Quiver OCR** : `validate_ocr_quiver` $\rightarrow$ 06d.

5 R sultats et m triques

5.1 Volumes

Ann�e	Digital	OCR	FINAL	D�posants	Sans bioguide
2020	6 886	8 791	15 677	109	0
2021	5 457	6 816	12 273	120	0
2022	3 601	10 900	14 501	110	0
2023	4 161	6 329	10 490	100	4
2024	2 694	6 277	8 971	97	0
2025	7 577	6 067	13 644	107	0
2026	2 300	3 790	6 090	84	0
Total	32 676	48 970	81 646	256 uniques	4

FINAL = digital + OCR apr s **d dup non destructrice** (cl  (`nk`, `occ`)) : 405 doublons cross-doc (r -d clarations / amendements) retir s, les **2 425** lignes multi-trust Khanna r elles **pr serv es** (parit  S nat ; cf. d cision 16). 4 lignes sans bioguide = un seul d posant manuscrit (  Ada Norah Henriquez  , 2023, doc 8219483).

5.2 Concordance Quiver (FINAL contre Quiver)

Année	cov %	accord sens %	accord montant %	nous $\geq$ Q / nous $<$ Q	déficits $>$ 30
2020	85,0	94,6	89,0	103 / 6	0
2021	88,6	94,4	90,1	115 / 5	1
2022	80,7	88,8	89,1	108 / 2	0
2023	81,0	94,1	93,8	98 / 3	0
2024	85,8	92,2	94,0	96 / 1	0
2025	91,3	93,8	98,6	104 / 3	0
2026	88,0	95,8	98,4	81 / 3	0
Global	85,9	~93	~93	—	2

Clé d'appariement House : `bioguide|ticker|date|type[:4]`, date brute. Le numérique seul couvre 35–74 %/an ; l'OCR fait monter à 81–91 %. `only_ours` global = 16 166 transactions : c'est le papier que Quiver ne voit pas (attendu). La date appariée est le *Traded* de Quiver (Filed $\approx$ 1 %), ce qui confirme le bon mappage.

Vrais-absents. Brut : 248 transactions $\hat{=}$ only-Quiver $\hat{=}$ pour déclarants sans papier (inclut artefacts ticker Quiver, amendements, dates ± 1 j). Après explication, **9 réellement absentes** sur 81 646 : 2021 Malinowski ($\times 1$, date ± 1 j), 2023 Schrader ($\times 3$, papier), 2024 $\hat{=}$ Calhoun $\hat{=}$ ($\times 2$, étiquetage Quiver J. James), 2025 Gottheimer ($\times 1$, post-snapshot), 2026 Pelosi ($\times 2$, dépôt post-snapshot). Aucun bug d'extraction.

5.3 Identité, ticker, dates

Identité : 99,99 % des lignes ont un BioGuideID (4 manquantes, un déposant manuscrit).

Ticker : 85,3 % global (point bas 2023 : 78,8 %). Sur OCR (06b), sources : `explicit`, `elec_dict` (dictionnaire électronique), `11m` (passe nom $\rightarrow$ ticker), `none`. La passe LLM apporte le gros volume (ex. 2022 : 4 383 11m). Les ~ 15 % restants sont des actifs non cotés (obligations, options, fonds, munis) : null à dessein.

Dates (`date_confidence`).

Année	n OCR	plausible %	implausible
2020	8 791	98,6	120
2021	6 816	79,6	1 389
2022	10 900	96,4	394
2023	6 329	99,2	50
2024	6 277	96,5	220
2025	6 067	98,1	118
2026	3 790	100,0	0
Total	48 970	95,3	2 291

Le pic 2021 est localisé : Diana Harshbarger porte l'essentiel des **1 389** implausibles, sur 2 documents. Problème d'un déposant manuscrit dense, pas systémique.

5.4 Clusters OCR et concentration

Census des 547 PDF scannés : A (tapé droit) 74, B (tapé tourné) 322, C (manuscrit) 151.

Cluster	docs census	docs avec txns	txns	ticker %	date plausible %
A (tapé droit)	74	59	5 957	84,2	99,6
B (tapé tourné)	322	295	42 151	82,8	94,7
C (manuscrit)	151	81	862	88,4	97,4

B porte 86 % du volume OCR. C est le point dur : 151 docs au census mais 81 produisent des transactions (862 au total), faible rendement (manuscrit).

Concentration. L'OCR est dominé par quelques déposants : Khanna **63,0 %**, McCaul 22,2 %, Harshbarger 7,2 % (top 3 = 92,4 % ; top 10 = 99,0 %).

5.5 Statut de validation par déposant (crosscheck)

Statut	déposants	transactions	dont OCR
quiver_validable	212	78 530	47 004
ocr_unique (source unique)	13	1 957	1 949
digital	31	1 155	13

13 déposants `ocr_unique` : Quiver=0, $\text{OCR} \geq 50\%$ $\rightarrow$ notre OCR est la **seule source**. Matériels : David P. Roe (1 686), Francis Rooney (189).

6 Validation : concorde-t-on bien ?

Méthode Quiver honnête. Deux axes : (1) comptes par déclarant *per-lot* (Quiver brut, déposants papier flaggés) ; (2) recouvrement au niveau transaction (clé invariante à la dédup). Quiver n'entre jamais dans la table.

Verdict. Oui, le FINAL concorde bien. Couverture 85,9 % (81–91 %/an), accord sens $\sim 93\%$, montant $\sim 93\%$, identité $\sim 100\%$, et **9 transactions réellement absentes sur 81 646**. Le numérique seul est faible (35–74 %) ; l'OCR ferme l'écart. Le papier (Khanna, Harshbarger...) n'a aucune source externe : il est validé en interne (PDF source, `date_confidence`, stabilité run-à-run, ticker %).

7 Décisions et justifications

1. **Quiver = vérification seule.** Garantit l'indépendance ; nos chiffres ne sont pas tirés vers Quiver.
2. **Dédup per-lot (occurrence_index).** Préserve les lots identiques légitimes d'un même PTR ; retire seulement les vrais doublons cross-dépôt.
3. **natural_key_hash = 7 champs sans ticker.** Robuste à l'enrichissement (le ticker arrive après).
4. **Cluster C non exécuté par défaut.** Dates manuscrites peu fiables ; découpage par qualité, pas par année ; récupération ciblée des 3 filers à forte perte Quiver.
5. **Deskew.** 525/547 scans couchés sans signal métadonnée ; montage 4-rotations (reconnaissance, pas calcul d'angle), page par page. Concordance 59,7 % $\rightarrow$ 69,0 %.
6. **date_confidence.** Flag indépendant de Quiver ; `implausible` = hors fenêtre légale (misread d'année). Attrape les dates aberrantes.
7. **Passe LLM nom $\rightarrow$ ticker.** Le dict électronique plafonne à $\sim 46\%$; LLM monte à $\sim 90\%$, cache versionné (re-run gratuit).
8. **Zéro changement de résultat.** La refonte ne modifie aucun octet de sortie ; prouvé fonction par fonction.
9. **Arbo plate data/house/.** Structure présentable ; déplacement vérifié (`check_golden` = 0 écart).
10. **Maps montant/owner/opération par chambre.** House et Sénat divergent (midpoints, labels) ; centralisé dans `amounts.py`.
11. **PROMPT_SHA préservé.** Déplacer le moteur OCR ne devait pas invalider 546 caches (re-OCR payant) ; prouvé.

12. **Clés Quiver non fusionnées entre chambres.** House garde sa clé brute (reproduit 07); Sénat la sienne.
13. **Tolérance date $\pm 3j$ (échantillon).** Quiver brute la date de $\pm 1-2j$; l'égalité stricte comptait ces écarts comme erreurs.
14. **Override manuel (Van Taylor).** $\acute{n}$ Nicholas V. Taylor $\acute{z}$ = Van Taylor, résolu explicitement.
15. **Suppression des globals identité House.** `build_reference/match_bioguide` délèguent au cur; plus aucune duplication.
16. **Dédup OCR non destructrice (parité Sénat).** L'OCR ne posait pas `occurrence_index`; on le pose (`cumcount(doc_id, nk)`) puis dédup (`nk, occ`). Retire 405 doublons cross-doc (amendements), préserve le multi-trust réel; sans `occ`, dédupliquer sur `nk` seul aurait détruit 2 425 lignes Khanna légitimes.

8 Fait / Pas fait / Différé

- **fait** : refonte complète (cur `congress_core`, package `house`, données `data/house/`).
- **fait** : électronique 2020–2026 (32 676 txns, $\geq 98\%$ Quiver/an).
- **fait** : OCR run complet (48 970 txns) $\rightarrow$ FINAL 81 646.
- **fait** : complétion des 40 docs `partial_error` (manuscrit, +66 txns); `filet golden` (108 fichiers); 5 invariants prouvés.
- **différé** : cluster C manuscrit (27,6 % du census) — exclu par défaut (qualité dates), récupération ciblée seulement. Décision assumée.
- **différé** : dates Harshbarger 2021 — **ambiguïté OCR intrinsèque**, non corrigeable par re-OCR; mitigée par `date_confidence`.
- **fait** : `sector_gics/etf_proxy` sur tout le multi-années (yfinance + repli LLM) — secteur rempli **83,2 %** (67 932/81 646) $\rightarrow$ table **12/12 champs**, parité Sénat.
- **non fait** : comités point-in-time (snapshot statique courant).
- **différé** : Sénat (le cur est prêt à être réutilisé), stratégie et backtest (hors périmètre données).

9 Limites et métriques manquantes

1. **Validation papier externe impossible.** Quiver, Kadoa et House Stock Watcher sautent tous les scans : 0 ligne pour Khanna/Harshbarger/McCaul. Pas de taux d'exactitude externe sur le papier (contrôles internes seulement).
2. **Comités non point-in-time.** `committee_membership` est constant sur 7 ans (0/256 varient) : snapshot statique. Une analyse de conflit d'intérêt par comité à la date de transaction n'est pas fondée.
3. **Pas de tolérance de date dans l'appariement House.** Clé date brute : une ambiguïté OCR d'1 jour casse le match. La couverture 85,9 % est donc un *plancher* (sous-estime sur dates OCR bruitées).
4. **only_quiver non décomposé par cause.** 248 brut : on sait que 9 sont réellement absents, mais le reste (amendements / artefacts ticker / dates) n'est pas ventilé automatiquement.
5. **Divers.** `asset_type` rempli à 91,1 %; `date_confidence` est une heuristique binaire (plausible/implausible), pas une mesure d'exactitude vs vérité terrain.

10 Reproductibilité

Filet de non-régression `tests/regression/` : `golden` de **108 fichiers** empreintés (sha256). Cinq invariants prouvés sur les colonnes figées, sans re-run ni appel API :

- `natural_key_hash` : drop-in exact (161 974 hash reproduits).
- `amount_midpoint` + `infer_asset_type` : 81 646 + 48 970 reproduits.

- `match_bioguide` : 3 514 bioguides reproduits ; port identique à l'original.
- `PROMPT_SHA` : préservé (cache OCR valide, 0 re-OCR).

Commande de vérification : `python tests/regression/check_golden.py` (code retour 0 si zéro écart).

11 Annexes

11.1 Carte des fichiers

- Cur : `congress_core/{paths,identity,schema,amounts,tickers,quiver,crosscheck,vision_ocr,llm}`
- Pipeline : `house/{digital,ocr,echantillon}.py` + `notebooks/notebook_house.ipynb`
- Données : `data/house/{tables,pdfs,index,reference,ocr_cache}/`
- Docs : `docs/{REFONTE_HOUSE,SYNTHESE_house_detail}.md`, ce rapport `docs/RAPPORT_HOUSE.tex`
- Filet : `tests/regression/` (`golden_manifest.json`, 108 entrées)
- Pilote figé : `0 HOUSE/2025_test/`

11.2 Glossaire

PTR

Periodic Transaction Report : déclaration de transaction (STOCK Act, ≤ 45 j).

BioGuideID

Identifiant unique d'un législateur (référentiel `congress-legislators`).

natural_key_hash

SHA-256 de 7 champs (sans ticker) : clé de transaction stable.

per-lot

Dédup qui préserve les lots identiques d'un même PTR via `occurrence_index`.

deskew

Redressement des scans couchés avant l'OCR (montage 4-rotations).

date_confidence

Flag plausible/implausible d'une date OCR (fenêtre légale 75 j).

cluster A/B/C

Typologie des scans : tapé droit / tapé tourné / manuscrit.

only_ours / only_quiver

Transactions présentes chez nous seulement / chez Quiver seulement.