

# Rapport qualité — Données de trading du Congrès américain

Chambre des représentants + Sénat · 2020–2026 · généré par `python -m common.quality` (lecture seule des tables FINAL, aucun appel API) · Quiver Quantitative = vérité-terrain externe, **jamais réinjectée**.

## Résumé exécutif

- Périmètre** — 89 852 transactions uniques de membres élus (House 81 607 + Sénat 8 245), 2020–2026, en **4 sous-corpus** (chambre × voie d'acquisition : électronique déterministe / scan OCR).
- Complétude vs Quiver** (§6) — dans notre fenêtre, on retrouve **93.9 % (House) / 91.5 % (Sénat)** des trades Quiver au niveau (déposant, ticker, sens). Le **vrai trou coté est minuscule** (22 House / 0 Sénat) ; le reste du résidu est de l'OCR récupérable ou du hors-périmètre.
- On est plus complet que Quiver** — **+6945 actions cotées qu'on a et que Quiver n'a pas, contre 13 trous inverses**. La base est, en pratique, un **sur-ensemble** de Quiver.
- Les « écarts » de date ne sont pas des erreurs** — la réconciliation 1-à-1 (§6.3) montre que l'essentiel est du « nous-seul » (Quiver n'a pas le trade) ; seuls 288 candidats House (même déclaration) méritent l'œil, et le vrai contrôle des dates reste l'audit PDF (§3).
- Données propres** — identité rattachée à 100.0 %, dates cohérentes 99.8 %, délai de divulgation médian 28 j, montants renseignés 99.0 %.

Plan : §1 construction & validation · §2 composition & complétude · §3 qualité des dates · §4 montants · §5 activité & concentration · §6 complétude vs Quiver (vérité-terrain).

## 1. Construction & validation du corpus

Avant toute statistique, voici **comment le corpus est construit**, dans l'ordre :

- Sources** — déclarations officielles : Chambre (*PTR*) et Sénat (*eFD*), chacune en deux voies — **électronique** (formulaire structuré, lecture déterministe) et **papier scanné** (PDF → **OCR** par modèle de vision).
- Extraction** — une ligne = une transaction (membre, date, actif, sens, fourchette de montant, détenteur).
- Enrichissement** — ticker (explicite dans la source · repris de l'électronique · résolu par LLM), secteur GICS (yfinance · LLM), identité (`bioguide_id`), ancienneté.
- Déduplication cross-année** — une même transaction re-divulguée une autre année (amendement, rapport annuel) ne compte qu'**une fois** (clé naturelle + rang d'occurrence).

**Réconciliation — des lignes brutes aux transactions uniques** (c'est notre corpus, pas Quiver) :

| chambre | lignes brutes | re-divulgations (dédup) | transactions uniques |
|---------|---------------|-------------------------|----------------------|
| house   | 81642         | 35                      | 81607                |
| senate  | 8841          | 596                     | 8245                 |
| TOTAL   | 90483         | 631                     | 89852                |

*lignes brutes* = FINAL concaténé 2020–2026 · *re-divulgations* = doublons cross-année retirés · *transactions uniques* = le corpus analysé dans tout ce rapport

## Validation & reproductibilité

Tout est **rejouable hors-ligne** (lecture seule des tables FINAL, **0 appel API**), adossé à trois filets automatiques :

- Golden octet-à-octet** — 201 tables CSV figées par SHA256 (125 House + 76 Sénat), rejouées à **zéro écart** (`tests/regression/check_golden.py`, `senate_check_golden.py`).
- Invariants porteurs** — pour chaque chambre `digital + OCR = FINAL`, identité rattachée à **100.0 %**, 256 bioguides (House) / 64 (Sénat) recomptés (`tests/regression/audit_metrics.py`).
- Transformations déterministes** — 11 tests reproduisent chaque étape (clé naturelle, montants, tickers, identité, ancienneté, cache Vision) depuis les colonnes figées.

## Les quatre sous-corpus

Toute la suite distingue **quatre familles** (chambre × voie), car leur qualité et leur composition diffèrent :

| sous-corpus        | n     | part % |
|--------------------|-------|--------|
| House électronique | 32667 | 36.4   |
| House OCR          | 48940 | 54.5   |
| Sénat électronique | 6566  | 7.3    |
| Sénat OCR          | 1679  | 1.9    |

*sous-corpus* = chambre × voie (électronique déterministe / scan OCR) · *n* = transactions uniques · *part %* du total

## 2. Composition & complétude

Ce que contient le corpus (opérations, détenteur, familles d'actifs), puis à quel point les champs sont remplis.

### Sens des opérations

| sous-corpus        | n     | achat % | vente % | échange % | autre % |
|--------------------|-------|---------|---------|-----------|---------|
| House électronique | 32667 | 49.7    | 49.7    | 0.6       | 0.0     |
| House OCR          | 48940 | 52.7    | 46.6    | 0.7       | 0.0     |
| Sénat électronique | 6566  | 48.6    | 50.5    | 0.9       | 0.0     |
| Sénat OCR          | 1679  | 54.0    | 45.8    | 0.2       | 0.0     |

*achat* = `operation_type` contient « Purchase » · *vente* = contient « Sale » (**inclut Sale (Partial) et (Full)**) · *échange* = « Exchange » · *autre* = reste

Détenteur déclaré

| sous-corpus        | n     | perso % | conjoint % | joint % | enfant % | autre % |
|--------------------|-------|---------|------------|---------|----------|---------|
| House électronique | 32667 | 51.9    | 19.7       | 26.2    | 2.2      | 0.0     |
| House OCR          | 48940 | 6.7     | 51.1       | 7.0     | 35.2     | 0.0     |
| Sénat électronique | 6566  | 15.7    | 41.4       | 40.1    | 2.9      | 0.0     |
| Sénat OCR          | 1679  | 26.9    | 73.0       | 0.1     | 0.1      | 0.0     |

titulaire du compte : perso = Self · conjoint = Spouse/SP · joint = Joint/JT · enfant = Dependent/Child/DC · autre = reste ou non déclaré

Familles d'actifs

Le non-coté (oblig. d'État, munis, obligations) domine l'OCR du Sénat :

| sous-corpus        | n     | action % | option % | oblig. État % | muni % | oblig. corp. % | fonds % | autre % | manquant % |
|--------------------|-------|----------|----------|---------------|--------|----------------|---------|---------|------------|
| House électronique | 32667 | 84.6     | 1.8      | 5.9           | 0.0    | 0.0            | 0.0     | 6.1     | 1.6        |
| House OCR          | 48940 | 81.7     | 0.0      | 0.8           | 0.0    | 0.1            | 3.1     | 0.6     | 13.8       |
| Sénat électronique | 6566  | 67.2     | 9.1      | 0.0           | 10.8   | 3.0            | 0.0     | 10.0    | 0.0        |
| Sénat OCR          | 1679  | 12.9     | 0.0      | 0.0           | 0.8    | 2.6            | 0.0     | 69.6    | 14.2       |

familles d'asset\_type : action = Stock · option · oblig. État = Gov/Treasury · muni = Municipal · oblig. corp. = Bond · fonds = Fund/ETF · manquant = vide

Couverture des champs enrichis (taux de remplissage)

| sous-corpus        | n     | ticker % | secteur % | ETF % | commission % | identité % | ancienneté % | montant renseigné % |
|--------------------|-------|----------|-----------|-------|--------------|------------|--------------|---------------------|
| House électronique | 32667 | 88.7     | 86.6      | 86.6  | 74.7         | 100.0      | 100.0        | 100.0               |
| House OCR          | 48940 | 83.7     | 81.0      | 81.0  | 94.5         | 100.0      | 100.0        | 98.2                |
| Sénat électronique | 6566  | 79.3     | 71.3      | 71.3  | 62.5         | 100.0      | 100.0        | 100.0               |
| Sénat OCR          | 1679  | 33.2     | 19.4      | 19.4  | 96.1         | 100.0      | 100.0        | 99.6                |

% de lignes où le champ est renseigné · identité = rattachée à un bioguide\_id · montant renseigné = amount\_midpoint non vide · ticker/secteur/ETF vides = actif non coté (normal, pas un défaut)

Secteurs & origine des champs résolus

| sous-corpus        | n     | secteur renseigné % | ETF % | top 3 secteurs                                                         |
|--------------------|-------|---------------------|-------|------------------------------------------------------------------------|
| House électronique | 32667 | 86.6                | 86.6  | Information Technology 20%, Financials 14%, Health Care 13%            |
| House OCR          | 48940 | 81.0                | 81.0  | Information Technology 20%, Financials 16%, Health Care 14%            |
| Sénat électronique | 6566  | 71.3                | 71.3  | Information Technology 22%, Financials 16%, Consumer Discretionary 10% |
| Sénat OCR          | 1679  | 19.4                | 19.4  | Financials 21%, Communication Services 18%, Information Technology 12% |

secteur renseigné % / ETF % = taux de remplissage (vide = non coté) · top 3 = secteurs GICS dominants

Origine du ticker (ticker\_source) :

| sous-corpus        | n     | dico élec % | LLM % | explicite % | aucune % |
|--------------------|-------|-------------|-------|-------------|----------|
| House électronique | 32667 | 0.0         | 0.0   | 88.7        | 11.3     |
| House OCR          | 48940 | 45.6        | 36.2  | 1.3         | 16.3     |
| Sénat électronique | 6566  | 0.5         | 0.7   | 77.1        | 20.7     |
| Sénat OCR          | 1679  | 9.5         | 8.3   | 15.4        | 66.8     |

dico élec = repris de l'électronique · LLM = résolu par LLM · explicite = déjà présent dans la source · aucune = non résolu

Origine du secteur (sector\_source) :

| sous-corpus        | n     | yfinance % | LLM % | manuel % | aucune % |
|--------------------|-------|------------|-------|----------|----------|
| House électronique | 32667 | 78.7       | 7.8   | 0.2      | 13.3     |
| House OCR          | 48940 | 75.4       | 5.6   | 0.1      | 18.9     |
| Sénat électronique | 6566  | 62.1       | 9.0   | 0.9      | 28.0     |
| Sénat OCR          | 1679  | 12.0       | 7.4   | 1.1      | 79.5     |

yfinance = base factuelle · LLM · manuel = correction d'audit · aucune

3. Qualité des dates

Trois questions, de la plus faible à la plus forte : les dates sont-elles lisibles et cohérentes (divulgarion ≥ transaction) ? le délai légal (STOCK Act ~45 j) est-il respecté ? reste-t-il des anomalies ?

Cohérence (disclosure\_date ≥ transaction\_date)

| chambre | n     | dates exploitables % | cohérentes % | incohérentes | année aberrante | date manquante |
|---------|-------|----------------------|--------------|--------------|-----------------|----------------|
| house   | 81607 | 99.8                 | 99.8         | 154          | 0               | 177            |
| senate  | 8245  | 99.9                 | 100.0        | 3            | 0               | 7              |

Par sous-corpus :

| sous-corpus        | n     | dates exploitables % | cohérentes % | incohérentes | année aberrante | date manquante |
|--------------------|-------|----------------------|--------------|--------------|-----------------|----------------|
| House électronique | 32667 | 100.0                | 99.9         | 18           | 0               | 0              |
| House OCR          | 48940 | 99.6                 | 99.7         | 136          | 0               | 177            |
| Sénat électronique | 6566  | 100.0                | 100.0        | 0            | 0               | 0              |
| Sénat OCR          | 1679  | 99.6                 | 99.8         | 3            | 0               | 7              |

dates exploitables = parseables (le reste = OCR illisible) · cohérentes = divulgation ≥ transaction · incohérentes = divulgation AVANT transaction (amendement/antidaté) · année aberrante = année impossible (postérieure au dépôt, ou < 2012) · date manquante = illisible. Des transactions 2013–2019 sont légitimes (divulgations tardives).

Délai légal de divulgation (STOCK Act ~45 j)

| chambre | n dates valides | ≤45j légal % | 45-75j % | >75j % | négatif % | délai médian (j) |
|---------|-----------------|--------------|----------|--------|-----------|------------------|
| house   | 81430           | 87.0         | 5.2      | 7.7    | 0.2       | 28               |
| senate  | 8238            | 91.0         | 2.8      | 6.2    | 0.0       | 27               |

Par sous-corpus :

| sous-corpus        | n dates valides | ≤45j légal % | 45-75j % | >75j % | négatif % | délai médian (j) |
|--------------------|-----------------|--------------|----------|--------|-----------|------------------|
| House électronique | 32667           | 81.9         | 4.9      | 13.2   | 0.1       | 28               |
| House OCR          | 48763           | 90.3         | 5.4      | 4.0    | 0.3       | 28               |
| Sénat électronique | 6566            | 90.6         | 1.9      | 7.5    | 0.0       | 26               |
| Sénat OCR          | 1672            | 92.4         | 6.5      | 0.9    | 0.2       | 29               |

*n dates valides* = transactions dont le délai est CALCULABLE (les deux dates présentes et lisibles ; « valide » = mesurable, pas « juste ») · *délai* = divulgation – transaction (j) · *≤45 j* = délai légal STOCK Act · *45-75 j* = marge tolérée · *>75 j* = retard · *négatif* = anomalie (divulgation avant transaction), comptée dans *n dates valides* · *délai médian en j*

Divulgations les plus tardives (> 365 j)

| déposant         | chambre | date txn   | date divulg. | délai (j) | ticker | opération      |
|------------------|---------|------------|--------------|-----------|--------|----------------|
| Jefferson Shreve | house   | 2015-05-08 | 2025-06-22   | 3698.0    | DHR    | Purchase       |
| Jefferson Shreve | house   | 2015-05-08 | 2025-06-22   | 3698.0    | DAL    | Purchase       |
| Richard W. Allen | house   | 2017-02-03 | 2023-08-10   | 2379.0    |        | Purchase       |
| Richard W. Allen | house   | 2017-02-13 | 2023-08-10   | 2369.0    | O      | Sale           |
| Richard W. Allen | house   | 2017-03-23 | 2023-08-10   | 2331.0    | BBT    | Sale           |
| Richard W. Allen | house   | 2017-03-23 | 2023-08-10   | 2331.0    | BBT    | Sale (Partial) |
| Richard W. Allen | house   | 2017-04-27 | 2023-08-10   | 2296.0    | XOM    | Sale           |
| Richard W. Allen | house   | 2017-04-27 | 2023-08-10   | 2296.0    | COST   | Purchase       |
| Richard W. Allen | house   | 2017-05-16 | 2023-08-10   | 2277.0    | GE     | Sale           |
| Richard W. Allen | house   | 2017-05-16 | 2023-08-10   | 2277.0    | FDX    | Purchase       |
| Thomas Suozzi    | house   | 2017-01-05 | 2022-12-19   | 2174.0    | PCLN   | Sale           |
| Thomas Suozzi    | house   | 2017-01-05 | 2022-12-19   | 2174.0    | DFS    | Sale           |
| Thomas Suozzi    | house   | 2017-01-05 | 2022-12-19   | 2174.0    | CME    | Sale           |
| Thomas Suozzi    | house   | 2017-01-05 | 2022-12-19   | 2174.0    | FB     | Sale           |
| Thomas Suozzi    | house   | 2017-01-05 | 2022-12-19   | 2174.0    | KMX    | Sale           |

*délai (j)* = divulgation – transaction · *divulgations > 1 an après la transaction* (souvent des amendements ou de vieux comptes régularisés)

**Audit des anomalies (échantillon de 12 PDF re-lus à la source).** ~½ sont FIDÈLES : coquilles du **déposant lui-même** (un PTR imprime littéralement 01/35/22), cellules vides ou parts de société sans date de transaction — on les transcrit sans les inventer. ~⅓ = **notre OCR** (mois/jour mal lu), corrigé à la lecture **quand le formulaire est lisible** (4 dates vérifiées, clé doc+date, figé inchangé). ~¼ = **provenance** (hallucination OCR ou pièce jointe absente du PDF). **On ne fabrique aucune date** : les illisibles restent flaggées.

4. Montants (amount\_midpoint)

Le montant = **midpoint** de la fourchette déclarée (les déclarations donnent des tranches, pas un chiffre exact). Vue par sous-corpus :

| sous-corpus        | n     | médiane \$ | moyenne \$ | P25 \$ | P75 \$ | P95 \$ | volume total M\$ |
|--------------------|-------|------------|------------|--------|--------|--------|------------------|
| House électronique | 32667 | 8000       | 53307      | 8000   | 15001  | 100001 | 1741.4           |
| House OCR          | 48940 | 8000       | 49627      | 8000   | 32500  | 175000 | 2386.0           |
| Sénat électronique | 6566  | 8000       | 100115     | 8000   | 32500  | 375000 | 657.4            |
| Sénat OCR          | 1679  | 32500      | 171021     | 8000   | 75000  | 750000 | 285.9            |

*médiane/moyenne/P25/P75/P95 en \$ · volume total = Σ midpoint (M\$) · midpoint = milieu de la fourchette déclarée*

*la plus petite tranche (≤ 15 k\$, midpoint 8 000 \$) domine → dès qu'elle dépasse 50 %, le P25 ET la médiane y tombent ensemble (cas House/Sénat élec). Sénat OCR < 50 % → médiane 32 500 ≠ P25 8 000.*

**Ensemble** — 88 982 montants renseignés · médiane 8 000 \$ · moyenne 56 985 \$ · P90 75 000 \$ · max 75 000 000 \$.

5. Activité & concentration

Qui trade, à quel point l'activité est concentrée, et ce que deviennent les positions.

Concentration du volume

| sous-corpus        | n déposants | HHI    | Gini  | top10 volume % |
|--------------------|-------------|--------|-------|----------------|
| House électronique | 234         | 662.7  | 0.877 | 68.8           |
| House OCR          | 40          | 2888.3 | 0.913 | 98.7           |
| Sénat électronique | 61          | 1269.1 | 0.835 | 84.6           |
| Sénat OCR          | 5           | 6388.7 | 0.695 | 100.0          |

HHI ∈ [0, 10000] et Gini ∈ [0, 1] mesurent la concentration du volume par déposant (plus c'est haut, plus quelques déposants dominant).

Où va le volume

Top tickers par volume estimé :

| ticker | n trades | volume M\$ |
|--------|----------|------------|
| MSFT   | 1014     | 261.3      |
| ICE    | 110      | 93.4       |
| BRP    | 7        | 81.8       |
| AAPL   | 741      | 80.4       |
| MET    | 114      | 76.2       |
| T      | 338      | 63.1       |
| NVDA   | 594      | 46.1       |
| DFS    | 66       | 42.9       |
| AMZN   | 684      | 42.3       |
| HBI    | 65       | 38.3       |
| GOOGL  | 599      | 29.8       |
| ADBE   | 381      | 23.2       |
| AVGO   | 269      | 18.1       |
| PYPL   | 355      | 17.0       |
| AESI   | 5        | 15.9       |

volume M\$ =  $\Sigma$  midpoint des trades du ticker · n trades = nombre de transactions

Volume par secteur GICS :

| secteur                | n trades | volume M\$ |
|------------------------|----------|------------|
| Information Technology | 14315    | 725.9      |
| Financials             | 10981    | 520.7      |
| Communication Services | 5593     | 263.1      |
| Consumer Discretionary | 8309     | 259.7      |
| Health Care            | 9495     | 229.7      |
| Industrials            | 8476     | 196.8      |
| Energy                 | 3077     | 141.5      |
| Consumer Staples       | 5137     | 138.5      |
| Materials              | 2898     | 61.8       |
| Real Estate            | 2729     | 53.6       |
| Utilities              | 1274     | 30.5       |

Top déposants

Par volume estimé ( $\Sigma$  midpoint) :

| déposant           | chambre | n trades | volume estimé M\$ |
|--------------------|---------|----------|-------------------|
| Michael T. McCaul  | house   | 10738    | 974.5             |
| Rohit Khanna       | house   | 30516    | 667.8             |
| Diana Harshbarger  | house   | 3124     | 464.5             |
| Darrell E. Issa    | house   | 20       | 250.5             |
| RICHARD BLUMENTHAL | senate  | 1226     | 221.3             |
| Josh Gottheimer    | house   | 2942     | 209.4             |
| Jefferson Shreve   | house   | 631      | 191.7             |
| Scott Franklin     | house   | 68       | 182.1             |
| Rick Scott         | senate  | 266      | 167.2             |
| Nancy Pelosi       | house   | 147      | 139.6             |
| Suzan K. DelBene   | house   | 406      | 125.9             |
| Kelly Loeffler     | senate  | 329      | 120.9             |
| David H McCormick  | senate  | 293      | 69.0              |
| Scott H. Peters    | house   | 334      | 64.6              |
| Kevin Hern         | house   | 760      | 60.1              |

volume estimé M\$ =  $\Sigma$  midpoint des transactions du déposant · n trades = nombre de transactions

Par nombre de transactions — 320 déposants distincts, dont **206** avec ≥ 10 transactions (éligibles au backtest) et **150** actifs sur ≥ 3 années :

| nom                   | total | dont OCR | OCR % | n années | 1re année | dern. année |
|-----------------------|-------|----------|-------|----------|-----------|-------------|
| Rohit Khanna          | 30862 | 30862    | 100   | 8        | 2019      | 2026        |
| Michael T. McCaul     | 10850 | 10850    | 100   | 7        | 2020      | 2026        |
| Diana Harshbarger     | 3515  | 3514     | 100   | 4        | 2021      | 2026        |
| Josh Gottheimer       | 2942  | 0        | 0     | 8        | 2019      | 2026        |
| Gilbert Cisneros      | 2153  | 0        | 0     | 4        | 2019      | 2026        |
| David P. Roe          | 1686  | 1686     | 100   | 1        | 2020      | 2020        |
| Lisa McClain          | 1532  | 109      | 7     | 3        | 2024      | 2026        |
| Thomas H Tuberville   | 1369  | 0        | 0     | 5        | 2021      | 2025        |
| Daniel Goldman        | 1291  | 0        | 0     | 2        | 2023      | 2025        |
| RICHARD BLUMENTHAL    | 1232  | 1232     | 100   | 8        | 2019      | 2026        |
| Thomas R Carper       | 923   | 0        | 0     | 6        | 2019      | 2024        |
| Susie Lee             | 857   | 0        | 0     | 8        | 2019      | 2026        |
| Donald Sternoff Beyer | 822   | 0        | 0     | 8        | 2019      | 2026        |
| Kathy Manning         | 803   | 0        | 0     | 5        | 2021      | 2025        |
| JOHN BOOZMAN          | 768   | 379      | 49    | 8        | 2019      | 2026        |
| Thomas Suozzi         | 765   | 20       | 3     | 9        | 2017      | 2026        |
| Kevin Hern            | 760   | 0        | 0     | 8        | 2019      | 2026        |
| Alan S. Lowenthal     | 676   | 0        | 0     | 4        | 2019      | 2022        |
| Lois Frankel          | 656   | 0        | 0     | 5        | 2019      | 2023        |
| Mark Green            | 653   | 0        | 0     | 6        | 2020      | 2025        |

$total = nb\ transactions \cdot dont\ OCR / OCR\ \% = part\ scannée \cdot n\ années = années\ actives \cdot 1re/dern.\ année = première/dernière\ année\ de\ transaction$

Devenir des achats à +12 mois (revente vs fermeture forcée, pour la stratégie)

Pour chaque achat (avec ticker), on suit la position : est-elle **revendue par le même membre sur le même ticker dans les 12 mois** (l'horizon de fermeture forcée de la stratégie) ? L'appariement se fait sur la **date de divulgation** — ce que la stratégie peut observer. Les achats divulgués il y a **moins de 12 mois** (après 2025-06-25) n'ont pas assez de recul pour juger : marqués *trop récents* et exclus des taux.

| chambre | achats (avec ticker) | trop récents | observables | revendu ≤12m | revendu ≤12m % | fermé de force | fermé de force +12m % |
|---------|----------------------|--------------|-------------|--------------|----------------|----------------|-----------------------|
| house   | 34698                | 2509         | 32189       | 23256        | 72.2           | 8933           | 27.8                  |
| senate  | 2468                 | 236          | 2232        | 1078         | 48.3           | 1154           | 51.7                  |

Par sous-corpus :

| sous-corpus        | achats (avec ticker) | trop récents | observables | revendu ≤12m | revendu ≤12m % | fermé de force | fermé de force +12m % |
|--------------------|----------------------|--------------|-------------|--------------|----------------|----------------|-----------------------|
| House électronique | 14010                | 1764         | 12246       | 6340         | 51.8           | 5906           | 48.2                  |
| House OCR          | 20688                | 745          | 19943       | 16916        | 84.8           | 3027           | 15.2                  |
| Sénat électronique | 2301                 | 231          | 2070        | 988          | 47.7           | 1082           | 52.3                  |
| Sénat OCR          | 167                  | 5            | 162         | 90           | 55.6           | 72             | 44.4                  |

$achats\ (avec\ ticker) \cdot trop\ récents = <12\ mois\ de\ recul\ depuis\ la\ divulgation\ (indéterminé,\ hors\ dénominateur) \cdot observables = achats - trop\ récents \cdot revendu\ ≤12m = une\ vente\ du\ même\ ticker\ divulguée\ dans\ les\ 12\ mois \cdot fermé\ de\ force\ +12m = aucune\ vente\ sous\ 12\ mois \rightarrow la\ stratégie\ clôt\ la\ position \cdot les\ deux\ \% \text{ portent sur les observables}$

6. Complétude vs Quiver (vérité-terrain externe)

**Section clé.** Quiver est un fournisseur commercial des mêmes données = notre **jugé externe**. But : montrer qu'on a **au moins tout ce que Quiver a** (Quiver  $\subseteq$  nous), qu'on est même **plus complet**, et que nos différences ne sont **pas des erreurs**. On procède comme un **entonnoir, de stricteesse croissante** : Niveau 1  $\rightarrow$  2  $\rightarrow$  3. Chiffres recalculés par `common/quiver_diagnosis.py`, **jamais réinjectés**.

6.1 Méthode

Chaque transaction est confrontée à Quiver par une clé normalisée, en **trois niveaux de plus en plus stricts** : **N1** a-t-on le trade ? (*sans la date*, §6.2)  $\rightarrow$  **N2** le même trade à la même date ? (§6.3)  $\rightarrow$  **N3** qui corrige quoi ? (§6.5).

| élément              | définition                                                                                                  |
|----------------------|-------------------------------------------------------------------------------------------------------------|
| univers comparé      | tous les trades Quiver <code>Filed</code> $\in$ 2020–2026 (notre fenêtre de scrape)                         |
| clé d'appariement    | ( <code>bioguide</code> , ticker normalisé, sens) — <b>+ date</b> au Niveau 2, <b>sans date</b> au Niveau 1 |
| normalisation ticker | MAJ + trim ; rejette (vide, NAN, NONE, --) ; retire PUT / CALL ; . / - $\rightarrow$ _                      |
| normalisation sens   | 1re lettre p/s/e $\rightarrow$ Purchase / Sale / Exchange                                                   |

Périmètre : le corpus FINAL dédoublé cross-année (89 852 transactions uniques, cf. §1 « Construction & validation du corpus »).

Réf. : `house/quiver.py` (`norm_ticker`, `norm_sense`), `common/quiver_diagnosis.py`.

6.2 Niveau 1 — A-t-on le trade ? (sans la date)

On compare des **combinaisons** (membre, action, sens), en **ignorant volontairement la date ET le nombre** : (Khanna, AAPL, Achat) compte pour **un**, qu'il l'ait acheté 1 fois ou 50. La question est donc grossière **exprès** : « a-t-on raté une combinaison **ENTIÈRE** que Quiver connaît ? » — le comptage trade par trade, c'est le Niveau 2 (§6.3).

On retrouve **93.9 % (House)** et **91.5 % (Sénat)** des combinaisons Quiver. Le **vrai trou** est minuscule (22 House / 0 Sénat) ; le reste est récupérable ou hors périmètre :

| chambre | trades Quiver (fenêtre) | qu'on a | inclusion % | résidu | récupérable (OCR) | hors périmètre | vrai trou coté |
|---------|-------------------------|---------|-------------|--------|-------------------|----------------|----------------|
| house   | 17481                   | 16416   | 93.9        | 1065   | 955               | 88             | 22             |
| senate  | 2587                    | 2366    | 91.5        | 221    | 0                 | 221            | 0              |

Le **résidu** se lit ainsi : **récupérable (OCR)** = membre lu en OCR papier dont on a capté le trade mais **pas résolu le ticker** (nom lisible  $\rightarrow$  récupérable, cf. note ; sinon non-coté déguisé/charabia OCR) · **hors périmètre** = « ticker » Quiver non-coté (CUSIP/fragment) + trade sous un ticker d'échange combiné (« PFE

VTRS » couvre PFE) + membre de l'autre chambre polluant le cache · **vrai trou coté** = le seul manque réel.

*Note* : une passe de **récupération nom**→**ticker** (vérifiée, **hors Quiver**, appliquée à la lecture — golden intact) a rendu leur ticker à **289 trades** d'actions que l'OCR/LLM avaient laissés vides (faux négatifs, ex. NEENAH PAPER→NP, TENCENT→TCEHY). Le « récupérable OCR » restant est surtout des **non-cotés déguisés** (préférentielles, fonds) et du **charabia OCR**, non mappables.

**Bilan net** — combinaisons cotées qu'on a et que Quiver n'a PAS vs trous inverses → on est un **sur-ensemble** de Quiver :

| chambre | actions qu'on a en + | vrais trous | solde net |
|---------|----------------------|-------------|-----------|
| house   | 6265                 | 10          | 6255      |
| senate  | 680                  | 3           | 677       |

6.3 Niveau 2 — Le même trade, à la même date ?

On descend au trade près. Comme un membre peut trader le même titre **plusieurs fois**, on ne demande PAS « ma date est-elle dans l'ensemble Quiver ? » : on **apparie 1-à-1** nos trades à ceux de Quiver, à l'intérieur de chaque (membre, ticker, sens). Exemple :

Khanna, AAPL, Achat – dates :  
NOUS : 08-jan-2020 · 13-fév-2020 · 01-juin-2020 · 10-mars-2023  
QUIVER : 08-jan-2020 · 12-fév-2020 · 10-mars-2023

Étape 1 – on retire les dates IDENTIQUES (une par une) :  
08-jan ↔ 08-jan et 10-mars-2023 ↔ 10-mars-2023 → 2 « apparié exact »  
(le trade 2023 s'apparie à SON 2023, jamais à un 2020)

Étape 2 – on apparie les RESTES au plus proche (plafond 90 j) :  
13-fév (nous) ↔ 12-fév (Quiver) = 1 j → « apparié proche » (≤ 10 j, bruit de date)  
01-juin (nous) : aucun reste Quiver à < 90 j → « NOUS-SEUL » (trade en plus)

Deux garde-fous répondent à « comment gérer qu'un membre ait plusieurs trades » : l'appariement **1-à-1 respecte les quantités** (si on a 50 trades et Quiver 40, ≥ **10 restent forcément en « nous-seul »**) ; le **plafond de 90 j** + l'**ancrage au dépôt** empêchent mécaniquement de confondre un trade 2020 et un trade 2023. Chaque trade tombe alors dans **une** catégorie :

| chambre | apparié exact | apparié proche (≤10j) | candidat écart | dont même déclaration | nous-seul | quiver-seul | candidat % |
|---------|---------------|-----------------------|----------------|-----------------------|-----------|-------------|------------|
| house   | 43309         | 605                   | 1629           | 288                   | 21891     | 4646        | 2.4        |
| senate  | 4361          | 0                     | 0              | 0                     | 1202      | 385         | 0.0        |

*apparié exact = même date · apparié proche = écart des dates de TRANSACTION ≤ 10 j (bruit/convention de date Quiver, même trade) · candidat écart = paire à 10–90 j, à inspecter (§6.4) · dont même déclaration = les deux trades viennent du MÊME formulaire de déclaration (PTR) — notre disclosure ≈ Filed Quiver ≤ 10 j → même trade, donc l'écart de date est un vrai désaccord (seul signal fort) · nous-seul = Quiver n'a PAS le trade (on est plus complet) · quiver-seul = on a raté.*

**Pourquoi les chiffres semblent contredire le §6.2 : c'est le niveau de stricteesse.** Au Niveau 1 (sans date), le vrai trou est 22/0 ; au Niveau 2 (trade + date), on compte 21891 trades « nous-seul » — normal, on trade plus souvent que Quiver ne capte au trade près. **Les deux disent la même chose : on est plus complet.**

6.4 Les candidats d'écart de date (même déclaration)

Les **seuls** candidats honnêtes d'erreur de date = les paires issues de la **même déclaration (PTR)** (288 House / 0 Sénat). Prudence : un petit delta peut être une **convention de date Quiver**, pas notre erreur. **Le vrai contrôle des dates reste l'audit PDF (§3)**, pas Quiver. doc\_id = pièce consultable :

| chambre | déposant     | ticker | sens | notre date | date Quiver | delta (j) | doc_id  |
|---------|--------------|--------|------|------------|-------------|-----------|---------|
| house   | Rohit Khanna | NOW    | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |
| house   | Rohit Khanna | ETR    | Sale | 2020-04-07 | 2020-04-18  | 11        | 8217213 |
| house   | Rohit Khanna | MSCI   | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |
| house   | Rohit Khanna | CHTR   | Sale | 2022-09-08 | 2022-09-19  | 11        | 8219242 |
| house   | Rohit Khanna | MPWR   | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |
| house   | Rohit Khanna | AMT    | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |
| house   | Rohit Khanna | LMT    | Sale | 2020-04-24 | 2020-04-13  | 11        | 8217213 |
| house   | Rohit Khanna | NKE    | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |
| house   | Rohit Khanna | CDNS   | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |
| house   | Rohit Khanna | FTV    | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |
| house   | Rohit Khanna | DXC    | Sale | 2020-03-25 | 2020-04-05  | 11        | 8217164 |
| house   | Rohit Khanna | ADBE   | Sale | 2023-10-26 | 2023-11-06  | 11        | 8220039 |

(Top 12 par delta croissant ; les 288 candidats sont dans quiver\_validation/candidats\_ecart\_date\_meme\_depot.csv.)

6.5 Niveau 3 — Que reste-t-il à corriger ?

On a vérifié l'**existence** (§6.2) et la **date** (§6.3). Restent deux choses : les **autres champs** des trades qu'on partage avec Quiver (sens, montant), et la **liste de ce qui est vraiment à corriger**.

**Autres champs — sens & montant.** Pour les trades qu'on a **tous les deux** (mêmes membre + ticker + date), est-on d'accord sur le sens (achat/vente) et le montant ?

| chambre | n paires | accord sens % | accord montant % |
|---------|----------|---------------|------------------|
| house   | 52376    | 95.8          | 93.1             |
| senate  | 4932     | 99.8          | 99.7             |

on apparie les cellules (membre, ticker, date) présentes des DEUX côtés ; un désaccord = vraie erreur d'extraction, listée dans desaccord\_champ\_.csv.\*

**La to-do (à corriger).** Un seul chiffre est **dur** — les vrais trous NOTRE\_MANQUE (le résidu après tous les filtres) ; les deux autres sont des **bornes hautes** ensemblistes = des listes à revoir cas par cas dans docs/quiver\_validation/, pas des taux d'erreur :

| à corriger                          | House | Sénat | nature                                                                                    | annexe            |
|-------------------------------------|-------|-------|-------------------------------------------------------------------------------------------|-------------------|
| vrais trous cotés (NOTRE_MANQUE)    | 10    | 3     | <b>DUR</b> — trade coté absent de chez nous (le résidu final filtré)                      | notre_manque_*    |
| lignes OCR papier (MANQUANT_PAPIER) | 1048  | 0     | borne haute — trades Quiver de déposants qu'on OCR, absents de nos clés exactes           | manquant_papier_* |
| tickers à revoir (ECART_TICKER)     | 5393  | 71    | borne haute — autre ticker ce jour-là (gonflée par la multiplicité, PAS un taux d'erreur) | ecart_ticker_*    |

Qui ? — les déposants derrière les vrais trous (NOTRE\_MANQUE), à investiguer :

| chambre | bioguide | nom                      | n trous |
|---------|----------|--------------------------|---------|
| house   | B001327  | Rob Bresnahan            | 5       |
| house   | P000197  | Nancy Pelosi             | 2       |
| house   | J000307  | John James               | 1       |
| house   | S000168  | Maria Elvira Salazar     | 1       |
| house   | W000797  | Debbie Wasserman Schultz | 1       |
| senate  | M001198  | Roger W Marshall         | 3       |

6.6 Annexe

Les tables **figées** 07c/07g/07h reproduisent la même comparaison en *exact-date* (elles **sous-comptent**, cf. §6.3) ; conservées pour la lignée/régression, non re-rendues ici. Les autres figées ( 07/07b/07d/07e/07f/06d ) sont des sorties historiques du pipeline.

Profil des clusters de scan (House OCR) — pourquoi le manuscrit est exclu (A = tapé droit, B = tapé tourné, C = manuscrit) :

| cluster       | n lignes | n docs | date plausible % | ticker % | Quiver a le trade % |
|---------------|----------|--------|------------------|----------|---------------------|
| A_tape_droit  | 5957     | 59     | 99.6             | 84.5     | 88.0                |
| B_tape_tourne | 42125    | 295    | 94.7             | 83.5     | 77.9                |
| C_manuscrit   | 858      | 80     | 97.4             | 89.0     | 35.3                |

*date plausible % / ticker % = qualité INTERNE (sans Quiver) · Quiver a le trade % = part de nos trades cotés que Quiver possède AUSSI (appariée sur membre+ticker+sens, date ou non). Sur le manuscrit (C), la qualité interne reste haute mais Quiver a le trade % s'effondre (ticker/identité mal lus, ou Quiver mince sur le papier) → faute de pouvoir le confirmer contre la vérité-terrain, on l'exclut par défaut (conservateur).*

Listes actionnables complètes (ligne à ligne) → docs/quiver\_validation/ (ecart\_ticker\_, notre\_manque\_, manquant\_papier\_, desaccord\_champ\_[typé], on\_est\_plus\_complet\_, quiver\_non\_cote\_, candidats\_ecart\_date\_meme\_depot). Hors golden.