

Rapport qualité — Données de trading du Congrès américain

Chambre des représentants + Sénat · 2020–2026 · généré par `python -m common.quality` (lecture seule des tables FINAL, aucun appel API) · Quiver Quantitative = vérité-terrain externe, **jamais réinjectée**.

Résumé exécutif

- Périmètre** — 89 852 transactions uniques de membres élus (House 81 607 + Sénat 8 245), 2020–2026, en **4 sous-corpus** (chambre × voie d'acquisition : électronique déterministe / scan OCR).
- Complétude vs Quiver** (§6) — dans notre fenêtre, on retrouve **93.8 % (House) / 91.5 % (Sénat)** des trades Quiver au niveau (déposant, ticker, sens). Le **vrai trou coté est minuscule** (22 House / 0 Sénat) ; le reste du résidu est de l'OCR récupérable ou du hors-périmètre.
- On est plus complet que Quiver** — **+6886 actions cotées qu'on a et que Quiver n'a pas, contre 13 trous inverses**. La base est, en pratique, un **sur-ensemble** de Quiver.
- Les « écarts » de date ne sont pas des erreurs** — la réconciliation 1-à-1 (§6.3) montre que l'essentiel est du « nous-seul » (Quiver n'a pas le trade) ; seuls 414 candidats House (même dépôt) méritent l'œil, et le vrai contrôle des dates reste l'audit PDF (§2).
- Données propres** — identité rattachée à 100.0 %, dates cohérentes 99.8 %, délai de divulgation médian 28 j, montants renseignés 99.0 %.

Plan : §1 composition · §2 cohérence des dates · §3 délai légal · §4 montants · §5 couverture & structure · §6 complétude vs Quiver (vérité-terrain).

1. Composition & qualité par sous-corpus

Les déclarations proviennent de **quatre sous-corpus** très différents (chambre × voie d'acquisition). Toute la suite distingue ces quatre familles, car leur qualité et leur composition diffèrent.

sous-corpus	n	part %
House électronique	32667	36.4
House OCR	48940	54.5
Sénat électronique	6566	7.3
Sénat OCR	1679	1.9

sous-corpus = chambre × voie (électronique déterministe / scan OCR) · n = transactions uniques · part % du total

Couverture des champs enrichis (taux de remplissage)

sous-corpus	n	ticker %	secteur %	ETF %	commission %	identité %	ancienneté %
House électronique	32667	88.7	86.6	86.6	74.7	100.0	100.0
House OCR	48940	83.1	81.0	81.0	94.5	100.0	100.0
Sénat électronique	6566	79.3	71.3	71.3	62.5	100.0	100.0
Sénat OCR	1679	33.2	19.4	19.4	96.1	100.0	100.0

% de lignes où le champ est renseigné · identité = rattachée à un `bioguide_id` · ticker/secteur/ETF vides = actif non coté (normal, pas un défaut)

Scorecard de qualité

sous-corpus	n	dates cohérentes %	date plausible %	année aberrante (n)	montant renseigné %
House électronique	32667	99.9	86.8	0	100.0
House OCR	48940	99.7	95.4	0	98.2
Sénat électronique	6566	100.0	92.5	0	100.0
Sénat OCR	1679	99.8	98.5	0	99.6

dates cohérentes = divulgation ≥ transaction · date plausible = transaction ∈ [0, 75 j] avant divulgation · année aberrante = année impossible (postérieure au dépôt, ou < 2012) · montant renseigné = `amount_midpoint` non vide

Mix par sous-corpus

Sens des opérations :

sous-corpus	n	achat %	vente %	échange %	autre %
House électronique	32667	49.7	49.7	0.6	0.0
House OCR	48940	52.7	46.6	0.7	0.0
Sénat électronique	6566	48.6	50.5	0.9	0.0
Sénat OCR	1679	54.0	45.8	0.2	0.0

achat = `operation_type` contient « Purchase » · vente = contient « Sale » (**includ Sale (Partial) et (Full)**) · échange = « Exchange » · autre = reste

Détenteur déclaré :

sous-corpus	n	perso %	conjoint %	joint %	enfant %	autre %
House électronique	32667	51.9	19.7	26.2	2.2	0.0
House OCR	48940	6.7	51.1	7.0	35.2	0.0
Sénat électronique	6566	15.7	41.4	40.1	2.9	0.0
Sénat OCR	1679	26.9	73.0	0.1	0.1	0.0

titulaire du compte : perso = Self · conjoint = Spouse/SP · joint = Joint/JT · enfant = Dependent/Child/DC · autre = reste ou non déclaré

Familles d'actifs (le non-coté — oblig. d'État, munis, obligations — domine l'OCR du Sénat) :

sous-corpus	n	action %	option %	oblig. État %	muni %	oblig. corp. %	fonds %	autre %	manquant %
House électronique	32667	84.6	1.8	5.9	0.0	0.0	0.0	6.1	1.6
House OCR	48940	81.7	0.0	0.8	0.0	0.1	3.1	0.6	13.8
Sénat électronique	6566	67.2	9.1	0.0	10.8	3.0	0.0	10.0	0.0
Sénat OCR	1679	12.9	0.0	0.0	0.8	2.6	0.0	69.6	14.2

familles d'asset_type : action = Stock · option · oblig. État = Gov/Treasury · muni = Municipal · oblig. corp. = Bond · fonds = Fund/ETF · manquant = vide

Secteurs & sources de résolution

sous-corpus	n	secteur renseigné %	ETF %	top 3 secteurs
House électronique	32667	86.6	86.6	Information Technology 20%, Financials 14%, Health Care 13%
House OCR	48940	81.0	81.0	Information Technology 20%, Financials 16%, Health Care 14%
Sénat électronique	6566	71.3	71.3	Information Technology 22%, Financials 16%, Consumer Discretionary 10%
Sénat OCR	1679	19.4	19.4	Financials 21%, Communication Services 18%, Information Technology 12%

secteur renseigné % / ETF % = taux de remplissage (vide = non coté) · top 3 = secteurs GICS dominants

Origine du ticker (ticker_source — comment le ticker a été obtenu) :

sous-corpus	n	dico élec %	LLM %	explicite %	aucune %
House électronique	32667	0.0	0.0	88.7	11.3
House OCR	48940	45.6	36.2	1.3	16.9
Sénat électronique	6566	0.5	0.7	77.1	20.7
Sénat OCR	1679	9.5	8.3	15.4	66.8

comment le ticker est obtenu : dico élec = repris de l'électronique · LLM = résolu par LLM · explicite = déjà présent dans la source · aucune = non résolu

Origine du secteur (sector_source) :

sous-corpus	n	yfinance %	LLM %	manuel %	aucune %
House électronique	32667	78.7	7.8	0.2	13.3
House OCR	48940	75.4	5.6	0.1	18.9
Sénat électronique	6566	62.1	9.0	0.9	28.0
Sénat OCR	1679	12.0	7.4	1.1	79.5

comment le secteur GICS est obtenu : yfinance = base factuelle · LLM · manuel = correction d'audit · aucune

Montants par sous-corpus

sous-corpus	n	médiane \$	moyenne \$	P25_\$	P75_\$	P95_\$	volume total M\$
House électronique	32667	8000	53307	8000	15001	100001	1741.4
House OCR	48940	8000	49627	8000	32500	175000	2386.0
Sénat électronique	6566	8000	100115	8000	32500	375000	657.4
Sénat OCR	1679	32500	171021	8000	75000	750000	285.9

\$ = midpoint des fourchettes déclarées · P25/P75/P95 = percentiles · volume total = Σ midpoint

la plus petite tranche (≤ 15 k\$, midpoint 8 000 \$) domine → dès qu'elle dépasse 50 %, le P25 ET la médiane y tombent ensemble (cas House/Sénat élec). Sénat OCR < 50 % → médiane 32 500 ≠ P25 8 000.

Concentration de l'activité

sous-corpus	n déposants	HHI	Gini	top10 volume %
House électronique	234	662.7	0.877	68.8
House OCR	40	2888.3	0.913	98.7
Sénat électronique	61	1269.1	0.835	84.6
Sénat OCR	5	6388.7	0.695	100.0

HHI ∈ [0, 10000] et Gini ∈ [0, 1] mesurent la concentration du volume par déposant (plus c'est haut, plus quelques déposants dominant).

Top tickers par volume estimé :

ticker	n trades	volume M\$
MSFT	1011	261.3
ICE	110	93.4
BRP	7	81.8
AAPL	739	80.4
MET	114	76.2
T	338	63.1
NVDA	594	46.1
DFS	66	42.9
AMZN	684	42.3
HBI	65	38.3
GOOGL	599	29.8
ADBE	381	23.2
AVGO	269	18.1
PYPL	355	17.0
AESI	5	15.9

volume M\$ = Σ midpoint des trades du ticker · n trades = nombre de transactions

Volume par secteur GICS :

secteur	n trades	volume M\$
Information Technology	14315	725.9
Financials	10981	520.7
Communication Services	5593	263.1
Consumer Discretionary	8309	259.7
Health Care	9495	229.7
Industrials	8476	196.8
Energy	3077	141.5
Consumer Staples	5137	138.5
Materials	2898	61.8
Real Estate	2729	53.6
Utilities	1274	30.5

2. Cohérence des dates (disclosure_date ≥ transaction_date)

chambre	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
house	81607	99.8	99.8	154	0	177
senate	8245	99.9	100.0	3	0	7

Par sous-corpus :

sous-corpus	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
House électronique	32667	100.0	99.9	18	0	0
House OCR	48940	99.6	99.7	136	0	177
Sénat électronique	6566	100.0	100.0	0	0	0
Sénat OCR	1679	99.6	99.8	3	0	7

dates exploitables = dates parseables (le reste = OCR illisible) · cohérentes = divulgation ≥ transaction · incohérentes = divulgation AVANT transaction (amendement/antidaté) · année aberrante = année impossible (postérieure au dépôt, ou < 2012) · date manquante = illisible. Des transactions 2013–2019 sont légitimes (divulgations tardives).

Audit des anomalies (échantillon de 12 PDF re-lus à la source). ~½ sont FIDÈLES : coquilles du **déposant lui-même** (un PTR imprime littéralement 01/35/22), cellules vides ou parts de société sans date de transaction — on les transcrit sans les inventer. ~⅓ = **notre OCR** (mois/jour mal lu), corrigé à la lecture **quand le formulaire est lisible** (4 dates vérifiées, clé doc+date, figé inchangé). ~⅓ = **provenance** (hallucination OCR ou pièce jointe absente du PDF). **On ne fabrique aucune date** : les illisibles restent flaggées.

3. Délai légal de divulgation (STOCK Act ~45 j)

chambre	n dates valides	≤45j légal %	45–75j %	>75j %	négatif %	délai médian (j)
house	81430	87.0	5.2	7.7	0.2	28
senate	8238	91.0	2.8	6.2	0.0	27

Par sous-corpus :

sous-corpus	n dates valides	≤45j légal %	45–75j %	>75j %	négatif %	délai médian (j)
House électronique	32667	81.9	4.9	13.2	0.1	28
House OCR	48763	90.3	5.4	4.0	0.3	28
Sénat électronique	6566	90.6	1.9	7.5	0.0	26
Sénat OCR	1672	92.4	6.5	0.9	0.2	29

n dates valides = transactions dont le délai est CALCULABLE (les deux dates, transaction ET divulgation, présentes et lisibles ; « valide » = mesurable, pas « juste ») · délai = divulgation – transaction (jours) · ≤45 j = délai légal STOCK Act · 45–75 j = marge tolérée · >75 j = retard · négatif = anomalie (divulgation avant transaction), comptée quand même dans n dates valides · délai médian en jours

Divulgations les plus tardives (> 365 j, suspects) :

déposant	chambre	date txn	date divulg.	délai (j)	ticker	opération
Jefferson Shreve	house	2015-05-08	2025-06-22	3698.0	DHR	Purchase
Jefferson Shreve	house	2015-05-08	2025-06-22	3698.0	DAL	Purchase
Richard W. Allen	house	2017-02-03	2023-08-10	2379.0		Purchase
Richard W. Allen	house	2017-02-13	2023-08-10	2369.0	O	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331.0	BBT	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331.0	BBT	Sale (Partial)
Richard W. Allen	house	2017-04-27	2023-08-10	2296.0	XOM	Sale
Richard W. Allen	house	2017-04-27	2023-08-10	2296.0	COST	Purchase
Richard W. Allen	house	2017-05-16	2023-08-10	2277.0	GE	Sale
Richard W. Allen	house	2017-05-16	2023-08-10	2277.0	FDX	Purchase
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	PCLN	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	DFS	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	CME	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	FB	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	KMX	Sale

délai (j) = divulgation – transaction · divulgations > 1 an après la transaction (souvent des amendements ou de vieux comptes régularisés)

4. Distribution des montants (amount_midpoint)

Stats globales (USD, midpoint des fourchettes déclarées) :

count	88982.0
mean	56985.0
std	595298.0
min	1.0
25%	8000.0
50%	8000.0
75%	32500.0
90%	75000.0
max	75000000.0

Par chambre :

	count	mean	std	min	25%	50%	75%	max
chamber								
house	80744.0	51116.0	569184.0	1.0	8000.0	8000.0	32500.0	75000000.0
senate	8238.0	114506.0	805522.0	8000.0	8000.0	8000.0	32500.0	50000000.0

Par sous-corpus :

	count	mean	std	min	25%	50%	75%	max
corpus								
House électronique	32667.0	53307.0	522013.0	1.0	8000.0	8000.0	15001.0	37500000.0
House OCR	48077.0	49628.0	599121.0	8000.0	8000.0	8000.0	32500.0	75000000.0
Sénat électronique	6566.0	100115.0	632303.0	8000.0	8000.0	8000.0	32500.0	15000000.0
Sénat OCR	1672.0	171021.0	1274262.0	8000.0	8000.0	32500.0	75000.0	50000000.0

count = nb · mean = moyenne · std = écart-type · 25/50/75 % = quartiles · USD (midpoint des fourchettes déclarées)

Top 15 déposants par volume estimé (Σ midpoint) :

déposant	chambre	n trades	volume estimé M\$
Michael T. McCaul	house	10738	974.5
Rohit Khanna	house	30516	667.8
Diana Harshbarger	house	3124	464.5
Darrell E. Issa	house	20	250.5
RICHARD BLUMENTHAL	senate	1226	221.3
Josh Gottheimer	house	2942	209.4
Jefferson Shreve	house	631	191.7
Scott Franklin	house	68	182.1
Rick Scott	senate	266	167.2
Nancy Pelosi	house	147	139.6
Suzan K. DelBene	house	406	125.9
Kelly Loeffler	senate	329	120.9
David H McCormick	senate	293	69.0
Scott H. Peters	house	334	64.6
Kevin Hern	house	760	60.1

volume estimé M\$ = Σ midpoint des transactions du déposant · n trades = nombre de transactions

5. Couverture par déposant & structure de l'activité

320 déposants distincts. **206** ont ≥ 10 transactions (éligibles au backtest), dont **150** actifs sur ≥ 3 années.

Top 20 déposants (transactions, OCR%, années actives) :

nom	total	dont OCR	OCR %	n années	1re année	dern. année
Rohit Khanna	30862	30862	100	8	2019	2026
Michael T. McCaul	10850	10850	100	7	2020	2026
Diana Harshbarger	3515	3514	100	4	2021	2026
Josh Gottheimer	2942	0	0	8	2019	2026
Gilbert Cisneros	2153	0	0	4	2019	2026
David P. Roe	1686	1686	100	1	2020	2020
Lisa McClain	1532	109	7	3	2024	2026
Thomas H Tuberville	1369	0	0	5	2021	2025
Daniel Goldman	1291	0	0	2	2023	2025
RICHARD BLUMENTHAL	1232	1232	100	8	2019	2026
Thomas R Carper	923	0	0	6	2019	2024
Susie Lee	857	0	0	8	2019	2026
Donald Sternoff Beyer	822	0	0	8	2019	2026
Kathy Manning	803	0	0	5	2021	2025
JOHN BOOZMAN	768	379	49	8	2019	2026
Thomas Suozzi	765	20	3	9	2017	2026
Kevin Hern	760	0	0	8	2019	2026
Alan S. Lowenthal	676	0	0	4	2019	2022
Lois Frankel	656	0	0	5	2019	2023
Mark Green	653	0	0	6	2020	2025

total = nb transactions · dont OCR / OCR % = part scannée · n années = années actives · 1re/dern. année = première/dernière année de transaction

Achats sans sortie déclarée (pour la stratégie)

Achats (avec ticker) sans vente ultérieure déclarée par le même membre sur le même ticker → positions qui seraient fermées de force à +12 mois dans la stratégie.

chambre	achats (avec ticker)	avec sortie	sans sortie %
house	34562	26783	22.5
senate	2468	1502	39.1

Par sous-corpus :

sous-corpus	achats (avec ticker)	avec sortie	sans sortie %
House électronique	14010	8288	40.8
House OCR	20552	18495	10.0
Sénat électronique	2301	1373	40.3
Sénat OCR	167	129	22.8

achats (avec ticker) · avec sortie = vente ultérieure du même ticker par le même membre · sans sortie % = position jamais fermée

6. Complétude vs Quiver (vérité-terrain externe)

Section clé. On confronte tous les trades Quiver de notre fenêtre aux nôtres, par **strictesse croissante** : inclusion date-agnostique (Quiver ⊆ nous, on est même plus complet) → réconciliation date-ancrée au trade près → verdicts actionnables. Chiffres recalculés par `common/quiver_diagnosis.py`, **jamais réinjectés**.

6.1 Méthode & périmètre

Chaque transaction est confrontée à Quiver par une clé normalisée, sur **deux lentilles de stricte** **se croissante** : l'**inclusion date-AGNOSTIQUE** (a-t-on le trade ? §6.2), puis la **réconciliation date-ANCRÉE** (le même trade, à la même date ? §6.3).

élément	définition
univers comparé	tous les trades Quiver Filed ∈ 2020–2026 (notre fenêtre de scrape)
clé d'appariement	(<code>bioguide</code> , ticker normalisé, sens) + date pour la réconciliation ; SANS date pour l'inclusion
normalisation ticker	MAJ + trim ; rejette {vide, NAN, NONE, --} ; retire PUT / CALL ; . / - → <code>_</code>
normalisation sens	1re lettre p/s/e → Purchase / Sale / Exchange
lentille 1 — inclusion (§6.2)	clé SANS date → « a-t-on tout ce que Quiver a » (complétude)
lentille 2 — réconciliation (§6.3)	appariement 1-à-1 ancré au dépôt → exact / proche / candidat / nous-seul / quiver-seul

Réf. : `house/quiver.py` (`norm_ticker`, `norm_sense`), `common/quiver_diagnosis.py` (*recalcul offline, jamais réinjecté*).

Périmètre comparé — le FINAL est dédoublé cross-année avant comparaison (une re-divulgateion tardive ne compte qu'une fois) :

chambre	lignes brutes	re-divulgations (dédup)	transactions uniques
house	81642	35	81607
senate	8841	596	8245
TOTAL	90483	631	89852

6.2 Inclusion & complétude nette (date-agnostique)

Quiver ⊆ nous. Dans notre fenêtre, on retrouve **93.8 % (House)** et **91.5 % (Sénat)** des trades Quiver au niveau (déposant, ticker, sens). Le **vrai trou coté** est minuscule (22 House / 0 Sénat) ; le reste du résidu est récupérable ou hors périmètre :

chambre	trades Quiver (fenêtre)	qu'on a	inclusion %	résidu	dont OCR récup.	dont non-coté	dont 2-jambes	dont autre chambre	vrai trou coté
house	17481	16397	93.8	1084	974	88	0	0	22
senate	2587	2366	91.5	221	0	0	21	200	0

Légende du résidu : **OCR récup.** = lignes papier ratées (re-OCR ciblé) · **non-coté** = « ticker » Quiver non appariable (CUSIP, préférentielle, fragment) · **2-jambes** = on a le trade sous un ticker d'échange (« PFE VTRS » couvre « PFE ») · **autre chambre** = déposant Rep→Sén dont les trades Chambre polluent le cache Sénat de Quiver · **vrai trou coté** = le seul manque réel.

Bilan net — actions cotées qu'on a et que Quiver n'a PAS vs vrais trous inverses (même lentille date-agnostique) → on est un **sur-ensemble** de Quiver :

chambre	actions qu'on a en +	vrais trous	solde net
house	6206	10	6196
senate	680	3	677

6.3 Réconciliation transaction-par-transaction (date-ancrée)

On descend au trade près : on **apparie 1-à-1** nos trades à ceux de Quiver par (déposant, ticker, sens), ancré au dépôt (disclosure ≈ Filed), date exacte puis plus proche. Chaque trade tombe dans **une** catégorie (une comparaison ensembliste, elle, sous-compterait dès qu'un titre est tradé plusieurs jours — elle ne sait pas appariar N à M) :

chambre	apparié exact	apparié proche (≤7j)	candidat écart	dont même dépôt	nous-seul	quiver-seul	candidat %
house	43250	467	1764	414	21699	4708	2.6
senate	4361	0	0	0	1202	385	0.0

apparié exact = même date · *apparié proche* = même trade à ≤ 7 j (bruit/convention de date) · *candidat écart* = paire à 7–90 j à inspecter · *dont même dépôt* = candidats dans le MÊME PTR (seul signal fort) · *nous-seul* = Quiver n'a PAS le trade (on est plus complet) · *quiver-seul* = on a raté.

Pourquoi ces nombres diffèrent du §6.2 — niveau de stricte **se croissante**. Au niveau (déposant, ticker, sens) *date-agnostique* (§6.2), le vrai trou coté est 22/0 ; au niveau *transaction date-ancrée* (ici), on compte 21699 trades « nous-seul » — normal, on trade plus souvent que Quiver ne capte au trade près. Les deux disent la même chose : **on est plus complet**.

6.4 Candidats d'écart de date (même dépôt)

Les **seuls** candidats honnêtes d'erreur de date sont ceux **dans un même dépôt** (414 House / 0 Sénat). Même là, prudence : un petit delta peut être une **convention de date Quiver**, pas notre erreur. Le **vrai contrôle des dates reste l'audit PDF (§2)** — Quiver, lui, n'a souvent pas le trade (« nous-seul ») ou le date autrement. doc_id = pièce consultable :

chambre	déposant	ticker	sens	notre date	date Quiver	delta (j)	doc_id
house	Rohit Khanna	SEE	Sale	2020-05-28	2020-05-20	8	8217329
house	Rohit Khanna	A	Sale	2021-09-28	2021-09-20	8	8218398
house	Rohit Khanna	PPL	Sale	2020-03-13	2020-03-05	8	8217164
house	Rohit Khanna	MRK	Purchase	2020-07-28	2020-07-20	8	8217557
house	Rohit Khanna	HLT	Sale	2020-07-31	2020-07-23	8	8217557
house	Rohit Khanna	F	Purchase	2020-02-03	2020-02-11	8	8217060
house	Rohit Khanna	TRGP	Sale	2020-02-19	2020-02-11	8	8217060
house	Rohit Khanna	SYK	Purchase	2020-07-29	2020-07-21	8	8217557
house	Rohit Khanna	ALB	Sale	2020-02-11	2020-02-19	8	8217060
house	Rohit Khanna	LEA	Sale	2022-04-21	2022-04-13	8	8218730
house	Rohit Khanna	KEYS	Sale	2020-05-28	2020-05-20	8	8217329
house	Rohit Khanna	VMC	Sale	2022-04-11	2022-04-03	8	8218730

(Top 12 par delta croissant ; les 414 candidats sont dans quiver_validation/candidats_ecart_date_meme_depot.csv.)

6.5 Verdicts actionnables

Chaque transaction reçoit un verdict (côté nous et côté Quiver) pour trier ce qui est **à corriger**. ecart_brut_pct (ECART_DATE + ECART_TICKER) **n'est PAS un taux d'erreur** : l' ECART_DATE est décomposé honnêtement au §6.3 (surtout « nous-seul » / convention de date), et nos tickers concordent avec la description d'actif.

Synthèse côté **NOUS** (part de NOS transactions par catégorie) :

chambre	nos txns	concordant %	écart brut %	structurel %	on est + complet %
house	81607	61.4	18.6	12.4	7.6
senate	8245	59.7	2.1	30.0	8.2

Verdicts nous→Quiver :

côté	verdict	n	%	à corriger
nous→Quiver (house)	CONCORDANT	50075	61.4	False
nous→Quiver (house)	ECART_DATE	9628	11.8	True
nous→Quiver (house)	ECART_TICKER	5539	6.8	True
nous→Quiver (house)	STRUCTUREL	10159	12.4	False
nous→Quiver (house)	ON_EST_PLUS_COMPLET	6206	7.6	False
nous→Quiver (senate)	CONCORDANT	4922	59.7	False
nous→Quiver (senate)	ECART_DATE	100	1.2	True
nous→Quiver (senate)	ECART_TICKER	71	0.9	True
nous→Quiver (senate)	STRUCTUREL	2472	30.0	False
nous→Quiver (senate)	ON_EST_PLUS_COMPLET	680	8.2	False

Verdicts Quiver→nous (only_quiver) — NOTRE_MANQUE = le seul vrai trou coté (résiduel après filtrage du non-coté), les autres s'expliquent par la date, le ticker, ou du papier :

côté	verdict	n	%	à corriger
Quiver→nous (house)	ECART_DATE	3418	49.2	True
Quiver→nous (house)	ECART_TICKER	2317	33.4	True
Quiver→nous (house)	MANQUANT_PAPIER	1066	15.4	True
Quiver→nous (house)	NON_COTE	132	1.9	False
Quiver→nous (house)	NOTRE_MANQUE	10	0.1	True
Quiver→nous (senate)	ECART_TICKER	22	88.0	True
Quiver→nous (senate)	NOTRE_MANQUE	3	12.0	True

Accord sur les trades qu'on a **TOUS LES DEUX** (cellules bio×ticker×date, par appartenance ensembliste) — un désaccord = vraie erreur d'extraction, typée dans desaccord_champ_*.csv :

chambre	n paires	accord sens %	accord montant %
house	52259	95.8	93.1
senate	4932	99.8	99.7

Top déposants **NOTRE_MANQUE** (les rares vrais trous, à investiguer) :

chambre	bioguide	nom	n trous
house	B001327	Rob Bresnahan	5
house	P000197	Nancy Pelosi	2
house	J000307	John James	1
house	S000168	Maria Elvira Salazar	1
house	W000797	Debbie Wasserman Schultz	1
senate	M001198	Roger W Marshall	3

6.6 Annexe figée : cross-check exact-date (tables historiques)

Vue **exact-date** issue des tables **figées** du pipeline. Le rapport ne lit que 07c/07g/07h ; les autres (07/07b/07d/07e/07f/06d) sont des sorties **historiques** du pipeline, gardées pour la lignée/régression. Cette vue **sous-compte par construction** (exact-date ensembliste, cf. §6.3). couverture % = part des trades Quiver retrouvés à la date exacte.

Couverture par scope et chambre :

chambre	scope	appariés	Quiver	nous seul	Quiver seul	couverture %
house	both	43279.0	50221.0	13482.0	6942.0	86.2
house	digital	25784.0	26252.0	415.0	468.0	98.2
house	ocr	17583.0	25743.0	13067.0	8160.0	68.3
senate	both	4324.0	4349.0	544.0	25.0	99.4
senate	digital	4324.0	4349.0	405.0	25.0	99.4
senate	ocr	0.0	15.0	64.0	15.0	0.0

Couverture / precision par année (scope both) :

chambre	année	appariés	Quiver	couverture %	precision %
house	2020	7115	8359	85.1	75.0
house	2021	5222	5893	88.6	63.2
house	2022	6075	7513	80.9	60.2
house	2023	6128	7567	81.0	84.7
house	2024	4670	5442	85.8	79.7
house	2025	9836	10773	91.3	90.8
house	2026	4233	4674	90.6	84.9
senate	2020	1251	1259	99.4	93.6
senate	2021	398	406	98.0	64.1
senate	2022	636	640	99.4	96.1
senate	2023	682	684	99.7	88.2
senate	2024	558	560	99.6	97.7
senate	2025	520	521	99.8	88.0
senate	2026	279	279	100.0	89.1

Par type d'actif (non-coté = muni/obligation, hors périmètre Quiver-actions) — House :

type d'actif	exact (date)	date ≠	absent	non-coté	total	Quiver a le trade %
Stock	47475	9301	8105	2796	67677	87.5
(inconnu)	1704	211	1015	4345	7275	65.4
Gov Security	5	0	23	2259	2287	17.9
Mutual Fund	130	92	715	575	1512	23.7
Other	161	14	7	810	992	96.2
CS	56	1	1	724	782	98.3
Option	492	7	83	0	582	85.7
HN	5	0	0	134	139	100.0
PS	6	0	0	103	109	100.0
Other Investment	2	0	0	61	63	100.0
CT	5	0	0	52	57	100.0
VA	0	0	0	40	40	
AB	14	0	1	24	39	93.3
Corporate Bond	3	2	0	32	37	100.0
OL	5	0	0	28	33	100.0
ET	16	0	0	0	16	100.0
RS	1	1	0	1	3	100.0
SA	1	0	0	2	3	100.0

— Sénat (l'OCR y est surtout du non-coté) :

type d'actif	exact (date)	date ≠	absent	non-coté	total	Quiver a le trade %
Stock	4071	105	783	68	5027	84.2
Other	350	21	158	1283	1812	70.1
Municipal Security	0	4	7	755	766	36.4
Option	421	10	23	63	517	94.9
Corporate Bond	1	3	54	188	246	6.9
(inconnu)	0	8	206	25	239	3.7
Commodities/Futures Contract	0	0	0	87	87	
Stock Option	75	0	2	3	80	97.4
Non-Public Stock	0	0	2	58	60	0.0
Cryptocurrency	4	0	2	1	7	66.7

Profil des clusters de scan (House OCR) — A = tapé droit, B = tapé tourné, C = manuscrit :

cluster	n lignes	n docs	date plausible %	ticker %	Quiver a le trade %
A_tape_droit	5957	59	99.6	84.2	88.0
B_tape_tourne	42125	295	94.7	82.9	77.9
C_manuscrit	858	80	97.4	88.5	35.3

date plausible % et ticker % = qualité INTERNE (calculée sans Quiver) · Quiver a le trade % = part de nos trades cotés que Quiver possède AUSSI, appariée sur (membre + ticker + sens), que la date coïncide OU non ; le complément (100 – %) = « absent » côté Quiver.

Sur le manuscrit (C), la qualité interne reste haute (voir date plausible % / ticker %) mais Quiver a le trade % s'effondre. L'appariement étant **date-agnostique**, ce décrochage vient du **ticker/identité mal lus** (ou d'un Quiver mince sur le papier manuscrit), **pas des dates**. Faute de pouvoir **confirmer** le manuscrit contre la vérité-terrain, on l'**exclut par défaut** — choix conservateur, pas « le manuscrit est faux ».

Décomposition en buckets par cluster — sur le manuscrit l' absent domine (ticker/identité) et l' exact (date) s'effondre davantage encore (OCR des dates) ; sur le tapé (A/B), Quiver a le trade % reste élevé :

cluster	exact (date)	date #	absent	non-coté	total	Quiver a le trade %
B_tape_tourne	18558	8653	7706	7234	42151	77.9
A_tape_droit	3784	630	600	943	5957	88.0
C_manuscrit	100	169	493	100	862	35.3

Listes actionnables complètes (ligne à ligne) → docs/quiver_validation/ (ecart_ticker_, notre_manque_, manquant_papier_, desaccord_champ_[typé], on_est_plus_complet_, quiver_non_cote_, candidats_ecart_date_meme_depot). Hors golden.