

Rapport qualité — Données de trading du Congrès américain

Chambre des représentants + Sénat · 2020–2026 · généré par `python -m common.quality` (lecture seule des tables FINAL, aucun appel API) · Quiver Quantitative = vérité-terrain externe, **jamais réinjectée**. Les % sont arrondis à 0,1 pt ; une somme de colonnes peut afficher 100,1.

Résumé exécutif

- Périmètre** — 89 852 transactions uniques de membres élus (House 81 607 + Sénat 8 245), 2020–2026, en **4 sous-corpus** (chambre × voie d'acquisition : électronique déterministe / scan OCR).
- Complétude vs Quiver** (§6) — dans notre fenêtre, on retrouve **93.9 % (House) / 91.5 % (Sénat)** des trades Quiver au niveau (déposant, ticker, sens). Le **trou coté est minuscule** — ≤ 22 House / 0 Sénat au niveau ticker (borne haute), dont **10 / 3 vrais trous confirmés au trade près** (§6.5) ; le reste du résidu est de l'OCR récupérable ou du hors-périmètre.
- On est plus complet que Quiver** — **+6945 actions cotées qu'on a et que Quiver n'a pas, contre 13 trous inverses**. La base est, en pratique, un **sur-ensemble** de Quiver.
- Les « écarts » de date ne sont pas des erreurs** — la réconciliation 1-à-1 (§6.3) montre que l'essentiel est du « nous-seul » (Quiver n'a pas le trade) ; seuls 288 candidats House (même déclaration) méritent l'œil, et le vrai contrôle des dates reste l'audit PDF (§3).
- Données propres** — identité rattachée à 100.0 %, dates cohérentes 99.8 %, délai de divulgation médian 28 j, montants renseignés 99.0 %.

Plan : §1 construction & validation · §2 composition & complétude · §3 qualité des dates · §4 montants · §5 activité & concentration · §6 complétude vs Quiver (vérité-terrain).

1. Construction & validation du corpus

Avant toute statistique, voici **comment le corpus est construit**, dans l'ordre :

- Sources** — déclarations officielles : Chambre (*PTR*) et Sénat (*eFD*), chacune en deux voies — **électronique** (formulaire structuré, lecture déterministe) et **papier scanné** (PDF → **OCR** par modèle de vision).
- Extraction** — une ligne = une transaction (membre, date, actif, sens, fourchette de montant, détenteur).
- Enrichissement** — ticker (explicite dans la source · repris de l'électronique · résolu par LLM), secteur GICS (yfinance · LLM), identité (*bioguide_id*), ancienneté.
- Déduplication cross-année** — une même transaction re-divulguée une autre année (amendement, rapport annuel) ne compte qu'**une fois** (clé naturelle + rang d'occurrence).

Réconciliation — des lignes brutes aux transactions uniques (c'est notre corpus, pas Quiver) :

chambre	lignes brutes	re-divulgations (dédup)	transactions uniques
house	81642	35	81607
senate	8841	596	8245
TOTAL	90483	631	89852

lignes brutes = FINAL concaténé 2020–2026 · *re-divulgations* = doublons cross-année retirés · *transactions uniques* = le corpus analysé dans tout ce rapport

Validation & reproductibilité

Tout est **rejouable hors-ligne** (lecture seule des tables FINAL, **0 appel API**), adossé à trois filets automatiques :

- Golden octet-à-octet** — 201 tables CSV figées par SHA256 (125 House + 76 Sénat), rejouées à **zéro écart** (`tests/regression/check_golden.py`, `senate_check_golden.py`).
- Invariants porteurs** — pour chaque chambre `digital + OCR = FINAL`, identité rattachée à **100.0 %**, 256 bioguides (House) / 64 (Sénat) recomptés (`tests/regression/audit_metrics.py`).
- Transformations déterministes** — 11 tests reproduisent chaque étape (clé naturelle, montants, tickers, identité, ancienneté, cache Vision) depuis les colonnes figées.

Les quatre sous-corpus

Toute la suite distingue **quatre familles** (chambre × voie), car leur qualité et leur composition diffèrent :

sous-corpus	n	part %
House électronique	32667	36.4
House OCR	48940	54.5
Sénat électronique	6566	7.3
Sénat OCR	1679	1.9

sous-corpus = chambre × voie (électronique déterministe / scan OCR) · *n* = transactions uniques · *part %* du total


2. Composition & complétude

Ce que contient le **corpus** (opérations, détenteur, familles d'actifs), puis à quel point les champs sont remplis.

Sens des opérations

sous-corpus	n	achat %	vente %	échange %	autre %
House électronique	32667	49.7	49.7	0.6	0.0
House OCR	48940	52.7	46.6	0.7	0.0
Sénat électronique	6566	48.6	50.5	0.9	0.0
Sénat OCR	1679	54.0	45.8	0.2	0.0

achat = *operation_type* contient « Purchase » · *vente* = contient « Sale » (**includ Sale (Partial) et (Full)**) · *échange* = « Exchange » · *autre* = reste



Détenteur déclaré

sous-corpus	n	perso %	conjoint %	joint %	enfant %	autre %
House électronique	32667	51.9	19.7	26.2	2.2	0.0
House OCR	48940	6.7	51.1	7.0	35.2	0.0
Sénat électronique	6566	15.7	41.4	40.1	2.9	0.0
Sénat OCR	1679	26.9	73.0	0.1	0.1	0.0


titulaire du compte : perso = Self · conjoint = Spouse/SP · joint = Joint/JT · enfant = Dependent/Child/DC · autre = reste ou non déclaré

Familles d'actifs

Le non-coté (oblig. d'État, munis, obligations) domine l'OCR du Sénat :

sous-corpus	n	action %	option %	oblig. État %	muni %	oblig. corp. %	fonds %	autre %	manquant %
House électronique	32667	84.6	1.8	5.9	0.0	0.0	0.0	6.1	1.6
House OCR	48940	81.7	0.0	0.8	0.0	0.1	3.1	0.6	13.8
Sénat électronique	6566	67.2	9.1	0.0	10.8	3.0	0.0	10.0	0.0
Sénat OCR	1679	12.9	0.0	0.0	0.8	2.6	0.0	69.6	14.2

familles d'asset_type : action = Stock · option · oblig. État = Gov/Treasury · muni = Municipal · oblig. corp. = Bond · fonds = Fund/ETF · manquant = vide



Couverture des champs enrichis (taux de remplissage)

sous-corpus	n	ticker %	secteur %	ETF %	commission %	identité %	ancienneté %	montant renseigné %
House électronique	32667	88.7	86.6	86.6	74.7	100.0	100.0	100.0
House OCR	48940	83.7	81.0	81.0	94.5	100.0	100.0	98.2
Sénat électronique	6566	79.3	71.3	71.3	62.5	100.0	100.0	100.0
Sénat OCR	1679	33.2	19.4	19.4	96.1	100.0	100.0	99.6

% de lignes où le champ est renseigné · identité = rattachée à un bioguide_id · montant renseigné = amount_midpoint non vide · ticker/secteur/ETF vides = actif non coté (normal, pas un défaut)

Secteurs & origine des champs résolus

sous-corpus	n	secteur renseigné %	ETF %	top 3 secteurs
House électronique	32667	86.6	86.6	Information Technology 20%, Financials 14%, Health Care 13%
House OCR	48940	81.0	81.0	Information Technology 20%, Financials 16%, Health Care 14%
Sénat électronique	6566	71.3	71.3	Information Technology 22%, Financials 16%, Consumer Discretionary 10%
Sénat OCR	1679	19.4	19.4	Financials 21%, Communication Services 18%, Information Technology 12%

secteur renseigné % / ETF % = taux de remplissage (vide = non coté) · top 3 = secteurs GICS dominants

Origine du ticker (ticker_source) :


sous-corpus	n	dico élec %	LLM %	nom d'actif %	récupéré %	explicite %	aucune %
House électronique	32667	0.0	0.0	0.0	0.0	88.7	11.3
House OCR	48940	45.6	36.2	0.0	0.6	1.3	16.3
Sénat électronique	6566	0.5	0.7	1.0	0.0	77.1	20.7
Sénat OCR	1679	9.5	8.3	0.0	0.0	15.4	66.8

dico élec = repris de l'électronique · LLM = résolu par LLM · nom d'actif = déduit du nom d'actif · récupéré = rendu par la passe nom→ticker vérifiée (cf. §6.2) · explicite = déjà présent dans la source · aucune = non résolu

Origine du secteur (sector_source) :

sous-corpus	n	yfinance %	LLM %	manuel %	aucune %
House électronique	32667	78.7	7.8	0.2	13.3
House OCR	48940	75.4	5.6	0.1	18.9
Sénat électronique	6566	62.1	9.0	0.9	28.0
Sénat OCR	1679	12.0	7.4	1.1	79.5

yfinance = base factuelle · LLM · manuel = correction d'audit · aucune



3. Qualité des dates

Trois questions, de la plus faible à la plus forte : les dates sont-elles **lisibles et cohérentes** (divulgarion ≥ transaction) ? le **délai légal** (STOCK Act ~45 j) est-il respecté ? reste-t-il des **anomalies** ?

Cohérence (disclosure_date ≥ transaction_date)

chambre	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
house	81607	99.8	99.8	154	0	177
senate	8245	99.9	100.0	3	0	7

Par sous-corpus :

sous-corpus	n	dates exploitables %	cohérentes %	incohérentes	année aberrante	date manquante
House électronique	32667	100.0	99.9	18	0	0
House OCR	48940	99.6	99.7	136	0	177
Sénat électronique	6566	100.0	100.0	0	0	0
Sénat OCR	1679	99.6	99.8	3	0	7

dates exploitables = parseables (% du total ; le reste = OCR illisible) · cohérentes = divulgation ≥ transaction, % **parmi les exploitables** (dénominateur = exploitables, pas le total → ce % peut dépasser « dates exploitables % ») · incohérentes = divulgation AVANT transaction (amendement/antidaté) · année aberrante = année impossible (postérieure au dépôt, ou < 2012) · date manquante = illisible. Des transactions 2013–2019 sont légitimes (divulgations tardives).


Délai légal de divulgation (STOCK Act ~45 j)

chambre	n dates valides	≤45j légal %	45–75j %	>75j %	négatif %	délai médian (j)
house	81430	87.0	5.2	7.7	0.2	28
senate	8238	91.0	2.8	6.2	0.0	27

Par sous-corpus :

sous-corpus	n dates valides	≤45j légal %	45–75j %	>75j %	négatif %	délai médian (j)
House électronique	32667	81.9	4.9	13.2	0.1	28
House OCR	48763	90.3	5.4	4.0	0.3	28
Sénat électronique	6566	90.6	1.9	7.5	0.0	26
Sénat OCR	1672	92.4	6.5	0.9	0.2	29

n dates valides = transactions dont le délai est CALCULABLE (les deux dates présentes et lisibles ; « valide » = mesurable, pas « juste ») · délai = divulgation – transaction (j) · ≤45 j = délai légal STOCK Act · 45–75 j = marge tolérée · >75 j = retard · négatif = anomalie (divulgation avant transaction), comptée dans n dates valides · délai médian en j



Divulgations les plus tardives (> 365 j)

déposant	chambre	date txn	date divulg.	délai (j)	ticker	opération
Jefferson Shreve	house	2015-05-08	2025-06-22	3698.0	DHR	Purchase
Jefferson Shreve	house	2015-05-08	2025-06-22	3698.0	DAL	Purchase
Richard W. Allen	house	2017-02-03	2023-08-10	2379.0		Purchase
Richard W. Allen	house	2017-02-13	2023-08-10	2369.0	O	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331.0	BBT	Sale
Richard W. Allen	house	2017-03-23	2023-08-10	2331.0	BBT	Sale (Partial)
Richard W. Allen	house	2017-04-27	2023-08-10	2296.0	XOM	Sale
Richard W. Allen	house	2017-04-27	2023-08-10	2296.0	COST	Purchase
Richard W. Allen	house	2017-05-16	2023-08-10	2277.0	GE	Sale
Richard W. Allen	house	2017-05-16	2023-08-10	2277.0	FDX	Purchase
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	PCLN	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	DFS	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	CME	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	FB	Sale
Thomas Suozzi	house	2017-01-05	2022-12-19	2174.0	KMX	Sale

délai (j) = divulgation – transaction · divulgations > 1 an après la transaction (souvent des amendements ou de vieux comptes régularisés)


Audit des anomalies (échantillon de 12 PDF re-lus à la source). ~½ sont FIDÈLES : coquilles du **déposant lui-même** (un PTR imprime littéralement 01/35/22), cellules vides ou parts de société sans date de transaction — on les transcrit sans les inventer. ~⅓ = **notre OCR** (mois/jour mal lu), corrigé à la lecture **quand le formulaire est lisible** (4 dates vérifiées, clé doc+date, figé inchangé). ~⅙ = **provenance** (hallucination OCR ou pièce jointe absente du PDF). **On ne fabrique aucune date** : les illisibles restent flaggées.

4. Montants (amount_midpoint)

Le montant = **midpoint** de la fourchette déclarée (les déclarations donnent des tranches, pas un chiffre exact). Vue par sous-corpus :


sous-corpus	n	médiane \$	moyenne \$	P25 \$	P75 \$	P95 \$	volume total M\$
House électronique	32667	8000	53307	8000	15001	100001	1741.4
House OCR	48940	8000	49627	8000	32500	175000	2386.0
Sénat électronique	6566	8000	100115	8000	32500	375000	657.4
Sénat OCR	1679	32500	171021	8000	75000	750000	285.9

médiane/moyenne/P25/P75/P95 en \$ · volume total = Σ midpoint (M\$) · midpoint = milieu de la fourchette déclarée



la plus petite tranche (≤ 15 k\$, midpoint 8 000 \$) domine → dès qu'elle dépasse 50 %, le P25 ET la médiane y tombent ensemble (cas House/Sénat élec). Sénat OCR < 50 % → médiane 32 500 ≠ P25 8 000.

Ensemble — 88 982 montants renseignés · médiane 8 000 \$ · moyenne 56 985 \$ · P90 75 000 \$ · max 75 000 000 \$.




5. Activité & concentration

Qui trade, à quel point l'activité est concentrée, et ce que deviennent les positions.

Concentration du volume

sous-corpus	n déposants	HHI	Gini	top10 volume %
House électronique	234	662.7	0.877	68.8
House OCR	40	2888.3	0.913	98.7
Sénat électronique	61	1269.1	0.835	84.6
Sénat OCR	5	6388.7	0.695	100.0

HHI ∈ [0, 10000] et Gini ∈ [0, 1] mesurent la concentration du volume par déposant (plus c'est haut, plus quelques déposants dominent).



Où va le volume

Top tickers par volume estimé :

ticker	n trades	volume M\$
MSFT	1014	261.3
ICE	110	93.4
BRP	7	81.8
AAPL	741	80.4
MET	114	76.2
T	338	63.1
NVDA	594	46.1
DFS	66	42.9
AMZN	684	42.3
HBI	65	38.3
GOOGL	599	29.8
ADBE	381	23.2
AVGO	269	18.1
PYPL	355	17.0
AESI	5	15.9

$\text{volume M\$} = \sum \text{midpoint des trades du ticker} \cdot n \text{ trades} = \text{nombre de transactions}$

Volume par secteur GICS :

secteur	n trades	volume M\$
Information Technology	14315	725.9
Financials	10981	520.7
Communication Services	5593	263.1
Consumer Discretionary	8309	259.7
Health Care	9495	229.7
Industrials	8476	196.8
Energy	3077	141.5
Consumer Staples	5137	138.5
Materials	2898	61.8
Real Estate	2729	53.6
Utilities	1274	30.5

Top déposants

Par volume estimé ($\sum$ midpoint) :


déposant	chambre	n trades	volume estimé M\$
Michael T. McCaul	house	10738	974.5
Rohit Khanna	house	30516	667.8
Diana Harshbarger	house	3124	464.5
Darrell E. Issa	house	20	250.5
RICHARD BLUMENTHAL	senate	1226	221.3
Josh Gottheimer	house	2942	209.4
Jefferson Shreve	house	631	191.7
Scott Franklin	house	68	182.1
Rick Scott	senate	266	167.2
Nancy Pelosi	house	147	139.6
Suzan K. DelBene	house	406	125.9
Kelly Loeffler	senate	329	120.9
David H McCormick	senate	293	69.0
Scott H. Peters	house	334	64.6
Kevin Hern	house	760	60.1

$\text{volume estimé M\$} = \sum \text{midpoint des transactions du déposant} \cdot n \text{ trades} = \text{nombre de transactions}$

Par nombre de transactions — 320 déposants distincts, dont **206** avec ≥ 10 transactions (éligibles au backtest) et **150** actifs sur ≥ 3 années :

nom	total	dont OCR	OCR %	n années	1re année	dern. année
Rohit Khanna	30862	30862	100	8	2019	2026
Michael T. McCaul	10850	10850	100	7	2020	2026
Diana Harshbarger	3515	3514	100	4	2021	2026
Josh Gottheimer	2942	0	0	8	2019	2026
Gilbert Cisneros	2153	0	0	4	2019	2026
David P. Roe	1686	1686	100	1	2020	2020
Lisa McClain	1532	109	7	3	2024	2026
Thomas H Tuberville	1369	0	0	5	2021	2025
Daniel Goldman	1291	0	0	2	2023	2025
RICHARD BLUMENTHAL	1232	1232	100	8	2019	2026
Thomas R Carper	923	0	0	6	2019	2024
Susie Lee	857	0	0	8	2019	2026
Donald Sternoff Beyer	822	0	0	8	2019	2026
Kathy Manning	803	0	0	5	2021	2025
JOHN BOOZMAN	768	379	49	8	2019	2026
Thomas Suozzi	765	20	3	9	2017	2026
Kevin Hern	760	0	0	8	2019	2026
Alan S. Lowenthal	676	0	0	4	2019	2022
Lois Frankel	656	0	0	5	2019	2023
Mark Green	653	0	0	6	2020	2025

total = nb transactions · dont OCR / OCR % = part scannée · n années = années actives · 1re/dern. année = première/dernière année de transaction



Devenir des achats à +12 mois (revente vs fermeture forcée, pour la stratégie)

Pour chaque achat (avec ticker), on suit la position : est-elle **revendue par le même membre sur le même ticker dans les 12 mois** (l'horizon de fermeture forcée de la stratégie) ? L'appariement se fait sur la **date de divulgation** — ce que la stratégie peut observer. Les achats divulgués il y a **moins de 12 mois** (après 2025-06-25) n'ont pas assez de recul pour juger : marqués *trop récents* et exclus des taux.

chambre	achats (avec ticker)	trop récents	observables	revendu ≤12m	revendu ≤12m %	fermé de force	fermé de force +12m %
house	34698	2509	32189	23256	72.2	8933	27.8
senate	2468	236	2232	1078	48.3	1154	51.7

Par sous-corpus :

sous-corpus	achats (avec ticker)	trop récents	observables	revendu ≤12m	revendu ≤12m %	fermé de force	fermé de force +12m %
House électronique	14010	1764	12246	6340	51.8	5906	48.2
House OCR	20688	745	19943	16916	84.8	3027	15.2
Sénat électronique	2301	231	2070	988	47.7	1082	52.3
Sénat OCR	167	5	162	90	55.6	72	44.4

achats (avec ticker) · trop récents = <12 mois de recul depuis la divulgation (indéterminé, hors dénominateur) · observables = achats – trop récents · revendu ≤12m = une vente du même ticker divulguée dans les 12 mois · fermé de force +12m = aucune vente sous 12 mois → la stratégie clôt la position · les deux % portent sur les observables

6. Complétude vs Quiver (vérité-terrain externe)

Section clé. Quiver est un fournisseur commercial des mêmes données = notre **juge externe**. But : montrer qu'on a **au moins tout ce que Quiver a** (Quiver ⊆ nous), qu'on est même **plus complet**, et que nos différences ne sont **pas des erreurs**. On procède comme un **entonnoir, de stricteesse croissante** : Niveau 1 → 2 → 3. Chiffres recalculés par `common/quiver_diagnosis.py`, **jamais réinjectés**.

6.1 Méthode

Chaque transaction est confrontée à Quiver par une clé normalisée, en **trois niveaux de plus en plus stricts** : **N1** a-t-on le trade ? (sans la date, §6.2) → **N2** le même trade à la même date ? (§6.3) → **N3** qui corrige quoi ? (§6.5).

élément	définition
univers comparé	tous les trades Quiver Filed ∈ 2020–2026 (notre fenêtre de scrape)
clé d'appariement	(bioguide, ticker normalisé, sens) — + date au Niveau 2, sans date au Niveau 1
normalisation ticker	MAJ + trim ; rejette [vide, NAN, NONE, --] ; retire PUT / CALL ; . / - → □
normalisation sens	1re lettre p/s/e → Purchase / Sale / Exchange

Périmètre : le corpus FINAL déduplicué cross-année (89 852 transactions uniques, cf. §1 « Construction & validation du corpus »).

Réf. : `house/quiver.py` (norm_ticker, norm_sense), `common/quiver_diagnosis.py`.

6.2 Niveau 1 — A-t-on le trade ? (sans la date)

On compare des **combinaisons** (membre, action, sens), en **ignorant volontairement la date ET le nombre** : (Khanna, AAPL, Achat) compte pour **un**, qu'il l'ait acheté 1 fois ou 50. La question est donc grossière **exprès** : « a-t-on raté une combinaison **ENTIÈRE** que Quiver connaît ? » — le comptage trade par trade, c'est le Niveau 2 (§6.3).

On retrouve **93.9 % (House)** et **91.5 % (Sénat)** des combinaisons Quiver. Le **trou coté** est minuscule (22 House / 0 Sénat) — c'est une **borne haute (sans date)** ; au trade près (§6.5), seule une partie sont de vrais trous confirmés. Le reste du résidu est récupérable ou hors périmètre :

chambre	trades Quiver (fenêtre)	qu'on a	inclusion %	résidu	récupérable (OCR)	hors périmètre	trou coté (borne haute)
house	17481	16416	93.9	1065	955	88	22
senate	2587	2366	91.5	221	0	221	0

Le **résidu** se lit ainsi : **récupérable (OCR)** = membre lu en OCR papier dont on a capté le trade mais **pas résolu le ticker** (nom lisible → récupérable, cf. note ; sinon non-coté déguisé/charabia OCR) · **hors périmètre** = « ticker » Quiver non-coté (CUSIP/fragment) + trade sous un ticker d'échange combiné (« PFE VTRS » couvre PFE) + membre de l'autre chambre polluant le cache · **trou coté (borne haute)** = combos manquants au niveau ticker (sans date) ; au trade près (§6.5), seul un sous-ensemble (NOTRE_MANQUE) sont de vrais trous confirmés.

Note : une passe de **récupération nom→ticker** (vérifiée, **hors Quiver**, appliquée à la lecture — golden intact) a rendu leur ticker à **289 trades** d'actions que l'OCR/LLM avaient laissés vides (faux négatifs, ex. NEENAH PAPER→NP, TENCENT→TCEHY). Le « récupérable OCR » restant est surtout des **non-cotés déguisés** (préférentielles, fonds) et du **charabia OCR**, non mappables.

Bilan net (au trade près) — actions cotées qu'on a et que Quiver n'a PAS vs **vrais trous** (NOTRE_MANQUE = le sous-ensemble des « trous borne haute » ci-dessus réellement absents au trade près) → on est un **sur-ensemble** de Quiver :

chambre	actions qu'on a en +	vrais trous	solde net
house	6265	10	6255
senate	680	3	677

6.3 Niveau 2 — Le même trade, à la même date ?

On descend au trade près. Comme un membre peut trader le même titre **plusieurs fois**, on ne demande PAS « ma date est-elle dans l'ensemble Quiver ? » : on **apparie 1-à-1** nos trades à ceux de Quiver, à l'intérieur de chaque (membre, ticker, sens). Exemple :

Khanna, AAPL, Achat – dates :
NOUS : 08-jan-2020 · 13-fév-2020 · 01-juin-2020 · 10-mars-2023
QUIVER : 08-jan-2020 · 12-fév-2020 · 10-mars-2023

Étape 1 – on retire les dates IDENTIQUES (une par une) :
08-jan ↔ 08-jan et 10-mars-2023 ↔ 10-mars-2023 → 2 « apparié exact »
(le trade 2023 s'apparie à SON 2023, jamais à un 2020)

Étape 2 – on apparie les RESTES au plus proche (plafond 90 j) :
13-fév (nous) ↔ 12-fév (Quiver) = 1 j → « apparié proche » (≤ 10 j, bruit de date)
01-juin (nous) : aucun reste Quiver à < 90 j → « NOUS-SEUL » (trade en plus)

Deux garde-fous répondent à « comment gérer qu'un membre ait plusieurs trades » : l'appariement **1-à-1 respecte les quantités** (si on a 50 trades et Quiver 40, ≥ **10 restent forcément en « nous-seul »**) ; le **plafond de 90 j + l'ancrage au dépôt** empêchent mécaniquement de confondre un trade 2020 et un trade 2023. Chaque trade tombe alors dans **une** catégorie :

chambre	apparié exact	apparié proche (≤10j)	candidat écart	dont même déclaration	nous-seul	quiver-seul	candidat %
house	43309	605	1629	288	21891	4646	2.4
senate	4361	0	0	0	1202	385	0.0

apparié exact = même date · apparié proche = écart des dates de TRANSACTION ≤ 10 j (bruit/convention de date Quiver, même trade) · candidat écart = paire à 10–90 j, à inspecter (§6.4) · dont même déclaration = les deux trades viennent du MÊME formulaire de déclaration (PTR) — notre *disclosure* ≈ Filed Quiver ≤ 10 j → même trade, donc l'écart de date est un vrai désaccord (seul signal fort) · nous-seul = Quiver n'a PAS le trade (on est plus complet) · quiver-seul = on a raté.

Pourquoi les chiffres semblent contredire le §6.2 : c'est le niveau de stricteesse. Au Niveau 1 (sans date), le trou coté (borne haute) est 22/0 ; au Niveau 2 (trade + date), on compte 21891 trades « nous-seul » — normal, on trade plus souvent que Quiver ne capte au trade près. **Les deux disent la même chose : on est plus complet.**

6.4 Les candidats d'écart de date (même déclaration)

Les **seuls** candidats honnêtes d'erreur de date = les paires issues de la **même déclaration (PTR)** (288 House / 0 Sénat). Prudence : un petit delta peut être une **convention de date Quiver**, pas notre erreur. **Le vrai contrôle des dates reste l'audit PDF (§3)**, pas Quiver. `doc_id` = pièce consultable :

chambre	déposant	ticker	sens	notre date	date Quiver	delta (j)	doc_id
house	Rohit Khanna	AMT	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	NKE	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	LMT	Sale	2020-04-24	2020-04-13	11	8217213
house	Rohit Khanna	NOW	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	UNP	Sale	2025-04-04	2025-04-15	11	8220906
house	Rohit Khanna	WST	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	GLW	Sale	2020-09-02	2020-09-13	11	8217686
house	Rohit Khanna	MSCI	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	IDXX	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	GPN	Sale	2025-04-26	2025-04-15	11	8220906
house	Rohit Khanna	VRSK	Sale	2023-10-26	2023-11-06	11	8220039
house	Rohit Khanna	CDNS	Sale	2023-10-26	2023-11-06	11	8220039

(Top 12 par delta croissant ; les 288 candidats sont dans `quiver_validation/candidats_ecart_date_meme_depot.csv`.)

6.5 Niveau 3 — Que reste-t-il à corriger ?

On a vérifié l'existence (§6.2) et la date (§6.3). Restent deux choses : les autres champs des trades qu'on partage avec Quiver (sens, montant), et la liste de ce qui est vraiment à corriger.

Autres champs — sens & montant. Pour les trades qu'on a tous les deux (mêmes membre + ticker + date), est-on d'accord sur le sens (achat/vente) et le montant ?

chambre	n paires	accord sens %	accord montant %
house	52376	95.8	93.1
senate	4932	99.8	99.7

on apparie les cellules (membre, ticker, date) présentes des DEUX côtés ; un désaccord = vraie erreur d'extraction, listée dans `desaccord_champ_*.csv`.*

La to-do (à corriger). Un seul chiffre est dur — les vrais trous NOTRE_MANQUE (le résidu après tous les filtres) ; les deux autres sont des bornes hautes ensemblistes = des listes à revoir cas par cas dans `docs/quiver_validation/`, pas des taux d'erreur :

à corriger	House	Sénat	nature	annexe
vrais trous cotés (NOTRE_MANQUE)	10	3	DUR — vrai trou confirmé au trade près (le sous-ensemble des « trous borne haute » du §6.2 réellement absents)	notre_manque_*
lignes OCR papier (MANQUANT_PAPIER)	1048	0	borne haute — trades Quiver de déposants qu'on OCR, absents de nos clés exactes	manquant_papier_*
tickers à revoir (ECART_TICKER)	5393	71	borne haute — autre ticker ce jour-là (gonflée par la multiplicité, PAS un taux d'erreur)	ecart_ticker_*

Qui ? — les déposants derrière les vrais trous (NOTRE_MANQUE), à investiguer :

chambre	bioguide	nom	n trous
house	B001327	Rob Bresnahan	5
house	P000197	Nancy Pelosi	2
house	J000307	John James	1
house	S000168	Maria Elvira Salazar	1
house	W000797	Debbie Wasserman Schultz	1
senate	M001198	Roger W Marshall	3

6.6 Annexe

Les tables figées 07c/07g/07h reproduisent la même comparaison en exact-date (elles sous-comptent, cf. §6.3) ; conservées pour la lignée/régression, non re-rendues ici. Les autres figées (07/07b/07d/07e/07f/06d) sont des sorties historiques du pipeline.

Profil des clusters de scan (House OCR) — pourquoi le manuscrit est exclu (A = tapé droit, B = tapé tourné, C = manuscrit) :

cluster	n lignes	n docs	date plausible %	ticker %	Quiver a le trade %
A_tape_droit	5957	59	99.6	84.5	88.0
B_tape_tourne	42125	295	94.7	83.5	77.9
C_manuscrit	858	80	97.4	89.0	35.3

date plausible % / ticker % = qualité INTERNE (sans Quiver) · Quiver a le trade % = part de nos trades cotés que Quiver possède AUSSI (appariée sur membre+ticker+sens, date ou non). Sur le manuscrit (C), la qualité interne reste haute mais Quiver a le trade % s'effondre (ticker/identité mal lus, ou Quiver mince sur le papier) → faute de pouvoir le confirmer contre la vérité-terrain, on l'exclut par défaut (conservateur).

Listes actionnables complètes (ligne à ligne) → docs/quiver_validation/ (ecart_ticker_, notre_manque_, manquant_papier_, desaccord_champ_[typé], on_est_plus_complet_, quiver_non_cote_, candidats_ecart_date_meme_depot). Hors golden.