

Méthode & légende

- Chaque point a été tranché **après lecture du code réel** (le code fait autorité) en trois catégories :
- **[ERREUR]** / **[À COMPLÉTER]** — concerne le **rapport** (RAPPORT_FINAL_V2) : soit une *vraie inexactitude*, soit un *manque de détail* à compléter.
 - **[CODE]** — concerne le **code** : duplication, module mort/legacy, ou asymétrie House/Sénat (avec verdict « vrai problème » vs « justifié »).
 - **[EXPLICATION]** — **explication** (Partie C) : c’est correct, il fallait juste l’expliquer.

Honnêteté méthodologique : cette analyse s’appuie sur 3 sondes automatiques *re-vérifiées à la main*. Une erreur de sonde a été écartée (elle prétendait que `senate/ticker_resolve.py` était inutilisé ; il est bien appelé par `senate/fusion.py:84`). Rien n’est appliqué ici : c’est une revue.

Catégorie	Nombre de points
[ERREUR] Rapport — vraies inexactitudes	2
[À COMPLÉTER] Rapport — à détailler	7
[CODE] Code — duplications / legacy / asymétries	6
[EXPLICATION] Explications (Partie C)	15

1 Partie A — le rapport : erreurs & améliorations

1.1 A.1 **[ERREUR]** §3.3 « la numérotation est l’enchaînement » — inexact

Le tableau §3.3 présente une convention de préfixes (03, 04, ..., 07, 08) « unifiée » et « ordonnée comme le pipeline ». **C’est faux pour les deux chambres** :

- **03/04/08 n’existent que côté Chambre** (le Sénat n’a ni index téléchargé, ni manifeste, ni cross-check « semaine 1 »).
- **L’ordre des numéros ≠ l’ordre d’exécution**. Côté Chambre, `run_year` écrit `08_crosscheck` avant `07_quiver`, et `06_FINAL` bien après (dans `run_ocr_year`). Côté Sénat, `07` et `07c-f` (Quiver sur le digital) sont écrits avant `06b` (OCR) et `06_FINAL` (fusion) — donc `06b < 07` numériquement, mais `07` précède `06b` à l’exécution.

Verdict — *vraie inexactitude*. Reformuler : les préfixes sont des **étiquettes de rôle** (pas un ordre strict), House-centrées ; donner la **séquence réelle par chambre**. `house/digital.py:run_year` · `house/ocr.py:run_ocr_year` · `senate/digital.py:run_year` · `senate/fusion.py:main`.

1.2 A.2 **[À COMPLÉTER]** §3.2 — l’étape d’acquisition + tri digital/scanné manque

Le schéma démarre aux boîtes `house.digital/senate.digital`. Or la *vraie* première phase — celle que tu décrivais — est **au-dessus** : récupérer l’index/la liste, puis décider digital vs scanné.

- **Chambre** : House Clerk publie un **ZIP par année** → index XML `03_ptr_index` → on télécharge chaque PDF → on l’**ouvre** pour trancher lisible/scanné → manifeste `04_`.
- **Sénat** : `accept_agreement` (CSRF) → `fetch_ptr_list` renvoie une **liste** où chaque entrée porte déjà `kind=ptr` (électronique) ou `paper` (scanné).

Verdict — *amélioration structurelle réelle* — l’étape existe dans le code mais pas dans le schéma.

Ajouter une boîte « 0. Acquisition & tri » au-dessus des boîtes 1/3. `house/digital.py:load_ptr_index, build_manifest · senate/digital.py:fetch_ptr_list`.

1.3 A.3 [ERREUR] §3.2 — « scans » (Chambre) vs « PTR papier » (Sénat)

Les boîtes OCR nomment la même chose de deux façons (un PTR papier scanné). Seul le *format image* diffère (PDF côté Chambre, .gif côté Sénat).

Verdict — incohérence de vocabulaire — harmoniser (« PTR papier scanné → Vision » des deux côtés).

1.4 A.4–A.7 [À COMPLÉTER] compléments de clarté (déjà listés au fil de la revue)

Repris intégralement de docs/RAPPORT_V2_A_CORRIGER.md :

- Définir `bioguide_id` (utilisé partout, jamais défini depuis le retrait des encadrés).
- Détailler §2 l'acquisition (Chambre ZIP→XML→DocID→PDF ; Sénat portail→liste→kind).
- Expliquer l'asymétrie des tables House/Sénat (pourquoi 03/04/08 côté Chambre ; cf. B.3 pour 07 vs 07c-f).
- §4.6 dire « même moteur Vision qu'en §4.5, sans skew ».
- §4.3 la clé / `occurrence_index` apparaissent *avant* leur explication (§4.8) → ajouter un renvoi.
- Gloses pour un lecteur non spécialiste : ETF/GICS/SPDR, « couverture » (= taux de remplissage), « taux de parsing », « passe LLM », YAML.

2 Partie B — le code : duplications, legacy & asymétries

Verdicts honnêtes, vérifiés par `grep` d'imports/usages réels.

2.1 B.1 [CODE] duplication — l'OCR Vision en trois exemplaires, le module « partagé » inutilisé

Trois implémentations du même moteur Vision coexistent : `congress_core/vision_ocr.py` (210 l., `VisionExtractor+des skew`), `house/ocr.py` (ses *propres* `detect_rotation`, `pdf_to_b64_images`, `extract_from_pdf`, l. 205-300), et `senate/ocr_engine.py` (376 l., moteur figé Q1). Vérifié : `vision_ocr/VisionExtractor` n'est importé **nette part** en prod (`house/` `senate/` `pipeline`) — **uniquement** par `tests/regression/{test_vision_sha, test_incremental}`. Donc la « source unique » `congress_core/vision_ocr.py` n'est, en pratique, **utilisée par personne** ; chaque chambre roule sa propre copie.

Verdict — vrai problème d'organisation. Deux options : (a) brancher la prod (*House*, idéalement *Sénat*) sur `congress_core/vision_ocr.py` et supprimer les copies ; ou (b) assumer ce module comme un « contrat de référence testé » et le documenter comme tel (sinon il ressemble à du code mort).

2.2 B.2 [CODE] duplication — `sector_enrich` en double

Le même rôle (`ticker` → secteur GICS → ETF SPDR) est implémenté **deux fois** : `congress_core/sector_enrich.py` (216 l., importé par la Chambre, `house/ocr.py:513`) et `senate/sector_enrich.py` (416 l., importé par le Sénat, `senate/fusion.py:30,85`). Logique *très* proche (même mapping GICS→ETF), implémentations *distinctes* (la version Sénat est plus étoffée).

Verdict — candidat sérieux à consolidation (un seul module paramétré) — mais **vérifier l'équivalence** avant de fusionner (ce ne sont pas des copies octet-à-octet).

2.3 B.3 [CODE] asymétrie — la validation Quiver du Sénat est plus riche que celle de la Chambre

C'est la « grosse différence entre les tables » que tu as remarquée. Le Sénat produit 07c (réconciliation transaction-niveau), 07d (**accord de champs** sens/date/montant), 07e (`ticker` par sénateur),

07f (only_quiver) et **déduplique les amendements**. La Chambre ne produit que 07 (deltas par déposant) + 07b (manquants) : **pas** d'accord de champs, pas de dedup d'amendements.

| Verdict — *asymétrie réelle. Soit **aligner** la Chambre sur le standard Sénat (07c-f), soit **documenter** pourquoi la clé « brute » Chambre s'en passe volontairement. `house/digital.py:validate_quiver` vs `senate/quiver_audit.py:reconcile`.*

2.4 B.4 [CODE] legacy / redondance — modules hors pipeline

`congress_core/pipeline.py:build_steps` n'enchaîne que 6 étapes (`house.digital`, `house.ocr`, `senate.digital`, `senate.ocr`, `senate.fusion`, `enrich_tenure`). **Hors pipeline** : `senate/census_probe.py` (Phase 0), `senate/revalidate_quiver.py` (**réécrit** les 07c-f déjà produits par `senate/digital.py` → **redondant**), `house/echantillon.py` (pilote OCR). Plus des artefacts de pilote/cache (`_ocr_echantillon*`, `_pilote_ocr`, `_scan_census_547`, `_paper_index_*`).

| Verdict — *outils ponctuels / legacy — à **archiver** ou marquer explicitement « hors pipeline ». `revalidate_quiver` mérite une décision (doublet d'écriture).*

2.5 B.5 [CODE] asymétrie de style — fusion « inline » (Chambre) vs modules dédiés (Sénat)

La Chambre **fusionne** + **valide** dans `house/ocr.py` (logique inline); le Sénat a des modules **dédiés** (`fusion.py`, `quiver_audit.py`).

| Verdict — *surtout **historique** (la Chambre a grossi « en place », le Sénat a été refondu en modules); pas un bug, mais une incohérence de style à uniformiser un jour.*

2.6 B.6 [CODE] mises au point (ce qui *n'est pas* un problème)

- `senate/ticker_resolve.py` est utilisé (`senate/fusion.py:84`) → **pas** legacy. La « passe LLM » ticker existe en 2 copies (`house/ocr.py:llm_resolve_tickers` et `senate/ticker_resolve.py`), toutes deux *actives* → duplication *mineure*.
- `senate/identity.py` (195 l.) duplique en partie `congress_core/identity.py` (290 l.), mais c'est **justifié** : schéma Sénat propre + enrichissement complet, autonome.

3 Partie C — explications (correct; il fallait juste l'expliquer)

Reprise structurée de `docs/RAPPORT_V2_EXPLICATIONS.md`. Rien à corriger ici.

3.1 Acquisition & sources

[EXPLICATION] eFD = *Electronic Financial Disclosure*, le **site public du Sénat** (`efdsearch.senate.gov`) — l'équivalent du site du *House Clerk*.

[EXPLICATION] **paper** / **.gif** / **OCR** = le **même** document sous 3 angles : déposé sur **papier** (nature) → servi en **.gif** (format image) → lu par **OCR** (technique). Pas trois choses.

[EXPLICATION] **Pourquoi un 04_ côté Chambre et pas Sénat ?** Côté Chambre il faut **ouvrir le PDF pour décider** lisible/scanné (`bool(text.strip())`) → verdict *calculé* (04_). Au Sénat la liste eFD **donne déjà** le type (`kind ptr/paper`) → rien à calculer.

3.2 Identité

[EXPLICATION] `bioguide_id` = identifiant unique officiel d'un parlementaire (P000197 = Pelosi), calculé **au matching**. Le référentiel charge les élus **actuels ET historiques** → même un ancien membre est retrouvé.

[EXPLICATION] **YAML** = un format de fichier texte simple (clé: valeur); « **embarqués** » = des copies locales dans le dépôt, servant de **repli hors-ligne** si le téléchargement échoue.

[EXPLICATION] **Variantes de noms** (indexées en plus de nom/prénom, pour matcher malgré une graphie différente) : *second prénom* (« John **Quincy** Adams ») ; *premier mot du nom officiel* (prénom « Jim », nom officiel « **James** E. Banks ») ; *dernier mot d'un nom composé* (« **Van Taylor** » → « Taylor »).

[EXPLICATION] `make_matcher` = fabrique une fonction `match(nom,prénom)` qui essaie, dans l'ordre : **override manuel** (1 cas figé) → **correspondance exacte** (surnoms compris) → **repli par nom de famille unique**.

[EXPLICATION] `years_in_office` calculé après : l'année de 1^{re} entrée est calculée au chargement du référentiel ; seule la *soustraction* par transaction est différée à la dernière étape (`enrich_tenure`), en *append octet-préservant*, pour ne pas perturber les schémas d'assemblage.

[EXPLICATION] **Chambre fixée par le pipeline** : `house/senate` n'est *pas* deviné depuis le nom — chaque pipeline traite ses documents et passe `chamber=...`. La désambiguïsation par chambre ne sert que pour les cas de même nom (côté Sénat).

3.3 Dédup, parsing, enrichissement

[EXPLICATION] **Clé naturelle + occurrence_index** : la **clé** (7 champs, sans ticker) repère les **doublons entre documents** (amendement re-déposé). L'`occurrence_index` numérote les répétitions *légitimes* dans un même dépôt (ex. la même vente via 3 comptes) pour ne pas les écraser → on déduplique sur le **couple** (clé, occurrence).

[EXPLICATION] « **taux de parsing 99–100 %** » = parmi les PDF *lisibles*, la part dont on a réussi à extraire les transactions (le reste → `05_parse_failures`).

[EXPLICATION] **Ticker en 3 voies** (Chambre et Sénat) : **explicite** (symbole imprimé) → **dictionnaire** (annuaire `nom→ticker` bâti sur les lignes déjà tickées) → **passe LLM** (Claude propose le symbole depuis le nom, filtré aux actions, caché).

[EXPLICATION] « **couverture** » = **taux de remplissage** = part des lignes où le champ est renseigné. **Jamais 100 %** : les actifs *non cotés* (obligations, munis) n'ont *légitimement* ni ticker ni secteur.

[EXPLICATION] **Secteur GICS → ETF SPDR** : une **action** a un **secteur** (GICS = 11 grands domaines : Tech, Santé...) ; un **ETF** = un fonds qui suit *tout* un secteur ; les **SPDR Select Sector** = 1 ETF par secteur (XLK=Tech, XLE=Énergie...). On traduit **ticker** → **secteur** → **ETF** (NVDA → Technologie → XLK) parce que la **version 2** de la stratégie Ramify trade des **ETF sectoriels**, pas les actions individuelles.

[EXPLICATION] **OCR Sénat = même moteur que House** (Vision, `tool_use` forcé, cache `prompt_sha`) **sans deskew** (les .gif Sénat sont droits ; le deskew redressait les scans *couchés* de la Chambre).