

Congress Trading Signal

État d'avancement & checklist structurée — pipeline *data* House & Sénat

25 juin 2026

1. Objectif et cadre du projet

But. Construire une stratégie systématique de *copy trading* qui réplique les transactions déclarées par les membres du Congrès américain (loi STOCK Act, 2012), puis la backtester sur le framework Ramify. Le projet se déroule en **4 semaines**, dont **2 entièrement consacrées à la donnée** (partie la plus critique : un backtest sur une donnée mal extraite ne vaut rien).

Où en est-on, en une phrase.

La **couche donnée** est largement construite et validée sur deux périmètres figés (House Q1 2025 et Sénat Q1 2025), étendue au **House digital 2020 → 2026**. Restent : l'OCR des scans à finir, l'enrichissement **secteur GICS → ETF** (non commencé), et **toute la partie stratégie + backtest** (semaines 3–4, non commencée).

Légende des statuts. **FAIT** fait et vérifié **EN COURS** commencé / partiel **À FAIRE** non commencé — hors périmètre actuel

2. Tableau de bord global

Bloc / livrable	Statut	Preuve / chiffre
<i>Semaine 1 — exploration, sourcing, architecture</i>		
Audit des sources & décision d'architecture	FAIT	House Clerk + Quiver + eFD audités ; 37 445 dépôts / 8 248 PTR recensés (2013–2026)
Téléchargement automatisé (House)	FAIT	PDF & index <code>ptr_index_{année}.csv</code> 2013–2026, 100 % succès
Pipeline d'extraction LLM (digital)	FAIT	Parsing PDF lisibles, rendement 99–100 %
Pipeline d'extraction LLM (OCR scans)	EN COURS	Infra Claude Vision validée ; <i>gate</i> de rigueur passé ; scaling partiel
<i>Semaine 2 — nettoyage, validation, table finale</i>		
Réconciliation tickers	EN COURS	Passe LLM nom→ticker : House 90 %, Sénat 67 % (le reste = actifs non cotés, par construction)
Normalisation noms / identité déclarant	FAIT	Rattachement BioGuideID 100 % (House & Sénat)
Déduplication & règles documentées	FAIT	Dédup <i>per-lot</i> canonique, règles écrites

Bloc / livrable	Statut	Preuve / chiffre
Validation qualité (dates, montants, couverture)	EN COURS	Validation Quiver honnête (nous $\geq$ Quiver) ; rapport qualité dédié à formaliser
Table finale — 12 champs garantis	EN COURS	10/12 champs OK ; 2 absents : <code>sector_gics</code> , <code>etf_proxy</code>
Métadonnées (chambre, parti, comités)	EN COURS	Présents via <i>congress-legislators</i> ; snapshot actuel , pas <i>point-in-time</i>
Mapping sectoriel GICS → ETF Ramify	À FAIRE	Aucune trace dans le code ; à construire (yf-nance/OpenBB)
Pipeline incrémental (mise à jour testée)	À FAIRE	Non démontré

Semaines 3-4 — stratégie & backtest

Stratégie V1 — actions directes	À FAIRE	Règle entrée/sortie spécifiée, non implémentée
Stratégie V2 — ETF sectoriels	À FAIRE	Dépend du mapping GICS
Sélection annuelle des K congressmen	À FAIRE	Critère (Sharpe / comités) à coder
Backtest sur framework Ramify	À FAIRE	Non commencé

3. Checklist détaillée

3.1 Semaine 1 — exploration, sourcing, architecture

FAIT **Cartographie des sources primaires.** House via `disclosures-clerk.house.gov` (PDF + index XML) ; Sénat via `efts.senate.gov` (PDF souvent scannés) ; agrégateurs Quiver & Capitol Trades évalués en *fallback/validation*.

FAIT **Audit de couverture.** 14 années (2013–2026) : **37 445 dépôts**, **8 248 PTR**. Quiver : 113 673 transactions, 2012–2026 (licence non commerciale $\Rightarrow$ validation/R&D uniquement).

FAIT **Décision d'architecture documentée.** Ordre de priorité : (1) House Clerk source primaire, (2) Sénat eFD, (3) Quiver = *fallback/validation* 2014+, (4) Capitol Trades = vérification manuelle.

FAIT **Téléchargement automatisé House** (PDF + index par année), stockage organisé par source/année/chambre, jamais re-téléchargé ensuite.

FAIT **Pipeline LLM — volet digital.** Extraction structurée (*tool_use*, sans échec silencieux) : déclarant, dates, ticker, type d'opération, fourchette de montant, type d'actif. Convention montant = **midpoint** définie.

EN COURS **Pipeline LLM — volet OCR (scans).** Claude Vision sur formulaires scannés. *Census* visuel complet des **547 PDF** scannés (3 clusters : A tapé droit 13,5 %, B tapé tourné 58,9 %, C manuscrit 27,6 %). *Gate* de validation passé (précision ticker A 93 % / B 89 %). *Reste* : finir le scaling et fusionner proprement dans les tables finales.

À FAIRE **Sénat historique.** eFD bloqué par CSRF + Akamai ; 52 sénateurs hors fenêtre de rétention. Q1 2025 obtenu, mais l'historique reste à débloquent (Playwright).

3.2 Semaine 2 — nettoyage, validation, table finale

EN COURS **Réconciliation tickers.** Passe LLM nom $\rightarrow$ ticker (cache versionné) : House 46 % $\rightarrow$ 90 %, Sénat 67 %. Les manquants restants sont **conservés avec flag** (`ticker_source`), pas jetés — décision

documentée. Quiver ne sert qu'à *auditer*, jamais à remplir.

FAIT **Identité des déclarants.** Normalisation & rattachement BioGuideID **100 %** (noms composés, suffixes, surnoms gérés); collisions homonymes résolues.

FAIT **Déduplication.** Canonique *per-lot* (préserve les lots identiques intra-PTR via `occurrence_index`); dédup inter-sources seulement.

EN COURS **Validation qualité systématique.** Méthode Quiver **honnête** (comparaison *per-lot*, par BioGuideID, exclusion des déposants papier des deux côtés) : **nous** $\geq$ **Quiver** sur $\sim 95\%$ des déclarants/an, vrais-absents 0,03 %, tous expliqués. *Reste* : formaliser le **rapport qualité synthétique** (cohérence `disclosure_date > transaction_date`, délai légal 45j, distribution des montants, couverture par congressman, taux de positions sans sortie).

EN COURS **Table finale — 12 champs garantis.** 10/12 présents et bien remplis sur les pilotes figés (cf. §5); `sector_gics` et `etf_proxy` absents.

EN COURS **Métadonnées de sélection.** `committee_membership` + `committees_key_flag` présents via *unitedstates/congress-legislators*. **Limite** : snapshot *actuel*, pas d'historique *point-in-time* (nécessaire pour un backtest historique fidèle); parti / années-en-poste à compléter via `api.congress.gov`.

À FAIRE **Mapping sectoriel GICS $\rightarrow$ ETF.** Pour chaque ticker : secteur GICS dominant (yfinance / OpenBB) puis ETF sectoriel cible de l'univers Ramify. À trancher : univers d'ETF cibles; gestion des entreprises multi-secteurs.

À FAIRE **Pipeline incrémental.** Mise à jour simulée sans relancer l'extraction complète; choix du format de stockage final (CSV / SQLite / Parquet).

3.3 Semaines 3–4 — stratégie & backtest

Spécification cible (rappel, à implémenter) :

À FAIRE **Entrée/sortie.** Entrée à la `disclosure_date` d'un *Purchase*; sortie à la `disclosure_date` du *Sale* du même déclarant sur le même ticker, sinon sortie forcée à +12 mois.

À FAIRE **Version 1 — actions directes** (signal brut, track records individuels).

À FAIRE **Version 2 — ETF sectoriels** (même logique, instrument substitué via le mapping GICS).

À FAIRE **Sélection annuelle des K congressmen** ($K \in [4, 10]$, min. 10 trades, critère robuste = Sharpe / alpha vs SPX; filtre comités Finance/Défense/Renseignement sur $\geq$ la moitié des K).

À FAIRE **Backtest annoté sur le framework Ramify**, V1 puis V2.

4. Couverture de la donnée (concret)

Année	House digital	House OCR (scans)	Sénat
2013–2015	À FAIRE	À FAIRE	À FAIRE
2016–2019	À FAIRE (lot 2)	À FAIRE	À FAIRE
2020	FAIT 6 886	EN COURS	À FAIRE
2021	FAIT 5 457	EN COURS	À FAIRE
2022	FAIT 3 601	EN COURS	À FAIRE
2023	FAIT 4 161	EN COURS	À FAIRE
2024	FAIT 2 694	EN COURS	À FAIRE
2025	FAIT 7 577	EN COURS	EN COURS Q1
2026	FAIT 2 300	EN COURS	À FAIRE
Total digital 2020–2026 32 676 transactions, rendement parse 99–100 %			

Deux versions figées de référence (qualité validée, OCR inclus) :

- **House Q1 2025** (0 HOUSE/2025_test/) : **2 272** transactions, 56 déclarants — pilote fiable, validé vs Quiver (électronique 99,9 %).
- **Sénat Q1 2025** (1 SENAT/senat_2025_test/) : **283** transactions, 17 sénateurs — identité 100 %, nous $\geq$ Quiver, 4 rapports papier en *backlog* OCR.

Remplissage des 12 champs obligatoires (pilotes figés)

Champ obligatoire	House Q1 2025	Sénat Q1 2025
declarant_name	100 %	100 %
chamber	100 %	100 %
party	100 %	100 %
committee_membership	90 %	76 %
transaction_date	100 %	100 %
disclosure_date	100 %	100 %
ticker	90 %	67 %
sector_gics	absent	absent
etf_proxy	absent	absent
operation_type	100 %	100 %
amount_midpoint	100 %	100 %
asset_type	97 %	100 %

Les champs à 100 % satisfont déjà l'exigence « sans valeurs manquantes ». Le `ticker` et `committee_membership` en deçà de 100 % correspondent à des actifs non cotés (obligations, fonds) ou à des membres hors snapshot — **flaggés**, pas perdus. Les deux champs **absents** (`sector_gics`, `etf_proxy`) sont le verrou principal restant de la table finale.

5. Chemin critique — ce qui reste, par priorité

1. **Mapping sectoriel GICS → ETF** (**À FAIRE**) — *bloquant pour la table finale ET la V2*. Ajouter `sector_gics` + `etf_proxy`; trancher l'univers ETF Ramify et le cas multi-secteurs.
2. **Finir l'OCR des scans** (**EN COURS**) — scaler le pipeline gâté sur les 547 PDF (cluster C manuscrit = point dur), fusionner dans les tables `_FINAL` avec validation stabilité + spot-check.
3. **Rapport qualité synthétique** (**EN COURS**) — graphiques & stats descriptives (cohérence dates, délai 45j, distribution montants, couverture/congressman, taux sans sortie).
4. **Métadonnées point-in-time** (**EN COURS**) — historique d'appartenance aux comités via `api.congress.gov` pour un backtest fidèle.
5. **Pipeline incrémental + format de stockage final** (**À FAIRE**).
6. **Étendre la couverture** (**À FAIRE**) — House digital 2013–2019 ; Sénat multi-années (débloquer eFD).
7. **Stratégie V1, puis V2, puis sélection K, puis backtest Ramify** (**À FAIRE**) — semaines 3–4.

6. Risques & points durs

- **OCR manuscrit (cluster C, 27,6 %)**. Concentré 2020–2021 ; Quiver y est mince $\Rightarrow$ validation = stabilité run-à-run + spot-check manuel, pas de vérité-terrain externe.
- **Comités non point-in-time**. Le snapshot actuel fausse un filtre de sélection appliqué à des années passées.

- **Licence Quiver non commerciale.** Usage R&D / validation uniquement, jamais comme source de remplissage.
- **Sénat historique.** CSRF + Akamai non contournés ; 52 sénateurs hors fenêtre de rétention (données irrécouvrables).
- **Multi-secteurs en V2.** Une entreprise à cheval sur plusieurs GICS demande une règle explicite de proxy ETF.
- **Pièges de backtest** (De Prado) : ne pas surinterpréter une sélection sur performance passée (overfitting), peu d'observations par personne (Grinold–Kahn).

Document généré automatiquement à partir de l'état réel des dossiers 0 HOUSE/ et 1 SENAT/ (comptages de lignes, taux de remplissage, dashboards de statut) croisé avec le cahier des charges des 4 semaines. Les statuts reflètent le contenu du dépôt à la date ci-dessus.